

Índice general

1	De dónde venimos: dos ortogonalidades, una identidad guardada	2
2	El triángulo rectángulo de la bondad de ajuste	3
3	Pitágoras: la varianza se descompone	4
4	¿Qué ajuste es mejor: el de arriba o el de abajo?	6
5	El coeficiente de determinación: $R^2 = \cos^2 \theta$	7
6	Interpretando R^2 : casos extremos	9
7	Ejemplo numérico: STC, SEC, SRC	9
8	Una advertencia: el nombre <i>suma explicada</i> es engañoso	10
9	En el caso de la regresión simple: $R^2 = \rho_{xy}^2$	12
10	Regresión lineal simple: STC, SEC y SRC con áreas	14
11	Recapitulación y guiño a la lección siguiente	15

Lección 8. Bondad de ajuste: de Pitágoras a R^2

Marcos Bujosa

5 de agosto de 2026

Resumen

Las mismas dos ortogonalidades de la lección 7, vistas ahora bajo el teorema de Pitágoras, descomponen la varianza de $\mathbf{y}$ en la del ajuste más la del error. El cociente resultante es el coseno al cuadrado del ángulo entre los datos y su ajuste, ambos en desviaciones: el coeficiente de determinación R^2 .

“Un triángulo rectángulo escondido en cada regresión.”

- ([slides](#)) — ([html](#)) — ([pdf](#))

1 De dónde venimos: dos ortogonalidades, una identidad guardada

En la lección 7 resolvimos las dos condiciones de ortogonalidad de la *regresión lineal simple*:

$$\langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0, \quad \langle \hat{\mathbf{e}}, \mathbf{x} \rangle_s = 0,$$

Que nos condujeron al hallazgo de dos identidades. Por una parte:

$$\mu_{\mathbf{y}} = \mu_{\hat{\mathbf{y}}}.$$

Y por otra:

$$\hat{\mathbf{y}} - \mu_{\hat{\mathbf{y}}} \mathbf{1} = \hat{\beta}_1 (\mathbf{x} - \mu_{\mathbf{x}} \mathbf{1}).$$

Hoy juntamos estas piezas con una herramienta conocida: el *teorema de Pitágoras* (lección 3).

De dónde venimos: dos ortogonalidades, una identidad guardada

La lección 7 resolvió el sistema de dos ortogonalidades que la lección 6 había dejado planteado: impusimos $\langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0$ y $\langle \hat{\mathbf{e}}, \mathbf{x} \rangle_s = 0$, y de ahí salieron $\hat{\beta}_0 = \mu_{\mathbf{y}} - \hat{\beta}_1 \mu_{\mathbf{x}}$ y $\hat{\beta}_1 = \sigma_{\mathbf{xy}} / \sigma_{\mathbf{x}}^2$.

De la primera condición obtuvimos, además, dos consecuencias que hoy son protagonistas. Primero, que la media del vector ajustado coincide con la media de los datos: $\mu_{\mathbf{y}} = \mu_{\hat{\mathbf{y}}}$ (porque $\hat{\mathbf{e}} \perp \mathbf{1}$ implica $\mu_{\hat{\mathbf{e}}} = 0$, y $\mathbf{y} = \hat{\mathbf{y}} + \hat{\mathbf{e}}$). Segundo, y esta es la pieza que hoy vamos a explotar, la identidad

$$\hat{\mathbf{y}} - \mu_{\hat{\mathbf{y}}} \mathbf{1} = \hat{\beta}_1 (\mathbf{x} - \mu_{\mathbf{x}} \mathbf{1}),$$

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

que decía, literalmente, que el vector en desviaciones del ajuste *es* el mismo vector que el vector en desviaciones de $\hat{\beta}_1 \mathbf{x}$. En la lección 7 la usamos únicamente para concluir que $\mathbf{y}$ forma el mismo ángulo con $\hat{\mathbf{y}}$ que con $\hat{\beta}_1 \mathbf{x}$, y anunciamos que la guardábamos para hoy.

El plan de la sesión es el siguiente. Vamos a construir, a partir de $\mathbf{y} = \hat{\mathbf{y}} + \hat{\mathbf{e}}$, un triángulo rectángulo cuya hipotenusa sea el vector en desviaciones $\mathbf{y} - \bar{\mathbf{y}}$. Aplicando el teorema de Pitágoras (lección 3) a ese triángulo obtendremos una descomposición de la varianza de $\mathbf{y}$; de ahí surgirá, de manera casi inmediata, el coeficiente de determinación R^2 como el coseno al cuadrado de un ángulo. Y, al final, la identidad guardada nos permitirá relacionar ese R^2 con la correlación ρ_{xy} de la lección 5, cerrando un círculo que empezamos a dibujar hace varias sesiones.

Para profundizar:

- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 2, sección 2.3: “Units of Measurement and Functional Form” y la presentación clásica de $SST = SSE + SSR$.

2 El triángulo rectángulo de la bondad de ajuste

Restando $\bar{\mathbf{y}}$ a ambos lados de $\mathbf{y} = \hat{\mathbf{y}} + \hat{\mathbf{e}}$ tenemos:

$$\mathbf{y} - \bar{\mathbf{y}} = (\hat{\mathbf{y}} - \bar{\mathbf{y}}) + \hat{\mathbf{e}}, \quad \text{con } \hat{\mathbf{e}} \perp \mathcal{L}(\hat{\mathbf{y}}, \bar{\mathbf{y}}) \text{ así,}$$

$(\mathbf{y} - \bar{\mathbf{y}})$ es la *hipotenusa* de un triángulo rectángulo cuyos catetos son $\hat{\mathbf{e}}$ y $(\hat{\mathbf{y}} - \bar{\mathbf{y}})$.




Figura 1: Proyección ortogonal de $\mathbf{y}$ (verde oscuro) sobre el plano de los regresores, vista desde dos ángulos. En azul, el vector de medias $\bar{\mathbf{y}}$ (proyección tanto de $\mathbf{y}$ como de $\hat{\mathbf{y}}$ sobre $\mathcal{L}(\mathbf{1})$). En rojo, el ajuste $\hat{\mathbf{y}}$ (en el plano); en violeta, su vector en desviaciones $\hat{\mathbf{y}} - \bar{\mathbf{y}}$. En verde claro, el vector en desviaciones $\mathbf{y} - \bar{\mathbf{y}}$. En gris, el vector de residuos $\hat{\mathbf{e}}$. El arco marca el ángulo θ entre los dos vectores en desviaciones.

El triángulo rectángulo de la bondad de ajuste

Detengámonos en justificar, una por una, las cuatro marcas de ortogonalidad de la figura, porque de la última de ellas sale todo lo que sigue (*para no acumular todas las marcas en el origen de coordenadas, las marcas están desplazadas a rectas discontinuas paralelas a algunos de los vectores*).

Marca 1 y marca 2: $\bar{\mathbf{y}} \perp (\mathbf{y} - \bar{\mathbf{y}})$ y $\bar{\mathbf{y}} \perp (\hat{\mathbf{y}} - \bar{\mathbf{y}})$. Ambas son la misma idea, ya conocida desde la lección 4: cualquier vector menos su proyección sobre $\mathcal{L}(\mathbf{1})$ cae en $\mathcal{L}(\mathbf{1})^\perp$, es decir, es ortogonal

a $\mathbf{1}$ (y por tanto a $\bar{\mathbf{y}}$, que es un múltiplo de $\mathbf{1}$). Esto vale tanto para $\mathbf{y}$ como para $\hat{\mathbf{y}}$, porque ambos comparten la misma proyección $\bar{\mathbf{y}}$ sobre $\mathcal{L}(\mathbf{1})$ (consecuencia de $\mu_{\mathbf{y}} = \mu_{\hat{\mathbf{y}}}$, lección 7).

Marca 3: $\hat{\mathbf{e}} \perp \hat{\mathbf{y}}$. Esta es la ortogonalidad “principal”: por construcción $\hat{\mathbf{e}}$ es ortogonal a *todo* el plano $\mathcal{L}(\mathbf{1}, \mathbf{x})$; y $\hat{\mathbf{y}}$ está en ese plano (por ser combinación lineal de $\mathbf{1}$ y de $\mathbf{x}$; pues $\hat{\mathbf{y}} = \hat{\beta}_0 \mathbf{1} + \hat{\beta}_1 \mathbf{x}$).

Marca 4 (la que nos interesa hoy): $\hat{\mathbf{e}} \perp (\hat{\mathbf{y}} - \bar{\mathbf{y}})$. Como en la marca anterior, se deduce porque $\hat{\mathbf{y}}$ y $\bar{\mathbf{y}}$ son vectores del plano $\mathcal{L}(\mathbf{1}, \mathbf{x})$ (para $\bar{\mathbf{y}}$ lo acabamos de ver y $\bar{\mathbf{y}}$ es un múltiplo de $\mathbf{1}$).

$$\langle \hat{\mathbf{e}}, \hat{\mathbf{y}} - \bar{\mathbf{y}} \rangle_s = \langle \hat{\mathbf{e}}, \hat{\mathbf{y}} \rangle_s - \mu_{\hat{\mathbf{y}}} \langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0 - \mu_{\hat{\mathbf{y}}} \cdot 0 = 0.$$

Con las cuatro marcas confirmadas, podemos leer la descomposición central de la sesión: restando $\bar{\mathbf{y}}$ a ambos lados de $\mathbf{y} = \hat{\mathbf{y}} + \hat{\mathbf{e}}$,

$$\mathbf{y} - \bar{\mathbf{y}} = (\hat{\mathbf{y}} + \hat{\mathbf{e}}) - \bar{\mathbf{y}} = (\hat{\mathbf{y}} - \bar{\mathbf{y}}) + \hat{\mathbf{e}},$$

Tal como indica la marca 4, los dos sumandos $(\hat{\mathbf{y}} - \bar{\mathbf{y}})$ y $\hat{\mathbf{e}}$ son ortogonales entre sí. Tenemos, por tanto, un triángulo rectángulo genuino: hipotenusa $\mathbf{y} - \bar{\mathbf{y}}$, catetos $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ y $\hat{\mathbf{e}}$.

Sobre la figura: las dos vistas muestran la misma escena en $\mathbb{R}^n$ (representada esquemáticamente) desde dos puntos de observación distintos, exactamente como hicimos con la correlación en la lección 5. La primera vista permite apreciar con claridad el triángulo rectángulo completo (hipotenusa y los dos catetos); la segunda, rotada, ayuda a visualizar mejor el ángulo θ marcado con el arco, protagonista de la próxima transparencia.

Nótese, para quien repase la lección 6, que esta misma figura *no* muestra explícitamente la componente $\hat{\beta}_1 \mathbf{x}$ dentro del plano: solo destaca en él la recta $\mathcal{L}(\mathbf{1})$ y las proyecciones sobre ella. Esto es deliberado: hace que la figura —y el argumento que construimos hoy— sirva igualmente como esquema de la regresión con cualquier número k de regresores, sustituyendo el plano $\mathcal{L}(\mathbf{1}, \mathbf{x})$ por un subespacio de dimensión k . Volveremos sobre esto en la última transparencia.

Para profundizar:

- Bujosa, M. *Curso de Álgebra Lineal*, cap. 11: descomposición ortogonal y teorema de Pitágoras en $\mathbb{R}^n$.

3 Pitágoras: la varianza se descompone

Aplicando el teorema de Pitágoras (lección 3) sobre $\mathbf{y} - \bar{\mathbf{y}} = (\hat{\mathbf{y}} - \bar{\mathbf{y}}) + \hat{\mathbf{e}}$, tenemos:

$$\|\mathbf{y} - \bar{\mathbf{y}}\|_s^2 = \|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s^2 + \|\hat{\mathbf{e}}\|_s^2.$$

$$\text{Es decir: } \boxed{\sigma_{\mathbf{y}}^2 = \sigma_{\hat{\mathbf{y}}}^2 + \sigma_{\hat{\mathbf{e}}}^2},$$

donde hemos usado que $\bar{\mathbf{y}} = \mu_{\mathbf{y}} \mathbf{1} = \mu_{\hat{\mathbf{y}}} \mathbf{1} = \bar{\hat{\mathbf{y}}}$ (pues $\mu_{\mathbf{y}} = \mu_{\hat{\mathbf{y}}}$).

Y multiplicando por n (es decir, volviendo a la norma euclídea usual en $\mathbb{R}^n$) tenemos:

$$\underbrace{\sum_i (y_i - \mu_{\mathbf{y}})^2}_{\text{STC}} = \underbrace{\sum_i (\hat{y}_i - \mu_{\mathbf{y}})^2}_{\text{SEC}} + \underbrace{\sum_i \hat{e}_i^2}_{\text{SRC}};$$

que es una expresión habitual en los manuales de econometría (o programas econométricos como Gretl) donde: STC = Suma Total de Cuadrados; SEC = Suma Explicada de Cuadrados; SRC = Suma Residual de Cuadrados.

Pitágoras: la varianza se descompone

Con el triángulo rectángulo ya establecido en la transparencia anterior, aplicar el teorema de Pitágoras (demostrado en la lección 3 para cualquier producto escalar con simetría, linealidad y positividad —propiedades que hereda $\langle \cdot, \cdot \rangle_s$, como se explicitó en la lección 4—) es inmediato:

$$\|\mathbf{y} - \bar{\mathbf{y}}\|_s^2 = \|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s^2 + \|\hat{\mathbf{e}}\|_s^2.$$

Reconociendo que $\|\mathbf{y} - \bar{\mathbf{y}}\|_s^2 = \sigma_{\mathbf{y}}^2$ (definición de varianza, lección 5) y que $\|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s^2 = \sigma_{\hat{\mathbf{y}}}^2$ (la varianza del propio vector ajustado puesto que $\bar{\mathbf{y}} = \mu_{\mathbf{y}}\mathbf{1} = \mu_{\hat{\mathbf{y}}}\mathbf{1} = \bar{\hat{\mathbf{y}}}$), llegamos a

$$\sigma_{\mathbf{y}}^2 = \sigma_{\hat{\mathbf{y}}}^2 + \sigma_{\hat{\mathbf{e}}}^2;$$

donde, como $\hat{\mathbf{e}}$ tiene media cero, $\mu_{\hat{\mathbf{e}}} = 0$ (primera condición de ortogonalidad de la lección 7), su varianza $\sigma_{\hat{\mathbf{e}}}^2$ coincide exactamente con $\|\hat{\mathbf{e}}\|_s^2$, puesto que $\bar{\hat{\mathbf{e}}} = \mathbf{0}$.

Esa es la razón por la que, los tres vectores involucrados en el triángulo rectángulo: $(\mathbf{y} - \bar{\mathbf{y}})$, $(\hat{\mathbf{y}} - \bar{\mathbf{y}})$ y $\hat{\mathbf{e}}$, aparecen, en la figura de la transparencia anterior, en el plano $\mathcal{L}(\mathbf{1})^\perp$ perpendicular a la recta $\mathcal{L}(\mathbf{1})$ (los tres pertenecen al plano de vectores con media cero).

Sobre el cambio de lenguaje a $STC=SEC+SRC$ en los manuales de econometría y programas econométricos como Gretl. Aquí hemos usado sistemáticamente el producto escalar de la estadística $\langle \cdot, \cdot \rangle_s$ (con su factor $1/n$) a lo largo de las lecciones 4, 5, 6 y 7. La medición de los vectores en desviaciones $(\mathbf{y} - \bar{\mathbf{y}})$, $(\hat{\mathbf{y}} - \bar{\mathbf{y}})$ y $\hat{\mathbf{e}}$ usando el producto escalar de la estadística, arroja la identidad $\sigma_{\mathbf{y}}^2 = \sigma_{\hat{\mathbf{y}}}^2 + \sigma_{\hat{\mathbf{e}}}^2$. Sin embargo, en la inmensa mayoría de los libros de texto —y en la salida que ofrece Gretl— esta identidad se presenta multiplicada por n (es decir, omitiendo el factor $1/n$):

$$STC = SEC + SRC, \quad \text{con } STC = \sum_i (y_i - \mu_{\mathbf{y}})^2, \quad SEC = \sum_i (\hat{y}_i - \mu_{\mathbf{y}})^2, \quad SRC = \sum_i \hat{e}_i^2.$$

Es decir, en la literatura es tradicional expresar la identidad pitagórica de más arriba midiendo el cuadrado de las longitudes de los vectores $(\mathbf{y} - \bar{\mathbf{y}})$, $(\hat{\mathbf{y}} - \bar{\mathbf{y}})$ y $\hat{\mathbf{e}}$ con el producto escalar usual en el espacio euclídeo: $\langle \cdot, \cdot \rangle_e$.

Tenga en cuenta, además, que en inglés la identidad se escribe habitualmente $SST = SSE + SSR$ (Sum of Squares Total, Explained, Residual). En este curso usaremos las siglas españolas $STC/SEC/SRC$.

Para profundizar:

- Wooldridge, J. M. (2020), cap. 2, ecuación (2.35) y comentario adyacente sobre la nomenclatura $SST/SSE/SSR$.




Figura 2: ¿Qué ajuste es mejor, el de arriba o el de abajo? Ambas filas comparten exactamente el mismo ajuste $\hat{\mathbf{y}}$ (rojo), el mismo vector de medias $\bar{\mathbf{y}}$ (azul) y el mismo vector en desviaciones del ajuste $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ (violeta), cada una vista desde dos ángulos distintos. Lo único que cambia es el tamaño del vector de residuos $\hat{\mathbf{e}}$ (gris) —mayor arriba, menor abajo— y, en consecuencia, el propio $\mathbf{y}$ (verde oscuro) y su vector en desviaciones $\mathbf{y} - \bar{\mathbf{y}}$ (verde claro).

4 ¿Qué ajuste es mejor: el de arriba o el de abajo?

- Arriba y abajo: mismo $\hat{\mathbf{y}}$, mismo $\bar{\mathbf{y}}$.
- Solo cambia $\hat{\mathbf{e}}$: menor abajo, mayor arriba.

Para comparar el ajuste entre $\mathbf{y}$ y $\hat{\mathbf{y}}$ basta mirar lo que *no* comparten.

¿Qué ajuste es mejor: el de arriba o el de abajo?

Antes de dar ninguna definición formal, merece la pena razonar sobre la figura, porque el razonamiento mismo va a sugerir, de manera casi inevitable, cómo debe definirse la medida de bondad de ajuste que buscamos.

El ajuste $\hat{\mathbf{y}}$ es mejor cuanto más se parezca a $\mathbf{y}$ —dicho con precisión (lección 3), cuanto menor sea la distancia $\|\mathbf{y} - \hat{\mathbf{y}}\|_s$ —. Pero comparar $\mathbf{y}$ y $\hat{\mathbf{y}}$ directamente esconde un hecho que ya conocíamos desde la lección 7: ambos comparten exactamente la misma componente sobre $\mathcal{L}(\mathbf{1})$, el vector de medias $\bar{\mathbf{y}}$ (pues $\mu_{\mathbf{y}} = \mu_{\hat{\mathbf{y}}}$). Esta es, precisamente, la razón por la que en la figura de arriba y en la de abajo el vector azul es idéntico: sea cual sea el tamaño del residuo, esa parte nunca cambia.

Como esa componente es siempre común, no aporta ninguna información sobre la calidad del ajuste: da igual cuál sea $\mathbf{y}$, el vector de medias de $\mathbf{y}$ y el de $\hat{\mathbf{y}}$ son inevitablemente el mismo. Por tanto, para comparar el ajuste basta con mirar lo que *no* es común: los dos vectores en desviaciones, $\mathbf{y} - \bar{\mathbf{y}}$ (verde claro) y $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ (violeta).

Del triángulo rectángulo de la transparencia anterior sabemos que estos dos vectores no son

independientes: $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ es un cateto, y $\mathbf{y} - \bar{\mathbf{y}}$ es la hipotenusa del mismo triángulo (el otro cateto es $\hat{\mathbf{e}}$). En particular, $\|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s \leq \|\mathbf{y} - \bar{\mathbf{y}}\|_s$ siempre (un cateto nunca es más largo que la hipotenusa), con igualdad exactamente cuando $\hat{\mathbf{e}} = \mathbf{0}$ (ajuste perfecto: los dos vectores en desviaciones coinciden).

Esto sugiere de manera natural cómo medir la bondad del ajuste: comparando las longitudes de esos dos vectores en desviaciones, es decir, mirando el ratio

$$\frac{\|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s^2}{\|\mathbf{y} - \bar{\mathbf{y}}\|_s^2}$$

(elevado al cuadrado, para trabajar con varianzas en lugar de con normas). Si $\hat{\mathbf{e}}$ es pequeño (figura de abajo), las dos longitudes son casi iguales, y el ratio está cerca de 1: buen ajuste. Si $\hat{\mathbf{e}}$ es grande (figura de arriba), $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ es mucho más corto que $\mathbf{y} - \bar{\mathbf{y}}$, y el ratio se hace mucho más pequeño que 1: mal ajuste. En nuestra figura, por tanto, *el ajuste de abajo es mejor que el de arriba* —y el ratio que acabamos de construir lo confirmará numéricamente en la próxima transparencia, donde por fin lo llamamos por su nombre: el coeficiente de determinación R^2 .

5 El coeficiente de determinación: $R^2 = \cos^2 \theta$

El *coeficiente de determinación* es el ratio entre el cuadrado de la norma del ajuste en desviaciones y el cuadrado de la norma del vector de datos en desviaciones:

$$R^2 = \frac{\|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s^2}{\|\mathbf{y} - \bar{\mathbf{y}}\|_s^2} = \frac{\sigma_{\hat{\mathbf{y}}}^2}{\sigma_{\mathbf{y}}^2}.$$

Multiplicando por n (transparencia anterior): $R^2 = \text{SEC}/\text{STC} = 1 - \text{SRC}/\text{STC}$.

Del triángulo rectángulo: $\cos \theta = \frac{\langle \mathbf{y} - \bar{\mathbf{y}}, \hat{\mathbf{y}} - \bar{\mathbf{y}} \rangle_s}{\|\mathbf{y} - \bar{\mathbf{y}}\|_s \|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s} = \rho_{\mathbf{y}\hat{\mathbf{y}}}.$

Como $\langle \mathbf{y} - \bar{\mathbf{y}}, \hat{\mathbf{y}} - \bar{\mathbf{y}} \rangle_s = \|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s^2$ (pues $\hat{\mathbf{e}} \perp \mathcal{L}(\mathbf{1}, \mathbf{x})$), $\cos \theta = \sigma_{\hat{\mathbf{y}}}/\sigma_{\mathbf{y}}$.

$$\boxed{R^2 = \cos^2 \theta = \rho_{\mathbf{y}\hat{\mathbf{y}}}^2} \quad \text{donde } \theta = \angle((\mathbf{y} - \bar{\mathbf{y}}), (\hat{\mathbf{y}} - \bar{\mathbf{y}})).$$

Como todo coseno al cuadrado, $0 \leq R^2 \leq 1$.

El coeficiente de determinación: $R^2 = \rho_{\mathbf{y}\hat{\mathbf{y}}}^2 = \cos^2 \theta$

La transparencia anterior nos dejó el camino casi servido: la bondad del ajuste se mide comparando las longitudes de los vectores en desviaciones $\mathbf{y} - \bar{\mathbf{y}}$ y $\hat{\mathbf{y}} - \bar{\mathbf{y}}$. Formalizamos esa intuición como definición:

Definición. El coeficiente de determinación es

$$R^2 = \frac{\|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s^2}{\|\mathbf{y} - \bar{\mathbf{y}}\|_s^2} = \frac{\sigma_{\hat{\mathbf{y}}}^2}{\sigma_{\mathbf{y}}^2}.$$

Multiplicando numerador y denominador por n se obtiene la forma habitual en los manuales:

$$R^2 = \frac{\text{SEC}}{\text{STC}} = 1 - \frac{\text{SRC}}{\text{STC}};$$

ya que, como $\text{STC} = \text{SEC} + \text{SRC}$, podemos sustituir $\text{SEC} = \text{STC} - \text{SRC}$.¹

Esta definición como ratio de normas admite una segunda lectura, tan reveladora como la primera: es, literalmente, el coseno al cuadrado de un ángulo. Recordemos la definición de coseno entre dos vectores (lección 3) aplicada aquí a los vectores en desviaciones de $\mathbf{y}$ y $\hat{\mathbf{y}}$ (como se hizo con $\mathbf{x}$ e $\mathbf{y}$ en la lección 5): el ángulo θ entre $\mathbf{y} - \bar{\mathbf{y}}$ y $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ cumple

$$\cos \theta = \frac{\langle \mathbf{y} - \bar{\mathbf{y}}, \hat{\mathbf{y}} - \bar{\mathbf{y}} \rangle_s}{\|\mathbf{y} - \bar{\mathbf{y}}\|_s \|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s} = \rho_{\mathbf{y}\hat{\mathbf{y}}}; \quad (1)$$

donde hemos usado la definición de correlación de la lección 5.

Para simplificar el numerador de (1), sustituimos $\mathbf{y} - \bar{\mathbf{y}} = (\hat{\mathbf{y}} - \bar{\mathbf{y}}) + \hat{\mathbf{e}}$ (transparencia 2):

$$\langle \mathbf{y} - \bar{\mathbf{y}}, \hat{\mathbf{y}} - \bar{\mathbf{y}} \rangle_s = \langle (\hat{\mathbf{y}} - \bar{\mathbf{y}}) + \hat{\mathbf{e}}, \hat{\mathbf{y}} - \bar{\mathbf{y}} \rangle_s = \|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s^2 + \underbrace{\langle \hat{\mathbf{e}}, \hat{\mathbf{y}} - \bar{\mathbf{y}} \rangle_s}_{=0 \text{ } (\hat{\mathbf{e}} \perp \mathcal{L}(\mathbf{1}, \mathbf{x}))} = \|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s^2;$$

donde hemos usado que $\hat{\mathbf{e}}$ es ortogonal al plano que contiene a los vectores $\hat{\mathbf{y}}$ y $\bar{\mathbf{y}}$.

Sustituyendo:

$$\cos \theta = \frac{\|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s^2}{\|\mathbf{y} - \bar{\mathbf{y}}\|_s \|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s} = \frac{\|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_s}{\|\mathbf{y} - \bar{\mathbf{y}}\|_s} = \frac{\sigma_{\hat{\mathbf{y}}}}{\sigma_{\mathbf{y}}}.$$

Elevando al cuadrado, y comparando con la definición del principio de esta misma transparencia:

$$\cos^2 \theta = \frac{\sigma_{\hat{\mathbf{y}}}^2}{\sigma_{\mathbf{y}}^2} = R^2,$$

donde, además, $\cos^2 \theta = \rho_{\mathbf{y}\hat{\mathbf{y}}}$.

Las dos lecturas son, por tanto, la misma cosa vista de dos maneras: R^2 es, a la vez, un ratio de normas al cuadrado (la forma que motivamos con la figura de la transparencia anterior) y un coseno al cuadrado (la forma habitual en los manuales, y que conecta directamente con la correlación entre el vector de datos $\mathbf{y}$ y su ajuste $\hat{\mathbf{y}}$). El ángulo θ es precisamente el ángulo marcado con el arco en la figura de la transparencia 2: el ángulo entre el vector en desviaciones de los datos y el vector en desviaciones de su ajuste: $\theta = \angle((\mathbf{y} - \bar{\mathbf{y}}), (\hat{\mathbf{y}} - \bar{\mathbf{y}}))$.

El hecho de que $0 \leq R^2 \leq 1$ tiene *dos* justificaciones independientes, que conviene señalar porque es un ejemplo bonito de cómo dos caminos distintos llevan a la misma cota. Por un lado, ya lo sabíamos por Pitágoras (transparencia 3): como $\text{SEC} + \text{SRC} = \text{STC}$ y $\text{SRC} \geq 0$, forzosamente $\text{SEC} \leq \text{STC}$, luego $R^2 \leq 1$ (y $R^2 \geq 0$ porque SEC y SRC son el cuadrado de dos longitudes o normas). Por otro, ahora lo sabemos también porque ningún coseno se sale de $[-1, 1]$, así que ningún coseno al cuadrado se sale de $[0, 1]$ —sin necesidad de invocar Pitágoras de nuevo.

¹Fíjese que $\frac{\text{SEC}}{\text{STC}} = \frac{\|\mathbf{y} - \bar{\mathbf{y}}\|_s^2}{\|\mathbf{y} - \bar{\mathbf{y}}\|_s^2}$ es el ratio de normas al cuadrado de los mismos vectores en desviaciones, pero medidos usando el producto escalar habitual $\langle \cdot, \cdot \rangle_e$ del espacio euclídeo $\mathbb{R}^n$

6 Interpretando R^2 : casos extremos

Con $\mathbf{y} = \hat{\mathbf{y}}$:

- $\theta = 0^\circ$ ($\hat{\mathbf{e}} = \mathbf{0}$): el ajuste *coincide* con los datos. $R^2 = 1$.

Con $(\hat{\mathbf{y}} - \bar{\mathbf{y}})$ fijo y no nulo, R^2 nunca *llega* a ser 0: solo se le acerca.

- $\theta \rightarrow 90^\circ$: si el residuo crece *sin límite*; $R^2 \rightarrow 0$, pero solo en ese límite.

¿Y puede R^2 ser exactamente 0?

- Sí — pero en otra situación: cuando el *propio ajuste* coincide con el vector de medias, $\hat{\mathbf{y}} = \bar{\mathbf{y}}$ (cateto nulo, sin residuo infinito). Es decir, cuando $\rho_{xy} = 0$.

Interpretando R^2 : casos extremos

Las figuras anteriores permiten comprender, sin necesidad de ninguna fórmula adicional, cuando se dan los casos extremos.

Si $\hat{\mathbf{e}} = \mathbf{0}$, el triángulo rectángulo degenera: la hipotenusa $\mathbf{y} - \bar{\mathbf{y}}$ coincide exactamente con el cateto $\hat{\mathbf{y}} - \bar{\mathbf{y}}$, el ángulo θ es 0° , y $R^2 = \cos^2 0^\circ = 1$: el ajuste reproduce los datos exactamente. Si, en cambio, dejamos crecer $\hat{\mathbf{e}}$ sin límite (manteniendo fijo el cateto, como en la figura), la hipotenusa se alarga cada vez más en la dirección de $\mathcal{L}(\mathbf{1}, \mathbf{x})^\perp$, el ángulo θ se abre progresivamente hacia 90° , y $R^2 = \cos^2 \theta$ se acerca a 0. Nótese que decir “ θ se abre hacia 90° ” es, aquí, exactamente lo mismo que decir “el residuo crece sin límite”.

Conviene precisar un matiz que la propia figura deja entrever. Mientras el cateto $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ permanezca fijo y *no nulo* (como en las dos escenas de la figura), $R^2 = \sigma_{\hat{\mathbf{y}}}^2 / (\sigma_{\hat{\mathbf{y}}}^2 + \sigma_{\hat{\mathbf{e}}}^2)$ es siempre estrictamente positivo, por grande que sea el residuo: R^2 se *acerca* a 0 tanto como queramos, pero solo lo *alcanza* en el límite de un residuo de norma infinita, que no es una situación real.

Esto no significa que R^2 no pueda ser *exactamente* 0 en la práctica: sí puede, pero en una situación distinta de la que muestra esta figura. Ocurre cuando el propio ajuste coincide con el vector de medias, $\hat{\mathbf{y}} = \bar{\mathbf{y}}$ —es decir, cuando el cateto $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ es $\mathbf{0}$, no cuando el residuo se dispara—. En la regresión simple, esto sucede exactamente cuando $\hat{\beta}_1 = 0$ (covarianza muestral nula entre $\mathbf{x}$ e $\mathbf{y}$, lección 7): el mejor ajuste posible resulta ser, sencillamente, “predecir siempre la media”, sin que $\mathbf{x}$ aporte nada. Es importante no confundir esta situación —perfectamente posible con datos $\mathbf{y}$ ordinarios, no constantes— con el caso degenerado en que $\mathbf{y}$ mismo fuera constante: en ese caso $\sigma_{\mathbf{y}}^2 = 0$ y R^2 ni siquiera estaría definido (0/0), exactamente igual que ocurría con la correlación en la lección 5.

7 Ejemplo numérico: STC, SEC, SRC

Retomamos el ejemplo de la lección 7: $\mathbf{x} = (1, 2, 3, 4, 5)$, $\mathbf{y} = (6, 6, 11, 16, 16)$, con $\hat{\beta}_0 = 2$, $\hat{\beta}_1 = 3$.

x_i	y_i	$\hat{y}_i = 2 + 3x_i$	$\hat{e}_i = y_i - \hat{y}_i$
1	6	5	1
2	6	8	-2
3	11	11	0
4	16	14	2
5	16	17	-1

$\mu_y = \mu_{\hat{y}} = 11$. Entonces:

$$\text{STC} = \sum (y_i - 11)^2 = 100, \quad \text{SEC} = \sum (\hat{y}_i - 11)^2 = 90, \quad \text{SRC} = \sum \hat{e}_i^2 = 10.$$

Comprobación: $90 + 10 = 100$. $R^2 = 90/100 = 0,9$.

Con $\sigma_x^2 = 2$, $\sigma_y^2 = 20$, $\sigma_{xy} = 6$: $\rho_{xy}^2 = 6^2 / (2 \cdot 20) = 36/40 = 0,9$. ¡Coincide!

Ejemplo numérico: STC, SEC, SRC

Verifiquemos con números todo lo dicho, retomando exactamente el ejemplo de la lección 7 (el mismo $n = 5$, con $\mathbf{x} = (1, 2, 3, 4, 5)$, $\mathbf{u} = (1, -2, 0, 2, -1)$ y $\mathbf{y} = 2 + 3\mathbf{x} + \mathbf{u} = (6, 6, 11, 16, 16)$), donde ya obtuvimos $\hat{\beta}_0 = 2$, $\hat{\beta}_1 = 3$ y comprobamos que, en ese ejemplo con truco, $\hat{\mathbf{e}} = \mathbf{u}$.

Los valores ajustados son $\hat{y}_i = 2 + 3x_i$: $\hat{\mathbf{y}} = (5, 8, 11, 14, 17)$. Los residuos, $\hat{e}_i = y_i - \hat{y}_i$: $\hat{\mathbf{e}} = (1, -2, 0, 2, -1)$ (efectivamente, coincide con $\mathbf{u}$, como ya sabíamos).

Media de $\mathbf{y}$ y de $\hat{\mathbf{y}}$: $\mu_y = \frac{6+6+11+16+16}{5} = 11$; $\mu_{\hat{y}} = \frac{5+8+11+14+17}{5} = \frac{55}{5} = 11$. Coinciden, como debía ser.

$$\text{STC}: \sum_i (y_i - 11)^2 = (-5)^2 + (-5)^2 + 0^2 + 5^2 + 5^2 = 25 + 25 + 0 + 25 + 25 = 100.$$

$$\text{SEC}: \sum_i (\hat{y}_i - 11)^2 = (-6)^2 + (-3)^2 + 0^2 + 3^2 + 6^2 = 36 + 9 + 0 + 9 + 36 = 90.$$

$$\text{SRC}: \sum_i \hat{e}_i^2 = 1^2 + (-2)^2 + 0^2 + 2^2 + (-1)^2 = 1 + 4 + 0 + 4 + 1 = 10.$$

Comprobación de Pitágoras: $\text{SEC} + \text{SRC} = 90 + 10 = 100 = \text{STC}$.

$R^2 = \text{SEC}/\text{STC} = 90/100 = 0,9$: el ajuste explica el 90 % de la variación total de $\mathbf{y}$.

Verifiquemos también la vía de la correlación (transparencia anterior). De la lección 7 ya teníamos $\sigma_x^2 = 2$ y $\sigma_{xy} = 6$. Y $\sigma_y^2 = \text{STC}/n = 100/5 = 20$. Entonces

$$\rho_{xy}^2 = \frac{\sigma_{xy}^2}{\sigma_x^2 \sigma_y^2} = \frac{6^2}{2 \cdot 20} = \frac{36}{40} = 0,9.$$

Coincide exactamente con R^2 , confirmando numéricamente el resultado $R^2 = \rho_{xy}^2$ de la transparencia anterior.

8 Una advertencia: el nombre *suma explicada* es engañoso

$\text{STC} = \text{SEC} + \text{SRC}$ es una identidad *puramente geométrica* sobre vectores de $\mathbb{R}^n$: se cumple siempre, contengan esos vectores lo que contengan.

Primer peligro: un R^2 alto NO requiere ninguna relación real entre $\mathbf{x}$ e $\mathbf{y}$.

Ejemplo célebre (Vigen, *Spurious Correlations*): consumo de queso per cápita en EE.UU. y personas que mueren enredadas en sus sábanas, $\rho \approx 0,947$. Nadie propone que el queso mate sofocando a sus víctimas en las sábanas.

Segundo peligro: aun cuando SÍ existe una relación real, R^2 no dice nada sobre su *dirección*.

Ampliar una vivienda aumenta su precio (relación razonable). Pero si regresamos *superficie sobre precio* (papeles invertidos), R^2 *no cambia* — y de ahí no se sigue que subir el precio agrande la casa.

Un R^2 alto no certifica relación alguna; y si la hay, no certifica su sentido.

Solo cuando el modelo sea sensato un R^2 alto será una buena señal.

Una advertencia: el nombre *suma explicada* es engañoso

Conviene detenerse, antes de seguir, en una advertencia que atañe al propio *nombre* que hemos venido usando: “Suma *Explicada* de Cuadrados”. La identidad $STC = SEC + SRC$ —o, equivalentemente, $\sigma_y^2 = \sigma_y^2 + \sigma_e^2$ — es una consecuencia puramente geométrica de la descomposición ortogonal $\mathbf{y} = \hat{\mathbf{y}} + \hat{\mathbf{e}}$. Se cumple exactamente igual sea cual sea el contenido de los vectores $\mathbf{x}$ e $\mathbf{y}$: la geometría de $\mathbb{R}^n$ no sabe nada de economía, de causalidad, ni de sentido común. El nombre “explicada” sugiere que hay algo sustantivo detrás; la propia matemática no lo garantiza en absoluto.

Primer peligro: no hace falta ninguna relación real para obtener un R^2 alto. El ejemplo más elocuente es el de las llamadas *correlaciones espurias*. Tyler Vigen, en su proyecto *Spurious Correlations* (tylervigen.com), recopiló decenas de pares de series con correlaciones altísimas y absolutamente ningún vínculo causal ni siquiera plausible: por ejemplo, el consumo de queso per cápita en Estados Unidos y el número de personas que mueren anualmente enredadas en sus sábanas, con $\rho \approx 0,947$ durante el periodo 2000-2009 (lo que equivaldría a un $R^2 \approx 0,897$ si regresáramos una serie sobre la otra). Nadie sostendría que comer queso provoca —ni evita— morir enredado en las sábanas: ambas series, sencillamente, crecieron en paralelo por razones completamente ajenas entre sí. La identidad $STC = SEC + SRC$ se cumple, con toda su fuerza matemática, exactamente igual para estos dos vectores sin sentido que para cualquier par de vectores con un significado económico razonable: la matemática, por sí sola, no distingue un caso del otro.

Segundo peligro, distinto del anterior: incluso cuando la relación SÍ es real, R^2 no dice nada sobre su dirección. Retomemos el ejemplo del precio y la superficie de las viviendas. Aquí sí existe una relación económicamente razonable: ampliar la superficie de una vivienda tiende a aumentar su precio. Si regresamos precio sobre superficie, obtenemos un R^2 que, en efecto, parece “explicar” el precio a partir del tamaño. Pero si invertimos los papeles —regresando *superficie sobre precio*—, obtenemos exactamente el mismo R^2 (como veremos en la próxima transparencia, en la regresión simple $R^2 = \rho_{xy}^2$, y esa correlación no distingue cuál variable hace de x y cuál de y : invertir los papeles no cambia su valor). Y sin embargo, decir que “el precio explica la superficie” —en el sentido de que subir el precio de una vivienda haría que esta ampliara su superficie— no tiene ningún sentido. La regresión, y el R^2 que de ella se deriva, son completamente indiferentes a cuál de las dos variables juega el papel de causa y cuál el de efecto: esa es una pregunta que solo puede responder una teoría económica previa, nunca la sola geometría de los datos.

La lección que hay que extraer de ambos peligros es la misma, aunque se manifieste de dos maneras distintas: *un R^2 alto solo puede ser tomado como “una buena señal” cuando el modelo es sensato y está bien fundamentado desde un punto de vista teórico*. Un R^2 alto no sirve, ni para afirmar que existe una relación real (primer peligro), ni para afirmar en qué sentido va esa relación si de verdad existe (segundo peligro). Tampoco un R^2 bajo implica que el modelo deba ser descartado. Retomaremos esta discusión, con más herramientas, en la lección 9 (“El puente”).

Advertencia para más adelante. R^2 tiene una propiedad puramente mecánica que conviene no olvidar: *nunca empeora al añadir regresores*, aunque esos regresores aporten muy poca información real. Precisamente por eso, más adelante necesitaremos una versión corregida de esta medida: el R^2 *ajustado*.

Para profundizar:

- Vigen, T. *Spurious Correlations*, tylervigen.com: catálogo de correlaciones estadísticamente altas y causalmente vacías.
- Wooldridge, J. M. (2020), cap. 2, sección 2.4: advertencias sobre la interpretación causal de R^2 .

Conviene subrayar la diferencia con la correlación tratada en la lección 7. Allí, $\rho_{xy} = \cos \theta'$ era el coseno del ángulo entre los vectores (en desviaciones) correspondientes a los *datos* y el *regresor* ($\mathbf{y} - \bar{\mathbf{y}}$ y $\mathbf{x} - \bar{\mathbf{x}}$). Aquí, $R^2 = \rho_{\mathbf{y}\hat{\mathbf{y}}}^2 = \cos^2 \theta$ es el cuadrado del coseno del ángulo *entre los datos y su ajuste* ($\mathbf{y} - \bar{\mathbf{y}}$ y $\hat{\mathbf{y}} - \bar{\hat{\mathbf{y}}}$), ambos en desviaciones. Son, en principio, dos ángulos distintos, definidos entre parejas de vectores distintas. En la próxima transparencia veremos que, en el caso particular de la regresión lineal simple (un único regresor $\mathbf{x}$ además de la constante), ambos ángulos coinciden exactamente.

9 En el caso de la regresión simple: $R^2 = \rho_{xy}^2$

Todo vector *no constante* del plano $\mathcal{L}(\mathbf{1}, \mathbf{x})$, una vez centrado, cae en *la misma recta*:

$$\mathbf{w} = c_0 \mathbf{1} + c_1 \mathbf{x} \quad (c_1 \neq 0) \implies \mathbf{w} - \bar{\mathbf{w}} = c_1 (\mathbf{x} - \mu_x \mathbf{1}).$$

El ajuste $\hat{\mathbf{y}} = \hat{\beta}_0 \mathbf{1} + \hat{\beta}_1 \mathbf{x}$ es uno de esos vectores: *traslación y reescalado* de $\mathbf{x}$.

Aplicando las propiedades de traslación y escala de la correlación a $\hat{\mathbf{y}} = \hat{\beta}_1 \mathbf{x} + \hat{\beta}_0 \mathbf{1}$:

$$\rho_{\mathbf{y}\hat{\mathbf{y}}} = \frac{\hat{\beta}_1}{|\hat{\beta}_1|} \rho_{\mathbf{y}\mathbf{x}}.$$

Como $\hat{\beta}_1$ y ρ_{xy} comparten siempre signo (lección 7): $\rho_{\mathbf{y}\hat{\mathbf{y}}} = |\rho_{xy}| \geq 0$.

$$\boxed{R^2 = \rho_{\mathbf{y}\hat{\mathbf{y}}}^2 = \rho_{xy}^2.}$$

No es casualidad: en $\mathcal{L}(\mathbf{1}, \mathbf{x})$ solo hay *una* dirección perpendicular $\mathbf{1}$. Todo vector no constante del plano —incluido $\hat{\mathbf{y}}$ — forma con $\mathbf{y}$ el mismo ángulo, salvo quizá el signo.

En el caso de la regresión simple: $R^2 = \rho_{xy}^2$

Esta transparencia cierra la identidad guardada de la lección 7, pero conviene detenerse en *por qué* el resultado es cierto, porque el argumento explica también por qué es exclusivo de la regresión simple.

Empecemos por un hecho general sobre el plano $\mathcal{L}(\mathbf{1}, \mathbf{x})$, que no depende en absoluto de cuál sea el ajuste MCO. Tomemos *cualquier* vector no constante del plano, es decir, cualquier $\mathbf{w} = c_0\mathbf{1} + c_1\mathbf{x}$ con $c_1 \neq 0$. Su media es $\mu_{\mathbf{w}} = c_0 + c_1\mu_{\mathbf{x}}$, así que su vector en desviaciones es

$$\mathbf{w} - \overline{\mathbf{w}} = (c_0\mathbf{1} + c_1\mathbf{x}) - (c_0 + c_1\mu_{\mathbf{x}})\mathbf{1} = c_1(\mathbf{x} - \mu_{\mathbf{x}}\mathbf{1}).$$

Es decir: *el vector en desviaciones de $\mathbf{w}$ es, salvo el escalar c_1 , siempre el mismo vector, $\mathbf{x} - \mu_{\mathbf{x}}\mathbf{1}$* . Dicho de otro modo, todos los vectores no constantes de $\mathcal{L}(\mathbf{1}, \mathbf{x})$, una vez centrados, caen en la misma recta $\mathcal{L}(\mathbf{x} - \mu_{\mathbf{x}}\mathbf{1})$ —una única dirección dentro de $\mathcal{L}(\mathbf{1})^\perp$ —. Esto no es más que la identidad guardada de la lección 7, $\hat{\mathbf{y}} - \overline{\mathbf{y}} = \hat{\beta}_1(\mathbf{x} - \mu_{\mathbf{x}}\mathbf{1})$, generalizada de $\hat{\mathbf{y}}$ a *cualquier* vector del plano: $\hat{\mathbf{y}}$ no tiene nada de especial en este sentido; es, sencillamente, uno más de esos vectores $\mathbf{w}$ (con $c_0 = \hat{\beta}_0$, $c_1 = \hat{\beta}_1$), y como tal hereda la propiedad.

Esta observación tiene una consecuencia inmediata sobre los ángulos. Si dos vectores en desviaciones son proporcionales, $(\mathbf{w} - \overline{\mathbf{w}}) = c_1(\mathbf{x} - \mu_{\mathbf{x}}\mathbf{1})$, entonces el ángulo que $\mathbf{w}$ forma con cualquier tercer vector coincide, salvo un posible cambio de 180° , con el que forma $\mathbf{x}$. Y como el coseno de θ y el de $180^\circ - \theta$ solo difieren en el signo, la *correlación* de $\mathbf{y}$ con $\mathbf{w}$ y con $\mathbf{x}$ coincide en valor absoluto, sea cual sea el vector $\mathbf{w}$ elegido (con tal de que $c_1 \neq 0$).

Podemos evitar repetir el argumento desde cero: ya demostramos esto mismo en la lección 5, bajo el nombre de *propiedades de traslación y escala* de la correlación. Allí vimos que, si $\mathbf{x}' = \lambda\mathbf{x} + a\mathbf{1}$ (una traslación seguida de un reescalado), entonces

$$\rho_{\mathbf{x}'\mathbf{y}} = \frac{\lambda}{|\lambda|} \rho_{\mathbf{x}\mathbf{y}}.$$

Y el ajuste $\hat{\mathbf{y}} = \hat{\beta}_1\mathbf{x} + \hat{\beta}_0\mathbf{1}$ es, literalmente, una transformación de ese tipo: un reescalado de $\mathbf{x}$ por $\hat{\beta}_1$, seguido de una traslación por $\hat{\beta}_0\mathbf{1}$. Aplicando la fórmula con $\lambda = \hat{\beta}_1$:

$$\rho_{\mathbf{y}\hat{\mathbf{y}}} = \frac{\hat{\beta}_1}{|\hat{\beta}_1|} \rho_{\mathbf{x}\mathbf{y}}.$$

No hace falta ninguna cuenta nueva: es la propiedad de la lección 5, aplicada al caso concreto en que el "reescalado" es precisamente la pendiente de la regresión.

Solo falta un ingrediente, ya demostrado en la lección 7: el signo de $\hat{\beta}_1$ coincide siempre con el signo de $\rho_{\mathbf{x}\mathbf{y}}$ (porque $\hat{\beta}_1 = \sigma_{\mathbf{x}\mathbf{y}}/\sigma_{\mathbf{x}}^2$ y $\sigma_{\mathbf{x}}^2 > 0$). Así que el factor $\hat{\beta}_1/|\hat{\beta}_1|$ es exactamente $\text{sign}(\rho_{\mathbf{x}\mathbf{y}})$, y

$$\rho_{\mathbf{y}\hat{\mathbf{y}}} = \text{sign}(\rho_{\mathbf{x}\mathbf{y}}) \cdot \rho_{\mathbf{x}\mathbf{y}} = |\rho_{\mathbf{x}\mathbf{y}}|.$$

Elevando al cuadrado, y usando $R^2 = \rho_{\mathbf{y}\hat{\mathbf{y}}}^2$ (transparencia anterior):

$$R^2 = \rho_{\mathbf{x}\mathbf{y}}^2.$$

Este resultado explica *por qué* es exclusivo de la regresión simple, sin necesidad de comparar dos cálculos algebraicos: en $\mathcal{L}(\mathbf{1}, \mathbf{x})$ hay una sola dirección no constante, así que *todos* los vectores no constantes del plano — $\mathbf{x}$, $2\mathbf{x}$, $\mathbf{x} + 7\mathbf{1}$, o el propio $\hat{\mathbf{y}}$ — forman con $\mathbf{y}$ el mismo ángulo, salvo el signo. En la lección 10 (regresión múltiple con $k > 1$ regresores no constantes), el subespacio análogo —los vectores no constantes de $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$, centrados— tiene dimensión k , no 1: ya no hay una única dirección, y $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ deja de estar alineado con ningún regresor individual. Por eso $R^2 = \cos^2 \theta$ seguirá siendo válido (no depende de la dimensión del subespacio), pero dejará de coincidir con el cuadrado de ninguna correlación simple $\rho_{x_j y}$.

Para profundizar:

- Wooldridge, J. M. (2020), cap. 2, ecuación (2.38): $R^2 = \hat{\rho}_{xy}^2$ en el modelo de regresión simple.

10 Regresión lineal simple: STC, SEC y SRC con áreas




Figura 3: STC, SEC y SRC como áreas de cuadrados sobre el diagrama de dispersión clásico. (Izquierda) STC: cada cuadrado tiene lado $y_i - \mu_y$ (distancia del dato a la media). (Centro) SRC: los cuadrados, mucho más pequeños, tienen lado $y_i - \hat{y}_i$ (distancia de cada dato a su ajuste). (Derecha) SEC: los puntos son ahora los ajustes $\hat{y}_i$ (alineados en la recta de regresión); el lado de cada cuadrado es $\hat{y}_i - \mu_y$.

Es la misma identidad $\text{STC} = \text{SRC} + \text{SEC}$ de la transparencia 3, ahora vista como suma de áreas, dato a dato.

Regresión lineal simple: STC, SEC y SRC con áreas

Los tres diagramas de la figura anterior viven en un espacio distinto del que hemos usado en las demás figuras de esta sesión: no es $\mathbb{R}^n$ (el espacio abstracto de los n datos, donde vive el triángulo de las transparencias 2-3), sino el plano (x, y) empleado en los diagramas de dispersión de toda la vida (y que ya hemos usado en el laboratorio que sigue a la lección 5). Es un complemento de la representación abstracta con vectores: mientras que allí una norma al cuadrado es “la longitud de un vector, elevada al cuadrado”, aquí cada sumando de STC, SEC o SRC es, literalmente, literalmente, *el área de un cuadrado* dibujado sobre el propio diagrama de dispersión.

En el panel de la izquierda, cada observación (x_i, y_i) tiene, en una esquina, el dato en sí; el lado del cuadrado dibujado es la distancia vertical $|y_i - \mu_y|$ entre el dato y la recta horizontal $y = \mu_y$.

La suma de las áreas de todos esos cuadrados es exactamente $STC = \sum_i (y_i - \mu_y)^2$.

En el panel central, los puntos ya no son los datos originales, sino los *valores ajustados* $\hat{y}_i$ —por eso aparecen perfectamente alineados sobre la recta de regresión—; el lado de cada cuadrado es ahora la distancia $|\hat{y}_i - \mu_y|$. La suma de áreas de estos cuadrados es $SEC = \sum_i (\hat{y}_i - \mu_y)^2$.

En el panel de la derecha, los cuadrados —notablemente más pequeños que en los dos paneles anteriores, cuando el ajuste es razonablemente bueno— tienen como lado la distancia vertical entre cada dato y su propio ajuste, $|y_i - \hat{y}_i|$, es decir, el residuo $|\hat{e}_i|$. La suma de estas áreas es $SRC = \sum_i \hat{e}_i^2$.

La identidad $STC = SEC + SRC$, que en las transparencias 2-3 demostramos como una única igualdad entre normas de vectores en $\mathbb{R}^n$, se lee aquí observación a observación: la suma de las áreas de la izquierda es igual a la suma de las áreas del centro más la suma de las áreas de la derecha. Es la misma identidad, vista con otros ojos —con los ojos del diagrama de dispersión en lugar de los del espacio abstracto de datos—, y por eso, deliberadamente, usamos aquí las siglas STC/SEC/SRC (la versión “sin dividir por n ”, de la que advertimos en la transparencia 3), porque es precisamente la versión que corresponde a sumar áreas de cuadrados sin más.

Esta segunda representación —cuadrados sobre el diagrama de dispersión frente a vectores abstractos en $\mathbb{R}^n$ — es, de hecho, la ilustración clásica que aparece en muchos manuales de econometría al presentar R^2 por primera vez; aquí llega en último lugar, precisamente para que el alumno entendiera primero *por qué* es cierta la identidad (Pitágoras en $\mathbb{R}^n$, transparencias 2-3) antes de verla como una simple receta de “sumar áreas de cuadraditos”.

Para profundizar:

- Wooldridge, J. M. (2020), cap. 2: representación gráfica clásica de la descomposición de varianzas sobre el diagrama de dispersión.

11 Recapitulación y guiño a la lección siguiente

Paso	Resultado
Descomposición ortogonal	$(\mathbf{y} - \bar{\mathbf{y}}) = (\hat{\mathbf{y}} - \bar{\mathbf{y}}) + \hat{\mathbf{e}}$, sumandos ortogonales
Pitágoras	$\sigma_y^2 = \sigma_{\hat{y}}^2 + \sigma_{\hat{e}}^2$ (STC=SEC+SRC)
Definición	$R^2 = SEC/STC = \cos^2 \theta = \rho_{y\hat{y}}^2$
Caso simple (un regresor)	$R^2 = \rho_{xy}^2$

Más adelante: el mismo argumento —Pitágoras + las dos ortogonalidades de la lección 7— se generalizará a k regresores: solo cambiará la dimensión del subespacio sobre el que proyectamos. Las primeras figuras de esta sesión, al no mostrar $\hat{\beta}_1 \mathbf{x}$ explícitamente, valdrán como esquema para el caso general.

Próxima sesión: laboratorio; verificaremos con datos reales que $\sum \hat{e}_i = 0$, $\sum x_i \hat{e}_i = 0$ y que el R^2 calculado a mano coincide con el que reporta Gretl.

Lección 9 — El puente: hasta ahora, pura geometría en $\mathbb{R}^n$, sin ningún supuesto probabilístico. La próxima lección teórica da el salto —como analogía, no como demostración— al espacio de las variables aleatorias: la esperanza condicional $E[Y | X]$ jugará el papel de $\hat{\mathbf{y}}$.

Recapitulación y guiño a la lección 9

El recorrido de hoy ha sido, otra vez, muy corto en ingredientes nuevos: la única pieza matemática genuinamente nueva ha sido aplicar el teorema de Pitágoras (lección 3) al triángulo rectángulo formado por $\mathbf{y} - \bar{\mathbf{y}}$, $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ y $\hat{\mathbf{e}}$ —un triángulo que ya estaba, en germen, en las dos condiciones de ortogonalidad resueltas en la lección 7—. Todo lo demás ha sido, una vez más, *aplicar* herramientas ya conocidas: la definición de varianza (lección 5), la definición de coseno (lección 3), y la fórmula de $\hat{\beta}_1$ (lección 7).

Merece la pena remarcar, para cerrar, tres ideas:

1. La descomposición $\sigma_{\mathbf{y}}^2 = \sigma_{\hat{\mathbf{y}}}^2 + \sigma_{\hat{\mathbf{e}}}^2$ (o, sin el factor $1/n$, $\text{STC} = \text{SEC} + \text{SRC}$) es consecuencia directa e inevitable de las dos ortogonalidades de la lección 7: es lo que se obtiene, sin ningún supuesto adicional, de aplicar Pitágoras a esas ortogonalidades.
2. $R^2 = \cos^2 \theta$ mide, literalmente, cuánto se parece —en dirección, no en escala— el vector de datos en desviaciones al vector ajustado en desviaciones. En la regresión simple, ese ángulo coincide con el de la correlación entre $\mathbf{x}$ e $\mathbf{y}$ (transparencia 5), cerrando el círculo abierto en la lección 5; en la regresión múltiple (lección 10) seguirá siendo $\cos^2 \theta$, pero ya no será el cuadrado de alguna correlación con un regresor particular.
3. Un R^2 alto no es una condición necesaria para tomarse en serio un modelo, ni un R^2 bajo una condición suficiente para descartarlo. La identidad $\text{STC} = \text{SEC} + \text{SRC}$ es una propiedad geométrica que no distingue entre una relación económicamente sensata y una correlación espuria: eso exige, siempre, una teoría previa ajena a la pura geometría de los datos.

La práctica de laboratorio que sigue a esta lección retoma exactamente los datos con los que se trabajó en la lección 5, y comprobará numéricamente, con un conjunto de datos completo, tanto las dos condiciones de ortogonalidad como la propia descomposición $\text{STC} = \text{SEC} + \text{SRC}$ y el valor de R^2 que reporta Gretl automáticamente al pedir una regresión.

Y la lección 9 (“El puente”) dará un paso de naturaleza distinta a los de las lecciones anteriores: hasta ahora hemos trabajado exclusivamente con vectores concretos de $\mathbb{R}^n$, sin ningún supuesto sobre cómo se generaron los datos. La lección 9 presentará, como *analogía* explícita —no como demostración—, el paralelismo entre esta geometría muestral (vectores de datos) y el mundo de las variables aleatorias: el valor esperado jugará el papel de la media; la esperanza $E[\cdot]$ el papel del vector de medias; la esperanza condicional $E[Y | X]$, el papel de la proyección $\hat{\mathbf{y}}$; y los supuestos del modelo clásico de regresión serán, precisamente, las condiciones que hacen legítimo ese paralelismo. Solo entonces podremos empezar a hablar, con algún rigor, de cuándo cabe una lectura causal de un buen ajuste —la pregunta que hoy hemos dejado, deliberadamente, sin responder.

Para profundizar:

- Wooldridge, J. M. (2020), cap. 2, secciones 2.3-2.4: resumen completo de $\text{STC}/\text{SEC}/\text{SRC}$, R^2 y sus limitaciones interpretativas.
- Bujosa, M. *Curso de Álgebra Lineal*, cap. 11: teorema de Pitágoras y ángulo entre vectores en $\mathbb{R}^n$.