

Índice general

1	De dónde venimos, y el puente que cruzamos hoy	2
2	Un vector es una función; una variable aleatoria, también	4
3	El producto escalar de la probabilidad	6
4	La esperanza: dos caras de la misma moneda	7
5	Esperanza condicional: proyección sobre un espacio ENORME	9
6	El Modelo Clásico de Regresión: los supuestos	11
7	Consecuencias de $E[U \mid X] = 0$	13
8	Advertencia: álgebra sí, causalidad no (todavía)	14
9	El salto: método de los momentos	16
10	Recapitulación: el diccionario	19

Lección 9. El puente: de los vectores de datos a las variables aleatorias

Marcos Bujosa

16 de agosto de 2026

Resumen

“Eros está en el medio de la sabiduría y de la ignorancia.” (Diotima a Sócrates, Platón, *Banquete*, 203e)

Todo lo que hemos hecho hasta ahora era geometría de vectores *completamente conocidos*. Hoy damos un salto: presentamos, como analogía —no como demostración—, el mismo lenguaje geométrico aplicado a variables aleatorias, donde lo que buscamos nunca se posee del todo. De ese salto nacen los supuestos del Modelo Clásico de Regresión y una nueva forma de leer las fórmulas que ya calculamos en la lección 7.

“De lo que medimos a lo que solo podemos inferir.”

- ([slides](#)) — ([html](#)) — ([pdf](#))

1 De dónde venimos, y el puente que cruzamos hoy

Siete lecciones enteras trabajando en $\mathbb{R}^n$: medias, varianzas, covarianzas, correlaciones, la regresión simple, R^2 .

En ningún momento hemos necesitado un supuesto probabilístico. Todo era geometría pura sobre vectores de datos completamente conocidos.

“Eros está en el medio de la sabiduría y de la ignorancia.” (Diotima, *Banquete*, 203e)

Hoy cruzamos un puente: presentamos el mismo lenguaje geométrico aplicado a *variables aleatorias*.

Advertencia, desde ya: lo que sigue es una **analogía**, no una demostración. Y solo es válida para variables aleatorias con esperanza y varianza definidas — *no todas la tienen*.

De dónde venimos, y el puente que cruzamos hoy

Detengámonos un momento antes de avanzar, porque el paso que vamos a dar hoy es de naturaleza distinta a los de las siete sesiones anteriores.

Desde la lección 2 hemos trabajado con un objeto perfectamente conocido: un vector de datos $\mathbf{y} = (y_1, \dots, y_n) \in \mathbb{R}^n$. Cada componente y_i es un número real concreto, dado, sin ambigüedad. La

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

media μ_y no es una *estimación* de nada: es, literalmente, el producto escalar $\langle \mathbf{y}, \mathbf{1} \rangle_s$, calculado con exactitud a partir de los n números que tenemos delante. Lo mismo la varianza, la covarianza, la correlación, el ajuste $\hat{\mathbf{y}}$ y el residuo $\hat{\mathbf{e}}$: todos son cantidades *exactas*, calculables sin margen de error a partir de los datos que poseemos. En este sentido, $\mathbb{R}^n$ con el producto escalar de la estadística es un mundo de conocimiento cerrado: no hay nada que el vector de datos nos oculte sobre sí mismo.

Pero cuando en econometría decimos cosas como “el salario *depende* de la educación” o “el precio de la vivienda *depende* de su superficie”, no estamos pensando únicamente en los 14, en los 506 o en los n datos concretos que tenemos delante. Estamos pensando en algo más amplio: en una relación que, sospechamos, se sostiene más allá de la muestra particular que hemos observado — en *cualquier* vivienda, en *cualquier* trabajador, no solo en los de nuestra tabla de datos. Para expresar esa aspiración necesitamos un objeto matemático distinto del vector: la *variable aleatoria*.

Aquí es donde entra, con toda su fuerza, la cita de Diotima a Sócrates que abre esta lección. En el *Banquete* de Platón, Diotima explica a Sócrates que Eros —el amor, entendido como deseo filosófico de saber— no es ni un dios (que ya posee la sabiduría y por tanto no necesita buscarla) ni un ignorante (que ni siquiera sabe que le falta algo, y por eso tampoco busca). Eros habita el espacio *intermedio*: sabe que no sabe, y precisamente por eso desea, busca, filosofa.

La analogía con lo que hacemos hoy es, creo, bastante exacta. El vector de datos $\mathbf{y} \in \mathbb{R}^n$ que hemos usado hasta ahora es un conocimiento cerrado, sin resquicios de ignorancia — sabemos exactamente cuánto vale cada y_i , y por tanto sabemos exactamente cuánto vale μ_y , σ_y^2 , o cualquier otra cantidad calculada a partir de él; pero es un conocimiento incompleto, limitado a la muestra de datos de que disponemos. Cuando aspiramos a decir algo sobre el salario “en general”, o sobre el precio de la vivienda “en general” — no solo de los 14 casos que observamos, sino de la relación subyacente que sospechamos que existe y que ni observamos ni observaremos jamás en su totalidad —, no estamos en la posición del sabio. Pero tampoco estamos en la del ignorante total: no partimos de la nada, tenemos una muestra, un vector concreto, una teoría económica que orienta la búsqueda. Estamos, como Eros, en el medio: con datos parciales pero con el deseo (y las herramientas) de inferir algo que va más allá de una colección de datos parciales.

La *variable aleatoria* es, precisamente, el objeto matemático que formaliza esa posición intermedia. No es el vector de datos que tenemos; es la “fuente” abstracta de la que ese vector es, en cierto sentido, una muestra concreta. Y la esperanza matemática $E[Y]$ no es, como veremos, algo que calculemos con exactitud a partir de una tabla de números: es un número teórico, generalmente desconocido, que solo podemos *inferir* —nunca poseer del todo— a partir de nuestra muestra. Ahí radica el “deseo filosófico” del econometrista: no tiene la certeza del sabio (no conoce $E[Y]$), pero tampoco actúa a ciegas como el ignorante (tiene un vector de datos y un método, la geometría que hemos construido, para acercarse a esa certeza inalcanzable).

Con esta imagen en mente, precisemos ya la advertencia técnica de la transparencia. Todo lo que sigue en esta sesión es una *analogía*, deliberadamente construida en paralelo con la geometría de las lecciones 4 y 5, pero *no* es una demostración de que las variables aleatorias se comporten exactamente como los vectores de $\mathbb{R}^n$. Hay diferencias reales, que iremos señalando conforme aparezcan (la primera, ya en la próxima transparencia). Y hay, además, una restricción importante que conviene decir en voz alta desde ya: no todas las variables aleatorias tienen esperanza matemática definida, y entre las que la tienen, no todas tienen además varianza definida. Aquí trabajaremos exclusivamente con variables aleatorias con esperanza y varianza definidas.

Para quien quiera ver hasta qué punto la intuición cotidiana sobre “el valor esperado” puede fallar cuando la esperanza no está bien definida, recomiendo el vídeo [“The Two Envelope Problem — a Mystifying Probability Paradox”](#): un ejercicio mental sencillo de enunciar, y sorprendentemente resbaladizo, precisamente porque la esperanza matemática involucrada no está bien definida.

Para profundizar:

- Platón, *Banquete*, 203e–204a (discurso de Diotima sobre la naturaleza de Eros).
- Wooldridge, J. M. (2020), Apéndice C.1–C.2: repaso de variable aleatoria, función de distribución y esperanza matemática desde la estadística clásica.

2 Un vector es una función; una variable aleatoria, también

Un vector $\mathbf{y} \in \mathbb{R}^n$ (lista ordenada de números —Lección 2) es una *función* que asigna un número a cada índice $i \in \{1, \dots, n\}$.

Una *variable aleatoria* Y es también una función — pero definida sobre un conjunto Ω (de “sucesos elementales”), generalmente más grande y sin una descripción explícita.

$\mathbb{R}^n$	Variables aleatorias
dominio $\{1, \dots, n\}$	dominio Ω
$\mathbf{y}(i) = y_i$	$Y(\omega)$
vector = lista de n números	v.a. = función sobre Ω

Lo que *sobrevive* al cambio:

La *combinación lineal* (lección 2) de variables aleatorias $\beta_0 1 + \beta_1 X$ sigue siendo una variable aleatoria, exactamente como $\beta_0 \mathbf{1} + \beta_1 \mathbf{x}$ era un vector.

Un vector es una función; una variable aleatoria, también

En la lección 2 definimos un vector $\mathbf{y} = (y_1, \dots, y_n)$ como una lista ordenada de números; pero esta definición nos permite afirmar que un vector de $\mathbb{R}^n$ es, sencillamente, una *función* que asigna a cada índice i , del conjunto $\{1, 2, \dots, n\}$, un número real y_i .

Una *variable aleatoria* Y es, formalmente, el mismo tipo de objeto: una función que asigna un número real a cada elemento de un conjunto. La diferencia está en el dominio. En $\mathbb{R}^n$, el dominio es el conjunto finito y perfectamente conocido $\{1, \dots, n\}$ (los índices de nuestras n observaciones). En el caso de una variable aleatoria, el dominio es un conjunto Ω —llamado convencionalmente “espacio de sucesos elementales”— que puede ser enorme, incluso infinito, y cuyos elementos concretos casi nunca se describen (salvo en en los cursos de probabilidad para presentar ejemplos triviales como el lanzamiento de un dado o una moneda). $Y(\omega)$ denota el valor numérico que la variable aleatoria Y asigna al elemento $\omega \in \Omega$. Como las variables aleatorias pueden sumarse y multiplicarse por escalares para obtener nuevas variables aleatorias, también forman un espacio vectorial (aunque ya no es el espacio $\mathbb{R}^n$ de las primeras lecciones).

Aquí aparece ya la primera diferencia real entre ambos mundos, y conviene señalarla sin rodeos: mientras que en $\mathbb{R}^n$ conocemos perfectamente el dominio (los índices $1, \dots, n$), en el caso de las variables aleatorias casi nunca sabemos, ni necesitamos saber, qué es exactamente Ω . Cuando decimos

“el precio de una vivienda, P , es una variable aleatoria”, no estamos pensando en un Ω concreto con sucesos elementales identificables uno a uno; estamos usando la maquinaria matemática de las variables aleatorias para modelizar de manera abstracta nuestra incertidumbre sobre ese precio, sin necesidad de precisar más.

Pese a esta diferencia importante, lo que sobrevive intacto a este cambio es precisamente lo que permite mantener la maquinaria que hemos usado hasta hoy: la *combinación lineal*, introducida ya en la lección 2. Del mismo modo que $\beta_0 \mathbf{1} + \beta_1 \mathbf{x}$ era, en $\mathbb{R}^n$, otro vector (obtenido sumando dos vectores tras multiplicarlos por escalares), la expresión $\beta_0 \cdot 1 + \beta_1 X$ —donde 1 denota la variable aleatoria *constante* igual a 1 en todo Ω ,¹ y X es otra variable aleatoria— es otra una variable aleatoria. Esta es la observación que permitirá, en unas transparencias, escribir el modelo de regresión $Y = \beta_0 \cdot 1 + \beta_1 X + U$ con total naturalidad: es la misma operación algebraica de siempre, solo que ahora los objetos que combinamos ya no son listas de n números, sino funciones sobre un dominio Ω (casi nunca especificado explícitamente).

Para poder aplicar toda la intuición de proyecciones y ortogonalidad que aprendimos en las lecciones 2 a 8, también necesitamos un producto escalar.² En este nuevo espacio de variables aleatorias, ese papel lo jugará la *esperanza matemática del producto*: $\langle X, Y \rangle_P = E[XY]$.

Debemos hacer dos advertencias de “honestidad epistemológica”:

1. *No todas las variables aleatorias sirven*: Asumiremos que las variables con las que trabajamos tienen varianza finita (y, por tanto, esperanza finita). Si han cursado probabilidad, sabrán que la mayoría de distribuciones famosas cumplen esto. Pero existen distribuciones (“colas pesadas” como la de Cauchy) donde la esperanza diverge hacia el infinito o directamente no está definida.³ En econometría asumiremos que nuestras variables económicas se portan bien y tienen varianzas finitas.
2. *Trabajaremos con un semi-producto escalar*: En $\mathbb{R}^n$, si $\|\mathbf{x}\|_s^2 = 0$, forzosamente $\mathbf{x} = \mathbf{0}$ (todos sus elementos son el número cero). En probabilidad, si $E[X^2] = 0$, sabemos que la variable X vale 0 con probabilidad 1 (casi seguro). Podría existir algún suceso ω , de probabilidad estrictamente nula, donde la variable tome otro valor: $X(\omega) \neq 0$. Desde el punto de vista geométrico esto es un engorro técnico menor: consideramos que todas las variables que difieren solo en sucesos de probabilidad cero pertenecen a una misma “clase de equivalencia” y las tratamos como si fueran el mismo vector. Por simplicidad, hablaremos de producto escalar asumiendo este matiz de fondo.

A partir de este nuevo producto escalar $\langle \cdot, \cdot \rangle_P$, podemos reconstruir *todo* nuestro diccionario geométrico.

Para profundizar:

- Wooldridge, J. M. (2020), Apéndice B.1: definición de variable aleatoria y su papel en el modelado econométrico.

¹es decir, $1(\omega) = 1$ para todo ω del dominio Ω .

²realmente un semi-producto escalar.

³Si sienten curiosidad por cómo un problema probabilístico puede romperse por culpa de una esperanza indefinida, les recomiendo vivamente este vídeo divulgativo: “[The Two Envelope Problem - a Mystifying Probability Paradox](#)”.

- Bujosa, M., *Lección 4: Variables aleatorias y momentos condicionados*, sección “[Las variables aleatorias como modelo](#)”: discusión extensa (con ejemplos, incluida la advertencia de que ni siquiera necesitamos describir Ω explícitamente) sobre la naturaleza de las variables aleatorias como funciones.

3 El producto escalar de la probabilidad

En $\mathbb{R}^n$: $\langle \mathbf{x}, \mathbf{y} \rangle_s = \frac{1}{n}(\mathbf{x} \cdot \mathbf{y})$.

Con variables aleatorias, el papel de $\langle \cdot, \cdot \rangle_s$ lo juega la *esperanza del producto*:

$$\langle X, Y \rangle_P = E[XY].$$

Advertencia honesta: $\langle \cdot, \cdot \rangle_P$ es solo un *semi*-producto escalar. $E[X^2] = \|X\|^2 = 0$ NO implica $X = 0$ (puede ser cero “casi seguro”; no lo desarrollaremos).

Pero Pitágoras, Cauchy–Schwarz y la desigualdad triangular (lección 3) solo exigían simetría, linealidad y positividad — *no* positividad estricta. Así que *siguen siendo válidos*, sin cambiar una coma.

El producto escalar de la probabilidad

Toda la geometría que hemos construido desde la lección 3 —ortogonalidad, ángulos, Pitágoras, proyecciones— dependía de un único ingrediente: un producto escalar $\langle \cdot, \cdot \rangle$ con tres propiedades abstractas (simetría, linealidad en cada argumento, positividad). En la lección 4 vimos que, para hacer estadística en $\mathbb{R}^n$, convenía usar el producto escalar $\langle \mathbf{x}, \mathbf{y} \rangle_s = \frac{1}{n}(\mathbf{x} \cdot \mathbf{y})$, con el factor $\frac{1}{n}$ elegido precisamente para que $\|\mathbf{1}\|_s = 1$.

Para dar el salto de hoy necesitamos, exactamente en el mismo lugar de la construcción, un producto escalar entre variables aleatorias. La elección natural —y la que hace que todo el paralelismo funcione— es la *esperanza del producto*:

$$\langle X, Y \rangle_P = E[XY],$$

donde XY denota el producto *punto a punto* de las dos funciones X y Y (es decir, la función que a cada $\omega \in \Omega$ le asigna $X(\omega) \cdot Y(\omega)$): el análogo exacto, en el mundo de las variables aleatorias, del producto componente a componente $\mathbf{x} \odot \mathbf{y}$ que en la lección 7 usamos para escribir la “fórmula de cálculo” de la varianza y la covarianza.

Verifiquemos que $\langle \cdot, \cdot \rangle_P$ hereda, en efecto, las propiedades que necesitamos:

- *Simetría:* $E[XY] = E[YX]$, trivialmente, porque el producto de números reales es conmutativo.
- *Linealidad:* $E[(aX + bZ)Y] = aE[XY] + bE[ZY]$, porque la esperanza matemática es una operación lineal (esto se demuestra en cualquier curso de probabilidad; aquí lo asumimos).
- *Positividad:* $E[X^2] \geq 0$, porque $X^2(\omega) \geq 0$ para todo ω , y la esperanza de una función no negativa no puede ser negativa.

Las tres se cumplen (aunque aquí solo lo enunciemos sin demostración). Pero hay una diferencia real, y conviene señalarla con la misma honestidad con que hemos señalado cada diferencia entre los dos mundos a lo largo de esta sesión: en $\mathbb{R}^n$, un producto escalar propio exige además que $\langle \mathbf{x}, \mathbf{x} \rangle = 0$ implique $\mathbf{x} = \mathbf{0}$ (positividad *estricta*); y en efecto, $\frac{1}{n}(\mathbf{x} \cdot \mathbf{x}) = 0$ obliga a que cada componente de $\mathbf{x}$ sea cero. Con $\langle \cdot, \cdot \rangle_P$ esto ya no es cierto: $E[X^2] = 0$ no implica que X sea la variable aleatoria idénticamente nula en todo Ω ; solo implica que X vale cero *con probabilidad uno* —es decir, que el conjunto de ω para los que $X(\omega) \neq 0$ tiene, en el sentido de la probabilidad, “tamaño” cero, aunque pudiera no estar vacío—. A un objeto así, que cumple simetría, linealidad y positividad pero no positividad estricta, se le llama *semi*-producto escalar (o semi-norma, cuando hablamos de $\sqrt{E[X^2]}$). No desarrollaremos esta sutileza —pertenece a un curso de probabilidad más formal—, pero es importante saber que existe, para no dar por sentado que el paralelismo con $\mathbb{R}^n$ es perfecto en todos sus detalles.

¿Qué salvamos, entonces, de todo el edificio construido en la lección 3? La buena noticia es que *todo*. Repasando las demostraciones de la lección 3 —Pitágoras, la desigualdad de Cauchy–Schwarz, la desigualdad triangular—, ninguna de ellas usó en ningún momento la propiedad de positividad *estricta*. Todas se apoyaban únicamente en simetría, linealidad y positividad (no estricta). Por tanto, esas tres demostraciones siguen siendo válidas, palabra por palabra, con $\langle \cdot, \cdot \rangle_P$ en lugar de $\langle \cdot, \cdot \rangle_s$: seguiremos pudiendo hablar de vectores ortogonales ($\langle X, Y \rangle_P = 0$), de la norma de una variable aleatoria ($\|X\|_P = \sqrt{E[X^2]}$), y de proyecciones ortogonales, con exactamente el mismo aparato geométrico.

A partir de aquí, y para no sobrecargar la notación, escribiremos sencillamente $E[XY]$ en lugar de $\langle X, Y \rangle_P$ (así lo hace, de hecho, toda la literatura econométrica): pero conviene tener presente, que la operación $E[XY]$ tiene el mismo papel que $\langle \mathbf{x}, \mathbf{y} \rangle_s$ en $\mathbb{R}^n$.

Para profundizar:

- Wooldridge, J. M. (2020), Apéndice B.3: propiedades de linealidad de la esperanza.

4 La esperanza: dos caras de la misma moneda

Recordando la lección 4 (dos caras de la media):

$\mathbb{R}^n$	Variables aleatorias
$\mu_{\mathbf{y}} = \langle \mathbf{y}, \mathbf{1} \rangle_s$	$E[Y] = \langle Y, 1 \rangle_P = E[Y \cdot 1]$
$\bar{\mathbf{y}} = \mu_{\mathbf{y}} \mathbf{1}$ (vector <i>constante</i>)	$E[Y 1] = E[Y] \cdot 1$ (función <i>constante</i>)

$E[Y]$ es un *número* por el que multiplicar la función constante 1 para obtener la función constante más próxima a Y (su proyección ortogonal sobre $\mathcal{L}(1)$).

$E[Y | 1]$ es una *función constante* — igual a $E[Y]$ en todo punto de Ω : la misma proyección, vista como variable aleatoria.

Exactamente la misma distinción que separaba $\mu_{\mathbf{y}}$ (número) de $\bar{\mathbf{y}}$ (vector).

La esperanza: dos caras de la misma moneda

En la lección 4 insistimos, con cierto detalle, en una distinción que entonces pudo parecer casi pedante: la media $\mu_{\mathbf{y}}$ es un *número* (un escalar), mientras que el vector de medias $\bar{\mathbf{y}} = \mu_{\mathbf{y}}\mathbf{1}$ es un *vector* (un objeto con n componentes, todas iguales a $\mu_{\mathbf{y}}$). Ambos están relacionados —el segundo se construye multiplicando el primero por $\mathbf{1}$ —, pero son objetos de naturaleza distinta, y confundirlos era, dijimos entonces, un error a evitar.

Esa distinción, que en $\mathbb{R}^n$ podía parecer un refinamiento notacional, resulta ser exactamente la que necesitamos ahora para no perdernos en el mundo de las variables aleatorias. Definimos:

Definición. La *esperanza matemática* de una variable aleatoria Y es

$$E[Y] = \langle Y, 1 \rangle_P = E[Y \cdot 1],$$

donde 1 denota la variable aleatoria constante igual a 1 en todo Ω .

Esta definición es, deliberadamente, un calco de $\mu_{\mathbf{y}} = \langle \mathbf{y}, \mathbf{1} \rangle_s$: la esperanza es, literalmente, el producto escalar de Y con la constante 1 , medido con el producto escalar de la probabilidad. $E[Y]$ es, por tanto, un *número real*: el mismo tipo de objeto que $\mu_{\mathbf{y}}$.

Pero, exactamente igual que en la lección 4, no basta con quedarnos en el número: necesitamos también su versión como *función constante*, el análogo exacto de $\bar{\mathbf{y}}$. Definimos:

Definición. La *esperanza de Y condicionada a 1* , denotada $E[Y \mid 1]$, es la función constante (sobre todo Ω) igual al número $E[Y]$:

$$E[Y \mid 1] = E[Y] \cdot 1.$$

Adviértase con cuidado la naturaleza de este objeto: $E[Y \mid 1]$ *no* es un número. Es una *variable aleatoria* —una función definida sobre todo Ω — que, eso sí, resulta ser particularmente sencilla: toma el mismo valor, $E[Y]$, en *cualquier* $\omega \in \Omega$ que se elija. Es el análogo exacto de $\bar{\mathbf{y}}$: así como $\bar{\mathbf{y}}$ era el vector cuyas n componentes eran todas iguales a $\mu_{\mathbf{y}}$, $E[Y \mid 1]$ es la función cuyo valor es siempre —en cualquier punto de su dominio, por vasto que sea Ω — igual a $E[Y]$.

¿Por qué merece la pena insistir tanto en esta distinción, que en $\mathbb{R}^n$ ya nos costó un esfuerzo notacional? Porque de aquí en adelante distinguiremos sistemáticamente $E[Y]$ (número) de $E[Y \mid X]$ (función, en general *no* constante, como veremos en la próxima transparencia). Si no fijamos bien ahora, con el caso más simple posible ($X = 1$, la variable aleatoria constante), la diferencia entre “el número” y “la función constante”, será mucho más difícil fijar después la diferencia entre valor esperado (“número”) y esperanza condicional (“variable aleatoria”).

Una nota tipográfica que puede ayudar a no confundirse: escribimos **1** (con negrita) para el vector de $\mathbb{R}^n$ formado por n unos, y *1* (cursiva sin negrita) para la variable aleatoria constante igual a uno sobre Ω . Las variables aleatorias, a diferencia de los vectores de $\mathbb{R}^n$, nunca se escriben en negrita en este curso; esta convención tipográfica, aunque modesta, ayuda a no perder de vista en qué mundo estamos trabajando en cada fórmula.

Podemos comprobar, con el mismo argumento de proyección ortogonal que usamos en la lección 4 para la media, que $E[Y]$ es efectivamente el número que hace que $E[Y \mid 1]$ sea la función constante

más próxima a Y (en la norma $\|\cdot\|_P$): la diferencia $Y - E[Y] \cdot 1$ debe ser ortogonal a la constante 1 , es decir, $E[(Y - E[Y] \cdot 1) \cdot 1] = 0$, lo cual se cumple trivialmente por la propia definición de $E[Y]$. No repetiremos aquí la deducción completa —es exactamente la misma álgebra de la lección 4, con $E[\cdot]$ en el lugar de $\langle \cdot, \cdot \rangle_s$ —, pero merece la pena que el lector la reconstruya por sí mismo, como ejercicio de que el paralelismo funciona en cada detalle.

Para profundizar:

- Wooldridge, J. M. (2020), Apéndice B.3: definición y propiedades básicas de $E[Y]$.

5 Esperanza condicional: proyección sobre un espacio ENORME

En regresión simple proyectábamos y sobre el *plano* $\mathcal{L}(1, X)$ — solo dos direcciones, 1 y X .

La *esperanza condicional* $E[Y | X]$ proyecta Y sobre un espacio mucho más grande: *el conjunto de TODAS las funciones de X* (con varianza finita) — no solo $\beta_0 + \beta_1 X$.

$E[Y | X]$ es, en general, la función de X *más próxima* a Y — y esa función puede tener *cualquier forma*: curva, escalón, lo que sea. No hay razón, a priori, para que sea una recta.

Y (verde), su proyección $E[Y | X]$ (rojo), $U = Y - E[Y | X]$ (gris) ortogonal a ella.

Anticipo: si (X, Y) son conjuntamente *normales*, $E[Y | X]$ SÍ resulta ser lineal — deja de ser supuesto y pasa a ser teorema.

La esperanza condicional: proyección sobre un espacio ENORME

Llegamos al concepto más importante de la sesión, y también al que exige más cuidado para no confundirlo con algo que ya conocemos.

En la lección 8 (regresión lineal simple), proyectamos y sobre el *plano* $\mathcal{L}(\mathbf{1}, \mathbf{x})$ — es decir, sobre el conjunto de todas las combinaciones lineales $\beta_0 \mathbf{1} + \beta_1 \mathbf{x}$. Ese plano, aunque contiene infinitos vectores, tiene solo *dos* direcciones independientes: fijado $\mathbf{x}$, cada vector del plano queda determinado por un único par de números (β_0, β_1) .

Sería tentador imaginar que, al pasar a variables aleatorias, la “esperanza condicional de Y dado X ”, $E[Y | X]$, es simplemente la proyección de Y sobre el análogo de ese mismo plano: el conjunto de todas las combinaciones $\beta_0 \cdot 1 + \beta_1 X$. Pero esto sería, en general, *incorrecto* — y la razón de por qué lo es constituye, quizá, la diferencia más profunda entre los dos mundos que hemos comparado hoy.

$E[Y | X]$ se define, en realidad, como la proyección de Y sobre un espacio mucho más grande: el conjunto de *todas* las funciones de X (con varianza finita) — es decir, de todas las variables aleatorias que se pueden escribir como $g(X)$ para alguna función g , sin restricción alguna sobre la forma de g . Este conjunto no solo contiene las combinaciones lineales $\beta_0 + \beta_1 X$; contiene también X^2 , $\sqrt{|X|}$, $\sin(X)$, funciones a trozos, y cualquier otra transformación imaginable de X que tenga varianza finita. En términos de la “dimensión” informal que usamos en la lección 5 (una recta tiene una dirección; un plano, dos), este espacio de funciones tiene, en general, *dimensión infinita*: hay infinitas direcciones independientes en las que “moverse” dentro de él, muchas más de las dos que teníamos en $\mathcal{L}(\mathbf{1}, \mathbf{x})$.

La *esperanza condicional* $E[Y | X]$ es, por definición, la función de X (dentro de ese espacio enorme) que resulta más próxima a Y en la norma $\|\cdot\|_P$ — es decir, la que hace mínima $E[(Y - g(X))^2]$ entre todas las funciones g posibles. Y aquí está la consecuencia que conviene subrayar con toda claridad: como el espacio sobre el que proyectamos es tan vasto, *no hay ninguna razón, en general, para que esa función más próxima sea una recta*. $E[Y | X]$ puede ser, en principio, cualquier curva: puede subir y luego bajar, puede tener escalones, puede curvarse de maneras arbitrariamente complicadas. La única propiedad que le exigimos, por definición, es ser la función de X que minimiza la distancia a Y — no que sea lineal.

La figura de la transparencia ilustra esta idea con el lenguaje visual que ya hemos usado en las lecciones 8 y 10: la variable aleatoria Y (verde) se descompone en dos partes ortogonales, su proyección $E[Y | X]$ (rojo) sobre el espacio de funciones de X , y el residuo $U = Y - E[Y | X]$ (gris), perpendicular a esa proyección —marcado, como en aquellas figuras, con un ángulo recto—. La diferencia esencial respecto a aquellas figuras es que aquí el “plano” sobre el que proyectamos ya no es un plano de dos direcciones: es, informalmente, un espacio con tantísimas direcciones que ni siquiera podemos dibujarlo con fidelidad geométrica; la figura debe leerse, por tanto, como un esquema, no como una representación literal.

Esta observación no es un mero tecnicismo: es, precisamente, la que da sentido genuino al *primer supuesto* del Modelo Clásico de Regresión, que presentaremos en la próxima transparencia. Decir que “ Y es, en promedio, una función *lineal* de X ” —es decir, que $E[Y | X] = \beta_0 + \beta_1 X$ — no es una trivialidad automática, como podría parecer si pensáramos (erróneamente) que $E[Y | X]$ vive por definición en el plano de las rectas. Es, por el contrario, un supuesto sustantivo: estamos afirmando que, de entre todas las infinitas formas funcionales posibles que $E[Y | X]$ podría tener, la que efectivamente tiene la relación entre X e Y resulta ser, precisamente, una recta.

Cerramos esta transparencia con un anticipo, sin desarrollarlo: hay, sin embargo, una circunstancia particular en la que la linealidad de $E[Y | X]$ deja de ser un supuesto y se convierte en un *teorema* —algo que se puede demostrar, no que haya que suponer—. Si X e Y son *conjuntamente normales* (si su distribución de probabilidad conjunta sigue una distribución normal bivalente), entonces se puede demostrar que, necesariamente, $E[Y | X]$ es una función lineal de X . No desarrollaremos aquí esta demostración —pertenecería a un curso de probabilidad más avanzado—, pero conviene saber que existe, porque explica por qué el supuesto de normalidad conjunta, cuando se añade al modelo clásico (algo que en este curso no haremos de forma sistemática, pero que aparece con frecuencia en los manuales), tiene una consecuencia muy concreta: convierte en teorema lo que, sin él, es solo un supuesto que imponemos por simplicidad.

Para profundizar:

- Bujosa, M., *Lección 4*, sección “Esperanza condicional”: definición completa de $E[Y | X]$ como proyección ortogonal sobre el subespacio probabilístico generado por X , con la advertencia (que aquí simplificamos) de que, en rigor, dicha proyección es una *clase de equivalencia* de variables aleatorias, no una única función.
- Wooldridge, J. M. (2020), Apéndice B.4 y capítulo 2, sección 2.6: introducción intuitiva a la esperanza condicional y su papel en la especificación del modelo de regresión.

6 El Modelo Clásico de Regresión: los supuestos

Ahora sí podemos escribir, con sentido pleno:

$$Y = \beta_0 \cdot 1 + \beta_1 X + U.$$

Tres supuestos (el Modelo Clásico de Regresión Lineal):

1. *Linealidad*: $E[Y | X] = \beta_0 \cdot 1 + \beta_1 X$. (De todo el espacio de funciones de X : precisamente la recta.)
2. *Exogeneidad estricta*: $E[U | X] = 0$.
3. *Homocedasticidad*: $\text{Var}[U | X] = \sigma^2$ (constante, no depende de X).

Nomenclatura: Y regresando; X regresor; U perturbación (“otras cosas”).

Nótese: *ya no llevan sombrero*. β_0, β_1 son parámetros *poblacionales*, desconocidos — no los $\hat{\beta}_0, \hat{\beta}_1$ de la lección 7.

El Modelo Clásico de Regresión: los supuestos

Con la transparencia anterior en la mano, ya podemos escribir la ecuación con la que trabajaremos el resto del curso, y hacerlo con pleno sentido —no como una fórmula memorizada, sino como consecuencia de todo lo dicho hasta ahora.

Definimos, sencillamente, $U = Y - E[Y | X]$: la diferencia entre Y y su proyección sobre el espacio (enorme) de las funciones de X . Por construcción —exactamente como en $\mathbb{R}^n$, donde $\mathbf{y} - \hat{\mathbf{y}}$ era ortogonal a todo el plano de regresores—, U es ortogonal (en el sentido de $\langle \cdot, \cdot \rangle_P$) a $E[Y | X]$, y a cualquier función de X . Con esta definición, podemos escribir siempre, sin ningún supuesto adicional:

$$Y = E[Y | X] + U.$$

Esta descomposición es, como todas las que hemos hecho en $\mathbb{R}^n$, puramente algebraica: se cumple *siempre*, sea $E[Y | X]$ una recta, una curva, o lo que sea. Ahora bien, el *Modelo Clásico de Regresión Lineal* consiste en añadir tres supuestos que, cuando se cumplen, simplifican radicalmente esta descomposición general y la reducen a algo mucho más manejable.

Primer supuesto: linealidad. Suponemos que

$$E[Y | X] = \beta_0 \cdot 1 + \beta_1 X,$$

para ciertos números β_0, β_1 . Como discutimos en la transparencia anterior, este es un supuesto genuino: de entre todas las funciones posibles de X que podrían ser la proyección de Y , estamos afirmando que la que efectivamente lo es resulta ser, precisamente, una recta. Con este supuesto, la descomposición general $Y = E[Y | X] + U$ se convierte en

$$Y = \beta_0 \cdot 1 + \beta_1 X + U.$$

Adviértase, y esto es importante, la ausencia de sombrero sobre β_0 y β_1 . En la lección 7 calculamos $\hat{\beta}_0, \hat{\beta}_1$ a partir de un vector de datos concreto $\mathbf{y}, \mathbf{x} \in \mathbb{R}^n$, mediante las condiciones de ortogonalidad

muestrales. Aquí, β_0 y β_1 son *parámetros poblacionales*: números fijos, pero *desconocidos*, que describen la relación teórica subyacente entre las variables aleatorias X e Y —no algo que calculemos a partir de una muestra concreta, sino algo que la muestra nos permitirá, más adelante en esta misma sesión, /estimar/—.

Segundo supuesto: exogeneidad estricta. Suponemos que

$$E[U \mid X] = 0,$$

es decir, que la esperanza condicional de la perturbación es la función constante igual a cero. Este supuesto es, con diferencia, el más fuerte y el más delicado de los tres: dice que, condicionando en X , la perturbación no revela absolutamente ninguna información adicional sobre su propio comportamiento medio; que X no tiene ninguna capacidad predictiva sobre U , ni siquiera parcial. En la próxima transparencia extraeremos algunas consecuencias muy concretas de este supuesto.

Tercer supuesto: homocedasticidad. Suponemos que

$$\text{Var}[U \mid X] = \sigma^2,$$

para algún número $\sigma^2 > 0$ que *no depende de X* . Es decir, la dispersión de la perturbación alrededor de su media (que ya es cero, por el supuesto anterior) es la misma, sea cual sea el valor de X que consideremos. Mencionamos este tercer supuesto de forma breve por ahora; será protagonista de una sesión posterior, cuando discutamos qué ocurre —y cómo se corrige— cuando *no* se cumple (heterocedasticidad).

Con estos tres supuestos ya podemos fijar la nomenclatura que usaremos durante el resto del curso, que —como observó Bujosa en su lección 4— resulta ser una nomenclatura un tanto pretenciosa en varios manuales, y que aquí preferimos presentar con sencillez: Y se llama *regresando* (la variable que queremos explicar); X , *regresor* (la variable con la que la explicamos); y U , *perturbación* —o, con una expresión menos solemne pero muy honesta, =otras cosas=: todo aquello que afecta a Y y que no hemos incluido explícitamente en el modelo a través de X .

Adviértase, finalmente, cómo esta terminología recupera —con pleno sentido ahora— la distinción que sembramos en la lección 6 (sesión 8) entre =regresor” (un vector, o ahora una variable aleatoria, que multiplica a un coeficiente β) y =variable explicativa” (el concepto sustantivo, con su matiz causal, que puede entrar en el modelo mediante uno o varios regresores). Ese matiz causal, que en la lección 6 pospusimos deliberadamente, es precisamente lo que abordaremos en la próxima transparencia.

Para profundizar:

- Bujosa, M., *Lección 5*, sección “Modelo Clásico de Regresión Lineal” y los “Supuestos 1, 2 y 3”: presentación formal (con proyecciones ortogonales sobre subespacios probabilísticos) de estos mismos tres supuestos.
- Wooldridge, J. M. (2020), capítulo 2, secciones 2.1 y 2.5: presentación clásica del modelo de regresión simple y sus supuestos.

7 Consecuencias de $E[U | X] = 0$

Como $E[U | X]$ es la proyección de U sobre *todo* el espacio de funciones de X : si esa proyección es la función 0, entonces U es ortogonal a *cualquier* función de X .

En particular, ortogonal a 1 y a X :

$$E[U] = 0 \quad \text{y} \quad E[UX] = 0.$$

El truco del vector de media nula, otra vez (lección 6, sesión 8): como $E[U] = 0$,

$$\text{Cov}(U, X) = E[UX] - E[U]E[X] = E[UX] = 0.$$

Exactamente el mismo argumento algebraico con el que, en la lección 6, un vector ortogonal a **1** tenía covarianza (no solo producto escalar) nula con cualquier otro vector.

Y por la Ley de las Esperanzas Iteradas ($E[Y] = E[E[Y | X]]$, que aquí no demostramos): $E[U] = E[E[U | X]] = E[0] = 0$ —coherente con lo anterior.

Consecuencias de $E[U | X] = 0$

El segundo supuesto del modelo clásico, $E[U | X] = 0$, parece a primera vista una condición abstracta y difícil de manejar. Pero, precisamente por ser una condición de *proyección ortogonal* sobre un espacio enorme (el de todas las funciones de X), tiene consecuencias muy concretas y muy manejables, que extraemos en esta transparencia.

Recordemos de la transparencia anterior a esta que $E[U | X]$ es, por definición, la proyección ortogonal de U sobre el espacio de todas las funciones de X . El supuesto $E[U | X] = 0$ afirma que esa proyección es, precisamente, la función idénticamente nula. Pero si la proyección de U sobre *todo* ese espacio es cero, entonces —por la propia definición de proyección ortogonal— U debe ser ortogonal a *cada uno* de los elementos de ese espacio; es decir, ortogonal a *cualquier* función de X , sin excepción.

En particular, dos funciones muy sencillas de X pertenecen a ese espacio: la función constante 1 (que trivialmente es una “función de X ”, aunque no dependa realmente de él) y la propia X . De la ortogonalidad de U frente a 1 y frente a X obtenemos, respectivamente:

$$E[U] = \langle U, 1 \rangle_P = E[U \cdot 1] = 0, \quad E[UX] = \langle U, X \rangle_P = 0.$$

Es decir: $E[U | X] = 0$ implica, como caso particular, tanto que la esperanza (sin condicionar) de U es cero, como que U y X tienen producto escalar nulo (en el sentido de $\langle \cdot, \cdot \rangle_P$).

Ahora bien, ¿qué es exactamente $E[UX]$, y en qué se diferencia de la *covarianza* entre U y X ? Aquí es donde reaparece, con toda su fuerza, “el truco del vector de media nula” que introdujimos en la lección 6 (sesión 8), al estudiar la ortogonalidad del residuo de la regresión frente a los regresores. Recordemos la definición general de covarianza (lección 5, adaptada al lenguaje de esperanzas):

$$\text{Cov}(U, X) = E[UX] - E[U]E[X].$$

Como acabamos de establecer que $E[U] = 0$, el segundo término de la derecha se anula, y queda:

$$\text{Cov}(U, X) = E[UX] - 0 \cdot E[X] = E[UX] = 0.$$

Es decir: como U tiene esperanza cero, su producto escalar con *cualquier* otra variable aleatoria —en particular con X — coincide exactamente con su covarianza. Este es, palabra por palabra, el mismo argumento algebraico que usamos en $\mathbb{R}^n$: si un vector es ortogonal a $\mathbf{1}$ (tiene media cero), su producto escalar con cualquier otro vector es idéntico a su covarianza con él —no hace falta restar ninguna media, porque la media de U ya es cero—. Aquí, el “truco” se traslada sin ningún cambio: $E[U] = 0$ hace que $E[UX]$ y $\text{Cov}(U, X)$ sean, literalmente, el mismo número.

La consecuencia práctica de todo esto es la que usaremos, dentro de un momento, para “resolver” el modelo poblacional: el supuesto $E[U | X] = 0$ —que en apariencia es una condición sobre una función entera— se traduce, para nuestros propósitos algebraicos inmediatos, en dos números concretos: $E[U] = 0$ y $\text{Cov}(U, X) = 0$. Son exactamente las dos condiciones —ahora poblacionales— que en la lección 7 impusimos, en su versión muestral, sobre el residuo $\hat{e}$: $\sum \hat{e}_i = 0$ y $\sum x_i \hat{e}_i = 0$.

Cerramos con una comprobación de consistencia que, además, introduce un resultado importante por sí mismo: la *Ley de las Esperanzas Iteradas*. Este resultado —que no demostraremos aquí, pero que enunciamos porque lo usaremos de nuevo más adelante en el curso— afirma que, para cualquier variable aleatoria Y y cualquier X ,

$$E[Y] = E[E[Y | X]].$$

Es decir: la esperanza (sin condicionar) de Y es igual a la esperanza (sin condicionar) de su esperanza condicionada a X . Este resultado es, de hecho, el análogo exacto de una propiedad que ya demostramos en la lección 7 sobre $\hat{y}$: recordemos que allí probamos $\mu_y = \mu_{\hat{y}}$ —la media del vector de datos coincide con la media de su ajuste— como consecuencia directa de que $\hat{e} \perp \mathbf{1}$. Aplicando la Ley de las Esperanzas Iteradas a nuestra perturbación U (con $Y = U$), obtenemos

$$E[U] = E[E[U | X]] = E[0] = 0,$$

donde hemos usado directamente el supuesto $E[U | X] = 0$. Este resultado coincide, como debía, con el que ya habíamos obtenido por la vía de la ortogonalidad directa unas líneas más arriba: dos caminos distintos —uno vía ortogonalidad frente a la constante 1, otro vía la Ley de las Esperanzas Iteradas— que llegan al mismo destino, $E[U] = 0$.

Para profundizar:

- Wooldridge, J. M. (2020), Apéndice B.5: Ley de las Esperanzas Iteradas, con demostración completa en el caso discreto.

8 Advertencia: álgebra sí, causalidad no (todavía)

Recordemos (lección 8, sesión 10): $\text{STC} = \text{SEC} + \text{SRC}$ era *pura álgebra*, cierta incluso al invertir precio y superficie.

$Y = E[Y | X] + U$ es exactamente igual de algebraica. *Siempre* existe, para cualesquiera X, Y con varianza finita. No presupone causalidad alguna.

X “causa” Y ; Y “causa” X ; una tercera variable causa ambas; o no hay ninguna relación sustantiva — la *misma* descomposición algebraica sirve para los cuatro casos.

Solo una *teoría económica previa* —externa a la propia álgebra— puede justificar leer $X \rightarrow Y$ en lugar de $Y \rightarrow X$.

Recordemos el mantra de la lección 1: *correlación no implica causalidad*. Hoy añadimos: *tampoco lo implica, por sí sola, la esperanza condicional*.

Advertencia: álgebra sí, causalidad no (todavía)

Antes de dar el último paso de esta sesión —el “salto” que nos permitirá reinterpretar, con una nueva mirada, las fórmulas ya calculadas en la lección 7—, conviene detenerse en una advertencia que ya anunciamos en la lección 8 (sesión 10) y que aquí adquiere su forma más general y, por eso, más importante.

En la lección 8 vimos que la identidad $STC = SEC + SRC$ era una consecuencia *puramente geométrica* de la descomposición ortogonal $\mathbf{y} = \hat{\mathbf{y}} + \hat{\mathbf{e}}$: se cumplía exactamente igual, con el mismo rigor matemático, tanto si regresábamos el precio de una vivienda sobre su superficie como si —invirtiendo, sin ningún sentido económico, los papeles— regresábamos la superficie sobre el precio. La geometría de $\mathbb{R}^n$ no sabe nada de economía, ni de causalidad, ni de qué variable “debería” explicar a cuál.

Pues bien: exactamente la misma advertencia se aplica, con idéntica fuerza, a la descomposición $Y = E[Y | X] + U$ que hemos construido hoy. Dados *cualesquiera* dos variables aleatorias X e Y con varianza finita —sin ninguna otra condición—, *siempre* existe su esperanza condicional $E[Y | X]$, y *siempre* podemos escribir esta descomposición ortogonal. Esto es cierto sea cual sea la relación real, si es que existe alguna, entre X e Y en el mundo económico que estemos modelizando. La descomposición no “sabe”, ni puede saber, si X genera a Y , si Y genera a X , si ambas son generadas conjuntamente por alguna tercera causa que no hemos incluido en el modelo, o si —en el caso más extremo— X e Y no guardan entre sí ninguna relación sustantiva y su asociación, si la hubiera, fuera puramente casual (recordemos, de la lección 1, el ejemplo de la correlación entre el consumo de queso per cápita y las muertes por enredarse en sábanas).

En cualquiera de esos cuatro escenarios —causalidad de X a Y , causalidad inversa, causa común, o pura coincidencia— la matemática que acabamos de construir es exactamente la misma, y produce exactamente la misma descomposición ortogonal. La descomposición algebraica, por sí sola, es completamente indiferente a cuál de esos cuatro escenarios describe realmente el fenómeno que estamos estudiando.

Esta es, precisamente, la razón por la que en la lección 6 (sesión 8) pospusimos deliberadamente la distinción entre “regresor” (una noción puramente estructural, sin ningún compromiso causal) y “variable explicativa” (un concepto que sí lleva, implícita, la pretensión de que X desempeña algún papel causal, aunque sea parcial, en la generación de Y). Cobramos hoy esa promesa: podemos llamar a X “regresor” con toda tranquilidad, en cualquier circunstancia, porque es una etiqueta puramente algebraica; pero solo deberíamos llamarlo “variable explicativa” —con esa carga causal— cuando dispongamos de alguna razón, *externa a la propia matemática*, que justifique semejante lectura.

¿De dónde puede venir esa razón? No de la geometría, ni del álgebra: únicamente de una *teoría económica previa*. Si, antes de mirar ningún dato, tenemos razones teóricas sólidas para pensar que la renta disponible de un consumidor influye en cuánto consume —y no al revés, ni

por alguna tercera vía—, entonces sí podemos aventurar una lectura causal de la descomposición $\text{Consumo} = E[\text{Consumo} \mid \text{Renta}] + U$. Pero si, por el contrario, no tenemos ninguna teoría previa que distinga qué variable debería hacer de X y cuál de Y —como en el ejemplo, deliberadamente absurdo pero matemáticamente impecable, de regresar la superficie de una vivienda sobre su precio—, entonces la descomposición algebraica sigue siendo perfectamente válida, pero carece de cualquier interpretación causal razonable.

Cerramos esta advertencia recuperando, de forma explícita, el mantra con el que abrimos el curso en la lección 1: *correlación no implica causalidad*. Hoy, con el aparato construido en esta sesión, podemos precisar ese mantra con mayor rigor: tampoco la existencia de una esperanza condicional bien definida —ni, por supuesto, el cumplimiento de los tres supuestos del modelo clásico que hemos presentado— implica, por sí sola, ninguna relación causal. Los tres supuestos garantizan que $\beta_0 + \beta_1 X$ es una buena *descripción estadística* de cómo varía Y en promedio según X ; no garantizan, en ningún caso, que esa variación sea el reflejo de una relación de causa a efecto.

Para profundizar:

- Bujosa, M., *Lección 4*, sección “Regresión como descomposición ortogonal” y el apartado “Un anhelo o pretensión como analistas: la regresión como modelo explicativo”: discusión extensa, con los mismos ejemplos, de por qué la descomposición ortogonal por sí sola no valida ninguna teoría causal.
- Angrist, J. y Pischke, J.-S. (2014), *Mastering ‘Metrics’*, capítulo 1: discusión accesible sobre la distinción entre asociación estadística y causalidad, con ejemplos económicos.

9 El salto: método de los momentos

De $E[U] = 0$ y $\text{Cov}(U, X) = 0$, sustituyendo $U = Y - \beta_0 - \beta_1 X$ y resolviendo (misma álgebra que la lección 7):

$$\beta_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}, \quad \beta_0 = E[Y] - \beta_1 E[X].$$

Pero $\text{Cov}(X, Y)$, $\text{Var}(X)$, $E[Y]$, $E[X]$ son *desconocidos* (son momentos *poblacionales*): no podemos calcular β_0, β_1 directamente.

El salto: sustituir cada momento poblacional por su análogo muestral — $E[X] \rightarrow \mu_x$, $\text{Cov}(X, Y) \rightarrow \sigma_{xy}$, etc.

$$\hat{\beta}_1 = \frac{\sigma_{xy}}{\sigma_x^2}, \quad \hat{\beta}_0 = \mu_y - \hat{\beta}_1 \mu_x.$$

Exactamente las fórmulas de la lección 7 — ahora leídas como *estimadores* de β_0, β_1 poblacionales, no como coeficientes de un ajuste puramente muestral.

El salto: método de los momentos

Llegamos al momento en que todo el andamiaje construido hoy se pone al servicio de algo muy concreto: entender, con una mirada nueva, las fórmulas que ya calculamos en la lección 7.

Partamos de las dos condiciones poblacionales que obtuvimos en la transparencia sobre las consecuencias de $E[U \mid X] = 0$: $E[U] = 0$ y $\text{Cov}(U, X) = 0$. Sustituyamos en ellas $U = Y - \beta_0 - \beta_1 X$

(el primer supuesto del modelo, despejando U) y resolvamos el sistema resultante para β_0, β_1 — es, deliberadamente, *exactamente* la misma álgebra que hicimos en la lección 7 para obtener $\hat{\beta}_0, \hat{\beta}_1$ a partir de las dos condiciones de ortogonalidad muestrales, solo que ahora con esperanzas en lugar de medias muestrales.

De $\text{Cov}(U, X) = 0$, usando la linealidad de la covarianza y que $\text{Cov}(\beta_0, X) = 0$ (una constante no covaría con nada):

$$\text{Cov}(U, X) = \text{Cov}(Y - \beta_0 - \beta_1 X, X) = \text{Cov}(Y, X) - \beta_1 \text{Var}(X) = 0,$$

de donde

$$\beta_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}.$$

Y de $E[U] = 0$:

$$E[U] = E[Y] - \beta_0 - \beta_1 E[X] = 0 \implies \beta_0 = E[Y] - \beta_1 E[X].$$

Estas dos fórmulas son, letra por letra, el análogo poblacional exacto de las que obtuvimos en la lección 7: $\hat{\beta}_1 = \sigma_{xy}/\sigma_x^2$ y $\hat{\beta}_0 = \mu_y - \hat{\beta}_1 \mu_x$, con $E[\cdot]$, $\text{Cov}(\cdot, \cdot)$ y $\text{Var}(\cdot)$ en el lugar de $\mu_\cdot$, $\sigma_\cdot$ y $\sigma_\cdot^2$.

Aquí topamos, sin embargo, con un problema real, y precisamente el que da nombre a esta transparencia. Las cantidades $\text{Cov}(X, Y)$, $\text{Var}(X)$, $E[Y]$ y $E[X]$ son *momentos poblacionales*: describen a las variables aleatorias X e Y en su totalidad, no a ninguna muestra concreta. Y, en general, *no los conocemos*. Salvo en casos de laboratorio completamente artificiales (donde nosotros mismos hemos construido X e Y y, por tanto, conocemos sus momentos por diseño), no tenemos manera de calcular $E[X]$ o $\text{Cov}(X, Y)$ con exactitud: solo disponemos de una muestra —un vector de datos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ — con la que aspiramos a *inferir* algo sobre esos momentos desconocidos.

Esta es, precisamente, la situación filosófica que anunciamos al abrir la sesión con la cita de Diotima: no poseemos β_0, β_1 (la “verdad” poblacional, que sería el conocimiento del sabio); pero tampoco carecemos de todo (no somos el ignorante que no sabe ni que le falta algo): tenemos una muestra, un vector concreto, con el que podemos intentar *aproximarnos* a esos parámetros desconocidos.

El “salto” que da nombre a esta transparencia consiste, precisamente, en resolver este problema del modo más directo posible: *sustituir cada momento poblacional (desconocido) por su análogo muestral (calculable)*. Donde aparecía $E[X]$ (desconocido), escribimos μ_x (calculable a partir de la muestra); donde aparecía $\text{Cov}(X, Y)$, escribimos σ_{xy} ; donde aparecía $\text{Var}(X)$, escribimos σ_x^2 ; y donde aparecía $E[Y]$, escribimos μ_y . El resultado de esta sustitución, aplicada a las dos fórmulas de más arriba, es:

$$\hat{\beta}_1 = \frac{\sigma_{xy}}{\sigma_x^2}, \quad \hat{\beta}_0 = \mu_y - \hat{\beta}_1 \mu_x.$$

¡Pero estas son, exactamente, las fórmulas que ya obtuvimos en la lección 7! No como consecuencia de ninguna casualidad, sino porque la ruta que hemos seguido —resolver las condiciones poblacionales y sustituir momentos poblacionales por muestrales— reproduce, paso a paso, la misma estructura algebraica que allí seguimos —resolver las dos condiciones de ortogonalidad muestral directamente sobre $\hat{\mathbf{e}}$ —. A esta estrategia general, de sustituir momentos teóricos desconocidos por

sus análogos muestrales para obtener un estimador, se le llama *método de los momentos*, y es, en este caso concreto, exactamente equivalente a la estimación por mínimos cuadrados ordinarios.

Lo que ha cambiado, entre la lección 7 y hoy, no es la fórmula —es idéntica—, sino su *interpretación*. En la lección 7, $\hat{\beta}_1$ era, sencillamente, la pendiente del ajuste que mejor se acomodaba a un vector de datos concreto: un hecho geométrico sobre ese vector, sin ninguna pretensión más allá de él. Hoy, con el modelo poblacional $Y = \beta_0 + \beta_1 X + U$ ya construido, $\hat{\beta}_1$ pasa a ser algo distinto: un *estimador* del parámetro poblacional (desconocido) β_1 —una aproximación, calculada a partir de nuestra muestra, a una cantidad que existe en el mundo económico subyacente pero que nunca observaremos directamente en su totalidad—.

Como ejemplo concreto, y para no perder el contacto con el trabajo empírico ya realizado en el laboratorio de la sesión 11: si escribimos el modelo poblacional $\text{price} = \beta_0 + \beta_1 \cdot \text{rooms} + U$, con la interpretación (bajo el segundo supuesto, y con las reservas causales de la transparencia anterior) de que β_1 mide cómo varía, en promedio, el precio de una vivienda cualquiera —no solo las 506 del Boston metropolitano que observamos— ante un incremento de una habitación, entonces el coeficiente $\hat{\beta}_1$ que Gretl calculó en aquella práctica no es solo “la pendiente de la recta que mejor se ajusta a esos 506 puntos”; es, además, nuestra mejor *estimación*, con los datos disponibles, de ese parámetro poblacional desconocido.

Terminamos con una observación que conviene no dejar pasar, porque cierra el círculo abierto en esta misma sesión de un modo particularmente satisfactorio. El espacio $(\mathbb{R}^n, \langle \cdot, \cdot \rangle_s)$ que hemos usado durante toda la primera parte del curso *es*, literalmente, un caso particular de espacio (semi-)euclídeo de probabilidad: basta imaginar que $\Omega = \{1, \dots, n\}$ (nuestros n índices de observación) y que cada uno de esos n sucesos elementales tiene probabilidad $\frac{1}{n}$ (equiprobables); entonces, la esperanza de una “variable aleatoria” definida sobre ese Ω tan pequeño es, precisamente, $\frac{1}{n} \sum_i (\cdot)_i$ —la media muestral que hemos usado todo el curso—. Dicho de otro modo: no es que la media aritmética se “parezca” a la esperanza matemática por una feliz coincidencia notacional; es que la media aritmética *es* una esperanza matemática, calculada sobre el caso particular, extremadamente simple, en que el espacio de sucesos elementales tiene solo n elementos equiprobables. Por eso “estimar” —sustituir $E[\cdot]$ por μ .— no es una metáfora ni una aproximación heurística: es, en el fondo, sustituir una esperanza tomada sobre un Ω enorme y desconocido por otra esperanza, perfectamente calculable, tomada sobre un Ω mucho más pequeño y completamente conocido —el de nuestros n datos—.

Para profundizar:

- Bujosa, M., *Lección 5*, sección “Estimación del Modelo Clásico de Regresión Lineal”: discusión extensa (con el ejemplo detallado del precio de la vivienda) de por qué sustituir momentos poblacionales por muestrales constituye “un salto audaz”, y de la relación exacta entre $(\mathbb{R}^n, \langle \cdot, \cdot \rangle_s)$ y un espacio de probabilidad.
- Wooldridge, J. M. (2020), Apéndice C.1: introducción al método de los momentos como principio general de estimación.

10 Recapitulación: el diccionario

$\mathbb{R}^n$ (dato conocido)	Variables aleatorias (a inferir)
vector de datos $\mathbf{y}$	variable aleatoria Y
$\mu_{\mathbf{y}} = \langle \mathbf{y}, \mathbf{1} \rangle_s$	$E[Y] = \langle Y, \mathbf{1} \rangle_P$
$\bar{\mathbf{y}}$ (vector constante)	$E[Y 1]$ (función constante)
$\hat{\mathbf{y}}$ (proyección sobre $\mathcal{L}(1, \mathbf{x})$)	$E[Y X]$ (proyección sobre TODAS las func. de X)
$\hat{\mathbf{e}} = \mathbf{y} - \hat{\mathbf{y}}$	$U = Y - E[Y X]$
$\sigma_{\mathbf{y}}^2$	$\text{Var}(Y)$
$\hat{\beta}_0, \hat{\beta}_1$ (ajuste de una muestra)	β_0, β_1 (parámetros poblacionales, a estimar)

Mismo lenguaje geométrico. Distinta naturaleza epistemológica: de lo *completamente conocido* a lo que solo *inferimos*.

Guiño a la Lección 10: con $k > 1$ regresores, notación matricial $\mathbf{X}\beta$ (anunciada en la lección 5); y, sin demostrarlo todavía, $E[\hat{\beta} | \mathbf{X}] = \beta$.

Recapitulación: el diccionario

Cerramos esta lección con la tabla que resume, de un vistazo, todo el camino recorrido. Conviene leerla despacio, fila por fila, porque cada línea condensa una transparencia entera de la sesión.

La primera fila recoge la idea de partida (transparencia 2): tanto el vector de datos $\mathbf{y}$ como la variable aleatoria Y son, en el fondo, funciones —solo que definidas sobre dominios de naturaleza radicalmente distinta: uno finito y perfectamente conocido ($\{1, \dots, n\}$), el otro potencialmente inmenso y, en la práctica, nunca descrito en detalle (Ω).

La segunda y tercera filas recogen la distinción, cuidadosamente mantenida durante toda la sesión, entre la esperanza como número y la esperanza como función constante (transparencia 4): $E[Y]$ es un escalar, tan concreto como $\mu_{\mathbf{y}}$; $E[Y | 1]$ es una función, tan poco reducible a un número como lo era $\bar{\mathbf{y}}$.

La cuarta fila recoge, quizá, la diferencia más profunda de toda la sesión (transparencia 5): mientras que $\hat{\mathbf{y}}$ era la proyección sobre un plano de solo dos direcciones, $E[Y | X]$ es la proyección sobre un espacio de funciones que, en general, tiene infinitas direcciones —razón por la cual la linealidad de $E[Y | X]$ es, en el caso general, un supuesto sustantivo, y no una consecuencia automática de la definición.

La quinta fila es la descomposición fundamental que ambos mundos comparten: en $\mathbb{R}^n$, $\mathbf{y} = \hat{\mathbf{y}} + \hat{\mathbf{e}}$; con variables aleatorias, $Y = E[Y | X] + U$. Ambas son descomposiciones ortogonales que existen *siempre*, sin necesidad de ningún supuesto adicional — y, por eso mismo, ninguna de las dos implica, por sí sola, ninguna relación de causalidad (transparencia 8).

La sexta fila recuerda que la varianza, en ambos mundos, mide lo mismo: la dispersión de la variable respecto a su valor esperado (constante).

Y la séptima fila, finalmente, recoge la diferencia epistemológica más importante de todas, la que hemos intentado transmitir con la imagen de Diotima: $\hat{\beta}_0, \hat{\beta}_1$ son cantidades *exactas*, calculadas sin margen de error a partir de un vector de datos concreto (lección 7); β_0, β_1 son cantidades

poblacionales, verdaderas pero desconocidas, que solo podemos *estimar* —nunca conocer con certeza— a partir de esa misma muestra. El salto de la última transparencia consistió, precisamente, en mostrar que ambas cantidades, la exacta y la inferida, comparten exactamente la misma fórmula.

El mensaje que debe quedar de esta sesión, por encima de cualquier fórmula concreta, es el siguiente: el lenguaje geométrico que hemos construido con tanto cuidado durante las lecciones 1 a 8 —vectores, producto escalar, proyección ortogonal, ángulos— no era exclusivo de $\mathbb{R}^n$. Es, más bien, un lenguaje general de la *aproximación óptima*, que se puede trasladar —con las honestas advertencias que hemos ido señalando en cada paso— a cualquier conjunto de objetos donde exista una noción razonable de producto escalar. Las variables aleatorias, con la esperanza del producto como su propio producto escalar, son uno de esos conjuntos; y por eso la esperanza condicional $E[Y | X]$ hereda, con toda naturalidad, el papel que en $\mathbb{R}^n$ jugaba la proyección $\hat{y}$.

Quedan, sin embargo, varias tareas pendientes que las próximas lecciones deberán resolver. La primera, inmediata: hasta ahora hemos trabajado con un único regresor X ; la lección 10 generalizará todo esto a k regresores $X_1, \dots, X_k$, retomando la notación matricial $\mathbf{X}\boldsymbol{\beta}$ que ya anunciamos, sin usarla todavía, al cierre de la lección 5. Y, en esa misma generalización, adelantaremos —sin demostrarlo por el momento— un resultado que necesitaremos más adelante: que el estimador MCO, ahora escrito en su forma matricial $\hat{\boldsymbol{\beta}}$, es insesgado, es decir, que $E[\hat{\boldsymbol{\beta}} | \mathbf{X}] = \boldsymbol{\beta}$. Solo mucho más adelante, cuando volvamos a restringirnos al caso de un único regresor, demostraremos con todo detalle por qué esto es cierto —y comprenderemos, entonces, con mayor precisión todavía, qué significa exactamente que $\hat{\beta}_1$ sea una *buena* estimación de β_1 .

Para profundizar:

- Wooldridge, J. M. (2020), capítulo 2, sección 2.6: resumen de los supuestos del modelo de regresión simple y su papel de cara a la inferencia estadística que se desarrollará en próximas lecciones.