

Índice general

1	De dos regresores a k : la misma pregunta, un espacio más grande	2
2	El subespacio $\mathcal{L}(1, x_1, \dots, x_k)$	3
3	La matriz $\mathbf{X}$ y la doble lectura de $\mathbf{X}\beta$	4
4	El ajuste como proyección	5
5	Ortogonalidad generalizada: $k + 1$ condiciones	6
6	Ecuaciones normales	7
7	Familia ortogonal y Pitágoras generalizado	9
8	R^2 en regresión múltiple	10
9	El puente cobrado (aserción, sin demostración)	11
10	Recapitulación y guiño a la sesión siguiente	13

Lección 10. Regresión múltiple: de dos ortogonalidades a $k + 1$

Marcos Bujosa

20 de agosto de 2026

Resumen

Generalizamos la proyección sobre un plano (lecciones 6 a 8) a un subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$ de $k + 1$ direcciones. La notación matricial comprime, sin añadir matemática nueva, las $k + 1$ condiciones de ortogonalidad en las *ecuaciones normales* $\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$. Cerramos cobrando —sin demostrar— la promesa de la lección 9 sobre las propiedades de $\hat{\boldsymbol{\beta}}$.

“Cuántos más regresores, mayor el espacio de búsqueda; la pregunta —¿qué punto del subespacio está más cerca de $\mathbf{y}$?— no cambia.”

- ([slides](#)) — ([html](#)) — ([pdf](#))

1 De dos regresores a k : la misma pregunta, un espacio más grande

En la práctica de regresión simple con datos reales, al terminar la regresión `price~rooms`, quedó una pregunta sin responder: ¿por qué el R^2 del modelo con *dos* regresores, `price~rooms+nox`, no iba a ser la suma de los dos R^2 simples?

En las lecciones 6-8 proyectamos $\mathbf{y}$ sobre el *plano* $\mathcal{L}(\mathbf{1}, \mathbf{x})$, generado por *dos* vectores.

Hoy añadimos regresores $\mathbf{x}_1, \dots, \mathbf{x}_k$ (k arbitrario) y proyectamos sobre $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$.

La pregunta es exactamente la misma de siempre: ¿qué combinación lineal $\beta_0 \mathbf{1} + \beta_1 \mathbf{x}_1 + \dots + \beta_k \mathbf{x}_k$ está más cerca de $\mathbf{y}$?

Seguimos sin supuestos probabilísticos —salvo en la última transparencia, donde cobramos “el puente” de la lección 9.

De dos regresores a k : la misma pregunta, un espacio más grande

Retomamos, para abrir esta lección, una pregunta que quedó deliberadamente sin respuesta al cierre de la práctica de regresión simple con datos reales: cuando estimamos por separado `price~rooms` y `price~nox`, obtuvimos dos valores de R^2 ; pero al estimar `price~rooms+nox` *simultáneamente*, con los dos regresores a la vez, ¿por qué no cabía esperar que el nuevo R^2 fuera, sencillamente, la suma de los dos anteriores? Aquella pregunta se dejó sembrada, sin resolver: hoy tenemos, por fin, el lenguaje necesario para responderla con precisión geométrica (llegaremos a ello en la transparencia 6).

El paso que damos hoy es, en su estructura, idéntico al que dimos en la lección 6: allí generalizamos la proyección sobre una *recta* $\mathcal{L}(\mathbf{1})$ (lección 4, la media) a la proyección sobre un *plano* $\mathcal{L}(\mathbf{1}, \mathbf{x})$, añadiendo un segundo vector generador. Hoy repetimos exactamente la misma operación, pero en lugar de añadir *un* regresor añadimos k regresores $\mathbf{x}_1, \dots, \mathbf{x}_k$ (además de la constante $\mathbf{1}$), obteniendo el subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$. La lógica del problema —buscar, dentro de un subespacio, el vector más cercano a $\mathbf{y}$ — no cambia en absoluto; lo único que cambia es el número de direcciones que generan ese subespacio. Recordemos que esto no es más que la *combinación lineal* de la lección 2, ahora con $k + 1$ sumandos en lugar de dos: $\beta_0 \mathbf{1} + \beta_1 \mathbf{x}_1 + \dots + \beta_k \mathbf{x}_k$.

Por eso, aunque el número de regresores crezca, el aparato conceptual que necesitamos sigue siendo exactamente el mismo: proyección ortogonal, condiciones de ortogonalidad del residuo frente a cada generador, y minimización de una distancia. Lo único genuinamente nuevo de esta sesión es un *lenguaje* —la notación matricial— que nos permite escribir, de forma compacta, un sistema con $k + 1$ ecuaciones en lugar de dos.

Para profundizar:

- Strang, G. (2016). *Introduction to Linear Algebra*, cap. 4: mínimos cuadrados con varios regresores, presentado como el mismo problema de proyección con más columnas.
- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 3, sección 3.1: motivación de la regresión múltiple.

2 El subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$

Recordando la notación de lecciones anteriores, generalizamos:

- Un generador: $\mathcal{L}(\mathbf{a})$ — una *recta*.
- Dos generadores: $\mathcal{L}(\mathbf{a}, \mathbf{b})$ — un *plano*.
- $k + 1$ generadores: $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$ — el conjunto de *todas* las combinaciones lineales de esos $k + 1$ vectores.

Si ninguno de los $k + 1$ generadores es combinación lineal de los demás (de manera informal: si son “independientes”), el subespacio tiene $k + 1$ direcciones.

Caso degenerado (adelanto, lección 14): si un regresor *es* combinación lineal exacta de los demás, el subespacio colapsa a menos de $k + 1$ direcciones — *colinealidad exacta*. La versión “casi exacta” (regresores casi alineados) es el tema de esa lección.

El subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$

La notación $\mathcal{L}(\cdot)$ ya nos resulta familiar desde la lección 2: denota el conjunto de todas las combinaciones lineales de los vectores que aparecen entre paréntesis. Con un único generador $\mathbf{a}$, $\mathcal{L}(\mathbf{a})$ es una recta (lección 4); con dos generadores no alineados, $\mathcal{L}(\mathbf{a}, \mathbf{b})$ es un plano (lección 6). Hoy generalizamos sin ningún esfuerzo adicional: con $k + 1$ generadores $\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k$, el conjunto

$$\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k) = \{\beta_0 \mathbf{1} + \beta_1 \mathbf{x}_1 + \dots + \beta_k \mathbf{x}_k \mid \beta_0, \dots, \beta_k \in \mathbb{R}\}$$

es, de nuevo, un subespacio de $\mathbb{R}^n$.

Retomamos aquí, de manera puramente informal (como ya hicimos en las lecciones 5 y 6, sin ninguna axiomática de por medio), la noción de *dimensión* de un subespacio: el número de “direcciones independientes” que lo generan. Si ninguno de los $k + 1$ vectores generadores puede escribirse como combinación lineal de los otros k —es decir, si son, informalmente, “independientes”—, el subespacio tiene $k + 1$ direcciones distintas. Esta es la situación habitual, y la que asumiremos por defecto en el resto de la sesión.

Pero conviene señalar, aunque sea de pasada, el caso opuesto: si alguno de los regresores fuera *exactamente* una combinación lineal de los demás —por ejemplo, si tuviéramos como regresores la superficie de una vivienda en metros cuadrados y esa misma superficie en pies cuadrados, que son proporcionales entre sí—, el subespacio generado por los $k + 1$ vectores colapsaría: tendría menos de $k + 1$ direcciones, y el sistema que resolveremos en unas transparencias dejaría de tener una única solución. A este fenómeno, en su versión exacta, lo llamamos *colinealidad exacta*; en su versión “casi exacta” —regresores muy correlacionados, sin llegar a ser combinaciones lineales perfectas— es el problema de *colinealidad* que se estudiará con detalle en la lección 14. Por ahora basta con tener presente que la hipótesis de independencia de los generadores no es gratuita: es la que garantiza que el problema de hoy tenga una solución bien definida.

Para profundizar:

- Strang, G. (2016), cap. 3: independencia lineal y dimensión de un subespacio (tratamiento formal de la noción que aquí seguimos usando de manera informal).

3 La matriz $\mathbf{X}$ y la doble lectura de $\mathbf{X}\beta$

Organizamos los $k + 1$ regresores como columnas de una *matriz* (anunciada ya en la lección 5):

$$\mathbf{X} = [\mathbf{1}; \mathbf{x}_1; \dots; \mathbf{x}_k].$$

Recordemos (lección 4) que la media era, *a la vez*, un producto escalar ($\mu_y = \langle \mathbf{y}, \mathbf{1} \rangle$) y el coeficiente de una combinación lineal ($\bar{\mathbf{y}} = \mu_y \mathbf{1}$). $\mathbf{X}\beta$ generaliza exactamente esa doble lectura:

- *Por filas* (lista de productos escalares): la componente i -ésima de $\mathbf{X}\beta$ es $\beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}$ — el valor predicho para la observación i .
- *Por columnas* (combinación lineal): $\mathbf{X}\beta = \beta_0 \mathbf{1} + \beta_1 \mathbf{x}_1 + \dots + \beta_k \mathbf{x}_k$ — un único vector de $\mathbb{R}^n$.

Ambas lecturas describen exactamente el mismo vector. Ninguna operación es nueva: es la notación matricial actuando como taquigrafía de lo que ya sabíamos hacer con sumatorios.

La matriz $\mathbf{X}$ y la doble lectura de $\mathbf{X}\beta$

La lección 5 anunció, en su “Guiño a la sesión siguiente”, que resultaría cómodo organizar los regresores como columnas de una única matriz $\mathbf{X}$, y que el producto $\mathbf{X}\beta$ admitiría una doble lectura. Cobramos hoy esa promesa, con $k + 1$ regresores en lugar de dos.

Siguiendo la convención de notación (matrices con `\mathbf{X}`, en negrita, para distinguirlas de los vectores), escribimos la matriz de regresores describiendo sus columnas:

$$\mathbf{X} = [\mathbf{1}; \mathbf{x}_1; \dots; \mathbf{x}_k],$$

una matriz de n filas (una por observación) y $k+1$ columnas (una por regresor, incluida la constante). Dado un vector de coeficientes $\beta = (\beta_0, \beta_1, \dots, \beta_k) \in \mathbb{R}^{k+1}$, el producto $\mathbf{X}\beta$ es un vector de $\mathbb{R}^n$, y puede leerse de dos maneras completamente equivalentes.

Primera lectura, por filas. Cada componente del vector $\mathbf{X}\beta$ es el producto escalar de β con la fila correspondiente de $\mathbf{X}$ (es decir, con los valores que toman los $k+1$ regresores en esa observación concreta):

$$(\mathbf{X}\beta)_i = \beta_0 \cdot 1 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}.$$

Esta es, generalizada, exactamente la misma operación que en la lección 4 convertía la media $\mu_y = \langle \mathbf{y}, \mathbf{1} \rangle$ en un producto escalar: allí teníamos un único regresor ($\mathbf{1}$); aquí tenemos $k+1$, y cada componente de $\mathbf{X}\beta$ es, sencillamente, otro producto escalar más, esta vez entre β y una fila de $\mathbf{X}$.

Segunda lectura, por columnas. El mismo vector $\mathbf{X}\beta$ es, igualmente, la combinación lineal de las columnas de $\mathbf{X}$ con coeficientes dados por β :

$$\mathbf{X}\beta = \beta_0 \mathbf{1} + \beta_1 \mathbf{x}_1 + \dots + \beta_k \mathbf{x}_k.$$

Esta es, generalizada, la otra cara de la misma media: allí $\bar{\mathbf{y}} = \mu_y \mathbf{1}$ era el vector constante resultante de multiplicar el único generador $\mathbf{1}$ por su coeficiente; aquí, $\mathbf{X}\beta$ es el vector resultante de combinar los $k+1$ generadores con sus respectivos coeficientes.

Insistimos en que no hay ninguna operación matemática nueva en esta transparencia: solo un cambio de notación, que nos permitirá escribir de forma compacta expresiones que, sin matrices, requerirían $k+1$ sumatorios escritos uno a uno. La utilidad de esta notación se hará evidente enseguida, al plantear las condiciones de ortogonalidad.

Para profundizar:

- Strang, G. (2016), cap. 2: el producto matriz-vector, presentado precisamente con esta doble lectura (combinación de columnas / productos escalares por filas).

4 El ajuste como proyección

Buscamos $\hat{\beta} \in \mathbb{R}^{k+1}$ tal que

$$\|\mathbf{y} - \mathbf{X}\hat{\beta}\|_s$$

sea *mínima*. El ajuste es $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$ (la proyección de $\mathbf{y}$ sobre $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$); el residuo, $\hat{\mathbf{e}} = \mathbf{y} - \hat{\mathbf{y}}$.

La lección 8 ya lo anticipó: esta figura, al no mostrar ningún $\hat{\beta}_j \mathbf{x}_j$ dentro del plano, “sirve igualmente como esquema de la regresión con cualquier número k de regresores”. Cobramos esa promesa: *nada cambia en el dibujo* al pasar de un regresor a k .

El ajuste como proyección

El problema de ajuste es, letra por letra, el mismo de la lección 6, con la única diferencia de que ahora el subespacio candidato tiene $k+1$ direcciones en lugar de dos. Buscamos el vector $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k)$ que hace que la distancia entre $\mathbf{y}$ y $\mathbf{X}\beta$ (para β recorriendo todo $\mathbb{R}^{k+1}$) sea mínima. Al vector del subespacio que logra esa distancia mínima lo llamamos, como siempre, el *ajuste*, $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$; a la diferencia $\hat{\mathbf{e}} = \mathbf{y} - \hat{\mathbf{y}}$, el *residuo*.




Figura 1: La misma figura de la lección 8, reutilizada como esquema general. Al no mostrar explícitamente ningún regresor individual dentro del plano —solo la recta $\mathcal{L}(\mathbf{1})$ —, sirve igualmente para representar la proyección sobre $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$, sea cual sea k .

La figura reutiliza, de manera deliberada, la misma imagen de tres vistas ya presentada en la lección 8 (OLS_fila_ancho.png). Conviene recordar por qué esa figura —a diferencia de la usada en la lección 6, que sí mostraba explícitamente las componentes $\hat{\beta}_0 \mathbf{1}$ y $\hat{\beta}_1 \mathbf{x}$ sobre dos ejes distintos— se construyó deliberadamente sin desglosar el plano en las direcciones de los regresores individuales: solo destacaba en ella la recta $\mathcal{L}(\mathbf{1})$ y las proyecciones sobre ella. Esa fue una decisión anticipada precisamente para esta transparencia: al no comprometerse con ningún regresor concreto, la figura sigue siendo una representación esquemática perfectamente válida cuando el subespacio pasa de tener dos direcciones a tener $k + 1$. Lo único que ya no podríamos dibujar, si quisiéramos ser literales, son los k ejes individuales $\mathcal{L}(\mathbf{x}_1), \dots, \mathcal{L}(\mathbf{x}_k)$ dentro del plano —pero la figura nunca pretendió mostrarlos, así que no hay nada que corregir en ella.

Para profundizar:

- Bujosa, M. *Curso de Álgebra Lineal*, cap. 11: proyección ortogonal sobre subespacios generados por varios vectores.

5 Ortogonalidad generalizada: $k + 1$ condiciones

Como en la lección 6, $\hat{\mathbf{e}}$ debe ser ortogonal a *todo* el subespacio, es decir, a cada uno de sus $k + 1$ generadores:

$$\langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0, \quad \langle \hat{\mathbf{e}}, \mathbf{x}_1 \rangle_s = 0, \quad \dots, \quad \langle \hat{\mathbf{e}}, \mathbf{x}_k \rangle_s = 0.$$

$k + 1$ ecuaciones, comprimidas en el *producto vector-matriz*:

$$\hat{\mathbf{e}} \mathbf{X} = \mathbf{0}.$$

Forma equivalente “de manual” (el mismo vector, escrito con la matriz traspuesta):

$$\mathbf{X}^\top \hat{\mathbf{e}} = \mathbf{0}.$$

$\hat{\mathbf{e}} \mathbf{X}$ y $\mathbf{X}^\top \hat{\mathbf{e}}$ son *el mismo vector* de $k + 1$ números: ambos tienen por componente j -ésima $\langle \hat{\mathbf{e}}, \mathbf{x}_j \rangle$.

Ortogonalidad generalizada: $k + 1$ condiciones

En la lección 6, la ortogonalidad de $\hat{e}$ frente a *todo* el plano $\mathcal{L}(\mathbf{1}, \mathbf{x})$ se traducía en dos condiciones, una por cada generador. Aquí ocurre exactamente lo mismo, solo que con $k+1$ generadores en vez de dos: basta que $\hat{e}$ sea ortogonal a cada uno de ellos para que sea ortogonal a *cualquier* combinación lineal, es decir, a todo el subespacio. Esto nos da las $k + 1$ condiciones:

$$\langle \hat{e}, \mathbf{1} \rangle_s = 0, \quad \langle \hat{e}, \mathbf{x}_j \rangle_s = 0 \quad (j = 1, \dots, k).$$

Escribir estas $k+1$ ecuaciones una a una, con su correspondiente sumatorio cada una, sería perfectamente posible pero tedioso. Aquí es donde la notación matricial demuestra su utilidad: recordando la *doble lectura* de la transparencia anterior, el producto *vector-matriz* $\hat{e}\mathbf{X}$ (multiplicar la lista $\hat{e}$ por la matriz $\mathbf{X}$, por columnas) es, precisamente, el vector de $k + 1$ componentes cuya j -ésima componente es el producto escalar de $\hat{e}$ con la j -ésima columna de $\mathbf{X}$. Así, las $k + 1$ condiciones de ortogonalidad se comprimen en una sola igualdad vectorial:

$$\hat{e}\mathbf{X} = \mathbf{0}.$$

Esta es la *forma primaria* —la más natural, porque no requiere transponer ningún vector (recordemos, lección 2: los vectores no se transponen). Sin embargo, en la inmensa mayoría de los manuales de econometría —y en la salida de muchos programas, incluido Gretl— la misma condición se escribe con la *matriz* traspuesta a la izquierda:

$$\mathbf{X}^\top \hat{e} = \mathbf{0}.$$

Conviene subrayar, para no crear confusión, que ambas expresiones designan *exactamente el mismo vector* de $k + 1$ números: la j -ésima componente de $\mathbf{X}^\top \hat{e}$ es, de nuevo, el producto escalar de la j -ésima columna de $\mathbf{X}$ (una fila de $\mathbf{X}^\top$) con $\hat{e}$. No es una matriz distinta la que se transpone: es la propia matriz de regresores $\mathbf{X}$, y esa transposición es legítima porque $\mathbf{X}$ *sí* es una matriz (una lista de vectores-columna), no un vector. Usaremos ambas notaciones indistintamente en lo que sigue, según convenga.

Una última precisión, en la línea de las advertencias ya hechas en la lección 8 sobre STC/SEC/SRC: al escribir $\mathbf{X}^\top \hat{e} = \mathbf{0}$ estamos usando, implícitamente, el producto escalar euclídeo $\langle \cdot, \cdot \rangle_e$ (sin el factor $1/n$), mientras que las condiciones $\langle \hat{e}, \mathbf{x}_j \rangle_s = 0$ de más arriba usan el producto estadístico. Esto no supone ninguna contradicción: como el factor $1/n$ es una constante positiva, multiplicarlo o no por cada ecuación no cambia si esa ecuación vale cero o no. Las dos formas de escribir la condición de ortogonalidad son, por tanto, exactamente equivalentes.

Para profundizar:

- Wooldridge, J. M. (2020), Apéndice E.1-E.2: la notación matricial de las ecuaciones normales en regresión múltiple.

6 Ecuaciones normales

Sustituyendo $\hat{e} = \mathbf{y} - \mathbf{X}\hat{\beta}$ en $\mathbf{X}^\top \hat{e} = \mathbf{0}$:

$$\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\beta}) = \mathbf{0} \implies \boxed{\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}.}$$

$k + 1$ ecuaciones, $k + 1$ incógnitas $(\hat{\beta}_0, \dots, \hat{\beta}_k)$. Aquí aparece por primera vez, y por única vez en el curso, un producto matriz-matriz: $\mathbf{X}^\top \mathbf{X}$.

Si los $k + 1$ generadores son independientes, $\mathbf{X}^\top \mathbf{X}$ es invertible y existe una única solución:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Esta fórmula *existe* (Gretl la calcula así); pero *nunca la usaremos para razonar*. El camino conceptual es siempre la ortogonalidad, no la inversión de matrices.

Ecuaciones normales

La transparencia anterior nos dejó las $k + 1$ condiciones de ortogonalidad comprimidas en $\mathbf{X}^\top \hat{\mathbf{e}} = \mathbf{0}$. Resolver este sistema para obtener $\hat{\beta}$ es puramente algebraico: sustituimos la definición del residuo, $\hat{\mathbf{e}} = \mathbf{y} - \mathbf{X}\hat{\beta}$, y distribuimos la matriz traspuesta:

$$\mathbf{X}^\top \mathbf{y} - \mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{0} \implies \mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}.$$

A este sistema de $k + 1$ ecuaciones lineales con $k + 1$ incógnitas se le llama, tradicionalmente, *ecuaciones normales* (el nombre viene de que expresan condiciones de ortogonalidad, es decir, de perpendicularidad o “normalidad” geométrica, no de la distribución normal de probabilidad).

Aquí aparece, por primera y única vez en todo el curso, un *producto matriz-matriz*: $\mathbf{X}^\top \mathbf{X}$, una matriz cuadrada de $(k + 1) \times (k + 1)$. No vamos a desarrollar ninguna teoría general sobre productos de matrices; nos basta con saber que su elemento (i, j) es, una vez más, un producto escalar: el producto escalar entre la columna i -ésima y la columna j -ésima de $\mathbf{X}$ —es decir, entre el regresor i -ésimo y el regresor j -ésimo—. Por ejemplo, el elemento $(0, 0)$ (fila y columna de la constante) es $\langle \mathbf{1}, \mathbf{1} \rangle_e = n$; el elemento que cruza $\mathbf{1}$ con $\mathbf{x}_j$ es $\langle \mathbf{1}, \mathbf{x}_j \rangle_e = n\mu_{x_j}$ (recordando la lección 4); y el elemento que cruza $\mathbf{x}_i$ con $\mathbf{x}_j$ es $\langle \mathbf{x}_i, \mathbf{x}_j \rangle_e$. Es decir: toda la matriz $\mathbf{X}^\top \mathbf{X}$ está construida, literalmente, con los mismos productos escalares que ya sabíamos calcular desde la lección 2; la novedad es solo organizarlos en una tabla.

Si los $k + 1$ generadores $\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k$ son independientes (en el sentido informal de la transparencia 2: ninguno es combinación lineal exacta de los demás), puede probarse —sin que nosotros lo hagamos aquí, pues excede el alcance del curso— que la matriz $\mathbf{X}^\top \mathbf{X}$ es *invertible*, y por tanto el sistema de ecuaciones normales tiene una única solución:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Esta es la fórmula que aparece en la práctica totalidad de los manuales de econometría, y es también, de hecho, la que Gretl (y cualquier otro software estadístico) utiliza internamente para calcular una regresión múltiple. Aquí la mencionamos por completitud —conviene saber que existe, y saber reconocerla si la veis en un libro—, pero *no* vamos a usarla como herramienta de razonamiento en este curso: no vamos a calcular inversas de matrices a mano, ni vamos a apoyarnos en propiedades de la inversa para demostrar nada. El camino conceptual que nos interesa —y que reaparecerá en la lección 15 al demostrar propiedades del estimador— sigue siendo, siempre, la condición de ortogonalidad $\mathbf{X}^\top \hat{\mathbf{e}} = \mathbf{0}$, no la fórmula con inversa.

Vale la pena señalar, para cerrar, que la propia existencia de esta inversa es precisamente lo que puede fallar cuando los regresores no son independientes: si $\mathbf{X}^\top \mathbf{X}$ no es invertible (colinealidad

exacta) o es “casi” no invertible (colinealidad severa), el sistema de ecuaciones normales deja de tener una solución única, o tiene una solución extremadamente sensible a pequeños cambios en los datos. Este es, precisamente, el problema que se estudiará en la lección 14.

Para profundizar:

- Wooldridge, J. M. (2020), Apéndice E: derivación matricial completa de las ecuaciones normales y condiciones de existencia de la inversa.

7 Familia ortogonal y Pitágoras generalizado

Recordemos (lección 3, Cauchy–Schwarz) la fórmula de proyección sobre *un* generador: $\alpha = \langle \mathbf{b}, \mathbf{a} \rangle / \langle \mathbf{a}, \mathbf{a} \rangle$. Y (lección 7) la “vía alternativa” con *dos* generadores ortogonales.

Si $\{\mathbf{1}, \mathbf{v}_1, \dots, \mathbf{v}_k\}$ son *mutuamente ortogonales*, cada coeficiente se calcula *por separado*, sin resolver ningún sistema:

$$\hat{\beta}_0 = \mu_{\mathbf{y}}, \quad \hat{\beta}_j = \frac{\langle \mathbf{y}, \mathbf{v}_j \rangle}{\langle \mathbf{v}_j, \mathbf{v}_j \rangle} \quad (j = 1, \dots, k).$$

Y Pitágoras se extiende a $k + 2$ términos:

$$\|\mathbf{y}\|_s^2 = \mu_{\mathbf{y}}^2 + \|\hat{\beta}_1 \mathbf{v}_1\|_s^2 + \dots + \|\hat{\beta}_k \mathbf{v}_k\|_s^2 + \|\hat{\mathbf{e}}\|_s^2.$$

Este caso, tan cómodo, es la excepción: con datos económicos reales, los regresores casi nunca son ortogonales entre sí. El caso general exige resolver las ecuaciones normales de la transparencia anterior.

Familia ortogonal y Pitágoras generalizado

Esta transparencia cobra una promesa muy antigua, sembrada en la lección 3 al demostrar Cauchy–Schwarz: allí construimos $\mathbf{h} = \mathbf{b} - \alpha \mathbf{a}$, con $\alpha = \langle \mathbf{a}, \mathbf{b} \rangle / \langle \mathbf{a}, \mathbf{a} \rangle$, y dijimos que ese $\alpha \mathbf{a}$ era la “sombra” de $\mathbf{b}$ sobre la dirección de $\mathbf{a}$ —la *proyección ortogonal*—. *En la lección 7 usamos esa misma fórmula, con /dos generadores ortogonales ($\mathbf{1}$ y $\mathbf{x} - \mu_{\mathbf{x}} \mathbf{1}$), para obtener $\hat{\beta}_1$ sin resolver ningún sistema: la llamamos, entonces, “vía alternativa”.*

Generalicemos esa vía alternativa a k generadores. Supongamos que, además de $\mathbf{1}$, disponemos de k vectores $\mathbf{v}_1, \dots, \mathbf{v}_k$ que son *mutuamente ortogonales entre sí* y, además, ortogonales a $\mathbf{1}$ (es decir, todos ellos de media cero). En ese caso —y *solo* en ese caso—, la proyección de $\mathbf{y}$ sobre $\mathcal{L}(\mathbf{1}, \mathbf{v}_1, \dots, \mathbf{v}_k)$ se descompone en $k + 1$ proyecciones *independientes*, cada una calculada con la misma fórmula de Cauchy–Schwarz de la lección 3, aplicada por separado a cada generador:

$$\hat{\beta}_0 = \frac{\langle \mathbf{y}, \mathbf{1} \rangle}{\langle \mathbf{1}, \mathbf{1} \rangle} = \mu_{\mathbf{y}}, \quad \hat{\beta}_j = \frac{\langle \mathbf{y}, \mathbf{v}_j \rangle}{\langle \mathbf{v}_j, \mathbf{v}_j \rangle} \quad (j = 1, \dots, k).$$

No hace falta resolver ningún sistema de ecuaciones normales: cada coeficiente se calcula de forma completamente aislada, exactamente como ocurría con dos generadores en la lección 7.

Esta ortogonalidad mutua tiene, además, una consecuencia sobre la descomposición de la varianza. El teorema de Pitágoras (lección 3) se enunció para *dos* vectores ortogonales, pero se extiende,

sin ninguna dificultad adicional, a *varios* vectores mutuamente ortogonales: si $\mathbf{w}_0, \mathbf{w}_1, \dots, \mathbf{w}_m$ son ortogonales dos a dos, entonces $\|\mathbf{w}_0 + \mathbf{w}_1 + \dots + \mathbf{w}_m\|^2 = \|\mathbf{w}_0\|^2 + \|\mathbf{w}_1\|^2 + \dots + \|\mathbf{w}_m\|^2$ (basta aplicar el caso de dos vectores repetidamente, agrupando de dos en dos). Aplicado a nuestra descomposición $\mathbf{y} = \mu_{\mathbf{y}}\mathbf{1} + \hat{\beta}_1\mathbf{v}_1 + \dots + \hat{\beta}_k\mathbf{v}_k + \hat{\mathbf{e}}$ (donde los $k + 2$ sumandos son mutuamente ortogonales, por construcción):

$$\|\mathbf{y}\|_s^2 = \mu_{\mathbf{y}}^2 + \|\hat{\beta}_1\mathbf{v}_1\|_s^2 + \dots + \|\hat{\beta}_k\mathbf{v}_k\|_s^2 + \|\hat{\mathbf{e}}\|_s^2.$$

Existe, de hecho, un procedimiento general —llamado /ortogonalización de Gram-Schmidt/— para construir, a partir de cualquier conjunto de regresores, una familia ortogonal que genere exactamente el mismo subespacio. No lo desarrollaremos en este curso: baste con el nombre, para quien quiera indagar por su cuenta.

Conviene cerrar esta transparencia con una advertencia importante, que prepara el terreno para la siguiente. Este escenario —regresores mutuamente ortogonales— es cómodo mnemotécnicamente, pero es la *excepción*, no la norma. Con datos económicos reales, los regresores casi siempre están correlacionados entre sí en alguna medida (por ejemplo, `rooms` y `nox` en `hprice2` probablemente no son independientes: los barrios más contaminados podrían tener, en promedio, viviendas de otro tamaño). Cuando los regresores no son mutuamente ortogonales, no hay atajo: hay que resolver el sistema completo de ecuaciones normales de la transparencia anterior.

Para profundizar:

- Strang, G. (2016), cap. 4, sección 4.4: ortogonalización de Gram-Schmidt (mención, sin desarrollar en este curso).

8 R^2 en regresión múltiple

Como $\langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0$ sigue siendo una de las $k + 1$ condiciones: $\mu_{\mathbf{y}} = \mu_{\hat{\mathbf{y}}}$ (lección 7) y $\text{STC} = \text{SEC} + \text{SRC}$ (lección 8) *siguen valiendo exactamente igual*, sin importar k .

Pero (cobramos la pregunta 5 de la práctica de regresión simple): en general,

$$R^2 \neq \rho_{x_1 y}^2 + \dots + \rho_{x_k y}^2.$$

¿Por qué? En la lección 8, $R^2 = \rho_{x y}^2$ porque el subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}) \cap \mathcal{L}(\mathbf{1})^\perp$ tenía *una sola* dirección: cualquier vector centrado del plano estaba alineado con $\mathbf{x} - \mu_{\mathbf{x}}\mathbf{1}$.

Con $k > 1$ regresores, ese mismo subespacio centrado tiene k *direcciones* (transparencia 2): $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ ya no está, en general, alineado con ningún $\mathbf{x}_j - \mu_{x_j}\mathbf{1}$ en particular.

Excepción (transparencia anterior): si los regresores son mutuamente ortogonales, entonces sí,

$$R^2 = \rho_{x_1 y}^2 + \dots + \rho_{x_k y}^2 \text{ exactamente — Pitágoras generalizado, dividido por } \sigma_{\mathbf{y}}^2.$$

R^2 en regresión múltiple

Podemos ahora responder, con precisión geométrica, a la pregunta que dejamos abierta al comienzo de la sesión: ¿por qué el R^2 de un modelo con dos (o más) regresores no es la suma de los R^2 de los modelos simples correspondientes?

Primero, lo que *sí* se conserva sin cambio alguno. La condición $\langle \hat{e}, \mathbf{1} \rangle_s = 0$ sigue siendo una de nuestras $k+1$ condiciones de ortogonalidad, exactamente igual que en la lección 6-7 (allí era una de dos; aquí, una de $k+1$). De ella se deduce, sin ningún cambio en el argumento, que $\mu_y = \mu_{\hat{y}}$ (lección 7). Y como $\hat{y} \perp \hat{e}$ sigue siendo cierto (el residuo es ortogonal a *todo* el subespacio, en particular al propio ajuste, que pertenece a él), el mismo triángulo rectángulo de la lección 8 —hipotenusa $y - \bar{y}$, catetos $\hat{y} - \bar{y}$ y $\hat{e}$ — sigue siendo válido, sea cual sea k . Por tanto, $\text{STC} = \text{SEC} + \text{SRC}$ y $R^2 = \text{SEC}/\text{STC} = \cos^2 \theta$ (con θ el ángulo entre $y - \bar{y}$ y $\hat{y} - \bar{y}$) se mantienen, sin necesidad de ninguna demostración nueva: son consecuencia, otra vez, de las mismas dos piezas (ortogonalidad y Pitágoras), que no dependen del número de regresores.

Lo que *deja de valer*, en cambio, es la identidad exclusiva de la regresión simple, $R^2 = \rho_{xy}^2$. Recordemos por qué era cierta allí: en la lección 8 demostramos que, en $\mathcal{L}(\mathbf{1}, \mathbf{x})$, *todo* vector no constante, una vez centrado, cae en la misma recta $\mathcal{L}(\mathbf{x} - \mu_x \mathbf{1})$ —porque ese subespacio centrado tenía una única dirección—. Eso obligaba a $\hat{y} - \bar{y}$ a estar alineado con $\mathbf{x} - \mu_x \mathbf{1}$, y de ahí salía $\rho_{y\hat{y}} = |\rho_{xy}|$.

Con $k > 1$ regresores, el subespacio centrado $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k) \cap \mathcal{L}(\mathbf{1})^\perp$ tiene, en general, k direcciones distintas (transparencia 2), no una sola. El vector $\hat{y} - \bar{y}$ es, ahora, una combinación de los k vectores centrados $\mathbf{x}_1 - \mu_{x_1} \mathbf{1}, \dots, \mathbf{x}_k - \mu_{x_k} \mathbf{1}$, y ya no tiene por qué estar alineado con ninguno de ellos en particular. Por eso R^2 , aunque sigue siendo $\cos^2 \theta$, ya no coincide, en general, con el cuadrado de ninguna correlación simple $\rho_{x_j y}$ —y, con más razón todavía, tampoco con la suma de esos cuadrados.

Hay, sin embargo, una excepción exacta, y es precisamente el caso especial de la transparencia anterior. Si los regresores centrados $\mathbf{x}_1 - \mu_{x_1} \mathbf{1}, \dots, \mathbf{x}_k - \mu_{x_k} \mathbf{1}$ son *mutuamente ortogonales*, el Pitágoras generalizado nos da

$$\sigma_y^2 = \sigma_{\hat{y}}^2 + \sigma_e^2, \quad \sigma_{\hat{y}}^2 = \|\hat{\beta}_1(\mathbf{x}_1 - \mu_{x_1} \mathbf{1})\|_s^2 + \dots + \|\hat{\beta}_k(\mathbf{x}_k - \mu_{x_k} \mathbf{1})\|_s^2,$$

y cada uno de esos sumandos, dividido por σ_y^2 , resulta ser exactamente $\rho_{x_j y}^2$ (por el mismo argumento de la lección 8, aplicado a cada dirección por separado, ya que ahora sí están alineadas cada una con su propio regresor). En ese caso muy particular, y solo en él,

$$R^2 = \rho_{x_1 y}^2 + \dots + \rho_{x_k y}^2.$$

Pero, como ya señalamos, la ortogonalidad mutua entre regresores económicos reales es la excepción, no la norma —lo comprobaremos en la práctica que sigue a esta lección, con `rooms` y `=nox=`—.

Para profundizar:

- Wooldridge, J. M. (2020), cap. 3, sección 3.2: por qué el R^2 de la regresión múltiple no se descompone, en general, en las correlaciones simples con cada regresor.

9 El puente cobrado (aserción, sin demostración)

Retomando el lenguaje de la lección 9: modelo poblacional con k regresores (regla de la variable aleatoria constante: nunca sumar un escalar directamente a una v.a.):

$$Y = \beta_0 \mathbf{1} + \beta_1 X_1 + \dots + \beta_k X_k + U.$$

Bajo los supuestos generalizados del MCRL (linealidad de $E[Y \mid X_1, \dots, X_k]$, exogeneidad estricta $E[U \mid X_1, \dots, X_k] = 0$, homocedasticidad), *aseveramos, sin demostrar*:

$$E[\hat{\beta} \mid \mathbf{X}] = \beta, \quad \text{Var}[\hat{\beta} \mid \mathbf{X}] = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}.$$

Esto es una *promesa*, generalización matricial de lo prometido en la lección 9. La lección 11 la demostrará —solo/ para el caso particular $k = 1$ — con las herramientas escalares que ya conocemos, sin matrices.

El puente cobrado (aserción, sin demostración)

Cerramos esta sesión conectándola con “el puente” de la lección 9. Allí dimos el salto desde $\mathbb{R}^n$ hasta el espacio de variables aleatorias, y planteamos el Modelo Clásico de Regresión Lineal con un único regresor X . Generalizamos ahora, de manera puramente notacional (sin ningún concepto nuevo), a k regresores $X_1, \dots, X_k$. Recordando la regla de la variable aleatoria constante fijada en la lección 9 —nunca se suma un escalar directamente a una variable aleatoria; todo escalar debe multiplicar a la variable aleatoria constante 1 —, el modelo poblacional de regresión múltiple se escribe

$$Y = \beta_0 1 + \beta_1 X_1 + \dots + \beta_k X_k + U,$$

con $\beta_0, \beta_1, \dots, \beta_k$ parámetros poblacionales desconocidos (sin sombrero, exactamente igual que en la lección 9), y U la perturbación, $U = Y - E[Y \mid X_1, \dots, X_k]$.

Los tres supuestos del modelo clásico de la lección 9 se generalizan de forma igualmente directa: (1) *linealidad*, $E[Y \mid X_1, \dots, X_k] = \beta_0 1 + \beta_1 X_1 + \dots + \beta_k X_k$; (2) *exogeneidad estricta*, $E[U \mid X_1, \dots, X_k] = 0$; (3) *homocedasticidad*, $\text{Var}[U \mid X_1, \dots, X_k] = \sigma^2 1$.

Bajo estos tres supuestos, y usando exactamente el mismo tipo de argumento que empleamos en la lección 9 —sustituir el modelo poblacional en las condiciones de exogeneidad y despejar—, se puede demostrar (no lo haremos aquí, con matrices) que el estimador $\hat{\beta}$ obtenido por MCO, ahora escrito en su forma matricial, cumple:

$$E[\hat{\beta} \mid \mathbf{X}] = \beta \quad (\text{insesgadez}), \quad \text{Var}[\hat{\beta} \mid \mathbf{X}] = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1} \quad (\text{varianza}).$$

Es importante ser honestos sobre el estatus de estas dos fórmulas en el punto en que estamos del curso: son una *aserción*, no una demostración. Las enunciamos porque son la generalización natural y esperable de lo que ya sabemos sobre proyecciones y esperanzas condicionadas (lección 9), y porque necesitaremos disponer de ellas —sobre todo de la segunda, la varianza— para construir, más adelante, errores estándar, contrastes de hipótesis e intervalos de confianza. Pero *no* las hemos demostrado, y no lo haremos con esta generalidad en este curso: exigiría manipular productos y traspuestas de matrices aleatorias, un nivel de álgebra matricial que hemos decidido no desarrollar (recordemos la advertencia de la transparencia 6: la inversa existe, pero no es una herramienta de razonamiento en este curso).

Lo que sí haremos, en la lección 11, es demostrar estas mismas dos propiedades —insesgadez y varianza— mas *únicamente para el caso particular de un solo regresor* ($k = 1$, la regresión simple de las lecciones 6-8), con un argumento enteramente escalar, sin ninguna matriz de por medio: escribiendo $\hat{\beta}_1$ como una combinación lineal ponderada de las observaciones Y_i , y usando

directamente la exogeneidad y la homocedasticidad de la lección 9. Ese caso particular es, de hecho, exactamente lo que resultaría de particularizar las fórmulas matriciales de hoy a $k = 1$; comprobarlo será una buena manera de cerrar el círculo en su momento.

Para profundizar:

- Wooldridge, J. M. (2020), cap. 3, secciones 3.3 (insesgadez) y Apéndice E.2 (varianza en notación matricial).

10 Recapitulación y guiño a la sesión siguiente

Regresión simple	Regresión múltiple
$\mathcal{L}(\mathbf{1}, \mathbf{x})$, un plano	$\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$, $k + 1$ direcciones
2 condiciones de ortogonalidad	$k + 1$ condiciones, comprimidas en $\mathbf{X}^\top \hat{\mathbf{e}} = \mathbf{0}$
$\hat{\beta}_0, \hat{\beta}_1$ (escalares)	$\hat{\boldsymbol{\beta}}$ (vector), vía $\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$
$R^2 = \rho_{xy}^2$ (siempre)	$R^2 = \cos^2 \theta$ (siempre); $= \sum_j \rho_{x_j y}^2$ solo si ortogonales

Una advertencia de interpretación, para la práctica: cada $\hat{\beta}_j$ mide un *efecto parcial* —“manteniendo constantes los demás regresores” (*ceteris paribus*)—. En `hprice2`, quien estime `price~rooms` sin más podría concluir, erróneamente, que “más habitaciones siempre encarece la vivienda”; pero *a igualdad de superficie*, no está nada claro que dividir el mismo espacio en más habitaciones deba subir el precio. El coeficiente de `rooms` en un modelo con más regresores no tiene por qué parecerse al de la regresión simple —ni en magnitud, ni siquiera en signo.

Guiño: en la práctica que sigue a esta lección, comprobaremos esto con datos reales (el conocido conjunto de viviendas de Ramanathan, en la pestaña `Gret1` de datos de muestra) y hablaremos del R^2 ajustado. En la lección 11, cobraremos —solo para $k = 1$ — la promesa de hoy sobre $E[\hat{\boldsymbol{\beta}} \mid \mathbf{X}]$ y $\text{Var}[\hat{\boldsymbol{\beta}} \mid \mathbf{X}]$.

Recapitulación y guiño a la sesión siguiente

El recorrido de esta sesión ha sido, en su estructura, una repetición deliberada de la lección 6-7, ahora con k regresores en lugar de uno. Ninguna idea matemática nueva ha sido necesaria: la proyección ortogonal, las condiciones de ortogonalidad del residuo, Pitágoras. Lo único genuinamente nuevo ha sido el *lenguaje* —la notación matricial— que nos permite escribir de forma compacta un problema que, con sumatorios, requeriría $k + 1$ ecuaciones escritas una a una.

La tabla resume el paralelismo completo entre ambos casos. Merece la pena detenerse en la última fila, que es la que responde a la pregunta con la que abrimos la sesión: en regresión simple, R^2 *siempre* coincide con ρ_{xy}^2 , porque el subespacio centrado tiene una única dirección; en regresión múltiple, R^2 sigue siendo $\cos^2 \theta$ —la definición geométrica no cambia—, pero deja de coincidir, en general, con ninguna suma de correlaciones simples, salvo en el caso especial (y poco frecuente con datos reales) de regresores mutuamente ortogonales.

La advertencia sobre el *efecto parcial* merece subrayarse, porque es la primera vez en el curso que disponemos del aparato necesario para plantearla con precisión. Hasta ahora, con un único regresor, “el efecto de $\mathbf{x}$ sobre $\mathbf{y}$ ” y “el coeficiente $\hat{\beta}_1$ ” eran, sin más matices, la misma cosa. Con varios regresores, $\hat{\beta}_j$ mide algo más sutil: cuánto cambia, en promedio, el ajuste ante un

cambio en $\mathbf{x}_j$, *manteniendo fijos los demás regresores del modelo* —de ahí la expresión latina *ceteris paribus* (“permaneciendo lo demás igual”)—. Esta es la razón exacta por la que el coeficiente de **rooms** puede cambiar —incluso de signo— al pasar de **price~rooms** a **price~rooms+nox**, o a un modelo que incluya también la superficie de la vivienda: cada modelo está respondiendo a una pregunta ligeramente distinta. La práctica que sigue a esta lección explorará esto con un ejemplo muy conocido en la literatura de enseñanza de econometría: el conjunto de datos de precios de viviendas de Ramanathan (accesible en Gretl como dataset de muestra, no en la colección de Wooldridge), donde comparar el modelo simple con **rooms** frente a un modelo que además controle por la superficie de la vivienda ilustra con claridad por qué “más habitaciones” no es, sin matices, sinónimo de “vivienda más cara”.

Cerramos con dos promesas explícitas para las próximas sesiones. La primera, de corto plazo: la práctica de laboratorio que sigue a esta lección aplicará todo lo de hoy con datos reales, calculará el R^2 ajustado —que compensa, precisamente, el hecho de que el R^2 ordinario nunca disminuye al añadir regresores (advertencia ya sembrada en la lección 8)— y comparará coeficientes parciales frente a los coeficientes de las regresiones simples correspondientes. La segunda, de plazo algo mayor: en la lección 11 volveremos sobre la aserción de la transparencia anterior —insesgadez y varianza de $\hat{\beta}$ — y la demostraremos, esta vez con todo rigor, aunque restringida al caso más sencillo de un único regresor, sin necesidad de ninguna matriz.

Para profundizar:

- Wooldridge, J. M. (2020), cap. 3, sección 3.4: interpretación *ceteris paribus* de los coeficientes de la regresión múltiple, con ejemplos económicos.