

Índice general

1	De dónde venimos: del plano al hiperplano	2
2	La geometría es la misma	3
3	El problema aritmético: demasiadas ecuaciones	4
4	La matriz de datos y la doble lectura	5
5	Las Ecuaciones Normales	6
6	Interpretación: Efecto parcial (<i>ceteris paribus</i>)	7
7	Familia ortogonal y Pitágoras generalizado	8
8	Modelo Poblacional y Propiedades (Adelanto)	9
9	Recapitulación y guiño a la lección siguiente	10
10	Pruebas	11
10.0.1	Propuesta de notación y expresiones (para tu validación)	11

Lección 10. Regresión múltiple: matrices y geometría en dimensiones altas

Marcos Bujosa

21 de agosto de 2026

Resumen

Generalizamos la regresión a cualquier número de regresores. La geometría sigue siendo idéntica (la ortogonalidad lo gobierna todo), pero el sistema de ecuaciones crece. Para no asfixiarnos en sumatorios, introducimos la notación matricial como una elegante herramienta de comprensión y exploramos el concepto más importante de la regresión múltiple: el efecto parcial o *ceteris paribus*.

“Más direcciones, el mismo principio: la sombra siempre cae en perpendicular.”

- ([slides](#)) — ([html](#)) — ([pdf](#))

1 De dónde venimos: del plano al hiperplano

En la lección 6 proyectamos el vector de datos $\mathbf{y}$ sobre el *plano* generado por $\mathbf{1}$ y $\mathbf{x}$. La ortogonalidad del residuo frente a **todo el plano** se tradujo en **dos** condiciones (una por generador).

En economía rara vez un fenómeno depende de un solo factor. El precio de una casa no depende solo de los metros cuadrados; influyen las habitaciones, la contaminación, la cercanía al transporte, etc.

El paso natural: Añadir más regresores. Proyectaremos $\mathbf{y}$ sobre el subespacio generado por k regresores (además de la constante):

$$\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k)$$

El ajuste será una combinación lineal de todos ellos:

$$\hat{\mathbf{y}} = \hat{\beta}_0 \mathbf{1} + \hat{\beta}_1 \mathbf{x}_1 + \hat{\beta}_2 \mathbf{x}_2 + \dots + \hat{\beta}_k \mathbf{x}_k.$$

El subespacio ya no es una recta ni un plano; es un “hiperplano” multidimensional. Pero **la geometría es exactamente la misma**.

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

De dónde venimos: del plano al hiperplano

Hasta ahora hemos avanzado sumando dimensiones de una en una. En la lección 4 resolvimos la proyección más sencilla: buscar el vector más cercano a los datos $\mathbf{y}$ dentro de la recta $\mathcal{L}(\mathbf{1})$. Obtuvimos la media. En la lección 6 dimos un paso más: añadimos una segunda dirección, el regresor $\mathbf{x}$, y proyectamos sobre el plano $\mathcal{L}(\mathbf{1}, \mathbf{x})$. Obtuvimos la regresión lineal simple.

Hoy damos el salto definitivo. En la realidad empírica, un solo regresor casi nunca es suficiente. Si queremos explicar el salario de una persona, no basta con conocer sus años de educación ($\mathbf{x}_1$); necesitamos conocer su experiencia laboral ($\mathbf{x}_2$), su antigüedad en la empresa ($\mathbf{x}_3$), etc.

Geométricamente, esto equivale a añadir más "ejes" o vectores generadores a nuestro subespacio. Si tenemos k variables explicativas, más el vector constante de unos $\mathbf{1}$, el subespacio sobre el que proyectaremos será $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$. Este subespacio ya no es un plano bidimensional, sino lo que en geometría se denomina un *hiperplano* (un espacio de dimensión $k + 1$).

¿Qué cambia en nuestra manera de afrontar el problema? Conceptualmente, **absolutamente nada**. Seguimos buscando el vector $\hat{\mathbf{y}}$ (el ajuste) de ese subespacio que minimiza la distancia a $\mathbf{y}$. Y, como sabemos desde la lección 3, ese punto de mínima distancia es la *proyección ortogonal*: el punto que garantiza que el vector de residuos $\hat{\mathbf{e}} = \mathbf{y} - \hat{\mathbf{y}}$ sea estrictamente perpendicular a todo el subespacio.

Para profundizar:

- Wooldridge, J. M. (2020), capítulo 3, sección 3.1: Motivación del modelo de regresión múltiple.

2 La geometría es la misma




Figura 1: Proyección ortogonal de $\mathbf{y}$ sobre un subespacio (aquí representado esquemáticamente por el plano inferior), vista desde tres ángulos. Es exactamente la misma figura de la regresión simple (lecciones 6 y 8), solo que ahora el plano inferior no representa solo a $\mathcal{L}(\mathbf{1}, \mathbf{x})$, sino a todo el subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$.

- $\hat{\mathbf{y}}$ sigue siendo la "sombra" de $\mathbf{y}$ sobre el subespacio de los regresores.
- $\hat{\mathbf{e}}$ sigue siendo **perpendicular a todas las direcciones** de dicho subespacio.

La geometría es la misma

Para ilustrar la regresión múltiple rescatamos la misma figura geométrica que ya usamos en la lección 6 (al plantear la regresión simple) y en la lección 8 (al demostrar $R^2 = \cos^2 \theta$). Esto no es un reciclaje por falta de imágenes, sino una decisión deliberada: en esas lecciones fuimos muy cuidadosos de NO dibujar la componente $\hat{\beta}_1 \mathbf{x}$ individualmente dentro del plano. Dibujamos únicamente la proyección sobre la constante ($\bar{\mathbf{y}}$) y el plano en su conjunto.

Esa abstracción nos permite ahora releer la misma figura para k regresores. El subespacio azul y negro ya no es un plano bidimensional, sino que representa esquemáticamente el inmenso subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$.

Todo lo que dedujimos de esta figura sigue siendo cierto:

1. El vector ajustado $\hat{\mathbf{y}}$ es la proyección ortogonal.
2. El residuo $\hat{\mathbf{e}}$ forma un ángulo de 90° con el subespacio entero.
3. El triángulo rectángulo formado por $\mathbf{y} - \bar{\mathbf{y}}$, $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ y $\hat{\mathbf{e}}$ sigue existiendo, lo que significa que el teorema de Pitágoras sigue funcionando: $\text{STC} = \text{SEC} + \text{SRC}$ ($\sigma_{\mathbf{y}}^2 = \sigma_{\hat{\mathbf{y}}}^2 + \sigma_{\hat{\mathbf{e}}}^2$) es igual de válido en la regresión múltiple.
4. El coeficiente de determinación se define exactamente igual: $R^2 = \cos^2 \theta$, donde θ sigue siendo el ángulo entre los vectores en desviaciones de los datos y de su ajuste.

Si la geometría es idéntica y todas las conclusiones teóricas se mantienen, ¿dónde está la dificultad de la regresión múltiple? En la aritmética. En la siguiente transparencia veremos qué pasa cuando intentamos escribir las condiciones de ortogonalidad a mano.

3 El problema aritmético: demasiadas ecuaciones

La exigencia de que $\hat{\mathbf{e}}$ sea ortogonal a TODO el subespacio implica que debe ser ortogonal a **cada uno de sus generadores**.

Tendremos $k + 1$ condiciones de ortogonalidad simultáneas:

$$\begin{aligned} \langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0 & \implies \frac{1}{n} \sum \hat{e}_i = 0 \\ \langle \hat{\mathbf{e}}, \mathbf{x}_1 \rangle_s = 0 & \implies \frac{1}{n} \sum x_{1i} \hat{e}_i = 0 \\ \langle \hat{\mathbf{e}}, \mathbf{x}_2 \rangle_s = 0 & \implies \frac{1}{n} \sum x_{2i} \hat{e}_i = 0 \\ & \dots \\ \langle \hat{\mathbf{e}}, \mathbf{x}_k \rangle_s = 0 & \implies \frac{1}{n} \sum x_{ki} \hat{e}_i = 0 \end{aligned}$$

Recordando que $\hat{e}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \dots + \hat{\beta}_k x_{ki})$, escribir y resolver este sistema con sumatorios es agotador. Necesitamos **comprimir** la notación.

El problema aritmético: demasiadas ecuaciones

En la lección 7 pudimos resolver el sistema de la regresión simple a mano porque solo teníamos dos ecuaciones ($\langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0$ y $\langle \hat{\mathbf{e}}, \mathbf{x} \rangle_s = 0$) y dos incógnitas ($\hat{\beta}_0, \hat{\beta}_1$). Despejamos en una, sustituimos en la otra, y llegamos al resultado.

Ahora tenemos $k + 1$ regresores (la constante y las k variables). Para que el residuo sea perpendicular a todo el hiperespacio, tiene que ser perpendicular a cada uno de sus ejes generadores. Esto nos arroja un sistema de $k + 1$ ecuaciones con $k + 1$ incógnitas ($\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k$).

Si intentamos sustituir $\hat{e}_i$ en cada ecuación y desarrollar los sumatorios, nos encontraremos con expresiones interminables. Despejar a mano un sistema de, por ejemplo, 5 regresores usando el símbolo $\sum$ es una pesadilla de subíndices cruzados.

No hay ningún concepto nuevo que descubrir aquí, solo un problema de notación: nuestra forma de escribir las cosas no está a la altura de la dimensión del problema. Para solucionarlo, vamos a introducir una herramienta matemática diseñada específicamente para agrupar vectores y hacer múltiples productos escalares de una sola vez: las **matrices**.

4 La matriz de datos y la doble lectura

En lugar de tener $k + 1$ vectores sueltos, los agrupamos como **columnas** en una gran tabla: la matriz de datos $\mathbf{X}$.

$$\mathbf{X} = [\mathbf{1}; \mathbf{x}_1; \dots; \mathbf{x}_k]$$

Y agrupamos los coeficientes a estimar en un vector columna: $\hat{\boldsymbol{\beta}} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k)$.

El producto matriz-vector $\mathbf{X}\hat{\boldsymbol{\beta}}$ tiene una **doble lectura** maravillosa:

1. **Lectura por columnas (la geometría):** Es la combinación lineal de los regresores.

$$\mathbf{X}\hat{\boldsymbol{\beta}} = \hat{\beta}_0\mathbf{1} + \hat{\beta}_1\mathbf{x}_1 + \dots + \hat{\beta}_k\mathbf{x}_k = \hat{\mathbf{y}}$$

2. **Lectura por filas (el individuo):** Da como resultado un vector donde cada fila i es el producto escalar entre los regresores del individuo i y los coeficientes.

$$\text{Fila } i: \quad \hat{y}_i = \hat{\beta}_0 \cdot 1 + \hat{\beta}_1 x_{1i} + \dots + \hat{\beta}_k x_{ki}$$

La matriz de datos y la doble lectura

En este curso no vamos a estudiar álgebra matricial (no calcularemos rangos, ni determinantes, ni nos detendremos en las propiedades abstractas de las matrices). Introducimos las matrices, representadas siempre con letras mayúsculas de palo seco en negrita (como $\mathbf{X}$), con un único propósito: como una **herramienta de compresión tipográfica**.

Una matriz no es más que una lista de vectores-columna puestos uno al lado del otro. Si agrupamos nuestra constante y todos nuestros regresores, construimos la matriz de diseño o matriz de datos $\mathbf{X}$. Si tenemos n observaciones y k variables (más la constante), esta matriz tiene n filas y $k + 1$ columnas.

Del mismo modo, agrupamos todos nuestros coeficientes $\hat{\beta}_j$ en un único vector $\hat{\beta}$.

El corazón de la notación matricial, y la razón por la que es tan útil, es la operación de multiplicar una matriz por un vector: $\mathbf{X}\hat{\beta}$. Esta operación admite dos lecturas complementarias, y dominar este "bilingüismo" es clave para la econometría.

La *primera lectura* (por columnas) es nuestra visión macroscópica, la geométrica. Nos dice que multiplicar una matriz por un vector equivale a hacer una **combinación lineal** de las columnas de la matriz, usando los elementos del vector como ponderadores (coeficientes). Así, $\mathbf{X}\hat{\beta}$ es, ni más ni menos, la definición misma de nuestro vector ajustado $\hat{y}$.

La *segunda lectura* (por filas) es la visión microscópica, la de los datos individuales. Nos dice que cada elemento resultante es el producto escalar de una fila de la matriz por el vector $\hat{\beta}$. Para la fila i (los datos de una persona, casa o empresa concreta), obtenemos exactamente su valor ajustado particular $\hat{y}_i$.

En el fondo, ya usamos esta misma doble lectura de forma germinal en la lección 4. Allí, la media μ_y era simultáneamente el coeficiente de la proyección $\mu_y \mathbf{1}$ (combinación lineal de una sola columna) y el resultado del producto escalar $\langle y, \mathbf{1} \rangle_s$.

5 Las Ecuaciones Normales

Nuestras $k + 1$ condiciones de ortogonalidad pedían que $\hat{e}$ fuera perpendicular a cada columna de $\mathbf{X}$.

Usando la lectura por filas, podemos escribir todas las condiciones de golpe multiplicando el vector $\hat{e}$ por la matriz $\mathbf{X}$:

$$\hat{e}^\top \mathbf{X} = \mathbf{0}^\top \quad (\text{donde } ^\top \text{ significa "traspuesto" a vector fila})$$

Sustituyendo $\hat{e} = y - \hat{y} = y - \mathbf{X}\hat{\beta}$:

$$(y - \mathbf{X}\hat{\beta})^\top \mathbf{X} = \mathbf{0}^\top \implies y^\top \mathbf{X} - \hat{\beta}^\top \mathbf{X}^\top \mathbf{X} = \mathbf{0}^\top$$

Despejando (y trasponiendo de nuevo a columnas), llegamos al corazón de los mínimos cuadrados, las **Ecuaciones Normales**:

$$\boxed{\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top y}$$

Nota: $\mathbf{X}^\top \mathbf{X}$ es el producto de matriz por matriz (recopila todos los productos escalares entre regresores). Si ningún regresor es combinación lineal perfecta de otros (no hay colinealidad exacta), esta matriz tiene **inversa**, pero no la calcularemos a mano.

Las Ecuaciones Normales

Si la matriz $\mathbf{X}$ agrupaba los regresores, necesitamos una forma de expresar que el vector $\hat{e}$ es ortogonal a todos ellos a la vez.

Aquí usamos de nuevo la matriz, pero traspuesta. El operador transposición (T) simplemente tumba un vector columna para convertirlo en un vector fila, o convierte las columnas de una matriz en filas. Si multiplicamos el vector fila $\hat{e}^T$ por la matriz $\mathbf{X}$ (leída por columnas), estamos haciendo el producto escalar de $\hat{e}$ contra la primera columna (la constante), luego contra la segunda ($\mathbf{x}_1$), etc.

Igualar todo eso a un vector fila de ceros ($\mathbf{0}^T$) es la compresión definitiva: estamos escribiendo en tres símbolos las $k + 1$ condiciones de ortogonalidad que nos asfixiaban en sumatorios.

A partir de ahí, solo aplicamos álgebra. Sustituimos $\hat{e}$ por su definición ($\mathbf{y} - \mathbf{X}\hat{\beta}$). Al aplicar la propiedad distributiva obtenemos una ecuación donde interviene $\mathbf{X}^T \mathbf{X}$. Esta es una matriz cuadrada $(k+1) \times (k+1)$ que recopila, en una sola tabla, absolutamente todos los productos escalares euclídeos posibles cruzando cada regresor consigo mismo y con los demás.

El resultado final, $\mathbf{X}^T \mathbf{X} \hat{\beta} = \mathbf{X}^T \mathbf{y}$, se conoce como las **Ecuaciones Normales**. "Normales" aquí significa geométricas, perpendiculares. Son la generalización matricial exacta de las fórmulas que vimos en la lección 7.

En un curso de álgebra lineal, el siguiente paso sería multiplicar ambos lados por la matriz inversa $(\mathbf{X}^T \mathbf{X})^{-1}$ para despejar $\hat{\beta}$ en el lado izquierdo. Nosotros sabemos que esa inversa existe (siempre y cuando ningún regresor sea una copia o combinación lineal perfecta de otro, es decir, si no hay colinealidad exacta, un tema que exploraremos en la sesión 20). Sin embargo, calcular inversas a mano no aporta ninguna intuición geométrica nueva ni económica. Los ordenadores (Gretl) resuelven este sistema instantáneamente. Lo importante para nosotros no es la mecánica de la matriz inversa, sino entender que todo el ajuste surge, única y exclusivamente, de exigir perpendicularidad ($\hat{e}^T \mathbf{X} = \mathbf{0}^T$).

Para profundizar:

- Strang, G. (2016), cap. 4. Ecuaciones normales como la forma estándar de resolver proyecciones en subespacios.

6 Interpretación: Efecto parcial (*ceteris paribus*)

En regresión simple, $\hat{\beta}_1$ recogía **todo** el efecto que x tuviera sobre y , incluyendo el efecto de otras variables ocultas que estuvieran correlacionadas con x .

En regresión múltiple, la interpretación de $\hat{\beta}_j$ es mucho más refinada:

$\hat{\beta}_j$ mide el cambio estimado en y ante un incremento de una unidad en x_j , **manteniendo constantes** (*ceteris paribus*) todos los demás regresores incluidos en el modelo.

Una advertencia clave: $\hat{\beta}_1$ en un modelo simple casi **nunca** coincide con el $\hat{\beta}_1$ del modelo múltiple. Geométricamente: proyectar $\mathbf{y}$ sobre el plano entero $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \mathbf{x}_2)$ da una "sombra" distinta en el eje $\mathbf{x}_1$ que si proyectáramos **solo** sobre $\mathcal{L}(\mathbf{1}, \mathbf{x}_1)$.

Y por esta misma razón geométrica (los ejes $\mathbf{x}_1$ y $\mathbf{x}_2$ no son perpendiculares entre sí), **el R^2 del modelo múltiple no es la suma de los R^2 individuales.**

Interpretación: Efecto parcial (*ceteris paribus*)

Llegamos al concepto más importante de la regresión múltiple para el analista de datos empíricos: la interpretación del coeficiente como un **efecto parcial** o *ceteris paribus* (locución latina que significa "manteniendo el resto igual").

Supongamos que regresamos el precio de una casa sobre el número de habitaciones. En la regresión simple de la lección pasada obtuvimos un $\hat{\beta}_1$ grande y positivo. ¿Significa eso que construir un tabique para dividir una sala grande en dos cuartos pequeños dispara el precio de la casa? Probablemente no. Lo que ocurre es que las casas con más habitaciones suelen ser, además, **casas más grandes** en metros cuadrados. El coeficiente simple estaba mezclando (confundiendo) el efecto del número de habitaciones con el efecto del tamaño total de la casa.

Si corremos una regresión múltiple incluyendo tanto habitaciones ($\mathbf{x}_1$) como metros cuadrados ($\mathbf{x}_2$), obligamos a la matemática a aislar la contribución de cada vector. Ahora, $\hat{\beta}_1$ mide cómo cambia el precio al añadir una habitación **manteniendo fijos los metros cuadrados**. Como veremos en el laboratorio de la próxima sesión (con el ejemplo clásico de Ramanathan), esta separación puede hacer que el coeficiente de habitaciones se reduzca drásticamente, o incluso que se vuelva **negativo** (porque añadir cuartos sin aumentar el espacio real solo significa hacer cuartos más minúsculos).

¿Por qué cambian los coeficientes? Geométricamente, la sombra (proyección) de $\mathbf{y}$ sobre el plano generado por $\mathbf{1}, \mathbf{x}_1, \mathbf{x}_2$ arroja unas "coordenadas" $(\hat{\beta}_1, \hat{\beta}_2)$. Si quitamos el vector $\mathbf{x}_2$ y proyectamos **solo** sobre la recta de $\mathbf{x}_1$ (más la constante), la sombra es otra completamente distinta. Los coeficientes se mezclarían **solo si $\mathbf{x}_1$ y $\mathbf{x}_2$ fueran estrictamente ortogonales entre sí** (es decir, si tuvieran covarianza cero). Como en economía las variables casi siempre están correlacionadas (las casas grandes tienen más habitaciones), los ejes del hiperplano son oblicuos, y aislar un efecto requiere proyectar sobre el conjunto.

¿Por qué el R^2 no se suma? En la lección 8 sembramos un anticipo: el R^2 de un modelo múltiple no es la suma de los R^2 de las variables por separado. La razón geométrica es exactamente la misma. Como $\mathbf{x}_1$ y $\mathbf{x}_2$ son vectores oblicuos (correlacionados), la información que aportan se solapa. Sumar el poder explicativo de $\mathbf{x}_1$ y el de $\mathbf{x}_2$ implicaría contar la zona solapada dos veces. Solo podríamos sumar los R^2 si los regresores centrados fuesen vectores perfectamente perpendiculares entre sí.

(**Nota causal mantenida**): Aislar el efecto de los metros cuadrados frente a las habitaciones hace la lectura mucho más rica, pero la advertencia de la lección 9 ("El puente") se mantiene intacta. La matemática aísla variaciones parciales, pero no garantiza que estemos capturando un efecto verdaderamente causal si hay otros factores críticos ausentes en el modelo.

7 Familia ortogonal y Pitágoras generalizado

¿Qué pasaría si **todos** los regresores centrados fueran perfectamente ortogonales entre sí? (Tuvieran covarianza mutua cero).

En ese caso puramente teórico, formarían una **familia ortogonal**. El problema de regresión múltiple se "desacoplaría" por completo: cada coeficiente $\hat{\beta}_j$ sería exactamente igual al que obtendríamos en una regresión simple.

Y el **Teorema de Pitágoras** (lección 3), que decía que $\|\mathbf{a} + \mathbf{b}\|^2 = \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2$ si $\mathbf{a} \perp \mathbf{b}$, se

generalizaría a múltiples vectores: Si $\mathbf{v}_1, \dots, \mathbf{v}_k$ son mutuamente ortogonales:

$$\|\mathbf{v}_1 + \mathbf{v}_2 + \dots + \mathbf{v}_k\|^2 = \|\mathbf{v}_1\|^2 + \|\mathbf{v}_2\|^2 + \dots + \|\mathbf{v}_k\|^2$$

Solo en este escenario mágico el R^2 múltiple sería la suma exacta de los R^2 individuales. (Pero en economía, las variables casi siempre están entrelazadas).

Familia ortogonal y Pitágoras generalizado

En la lección 7 vimos un "atajo" alternativo para resolver la regresión simple: en lugar de usar $\mathbf{1}$ y $\mathbf{x}$ (que no eran ortogonales), cambiábamos los generadores del plano a $\mathbf{1}$ y $\mathbf{x} - \mu_{\mathbf{x}}\mathbf{1}$, que sí eran perpendiculares. Al tener generadores perpendiculares, el sistema de ecuaciones desaparecía y cada coeficiente se calculaba de forma independiente (proyectando la "sombra" solo sobre ese eje).

¿Podemos hacer lo mismo aquí? Si por casualidad nuestros regresores centrados $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$ tuvieran covarianza cero entre todos ellos (es decir, fueran todos perpendiculares formando lo que se llama una **familia ortogonal**), la matriz $\mathbf{X}^T \mathbf{X}$ se volvería maravillosamente sencilla (casi todos los elementos fuera de la diagonal principal serían ceros). En este escenario, el efecto de $\mathbf{x}_1$ no se mezclaría en absoluto con el de $\mathbf{x}_2$. El coeficiente $\hat{\beta}_1$ en el modelo múltiple sería **idéntico** al de la regresión simple.

En este caso, la descomposición de la varianza también se simplifica. El Teorema de Pitágoras que demostramos en la lección 3 para dos vectores se generaliza a cualquier número de vectores que sean mutuamente ortogonales. La suma de las varianzas explicadas por cada variable coincidiría perfectamente con la varianza explicada total.

Sin embargo, esto es casi una rareza de laboratorio. En los experimentos controlados de ciencias naturales, el investigador diseña las dosis para que sean ortogonales (ej. luz y agua en plantas). Pero en economía, los datos son observacionales. Las variables viajan juntas: la gente con más educación suele tener más experiencia, las casas grandes tienen más baños, etc. Por eso la regresión múltiple es indispensable: es la única forma de "desenredar" (desacoplar) efectos que la realidad nos entrega mezclados.

Para profundizar:

- Bujosa, M. *Curso de Álgebra Lineal*, cap. 11. Proyección ortogonal sobre subespacios generados por una familia ortogonal.

8 Modelo Poblacional y Propiedades (Adelanto)

Igual que en la lección 9, el modelo muestral $\mathbf{y} = \mathbf{X}\hat{\boldsymbol{\beta}} + \hat{\mathbf{e}}$ es solo una aproximación a un **Modelo Poblacional** con variables aleatorias. Con k regresores, el MCRL asume:

$$Y = \beta_0 1 + \beta_1 X_1 + \dots + \beta_k X_k + U$$

1. Linealidad: $E[Y | \mathbf{X}] = \beta_0 1 + \dots + \beta_k X_k$
2. Exogeneidad: $E[U | \mathbf{X}] = 0$
3. Homocedasticidad: $Var[U | \mathbf{X}] = \sigma^2 1$

Bajo estos supuestos, el estimador MCO $\hat{\beta}$ tiene propiedades teóricas excelentes. Adelantamos dos resultados clave:

1. **Insesgadez:** $E[\hat{\beta} | \mathbf{X}] = \beta$ (El estimador "acierta" en promedio).
2. **Varianza:** $Var[\hat{\beta} | \mathbf{X}] = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$

(Estas fórmulas se demostrarán con rigor en la lección 11, pero exclusivamente para el caso sencillo de un solo regresor).

Modelo Poblacional y Propiedades (Adelanto)

En la lección 9 ("El puente") establecimos la correspondencia entre los vectores observados de la muestra y el mecanismo abstracto que los generó (las variables aleatorias). Esa analogía se traslada íntegramente a la regresión múltiple.

El verdadero modelo subyacente que intentamos inferir asume que la esperanza condicional de Y (dado el conocimiento conjunto de todos los regresores) es un hiperplano poblacional perfecto. La perturbación U tiene esperanza cero y su varianza es constante (σ^2), independientemente de los valores de las variables X .

El vector $\hat{\beta}$ que obtenemos de resolver las ecuaciones normales en nuestra muestra es nuestro **estimador**. Como depende de los datos de la muestra, y los datos cambian si extraemos otra muestra, $\hat{\beta}$ es en realidad un vector de variables aleatorias.

La econometría teórica se ocupa de evaluar si $\hat{\beta}$ es un "buen" estimador. Adelantamos aquí dos conclusiones centrales que la matemática garantiza si se cumplen los supuestos del modelo:

1. **Insesgadez:** La esperanza de nuestro estimador es el verdadero parámetro. Si repitiéramos nuestro estudio con miles de muestras distintas, el promedio de todos nuestros cálculos de $\hat{\beta}_1$ convergería exactamente al verdadero efecto β_1 en la población.
2. **Varianza:** La incertidumbre (dispersión) de nuestro estimador alrededor de la verdad depende de dos cosas: del "ruido" intrínseco del universo (σ^2) y de la matriz $(\mathbf{X}^\top \mathbf{X})^{-1}$. Es decir, la precisión de nuestra estimación depende fuertemente de la correlación entre nuestros propios regresores. (Este será el tema central de la sesión 20, la Colinealidad).

Por el momento, tomamos estas fórmulas como un adelanto conceptual. En la lección 11 bajaremos estas ideas a tierra y las demostraremos paso a paso, volviendo por un momento a la comodidad de un solo regresor, para evitar el álgebra matricial engorrosa.

9 Recapitulación y guiño a la lección siguiente

- Al añadir regresores pasamos del plano a subespacios de mayor dimensión, pero **el principio geométrico es idéntico:** $\hat{e}$ es perpendicular a todos los regresores.
- Para comprimir los $k + 1$ sumatorios usamos la matriz $\mathbf{X}$. Las **Ecuaciones Normales** $(\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y})$ resuelven el sistema.
- El salto conceptual clave: $\hat{\beta}_j$ aísla el efecto de la variable x_j manteniendo fijos los demás regresores (**efecto parcial / ceteris paribus**).

- Los coeficientes y el R^2 del modelo simple no se suman por piezas, porque en economía los regresores casi siempre son oblicuos (están correlacionados entre sí).

Próxima sesión — Laboratorio Gretl: Estimaremos modelos múltiples con datos reales (precios de casas). Verificaremos empíricamente cómo el coeficiente de una variable puede cambiar radicalmente (incluso de signo) al incluir otras que estaban actuando como "variables ocultas" de confusión. Además, como "el R^2 nunca empeora al añadir regresores", introduciremos el R^2 ajustado para penalizar los modelos innecesariamente complejos.

Recapitulación y guiño a la lección siguiente

Esta lección marca la consolidación de la principal herramienta empírica de la econometría: la regresión lineal múltiple.

Hemos visto que el salto de uno a k regresores no requiere inventar una nueva matemática. La regla fundamental que fijamos en la lección 6 (la "sombra" siempre cae en perpendicular) sigue siendo suficiente para dictar las ecuaciones. Las matrices aparecieron aquí exclusivamente como un alivio tipográfico. Las Ecuaciones Normales, bajo esa apariencia sofisticada, no son más que la instrucción: "haz que el error no tenga correlación con nada de lo que he incluido en mi modelo".

Pero el verdadero salto cualitativo de hoy es interpretativo. Al pasar a múltiples dimensiones descubrimos el concepto de **ceteris paribus**. La regresión múltiple es la mejor aproximación de las ciencias sociales a un experimento de laboratorio: nos permite "congelar" variables matemáticamente cuando no podemos congelarlas físicamente.

La próxima sesión será puramente práctica. Iremos al software Gretl y pondremos a prueba esta teoría con datos de precios de viviendas (el famoso conjunto de datos de Ramanathan). Veremos con nuestros propios ojos cómo nuestra intuición puede engañarnos si usamos regresiones simples: analizaremos si tener más habitaciones realmente sube el precio de la casa, una vez que *aislamos* el efecto de los metros cuadrados totales.

Por último, en ese mismo laboratorio abordaremos una pequeña trampa matemática del R^2 . Como vimos en la lección 8, el R^2 es un coseno al cuadrado que premia la cercanía. Por una propiedad mecánica del álgebra lineal, al añadir **cualquier** variable al modelo (aunque sea la cantidad de lluvia en Marte), el ángulo de la sombra nunca puede aumentar; el R^2 solo puede quedarse igual o subir. Para evitar incluir variables inútiles solo por inflar esta métrica, el laboratorio introducirá el R^2 *ajustado*.

10 Pruebas

10.0.1 Propuesta de notación y expresiones (para tu validación)

1. El operador selector

- Columna j de la matriz: $\mathbf{X}_{|j} \Rightarrow \mathbf{X}_{|j}$
- Fila i de la matriz: $\{\}_{i|} \mathbf{X} \Rightarrow {}_i\mathbf{X}$
- Componente i de un vector: $\mathbf{a}_{|i}$ (o simplemente a_i)

2. Definición natural: Vector $\times$ Matriz Si agrupamos las condiciones de ortogonalidad (productos escalares del residuo por cada generador), definimos la operación $\hat{\mathbf{e}}\mathbf{X}$ de modo que su componente j -ésima sea exactamente ese producto escalar. Usando el selector, la definición queda muy limpia:

$$(\hat{\mathbf{e}}\mathbf{X})_{|j} = \hat{\mathbf{e}} \cdot \mathbf{X}_{|j}$$

Así, las condiciones de ortogonalidad se comprimen como $\hat{\mathbf{e}}\mathbf{X} = \mathbf{0}$.

3. Definición natural: Matriz $\times$ Vector Por otro lado, definimos $\mathbf{X}\hat{\boldsymbol{\beta}}$ como la *combinación lineal de las columnas* de $\mathbf{X}$ con los pesos $\hat{\beta}_j$:

$$\mathbf{X}\hat{\boldsymbol{\beta}} = \hat{\beta}_0\mathbf{X}_{|1} + \hat{\beta}_1\mathbf{X}_{|2} + \dots = \hat{\mathbf{y}}$$

4. La doble lectura y el papel de la transposición Aquí es donde entraría el ejemplo numérico que propones (p. ej., una matriz 3×2 y un vector de tamaño 2) para que los alumnos "vean" que la componente i -ésima de esa combinación lineal es, de hecho, el producto escalar de la fila i de la matriz por el vector $\hat{\boldsymbol{\beta}}$:

$$(\mathbf{X}\hat{\boldsymbol{\beta}})_{|i} = {}_i\mathbf{X} \cdot \hat{\boldsymbol{\beta}}$$

Y aquí entra la transposición de matrices (como operación que convierte filas en columnas, de modo que la fila i de $\mathbf{X}$ es la columna i de $\mathbf{X}^\top$):

$${}_i\mathbf{X} = (\mathbf{X}^\top)_{|i}$$

De esto se deduce inmediatamente que "vector $\times$ matriz" es lo mismo que "matriz transpuesta $\times$ vector": $\mathbf{e}\mathbf{X} = \mathbf{X}^\top \mathbf{e}$. Esto nos permite reescribir $\hat{\mathbf{e}}\mathbf{X} = \mathbf{0}$ como $\mathbf{X}^\top \hat{\mathbf{e}} = \mathbf{0}$, lo que abre la puerta directa a las Ecuaciones Normales:

$$\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0} \implies \mathbf{X}^\top \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$$

¿Qué te parece la estética de $\{\}_{|i}\boldsymbol{\beta}$ (${}_i\mathbf{X}$)? ¿Y ves bien esta secuencia lógica (1. vector por matriz como empaquetador de productos punto $\rightarrow$ 2. matriz por vector como combinación lineal $\rightarrow$ 3. ejemplo numérico que revela la doble lectura $\rightarrow$ 4. transposición $\rightarrow$ 5. Ecuaciones Normales) para estructurar el arranque de la sesión 13? Si estás de acuerdo, me pongo a redactar la lección completa siguiendo exactamente esta ruta.