

Índice general

1	De dónde venimos: del plano al hiperplano	2
2	La geometría es la misma	3
3	El problema aritmético: demasiadas ecuaciones	4
4	La matriz de datos y el operador selector	5
5	Vector por Matriz y las Condiciones de Ortogonalidad	6
6	Matriz por Vector (El Ajuste) y la Doble Lectura	7
7	Transposición	8
8	Ecuaciones normales	9
9	Familia ortogonal y Pitágoras generalizado	11
10	R^2 en regresión múltiple	12
11	Interpretación: Efecto parcial (<i>ceteris paribus</i>)	14
12	Recapitulación y guiño a la lección siguiente	15

Lección 10. Regresión múltiple: de dos ortogonalidades a $k + 1$

Marcos Bujosa

20 de agosto de 2026

Resumen

Generalizamos la regresión a cualquier número de regresores. La geometría sigue siendo idéntica (la ortogonalidad lo gobierna todo), pero el sistema de ecuaciones crece. Para no asfixiarnos en sumatorios, introducimos una notación matricial natural basada en un *operador selector*. Descubriremos que el álgebra de matrices es solo una compresión elegante de los productos escalares y las combinaciones lineales que ya conocemos, y exploraremos el concepto central de la regresión múltiple: el efecto parcial o *ceteris paribus*.

“Cuanto más regresores, mayor el espacio de búsqueda; la pregunta —¿qué punto del subespacio está más cerca de $\mathbf{y}$?— no cambia.”

- ([slides](#)) — ([html](#)) — ([pdf](#))

1 De dónde venimos: del plano al hiperplano

En la lección 6 proyectamos el vector de datos $\mathbf{y}$ sobre el *plano* generado por $\mathbf{1}$ y $\mathbf{x}$. La ortogonalidad del residuo frente a **todo el plano** se tradujo en **dos** condiciones (una por generador).

En economía rara vez un fenómeno depende de un solo factor $\mathbf{x}$. El precio de una casa no depende solo de los metros cuadrados; influyen su localización, el acceso los servicios públicos cercanos (transporte, comercios, colegios, etc), la contaminación, etc.

El paso natural: Añadir más regresores. Proyectaremos $\mathbf{y}$ sobre el subespacio generado por k regresores (además de la constante):

$$\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k)$$

El ajuste será una combinación lineal de todos ellos:

$$\hat{\mathbf{y}} = \hat{\beta}_0 \mathbf{1} + \hat{\beta}_1 \mathbf{x}_1 + \hat{\beta}_2 \mathbf{x}_2 + \dots + \hat{\beta}_k \mathbf{x}_k.$$

El subespacio ya no es una recta ni un plano; es un hiperplano multidimensional. Pero **la geometría es exactamente la misma**.

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

De dónde venimos: del plano al hiperplano

Hasta ahora hemos avanzado sumando dimensiones de una en una. En la lección 4 resolvimos la proyección más sencilla: buscar el vector más cercano a los datos $\mathbf{y}$ dentro de la recta $\mathcal{L}(\mathbf{1})$. Obtuvimos la media. En la lección 6 dimos un paso más: añadimos una segunda dirección, el regresor $\mathbf{x}$, y proyectamos sobre el plano $\mathcal{L}(\mathbf{1}, \mathbf{x})$. Obtuvimos la regresión lineal simple.

Hoy damos el salto definitivo. En la realidad empírica, un solo regresor casi nunca es suficiente. Si queremos explicar el salario de una persona, no basta con conocer sus años de educación ($\mathbf{x}_1$); necesitamos conocer su experiencia laboral ($\mathbf{x}_2$), su antigüedad en la empresa ($\mathbf{x}_3$), etc.

Geométricamente, esto equivale a añadir más “ejes” o vectores generadores a nuestro subespacio. Si tenemos k variables explicativas, más el vector constante de unos $\mathbf{1}$, el subespacio sobre el que proyectaremos será $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$. Este subespacio ya no es un plano bidimensional, sino lo que en geometría se denomina de manera genérica un *hiperplano* (un espacio de dimensión $k + 1$).

¿Qué cambia en nuestra manera de afrontar el problema? Conceptualmente, **absolutamente nada**. Seguimos buscando el vector $\hat{\mathbf{y}}$ (el ajuste) de ese subespacio que está más cerca de $\mathbf{y}$. Y, como sabemos desde la lección 3, ese punto de mínima distancia es la *proyección ortogonal*: el punto que garantiza que el vector de residuos $\hat{\mathbf{e}} = \mathbf{y} - \hat{\mathbf{y}}$ sea estrictamente perpendicular a todo el subespacio.

Para profundizar:

- Wooldridge, J. M. (2020), capítulo 3, sección 3.1: Motivación del modelo de regresión múltiple.
- Bujosa, M. *Curso de Álgebra Lineal*, [capítulo 13](#), sección “Proyecciones sobre subespacios”: [libro online](#).

2 La geometría es la misma

- $\hat{\mathbf{y}}$ sigue siendo la “sombra” de $\mathbf{y}$ sobre el subespacio de los regresores.
- $\hat{\mathbf{e}}$ sigue siendo **perpendicular a todas las direcciones** de dicho subespacio.

La geometría es la misma

Para ilustrar la regresión múltiple rescatamos la misma figura geométrica que ya usamos en la lección 8 (al demostrar $R^2 = \cos^2 \theta$). Esto no es un reciclaje por falta de imágenes, sino una decisión deliberada: en aquella lección fuimos muy cuidadosos de NO dibujar la componente $\hat{\beta}_1 \mathbf{x}$ individualmente dentro del plano (algo que sí hicimos en la lección 6). En la lección 8 dibujamos únicamente la proyección $\bar{\mathbf{y}}$ sobre los vectores constantes y la proyección $\hat{\mathbf{y}}$ sobre el subespacio formado por los regresores (que en aquel momento correspondía al plano engendrado por $\mathbf{1}$ y $\mathbf{x}$). Esa fue una decisión anticipada precisamente para esta transparencia: al no comprometerse con ningún regresor concreto, la figura sigue siendo una representación esquemática perfectamente válida cuando el subespacio pasa de tener dos direcciones a tener $k+1$. Lo único que ya no podríamos dibujar, si quisiéramos ser literales, son los $k+1$ ejes individuales $\mathcal{L}(\mathbf{x}_1), \dots, \mathcal{L}(\mathbf{x}_k)$ dentro del plano —pero la figura nunca pretendió mostrarlos, así que no hay nada que corregir en ella.

Esa abstracción nos permite ahora releer la misma figura para k regresores. El subespacio representado por el “suelo” de la figura ya no es un plano bidimensional, sino que representa




Figura 1: Proyección ortogonal de $\mathbf{y}$ sobre un subespacio (aquí representado esquemáticamente por el plano inferior), vista desde dos ángulos distintos. Es exactamente la misma figura de la regresión simple (lección 8), solo que ahora el plano inferior que forma el suelo de la figura no representa a $\mathcal{L}(\mathbf{1}, \mathbf{x})$, ahora representa a un subespacio vectorial mucho más grande: $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$ (como ya no es un plano, no lo podemos representar fielmente en la figura. Esta figura es solo un esquema mental; una representación abstracta, no una representación literal).

esquemáticamente el inmenso subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k)$ de $k + 1$ dimensiones.

Todo lo que dedujimos en la lección 8 respecto de esta figura sigue siendo cierto ahora:

1. El vector ajustado $\hat{\mathbf{y}}$ es la proyección ortogonal.
2. El residuo $\hat{\mathbf{e}}$ forma un ángulo de 90° con el subespacio entero.
3. El triángulo rectángulo formado por $\mathbf{y} - \bar{\mathbf{y}}$, $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ y $\hat{\mathbf{e}}$ sigue existiendo, lo que significa que el teorema de Pitágoras sigue funcionando: $\text{STC} = \text{SEC} + \text{SRC}$ ($\sigma_{\mathbf{y}}^2 = \sigma_{\hat{\mathbf{y}}}^2 + \sigma_{\hat{\mathbf{e}}}^2$) es igual de válido en la regresión múltiple.
4. El coeficiente de determinación se define exactamente igual: $R^2 = \cos^2 \theta$, donde θ sigue siendo el ángulo entre los vectores en desviaciones de los datos y de su ajuste.

Si la geometría es idéntica y todas las conclusiones teóricas se mantienen, ¿dónde está la dificultad de la regresión múltiple? En la aritmética. En la siguiente transparencia veremos qué pasa cuando intentamos escribir las condiciones de ortogonalidad a mano.

3 El problema aritmético: demasiadas ecuaciones

La exigencia de que $\hat{\mathbf{e}}$ sea ortogonal a TODO el subespacio implica que debe ser ortogonal a **cada uno de sus generadores**.

Tendremos $k + 1$ condiciones de ortogonalidad simultáneas:

$$\begin{aligned}\langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0 &\implies \frac{1}{n} \sum \hat{e}_i = 0 \\ \langle \hat{\mathbf{e}}, \mathbf{x}_1 \rangle_s = 0 &\implies \frac{1}{n} \sum x_{1i} \hat{e}_i = 0 \\ \langle \hat{\mathbf{e}}, \mathbf{x}_2 \rangle_s = 0 &\implies \frac{1}{n} \sum x_{2i} \hat{e}_i = 0 \\ &\dots \\ \langle \hat{\mathbf{e}}, \mathbf{x}_k \rangle_s = 0 &\implies \frac{1}{n} \sum x_{ki} \hat{e}_i = 0\end{aligned}$$

Recordando que $\hat{e}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \dots + \hat{\beta}_k x_{ki})$, solo queda encontrar los $k + 1$ parámetros $\hat{\beta}_j$ que satisfacen estas $k + 1$ condiciones.

Pero escribir y resolver este sistema con sumatorios es agotador. Necesitamos **comprimir** la notación.

El problema aritmético: demasiadas ecuaciones

En la lección 7 pudimos resolver el sistema de la regresión simple a mano porque solo teníamos dos ecuaciones ($\langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0$ y $\langle \hat{\mathbf{e}}, \mathbf{x} \rangle_s = 0$) y dos incógnitas ($\hat{\beta}_0, \hat{\beta}_1$). Despejamos en una, sustituimos en la otra, y llegamos al resultado.

Ahora tenemos $k + 1$ regresores (la constante y las k variables). Para que el residuo sea perpendicular a todo el hiperespacio, tiene que ser perpendicular a cada uno de sus ejes generadores. Esto nos arroja un sistema de $k + 1$ ecuaciones con $k + 1$ incógnitas ($\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k$).

Si intentamos sustituir $\hat{e}_i$ en cada ecuación y desarrollar los sumatorios, nos encontraremos con expresiones interminables. Despejar a mano un sistema de, por ejemplo, 5 regresores usando el símbolo $\sum$ es una pesadilla de subíndices cruzados.

No hay ningún concepto nuevo que descubrir aquí, solo un problema de notación: nuestra forma de escribir las cosas no está a la altura de la dimensión del problema. Para solucionarlo, vamos a introducir una herramienta matemática diseñada específicamente para agrupar vectores y hacer múltiples productos escalares de una sola vez: las **matrices**. Pero lo haremos usando una notación especial muy intuitiva.

4 La matriz de datos y el operador selector

En lugar de tener $k + 1$ vectores sueltos, los agrupamos como **columnas** en una matriz de datos **X**. Las matrices se escriben en palo seco negrita (**X**).

$$\mathbf{X} = [\mathbf{1}; \mathbf{x}_1; \dots; \mathbf{x}_k]$$

Para “navegar” por la matriz usaremos un **operador selector** (la barra vertical $|$):

- Actuando por la **derecha**, selecciona la **columna** j :

$$\mathbf{X}_{|j} \text{ es el } j\text{-ésimo regresor.}$$

- Actuando por la **izquierda**, selecciona la **fila** i :

${}_i\mathbf{X}$ son los datos del i -ésimo individuo.

El selector sobre un **vector**: siempre extrae su componente i -ésima:

$$\mathbf{v}_{|i} = {}_i\mathbf{v} = v_i$$

La matriz de datos y el operador selector

Para evitar hundirnos en un mar de sumatorios, vamos a agrupar todos nuestros regresores. Una matriz no es más que una tabla, una lista de vectores-columna del mismo tamaño puestos uno al lado del otro. Si agrupamos nuestra constante y todos nuestros regresores, construimos la matriz de diseño o matriz de datos $\mathbf{X}$. Las matrices las denotaremos siempre con letras mayúsculas de palo seco en negrita, para distinguirlas visualmente de los vectores.

Para operar con esta matriz de una forma que sea perfectamente coherente con todo lo que ya sabemos de vectores, vamos a introducir una notación especial basada en un **operador selector** (la barra vertical), que actúa como un índice inteligente. Esta notación no es la habitual en los manuales clásicos anglosajones (pero es la que se utiliza en el *Curso de Álgebra Lineal* que nos sirvió de referencia en las primeras lecciones del curso).

La mecánica es muy visual:

- Si el selector actúa sobre la matriz $\mathbf{X}$ por la **derecha** ($\mathbf{X}_{|j}$), la “corta” verticalmente. Nos devuelve la columna j -ésima (es decir, el vector que contiene todas las observaciones del regresor j).
- Si el selector actúa por la **izquierda** (${}_i\mathbf{X}$), la “corta” horizontalmente. Nos devuelve la fila i -ésima (es decir, el conjunto de características del individuo i).

¿Qué pasa si aplicamos este selector a un vector, que solo tiene una dimensión? La regla es muy simple: el selector extrae la componente i -ésima del vector, y **da igual por qué lado se aplique**. Tanto $\mathbf{v}_{|i}$ como ${}_i\mathbf{v}$ significan exactamente lo mismo: el número v_i .

Para profundizar:

- Bujosa, M. *Curso de Álgebra Lineal*, lecciones 1 a 3. Definición del operador selector y sus reglas. [libro online](#).

5 Vector por Matriz y las Condiciones de Ortogonalidad

Definiremos la operación **vector** $\times$ **matriz** ($\mathbf{vX}$) de forma que el resultado sea un nuevo vector, cuya componente j -ésima sea el **producto escalar** entre $\mathbf{v}$ y la columna j de la matriz:

$$(\mathbf{vX})_{|j} = \mathbf{v} \cdot \mathbf{X}_{|j}$$

Aplicando esto a nuestro problema, la enorme lista de $k + 1$ productos escalares $\hat{\mathbf{e}} \cdot \mathbf{x}_j = 0$ se comprime en una única y elegante ecuación:

$$\boxed{\hat{\mathbf{e}}\mathbf{X} = \mathbf{0}}$$

(donde $\mathbf{0}$ es el vector formado por $k + 1$ ceros), pues

$$\hat{\mathbf{e}}\mathbf{X} = \hat{\mathbf{e}}[1; \mathbf{x}_1; \dots; \mathbf{x}_k] = (\hat{\mathbf{e}} \cdot \mathbf{1}, \hat{\mathbf{e}} \cdot \mathbf{x}_1, \dots, \hat{\mathbf{e}} \cdot \mathbf{x}_k) = (0, 0, \dots, 0).$$

Simplificación de la notación: Como $(\mathbf{v}\mathbf{X})_{|j} = \mathbf{v} \cdot (\mathbf{X}_{|j})$, podemos **prescindir de los paréntesis y el punto** y escribir sencillamente $\mathbf{v}\mathbf{X}_{|j}$ para denotar ambas operaciones. Lo re-interpretamos como: “el selector sobre la matriz tiene precedencia sobre el producto”.

Vector por Matriz y las Condiciones de Ortogonalidad

Si recordamos la transparencia 3, nuestro problema aritmético consistía en que teníamos $k + 1$ ecuaciones de la forma $\hat{\mathbf{e}} \cdot \mathbf{x}_j = 0$. Necesitamos una operación que “empaquete” todos esos productos escalares de una sola vez.

Esa operación es precisamente el producto de un vector por una matriz. Lo definimos geométricamente: $\mathbf{v}\mathbf{X}$ da como resultado un vector, y su componente j -ésima se calcula haciendo el producto escalar del vector $\mathbf{v}$ contra la columna j -ésima de la matriz $\mathbf{X}$.

Gracias a esta operación, podemos agrupar la extenuante lista de sumatorios en la expresión más limpia de toda la econometría: $\hat{\mathbf{e}}\mathbf{X} = \mathbf{0}$. Esta ecuación nos dice, de un solo golpe de vista, que el vector de residuos es ortogonal a cada una de las columnas (regresores) de la matriz de diseño.

Para profundizar:

- Wooldridge, J. M. (2020), Apéndice E.1-E.2: la notación matricial de las ecuaciones normales en regresión múltiple.
- Bujosa, M. *Curso de Álgebra Lineal*, lección 2. Combinaciones lineales. [libro online](#).

6 Matriz por Vector (El Ajuste) y la Doble Lectura

Por otro lado, listamos los parámetros a estimar en un vector: $\hat{\boldsymbol{\beta}} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k)$.

Definiremos la operación **matriz $\times$ vector** ($\mathbf{X}\mathbf{b}$) como la **combinación lineal de las columnas** de la matriz $\mathbf{X}$, usando los elementos del vector $\mathbf{b}$ como ponderadores:

$$\mathbf{X}\hat{\boldsymbol{\beta}} = \hat{\beta}_0\mathbf{X}_{|1} + \hat{\beta}_1\mathbf{X}_{|2} + \dots + \hat{\beta}_k\mathbf{X}_{|k+1}$$

Pero esta combinación lineal de las columnas es, exactamente, la definición que dimos de nuestro vector de ajuste $\hat{\mathbf{y}}$ en la transparencia 1:

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$

¿Cuál es el valor ajustado para el individuo i ? Recordando que el operador por la izquierda selecciona la i -ésima componente del ajuste (y la precedencia del selector):

$${}_i\hat{\mathbf{y}} = {}_i\mathbf{X}\hat{\boldsymbol{\beta}} = {}_i\mathbf{X} \cdot \hat{\boldsymbol{\beta}}$$

El ajuste para un individuo es el producto punto de sus datos (la fila ${}_i\mathbf{X}$) por los parámetros ajustados $\hat{\boldsymbol{\beta}}$.

Matriz por Vector (El Ajuste) y la Doble Lectura

Ya hemos visto qué pasa cuando multiplicamos por la izquierda (vector por matriz). Ahora vamos a definir qué ocurre cuando multiplicamos por la derecha (matriz por vector).

Agrupamos todos nuestros coeficientes $\hat{\beta}_j$ en un único vector de parámetros $\hat{\beta}$.

Definiremos $\mathbf{X}\hat{\beta}$ de la manera más natural para nuestro marco de referencia: como una *combinación lineal* de las columnas. Es decir, tomamos cada columna de la matriz $\mathbf{X}$, la multiplicamos por su correspondiente coeficiente en el vector $\hat{\beta}$, y sumamos todo.

Si nos fijamos bien, esta suma ponderada de las columnas de $\mathbf{X}$ es literalmente la ecuación que define nuestro ajuste $\hat{\mathbf{y}}$. El vector $\hat{\mathbf{y}}$ pertenece al hiperplano generado por las columnas de $\mathbf{X}$, y $\hat{\beta}$ nos da las “coordenadas” de $\hat{\mathbf{y}}$ en ese hiperplano (nos dice cuánto avanzar o retroceder en la dirección de cada regresor para llegar al punto $\hat{\mathbf{y}}$).

A partir de ahora, cuando veamos la expresión $\mathbf{X}\hat{\beta}$, debemos leerla mentalmente como “la combinación lineal de los regresores” que queda más cerca del vector del vector $\mathbf{y}$ (del regresando).

Ahora sabemos que $\mathbf{X}\hat{\beta}$ es el vector con todos los valores ajustados $\hat{\mathbf{y}}$. Para seleccionar el ajuste correspondiente a un individuo i aplicaremos el operador selector por la izquierda: gracias a las reglas de nuestro operador selector (que tiene precedencia sobre el producto), ${}_i\mathbf{X}\hat{\beta}$ se evalúa como el producto escalar de la fila i -ésima de la matriz $\mathbf{X}$ por el vector $\hat{\beta}$, es decir ${}_i\mathbf{X} \cdot \hat{\beta}$. Esto arroja una **doble lectura** del producto *matriz por vector*: en su conjunto es una combinación lineal de columnas pero, “por dentro” (componente a componente) es un listado de productos punto de cada fila por el vector.

Para profundizar:

- Wooldridge, J. M. (2020), Apéndice E.1-E.2: la notación matricial de las ecuaciones normales en regresión múltiple.
- Bujosa, M. *Curso de Álgebra Lineal*, lección 2. Combinaciones lineales. [libro online](#).

7 Transposición

La **transposición** de una matriz ($\mathbf{X}^\top$) convierte sus filas en columnas (y viceversa). Su definición rigurosa usando el selector es:

$${}_i\mathbf{X} = (\mathbf{X}^\top)_{|i} \quad \left(\text{o equivalentemente} \quad \mathbf{X}_{|i} = {}_i(\mathbf{X}^\top) \right).$$

Por tanto, $\mathbf{v}\mathbf{X}$ y $\mathbf{X}^\top\mathbf{v}$ son **exactamente el mismo vector**:

$$(\mathbf{v}\mathbf{X})_{|i} = \mathbf{v} \cdot \mathbf{X}_{|i} = \mathbf{X}_{|i} \cdot \mathbf{v} = {}_i(\mathbf{X}^\top) \cdot \mathbf{v} = {}_i(\mathbf{X}^\top\mathbf{v})$$

Así, la condición de ortogonalidad $\hat{\mathbf{e}}\mathbf{X} = \mathbf{0}$ puede escribirse de forma equivalente como:

$$\boxed{\mathbf{X}^\top\hat{\mathbf{e}} = \mathbf{0}}$$

Transposición

Para poder conectar las operaciones por la derecha y por la izquierda, introducimos la **transposición de matrices**.¹ La definición es que la fila i de $\mathbf{X}$ es la columna i de su transpuesta $\mathbf{X}^\top$. En lenguaje de selectores: ${}_i\mathbf{X} = (\mathbf{X}^\top)_{|i}$.

Si cruzamos esta definición con lo que sabemos de los productos, llegamos a una identidad vital: multiplicar el vector $\mathbf{v}$ por la matriz $\mathbf{X}$ da el mismo resultado que multiplicar la matriz transpuesta $\mathbf{X}^\top$ por el vector $\mathbf{v}$. ¡Es el mismo vector!

Veámoslo: $(\mathbf{X}^\top)\mathbf{v}$ es la combinación lineal de las columnas de $\mathbf{X}^\top$ (las filas de $\mathbf{X}$), y también es el vector cuyas componentes son los productos punto de $\mathbf{v}$ con cada columna de $\mathbf{X}$ (cada fila de $\mathbf{X}^\top$); pero esa era la definición de $\mathbf{v}\mathbf{X}$. Por tanto $(\mathbf{X}^\top)\mathbf{v} = \mathbf{v}\mathbf{X}$.

Esto nos permite reescribir nuestra gran ecuación de ortogonalidad. Sabíamos que $\hat{\mathbf{e}}\mathbf{X} = \mathbf{0}$. Gracias a esta dualidad, podemos escribirla con toda legitimidad poniendo la matriz (transpuesta) al principio: $\mathbf{X}^\top\hat{\mathbf{e}} = \mathbf{0}$. Esta es la llave que abre la puerta a las Ecuaciones Normales.

De propina: ahora tenemos una nueva interpretación de la operación *vector por matriz*. Dado que $(\mathbf{X}^\top)\mathbf{v} = \mathbf{v}\mathbf{X}$ y dado que $(\mathbf{X}^\top)\mathbf{v}$ es la combinación lineal de las columnas de $\mathbf{X}^\top$ (que son las filas de $\mathbf{X}$), tenemos que $\mathbf{v}\mathbf{X}$ es la combinación lineal de las filas: la misma combinación lineal de los mismos vectores. Resumiendo, al igual que *matriz por vector* es una combinación lineal de columnas, *vector por matriz* es una combinación lineal de filas.

*(Para entender todos los ingredientes de las ecuaciones normales —que denotan de manera compacta las $k + 1$ condiciones de ortogonalidad de la transparencia 3— nos falta estudiar una última operación: el producto de matrices (tan solo haré unos breves comentarios en los apuntes desarrollados de la siguiente transparencia) y señalar una cuestión importante (que aquí no demostraré): todas estas operaciones (operador selector, matriz por vector, vector por matriz, transposición y producto de matrices) son **lineales**: la operación sobre una suma es la suma de las operaciones (propiedad distributiva respecto de la suma), y la operación es asociativa respecto del producto.²).*

Para profundizar:

- Wooldridge, J. M. (2020), Apéndice E.1-E.2: la notación matricial de las ecuaciones normales en regresión múltiple.
- Bujosa, M. *Curso de Álgebra Lineal*, lecciones 1 a 3. [libro online](#).

8 Ecuaciones normales

Sustituyendo $\hat{\mathbf{e}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}$ en $\mathbf{X}^\top\hat{\mathbf{e}} = \mathbf{0}$:

$$\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0} \implies \boxed{\mathbf{X}^\top\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^\top\mathbf{y}.}$$

¹A diferencia de otros textos donde se transponen vectores (como si un vector pudiera estar de pie o tumbado), aquí somos fieles a la geometría: los vectores son listas de números (listas de coordenadas), punto. Lo único que se transpone (se reordena) son las tablas, las matrices.

²Para ver en detalle el producto de matrices y la demostración de linealidad para cada una de las operaciones puede consultar el manual [Un Curso de Álgebra Lineal](#).

Aquí aparece (por primera y última vez en el curso) un producto de matrices: $\mathbf{X}^\top \mathbf{X}$; baste saber que es otra matriz.

La expresión del recuadro es el sistema de *ecuaciones normales*.

Cuando los $k+1$ regresores son linealmente independientes, este sistema tiene una única solución, cuya expresión matricial es:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

No se preocupe por la expresión, los ordenadores saben calcularla. Lo importante es que dicha solución garantiza que $\mathbf{X}^\top \hat{\mathbf{e}} = \mathbf{0}$; es decir, que al usar $\hat{\beta}$ para calcular $\hat{\mathbf{y}} = \mathbf{X} \hat{\beta}$, obtenemos la combinación lineal de los regresores más cercana a $\mathbf{y}$.

Ecuaciones normales

La transparencia anterior nos dejó las $k+1$ condiciones de ortogonalidad comprimidas en $\mathbf{X}^\top \hat{\mathbf{e}} = \mathbf{0}$. Resolver este sistema para obtener $\hat{\beta}$ es puramente algebraico: sustituimos la definición del residuo, $\hat{\mathbf{e}} = \mathbf{y} - \mathbf{X} \hat{\beta}$, y distribuimos la matriz traspuesta:

$$\mathbf{X}^\top \mathbf{y} - \mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{0} \implies \mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}.$$

A este sistema de $k+1$ ecuaciones lineales con $k+1$ incógnitas se le llama, tradicionalmente, *ecuaciones normales* (el nombre viene de que expresan condiciones de ortogonalidad, es decir, de perpendicularidad o “normalidad” geométrica, no de la distribución normal de probabilidad).

Aquí aparece, por primera y única vez en todo el curso, un *producto matriz-matriz*: $\mathbf{X}^\top \mathbf{X}$, una matriz cuadrada de $(k+1) \times (k+1)$. No vamos a desarrollar ninguna teoría general sobre productos de matrices; nos basta con saber que su elemento (i, j) es un producto escalar del espacio euclídeo: el producto entre la columna i -ésima y la columna j -ésima de $\mathbf{X}$ —es decir, entre regresores—. Por ejemplo, el elemento $(1, 1)$ (fila y columna constantes $\mathbf{1}$) es $\langle \mathbf{1}, \mathbf{1} \rangle_e = n$; el elemento que cruza $\mathbf{1}$ con $\mathbf{x}_j$ es $\langle \mathbf{1}, \mathbf{x}_j \rangle_e = n\mu_{x_j}$ (recordando la lección 4); y el elemento que cruza $\mathbf{x}_i$ con $\mathbf{x}_j$ es $\langle \mathbf{x}_i, \mathbf{x}_j \rangle_e$. Es decir: toda la matriz $\mathbf{X}^\top \mathbf{X}$ está construida, literalmente, con los mismos productos escalares que ya sabíamos calcular desde la lección 2; la novedad es solo organizarlos en una tabla.

Si los $k+1$ regresores $\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k$ son linealmente independientes (si ninguno es combinación lineal de los demás), puede probarse —sin que nosotros lo hagamos aquí, pues excede el alcance del curso— que la matriz $\mathbf{X}^\top \mathbf{X}$ es *invertible*, y que el sistema de ecuaciones normales tiene una única solución:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Esta es la fórmula que aparece en la práctica totalidad de los manuales de econometría, y es también, de hecho, la que Gretl (y cualquier otro software estadístico) utiliza internamente para calcular una regresión múltiple. Aquí la mencionamos por completitud —conviene saber que existe, y saber reconocerla si la veis en un libro—, pero *no* vamos a usarla como herramienta de razonamiento en este curso: no vamos a calcular inversas de matrices a mano, ni vamos a apoyarnos en propiedades de la inversa para demostrar nada. El camino conceptual que nos interesa —y que reaparecerá en la lección 15 al demostrar propiedades del estimador— sigue siendo, siempre, la condición de ortogonalidad $\mathbf{X}^\top \hat{\mathbf{e}} = \mathbf{0}$, no la fórmula con inversa.

Vale la pena señalar, para cerrar, que la existencia de una única solución para las ecuaciones normales es precisamente lo que falla cuando los regresores no son linealmente independientes: en tal caso $\mathbf{X}^\top \mathbf{X}$ no es invertible (*colinealidad exacta*) y el sistema de ecuaciones normales deja de tener una solución única. En la lección 14 veremos un problema distinto: la *colinealidad de grado*, una situación en la que el sistema de ecuaciones normales tiene solución única, pero extremadamente sensible a pequeños cambios en los datos (algo que acarrea un grave problema en la interpretación de resultados). Ocurre cuando algunos regresores están casi alineados.

La siguiente transparencia se ocupa de la situación contraria: cuando los regresores son perpendiculares entre sí.

Para profundizar:

- Wooldridge, J. M. (2020), Apéndice E: derivación matricial completa de las ecuaciones normales y condiciones de existencia de la inversa.

9 Familia ortogonal y Pitágoras generalizado

Recordemos (lección 3, Cauchy–Schwarz) la fórmula de proyección sobre *un* generador: $\alpha = \langle \mathbf{b}, \mathbf{a} \rangle / \langle \mathbf{a}, \mathbf{a} \rangle$. Y (lección 7) la “vía alternativa” con *dos* generadores ortogonales.

Si $\{\mathbf{1}, \mathbf{v}_1, \dots, \mathbf{v}_k\}$ son *mutuamente ortogonales* (así que como $\mathbf{1} \perp \mathbf{v}_j \Rightarrow \mu_{v_j} = 0$), cada coeficiente se calcula *por separado*, sin resolver ningún sistema:

$$\hat{\beta}_0 = \mu_{\mathbf{y}}, \quad \hat{\beta}_j = \frac{\langle \mathbf{y}, \mathbf{v}_j \rangle_s}{\langle \mathbf{v}_j, \mathbf{v}_j \rangle_s} = \frac{\sigma_{\mathbf{y}, \mathbf{v}_j}}{\sigma_{\mathbf{v}_j}^2} \quad (j = 1, \dots, k).$$

Y Pitágoras se extiende a $k + 2$ términos:

$$\|\mathbf{y}\|_s^2 = \mu_{\mathbf{y}}^2 + \|\hat{\beta}_1 \mathbf{v}_1\|_s^2 + \dots + \|\hat{\beta}_k \mathbf{v}_k\|_s^2 + \|\hat{\mathbf{e}}\|_s^2.$$

Este caso, tan extraordinario, es la excepción: con datos económicos reales, los regresores nunca son ortogonales entre sí. El caso general exige resolver las ecuaciones normales de la transparencia anterior.

Familia ortogonal y Pitágoras generalizado

Esta transparencia cobra una promesa muy antigua, sembrada en la lección 3 al demostrar Cauchy–Schwarz: allí construimos $\mathbf{h} = \mathbf{b} - \alpha \mathbf{a}$, con $\alpha = \langle \mathbf{a}, \mathbf{b} \rangle / \langle \mathbf{a}, \mathbf{a} \rangle$, y dijimos que ese $\alpha \mathbf{a}$ era la “sombra” de $\mathbf{b}$ sobre la dirección de $\mathbf{a}$ —la *proyección ortogonal*. En la lección 7 usamos esa misma fórmula, con *dos* regresores ortogonales ($\mathbf{1}$ y $\mathbf{x} - \mu_{\mathbf{x}} \mathbf{1}$), para obtener $\hat{\beta}_1$ sin resolver ningún sistema: la llamamos, entonces, “vía alternativa”.

Generalicemos esa vía alternativa a k generadores. Supongamos que, además de $\mathbf{1}$, disponemos de k vectores $\mathbf{v}_1, \dots, \mathbf{v}_k$ que son *mutuamente ortogonales entre sí* y, además, ortogonales a $\mathbf{1}$ (es decir, todos ellos de media cero). En ese caso —y *solo* en ese caso—, la proyección de $\mathbf{y}$ sobre $\mathcal{L}(\mathbf{1}, \mathbf{v}_1, \dots, \mathbf{v}_k)$ se descompone en $k + 1$ proyecciones *independientes*, cada una calculada con la misma fórmula de Cauchy–Schwarz de la lección 3, aplicada por separado a cada generador:

$$\hat{\beta}_0 = \frac{\langle \mathbf{y}, \mathbf{1} \rangle}{\langle \mathbf{1}, \mathbf{1} \rangle} = \mu_{\mathbf{y}}, \quad \hat{\beta}_j = \frac{\langle \mathbf{y}, \mathbf{v}_j \rangle_s}{\langle \mathbf{v}_j, \mathbf{v}_j \rangle_s} = \frac{\sigma_{\mathbf{y}, \mathbf{v}_j}}{\sigma_{\mathbf{v}_j}^2} \quad (j = 1, \dots, k),$$

(donde $\langle \mathbf{y}, \mathbf{v}_j \rangle_s = \sigma_{\mathbf{y}, \mathbf{v}_j}$ y $\langle \mathbf{v}_j, \mathbf{v}_j \rangle_s = \sigma_{\mathbf{v}_j}^2$ por tener $\mathbf{v}_j$ media cero). Por tanto, en este caso tan especial, no hace falta resolver ningún sistema de ecuaciones normales: cada coeficiente se calcula de forma completamente aislada, exactamente como ocurría con dos generadores ortogonales que vimos en la lección 7.

Esta ortogonalidad mutua tiene, además, una consecuencia sobre la descomposición de la varianza. El teorema de Pitágoras (lección 3) se enunció para *dos* vectores ortogonales, pero se extiende, sin ninguna dificultad adicional, a *varios* vectores mutuamente ortogonales: si $\mathbf{w}_0, \mathbf{w}_1, \dots, \mathbf{w}_m$ son ortogonales dos a dos, entonces $\|\mathbf{w}_0 + \mathbf{w}_1 + \dots + \mathbf{w}_m\|^2 = \|\mathbf{w}_0\|^2 + \|\mathbf{w}_1\|^2 + \dots + \|\mathbf{w}_m\|^2$ (basta aplicar el caso de dos vectores repetidamente, agrupando de dos en dos). Aplicado a nuestra descomposición $\mathbf{y} = \mu_{\mathbf{y}}\mathbf{1} + \hat{\beta}_1\mathbf{v}_1 + \dots + \hat{\beta}_k\mathbf{v}_k + \hat{\mathbf{e}}$ (donde los $k + 2$ sumandos son mutuamente ortogonales, por construcción):

$$\|\mathbf{y}\|_s^2 = \mu_{\mathbf{y}}^2 + \|\hat{\beta}_1\mathbf{v}_1\|_s^2 + \dots + \|\hat{\beta}_k\mathbf{v}_k\|_s^2 + \|\hat{\mathbf{e}}\|_s^2.$$

Conviene cerrar esta transparencia con una advertencia importante, que prepara el terreno para la siguiente. Este escenario —regresores mutuamente ortogonales— es cómodo computacionalmente, pero es la *excepción*, no la norma. Con datos económicos reales, los regresores casi siempre están correlacionados entre sí en alguna medida (por ejemplo, la antigüedad y la experiencia de un trabajador) y no suelen tener media cero. Cuando los regresores no son mutuamente ortogonales, no hay atajo: hay que resolver el sistema completo de ecuaciones normales de la transparencia anterior.

Para profundizar:

- Strang, G. (2016), cap. 4, sección 4.4: ortogonalización de Gram-Schmidt (mención, sin desarrollar en este curso).

10 R^2 en regresión múltiple

Como $\langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0$ sigue siendo una de las $k + 1$ condiciones: $\mu_{\mathbf{y}} = \mu_{\hat{\mathbf{y}}}$ (lección 7) y $\text{STC} = \text{SEC} + \text{SRC}$ (lección 8) *siguen valiendo exactamente igual*, sin importar k .

Pero (cobramos la pregunta 5 de la práctica de regresión simple): en general,

$$R^2 \neq \rho_{x_1 y}^2 + \dots + \rho_{x_k y}^2.$$

¿Por qué? En la lección 8, $R^2 = \rho_{x y}^2$ porque el subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}) \cap \mathcal{L}(\mathbf{1})^\perp$ tenía *una sola* dirección: cualquier vector centrado del plano estaba alineado con $\mathbf{x} - \mu_{\mathbf{x}}\mathbf{1}$.

Con $k > 1$ regresores, ese mismo subespacio centrado tiene k *direcciones* (transparencia 2): $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ ya no está, en general, alineado con ningún $\mathbf{x}_j - \mu_{x_j}\mathbf{1}$ en particular.

Excepción (transparencia anterior): si los regresores son mutuamente ortogonales, entonces sí, $R^2 = \rho_{x_1 y}^2 + \dots + \rho_{x_k y}^2$ exactamente — Pitágoras generalizado, dividido por $\sigma_{\mathbf{y}}^2$.

R^2 en regresión múltiple

Podemos ahora responder, con precisión geométrica, a la pregunta que dejamos abierta al comienzo de la sesión: ¿por qué el R^2 de un modelo con dos (o más) regresores no es la suma de los R^2 de los modelos simples correspondientes?

Primero, lo que *sí* se conserva sin cambio alguno. La condición $\langle \hat{\mathbf{e}}, \mathbf{1} \rangle_s = 0$ sigue siendo una de nuestras $k+1$ condiciones de ortogonalidad, exactamente igual que en la lección 6-7 (allí era una de dos; aquí, una de $k+1$). De ella se deduce, sin ningún cambio en el argumento, que $\mu_{\mathbf{y}} = \mu_{\hat{\mathbf{y}}}$ (lección 7). Y como $\hat{\mathbf{y}} \perp \hat{\mathbf{e}}$ sigue siendo cierto (el residuo es ortogonal a *todo* el subespacio, en particular al propio ajuste, que pertenece a él), el mismo triángulo rectángulo de la lección 8 —hipotenusa $\mathbf{y} - \bar{\mathbf{y}}$, catetos $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ y $\hat{\mathbf{e}}$ — sigue siendo válido, sea cual sea k . Por tanto, $\text{STC} = \text{SEC} + \text{SRC}$ y $R^2 = \text{SEC}/\text{STC} = \cos^2 \theta$ (con θ el ángulo entre $\mathbf{y} - \bar{\mathbf{y}}$ y $\hat{\mathbf{y}} - \bar{\mathbf{y}}$) se mantienen, sin necesidad de ninguna demostración nueva: son consecuencia, otra vez, de las mismas dos piezas (ortogonalidad y Pitágoras), que no dependen del número de regresores.

Lo que *deja de valer*, en cambio, es la identidad exclusiva de la regresión simple, $R^2 = \rho_{xy}^2$. Recordemos por qué era cierta allí: en la lección 8 demostramos que, en $\mathcal{L}(\mathbf{1}, \mathbf{x})$, *todo* vector no constante, una vez centrado, cae en la misma recta $\mathcal{L}(\mathbf{x} - \mu_{\mathbf{x}}\mathbf{1})$ —porque ese subespacio centrado tenía una única dirección—. Eso obligaba a $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ a estar alineado con $\mathbf{x} - \mu_{\mathbf{x}}\mathbf{1}$, y de ahí salía $\rho_{y\hat{y}} = |\rho_{xy}|$.

Con $k > 1$ regresores, el subespacio centrado $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_k) \cap \mathcal{L}(\mathbf{1})^\perp$ tiene, en general, k direcciones distintas (transparencia 2), no una sola. El vector $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ es, ahora, una combinación de los k vectores centrados $\mathbf{x}_1 - \mu_{x_1}\mathbf{1}, \dots, \mathbf{x}_k - \mu_{x_k}\mathbf{1}$, y ya no tiene por qué estar alineado con ninguno de ellos en particular. Por eso R^2 , aunque sigue siendo $\cos^2 \theta$, ya no coincide, en general, con el cuadrado de ninguna correlación simple $\rho_{x_j y}$ —y, con más razón todavía, tampoco con la suma de esos cuadrados.

Hay, sin embargo, una excepción exacta, y es precisamente el caso especial de la transparencia anterior. Si los regresores centrados $\mathbf{x}_1 - \mu_{x_1}\mathbf{1}, \dots, \mathbf{x}_k - \mu_{x_k}\mathbf{1}$ son *mutuamente ortogonales*, el Pitágoras generalizado nos da

$$\sigma_{\mathbf{y}}^2 = \sigma_{\hat{\mathbf{y}}}^2 + \sigma_{\hat{\mathbf{e}}}^2, \quad \sigma_{\hat{\mathbf{y}}}^2 = \|\hat{\beta}_1(\mathbf{x}_1 - \mu_{x_1}\mathbf{1})\|_s^2 + \dots + \|\hat{\beta}_k(\mathbf{x}_k - \mu_{x_k}\mathbf{1})\|_s^2,$$

y cada uno de esos sumandos, dividido por $\sigma_{\mathbf{y}}^2$, resulta ser exactamente $\rho_{x_j y}^2$ (por el mismo argumento de la lección 8, aplicado a cada dirección por separado, ya que ahora sí están alineadas cada una con su propio regresor). En ese caso muy particular, y solo en él,

$$R^2 = \rho_{x_1 y}^2 + \dots + \rho_{x_k y}^2.$$

Pero, como ya señalamos, la ortogonalidad mutua entre regresores económicos reales es la excepción, no la norma —lo comprobaremos en la práctica que sigue a esta lección, con `rooms` y `=nox=`—.

Para profundizar:

- Wooldridge, J. M. (2020), cap. 3, sección 3.2: por qué el R^2 de la regresión múltiple no se descompone, en general, en las correlaciones simples con cada regresor.

11 Interpretación: Efecto parcial (*ceteris paribus*)

En regresión simple, $\hat{\beta}_1$ recogía el efecto que $\mathbf{x}$ tuviera sobre $\mathbf{y}$, junto con el efecto de variables ausentes en el ajuste, pero correladas con $\mathbf{x}$.

En regresión múltiple, la interpretación de $\hat{\beta}_j$ es mucho más refinada:

$\hat{\beta}_j$ mide el cambio estimado en $\mathbf{y}$ ante un incremento de una unidad en el regresor j , **manteniendo constantes** (*ceteris paribus*) los demás regresores incluidos en el modelo.

Advertencia clave: $\hat{\beta}_1$ en la regresión simple casi **nunca** coincide con el $\hat{\beta}_1$ en la múltiple. Geométricamente: proyectar $\mathbf{y}$ sobre el hiperplano $\mathcal{L}(\mathbf{1}, \mathbf{x}_1, \mathbf{x}_2)$ da una “sombra” distinta en el eje $\mathbf{x}_1$ que si proyectáramos **solo** sobre $\mathcal{L}(\mathbf{1}, \mathbf{x}_1)$.

¿Cuándo coincidirán? Solo si $\mathbf{x}_1$ y $\mathbf{x}_2$ (con media nula) fueran ortogonales entre sí (es decir, si tuvieran covarianza cero). En ese raro caso formarían una **familia ortogonal** y sus efectos no colisionarían.

Y por esta misma razón geométrica (los ejes $\mathbf{x}_1$ y $\mathbf{x}_2$ no suelen ser perpendiculares), **el R^2 del modelo múltiple no es la suma de los R^2 de modelos parciales.**

Interpretación: Efecto parcial (*ceteris paribus*)

Llegamos al concepto más importante de la regresión múltiple para el analista de datos empíricos: la interpretación del coeficiente como un **efecto parcial** o *ceteris paribus* (locución latina que significa “manteniendo el resto igual”).

Supongamos que regresamos el precio de una casa sobre el número de habitaciones. En la regresión simple de lecciones pasadas obtuvimos un $\hat{\beta}_1$ grande y positivo. ¿Significa eso que construir un tabique para dividir una sala grande en dos cuartos pequeños dispara el precio de la casa? Evidentemente no. Lo que ocurre es que las casas con más habitaciones suelen ser, además, **casas más grandes** en metros cuadrados. El coeficiente simple estaba mezclando (confundiendo) el efecto del número de habitaciones con el efecto del tamaño total de la casa, precisamente porque ambas variables tienen una covarianza positiva.

Si corremos una regresión múltiple incluyendo tanto habitaciones ($\mathbf{x}_1$) como metros cuadrados ($\mathbf{x}_2$), obligamos a la matemática a aislar la contribución de cada vector. Ahora, $\hat{\beta}_1$ mide cómo cambia el precio al añadir una habitación **manteniendo fijos los metros cuadrados** (condición *ceteris paribus*). Como veremos en el laboratorio de la próxima sesión, esta separación matemática suele provocar que el coeficiente de habitaciones se vuelva **negativo**: añadir cuartos sin aumentar el espacio real solo significa hacer cuartos más minúsculos, lo que deprecia la vivienda.

¿Por qué cambian los coeficientes y por qué el R^2 no se suma? Geométricamente, la sombra (proyección) de $\mathbf{y}$ sobre el plano generado por $\mathbf{1}, \mathbf{x}_1, \mathbf{x}_2$ arroja unas coordenadas conjuntas $(\hat{\beta}_1, \hat{\beta}_2)$. Si quitamos el vector $\mathbf{x}_2$ y proyectamos **solo** sobre $\mathbf{x}_1$, la sombra cambia por completo de posición para compensar la ausencia del otro vector.

¿Cuándo se mantendrían idénticos los coeficientes? Única y exclusivamente si los regresores (una vez centrados) fueran perfectamente perpendiculares entre sí, formando lo que en álgebra se llama una **familia ortogonal**. Si su covarianza mutua fuera cero, el sistema se “desacoplaría”, el efecto

de uno no se mezclaría en absoluto con el del otro, y el R^2 total sería la suma exacta de los R^2 de las regresiones individuales. Pero en economía observacional, las variables (como la renta y el nivel de estudios) casi siempre viajan juntas, haciéndolas vectores oblicuos. Por eso la regresión múltiple es indispensable: es la única forma de “desenredar” matemáticamente efectos que la realidad nos entrega mezclados.

(Nota causal mantenida): Aislar el efecto de los metros cuadrados frente a las habitaciones hace la lectura estadística infinitamente más rica, pero la advertencia causal de la lección 9 (“El puente”) se mantiene intacta. La matemática aísla variaciones parciales de las variables *que hemos introducido en la matriz*, pero no garantiza que estemos capturando un efecto verdaderamente causal si aún existen otras variables clave omitidas en la realidad poblacional.

12 Recapitulación y guiño a la lección siguiente

- Al añadir regresores pasamos del plano a subespacios de mayor dimensión, pero **el principio geométrico es idéntico**: el residuo $\hat{e}$ es perpendicular a todos y cada uno de los regresores.
- Para comprimir la notación usamos la matriz $\mathbf{X}$ y el operador selector. Definimos operaciones apoyadas en la geometría (productos escalares y combinaciones lineales), evitando reglas algorítmicas sin sentido.
- Las **Ecuaciones Normales** ($\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}$) concentran en una línea todo el sistema de proyecciones.
- El salto conceptual clave: $\hat{\beta}_j$ aísla el efecto de la variable $\mathbf{x}_j$ manteniendo fijos los demás regresores (**efecto parcial / ceteris paribus**).
- Como los regresores en economía no son ortogonales entre sí, los coeficientes simples cambian al incluir variables, y el R^2 no es la suma de sus partes.

Próxima sesión — Laboratorio Gretl: Estimaremos modelos múltiples con datos reales (precios de casas). Verificaremos empíricamente cómo nuestra intuición puede ser destruida por el efecto *ceteris paribus* (el coeficiente de habitaciones volviéndose negativo). Además, como “el R^2 nunca empeora al añadir regresores”, introduciremos el **R-cuadrado ajustado** para penalizar modelos innecesariamente complejos.

Recapitulación y guiño a la lección siguiente

Esta lección marca la consolidación de la principal herramienta empírica de la econometría: la regresión lineal múltiple.

Hemos visto que el salto de uno a k regresores no requiere inventar una nueva matemática. La regla fundamental que fijamos en la lección 6 (la “sombra” siempre cae en perpendicular) sigue siendo suficiente para dictar las ecuaciones. Las matrices aparecieron aquí exclusivamente como un elegante alivio tipográfico. Las Ecuaciones Normales, bajo esa apariencia sofisticada, no son más que la instrucción matemática: “haz que el error no tenga correlación con ninguna de las variables que he incluido en mi modelo”.

Pero el verdadero salto cualitativo de hoy es interpretativo. Al pasar a múltiples dimensiones

descubrimos el concepto de **ceteris paribus**. La regresión múltiple es la mejor aproximación de las ciencias sociales observacionales a un experimento de laboratorio: nos permite “congelar” variables matemáticamente cuando no podemos congelarlas físicamente en el mundo real.

La próxima sesión será puramente práctica. Iremos al software Gretl y pondremos a prueba esta teoría con datos reales de viviendas. Veremos con nuestros propios ojos cómo nuestra intuición puede engañarnos si usamos regresiones simples: analizaremos si tener más habitaciones realmente sube el precio de la casa, una vez que *aíslamos* el efecto de los metros cuadrados totales. El resultado nos forzará a respetar la diferencia entre efecto simple y efecto parcial.

Por último, en ese mismo laboratorio abordaremos una pequeña trampa matemática del R^2 . Como vimos en la lección 8, el R^2 es un coseno al cuadrado que premia la cercanía. Por una propiedad mecánica del álgebra lineal (la distancia a un subespacio nunca puede ser mayor que la distancia a un subespacio más pequeño contenido en él), al añadir **cualquier** variable al modelo, el ángulo de la sombra nunca puede aumentar; el R^2 solo puede quedarse igual o subir. Para evitar la tentación de incluir variables inútiles solo para inflar esta métrica, el laboratorio introducirá una medida correctora: el R^2 *ajustado*.