Índice general

1 De dónde venimos: nos falta la forma **2**

2 El supuesto nuevo: normalidad **4**

3 El error estándar, y el precio de estimar σ **7**

4 Un contraste que ya puede hacer: la media **9**

5 El contraste t **11**

6 Lectura geométrica: la razón de catetos **13**

7 Por qué el valor crítico depende de $n - k$ **15**

8 El intervalo de confianza **19**

9 Cómo se lee una tabla de resultados **21**

10 Significación estadística $\neq$ relevancia económica **24**

11 Recapitulación y guiño a las sesiones siguientes **27**

Lección 12. Inferencia: error estándar, intervalo de confianza y contraste t

Marcos Bujosa

4 de noviembre de 2026

Resumen

La lección 11 dejó a $\hat{\beta}_2$ bien centrado y con una varianza conocida, pero le faltaba lo esencial para contrastar hipótesis: la *forma* de su distribución. Hoy la obtenemos suponiendo normalidad de la perturbación.

Con ella construimos el error estándar, el intervalo de confianza y el contraste t, que no mide nada que el R^2 no midiera ya, y aprendemos a *leer* una tabla de resultados.

"Significativo" no quiere decir "grande", ni "importante", ni "verdadero".

- (slides) — (html) — (pdf)

1 De dónde venimos: nos falta la forma

De la lección 11 nos traemos dos resultados sobre el modelo lineal simple ($k = 2$: la constante *1* y un único regresor no constante X):

$$\mathrm{E}(\hat{\beta}_2) = \beta_2, \qquad Var[\hat{\beta}_2 \mid \boldsymbol{X}] = \frac{\sigma^2}{\sum_i (X_i - \overline{X})^2} = \frac{\sigma^2}{nS^2}.$$

Y nos traemos también una limitación que la lección 11 dejó enunciada: eso *no basta* para responder a

- si β_2 valiese cero, ¿serían datos como estos demasiado raros?
- ¿en qué rango de valores puedo confiar razonablemente que está β_2?

Saber dónde está centrada una distribución y cuánto se dispersa no permite responder a esas preguntas: necesitamos la **forma** de la distribución de probabilidad.

Hoy: un supuesto nuevo, tres herramientas (error estándar, intervalo, contraste) y, sobre todo, aprender a *leerlas*.

Esta obra está bajo una licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional (CC BY-SA 4.0).

De dónde venimos: nos falta la forma

La lección 11 terminó reconociendo un límite. Allí demostramos que $\hat{\beta}_2$ está bien centrado en β_2 (insesgadez) y calculamos cuánto se dispersa alrededor de ese centro ($Var[\hat{\beta}_2 \mid \boldsymbol{X}]$). Con esas dos cantidades sabemos mucho, pero desconocemos aquello que permite hacer *inferencia*: cuánta probabilidad acumula la distribución de $\hat{\beta}_2$ a partir de un valor dado.

Un ejemplo elemental lo deja claro. Imagine dos variables aleatorias con la misma esperanza, 0, y la misma varianza, 1. La primera es normal estándar, $N(0,1)$; la segunda toma solo los valores -1 y $+1$, con probabilidad $1/2$ cada uno. Ambas tienen idénticos los dos primeros momentos, y sin embargo la probabilidad de superar el valor 1,5 es de aproximadamente 0,067 en la primera y exactamente 0 en la segunda. Esperanza y varianza no determinan la distribución; y las preguntas de la inferencia, como "¿cuán raro sería observar una estimación tan alejada de cero como la que tengo delante, si en realidad β_2 fuese cero?", son preguntas sobre probabilidades de colas (la probabilidad de que la variable supere un valor dado), no sobre momentos (esperanza y varianza).

La lección 11 ya nos dio la pieza que hoy resultará decisiva. Allí escribimos $\hat{\beta}_2 = \beta_2\, \mathit{1} + \sum_i W_i U_i$, y esa descomposición no era un paso intermedio prescindible: dice que el error de estimación $\hat{\beta}_2 - \beta_2\, \mathit{1}$ es una *suma ponderada de las perturbaciones*. Si supiéramos qué forma tiene la distribución de las U_i, sabríamos qué forma tiene la de $\hat{\beta}_2$ condicionada a $\boldsymbol{X}$. Eso es lo que vamos a hacer: suponer una forma para U y leer la consecuencia.

Sobre el reparto de la sesión: primero se construye el aparato (el supuesto, el error estándar y el contraste), después se traduce a geometría (la razón de catetos y los grados de libertad) y por último se interpreta (el intervalo, la tabla de resultados y la significación). Esa última parte es la que usará cada vez que lea un cuadro de resultados.

Para quien venga del curso de Estadística del primer curso, esta tabla pone en correspondencia lo que allí se vio con lo que estas tres lecciones hacen. Las dos primeras filas son de la lección 11; las demás, de esta y de la siguiente.

En su curso de Estadística	En este curso	Dónde
$\bar{x}$, también cuando es una variable aleatoria	$\overline{X}$ para la variable aleatoria, $\mu_{\boldsymbol{x}}$ para el número	L11
parámetro / estimador / estimación, con μ	β_2 / $\hat{\beta}_2(\boldsymbol{X}, \boldsymbol{Y})$ / $\hat{\beta}_2(\boldsymbol{x}, \boldsymbol{y})$	L11
$\sigma_{\bar{x}} = \sigma/\sqrt{n}$, el "error de muestreo"	$\mathrm{ee}(\hat{\beta}_2) = \mathfrak{s}/\lVert \boldsymbol{x} - \overline{\boldsymbol{x}} \rVert_e$, el error estándar	L12
$N(\mu, \sigma)$	$N(\mu, \sigma^2)$	L12
$z_{\alpha/2} = 1{,}96$, leído en una tabla	t_c de la t_{n-k}; vale 1,96 cuando $n-k$ es grande	L12
σ desconocida: se pone S, su cuasidesviación típica, en su lugar y se sigue usando el 1,96 de la normal, a condición de que $n > 30$	σ desconocida: se pone $\mathfrak{s}$ en su lugar y la normal se convierte en la t_{n-k}, para cualquier n	L12

Continúa en la siguiente página

Continúa de la página anterior

En su curso de Estadística	En este curso	Dónde
α: el complemento del nivel de confianza	α: probabilidad de rechazar H_0 siendo cierta; el intervalo al $1-\alpha$ es el conjunto de valores que el contraste al nivel α no rechaza	L12
$\bar{x} \pm 1{,}96\,\sigma/\sqrt{n}$	$\hat{\beta}_2 \pm t_c\,\mathrm{ee}(\hat{\beta}_2)$	L12
contraste de hipótesis: solo nombrado	H_0, estadístico, valor crítico, valor p	L12
SCR (de regresión) y SCE (del error)	SEC y SRC	L8, L12, L13
"F" y "Valor crítico de F" al pie de la salida de Excel	el F de significación conjunta y su valor p (lo que Excel rotula "Valor crítico de F" es el valor p, no F_c)	L13

Notación de la primera columna. Es la de su curso de Estadística: $\bar{x}$ designa tanto el número como la variable aleatoria; S es la cuasidesviación típica de la muestra (divisor $n-1$); $N(\mu, \sigma)$ lleva como segundo argumento la desviación típica; y α es el complemento del nivel de confianza.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, introducción y sección 4.1 (por qué la distribución muestral, y no solo sus momentos, es lo que hace falta para contrastar hipótesis).

2 El supuesto nuevo: normalidad

Condicionada a $\boldsymbol{X}$, cada perturbación U_i es *normal* de esperanza 0 y varianza σ^2.

La descomposición de la lección 11 basta:

$$\hat{\beta}_2 = \beta_2\, 1 + \sum_i W_i U_i.$$

Los W_i son funciones de $\boldsymbol{X}$: con los regresores en su valor $\boldsymbol{x}$ son números, y una suma ponderada de normales independientes con pesos numéricos es normal (apuntes):

$$\boxed{\hat{\beta}_2 \,\Big|\, \boldsymbol{X} \;\sim\; N\Big(\beta_2,\; \frac{\sigma^2}{\sum_i (X_i - \overline{X})^2}\Big).}$$

Lo *nuevo* es el símbolo "N"; y es un supuesto genuino: la práctica C de la sesión 16 (actividad 1 (html)) mostró que insesgadez y varianza no la necesitan.

Geométricamente: la normalidad hace *isótropa* la perturbación: sus coordenadas en cualquier base ortonormal son independientes y con la misma distribución.

El supuesto nuevo: normalidad

El Modelo Clásico de Regresión Lineal de la lección 9 constaba de tres supuestos (linealidad, independencia lineal de los regresores y homocedasticidad), a los que la lección 11 añadió el muestreo

aleatorio. Hoy incorporamos un supuesto más, la *normalidad* de la perturbación; diremos qué añade y qué no. Formalmente, suponemos que, condicionada a la matriz aleatoria de regresores $\boldsymbol{X}$, cada U_i tiene distribución normal:

$$U_i \,\Big|\, \boldsymbol{X} \;\sim\; N(0,\sigma^2), \qquad i=1,\ldots,n.$$

Hasta ahora solo habíamos condicionado momentos, una esperanza y una varianza; hoy condicionamos una distribución entera, y "condicionada a $\boldsymbol{X}$" significa lo mismo que en la lección 9: proyectar. La probabilidad de cada suceso $\{U_i \le u\}$ es la esperanza de su *indicadora* (la variable aleatoria que vale 1 cuando el suceso ocurre y 0 cuando no), y condicionarla en $\boldsymbol{X}$ es proyectarla ortogonalmente sobre el espacio de las funciones de $\boldsymbol{X}$, es decir, tomar su sombra, como la lección 9 hizo con Y para definir $E[Y \mid X]$: el resultado, $P[U_i \le u \mid \boldsymbol{X}]$, es una variable aleatoria, no un número (apéndice, sección 1.4 (html)). El supuesto dice dos cosas sobre esas sombras: que todas son constantes, es decir, que la distribución de U_i no depende de $\boldsymbol{X}$ (es la independencia de U_i respecto de $\boldsymbol{X}$ leída con proyecciones, la que la lección 11 anunció que haría falta hoy; apéndice, sección 1.5 (html)), y cuáles son esas constantes: las de una $N(0,\sigma^2)$. Es el patrón de los supuestos que ya teníamos, $E[U_i \mid \boldsymbol{X}] = \mathit{0}$ y $E[U_i^2 \mid \boldsymbol{X}] = \sigma^2\,\mathit{1}$, que dicen que dos funciones de U_i tienen sombra constante; hoy lo pedimos para todas las indicadoras a la vez y fijamos qué constantes son. La fórmula de esas constantes está al final de la sección 1.5 del apéndice (html).

Obsérvese que este supuesto no cambia ninguno de los momentos que ya teníamos: la esperanza condicional sigue siendo $E[U_i \mid \boldsymbol{X}] = \mathit{0}$ y la varianza condicional sigue siendo $Var[U_i \mid \boldsymbol{X}] = \sigma^2\,\mathit{1}$, como en la lección 11. Lo único que añade es *de qué forma* se reparte la probabilidad alrededor de ese valor esperado, con esa varianza.[1]

De aquí a la distribución de $\hat\beta_2$ no hace falta ninguna cuenta nueva: basta releer lo que ya escribimos en la lección 11. Allí obtuvimos, por álgebra pura y sin tomar esperanzas,

$$\hat\beta_2 = \beta_2\,\mathit{1} + \sum_i W_i U_i, \qquad \text{con} \qquad W_i = \frac{X_i - \overline{X}}{\sum_j (X_j - \overline{X})^2}.$$

Los pesos W_i son funciones de $\boldsymbol{X}$. Para la esperanza y la varianza condicionales bastó el Lema de la lección 11, que los saca fuera de $E[\,\cdot \mid \boldsymbol{X}]$. Para la distribución condicional hace falta algo más, y

[1] *Una precisión notacional.* Los argumentos de $N(\cdot,\cdot)$ son los *parámetros* de la distribución: la esperanza y la varianza. En una distribución condicionada a $\boldsymbol{X}$ pueden ser funciones de $\boldsymbol{X}$, es decir, variables aleatorias. En la $N(0,\sigma^2)$ de las U_i son dos números, porque sus sombras son constantes; en la de $\hat\beta_2$, la esperanza es el número β_2 y la varianza $\sigma^2/\sum_i (X_i-\overline{X})^2$ es una función de $\boldsymbol{X}$. El símbolo se lee entonces así: para cada valor $\boldsymbol{x}$ de los regresores, $\hat\beta_2$ es normal con esperanza β_2 y varianza $\sigma^2/\sum_i (x_i-\overline{x})^2$, dos números (el apéndice, sección 9 (html), lo dice en general). En $N(0,\sigma^2)$ escribimos 0 a secas, y no $\mathit{0}$. La regla del curso que obliga a escribir $\beta_1\,\mathit{1}$ en lugar de β_1 existe para que cada operación se haga entre objetos del tipo para el que está definida: una variable aleatoria se suma a otra variable aleatoria, no a un número, y los dos lados de una igualdad han de ser del mismo tipo ($X = 1$ no tiene sentido, porque X es una función y 1 un número). A los argumentos de una distribución no les aplicamos la regla, para no complicar la notación. Compárese: $E[U_i \mid \boldsymbol{X}] = \mathit{0}$ es una igualdad entre variables aleatorias (la esperanza condicional lo es), mientras que "la esperanza de esa normal es 0" es una afirmación sobre el valor numérico de un parámetro. Y el segundo argumento es la *varianza*: $N(\mu,\sigma^2)$. Su curso de Estadística escribía $N(\mu,\sigma)$, con la desviación típica, y Gretl sigue esa misma convención: `normal(m, s)` simula una normal de media `m` y desviación típica `s`, como se explicó en la práctica B de la sesión 7 (html). Las dos convenciones son correctas y conviven; los manuales de econometría prefieren la de la varianza porque con ella la varianza de $\hat\beta_2$ se lee dentro del paréntesis, sin raíces. Lo único que hay que vigilar es no mezclarlas: para simular una $N(0,\sigma^2)$ en Gretl se escribe `normal(0, sigma)`, no `normal(0, sigma^2)`.

lo tenemos: con los regresores en su valor $\boldsymbol{x}$ los pesos son números, $w_i = (x_i - \overline{x})/\sum_j (x_j - \overline{x})^2$, y las U_i siguen siendo $N(0, \sigma^2)$ e independientes, porque son independientes de $\boldsymbol{X}$ (todas sus sombras son constantes) e independientes entre sí (muestreo aleatorio, lección 11). Queda un resultado de probabilidad que no demostraremos: una suma ponderada de normales independientes, con pesos numéricos, es normal. Es la propiedad de la normal que el apéndice enuncia en la sección 8 (html), y de la que en la sección 9 sale esta distribución y, después, la t. Por tanto, condicionando en $\boldsymbol{X}$, $\hat{\beta}_2$ es normal, con el valor esperado y la varianza que ya calculamos en la lección 11:

$$\hat{\beta}_2 \,\Big|\, \boldsymbol{X} \;\sim\; N\Big(\beta_2,\; \frac{\sigma^2}{\sum_i (X_i - \overline{X})^2}\Big).$$

La varianza condicional $\sigma^2/\sum_i (X_i - \overline{X})^2$ es una función de $\boldsymbol{X}$, una variable aleatoria, como en la lección 11: a diferencia de las sombras de las U_i, la distribución condicional de $\hat{\beta}_2$ sí depende de los regresores, y solo a través de esa varianza; el apéndice, sección 9, escribe explícitamente $P[\hat{\beta}_2 \leq u \mid \boldsymbol{X}]$ como función de $\boldsymbol{X}$. En "El error estándar, y el precio de estimar σ" evaluaremos esa varianza sobre los regresores observados $\boldsymbol{x}$ y obtendremos un número, como en la lección 11 al pasar de estimador a estimación; $\hat{\beta}_2$ no deja de ser aleatoria por ello: la aleatoriedad que cuenta aquí es la de la perturbación.

Fijar los regresores no fija $\hat{\beta}_2$. En la descomposición de la lección 11, $\hat{\beta}_2 = \beta_2\, 1 + \sum_i W_i U_i$, poner los regresores en su valor $\boldsymbol{x}$ convierte los pesos en números, $w_i = (x_i - \overline{x})/\sum_j (x_j - \overline{x})^2$, y deja $\hat{\beta}_2 = \beta_2\, 1 + \sum_i w_i U_i$: una función de las perturbaciones, que no se han fijado, con varianza $\sigma^2 \sum_i w_i^2 = \sigma^2/\sum_i (x_i - \overline{x})^2$. Esa varianza es la dispersión de $\hat{\beta}_2$ entre muestras con esos mismos regresores y perturbaciones distintas, la que el laboratorio de la sesión 16 midió repitiendo el sorteo de U con el regresor fijo (práctica A, actividad 4 (html)).

La normalidad es un supuesto *añadido*, no una consecuencia de los anteriores, y la práctica C de la sesión 16 lo mostró (actividad 1 (html) y actividad 2 (html)). Allí se repitió el experimento de Monte Carlo con perturbaciones uniformes y con perturbaciones muy asimétricas (una χ^2 centrada, la de la práctica C), no normales, y el resultado fue que la media de las estimaciones seguía cayendo sobre β_2 y la varianza de las estimaciones seguía coincidiendo con la fórmula de la lección 11. No podía ser de otro modo: aquella demostración nunca usó la normalidad. Lo que *sí* cambiaba era la forma del histograma. Y cambiaba de una manera instructiva: con $n = 506$ el histograma parecía normal aunque U no lo fuese; con $n = 12$ y la más asimétrica de las perturbaciones ensayadas allí el histograma se apartaba de la normal, por las colas (valores extremos más frecuentes que en una normal) más que por la asimetría; y cuando una observación dominaba el regresor heredaba la asimetría de U. Volveremos sobre esa dependencia del tamaño muestral al final de la sesión, porque es la razón por la que la inferencia que hoy construimos sigue siendo aproximadamente válida en muestras grandes incluso cuando la normalidad falla.

Queda la lectura geométrica, la de la transparencia: la normalidad hace isótropa la perturbación. La perturbación $\boldsymbol{U} = (U_1, \ldots, U_n)$ es una lista de n variables aleatorias, no un vector de $\mathbb{R}^n$, así que "sus coordenadas" se definen como la lección 11 definió el estimador $\hat{\beta}_2$: la fórmula que calcula la estimación con los datos $x_1, \ldots, x_n, y_1, \ldots, y_n$, evaluada sobre la muestra aleatoria $X_1, \ldots, X_n, Y_1, \ldots, Y_n$. Tomemos una base ortonormal $\boldsymbol{b}_1, \ldots, \boldsymbol{b}_{n-1}$ (vectores de longitud 1 y ortogonales dos a dos) de $\mathcal{L}(\mathbf{1})^\perp$, el subespacio de los vectores en desviaciones (lección 4): el primer vector es el regresor en desviaciones dividido por su longitud, $\boldsymbol{b}_1 = (\boldsymbol{x} - \overline{\boldsymbol{x}})/\|\boldsymbol{x} - \overline{\boldsymbol{x}}\|$, y los $n - 2$

restantes completan la base por una regla fija (la práctica D de la sesión 14 construye una así con Gretl; actividad 7 (html)). La coordenada de un vector $\boldsymbol{v}$ sobre $\boldsymbol{b}_j$ es su producto escalar con él,

$$c_j = \langle \boldsymbol{b}_j, \boldsymbol{v} \rangle = \sum_{i=1}^{n} b_{ji}\, v_i,$$

la fórmula de la familia ortogonal de la lección 10, $\langle \boldsymbol{b}_j, \boldsymbol{v} \rangle / \langle \boldsymbol{b}_j, \boldsymbol{b}_j \rangle$, con denominador 1 porque $\boldsymbol{b}_j$ tiene longitud 1. Cada componente b_{ji} de la base es una fórmula de $x_1, \ldots, x_n$; evaluada sobre $X_1, \ldots, X_n$ es una variable aleatoria, que llamamos B_{ji}.

Evaluemos ahora la fórmula de c_j con las perturbaciones centradas $U_i - \overline{U}$ en el lugar de los v_i (centradas porque la base es de $\mathcal{L}(\mathbf{1})^\perp$, el subespacio de los vectores en desviaciones) y las B_{ji} en el lugar de los b_{ji}: el resultado son $n-1$ variables aleatorias,

$$C_j = \sum_{i=1}^{n} B_{ji}\,(U_i - \overline{U}), \qquad j = 1, \ldots, n-1,$$

las *coordenadas de la perturbación* $\boldsymbol{U}$ sobre $\boldsymbol{b}_1, \ldots, \boldsymbol{b}_{n-1}$. La primera es conocida. $B_{1i} = (X_i - \overline{X})/\sqrt{\sum_j (X_j - \overline{X})^2}$ es el peso $W_i = (X_i - \overline{X})/\sum_j (X_j - \overline{X})^2$ de la lección 11 multiplicado por $\sqrt{\sum_j (X_j - \overline{X})^2}$, la longitud del regresor X en desviaciones evaluada sobre $X_1, \ldots, X_n$; y la media $\overline{U}$ desaparece de C_1 porque $\sum_i B_{1i} = 0$. Queda

$$C_1 = \sqrt{\textstyle\sum_j (X_j - \overline{X})^2} \sum_{i=1}^{n} W_i U_i = \sqrt{\textstyle\sum_j (X_j - \overline{X})^2}\,(\hat{\beta}_2 - \beta_2\, 1),$$

es decir, la coordenada de la perturbación sobre la dirección del regresor es el error de estimación $\hat{\beta}_2 - \beta_2\, 1$ de la lección 11 multiplicado por la longitud del regresor en desviaciones. C_1 no es un objeto nuevo: es el error de estimación cambiado de escala.

Con los supuestos de la lección 11, homocedasticidad e incorrelación, las $n-1$ coordenadas $C_1, \ldots, C_{n-1}$ son variables aleatorias centradas (de esperanza nula), ortogonales entre sí, $E[C_j C_l \mid \boldsymbol{X}] = 0$, y de la misma longitud, $E[C_j^2 \mid \boldsymbol{X}] = \sigma^2\, 1$ (apéndice, Resultado 1 (html)). Con normalidad son, además, independientes y con la misma distribución $N(0, \sigma^2)$, sea cual sea la base ortonormal elegida (apéndice, Resultado 3 (html)). Eso es la *isotropía*: ninguna dirección se distingue de otra. Es lo que usará "Por qué el valor crítico depende de $n-k$": la coordenada sobre el regresor y las $n-2$ restantes son independientes, y de ahí sale la distribución del ángulo. La construcción y las demostraciones están en el apéndice, secciones 5.2 (html), 6.3 (html), 7 (html) y 8 (html).

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.1 (supuesto MLR.6 de normalidad y distribuciones muestrales normales de los estimadores MCO).

3 El error estándar, y el precio de estimar σ

Esa varianza contiene σ^2, que *no conocemos*: la estimamos con la cuasivarianza de los residuos (lección 11), $\mathfrak{s}^2 = \mathrm{SRC}/(n-k)$.

Sustituyendo σ por $\mathfrak{s}$ sobre los datos observados, el *error estándar* de $\hat{\beta}_2$:

$$\boxed{\mathrm{ee}(\hat{\beta}_2) = \frac{\mathfrak{s}}{\sqrt{\sum_i (x_i - \mu_{\boldsymbol{x}})^2}} = \frac{\mathfrak{s}}{\|\boldsymbol{x} - \overline{\boldsymbol{x}}\|_e}.}$$

Un cociente de longitudes: *longitud del residuo por unidad de longitud del regresor en desviaciones.*

El precio de estimar σ: la normal se convierte en una *t de Student con $n-k$ grados de libertad* (enunciado; demostración en el apéndice):

$$\frac{\hat{\beta}_2 - \beta_2}{\text{ee}(\hat{\beta}_2)} \sim t_{n-k}.$$

El error estándar, y el precio de estimar σ

La varianza de $\hat{\beta}_2$ en su distribución condicional, $\sigma^2/\sum_i (X_i - \overline{X})^2$ (transparencia "El supuesto nuevo: normalidad"), tiene un problema práctico evidente: contiene σ^2, la varianza de la perturbación poblacional, que es desconocida, como toda cantidad poblacional. La lección 11 ya nos dejó resuelto ese punto: σ^2 se estima mediante la cuasivarianza de los residuos, $\mathfrak{s}^2 = \text{SRC}/(n-k)$, usando el tercer miembro de la familia de productos escalares del curso, el de divisor $n-k$. Recordemos que ese divisor no era arbitrario: los residuos viven en el subespacio ortogonal a las columnas de $\mathbf{X}$, de dimensión $n-k$, y dividir por esa dimensión es lo que hace insesgado al estimador.

Sustituyendo σ por $\mathfrak{s}$ en la raíz cuadrada de la varianza, y aplicando la expresión sobre los *datos observados* en lugar de sobre la muestra aleatoria, obtenemos el *error estándar* de $\hat{\beta}_2$:

$$\text{ee}(\hat{\beta}_2) = \frac{\mathfrak{s}}{\sqrt{\sum_i (x_i - \mu_{\boldsymbol{x}})^2}} = \frac{\mathfrak{s}}{\|\boldsymbol{x} - \overline{\boldsymbol{x}}\|_e}.$$

Sobre la notación: el término "error estándar" es una de las fuentes de confusión más frecuentes al leer resultados. Un error estándar mide la dispersión de un *estimador*: cuánto variaría el número que hemos calculado si volviéramos a sortear las perturbaciones con esos mismos regresores. No mide la dispersión de unos datos. Y el objeto que acabamos de escribir es un *número*: se calcula con los datos que tenemos. Es la realización de una variable aleatoria, la que resulta de evaluar esa misma fórmula sobre la muestra aleatoria. Es el mismo abuso de lenguaje, cómodo y universal, que ya hicimos en la lección 11 al llamar "sesgado" a SRC/n e "insesgado" a $\mathfrak{s}^2$: fórmulas escritas con los residuos observados, para hablar de propiedades que son del estimador subyacente.[2]

Escrito así, el error estándar es un *cociente de dos longitudes*, y esa es su lectura más útil. En el numerador, $\mathfrak{s} = \sqrt{\langle \widehat{\boldsymbol{e}}, \widehat{\boldsymbol{e}} \rangle_{n-k}}$ es la longitud del vector de residuos, medida con el producto escalar de divisor $n-k$ de la lección 11; es lo que tenemos en lugar de σ, la desviación típica de la perturbación. En el denominador, $\|\boldsymbol{x} - \overline{\boldsymbol{x}}\|_e$ mide cuánto se separa el regresor de su propia media: es la longitud euclídea del vector en desviaciones de la lección 4. Por tanto: *el error estándar es la longitud del residuo por unidad de longitud del regresor en desviaciones.* Un regresor con mucha variación (un vector en desviaciones largo) permite estimar su coeficiente con precisión; un regresor cuyos valores apenas cambian dentro de la muestra (un vector en desviaciones corto), no, aunque $\mathfrak{s}$ sea relativamente pequeño. Es la lectura geométrica de algo que en la lección 11 aparecía como "más dispersión en X, más precisión", y la veremos dibujada en "El intervalo de confianza".

[2] La confusión se agrava con la traducción. En inglés, la salida de un programa como Gretl distingue "S.D. dependent var" (*standard deviation*: dispersión de los datos del regresando) de "S.E. of regression" (*standard error*) y de la columna "Std. Error" de cada coeficiente. En la versión española de Gretl las tres se rotulan como desviación típica ("D.T. de la vble. dep.", "D.T. de la regresión" y la cabecera "Desv. típica" de la columna de los coeficientes), de modo que tres cantidades conceptualmente distintas comparten etiqueta. Volveremos sobre ello en "Cómo se lee una tabla de resultados".

Queda el segundo asunto de esta transparencia, la distribución del cociente. Si conociéramos σ, de la distribución normal de $\hat{\beta}_2$ condicionada a $\boldsymbol{X}$ (transparencia "El supuesto nuevo: normalidad") se seguiría inmediatamente que

$$\frac{\hat{\beta}_2 - \beta_2}{\sqrt{\sigma^2 / \sum_i (X_i - \overline{X})^2}} \sim N(0,1),$$

porque restar la esperanza y dividir por la desviación típica (*tipificar*) convierte cualquier normal en la normal estándar. De ahí salía el 1,96 de los intervalos de su curso de Estadística: es el valor que deja 0,025 en cada cola de la normal estándar. Pero no conocemos σ: en su lugar usamos $\mathfrak{s}$. Y $\mathfrak{s}$, como $\hat{\beta}_2$, es la realización de un estimador: la variable aleatoria que resulta de evaluar $\sqrt{\text{SRC}/(n-k)}$ sobre la lista de residuos $(\hat{E}_1, \ldots, \hat{E}_n)$ de la lección 11, y que denotamos con el mismo símbolo. Al dividir por una cantidad que también fluctúa de muestra en muestra, el cociente resultante se dispersa más que una normal estándar: puede salir grande porque el numerador sea grande, pero también porque el denominador haya salido pequeño por azar. El resultado exacto es que ese cociente sigue una distribución conocida, la *t de Student con $n-k$ grados de libertad*:

$$\frac{\hat{\beta}_2 - \beta_2}{\text{ee}(\hat{\beta}_2)} \sim t_{n-k}.$$

El nombre "grados de libertad" designa el único parámetro de esa distribución, el número $n-k$; su significado geométrico está en "Por qué el valor crítico depende de $n-k$". La demostración está en el apéndice (secciones 8 (html) y 9); aquí basta con la idea: numerador y denominador son funciones de coordenadas de la perturbación distintas, la de la dirección del regresor y las $n-k$ del residuo, y con normalidad esas coordenadas son independientes; eso, y nada más, es lo que convierte el cociente en una t_{n-k}. La distribución t_{n-k} es simétrica y acampanada como la normal, pero con colas más gruesas (los valores alejados de cero son más probables que en la normal), y tanto más gruesas cuanto menor sea $n-k$; a medida que $n-k$ crece, se acerca a la normal estándar hasta hacerse indistinguible de ella en la práctica (con $n-k$ del orden de unas decenas, la diferencia ya es pequeña). El número de grados de libertad es $n-k$, el mismo que aparecía en el divisor de $\mathfrak{s}^2$.

Su curso de Estadística hizo esta misma sustitución, S en lugar de σ, y siguió usando el 1,96 de la normal con la condición $n > 30$. Esa condición es la aproximación de la t_{n-k} por la normal en muestras grandes: la regla de allí es la de hoy cuando $n-k$ es grande, y la t_{n-k} es lo que hay que usar cuando no lo es.

Nota de coherencia: en este curso, k cuenta *todos* los regresores, incluida la constante. Por eso los grados de libertad se escriben siempre $n-k$ y nunca $n-k-1$. En el modelo lineal simple de hoy, $k=2$ y los grados de libertad son $n-2$.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.2 (el estadístico t y su distribución); y cap. 3, sección 3.4 (errores estándar de los coeficientes).

4 Un contraste que ya puede hacer: la media

Su curso de Estadística dejó la media muestral con distribución conocida, $\overline{X} \sim N(\mu, \sigma^2/n)$ (allí escrita $N(\mu, \sigma/\sqrt{n})$), y con ella el intervalo $\overline{X} \pm 1{,}96\,\sigma/\sqrt{n}$. Le faltó el paso siguiente.

Pregunta: si μ valiese μ_0, ¿serían datos como estos demasiado raros? *Hipótesis nula*: $H_0\colon \mu = \mu_0$.

Suponemos provisionalmente H_0. Entonces

$$\frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}} \;\sim\; N(0,1)\,:$$

la distancia de $\overline{X}$ a μ_0, medida en desviaciones típicas de $\overline{X}$. Bajo H_0, el 95 % de las muestras dan un cociente entre $-1{,}96$ y 1,96.

Decisión: si el cociente observado queda fuera, datos como estos serían raros bajo H_0 (ocurren el 5 % de las veces): se rechaza H_0. Si queda dentro, no se rechaza.

Con $\hat{\beta}_2$ en lugar de $\overline{X}$, $\text{ee}(\hat{\beta}_2)$ en lugar de $\sigma/\sqrt{n}$ y t_c en lugar de 1,96: el contraste t de la transparencia siguiente.

Un contraste que ya puede hacer: la media

Antes de construir el contraste sobre β_2 veamos la lógica entera en el único caso que su curso de Estadística dejó preparado. Allí quedó enunciado que, con n copias independientes de una variable de esperanza μ y varianza σ^2, la media muestral tiene esperanza μ y varianza σ^2/n (la lección 11 lo demostró como caso $k = 1$), y que es normal si la variable lo es o si n es grande. Con eso se construyó el intervalo $\overline{X} \pm 1{,}96\,\sigma/\sqrt{n}$. El contraste de hipótesis se nombró y no se desarrolló; es lo que hacemos ahora, con esas mismas piezas.

La pregunta de un contraste no es "¿cuánto vale μ?" sino "si μ valiese un número concreto μ_0, ¿serían datos como estos demasiado raros?". Ese número es la *hipótesis nula*, $H_0 : \mu = \mu_0$, y el razonamiento tiene tres pasos. Primero, suponemos provisionalmente que H_0 es cierta. Segundo, bajo ese supuesto conocemos la distribución de un estadístico: $(\overline{X} - \mu_0)/(\sigma/\sqrt{n})$ es una normal estándar, porque restar la esperanza y dividir por la desviación típica tipifica cualquier normal (es el valor tipificado z de su curso de Estadística, con una variable aleatoria en lugar de un dato); ese cociente dice a cuántas desviaciones típicas de $\overline{X}$ está la media observada del valor μ_0. Tercero, comparamos el cociente observado con lo que esa distribución produce habitualmente: el 95 % de las veces cae entre $-1{,}96$ y 1,96. Si el observado queda fuera, o hemos tenido una muestra muy rara, de las que salen una vez de cada veinte, o el supuesto provisional era falso; el contraste opta por lo segundo y *rechaza* H_0. ¿Por qué opta por lo segundo, si una vez de cada veinte no es tan raro? Porque el umbral lo elegimos nosotros: el 5 % es una convención. Si una vez de cada veinte no nos parece bastante raro para descartar H_0, podemos exigir una de cada cien, y el 1,96 pasa a ser 2,58; o una de cada mil, y pasa a ser 3,29. Cuanto más exigentes seamos, menos veces rechazaremos una H_0 cierta y más veces dejaremos sin rechazar una falsa. Qué nivel conviene depende de cuánto nos preocupe cada uno de esos dos errores, y eso cambia con el problema: en otros campos se exigen umbrales mucho más estrictos que una vez de cada veinte. El 5 % es solo la costumbre en economía. Si queda dentro, datos como estos no serían raros bajo H_0 y *no se rechaza*; lo que no quiere decir que H_0 sea cierta, como veremos en la sección "Significación estadística ≠ relevancia económica".

Los nombres, que reaparecen en "El contraste t": el 1,96 es el *valor crítico*, el 5 % es el *nivel de significación* α, la probabilidad de rechazar H_0 cuando es cierta, y el conjunto de valores del cociente que llevan a rechazar, $|\cdot| > 1{,}96$, es la *región crítica*. Su curso de Estadística usaba la letra α solo como complemento del nivel de confianza; aquí tiene además este significado, y los dos

coinciden: μ_0 no se rechaza al nivel α cuando μ_0 está dentro del intervalo de confianza al $1-\alpha$, porque la desigualdad $|\overline{X}-\mu_0| \le 1{,}96\,\sigma/\sqrt{n}$ es la misma escrita de dos maneras. El intervalo es el conjunto de las hipótesis que no se rechazan; volveremos sobre esto en "El intervalo de confianza".

Queda una objeción que su curso ya resolvió a medias: σ no se conoce y se sustituye por una estimación. El precio, la distribución t_{n-k} en lugar de la normal, está en "El error estándar, y el precio de estimar σ"; con muchas observaciones la diferencia desaparece, y esa es la condición $n > 30$ de allí. En "El contraste t" el contraste es este mismo, con $\hat{\beta}_2$ en el papel de $\overline{X}$, el error estándar en el de $\sigma/\sqrt{n}$ y el valor crítico de la t_{n-k} en el del 1,96.

Para profundizar: Wooldridge, J. M. (2020), apéndice C, sección C.6 (contraste de hipótesis sobre la media de una población normal).

5 El contraste t

La misma lógica de la transparencia anterior, con $\hat{\beta}_2$. *Hipótesis nula*: $H_0 : \beta_2 = 0$ ("el regresor no aporta nada"), frente a $H_1 : \beta_2 \neq 0$.

Estadístico (bajo H_0, sustituyendo $\beta_2 = 0$ en la transparencia anterior):

$$t = \frac{\hat{\beta}_2}{\mathrm{ee}(\hat{\beta}_2)} \;\sim\; t_{n-k}.$$

Decisión al nivel α (habitualmente 0,05): se rechaza H_0 si $|t| > t_c$, el valor crítico de la t_{n-k} que deja $\alpha/2$ en cada cola; el conjunto $|t| > t_c$ es la *región crítica*.

Valor p: probabilidad de un $|t|$ *al menos tan grande* como el obtenido, *si* H_0 *fuese cierta*. Se rechaza si es menor que α.

Nada obliga a contrastar contra cero: para $H_0 : \beta_2 = c$ (p. ej. una elasticidad unitaria), $t = (\hat{\beta}_2 - c)/\mathrm{ee}(\hat{\beta}_2)$.

El contraste t

Con la distribución t_{n-k} del cociente $(\hat{\beta}_2 - \beta_2)/\mathrm{ee}(\hat{\beta}_2)$, obtenida en "El error estándar, y el precio de estimar σ", el contraste se construye sin ningún ingrediente nuevo. La hipótesis que se contrasta con más frecuencia es $H_0 : \beta_2 = 0$, que en términos del modelo poblacional dice que el regresor no interviene: si $\beta_2 = 0$, entonces $Y = \beta_1\, 1 + U$ (el regresor X no aparece). La *hipótesis alternativa*, lo que se sostiene si H_0 se rechaza, es habitualmente $H_1 : \beta_2 \neq 0$: no especifica ningún valor concreto y admite desviaciones en los dos sentidos, por debajo y por encima de cero, las dos colas de la distribución; de ahí que el contraste se llame *de dos colas*.

El razonamiento es el de todo contraste de hipótesis, y conviene enunciarlo con cuidado porque es donde se cometen los errores de interpretación. *Suponemos provisionalmente* que H_0 es cierta. Bajo ese supuesto, sustituyendo $\beta_2 = 0$ en el resultado de "El error estándar, y el precio de estimar σ", sabemos cómo se distribuye el cociente

$$t = \frac{\hat{\beta}_2}{\mathrm{ee}(\hat{\beta}_2)} \;\sim\; t_{n-k}.$$

Este cociente es la distancia entre la estimación y el valor 0, expresada en una unidad de medida nueva: el error estándar. Dividir una longitud por otra dice cuántas veces cabe la segunda en la primera (seis metros entre metro y medio son cuatro), de modo que $t = 3$ significa que $\hat{\beta}_2$ dista de cero tres errores estándar. Con esa unidad, la pregunta "¿está lejos de cero?" ya no depende de las unidades de X e Y: se compara con la imprecisión propia del estimador. Por eso t no cambia al cambiar las unidades, como veremos en "Cómo se lee una tabla de resultados". Si el valor que obtenemos con nuestros datos es de los que la t_{n-k} produce con facilidad, no hay nada que nos induzca a rechazar H_0. Si es un valor que la t_{n-k} produciría muy raramente, tenemos un conflicto: o bien hemos tenido una muestra de las que la t_{n-k} produce muy raramente, o bien el supuesto provisional era falso. El contraste opta por lo segundo, y al hacerlo acepta un riesgo cuantificado de equivocarse.

Ese riesgo es el *nivel de significación* α, la probabilidad de rechazar H_0 siendo cierta, que se fija de antemano (por convención, $\alpha = 0{,}05$; también se usan 0,10 y 0,01).[3] Fijado α, el *valor crítico* t_c es el número que deja una probabilidad $\alpha/2$ en cada cola de la t_{n-k}, y la regla es: rechazar H_0 si $|t| > t_c$. El conjunto de valores que llevan a rechazar se llama *región crítica*. t_c depende de dos cosas: del nivel α que hayamos elegido y de los grados de libertad $n-k$. Esta segunda dependencia tiene una lectura geométrica, que desarrolla "Por qué el valor crítico depende de $n-k$".

El contraste acaba en una decisión, rechazar o no. El *valor p* informa de algo previo a la decisión, la rareza de los datos bajo H_0: es la probabilidad de que la t_{n-k} produzca un valor tan alejado de cero, o más, que el t que hemos obtenido, siempre bajo el supuesto de que H_0 es cierta. Es el mismo objeto que el "valor p" que Gretl imprimió junto a los histogramas del laboratorio de la sesión 16: allí H_0 era "las estimaciones son normales". Con las perturbaciones normales de la práctica A (actividad 5 (html)) el valor p fue 0,13: un histograma así no sería raro si lo fuesen. Con la perturbación asimétrica y $n = 12$ de la práctica C (actividad 2 (html)) fue 0,000: un histograma así sería muy raro si lo fuesen. Con él, la decisión es inmediata: se rechaza H_0 al nivel α si el valor p es menor que α, lo mismo que comparar $|t|$ con t_c. Su ventaja es que permite a cada lector aplicar su propio α: un valor p de 0,048 y otro de 0,000001 llevan ambos a "rechazar al 5 %", pero no dicen lo mismo. Hay que leerlo con cuidado: es la probabilidad de unos datos como estos si H_0 fuese cierta, no la probabilidad de que H_0 sea cierta; la sección "Significación estadística ≠ relevancia económica" vuelve sobre esa lectura.

Por último, hay que deshacer una asociación demasiado automática entre "contraste t" y "contrastar contra cero". El cero tiene un lugar privilegiado porque corresponde a la pregunta "¿interviene este regresor?", pero la construcción vale para cualquier valor de referencia: para contrastar $H_0 : \beta_2 = c$ basta usar

$$t = \frac{\hat{\beta}_2 - c}{\mathrm{ee}(\hat{\beta}_2)},$$

que bajo esa H_0 sigue igualmente una t_{n-k}. Y hay preguntas económicas que exigen eso. Si el modelo está escrito en logaritmos y β_2 es una elasticidad (algo que veremos con detalle más adelante en el curso), la pregunta interesante rara vez es "¿es la elasticidad distinta de cero?" (casi siempre lo es), sino "si fuese unitaria, ¿serían estos datos demasiado raros?", es decir, $H_0 : \beta_2 = 1$. Del mismo modo, si la teoría predice un valor concreto, contrastar contra ese valor es lo que pone a prueba la

[3] Son los más empleados por costumbre; la elección del nivel, y los dos errores que hay que sopesar, se discutió en "Un contraste que ya puede hacer: la media".

teoría; contrastar contra cero, no.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, secciones 4.2a-4.2e (contrastes de una y dos colas, valores críticos, valores p, y contrastes de hipótesis con valores de referencia distintos de cero).

6 Lectura geométrica: la razón de catetos

En el modelo lineal simple ($k = 2$), con $\widehat{\boldsymbol{y}} - \overline{\boldsymbol{y}} = \hat{\beta}_2(\boldsymbol{x} - \overline{\boldsymbol{x}})$ y $\mathfrak{s}^2 = \mathrm{SRC}/(n-k)$, el estadístico queda:

$$t^2 = (n-k)\,\frac{\mathrm{SEC}}{\mathrm{SRC}}, \qquad \text{es decir} \qquad |t| = \sqrt{n-k}\;\frac{\|\widehat{\boldsymbol{y}} - \overline{\boldsymbol{y}}\|_e}{\|\widehat{\boldsymbol{e}}\|_e}.$$

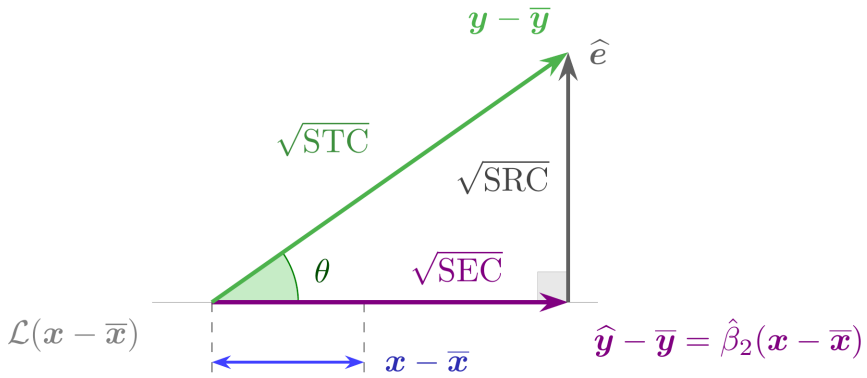


Figura 1: El triángulo rectángulo de la lección 8, con los dos catetos medidos. En verde, el vector de datos en desviaciones (la hipotenusa, de longitud $\sqrt{\mathrm{STC}}$); en violeta, el ajuste en desviaciones (el cateto explicado, de longitud $\sqrt{\mathrm{SEC}}$), rotulado a la derecha de su punta, que es un múltiplo del regresor en desviaciones (en azul, medido bajo el eje); en gris, el residuo (el cateto residual, de longitud $\sqrt{\mathrm{SRC}}$). El ángulo $\theta = \measuredangle((\boldsymbol{y} - \overline{\boldsymbol{y}}), (\widehat{\boldsymbol{y}} - \overline{\boldsymbol{y}}))$ es el que corresponde a $R^2 = \cos^2\theta$. El estadístico t compara los dos catetos.

Y como $\mathrm{STC} = \mathrm{SEC} + \mathrm{SRC}$, también $t^2 = (n-k)R^2/(1-R^2)$: *el contraste t no mide nada que el R^2 no midiera ya.*

Lectura geométrica: la razón de catetos

Hasta aquí, la construcción del contraste ha sido puramente probabilística. Esta transparencia y "Por qué el valor crítico depende de $n-k$" la traducen al lenguaje geométrico del curso: el estadístico t es un objeto que ya conocíamos desde la lección 8, mirado con otra escala. Toda esta sección está escrita para el modelo lineal simple, $k = 2$: la constante y un único regresor no constante. El último párrafo dice qué cambia con más regresores.

Empecemos por la pieza que hace posible la traducción. En el modelo lineal simple, el ajuste es $\widehat{\boldsymbol{y}} = \hat{\beta}_1\mathbf{1} + \hat{\beta}_2\boldsymbol{x}$, y sabemos desde la lección 7 que el ajuste y los datos tienen la misma media, $\mu_{\widehat{\boldsymbol{y}}} = \mu_{\boldsymbol{y}}$. Recordando además la notación de la lección 4 (la barra sobre un vector denota el vector constante formado por su media, $\overline{\boldsymbol{v}} = \mu_{\boldsymbol{v}}\mathbf{1}$), y usando $\mu_{\widehat{\boldsymbol{y}}} = \hat{\beta}_1 + \hat{\beta}_2\mu_{\boldsymbol{x}}$, se obtiene

$$\widehat{\boldsymbol{y}} - \overline{\boldsymbol{y}} = (\hat{\beta}_1\mathbf{1} + \hat{\beta}_2\boldsymbol{x}) - (\hat{\beta}_1 + \hat{\beta}_2\mu_{\boldsymbol{x}})\mathbf{1} = \hat{\beta}_2(\boldsymbol{x} - \mu_{\boldsymbol{x}}\mathbf{1}) = \hat{\beta}_2(\boldsymbol{x} - \overline{\boldsymbol{x}}).$$

Es decir: el ajuste en desviaciones es el regresor en desviaciones multiplicado por $\hat{\beta}_2$. En el triángulo rectángulo de la lección 8, el ajuste en desviaciones y el residuo son los dos catetos, y el vector de datos en desviaciones es la hipotenusa. Hoy llamaremos *cateto explicado* al primero, porque su longitud al cuadrado es la SEC, y *cateto residual* al segundo, cuya longitud al cuadrado es la SRC (el nombre arrastra la reserva que hicimos en la lección 8 sobre la palabra "explicada"). La igualdad anterior dice que el cateto explicado está alineado con el regresor en desviaciones. Eso solo ocurre con un único regresor no constante: con dos o más, el ajuste en desviaciones vive en un subespacio de dimensión $k-1$ y ya no está alineado con ningún regresor en particular (lección 10). Por eso hoy trabajamos con $k = 2$.

Tomando longitudes euclídeas al cuadrado en esa igualdad obtenemos $\mathrm{SEC} = \hat{\beta}_2^2 \, \|\boldsymbol{x} - \overline{\boldsymbol{x}}\|_e^2$. A partir de aquí la cuenta es mecánica. Partimos del estadístico, escribimos el error estándar como el cociente de longitudes de "El error estándar, y el precio de estimar σ" y elevamos al cuadrado:

$$t = \frac{\hat{\beta}_2}{\mathrm{ee}(\hat{\beta}_2)} = \frac{\hat{\beta}_2 \, \|\boldsymbol{x} - \overline{\boldsymbol{x}}\|_e}{\mathfrak{s}}, \qquad t^2 = \frac{\hat{\beta}_2^2 \, \|\boldsymbol{x} - \overline{\boldsymbol{x}}\|_e^2}{\mathfrak{s}^2} = \frac{\mathrm{SEC}}{\mathrm{SRC}/(n-k)} = (n-k)\,\frac{\mathrm{SEC}}{\mathrm{SRC}},$$

que es la identidad anunciada. ■

A la izquierda, un estadístico de contraste, construido con supuestos probabilísticos, normalidad y la distribución del estimador. A la derecha, dos sumas de cuadrados que calculamos en la lección 8 sin la menor referencia a la probabilidad, y un número entero, $n-k$, que también es geometría: la dimensión del subespacio donde vive el residuo (lección 11). Nada de lo que hay a la derecha es probabilístico. La lectura es directa: el estadístico t compara la longitud del cateto explicado con la del cateto residual. Un cateto explicado largo frente a un residuo corto, es decir, un ángulo θ pequeño, da un $|t|$ grande; un cateto explicado corto frente a un residuo largo, un ángulo próximo a 90°, da un $|t|$ pequeño.

Nótese que la identidad está escrita para $|t|$, no para t: el cociente de longitudes es siempre positivo, mientras que t hereda el signo de $\hat{\beta}_2$. Si $\hat{\beta}_2$ es negativo, el cateto explicado apunta en el sentido opuesto sobre la misma recta $\mathcal{L}(\boldsymbol{x} - \overline{\boldsymbol{x}})$ (el conjunto de todos los múltiplos del regresor en desviaciones; geométricamente, una recta de $\mathbb{R}^n$), y nada más cambia: las longitudes, el ángulo y el valor de $|t|$ son los mismos. Por eso la figura está dibujada con $\hat{\beta}_2 > 0$; el caso $\hat{\beta}_2 < 0$ se lee igual.

La transparencia escribe la misma identidad de una segunda manera, con el R^2 en el lugar de las dos sumas de cuadrados: $t^2 = (n-k)R^2/(1-R^2)$. Se obtiene recordando dos cosas de la lección 8: que $R^2 = \mathrm{SEC}/\mathrm{STC}$ y que $\mathrm{STC} = \mathrm{SEC} + \mathrm{SRC}$ (el teorema de Pitágoras aplicado al triángulo de la figura, en su versión con norma euclídea, sin el factor $1/n$ del producto escalar estadístico). De la segunda, $\mathrm{SRC} = \mathrm{STC} - \mathrm{SEC}$, y dividiendo numerador y denominador por STC:

$$\frac{\mathrm{SEC}}{\mathrm{SRC}} = \frac{\mathrm{SEC}/\mathrm{STC}}{1 - \mathrm{SEC}/\mathrm{STC}} = \frac{R^2}{1-R^2}, \qquad \text{luego} \qquad t^2 = (n-k)\,\frac{R^2}{1-R^2}.$$

Y como $R^2 = \cos^2\theta$, donde $\theta = \measuredangle((\boldsymbol{y} - \overline{\boldsymbol{y}}), (\widehat{\boldsymbol{y}} - \overline{\boldsymbol{y}}))$, resulta que $|t|$ es una función únicamente del ángulo θ y del número $n - k$. No hay ninguna otra información en el estadístico t: dado el ángulo y dados los grados de libertad, $|t|$ está determinado.

Esto tiene una consecuencia práctica, que reaparecerá en la sección "Significación estadística ≠ relevancia económica": un R^2 alto y un $|t|$ alto no son dos resultados independientes que se refuercen mutuamente. Son la misma medida, expresada dos veces. Lo que $|t|$ añade al R^2 no es información sobre la relación, sino el factor $\sqrt{n-k}$: cuántas observaciones respaldan ese ángulo.

Podemos comprobar la identidad con el ejemplo numérico de la lección 8, donde STC = 100, SEC = 90, SRC = 10 y $n = 5$ (con $k = 2$, luego $n - k = 3$):

$$t^2 = 3 \cdot \frac{90}{10} = 27, \qquad |t| = 5{,}20.$$

Y, por la otra vía, $R^2 = 0{,}9$ da $t^2 = 3 \cdot \frac{0{,}9}{0{,}1} = 27$, el mismo número.

Qué cambia con más regresores. Con $k > 2$ el ajuste en desviaciones ya no es un múltiplo de ningún regresor, y la identidad se mantiene cambiando un vector: en el lugar del regresor en desviaciones $\boldsymbol{x} - \overline{\boldsymbol{x}}$ entra la parte del regresor j que no se puede reconstruir con los demás, que la lección 14 definirá y medirá. La "Recapitulación y guiño a las sesiones siguientes" enuncia la fórmula del error estándar que resulta, y la demostración está en el apéndice, sección 5.4 (html). La segunda escritura, con el R^2, no se traslada al t de un coeficiente: pasa al estadístico F de la lección 13, que contrasta todos los coeficientes a la vez.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5 (donde aparece, para el contraste F, la misma relación entre estadísticos de contraste y sumas de cuadrados que aquí hemos obtenido para t).

7 Por qué el valor crítico depende de $n - k$

La identidad anterior separa la significación en *dos* factores: $|t| = \sqrt{n-k} \times \sqrt{\text{SEC}/\text{SRC}} = \sqrt{n-k} \times \sqrt{R^2/(1-R^2)}$, es decir, *cuántas observaciones* × *qué fuerza tiene la relación*.

Con pocas observaciones un ángulo pequeño no prueba nada: en $\mathbb{R}^2$ *todo* par de vectores en desviaciones está alineado ($R^2 = 1$ siempre, $n - k = 0$). En $\mathbb{R}^n$ con n grande, un vector tomado al azar forma, con probabilidad alta, un ángulo próximo a 90° con cualquier dirección fija. Por eso el mismo ángulo de 45° es corriente bajo H_0 con $n = 5$ y muy raro con $n = 500$.

La región crítica es un *cono* alrededor de $\mathcal{L}(\boldsymbol{x} - \overline{\boldsymbol{x}})$ cuya abertura fija t_c: 28,6° con $n - k = 3$, 86,5° con $n - k = 1000$. El mismo vector a 45° queda fuera con $n = 5$ y dentro con $n = 1002$.

Por qué el valor crítico depende de $n - k$

La identidad de "Lectura geométrica: la razón de catetos" descompone la significación estadística en dos factores.[4] Uno es geométrico y describe *la relación*: la razón entre los dos catetos, equivalentemente el ángulo θ, equivalentemente el R^2. El otro es aritmético y describe *el tamaño*

[4] En el apéndice, sección 5.4 (html), la misma identidad se obtiene en una base ortonormal adaptada, y vale para cualquier k con la parte propia del regresor en el lugar del regresor.

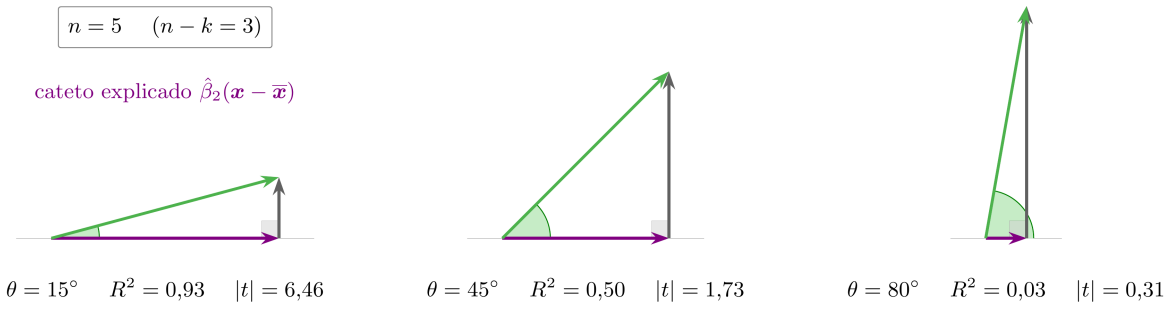


Figura 2: El mismo triángulo con tres aberturas del ángulo θ, con su $R^2 = \cos^2\theta$ y el $|t|$ que resulta con $n = 5$ $(n - k = 3)$, cuyo valor crítico al 5 % es 3,18. La hipotenusa mide lo mismo en los tres paneles: lo único que cambia es el ángulo. Solo el primero resulta significativo al 5 %. Bajo H_0 los tres paneles son posibles: la hipótesis nula no fija el ángulo, sino su distribución (apuntes de esta transparencia).

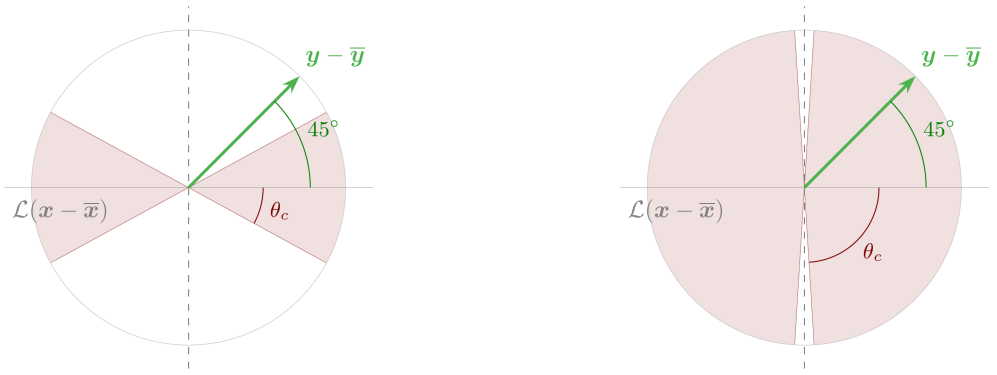


Figura 3: La región crítica al 5 % (sombreada) como un cono alrededor de la recta generada por el regresor en desviaciones, vista en el plano que forman el regresor en desviaciones y el vector de datos en desviaciones. El nivel es el mismo en los dos paneles. A la izquierda, con $n = 5$: la abertura es de 28,6°. A la derecha, con $n = 1002$: la abertura es de 86,5°, casi todo el espacio. El vector de datos en desviaciones forma en los dos paneles el mismo ángulo de 45° con el regresor, y el veredicto es opuesto. La línea vertical a trazos es la dirección ortogonal al regresor; la franja sin sombrear a su alrededor, muy estrecha en el panel derecho, son los ángulos próximos a 90° en los que no se rechaza.

de la muestra: el factor $\sqrt{n-k}$, que solo cuenta observaciones. Un mismo ángulo, con más observaciones, produce un $|t|$ mayor; un mismo número de observaciones, con un ángulo más cerrado,

también. La significación es el producto de ambas cosas, y por eso no puede leerse como si midiera solo una de las dos.

¿Por qué hay que corregir por los grados de libertad? ¿Por qué un ángulo pequeño no basta, por sí solo, para rechazar? La respuesta ya está demostrada en este curso: es el resultado de la lección 5 según el cual *en* $\mathbb{R}^2$ *la correlación es siempre* ± 1. Recordemos el argumento: el subespacio $\mathcal{L}(\mathbf{1})^\perp$, donde viven todos los vectores en desviaciones, tiene dimensión $n-1$, de modo que en $\mathbb{R}^2$ es una simple recta; y dos vectores cualesquiera sobre una recta están forzosamente alineados.

Traduzcamos eso al lenguaje de hoy. Con $n = 2$ observaciones y $k = 2$ coeficientes, la recta de regresión pasa por los dos puntos: el residuo es nulo, $\mathrm{SRC} = 0$, el ángulo θ es $0°$ y $R^2 = 1$. Un ajuste perfecto. ¿Prueba eso una relación entre las variables? No: prueba que dos puntos determinan una recta. Y el aparato construido lo refleja: los grados de libertad son $n-k = 2-2 = 0$, la cuasivarianza $\mathfrak{s}^2 = \mathrm{SRC}/(n-k)$ es un cociente de la forma $0/0$, el error estándar no está definido y el estadístico t no existe. No es que el contraste dé un resultado ambiguo: es que *no hay contraste posible*. Con $n = 3$ ya hay un grado de libertad, y el contraste existe, pero su valor crítico al 5 % es 12,71: H_0 es difícil de rechazar, porque con tres puntos un ángulo pequeño sigue siendo fácil de obtener por azar.

Con esto en mente, la figura de la transparencia se lee así. Los tres paneles tienen la misma hipotenusa y solo cambia el ángulo: con $\theta = 15°$ el R^2 es de 0,93 y $|t| = 6{,}46$, por encima de 3,18 (el valor crítico de la t_3 al 5 %); con $\theta = 45°$, un R^2 de 0,50 ya no basta ($|t| = 1{,}73$); y con $\theta = 80°$ el cateto explicado es casi nulo.

La hipótesis $H_0 : \beta_2 = 0$ tan solo habla del parámetro poblacional, no de la muestra: bajo H_0 pueden darse muestras como las de cualquiera de los tres paneles (aunque con distinta probabilidad). Lo que H_0 fija es el centro de la distribución de $\hat{\beta}_2$: $E[\hat{\beta}_2 \mid \boldsymbol{X}] = 0$ (lección 11), es decir, el cateto explicado, $\hat{\beta}_2(\boldsymbol{x}-\overline{\boldsymbol{x}})$ evaluado sobre la muestra aleatoria, tiene esperanza nula: apunta tan a menudo en un sentido como en el otro, y por eso se promedia a cero; su longitud, que no tiene signo, no (lección 13), y la distribución del ángulo es simétrica alrededor de $90°$ (lo cual no impide que pueda ocurrir un caso como el de la figura de la izquierda). Lo que el contraste mide es cuánto se aleja la muestra de datos de ese centro.

Hay una propiedad de los espacios de dimensión alta que enunciamos sin demostrar: *en* $\mathbb{R}^n$ *con* n *grande, dos direcciones tomadas al azar son casi ortogonales*. Dicho de otra forma: si el vector de datos en desviaciones apunta "a un sitio cualquiera", lo esperable es que forme con la dirección del regresor un ángulo próximo a $90°$, y tanto más próximo cuanto mayor sea n. La lección 13 la hará precisa con el R^2 que regala el azar, y el apéndice (sección 8) (html) la demuestra con normalidad: bajo H_0, $\cos^2\theta$ tiene esperanza $1/(n-1)$. Por eso un ángulo de, digamos, $45°$ es poco informativo con cinco observaciones, porque bajo H_0 sale a menudo, y muy informativo con quinientas, porque bajo H_0 casi nunca ocurre.

Ahora podemos decir qué aporta la normalidad. Hacen falta dos pasos: ver qué es la hipotenusa bajo H_0, en este párrafo, y ver de qué depende entonces la distribución del ángulo, en el siguiente. Partimos del modelo, $Y_i = \beta_1\, 1 + \beta_2 X_i + U_i$. Bajo $H_0 : \beta_2 = 0$ el término $\beta_2 X_i$ desaparece y queda $Y_i = \beta_1\, 1 + U_i$ para cada i: la variable dependiente es la constante β_1 más la perturbación. La media muestral es entonces $\overline{Y} = \beta_1\, 1 + \overline{U}$, y al restarla la constante se cancela: $Y_i - \overline{Y} = U_i - \overline{U}$. Así que, bajo H_0, la hipotenusa del triángulo que vemos, $\boldsymbol{y} - \overline{\boldsymbol{y}}$, es la realización de las perturbaciones

centradas $(U_1-\overline{U},\ldots,U_n-\overline{U})$: no queda rastro de β_1 ni de β_2, solo la perturbación. La consecuencia es que, bajo H_0, el ángulo θ no depende de ningún parámetro: es el ángulo que forman, en $\mathbb{R}^n$, la realización de la perturbación centrada y el regresor en desviaciones, y su distribución, la del ángulo evaluado sobre la muestra aleatoria, es la que dicte la distribución de la perturbación. Ahí es donde entra la normalidad.

El ángulo θ entre esa hipotenusa y la dirección del regresor en desviaciones es una fórmula de datos (lección 5) que, evaluada sobre la muestra aleatoria, es una variable aleatoria (lección 11). Con la base ortonormal de "El supuesto nuevo: normalidad", elegida con su primer vector en la dirección del regresor en desviaciones, $\cos\theta$ es la primera coordenada de la perturbación dividida por la raíz de la suma de los cuadrados de las $n-1$ coordenadas. Como bajo normalidad las $n-1$ coordenadas son independientes y con la misma distribución (isotropía), la distribución de ese cociente no depende de cuál sea la dirección del regresor: solo de cuántas coordenadas entran en el denominador junto a la primera, que son $n-2$, es decir, $n-k$ con $k=2$: la dimensión del subespacio donde vive el residuo. La demostración está en el apéndice (sección 9) (html), donde además se ve que esa distribución, escrita en la escala del estadístico, es la t_{n-k} de "El error estándar, y el precio de estimar σ"; aquí basta con la conclusión: como $|t|$ es $\sqrt{n-k}$ por la razón de catetos, y la razón de catetos decrece cuando el ángulo crece, fijado $n-k$ conocer la distribución del ángulo bajo H_0 es conocer la del estadístico. Por eso los grados de libertad de la t_{n-k} son $n-k$: el número de coordenadas de la perturbación, ortogonales al regresor, hacia las que el ángulo se puede abrir. Sin normalidad las coordenadas siguen siendo ortogonales y de la misma longitud, pero no independientes: la t_{n-k} deja de ser la distribución exacta del estadístico. Qué queda entonces, y por qué con muchas observaciones sigue sirviendo, se explica en "Significación estadística ≠ relevancia económica".

La distribución del ángulo permite leer la región crítica de otra manera. Rechazar H_0 cuando $|t|>t_c$ equivale, por la identidad, a rechazarla cuando el ángulo es menor que un cierto ángulo crítico θ_c. La región crítica está asociada con un *cono* alrededor de la recta generada por el regresor en desviaciones, y el valor crítico t_c determina la *abertura* de ese cono. Lo que hace el contraste es preguntar si el vector de datos en desviaciones ha caído dentro de dicho cono.

La figura pone números a la idea. La abertura del cono se obtiene de la identidad: el ángulo crítico es aquel cuya razón de catetos vale $t_c/\sqrt{n-k}$, con t_c el valor crítico de la t_{n-k} al 5 %. Con $n=5$ ($n-k=3$, $t_c=3{,}18$) sale $\theta_c=28{,}6°$: el cono es estrecho, y hace falta que los datos se alineen mucho con el regresor para rechazar. Con $n=1002$ ($n-k=1000$, $t_c=1{,}96$) sale $\theta_c=86{,}5°$: el cono ocupa casi todo el espacio, y basta un ángulo apenas distinto de la ortogonalidad para rechazar. Los dos paneles muestran el *mismo* vector de datos, a 45° del regresor: fuera del cono en el primer caso (no se rechaza, $|t|=1{,}73$), dentro en el segundo (se rechaza, $|t|=31{,}6$).

Hay que ser cuidadoso al interpretar ese contraste, porque admite dos lecturas y solo una es correcta. La lectura *incorrecta* sería: "con muchas observaciones el contraste es más laxo, rechaza con menos exigencia". No: el contraste mantiene, en los dos paneles, la misma probabilidad de rechazar H_0 siendo cierta, el nivel $\alpha=5\,\%$: eso es lo que significa haber calculado la abertura con t_c. Lo que cambia es que, con mil dos observaciones (figura de la derecha), el azar produce casi siempre ángulos muy próximos a 90°: casi toda la probabilidad (95 %) se concentra en la rendija vertical de la figura, los ángulos próximos a 90° que quedan fuera del cono; de manera que ese amplio cono (con apertura $2\theta_c$) corresponde únicamente al 5 % de los casos. La lectura correcta es:

con muchas observaciones, una desviación muy pequeña de la ortogonalidad ya es estadísticamente detectable.

Que esa desviación sea *económicamente relevante* es otra cuestión, que trata "Significación estadística ≠ relevancia económica".

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.2a (dependencia del valor crítico respecto de los grados de libertad). Fisher, R. A. (1915), "Frequency distribution of the values of the correlation coefficient in samples from an indefinitely large population", *Biometrika* 10, 507-521: el artículo donde la distribución del coeficiente de correlación se obtiene, originalmente, por un argumento geométrico sobre ángulos como el que aquí solo hemos enunciado.

8 El intervalo de confianza

Un *rango* de valores de β_2 que el contraste no rechaza, en vez de un veredicto:

$$\boxed{\left[\ \hat{\beta}_2 - t_c \cdot \mathrm{ee}(\hat{\beta}_2)\ ,\quad \hat{\beta}_2 + t_c \cdot \mathrm{ee}(\hat{\beta}_2)\ \right]}$$

con el mismo t_c del contraste; semiamplitud $t_c \cdot \mathfrak{s}/\|\boldsymbol{x} - \overline{\boldsymbol{x}}\|_e$.

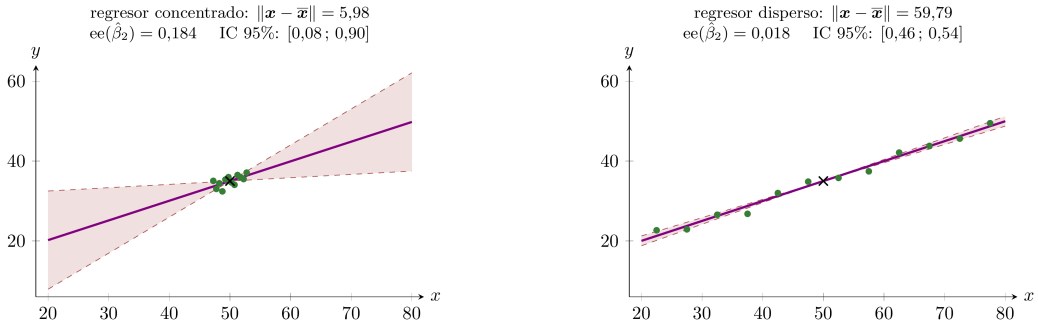


Figura 4: Dos ajustes con *la misma* muestra de perturbaciones, el mismo $n = 12$ y el mismo residuo, y por tanto el mismo $\mathfrak{s} = 1{,}10$. Lo único distinto es cuánto se separan los valores del regresor. La zona sombreada es el haz de rectas cuyas pendientes caen en el intervalo de confianza al 95 %, dibujadas pivotando sobre el punto de las medias, por donde la recta de regresión pasa siempre. Diez veces más largo el regresor en desviaciones, diez veces más estrecho el haz.

Dice: los extremos del intervalo son variables aleatorias, y el suceso "el intervalo contiene a β_2" tiene probabilidad 0,95. *No dice*: que β_2 esté en *este* intervalo con probabilidad 0,95; β_2 no es aleatorio, y estos dos extremos, ya calculados, tampoco.

El intervalo de confianza

El contraste de hipótesis responde sí o no. El intervalo de confianza responde a otra pregunta, "¿bajo qué valores de β_2 no serían demasiado raros datos como estos?", con el "demasiado" fijado por α y con las mismas piezas. Su construcción sale de despejar en la distribución de la sección "El

error estándar, y el precio de estimar σ”: si $(\hat\beta_2-\beta_2)/\mathrm{ee}(\hat\beta_2)$ sigue una t_{n-k}, entonces ese cociente cae entre $-t_c$ y $+t_c$ con probabilidad $1-\alpha$, y despejando β_2 de esa doble desigualdad se obtiene

$$\Big[\ \hat\beta_2 - t_c\cdot\mathrm{ee}(\hat\beta_2)\ ,\quad \hat\beta_2 + t_c\cdot\mathrm{ee}(\hat\beta_2)\ \Big].$$

Es, por tanto, el contraste mismo, formulado como conjunto de valores. Y esa equivalencia es exacta: un valor c queda *fuera* del intervalo de confianza al 95 % si y solo si el contraste de $H_0\colon \beta_2 = c$ se rechaza al 5 %. El intervalo es el conjunto de las hipótesis que *no* se rechazarían. Por eso contiene toda la información del contraste y algo más: no solo dice si el cero se rechaza, sino qué otros valores también, y con qué margen. El apéndice (sección 9, “Del contraste al intervalo”) (html) escribe el suceso “el intervalo contiene a β_2” con las coordenadas de la perturbación y lee su probabilidad $1-\alpha$ como la fracción de columnas de la matriz de copias (la tabla de copias de la lección 11) en las que ocurre: es lo que la práctica C de la sesión 18 (actividad 1 (html)) mide repitiendo muestras.

La semiamplitud del intervalo, la mitad de su anchura (el margen de error de su curso de Estadística), $t_c\cdot\mathfrak{s}/\|\boldsymbol{x}-\overline{\boldsymbol{x}}\|_e$, es el error estándar multiplicado por t_c, y hereda su lectura como cociente de longitudes: longitud del residuo por unidad de longitud del regresor en desviaciones. La figura la hace visible. Toda recta con pendiente dentro del intervalo se ha dibujado pasando por el punto de las medias $(\mu_{\boldsymbol{x}},\mu_{\boldsymbol{y}})$, como toda recta de regresión (lección 7 (html)), y la zona sombreada es el haz de todas ellas, limitado por las dos rectas de pendiente extrema, $\hat\beta_2 \pm t_c\cdot\mathrm{ee}(\hat\beta_2)$. La semiamplitud es, por tanto, una diferencia de pendientes: a una distancia horizontal d del punto de las medias, el haz se abre verticalmente $d\cdot t_c\cdot\mathrm{ee}(\hat\beta_2)$ por encima y por debajo de la recta de regresión, bisectriz del haz, y la semiamplitud es esa abertura por unidad de distancia al punto de las medias. Un intervalo diez veces más estrecho es un haz diez veces más cerrado.

Los dos paneles de la figura comparten todo excepto la dispersión del regresor: los mismos parámetros ($\beta_1 = 10$, $\beta_2 = 0{,}5$), las mismas doce perturbaciones y el mismo vector de residuos, porque el regresor en desviaciones apunta en la misma dirección en los dos casos y solo cambia su longitud.[5] En consecuencia $\mathfrak{s} = 1{,}10$ en ambos, y toda la diferencia procede del denominador: $\|\boldsymbol{x}-\overline{\boldsymbol{x}}\|_e$ vale 5,98 en el panel izquierdo y 59,79 en el derecho. Diez veces más largo el regresor en desviaciones, diez veces más pequeño el error estándar (0,184 frente a 0,018) y diez veces más estrecho el intervalo: [0,08; 0,90] frente a [0,46; 0,54].

Y no es solo el intervalo lo que se estrecha: el error de estimación efectivamente cometido también se divide por diez. La pendiente verdadera es $\beta_2 = 0{,}5$; con el regresor concentrado se estima 0,4931 (error de −0,0069) y con el regresor disperso, 0,4993 (error de −0,00069). El mismo factor de diez que separa las longitudes. La lectura sustantiva es la que importa: *para estimar bien el efecto de una variable hace falta que esa variable varíe*. Si en su muestra todo el mundo tiene aproximadamente la misma educación, no podrá medir con precisión el efecto de la educación sobre el salario, por muy precisas que sean sus mediciones y por muchas observaciones que tenga. Esta idea reaparecerá, con varios regresores, al estudiar la colinealidad.

El panel izquierdo es un ejemplo de una situación frecuente: el contraste rechaza $H_0\colon \beta_2 = 0$ (el cero no está en el intervalo, $|t| = 2{,}68$ frente a un crítico de 2,23), y sin embargo el intervalo

[5] En los dos paneles el regresor toma valores igualmente espaciados alrededor de 50; lo único que cambia es el paso (0,5 frente a 5). Al ser el mismo patrón multiplicado por una constante, el vector en desviaciones tiene la misma dirección y una longitud diez veces mayor, y la proyección de la realización de las perturbaciones sobre esa dirección, y por tanto el residuo, es idéntica. De ahí que SRC y $\mathfrak{s}$ coincidan en ambos paneles, y que toda la diferencia recaiga sobre el denominador del error estándar.

es tan ancho, de 0,08 a 0,90, que apenas informa sobre la magnitud del efecto. Si un resultado así se comunica diciendo solo "el efecto es significativo", se está ocultando lo esencial: que el rango de valores que el contraste no descarta es tan amplio que no sabemos, ni aproximadamente, cuánto vale β_2. Por eso hay que dar el intervalo y no solo el veredicto, sobre todo al leer o escribir un informe.

Su curso de Estadística construyó el intervalo $\bar{x} \pm 1{,}96\,\sigma/\sqrt{n}$ para la media y dio de él la lectura que sigue: el nivel de confianza es del procedimiento, y la probabilidad es anterior a tomar la muestra. El de hoy es ese intervalo con $\hat{\beta}_2$, $\mathrm{ee}(\hat{\beta}_2)$ y t_c en lugar de $\bar{x}$, $\sigma/\sqrt{n}$ y 1,96.

Queda la cuestión de la interpretación, donde es fácil equivocarse. La afirmación correcta es sobre el *procedimiento*, no sobre este intervalo concreto. Evaluada sobre la muestra aleatoria, la receta da un intervalo cuyos extremos, $\hat{\beta}_2 \pm t_c\,\mathrm{ee}(\hat{\beta}_2)$, son variables aleatorias, y lo que garantiza la distribución t_{n-k} es que el suceso "ese intervalo contiene a β_2" tiene probabilidad 0,95. La lectura en términos de repeticiones, "si repitiéramos el muestreo muchas veces, alrededor del 95 % de los intervalos contendrían a β_2", es una consecuencia de esa probabilidad, no su definición. La afirmación incorrecta, y muy tentadora, es "hay un 95 % de probabilidad de que β_2 esté entre 0,46 y 0,54". No tiene sentido en este marco: β_2 es un número fijo y desconocido, no una variable aleatoria, así que no hay ninguna distribución de probabilidad sobre sus valores posibles. Lo aleatorio es el intervalo, cuyos extremos son variables aleatorias, funciones de la muestra aleatoria; no el parámetro. Este intervalo concreto, el que tenemos delante, o contiene a β_2 o no lo contiene; el 0,95 es la probabilidad de que el método acierte, no la de que acierte esta vez.[6] La cobertura de los intervalos, la fracción de ellos que acierta, es lo que comprobaremos con datos simulados en la práctica C de la sesión 18 (actividad 1 (html)).

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.3 (intervalos de confianza y su relación con los contrastes de dos colas).

9 Cómo se lee una tabla de resultados

Toda salida de estimación, de Gretl o de otro programa, tiene para cada regresor las mismas cuatro columnas; los rótulos son los de Gretl en español:

[6] Hay enfoques de la estadística, los llamados bayesianos, en los que sí tiene sentido asignar una distribución de probabilidad a un parámetro desconocido, y en los que existe un objeto (el *intervalo de credibilidad*) del que sí puede decirse "contiene a β_2 con probabilidad 0,95". Son objetos distintos, construidos con supuestos distintos, y a veces numéricamente parecidos. El de este curso es el intervalo de confianza clásico, y su garantía es la que se ha descrito: sobre el procedimiento.

Columna	Qué es	A qué pregunta responde
Coeficiente	$\hat{\beta}_j$	¿de qué *tamaño* es el efecto del regresor x_j sobre el regresando y, en las unidades del problema?
Desv. típica	$\mathrm{ee}(\hat{\beta}_j)$	¿con cuánta *precisión* lo hemos medido?
Estadístico t	el cociente de las dos anteriores	¿a cuántos errores estándar del cero está?
Valor p	$\mathrm{P}(\lvert t_{n-k}\rvert > \lvert t\rvert)$	¿cuán raro sería esto si el efecto fuese nulo?

Las dos últimas se *reconstruyen* a partir de las dos primeras: t = coeficiente / error estándar, y el valor p es una probabilidad calculada con t.

Aviso terminológico: en la salida en español de Gretl, "desviación típica" rotula **tres** cantidades distintas: la de la variable dependiente (dispersión de los datos), la de la regresión ($\mathfrak{s}$) y la de cada coeficiente (su error estándar). En inglés solo la primera es *standard deviation*; las otras dos son *standard error*.

Cómo se lee una tabla de resultados

Todo lo construido hasta aquí se presenta, en la práctica, en forma de tabla: cuatro columnas por regresor, más unas pocas líneas de resumen del modelo. Tomemos como ejemplo el panel derecho de la figura de "El intervalo de confianza", el del regresor disperso, cuya estimación completa es esta:

Regresor	Coeficiente	Desv. típica	Estadístico t	Valor p
constante	10,0343	0,9732	10,31	$1{,}2 \cdot 10^{-6}$
x	0,4993	0,0184	27,14	$1{,}1 \cdot 10^{-10}$

con $n = 12$, $k = 2$, STC = 903,40, SEC = 891,30, SRC = 12,10, $\mathfrak{s} = 1{,}1001$ y $R^2 = 0{,}9866$.

La *primera columna* es el tamaño estimado del efecto del regresor sobre el regresando, en las unidades del problema: cuánto cambia y, en el ajuste, cuando x aumenta una unidad. Aquí, $\hat{\beta}_2 = 0{,}4993$ significa que a un aumento de una unidad de x le corresponde, en el ajuste, un aumento de 0,4993 unidades de y. Es, junto con el error estándar, una de las dos columnas cuyo valor cambia si cambian las unidades de medida: si midiéramos x en centenares (es decir, $x/100$), el coeficiente se multiplicaría por cien (si un metro cuadrado más sube el precio 2 000 euros, cien metros cuadrados más lo suben 200 000).

La *segunda columna* es el error estándar, y responde a una pregunta distinta: no cuánto vale el efecto, sino con cuánta precisión lo hemos medido. Un coeficiente sin su error estándar es un número sin unidades de incertidumbre, y no se puede evaluar.

La *tercera y la cuarta columnas se reconstruyen a partir de las dos primeras*, y añaden su lectura. El estadístico t es el cociente de la primera entre la segunda: a cuántos errores estándar de cero está el coeficiente. El valor p es una probabilidad: la de que la distribución t_{n-k} produzca un valor tan alejado de cero, o más, que el t obtenido, si H_0 fuese cierta. Esa probabilidad disminuye cuando $|t|$ crece, así que, fijados los grados de libertad, a cada $|t|$ le corresponde un único valor p. A

diferencia del coeficiente y de su error estándar, el estadístico t y el valor p *no* cambian si cambian las unidades de medida: el coeficiente y su error estándar se multiplican por el mismo factor y el cociente se conserva. Eso los hace cómodos para comparar y, al mismo tiempo, inservibles para valorar la magnitud del efecto.

El pie de la tabla también informa. El $R^2 = 0{,}9866$ dice, como sabemos desde la lección 8, que el ajuste reproduce el 98,66 % de la variación total de $\boldsymbol{y}$; en el triángulo, el ángulo θ es de unos 6,6°.

El otro número del pie es $\mathfrak{s} = 1{,}1001$, el que Gretl rotula "D.T. de la regresión" ("S.E. of regression" en la salida inglesa). Es la realización del estimador de σ de "El error estándar, y el precio de estimar σ": la longitud del vector de residuos medida con el producto escalar de divisor $n - k$,

$$\mathfrak{s} = \sqrt{\frac{\text{SRC}}{n-k}} = \sqrt{\frac{12{,}10}{10}} = 1{,}1001.$$

Estima la desviación típica σ de la perturbación, es decir, el tamaño típico de lo que separa cada observación de la recta poblacional, y está en las mismas unidades que $\boldsymbol{y}$ porque los residuos lo están. Es, además, el numerador de todos los errores estándar de la tabla: $\text{ee}(\hat{\beta}_2) = \mathfrak{s}/\|\boldsymbol{x} - \overline{\boldsymbol{x}}\|_e = 1{,}1001/59{,}79 = 0{,}0184$, la cifra de la segunda columna.

Un número con unidades no es grande ni pequeño por sí solo: hay que compararlo con algo medido en las mismas unidades, y hay dos comparaciones naturales. En las dos, "perturbación típica" significa una perturbación del tamaño de $\mathfrak{s}$, la desviación típica estimada: ni de las más pequeñas ni de las más grandes. La primera comparación es con la dispersión de $\boldsymbol{y}$: $\mathfrak{s}$ frente a la desviación típica de los datos, $\sqrt{\text{STC}/n}$. Dice qué parte de la variación de $\boldsymbol{y}$ queda sin explicar, y es la misma información que $1 - R^2$. Aquí, 1,10 frente a 8,68: un octavo (Gretl imprime 9,06 en lugar de 8,68 porque divide por $n - 1$; la nota al pie del final de la sección lo explica).

La segunda comparación es con el efecto estimado, y pasa $\mathfrak{s}$ a unidades de x. El coeficiente convierte unidades de x en unidades de y, así que el cociente $\mathfrak{s}/\hat{\beta}_2$ dice cuánto habría que mover x para que el ajuste cambiase tanto como una perturbación típica. La lectura es por comparación con cuánto varía x en la muestra: si x se mueve entre observaciones mucho más que esas unidades, el efecto del regresor domina sobre la perturbación; si se mueve otro tanto, la perturbación pesa tanto como el regresor. Aquí $\mathfrak{s}/\hat{\beta}_2 = 2{,}2$: una perturbación típica equivale al efecto de mover x en 2,2 unidades. En la muestra, la desviación típica de x es de 17,3 unidades, unas ocho veces más. El efecto del regresor a lo largo de la muestra es, por tanto, unas ocho veces mayor que una perturbación típica: la perturbación pesa poco. Esta comparación, en unidades del problema, es la que el R^2 no puede hacer, porque el R^2 es adimensional: un número sin unidades.

Por último, la tabla permite comprobar la identidad de la sección "Lectura geométrica: la razón de catetos": $\sqrt{(n-k)\,\text{SEC}/\text{SRC}} = \sqrt{10 \cdot 891{,}30/12{,}10} = 27{,}14$, que es el $|t|$ de la tabla.

Queda el aviso terminológico, que en español es más necesario que en inglés. En la salida original de Gretl aparecen, en sitios distintos, "S.D. dependent var" (la desviación típica de la variable dependiente: una dispersión de *datos*), "S.E. of regression" (nuestra $\mathfrak{s}$: una estimación de la desviación típica de la *perturbación*) y la columna "Std. Error" de cada coeficiente (el error estándar propiamente dicho: la dispersión de un *estimador*). Son tres cantidades conceptualmente distintas, y la versión española de Gretl rotula las tres como desviación típica: "D.T. de la vble. dep.", "D.T. de la regresión" y, como cabecera de la columna de los errores estándar, "Desv. típica".

La distinción entre *desviación típica* y *error estándar*, que en inglés está en el propio nombre, se pierde. Al leer una salida en español, identifique cada una por su posición, no por su etiqueta.[7]

Una última observación sobre los artículos y los informes ajenos. Muchos no publican las cuatro columnas: es habitual dar el coeficiente y, debajo, entre paréntesis, el error estándar o, en algunas tradiciones, el estadístico t, con asteriscos que codifican niveles de significación. Antes de interpretar nada hay que averiguar qué contiene el paréntesis, porque la diferencia es enorme: un 0,02 bajo un coeficiente de 0,5 significa una estimación muy precisa si es un error estándar, y una estimación pésima si es un estadístico t. La nota al pie de la tabla lo suele decir.[8]

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.6 (cómo se informan los resultados de una regresión, y cómo leer las convenciones habituales de presentación).

10 Significación estadística ≠ relevancia económica

La identidad de la sección "Lectura geométrica: la razón de catetos" lo explica: $|t|$ mezcla *fuerza de la relación* con *tamaño de la muestra*. Tres casos inventados, calculados con la fórmula:

n	R^2	θ	$\lvert t\rvert$	Veredicto al 5 %
3	0,90	18,4°	3,00	no significativo ($t_c = 12{,}71$)
5	0,90	18,4°	5,20	significativo ($t_c = 3{,}18$)
1002	0,01	84,3°	3,18	significativo ($t_c = 1{,}96$)

Mismo ángulo, veredicto opuesto (filas 1 y 2). Y un ángulo de 84° (casi ortogonal, R^2 del 1 %) resulta significativo con mil observaciones (fila 3).

La significación dice si el efecto es *distinguible de cero*, no si es *grande*. Para juzgar si es grande hay que mirar el coeficiente en las unidades del problema, el intervalo de confianza y el R^2, no el $|t|$.

Y tres avisos más: "no rechazar" no es "aceptar"; el valor p no es la probabilidad de que H_0 sea cierta; y nada de todo esto establece causalidad.

Significación estadística ≠ relevancia económica

El contenido de esta transparencia se resume en una frase: *"significativo" no quiere decir "grande"*. Se lee en la identidad que obtuvimos en la sección "Lectura geométrica: la razón de catetos".

[7] Hay una relación entre las dos primeras. La "desviación típica de la variable dependiente" que imprimen los programas es $\sqrt{\mathrm{STC}/(n-1)}$, es decir, la misma fórmula que $\mathfrak{s} = \sqrt{\mathrm{SRC}/(n-k)}$ evaluada en el modelo con un único regresor, la constante ($k = 1$): en ese modelo el ajuste es el vector de medias y el residuo es el vector en desviaciones, luego SRC = STC y $n - k = n - 1$. La "dispersión de los datos" es, por tanto, el caso degenerado de la "dispersión residual" cuando el modelo no aporta nada más que la media. El apéndice (sección 7.2) (html) hace la misma observación desde el otro lado: el divisor $n-1$ de la varianza muestral es el caso $k = 1$ de la insesgadez de $\mathfrak{s}^2$.

[8] Si no lo dice, los propios asteriscos permiten deducirlo, porque marcan los coeficientes con $|t|$ por encima del valor crítico, que ronda el 2. Si el paréntesis contuviera el estadístico t, un coeficiente con asteriscos llevaría en él un número mayor que 2; si lleva uno pequeño, como el 0,02 del ejemplo, el paréntesis es el error estándar, y el t se obtiene dividiendo, $0{,}5/0{,}02 = 25$, que es coherente con los asteriscos. Basta comprobar cuál de las dos lecturas cuadra con las estrellas de la tabla.

Recordémosla: $|t| = \sqrt{n-k} \cdot \sqrt{\text{SEC}/\text{SRC}}$. El estadístico de contraste es el producto de dos factores que miden cosas completamente distintas. El segundo mide la *fuerza de la relación* en la muestra: el ángulo, el R^2, la razón de catetos. El primero solo cuenta *observaciones*. Un $|t|$ grande puede deberse a cualquiera de los dos, y el estadístico no distingue entre ellos: con suficientes observaciones, una relación arbitrariamente débil produce un $|t|$ arbitrariamente grande. Decir "el coeficiente es significativo" es, por tanto, decir algo sobre el producto de los dos factores, no sobre el efecto.

La tabla de la transparencia lleva esa mezcla de los dos factores al extremo con tres casos inventados, calculados con la fórmula a partir de n y R^2, no procedentes de datos. En los tres casos se contrasta la misma hipótesis, $H_0\colon \beta_2 = 0$, la de que el regresor no interviene. Las dos primeras filas tienen el *mismo* R^2 de 0,90 (el mismo ángulo de 18,4°, la misma fuerza de relación en la muestra) y veredictos opuestos: con $n = 3$ el estadístico vale 3,00 frente a un valor crítico de 12,71, y no se rechaza H_0; con $n = 5$ vale 5,20 frente a 3,18, y se rechaza. La tercera fila hace el recorrido inverso: un R^2 del 1 % (un ángulo de 84,3°, prácticamente ortogonal, una relación casi inexistente) lleva a rechazar H_0 al 5 % en cuanto hay mil observaciones. Traduzcamos lo que dice ese R^2: el ajuste reproduce el 1 % de la variación total del regresando, y el 99 % restante queda en el residuo. El efecto es distinguible de cero, pero para entender por qué varía el regresando ese regresor no cuenta casi nada: significativo e irrelevante a la vez. Esta situación es frecuente con las bases de datos grandes de hoy, donde casi cualquier coeficiente resulta significativo y la significación deja, en consecuencia, de aportar información.

¿Qué mirar entonces? Tres cosas, por orden. *Primera*: el coeficiente, en las unidades del problema. La pregunta es si su magnitud es económicamente apreciable. Un efecto de dos céntimos sobre el salario mensual puede ser muy significativo y carecer de interés. Un efecto de doscientos euros puede no ser significativo y merecer toda la atención; en ese caso lo razonable es buscar una muestra mayor y ver si el efecto se sostiene con más datos. Esta lectura del coeficiente recorre el resto del curso: con logaritmos y variables dicotómicas, buena parte del trabajo consiste en saber qué significa $\hat{\beta}_j$ en cada caso (un cambio absoluto, un cambio porcentual, una elasticidad, un desplazamiento). *Segunda*: el intervalo de confianza. Dice de una vez si el efecto es distinguible de cero y con qué margen. El panel izquierdo de la figura de la sección "El intervalo de confianza" era un ejemplo: significativo, pero con un intervalo tan ancho que informa de casi nada. *Tercera*: el R^2. Informa de la fuerza de la relación sin mezclarla con el tamaño de la muestra. Hay que leerlo con la cautela de la lección 8: no mide la calidad del modelo, y un R^2 alto puede ser espurio.

Los tres avisos de la transparencia son los errores de lectura más frecuentes.

"No rechazar" no es "aceptar". Cuando el contraste no rechaza $H_0\colon \beta_2 = 0$, lo correcto es decir que datos como estos no serían raros si β_2 fuese cero; no que β_2 sea cero. La diferencia es la que hay entre "no he encontrado pruebas" y "he probado que no hay nada". Un contraste no rechaza por dos motivos muy distintos: porque el efecto es realmente nulo, o porque la muestra no permite detectarlo (regresor poco disperso, muestra pequeña, perturbación muy dispersa). El intervalo de confianza permite distinguir los dos casos: un intervalo estrecho alrededor del cero es informativo ("si hay efecto, es pequeño"); un intervalo ancho que contiene al cero no dice casi nada. Por eso, ante un resultado no significativo, la pregunta útil no es "¿acepto H_0?" sino "¿qué anchura tiene mi intervalo?".

El valor p no es la probabilidad de que H_0 sea cierta. Es la probabilidad de observar unos datos

al menos tan extremos como los observados *suponiendo que H_0 es cierta*. Las dos cosas se parecen en la redacción y no tienen nada que ver: la primera exigiría una distribución de probabilidad sobre las hipótesis, que en este marco no existe: β_2 es un número fijo, como ya discutimos con el intervalo. Un valor p de 0,03 no significa "hay un 3 % de probabilidad de que el regresor no importe". Significa: "si el regresor no importara, datos como estos aparecerían el 3 % de las veces".

Nada de esto establece causalidad. El contraste t se pronuncia sobre un coeficiente de un ajuste; de si ese coeficiente mide un efecto causal no dice, ni puede decir, nada. Es la misma advertencia de la lección 9, la descomposición ortogonal no implica causalidad, y de la lección 8, donde las correlaciones espurias cumplen la identidad de Pitágoras igual que las relaciones sensatas. Un coeficiente significativo en una relación espuria es igual de significativo. La significación mide cuán raros serían los datos bajo una hipótesis sobre un parámetro; la causalidad es una cuestión ajena, que exige teoría y, sobre todo, un diseño que permita sostenerla.

Un cuarto aviso, que apunta ya a las dos lecciones siguientes. Los contrastes t que hemos construido son *individuales*: cada uno se pronuncia sobre un coeficiente, por separado. Y en regresión múltiple puede ocurrir que ningún coeficiente sea individualmente significativo y que, sin embargo, los regresores en conjunto sí mejoren el ajuste: eso es lo que detecta el contraste F de la lección 13. Suele ser síntoma de que dos o más regresores apuntan en direcciones muy próximas y el ajuste no puede repartir el efecto entre ellos con precisión. Es la colinealidad, a la que dedicaremos la lección 14.

Y, para cerrar, una observación sobre el supuesto de normalidad con el que abrimos la sesión. En la práctica C de la sesión 16 (actividad 2 (html)) vimos que, con $n = 506$, el histograma de las estimaciones parecía normal aunque la perturbación no lo fuera, mientras que con $n = 12$ dejaba de ser normal. El teorema central del límite, el que su curso de Estadística usó para la media muestral, garantiza que, al crecer la muestra, la distribución de $\hat{\beta}_2$ se aproxima a la normal aunque U no sea normal. La consecuencia práctica: en muestras grandes, los contrastes t y los intervalos de confianza de esta lección siguen siendo aproximadamente válidos sin el supuesto de normalidad. En muestras pequeñas, en cambio, ese supuesto es el que sostiene el resultado *exacto*, y si falla, el valor p que imprime el programa puede estar bastante equivocado.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.2f (significación económica frente a significación estadística); y cap. 5, sección 5.2 (normalidad asintótica de MCO y validez aproximada de los contrastes en muestras grandes).

11 Recapitulación y guiño a las sesiones siguientes

Pieza	Fórmula	Lectura geométrica
Error estándar	$\mathfrak{s}/\|\boldsymbol{x}-\overline{\boldsymbol{x}}\|_e$	longitud del residuo por unidad de longitud del regresor
Estadístico t	$\hat{\beta}_2/\mathrm{ee}(\hat{\beta}_2)$	$\sqrt{n-k}\times$ razón de catetos
Grados de libertad	$n-k$	dimensión del subespacio del residuo: coordenadas de la perturbación en $\mathfrak{s}^2$
Región crítica	t fuera de $[-t_c, t_c]$, es decir, $\|t\| > t_c$	cono alrededor de la dirección del regresor
Intervalo de confianza	$\hat{\beta}_2 \pm t_c \cdot \mathrm{ee}(\hat{\beta}_2)$	haz de pendientes no rechazadas

Un solo supuesto nuevo (normalidad); todo lo demás venía de las lecciones 8 y 11.

Lección 13: la misma fórmula, $\frac{\mathrm{SEC}/(k-1)}{\mathrm{SRC}/(n-k)}$, con $k>2$ es el contraste F, que juzga varios regresores a la vez. Con $k=2$, $F=t^2$.

Más adelante: con k regresores, $\mathrm{ee}(\hat{\beta}_j) = \mathfrak{s}/\|\tilde{\boldsymbol{x}}_j\|_e$, donde $\|\tilde{\boldsymbol{x}}_j\|_e$ es la *longitud propia* del regresor j: lo que le queda tras descontar lo que comparte con los demás. Colinealidad.

Recapitulación y guiño a las sesiones siguientes

El único supuesto añadido en esta sesión ha sido la normalidad de la perturbación, y su único cometido ha sido dar *forma* a una distribución cuyos dos primeros momentos ya conocíamos y, con ello, hacer independientes las coordenadas de la perturbación; esa independencia es lo único que distingue la t_{n-k} exacta de una aproximación (apéndice, secciones 8 (html) y 9). Todo lo demás (el triángulo, las sumas de cuadrados, el R^2, la varianza de $\hat{\beta}_2$, la cuasivarianza de los residuos con su divisor $n-k$) estaba ya disponible desde las lecciones 8 y 11.

La tabla resume las cinco piezas y su lectura geométrica. El patrón que las recorre: las cinco se leen en el triángulo de la lección 8, el que forman el vector de datos en desviaciones, el ajuste en desviaciones y el residuo. El error estándar compara la longitud del residuo con la del regresor en desviaciones; el estadístico t compara los dos catetos; el intervalo de confianza traduce esa comparación a un haz de pendientes; los grados de libertad cuentan las direcciones, ortogonales al regresor, hacia las que puede abrirse el ángulo; y la región crítica es un cono alrededor del regresor cuya abertura fija el valor crítico. Toda la inferencia de esta lección se lee en ese triángulo.

Dos hilos quedan abiertos, y los dos salen de la misma identidad.

El primero apunta a la lección siguiente. Hoy hemos visto que $t^2 = (n-k)\,\mathrm{SEC}/\mathrm{SRC}$. Pero lo podemos escribir de otro modo,

$$t^2 = \frac{\mathrm{SEC}/1}{\mathrm{SRC}/(n-k)}\,:$$

la suma explicada dividida por 1, entre la suma residual dividida por sus grados de libertad, $n-k$. Ese 1 es el número de regresores no constantes, es decir, $k-1$ con $k=2$. Escrito con $k-1$ en su sitio, $\dfrac{\mathrm{SEC}/(k-1)}{\mathrm{SRC}/(n-k)}$ es el *estadístico* F: su fórmula es esta misma para cualquier k, y contrasta de

manera simultánea que todos los coeficientes salvo la constante son cero. Con $k = 2$, el F es t^2: el mismo objeto con otro nombre. La figura del triángulo servirá, sin cambios, para la lección 13.

El segundo apunta algo más lejos. Todo lo de hoy se ha demostrado para $k = 2$, con un único regresor no constante, porque solo en ese caso el cateto explicado es un múltiplo del regresor. Con más regresores, la fórmula del error estándar sigue siendo un cociente de longitudes, pero el denominador cambia de una manera muy instructiva: en lugar de la longitud del regresor en desviaciones, aparece la longitud de $\tilde{\boldsymbol{x}}_j$, la parte del regresor j que *no* se puede reconstruir a partir de los demás regresores; la llamaremos la *longitud propia* del regresor. Lo enunciamos aquí; la lección 14 definirá esa parte propia y medirá su longitud, y la demostración está en el apéndice (html), secciones 5.4, 6.5 y 7.1:

$$\mathrm{ee}(\hat{\beta}_j) = \frac{\mathfrak{s}}{\|\tilde{\boldsymbol{x}}_j\|_e}.$$

La lectura es inmediata y anticipa un problema que trataremos con detalle: si el regresor j forma un ángulo muy pequeño con el subespacio generado por los demás, es decir, si apunta casi en la misma dirección que ellos, entonces $\tilde{\boldsymbol{x}}_j$ es muy corto, el error estándar crece mucho y el coeficiente se estima con muy poca precisión. No porque falte información en los datos, sino porque esa información no permite separar el efecto de ese regresor del de los demás regresores. Es la *colinealidad*, y es la traducción, en el lenguaje de los ángulos de este curso, de lo que en "El intervalo de confianza" vimos con un solo regresor: para medir bien el efecto de una variable hace falta que esa variable varíe *por su cuenta*.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5 (el contraste F, con el que arranca la lección siguiente); y cap. 3, sección 3.4 (varianza de los estimadores MCO en regresión múltiple y el papel de la colinealidad).