

Índice general

1	De dónde venimos: los contrastes t son individuales	2
2	La hipótesis conjunta	3
3	El estadístico F	5
4	Lectura geométrica: la misma figura	7
5	El F en una tabla de resultados	9
6	Restricciones lineales: modelos anidados	10
7	Tres restricciones sobre <code>hprice2</code>	14
8	Conjunto $\neq$ individual: el caso de la apertura	15
9	Qué dice y qué no dice el F	16
10	Recapitulación y guiño a las sesiones siguientes	18

Lección 13. El contraste F : significación conjunta

Marcos Bujosa

28 de septiembre de 2026

Resumen

Hoy haremos preguntas sobre varios coeficientes a la vez: ¿aportan algo *en conjunto* estos regresores?, ¿tienen el mismo efecto estas dos variables?, ¿suman uno estos dos coeficientes? Las responde el estadístico F : la razón entre las longitudes al cuadrado de los dos catetos del triángulo de la lección 8, cada una dividida por su dimensión. La segunda mitad enseña a leer el F de una tabla de resultados: qué afirma y qué no.

“Varios coeficientes, una hipótesis: hace falta un estadístico que mire en varias direcciones a la vez.”

- ([slides](#)) — ([html](#)) — ([pdf](#))

1 De dónde venimos: los contrastes t son individuales

La lección 12 juzga *un* coeficiente cada vez, $t = \hat{\beta}_j / \text{ee}(\hat{\beta}_j)$, y demostró (con $k = 2$) que $t^2 = (n - k) \text{SEC}/\text{SRC}$. En el laboratorio anterior, al pie de la tabla de `price` sobre `rooms`, apareció un $F(1, 504) = 472,95$ igual a t^2 .

Un caso real (`hprice2`; `price` sobre `rooms`, `nox` y su logaritmo `lnox`):

Regresor	Coefficiente	Desv. típica	Estadístico t	Valor p
<code>rooms</code>	8161,84	418,34	19,51	10^{-63}
<code>nox</code>	404,19	2198,85	0,18	0,854
<code>lnox</code>	-13262,2	12655,7	-1,05	0,295

¿Sobran `nox` y `lnox`? Cada t , por separado, no lo descarta. Excluirlos a la vez, el F lo rechaza.

Hoy: el F por derecho propio, y la resolución de este caso al final.

De dónde venimos: los contrastes t son individuales

Todo el aparato de la lección 12 (error estándar, intervalo de confianza, contraste t) se pronuncia sobre *un* coeficiente cada vez. Es lo natural cuando la pregunta es “¿interviene este regresor?”, y es lo que hace la tabla de resultados fila a fila. Pero muchas preguntas económicas no son sobre un coeficiente, sino sobre varios a la vez: ¿aportan algo *en conjunto* estos tres regresores?, ¿tienen el mismo efecto estas dos variables?, ¿son compatibles los datos con que la suma de dos coeficientes

Esta obra está bajo una licencia [Creative Commons Atribución-CompartirIgual 4.0 Internacional](#) (CC BY-SA 4.0).

valga uno? Ninguna de ellas se responde con una fila de la tabla. Hoy construimos la herramienta que las responde a todas.

Dos piezas de las sesiones anteriores hacen el trabajo. La primera es la identidad de la lección 12, $t^2 = (n - k) \text{SEC}/\text{SRC}$: el cuadrado del estadístico t es la razón entre las longitudes al cuadrado de los dos catetos del triángulo de la lección 8, multiplicada por la dimensión $n - k$. La segunda es una observación del laboratorio anterior: al pie de toda tabla de regresión Gretl imprime un número rotulado F , y en la regresión simple de `price` sobre `rooms` ese número, 472,95, coincidía con t^2 .¹ Allí dijimos que el F era “el cociente entre la parte explicada y la parte residual, cada una dividida por su número de dimensiones” y que la lección 13 lo convertiría en un contraste por derecho propio. Esa es la lección de hoy.

La tabla de la transparencia es el caso que motiva la sesión. Es una regresión con datos reales (las viviendas de `hprice2` de los laboratorios) del precio mediano sobre tres regresores: el número de habitaciones y *dos* medidas de la contaminación del aire, la concentración de óxidos de nitrógeno `nox` y su logaritmo `lnox`. Los coeficientes de `nox` y `lnox` tienen ambos un valor p muy alto: 0,854 y 0,295. Si uno lee la tabla como enseñó la lección 12, fila a fila, podría asumir que ninguno de los dos interviene y que ambos sobran. Sin embargo, como veremos en la sección “Conjunto $\neq$ individual”, si se quitan *los dos a la vez* el ajuste empeora: la contaminación sí mejora el ajuste. El error está en leer una pregunta sobre dos coeficientes con dos respuestas sobre uno.

Sobre el reparto de la sesión: las cuatro primeras transparencias construyen el contraste F de significación conjunta y lo leen en el triángulo; la quinta lo lee en una tabla de Gretl; la sexta y la séptima lo generalizan a cualquier hipótesis lineal sobre los coeficientes; las dos siguientes lo interpretan, y la décima recapitula.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, introducción a la sección 4.5 (por qué los contrastes t individuales no responden a hipótesis sobre varios coeficientes).

2 La hipótesis conjunta

Significación conjunta: $H_0: \beta_2 = \beta_3 = \dots = \beta_k = 0$ (“ningún regresor aporta nada”) frente a H_1 : al menos uno es distinto de cero.

Geométricamente: bajo H_0 el modelo poblacional se reduce a la constante, y el ajuste que respeta H_0 es el vector de medias $\bar{\mathbf{y}}$. El ajuste completo $\hat{\mathbf{y}}$ siempre se separa de $\bar{\mathbf{y}}$, aunque solo sea por azar. La pregunta es si el subespacio de los regresores acerca $\hat{\mathbf{y}}$ a $\mathbf{y}$ *más de lo esperable por el azar*.

¿Por qué no $k - 1$ contrastes t ? Cada t juzga a su regresor *con los demás dentro del modelo*; “todos no significativos uno a uno” no es “todos nulos a la vez” (la tabla de la apertura).

Cada t mide una sola dirección, la de su regresor. Una hipótesis sobre varios coeficientes pide un estadístico que mida el cateto explicado entero, en su subespacio de dimensión $k - 1$.

¹Práctica A de la sesión 18, [actividad 3 \(html\)](#): tres `printf` comparan t^2 con $(n - k) \text{SEC}/\text{SRC}$ y con el `$Fstat` del modelo, y el bloque `restrict` devuelve el mismo $F(1, 504)$.

La hipótesis conjunta

Un contraste muy frecuente es el de *significación conjunta*, cuya hipótesis nula es: que todos los coeficientes de los regresores no constantes sean cero a la vez, $\beta_2 = \dots = \beta_k = 0$. En términos del modelo poblacional de la lección 10, $Y = \beta_1 1 + \beta_2 X_2 + \dots + \beta_k X_k + U$, dice que ninguno de los regresores interviene: $Y = \beta_1 1 + U$, así que lo mejor que puede hacerse para predecir Y es emplear su media. La hipótesis alternativa es la negación lógica: *al menos uno* de esos coeficientes es distinto de cero. H_1 pide poco: no dice cuál ni cuántos, solo que no son todos nulos.

La traducción geométrica usa el vocabulario de la lección 10. El ajuste $\hat{\mathbf{y}}$ es la proyección de $\mathbf{y}$ sobre $\mathcal{L}(\mathbf{1}, \mathbf{x}_2, \dots, \mathbf{x}_k)$, y el triángulo rectángulo de la lección 8 (hipotenusa $\mathbf{y} - \bar{\mathbf{y}}$, catetos $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ y $\hat{\mathbf{e}}$) sigue existiendo sea cual sea k , como se estudió allí.

Si H_0 fuese cierta, el modelo poblacional no contendría ningún regresor distinto de la constante y el ajuste correspondiente a H_0 sería el vector de medias; consecuentemente, el cateto explicado $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ “debería” ser nulo.²

En la práctica ese cateto no será exactamente cero ni siquiera con H_0 cierta: para que lo fuera debería ocurrir que el vector de datos $\mathbf{y}$ fuera exactamente perpendicular a los vectores de datos que constituyen los regresores del ajuste, y la probabilidad de que eso ocurra es casi nula en la práctica. Por tanto, la pregunta que el contraste tiene que responder es si el cateto explicado es *más largo de lo que cabe esperar que sea por azar* cuando H_0 es cierta. Es la misma pregunta de la lección 12, con una diferencia: allí el cateto explicado vivía en una recta (la del regresor en desviaciones) y aquí vive en un subespacio de dimensión $k - 1$ (el de los $k - 1$ regresores en desviaciones, lección 10).

Para responder no basta con mirar los $k - 1$ contrastes t de la tabla. La razón está en el *contenido* de la hipótesis: cada t contrasta $H_0: \beta_j = 0$ *manteniendo a los demás regresores en el modelo*. Es decir, el t de **nox** pregunta si **nox** aporta algo *además de rooms* y **lnox**, y el de **lnox** pregunta si aporta algo además de **rooms** y **nox**. Ambos pueden responder “no se rechaza $H_0: \beta_j = 0$ ” (es decir, los datos sugieren omitir un regresor si el otro se mantiene) y, sin embargo, el contraste conjunto puede rechazar que sobren los dos a la vez (es decir, los datos sugieren que se deben mantener ambos a la vez). “Todos individualmente nulos” y “todos simultáneamente nulos” son afirmaciones distintas, y la segunda constituye la H_0 para el contraste de *significatividad conjunta*.³

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5 (“Testing multiple linear restrictions”: el planteamiento de la hipótesis conjunta y por qué los t individuales no la contrastan).

²Y la hipotenusa igual al cateto del error: $\mathbf{y} - \bar{\mathbf{y}} = \hat{\mathbf{e}}$.

³Hay una segunda razón, de *probabilidad*. Si se rechazara H_0 conjunta en cuanto alguno de los $k - 1$ contrastes t rechace, la probabilidad de rechazar una H_0 cierta sería mayor que el 5%: el suceso “alguno rechaza” contiene al suceso “el primero rechaza”, que ya tiene probabilidad 0,05, y un suceso no tiene menos probabilidad que otro contenido en él (lección 12). Un contraste conjunto es un único contraste, con un único nivel de significación, sobre la hipótesis que interesa.

3 El estadístico F

Los dos catetos de la lección 8, cada uno dividido por la dimensión del subespacio donde vive ($k - 1$ para el explicado, lección 10; $n - k$ para el residuo, lección 11):

$$F = \frac{\text{SEC}/(k - 1)}{\text{SRC}/(n - k)} \quad (\text{el denominador es } \mathfrak{s}^2).$$

Bajo H_0 la longitud al cuadrado del ruido se reparte, en promedio, por igual entre las dimensiones (homocedasticidad e incorrelación): numerador y denominador estiman los dos σ^2 , y $F \approx 1$. Un F mucho mayor que 1 es evidencia contra H_0 .

Enunciado, no demostrado: bajo H_0 , $F \sim F_{k-1, n-k}$. Se rechaza al nivel α si $F > F_c$, con F_c el valor que deja α en la *cola derecha* (una sola cola: F compara longitudes, no tiene signo). Valor p : $P(F_{k-1, n-k} > F)$.

El estadístico F

La lección 12 dejó el estadístico t escrito como $t^2 = \frac{\text{SEC}/1}{\text{SRC}/(n-k)}$, y en su recapitulación hizo notar que ese 1 es $k - 1$ con $k = 2$. Con $k - 1$ en su sitio, la misma fórmula es el estadístico F :

$$F = \frac{\text{SEC}/(k - 1)}{\text{SRC}/(n - k)}.$$

El curso ya conoce los dos divisores. El denominador, $\text{SRC}/(n - k)$, es la cuasivarianza de los residuos $\mathfrak{s}^2$ de la lección 11: la suma de cuadrados del residuo dividida por la dimensión $n - k$ del subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}_2, \dots, \mathbf{x}_k)^\perp$ donde el residuo vive. El numerador hace lo mismo con el otro cateto: $\text{SEC} = \|\hat{\mathbf{y}} - \bar{\mathbf{y}}\|_e^2$ es la suma de cuadrados del cateto explicado, y $k - 1$ es la dimensión del subespacio donde ese cateto vive, el de los regresores en desviaciones (lección 10). Así que F compara los dos catetos *por dimensión*. La razón de dividir es esta. Si en cada subespacio se toma una base de vectores ortogonales de norma uno, la longitud al cuadrado de un vector es la suma de sus coordenadas al cuadrado (Pitágoras generalizado, lección 10): el cateto explicado suma $k - 1$ coordenadas al cuadrado y el residuo, $n - k$. Un cateto puede ser largo por dos motivos: porque sus coordenadas son grandes o porque son muchas. Dividir por el número de coordenadas deja solo el primero: $\text{SEC}/(k - 1)$ es la media de las coordenadas al cuadrado del cateto explicado y $\text{SRC}/(n - k)$, la del residuo. F es el cociente de esas dos medias, y el párrafo siguiente dice por qué, bajo H_0 , deben parecerse.⁴

¿Por qué sirve ese cociente para contrastar H_0 ? La respuesta es la isotropía de la lección 12, la misma que explicaba por qué el valor crítico depende de $n - k$. La enunciamos sin demostrar. Supongamos H_0 cierta. Entonces el modelo poblacional es $Y = \beta_1 \mathbf{1} + U$ y, como vimos en la lección

⁴Los dos divisores cuentan dimensiones: $k - 1$ las del cateto explicado y $n - k$ las del residuo. Suman $(k - 1) + (n - k) = n - 1$, la dimensión de $\mathcal{L}(\mathbf{1})^\perp$ (lección 4), donde vive el triángulo entero. La misma lectura, longitud al cuadrado por dirección, explica el divisor n del producto escalar estadístico: $\|\mathbf{v}\|_s^2 = \frac{1}{n} \sum_i v_i^2$ es la media de las n coordenadas al cuadrado de $\mathbf{v}$ en $\mathbb{R}^n$, y el vector $\mathbf{1}$ mide 1 porque todas sus coordenadas valen 1. La diferencia está en el espacio donde se cuenta: el producto escalar estadístico cuenta siempre las n direcciones de $\mathbb{R}^n$; $\mathfrak{s}^2$ y el F cuentan las del subespacio donde vive cada vector. Por eso la varianza de $\mathbf{y}$ divide por n y la cuasivarianza $\text{STC}/(n - 1)$ por las $n - 1$ direcciones de $\mathcal{L}(\mathbf{1})^\perp$ (nota de la tabla de resultados, lección 12).

12, $\mathbf{Y} - \bar{Y}\mathbf{1} = \mathbf{U} - \bar{U}\mathbf{1}$: la hipotenusa del triángulo es la realización del vector de perturbaciones centrado. Bajo los supuestos de la lección 12 (homocedasticidad, independencia, normalidad) la distribución de ese vector no privilegia ninguna dirección dentro de $\mathcal{L}(\mathbf{1})^\perp$. Proyectar sobre un subespacio de dimensión d es una operación de $\mathbb{R}^n$ sobre cada realización (lecciones 6 y 10); la longitud al cuadrado de esa proyección, evaluada sobre la muestra aleatoria, es una variable aleatoria (lección 11), y con componentes de varianza σ^2 e incorreladas su esperanza es $d\sigma^2$, sea cual sea el subespacio: el ruido reparte su longitud al cuadrado *por igual* entre las dimensiones. Para esto bastan la homocedasticidad y la incorrelación de la lección 11; la normalidad, como en la lección 12, hará falta para la distribución del cociente.⁵ Aplicado a los dos catetos: bajo H_0 , la longitud al cuadrado del cateto explicado vale en promedio $(k-1)\sigma^2$ y la del residuo, $(n-k)\sigma^2$.⁶ Dividiendo cada una por su dimensión, *numerador y denominador de F estiman ambos σ^2* , y su cociente debe rondar 1. Si H_0 es falsa, el cateto explicado contiene además la parte de $\mathbf{y}$ que cae sobre el subespacio de los regresores y no es ruido, una longitud que no se reparte con el residuo: el numerador crece y F se hace grande. Un F mucho mayor que 1 es evidencia contra H_0 ; un F cercano a 1 (o menor) es compatible con ella.

Para convertir esta idea en un contraste con nivel de significación hace falta saber *cuánto* mayor que 1 es “mucho”, y eso exige la distribución de F bajo H_0 . Igual que en la lección 12 con la t de Student, la enunciamos sin demostrar: bajo H_0 y los supuestos de la lección 12, el estadístico sigue una *distribución F de Fisher-Snedecor con $k-1$ y $n-k$ grados de libertad*, $F_{k-1, n-k}$. Es una distribución que solo toma valores positivos, asimétrica, con media próxima a 1 y una cola derecha larga. Su forma depende de los dos números de grados de libertad, las dos dimensiones de los subespacios donde viven los catetos del triángulo.⁷ La regla de decisión tiene una novedad respecto a la lección 12: la región crítica está en *una sola cola*. Se rechaza H_0 al nivel α si $F > F_c$, donde F_c es el valor de la $F_{k-1, n-k}$ que deja probabilidad α a su derecha. No hay cola izquierda porque F compara longitudes al cuadrado y no tiene signo: un F pequeño dice que el cateto explicado es corto, que es lo que H_0 predice. El valor p es la probabilidad de un valor al menos tan grande como el observado si H_0 fuese cierta, $P(F_{k-1, n-k} > F)$, y Gretl lo imprime al lado del F al pie de cada tabla.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5 (el estadístico F y su distribución bajo la hipótesis nula); apéndice B (distribuciones χ^2 , t y F y la relación $t_\nu^2 = F_{1, \nu}$).




Figura 1: El triángulo de las lecciones 8 y 12, sin cambiar un trazo. En verde, el vector de datos en desviaciones (hipotenusa, longitud $\sqrt{\text{STC}}$); en violeta, el ajuste en desviaciones (cateto explicado, longitud $\sqrt{\text{SEC}}$), que con varios regresores ya no es múltiplo de ninguno de ellos: el eje horizontal es ahora un subespacio de dimensión $k - 1$; en gris, el residuo (cateto residual, longitud $\sqrt{\text{SRC}}$), en un subespacio de dimensión $n - k$. El ángulo θ es el de $R^2 = \cos^2 \theta$. El estadístico F compara los dos catetos, cada uno dividido por su dimensión.

4 Lectura geométrica: la misma figura

$$F = \frac{n - k}{k - 1} \cdot \frac{\text{SEC}}{\text{SRC}} = \frac{n - k}{k - 1} \cdot \frac{R^2}{1 - R^2} : \quad \text{función de } \theta \text{ y de dos dimensiones.}$$

Con $k = 2$: $F = (n - 2) \text{SEC} / \text{SRC} = t^2$, y también $F_c = t_c^2$. El ejemplo de la lección 8 ($n = 5$): $F = \frac{90/1}{10/3} = 27 = t^2$; el valor crítico $F_c(1, 3) = 10,13 = 3,18^2$. Bajo H_0 , por azar, R^2 vale en promedio $(k - 1)/(n - 1)$: ahí $F = 1$ y $\bar{R}^2 = 0$.

Lectura geométrica: la misma figura

La figura es similar a la de la lección 12. Con k regresores el esquema del triángulo rectángulo de la bondad de ajuste (lección 8) se mantiene intacto: $\text{STC} = \text{SEC} + \text{SRC}$ y también se mantiene

⁵No lo demostramos; su versión más elemental ya la conoce: la longitud al cuadrado de un vector de n componentes independientes con varianza σ^2 y media cero vale $n\sigma^2$ en promedio, porque cada componente aporta σ^2 . Proyectar sobre un subespacio de dimensión d deja “ d componentes” de las n , y la incorrelación garantiza que da igual cuáles.

⁶Las palabras “en promedio” esconden el mismo abuso de notación de la lección 11: SEC y SRC son aquí las fórmulas de la lección 8 *evaluadas sobre la muestra aleatoria*, variables aleatorias y no los números de una tabla, y lo que se afirma es $E(\text{SEC}) = (k - 1)\sigma^2$ bajo H_0 y $E(\text{SRC}) = (n - k)\sigma^2$. La segunda igualdad es, dicho de otro modo, la insesgadez de s^2 que la lección 11 enunció; y vale con o sin H_0 , porque el residuo no cambia por que los regresores aporten algo o no.

⁷Su prueba exige la distribución χ^2 de cada suma de cuadrados y la independencia entre ambas, el mismo aparato que la lección 12 declinó desarrollar para la t . De hecho, la t_{n-k} y la $F_{1, n-k}$ son la misma distribución mirada de dos maneras: si $T \sim t_{n-k}$, entonces $T^2 \sim F_{1, n-k}$. Es la versión distribucional de $F = t^2$ que veremos en la transparencia siguiente.

que $R^2 = \cos^2 \theta$. El motivo es que el residuo MCO siempre es ortogonal a el subespacio de los regresores; así que, en particular, $\hat{e} \perp \hat{\mathbf{y}} - \bar{\mathbf{y}}$ puesto que los vectores $\hat{\mathbf{y}}$ y $\bar{\mathbf{y}}$ son combinación lineal de los regresores. Lo único que cambia en esta figura respecto a la lección anterior es el eje horizontal: el cateto explicado ya no es un múltiplo del regresor no constante en desviaciones, porque ahora hay $k - 1$ regresores y $\hat{\mathbf{y}} - \bar{\mathbf{y}}$ es una combinación de todos ellos que, en general, no está alineada con ninguno (lección 10). La recta horizontal representa aquí un subespacio de dimensión $k - 1$ (y en la lección anterior correspondía únicamente a los múltiplos del regresor no constante en desviaciones $(\mathbf{x} - \bar{\mathbf{x}})$).

Escribamos F en términos del triángulo. Sacando los divisores fuera,

$$F = \frac{\text{SEC}/(k - 1)}{\text{SRC}/(n - k)} = \frac{n - k}{k - 1} \cdot \frac{\text{SEC}}{\text{SRC}},$$

y como $\text{SEC}/\text{SRC} = R^2/(1 - R^2)$,⁸

$$F = \frac{n - k}{k - 1} \cdot \frac{R^2}{1 - R^2}.$$

Es la misma estructura que la identidad de la lección 12 con un factor distinto: allí $t^2 = (n - k) R^2/(1 - R^2)$; aquí el $n - k$ se divide además por $k - 1$. En los dos casos el estadístico es una función únicamente del ángulo θ (vía $R^2 = \cos^2 \theta$) y de las dimensiones de los subespacios donde viven los catetos. Y en los dos casos vale la misma lectura: *el contraste no mide nada que el R^2 no midiera ya*; lo que añade es el factor que cuenta cuántas dimensiones respaldan ese ángulo. Un R^2 dado es tanto más sorprendente cuantas más observaciones haya ($n - k$ grande) y cuantos *menos* regresores se hayan usado para conseguirlo ($k - 1$ pequeño).

La razón está en cuánto R^2 produce el azar por sí solo. Bajo H_0 el vector de datos en desviaciones no tiene ninguna dirección preferida dentro de $\mathcal{L}(\mathbf{1})^\perp$, que tiene dimensión $n - 1$.⁹ Tomemos en ese espacio una base ortonormal cuyos $k - 1$ primeros vectores generen el subespacio de los regresores en desviaciones. La longitud al cuadrado del vector de datos, STC, es la suma de los cuadrados de sus $n - 1$ coordenadas, y por simetría cada coordenada se lleva en promedio la misma fracción, $1/(n - 1)$. El cateto explicado, SEC, es la suma de las $k - 1$ primeras. Así que, cuando H_0 es cierta, $R^2 = \text{SEC}/\text{STC}$ vale en promedio $(k - 1)/(n - 1)$: ese es el R^2 que se obtiene sin que los regresores tengan nada que ver con el regresando. Crece con el número de regresores, porque cada regresor añadido aporta una coordenada más al cateto explicado; y decrece con n , porque el mismo número de coordenadas es una fracción menor del total. Un R^2 de 0,30 dice cosas distintas con $n = 11$ y $k = 4$, donde el azar da 0,30 en promedio, que con $n = 101$ y $k = 2$, donde el azar da 0,01.

El estadístico F compara el R^2 observado con esa referencia: sustituyendo $R^2 = (k - 1)/(n - 1)$ en la fórmula sale $F = 1$ exactamente. Y es la misma referencia que usa el R^2 ajustado de la práctica que siguió a la lección 10: $\bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-k}$ vale cero en ese mismo punto. Las dos herramientas descuentan lo mismo, el ajuste que el azar regala por cada regresor; el $\bar{R}^2$ lo hace para comparar modelos y el F para decidir si lo que sobra de ese descuento es demasiado para ser casualidad. Con $k = 2$ la referencia es $1/(n - 1)$, y eso explica la propiedad que la lección 12

⁸Dividiendo numerador y denominador por STC y usando Pitágoras (lección 12).

⁹Ese es aquí el papel de la normalidad: garantiza que, bajo H_0 , el vector de perturbaciones en desviaciones no favorece ninguna dirección de $\mathcal{L}(\mathbf{1})^\perp$.

enunció sin demostrar: que en dimensión alta dos direcciones tomadas al azar son casi ortogonales. Con un solo regresor el subespacio de los regresores en desviaciones es una recta, y $R^2 = \cos^2 \theta$ es el cuadrado del coseno del ángulo entre el vector de datos en desviaciones y esa recta. Ese cuadrado vale en promedio $1/(n-1)$ porque la recta es una sola de las $n-1$ direcciones ortonormales entre las que el vector reparte su longitud al cuadrado, y las otras $n-2$ se quedan con el resto. Cuantas más observaciones, más direcciones compiten con la del regresor y menor es la parte que le toca. Un ángulo pequeño con una dirección fija exige que casi toda la longitud caiga precisamente en ella, y el azar no tiene ningún motivo para hacerlo. Los números: con $n=5$ el promedio de $\cos^2 \theta$ es $1/4$, el de un ángulo de 60° ; con $n=1002$ es $1/1001$, el de un ángulo de $88,2^\circ$. Es la figura del cono de la lección 12: con mil observaciones casi todo el azar cae en la rendija vertical. La conclusión: con muchos datos, H_0 se rechaza en cuanto el ángulo se desvía ligeramente de los 90° , porque con H_0 cierta el azar casi nunca produce ni siquiera esa pequeña desviación. Un R^2 minúsculo basta entonces para rechazar.

El caso $k=2$ es el de la lección 12. Con un único regresor no constante, $k-1=1$ y la fórmula se reduce a $F = (n-2) \text{SEC}/\text{SRC}$, que es t^2 . También coincide el valor crítico, porque la $F_{1,n-k}$ es la distribución del cuadrado de una t_{n-k} , de modo que $F_c = t_c^2$ y las dos reglas de decisión rechazan en los mismos casos. Es lo que el laboratorio anterior verificó sobre `hprice2` con `restrict`, y lo que el ejemplo de juguete de la lección 8 permite comprobar con números redondos: $\text{SEC} = 90$, $\text{SRC} = 10$, $n = 5$, luego $F = (90/1)/(10/3) = 27$, el mismo $t^2 = 27$ de la lección 12; y el valor crítico al 5 % de la $F_{1,3}$ es 10,13, el cuadrado del 3,18 de la t_3 . Se rechaza por las dos vías, y por el mismo margen.

También la región crítica se lee igual que en la lección 12: rechazar cuando $F > F_c$ equivale a rechazar cuando el ángulo θ es menor que un ángulo crítico θ_c (un *cono* alrededor del subespacio de los regresores en desviaciones), y la abertura de ese cono depende de las dos dimensiones. Con los números de la transparencia siguiente ($n=506$, $k=4$), la abertura al 5 % es de $82,9^\circ$: casi todo el espacio, por la misma razón que en la lección 12: en dimensión alta el azar solo produce ángulos próximos a 90° .

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5, apartado “The R -squared form of the F statistic”.

5 El F en una tabla de resultados

`hprice2`: `price` sobre `rooms`, `nox` y `stratio` (el modelo de la [actividad 3 \(html\)](#) de la práctica sobre `hprice2` que siguió a la lección 10).

Regresor	Coefficiente	Desv. típica	Estadístico t
constante	9458,01	4371,41	2,16
<code>rooms</code>	7000,63	409,15	17,11
<code>nox</code>	-1693,33	236,25	-7,17
<code>stratio</code>	-1166,96	128,76	-9,06

$n = 506$, $k = 4$, $R^2 = 0,6005$, $\text{SRC} = 1,711 \cdot 10^{10}$, $\text{SEC} = 2,572 \cdot 10^{10}$, $s = \sqrt{\text{SRC}/(n-k)} = 5837,8$ (la “D.T. de la regresión” de Gretl); al pie: $F(3, 502) = 251,5$, valor $p = 1,3 \cdot 10^{-99}$.

Lectura: $F = 251,5$ dice que, por dimensión, el cateto explicado tiene una longitud al cuadrado

doscientas cincuenta veces mayor que la del residuo; si H_0 fuese cierta esa razón debería rondar 1. Frente a $F_c(3, 502) = 2,62$ al 5 %, se rechaza que los tres coeficientes sean cero a la vez. *No dice*: cuáles importan, ni cuánto.

El F en una tabla de resultados

Toda tabla de regresión de Gretl termina con dos líneas de resumen que, hasta hoy, habíamos leído solo en parte: el R^2 y la desviación típica de la regresión $\mathfrak{s}$ (lección 12), y a su lado un “ $F(k - 1, n - k)$ ” con su valor p . Ese F es el estadístico de significación conjunta de esta lección: contrasta, automáticamente y para cualquier modelo que se estime, la hipótesis de que todos los coeficientes de los regresores no constantes son cero a la vez. Los dos números entre paréntesis se denominan *grados de libertad* y son las dimensiones de los subespacios donde viven los catetos del triángulo.

Tomemos el modelo de la [actividad 3 \(html\)](#) de la práctica sobre `hprice2` que siguió a la lección 10, el precio mediano de la vivienda sobre el número de habitaciones, la contaminación y la ratio alumnos/profesor del distrito. Con $n = 506$ y $k = 4$ (tres regresores más la constante), las dimensiones son $k - 1 = 3$ y $n - k = 502$. Todo lo que hace falta para reconstruir el F está en la tabla o sale de ella con la lección 8: SRC lo imprime Gretl; STC se obtiene de $R^2 = 1 - \text{SRC}/\text{STC}$, y $\text{SEC} = \text{STC} - \text{SRC} = 2,572 \cdot 10^{10}$. Dividiendo cada cateto por su dimensión, el numerador vale $8,573 \cdot 10^9$ y el denominador $3,408 \cdot 10^7$, que es $\mathfrak{s}^2 = 5837,8^2$, como debe. El cociente es 251,5, el F de la tabla. Por la otra vía, $\frac{502}{3} \cdot \frac{0,6005}{0,3995} = 251,5$, el mismo número.

El valor crítico de la $F_{3,502}$ al 5 % es 2,62, y al 1 %, 3,82; el estadístico observado es cien veces mayor y el valor p es del orden de 10^{-99} . Se rechaza H_0 : datos como estos serían muy raros si `rooms`, `nox` y `stratio` tuvieran, a la vez, coeficiente nulo. La magnitud también se lee: $F = 251,5$ dice que, por dimensión, el cateto explicado tiene una longitud al cuadrado doscientas cincuenta veces mayor que la del residuo; si H_0 fuese cierta esa razón debería rondar 1.

Y lo que el F *no* dice, que la sección “Qué dice y qué no dice el F ” desarrollará. Rechazar $H_0: \beta_2 = \beta_3 = \beta_4 = 0$ es rechazar que *los tres* sean nulos a la vez; es compatible con que dos de ellos lo sean. El F conjunto no señala a ningún regresor en particular, ni dice nada de la magnitud de los efectos: para eso están las columnas de la tabla y los intervalos de confianza de la lección 12.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5, apartado “The F statistic for overall significance of a regression”; y sección 4.6 (cómo se presentan los resultados, incluido el F).

6 Restricciones lineales: modelos anidados

Imponer q restricciones lineales sobre los β (excluir, igualar, fijar) obliga al ajuste a vivir en un subespacio *menor* del de los regresores. Proyectar sobre él aleja el ajuste de $\mathbf{y}$: ajuste restringido $\hat{\mathbf{y}}_r$, con $\text{SRC}_r \geq \text{SRC}$.

$$F = \frac{(\text{SRC}_r - \text{SRC})/q}{\text{SRC}/(n - k)} \sim F_{q, n-k} \text{ bajo } H_0 \quad (\text{conjunta: } \hat{\mathbf{y}}_r = \bar{\mathbf{y}}, q = k - 1).$$




Figura 2: Izquierda: el subespacio de los regresores y , dentro de él, el subespacio restringido; $\hat{y}$ es la “sombra” de y sobre el plano y $\hat{y}_r$ su “sombra” sobre la recta, más lejos de y . Derecha: el triángulo sombreado visto de frente, con el ajuste restringido en el papel del vector de medias: hipotenusa $\sqrt{\text{SRC}_r}$, catetos $\sqrt{\text{SRC}_r - \text{SRC}}$ (en las q direcciones del plano de los regresores ortogonales al subespacio restringido) y $\sqrt{\text{SRC}}$. El ángulo recto es $\hat{y} - \hat{y}_r \perp \hat{e}$, de donde $\text{SRC}_r = \text{SRC} + \|\hat{y} - \hat{y}_r\|_e^2$. Con $\hat{y}_r = \bar{y}$ es la figura anterior.

Restricciones lineales: modelos anidados

Empecemos por la geometría, porque es lo que permite tratar con una única herramienta todas las hipótesis de esta sección. Imponer q restricciones lineales sobre los coeficientes (excluir un regresor, igualar dos coeficientes, fijar un valor) equivale a exigir que el ajuste sea una combinación lineal de los regresores *de un tipo particular*. El conjunto de esas combinaciones es un subespacio menor que $\mathcal{L}(\mathbf{1}, \mathbf{x}_2, \dots, \mathbf{x}_k)$, contenido en él, con q dimensiones menos.¹⁰ El *ajuste restringido* $\hat{y}_r$ es la proyección de y sobre ese subespacio menor (lo que Gretl calcula al estimar, por ejemplo, el modelo sin `nox` ni `stratio` a la vez), y su suma de cuadrados residual, $\text{SRC}_r = \|y - \hat{y}_r\|_e^2$, es necesariamente mayor o igual que la del modelo completo: proyectar sobre un subespacio más pequeño nunca acerca más. Es la propiedad que la lección 8 anunció como “ R^2 nunca empeora al añadir regresores” y que la práctica del R^2 ajustado hizo explícita: quitar regresores nunca reduce SRC. La figura de la izquierda en la transparencia, repetida aquí más grande, lo muestra: el plano es el subespacio de los regresores; la recta dentro de él representa el subespacio restringido; $\hat{y}$ es la “sombra” de y sobre el plano y $\hat{y}_r$ su “sombra” sobre la recta, más lejos de y .

Con esa imagen delante, la definición general. Una *hipótesis lineal* es un sistema de q ecuaciones lineales sobre los coeficientes del modelo poblacional, y el ajuste pierde una dimensión por cada ecuación. Tres ejemplos que reaparecerán con números en la transparencia siguiente: excluir dos regresores a la vez, $\beta_3 = \beta_4 = 0$ ($q = 2$); excluir uno solo, $\beta_4 = 0$ ($q = 1$, el contraste t de siempre); y una hipótesis que no excluye a nadie, sino que relaciona dos coeficientes, $\beta_3 = \beta_4$ ($q = 1$). Otras fijan un valor (una elasticidad unitaria, $\beta_2 = 1$) o una suma (rendimientos constantes a escala,

¹⁰Con $\beta_3 = \beta_4 = 0$, el subespacio restringido es $\mathcal{L}(\mathbf{1}, \mathbf{x}_2)$: hemos perdido dos generadores. Con $\beta_3 = \beta_4$, es $\mathcal{L}(\mathbf{1}, \mathbf{x}_2, \mathbf{x}_3 + \mathbf{x}_4)$: la combinación $\beta_3 \mathbf{x}_3 + \beta_4 \mathbf{x}_4$ con $\beta_3 = \beta_4$ es $\beta_3(\mathbf{x}_3 + \mathbf{x}_4)$, así que los dos regresores se funden en uno y se pierde una dimensión. Las restricciones que fijan un valor, como $\beta_2 = 1$, dan un conjunto que no pasa por el origen (un subespacio *trasladado* por $\mathbf{x}_2$); el argumento que sigue vale igual, porque lo único que usa es que los dos ajustes están en $\mathcal{L}(\mathbf{1}, \mathbf{x}_2, \dots, \mathbf{x}_k)$.




Figura 3: Los dos subespacios. El plano es $\mathcal{L}(\mathbf{1}, \mathbf{x}_2, \dots, \mathbf{x}_k)$; la recta, dentro de él, es el subespacio restringido. $\mathbf{y}$ está fuera del plano; $\hat{\mathbf{y}}$ es su “sombra” sobre el plano y $\hat{\mathbf{y}}_r$ su “sombra” sobre la recta. El triángulo sombreado es el de la transparencia, visto desde fuera del plano.

$\beta_2 + \beta_3 = 1$, que veremos al hablar de la función de producción). La significación conjunta de las transparencias anteriores es solo una de ellas, y no siempre la más interesante: su subespacio restringido es $\mathcal{L}(\mathbf{1})$.

En términos de este esquema geométrico, la pregunta del contraste es *cuánto* crece SRC al imponer las restricciones. Si H_0 es cierta, el modelo restringido es el verdadero y el aumento $\text{SRC}_r - \text{SRC}$ es solo la parte del ruido que recogían por azar las q direcciones del plano de los regresores ortogonales al subespacio restringido, las que el modelo completo tiene y el restringido no. Si H_0 es falsa, las restricciones le quitan al ajuste algo que sí lo acercaba a $\mathbf{y}$, y el aumento es grande. Para medirlo hace falta el resultado que hoy demostramos:

Proposición (Pitágoras anidado). Los dos ajustes cumplen $\hat{\mathbf{y}} - \hat{\mathbf{y}}_r \perp \hat{\mathbf{e}}$, y por tanto

$$\text{SRC}_r = \text{SRC} + \|\hat{\mathbf{y}} - \hat{\mathbf{y}}_r\|_e^2.$$

Demostración. El ajuste restringido $\hat{\mathbf{y}}_r$ es una combinación lineal de los regresores (de un tipo particular), luego pertenece a $\mathcal{L}(\mathbf{1}, \mathbf{x}_2, \dots, \mathbf{x}_k)$; y $\hat{\mathbf{y}}$ también. Su diferencia está, por tanto, en ese subespacio, y el residuo del modelo completo es ortogonal a todo él (lección 10: $\hat{\mathbf{e}}\mathbf{X} = \mathbf{0}$). Así que $\hat{\mathbf{y}} - \hat{\mathbf{y}}_r \perp \hat{\mathbf{e}}$. Ahora escribimos el residuo restringido como suma de dos vectores ortogonales:

$$\mathbf{y} - \hat{\mathbf{y}}_r = (\hat{\mathbf{y}} - \hat{\mathbf{y}}_r) + (\mathbf{y} - \hat{\mathbf{y}}) = (\hat{\mathbf{y}} - \hat{\mathbf{y}}_r) + \hat{\mathbf{e}}.$$

Aplicando el teorema de Pitágoras de la lección 3, $\|\mathbf{y} - \hat{\mathbf{y}}_r\|_e^2 = \|\hat{\mathbf{y}} - \hat{\mathbf{y}}_r\|_e^2 + \|\hat{\mathbf{e}}\|_e^2$, que es la igualdad anunciada. ■

La figura hace visible un hecho más: $\hat{\mathbf{y}}_r$ es también la proyección de $\hat{\mathbf{y}}$ sobre el subespacio restringido. Llamemos $\mathbf{v}_r$ a la “sombra” de $\hat{\mathbf{y}}$ sobre ese subespacio: es el vector del subespacio restringido tal que $\hat{\mathbf{y}} - \mathbf{v}_r$ es ortogonal a dicho subespacio (la condición de ortogonalidad que caracteriza la proyección, lecciones 6 y 10). Ahora bien, $\mathbf{y} - \mathbf{v}_r = (\mathbf{y} - \hat{\mathbf{y}}) + (\hat{\mathbf{y}} - \mathbf{v}_r)$, y los dos sumandos son ortogonales al subespacio restringido: el primero porque $\hat{\mathbf{e}}$ es ortogonal a todo el plano y el subespacio restringido es una parte del plano; el segundo por la definición de $\mathbf{v}_r$. Luego $\mathbf{y} - \mathbf{v}_r$ es ortogonal al subespacio restringido, y como $\mathbf{v}_r$ está en él, $\mathbf{v}_r$ es la “sombra” de $\mathbf{y}$: es decir, $\mathbf{v}_r = \hat{\mathbf{y}}_r$. Así que $\mathbf{y}$ y $\hat{\mathbf{y}}$ tienen la misma “sombra” sobre el subespacio restringido. La proyección puede hacerse en dos pasos, primero sobre el plano y después sobre la recta.

Fíjese que la figura marca tres ángulos rectos, y cada uno tiene su lectura. Uno está en el punto donde termina el vector $\hat{\mathbf{y}}$, que es donde acaba el cateto $\hat{\mathbf{y}} - \hat{\mathbf{y}}_r$ y empieza el cateto $\hat{\mathbf{e}}$: es el ángulo recto del triángulo sombreado, y es recto porque el primer cateto está en el plano y el segundo es ortogonal a todo el plano. Los otros dos están en el punto donde termina el vector $\hat{\mathbf{y}}_r$, y en ambos uno de los catetos está sobre la recta del subespacio restringido. El que forma con $\hat{\mathbf{y}} - \hat{\mathbf{y}}_r$ es la condición de ortogonalidad que define a $\hat{\mathbf{y}}_r$ como “sombra” de $\hat{\mathbf{y}}$; el que forma con $\mathbf{y} - \hat{\mathbf{y}}_r$ es lo que acabamos de demostrar, que $\hat{\mathbf{y}}_r$ es también la “sombra” de $\mathbf{y}$. El primero de esos dos dice además en qué subespacio está $\hat{\mathbf{y}} - \hat{\mathbf{y}}_r$: en el de los vectores del plano de los regresores ortogonales al subespacio restringido. Ese subespacio tiene dimensión q y es el eje horizontal del triángulo de la derecha de la transparencia.

Volvamos al Pitágoras anidado. La proposición es la de la lección 8 ($\text{STC} = \text{SEC} + \text{SRC}$) con el vector de medias sustituido por el ajuste restringido, y la figura de la transparencia es la de la lección 8 con esa sustitución: hipotenusa $\mathbf{y} - \hat{\mathbf{y}}_r$, catetos $\hat{\mathbf{y}} - \hat{\mathbf{y}}_r$ y $\hat{\mathbf{e}}$. El aumento de la suma de cuadrados residual al imponer las restricciones es la longitud al cuadrado del cateto $\hat{\mathbf{y}} - \hat{\mathbf{y}}_r$: $\text{SRC}_r - \text{SRC} = \|\hat{\mathbf{y}} - \hat{\mathbf{y}}_r\|_e^2$. Ese cateto es lo que el ajuste completo añade al restringido, porque $\hat{\mathbf{y}} = \hat{\mathbf{y}}_r + (\hat{\mathbf{y}} - \hat{\mathbf{y}}_r)$, y pertenece al subespacio de dimensión q del párrafo anterior, el de los vectores del plano de los regresores ortogonales al subespacio restringido. Así que ese cateto tiene q dimensiones, igual que el residuo tiene $n - k$. Con esto, el estadístico se construye igual que el de significación conjunta, cada cateto dividido por su dimensión:

$$F = \frac{(\text{SRC}_r - \text{SRC})/q}{\text{SRC}/(n - k)} = \frac{\|\hat{\mathbf{y}} - \hat{\mathbf{y}}_r\|_e^2/q}{s^2}.$$

El mismo reparto por dimensión de la sección “El estadístico F ” hace que, bajo H_0 , numerador y denominador estimen ambos σ^2 . Su distribución bajo H_0 , que enunciamos sin demostrar, es la $F_{q, n-k}$, y la regla es la de siempre: rechazar si $F > F_c$. La significación conjunta es el caso particular en que el subespacio restringido es $\mathcal{L}(\mathbf{1})$: entonces $\hat{\mathbf{y}}_r = \bar{\mathbf{y}}$, $\text{SRC}_r = \text{STC}$, el aumento es SEC y $q = k - 1$. Las transparencias anteriores trataban este caso.

El nombre habitual: los dos modelos están *anidados*, el restringido dentro del completo, y el F compara el ajuste del pequeño con el del grande. Cualquier par de modelos anidados, es decir, cualquier hipótesis lineal, se contrasta con la misma receta: estimar los dos, leer las dos sumas de cuadrados residuales, contar q y $n - k$.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5 (“Testing exclusion restrictions” y “Testing general linear restrictions”); y sección 4.4 (contraste de una única combinación lineal de coeficientes, el caso $q = 1$).

7 Tres restricciones sobre hprice2

Modelo completo: **price** sobre **rooms**, **nox** y **stratio** ($\text{SRC} = 1,711 \cdot 10^{10}$, $n - k = 502$, $\mathfrak{s}^2 = \text{SRC}/(n - k) = 3,408 \cdot 10^7$). En Gretl: menú **Contrastes** -> **Restricciones lineales** o el comando **restrict** del laboratorio anterior.

H_0	q	$\text{SRC}_r - \text{SRC}$	F	F_c al 5 %	Veredicto
$\beta_{\text{nox}} = \beta_{\text{stratio}} = 0$	2	$4,985 \cdot 10^9$	73,1	3,01	se rechaza ($p = 10^{-28}$)
$\beta_{\text{stratio}} = 0$	1	$2,799 \cdot 10^9$	82,1	3,86	se rechaza; $82,1 = (-9,06)^2$
$\beta_{\text{nox}} = \beta_{\text{stratio}}$	1	$1,213 \cdot 10^8$	3,56	3,86	no se rechaza ($p = 0,060$)

La segunda fila es el contraste t de la tabla, al cuadrado. La tercera *no* es de exclusión: el modelo restringido regresa **price** sobre **rooms** y la *suma* **nox** + **stratio**: otro subespacio, no menos regresores.

Tres restricciones sobre hprice2

Los tres contrastes de la tabla se hacen sobre el mismo modelo completo de la sección “El F en una tabla de resultados”, de modo que el denominador es siempre el mismo: $\text{SRC}/(n - k) = \mathfrak{s}^2 = 3,408 \cdot 10^7$. Lo que cambia de fila a fila es el numerador, es decir, el modelo restringido que se compara.

Primera fila: dos exclusiones a la vez, $H_0: \beta_{\text{nox}} = \beta_{\text{stratio}} = 0$. El modelo restringido es la regresión simple de **price** sobre **rooms** que arrastramos desde el laboratorio que siguió a la lección 8, con $\text{SRC}_r = 2,209 \cdot 10^{10}$. El aumento al quitar los dos regresores es $4,985 \cdot 10^9$, que repartida entre $q = 2$ dimensiones y dividida por $\mathfrak{s}^2$ da $F = 73,1$, frente a un valor crítico $F_c(2, 502) = 3,01$. Se rechaza: la contaminación y la ratio alumnos/profesor añaden, juntas, mucho más de lo que dos direcciones de azar suelen añadir. Es la respuesta a la pregunta “¿sobran estas dos variables?”, que ningún t individual formula.

Segunda fila: una exclusión, $H_0: \beta_{\text{stratio}} = 0$. Ahora el modelo restringido es **price** sobre **rooms** y **nox**, con $\text{SRC}_r = 1,991 \cdot 10^{10}$; el aumento es $2,799 \cdot 10^9$, $q = 1$, y $F = 82,1$. Compárese con la tabla de la sección “El F en una tabla de resultados”: el t de **stratio** era $-9,06$, y $(-9,06)^2 = 82,1$. Es la identidad $F = t^2$ con $q = 1$, ahora en un modelo con varios regresores: el contraste t de un coeficiente es el contraste F de una única restricción de exclusión, y el valor crítico $F_c(1, 502) = 3,86$ es el cuadrado del $t_c = 1,96$ de la lección 12. Con $k = 2$ lo demostró la transparencia “Lectura geométrica: la misma figura”; con varios regresores lo comprobamos aquí con números, y su demostración general usa la fórmula de $\text{ee}(\hat{\beta}_j)$ que la lección 12 enunció sin demostrar. Gretl lo confirma si se le pide la restricción con **restrict** o desde el menú: devuelve un $F(1, 502)$ idéntico al t^2 , con el mismo valor p .

Tercera fila: una igualdad, $H_0: \beta_{\text{nox}} = \beta_{\text{stratio}}$ (“una unidad más de contaminación cuesta lo mismo que un alumno más por profesor”). Esta hipótesis no excluye a nadie, así que hay que decir cuál es su modelo restringido. Bajo H_0 , la combinación $\beta_{\text{nox}}\mathbf{x}_{\text{nox}} + \beta_{\text{stratio}}\mathbf{x}_{\text{stratio}}$ se convierte en $\beta_{\text{nox}}(\mathbf{x}_{\text{nox}} + \mathbf{x}_{\text{stratio}})$: los dos regresores se funden en uno, la suma, y el modelo restringido es la regresión de **price** sobre **rooms** y **nox** + **stratio**. Su SRC_r es $1,723 \cdot 10^{10}$, apenas por encima del completo: el aumento es $1,213 \cdot 10^8$ y $F = 3,56$, ligeramente por debajo del valor crítico 3,86. No se rechaza al 5 %, con un valor p de 0,060 que conviene informar tal cual: los datos son *compatibles* con que los dos efectos sean iguales, aunque por poco, y la lección 12 ya advirtió que “no

rechazar” no es “aceptar”. Esta fila muestra que imponer una restricción es cambiar de subespacio, no necesariamente recortar regresores: el subespacio $\mathcal{L}(\mathbf{1}, \mathbf{x}_{\text{rooms}}, \mathbf{x}_{\text{nox}} + \mathbf{x}_{\text{stratio}})$ tiene una dimensión menos que el completo, pero no se obtiene quitando ninguna columna de $\mathbf{X}$.¹¹

En Gretl, las tres filas se obtienen sin estimar a mano el modelo restringido: en la ventana del modelo completo, el menú **Contrastes -> Restricciones lineales** (o el bloque **restrict** que el laboratorio anterior usó con **b[2]=0**) acepta cualquier sistema de ecuaciones lineales sobre los coeficientes y devuelve el F con sus dos grados de libertad y su valor p . Un laboratorio posterior lo aplicará con varias restricciones a la vez y comprobará, estimando los dos modelos, que el F que imprime es el cociente de sumas de cuadrados de esta lección.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.4 (contrastar $\beta_j = \beta_h$ como un t con la covarianza de los estimadores, y por qué la vía del modelo restringido es más cómoda); manual de Gretl, comando **restrict**.

8 Conjunto $\neq$ individual: el caso de la apertura

Modelo (price sobre rooms y ...)	t de nox	t de lnox	R^2	F de excluir ambos
... nox	-7,43		0,5352	
... lnox		-7,51	0,5361	
... nox y lnox	0,18	-1,05	0,5362	$F(2, 502) = 28,2$ ($F_c = 3,01$)

$\rho_{\text{nox}, \text{lnox}} = 0,994$: los dos regresores apuntan casi en la misma dirección. Cada uno solo es muy significativo; juntos, el ajuste no puede repartir el efecto entre ellos: a cada uno le queda muy poca longitud *propia* (lección 12), su error estándar se dispara y su t se hunde. Pero el subespacio que generan *juntos* sí acerca $\hat{\mathbf{y}}$ a $\mathbf{y}$, y el F lo ve.

Un F conjunto alto con t individuales pequeños es la firma de la *colinealidad* (lección 14). La conclusión correcta no es “sobran los dos”, sino “no se puede separar cuál de los dos”.

Conjunto $\neq$ individual: el caso de la apertura

Volvamos a la tabla con la que abrimos la sesión, ahora con la herramienta para leerla. Las tres filas de la transparencia son tres regresiones del precio mediano de la vivienda: sobre **rooms** y la concentración de óxidos de nitrógeno **nox**; sobre **rooms** y el logaritmo de esa concentración, **lnox**; y sobre **rooms** y las dos medidas a la vez. Las dos primeras dicen lo mismo: el coeficiente de la contaminación es negativo y se separa con claridad de cero, con un t de $-7,4$ o $-7,5$ y un R^2 de $0,535$ o $0,536$. Da casi igual medirla en niveles o en logaritmos, porque la correlación entre **nox** y **lnox** es $0,994$; en el lenguaje de la lección 5, sus vectores en desviaciones forman un ángulo de unos 6° , prácticamente la misma dirección.

La tercera fila, leída fila a fila, dice otra cosa. Con las dos medidas en el modelo, el t de **nox** cae a $0,18$ y el de **lnox** a $-1,05$; los valores p son $0,854$ y $0,295$, y la lectura fila a fila de la lección 12 podría

¹¹Con la fórmula matricial de la lección 11 para la varianza de $\hat{\beta}$, este contraste puede hacerse también como un t : el estadístico es $(\hat{\beta}_{\text{nox}} - \hat{\beta}_{\text{stratio}})$ dividido por el error estándar de esa diferencia, que involucra la covarianza $\text{Cov}[\hat{\beta}_{\text{nox}}, \hat{\beta}_{\text{stratio}} | \mathbf{X}]$ de fuera de la diagonal. Su cuadrado es el F de la tabla; la vía de las sumas de cuadrados evita tener que calcular esa covarianza.

llevar a asumir que ninguna de las dos interviene. Pero el R^2 apenas ha cambiado (0,5362) y el F de excluir las dos a la vez vale 28,2 frente a un crítico de 3,01: quitar la contaminación del modelo, en cualquiera de sus dos formas, empeora el ajuste. Las dos variables *juntas* son significativas; *cada una*, en presencia de la otra, no lo es.

La lección 12 dio la clave en su recapitulación: con varios regresores, el error estándar de $\hat{\beta}_j$ es $s/\|\tilde{\mathbf{x}}_j\|_e$, donde $\tilde{\mathbf{x}}_j$ es lo que le queda de *propio* al regresor j tras descontar lo que comparte con los demás. Cuando **nox** y **lnox** están los dos en el modelo, casi todo lo que tiene cada uno lo comparte con el otro. La parte propia de cada uno es un vector muy corto, el error estándar de cada coeficiente se dispara y el t se hunde: compárense las desviaciones típicas de la tabla de la apertura, 2198,85 y 12655,7, con los 236 que tenía **nox** en el modelo con **rooms** y **stratio**, sin **lnox**, en la sección “El F en una tabla de resultados”. El contraste t de **nox** pregunta si **nox** aporta algo *que lnox no aporte ya*, y los datos no permiten afirmar que aporte; y lo mismo al revés. Pero esa es una pregunta sobre la *dirección propia* de cada regresor, no sobre el subespacio que generan entre los dos. Ese subespacio, un plano dentro de $\mathcal{L}(\mathbf{1})^\perp$, sí contiene una dirección en la que $\mathbf{y}$ se proyecta con fuerza, y el F de excluir ambas mide eso: cuánto se alarga el residuo si se suprime el plano entero. Por eso el F es grande mientras los dos t son pequeños.

Esta situación tiene nombre, *colinealidad*, y le dedicaremos la lección 14. La lectura correcta de la tabla importa porque el error contrario es frecuente en informes y artículos: ante dos regresores con t pequeños, eliminar los dos “porque no son significativos”. El contraste conjunto dice que eso es un error: los datos no permiten *separar* el efecto de uno del efecto del otro, pero rechazan que sobren los dos a la vez. La respuesta razonable es quedarse con uno de los dos (cualquiera de las dos primeras filas) o, si la pregunta económica exige distinguirlos, reconocer que estos datos no lo permiten. Es la moraleja de la lección 12 con un solo regresor, para medir un efecto hace falta que la variable varíe, trasladada a varios: para medir el efecto de cada uno hace falta que cada uno varíe *por su cuenta*.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5, apartado “Relationship between F and t statistics” (el ejemplo en que ningún t es significativo y el F sí lo es); y cap. 3, sección 3.4, apartado sobre multicolinealidad.

9 Qué dice y qué no dice el F

$F = \frac{n-k}{k-1} \cdot \frac{R^2}{1-R^2}$ mezcla, como el t , *fuerza de la relación* (el ángulo) con *dimensiones* ($n - k$ y $k - 1$). Con $k = 4$:

n	R^2	θ	F	Veredicto al 5 %
6	0,90	18,4°	6,00	no significativo ($F_c = 19,16$)
10	0,90	18,4°	18,00	significativo ($F_c = 4,76$)
1003	0,01	84,3°	3,36	significativo ($F_c = 2,61$)

El F del pie de la tabla contrasta la hipótesis *menos* interesante (que nada explique nada) y con muestras grandes se rechaza casi siempre. Los F que informan nacen de una pregunta: ¿sobran estas dos variables?, ¿tienen el mismo efecto?, ¿es la elasticidad unitaria?

Doce viviendas: $F(3, 8) = 9,55 > 4,07$, significativo... con **stratio** a $t = -0,10$ e intervalos muy anchos. Un F no dice cuál regresor ni cuánto: mire los coeficientes y sus intervalos. Y nada de esto

establece causalidad.

Qué dice y qué no dice el F

Todo lo que la lección 12 dijo sobre la lectura del t vale para el F , y la forma $F = \frac{n-k}{k-1} \cdot \frac{R^2}{1-R^2}$ lo muestra: el estadístico es el producto de un factor que mide la fuerza de la relación en la muestra (el ángulo, el R^2) y otro que solo cuenta dimensiones. La tabla de la transparencia repite, con $k = 4$, el experimento de la lección 12. Las dos primeras filas tienen el mismo R^2 de 0,90, el mismo ángulo de $18,4^\circ$, y veredictos opuestos: con $n = 6$ hay solo $n - k = 2$ dimensiones para el residuo, el valor crítico de la $F_{3,2}$ es 19,16 y un F de 6 no basta; con $n = 10$ el crítico baja a 4,76 y $F = 18$ rechaza con holgura. La tercera fila hace el camino inverso: un R^2 del 1 % (un ángulo de 84° , casi ortogonalidad) resulta conjuntamente significativo con mil observaciones. Compárese con la tabla análoga de la lección 12: con $k = 2$ bastaban $n = 5$ para que $R^2 = 0,90$ fuese significativo; con $k = 4$ hacen falta más, porque el mismo R^2 conseguido con tres regresores en vez de uno es más fácil de obtener por azar: hay más direcciones sobre las que proyectar, y el azar regala, en promedio, $(k - 1)/(n - 1)$ de R^2 . Es el descuento por $k - 1$ del numerador, y es la misma idea que motivó el R^2 ajustado.

Hay una segunda advertencia, propia del F . El F que Gretl imprime al pie de cada tabla contrasta la significación conjunta de *todos* los regresores: la hipótesis de que ninguno de ellos tenga nada que ver con el regresando. En la práctica es la hipótesis menos interesante que cabe formular, porque nadie estima un modelo con regresores elegidos al azar; y con muestras grandes se rechaza casi sin excepción, como muestra la tercera fila de la tabla. Un F automático grande no informa; uno pequeño en una muestra grande es una señal de alarma. Los contrastes F que informan son los de la transparencia “Tres restricciones sobre `hprice2`”: nacen de una pregunta concreta (¿sobran estas dos variables?, ¿tienen el mismo efecto?, ¿vale uno la elasticidad?, ¿son constantes los rendimientos a escala?) y su respuesta cambia algo. El F automático conviene mirarlo una vez y no volver sobre él.

La tercera advertencia es la que el laboratorio anterior ilustró con doce viviendas para el t , y que vale igual para el F . Con la misma submuestra aleatoria de doce viviendas y el modelo de `rooms`, `nox` y `stratio`, el $F(3, 8)$ de significación conjunta vale 9,55 frente a un crítico de 4,07: se rechaza H_0 : datos como estos serían muy raros si los tres coeficientes fuesen nulos a la vez. Y sin embargo el t de `stratio` es $-0,10$, el de `nox`, $-2,6$, apenas supera el crítico 2,31, y los intervalos de confianza de los tres coeficientes son muy anchos. El F significativo dice que *algo* del subespacio de los regresores mejora el ajuste del precio; no dice qué, ni cuánto, ni con qué precisión. Como en la lección 12, lo que informa es el coeficiente en las unidades del problema y su intervalo, y un F , como un t , solo dice si la desviación respecto a la hipótesis es distinguible del azar. Un F no significativo tampoco prueba que las restricciones sean ciertas: es la ausencia de evidencia en su contra, y con pocas observaciones esa ausencia es frecuente aunque H_0 sea falsa.

Y, como siempre, nada de esto establece causalidad. Un F conjunto significativo dice que la proyección de $\mathbf{y}$ sobre el subespacio de los regresores es más larga de lo que el azar produciría; de si alguno de esos regresores *causa* el regresando no dice nada, por las mismas razones de las lecciones 8, 9 y 12. Las correlaciones espurias producen F grandes igual que producen t grandes.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.2f (significación económica frente a estadística, que se aplica sin cambios al F) y sección 4.5, apartado sobre el valor p del contraste

F .

10 Recapitulación y guiño a las sesiones siguientes

Pieza	Fórmula	Lectura geométrica
F de significación conjunta	$\frac{SEC/(k-1)}{SRC/(n-k)} = \frac{n-k}{k-1} \frac{R^2}{1-R^2}$	razón de longitudes al cuadrado de los catetos, cada una por su dimensión
F de q restricciones	$\frac{(SRC_r - SRC)/q}{SRC/(n-k)}$	el mismo triángulo, con $\hat{\mathbf{y}}_r$ en el papel de $\bar{\mathbf{y}}$
Caso $q = 1$	$F = t^2, F_c = t_c^2$	el contraste t es un F de una restricción
Grados de libertad	$k - 1$ (o q) y $n - k$	dimensiones de los dos catetos
Región crítica	$F > F_c$ (una cola)	cono alrededor del subespacio de los regresores

Un único ingrediente nuevo: dividir cada cateto por su dimensión. Demostrado: Pitágoras anidado y $F = t^2$ (con $k = 2$). Enunciado: la distribución $F_{q, n-k}$.

Lección 14: colinealidad. La longitud propia $\|\tilde{\mathbf{x}}_j\|_e$ de cada regresor y el *factor de inflación de la varianza* explican con números el caso de **nox** y **lnox**. *En un laboratorio posterior:* **restrict** con varias restricciones a la vez, y la distribución del F bajo H_0 con datos simulados.

Recapitulación y guiño a las sesiones siguientes

La sesión tiene un solo ingrediente nuevo. Todo el aparato (el triángulo, las sumas de cuadrados, el R^2 , la cuasivarianza $\mathfrak{s}^2$, la isotropía del ruido bajo normalidad) estaba ya sobre la mesa desde las lecciones 8, 11 y 12. Lo único que hoy hemos añadido es una idea: comparar los dos catetos *por dimensión*, dividiendo cada suma de cuadrados por el número de direcciones del subespacio donde vive. Con ella, el contraste t de la lección 12 resulta ser el caso de una sola dirección, y el contraste de cualquier hipótesis lineal sobre los coeficientes (excluir, igualar, fijar) se reduce a una única receta: estimar el modelo con y sin la hipótesis, leer las dos sumas de cuadrados residuales y contar dimensiones.

La tabla resume las piezas. Como en la lección 12, distingamos lo demostrado de lo enunciado. Se ha demostrado, con material del propio curso, el Pitágoras anidado (el aumento de la suma de cuadrados residual al imponer restricciones es la longitud al cuadrado de un cateto ortogonal al residuo) y las identidades $F = \frac{n-k}{k-1} \frac{R^2}{1-R^2}$ y, con $k = 2$, $F = t^2$. Se ha enunciado sin demostrar, igual que la t de Student en la lección 12, la distribución $F_{q, n-k}$ del estadístico bajo H_0 , que descansa en la isotropía del ruido; el reparto en promedio de la longitud al cuadrado entre dimensiones solo usa homocedasticidad e incorrelación. La parte geométrica está demostrada; la probabilística, enunciada.

Quedan dos hilos abiertos. El primero es el caso de **nox** y **lnox**, que hoy hemos sabido *leer* pero no *medir*. La lección 12 enunció que con varios regresores $ee(\hat{\beta}_j) = \mathfrak{s}/\|\tilde{\mathbf{x}}_j\|_e$, con $\tilde{\mathbf{x}}_j$ la parte propia del regresor j ; hoy hemos visto qué pasa cuando esa parte propia es casi nula: el t individual se hunde mientras el conjunto sigue siendo significativo. La lección 14 pondrá números a $\|\tilde{\mathbf{x}}_j\|_e$,

mostrará que se calcula con una regresión auxiliar de $\mathbf{x}_j$ sobre los demás regresores, y de ahí saldrá el *factor de inflación de la varianza*, la medida habitual de cuánto encarece la colinealidad cada error estándar. El segundo hilo es de laboratorio. En una práctica posterior se aplicará **restrict** con varias restricciones simultáneas sobre datos reales, comprobando estimación a estimación que el F de Gretl es el cociente de sumas de cuadrados de hoy. Y se simulará, con el **loop** del laboratorio que siguió a la lección 11, la distribución del F bajo una H_0 cierta: los histogramas mostrarán que ronda 1 y que la cola derecha es la que Gretl tabula.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5 (resumen del contraste F); cap. 3, sección 3.4, apartado “Multicollinearity” (con el que arranca la lección siguiente).