Índice general

1 De dónde venimos: los contrastes t son individuales **2**

2 La hipótesis conjunta **3**

3 El estadístico F **5**

4 Lectura geométrica: la misma figura **7**

5 El F en una tabla de resultados **10**

6 Restricciones lineales: modelos anidados **11**

7 Tres restricciones sobre `hprice2` **15**

8 Conjunto $\neq$ individual: el caso de la apertura **17**

9 Qué dice y qué no dice el F **18**

10 Recapitulación y guiño a las sesiones siguientes **20**

Lección 13. El contraste F: significación conjunta

Marcos Bujosa

10 de noviembre de 2026

Resumen

Hoy haremos preguntas sobre varios coeficientes a la vez: ¿aportan algo *en conjunto* estos regresores?, ¿tienen el mismo efecto estas dos variables?, ¿suman uno estos dos coeficientes? Las responde el estadístico F: la razón entre las longitudes al cuadrado de los dos catetos del triángulo de la lección 8, cada una dividida por su dimensión. La segunda mitad enseña a leer el F de una tabla de resultados: qué afirma y qué no.

"Varios coeficientes, una hipótesis: hace falta un estadístico que mire en varias direcciones a la vez."

- (slides) — (html) — (pdf)

1 De dónde venimos: los contrastes t son individuales

La lección 12 juzga *un* coeficiente cada vez, $t = \hat{\beta}_j/\text{ee}(\hat{\beta}_j)$, y demostró (con $k = 2$) que $t^2 = (n-k)\,\text{SEC/SRC}$. En el laboratorio anterior, al pie de la tabla de `price` sobre `rooms` (actividad 1 (html)), apareció un $F(1, 504) = 472{,}95$ que la actividad 3 (html) comprobó igual a t^2.

Un caso real (`hprice2`; `price` sobre `rooms`, `nox` y su logaritmo `lnox`):

Regresor	Coeficiente	Error estándar	Estadístico t	Valor p
`rooms`	8161,84	418,34	19,51	10^{-63}
`nox`	404,19	2198,85	0,18	0,854
`lnox`	-13262,2	12655,7	-1,05	0,295

¿Sobran `nox` y `lnox`? Cada t por separado no lo descarta. Pero la pregunta es sobre los dos *a la vez*, y eso ningún t lo contesta. Hoy: el F por derecho propio, y con él la respuesta a esta última pregunta al final.

De dónde venimos: los contrastes t son individuales

Todo el aparato de la lección 12 (error estándar, intervalo de confianza, contraste t) se pronuncia sobre *un* coeficiente cada vez. Es lo natural cuando la pregunta es "¿interviene este regresor?", y es lo que hace la tabla de resultados fila a fila. Pero muchas preguntas económicas no son sobre un coeficiente, sino sobre varios a la vez: ¿aportan algo *en conjunto* estos tres regresores?, ¿tienen

Esta obra está bajo una licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional (CC BY-SA 4.0).

el mismo efecto estas dos variables?, si la suma de dos coeficientes valiese uno, ¿serían estos datos demasiado raros? Ninguna de ellas se responde con una fila de la tabla. Hoy construimos la herramienta que las responde a todas.

Dos piezas de las sesiones anteriores bastan para construirla. La primera es la identidad de la lección 12, $t^2 = (n-k)\,\mathrm{SEC/SRC}$: el cuadrado del estadístico t es la razón entre las longitudes al cuadrado de los dos catetos del triángulo de la lección 8, multiplicada por la dimensión $n-k$. La segunda es una observación de la práctica A de la sesión 18: al pie de toda tabla de regresión Gretl imprime un número rotulado F, y en la regresión simple de `price` sobre `rooms` ese número, 472,95, coincidía con t^2.[1] Allí dijimos que el F era "el cociente entre la parte explicada y la parte residual, cada una dividida por su número de dimensiones" y que la lección 13 lo convertiría en un contraste por derecho propio. Esa conversión es la lección de hoy.

La tabla de la transparencia es el caso que motiva la sesión. Es una regresión con datos reales (las viviendas de `hprice2` de los laboratorios) del precio mediano sobre tres regresores: el número de habitaciones y *dos* medidas de la contaminación del aire, la concentración de óxidos de nitrógeno `nox` y su logaritmo `lnox`. Los coeficientes de `nox` y `lnox` tienen ambos un valor p muy alto: 0,854 y 0,295. Si uno lee la tabla como enseñó la lección 12, fila a fila, podría asumir que ninguno de los dos interviene y que ambos sobran. Sin embargo, como veremos en la sección "Conjunto ≠ individual", si se quitan *los dos a la vez* el ajuste empeora más de lo que cabe esperar por azar: la contaminación sí aporta al ajuste. El error está en contestar a una pregunta conjunta sobre dos coeficientes con dos respuestas a preguntas sobre coeficientes individuales.

Sobre el reparto de la sesión: las cuatro primeras transparencias construyen el contraste F de significación conjunta y lo leen en el triángulo; la quinta lo lee en una tabla de Gretl; la sexta y la séptima lo generalizan a cualquier hipótesis lineal sobre los coeficientes; las dos siguientes lo interpretan, y la décima recapitula.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, introducción a la sección 4.5 (por qué los contrastes t individuales no responden a hipótesis sobre varios coeficientes).

2 La hipótesis conjunta

Significación conjunta: $H_0 : \beta_2 = \beta_3 = \cdots = \beta_k = 0$ ("ningún regresor no constante aporta nada") frente a H_1: al menos uno es distinto de cero.

Geométricamente: bajo H_0 el modelo poblacional se reduce al regresor constante, $Y = \beta_1\, 1 + U$, y el ajuste que respeta H_0 es el vector de medias $\overline{\boldsymbol{y}}$. Aunque H_0 sea cierta, el ajuste con más regresores $\widehat{\boldsymbol{y}}$ no coincide con $\overline{\boldsymbol{y}}$: esos regresores recogen parte de la perturbación, y el cateto explicado tiene longitud positiva. La pregunta es si esa longitud es *mayor de lo que cabe esperar por azar*.

¿Por qué no $k-1$ contrastes t? Cada t juzga a su regresor *con los demás dentro del modelo*; "todos no significativos uno a uno" no es "todos nulos a la vez" (la tabla de la apertura).

Cada t mide una sola dirección, la de su regresor. La significación conjunta pide un estadístico que mida el cateto explicado entero, en su subespacio de dimensión $k-1$.

[1] Práctica A de la sesión 18, actividad 3 (html): tres `printf` comparan t^2 con $(n-k)\,\mathrm{SEC/SRC}$ y con el `$Fstat` del modelo, y el bloque `restrict` devuelve el mismo $F(1, 504)$.

La hipótesis conjunta

Un contraste muy frecuente es el de *significación conjunta*, cuya hipótesis nula es: que todos los coeficientes de los regresores no constantes sean cero a la vez, $\beta_2 = \cdots = \beta_k = 0$. En términos del modelo poblacional de la lección 10, $Y = \beta_1\, 1 + \beta_2 X_2 + \cdots + \beta_k X_k + U$, dice que ninguno de los regresores interviene: $Y = \beta_1\, 1 + U$, así que lo mejor que puede hacerse para predecir Y es su valor esperado, la constante β_1; en la muestra, la media. La hipótesis alternativa es la negación lógica: *al menos uno* de esos coeficientes es distinto de cero. H_1 es poco exigente: no dice cuál ni cuántos, solo que no son todos nulos.

La traducción geométrica usa el vocabulario de la lección 10. El ajuste $\widehat{\boldsymbol{y}}$ es la proyección de $\boldsymbol{y}$ sobre $\mathcal{L}(\mathbf{1}, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_k)$, y el triángulo rectángulo de la lección 8 (hipotenusa $\boldsymbol{y} - \overline{\boldsymbol{y}}$, catetos $\widehat{\boldsymbol{y}} - \overline{\boldsymbol{y}}$ y $\widehat{\boldsymbol{e}}$) sigue existiendo sea cual sea k, como se estudió allí.

Si H_0 fuese cierta, el modelo poblacional no contendría ningún regresor distinto de la constante y el ajuste correspondiente a H_0 sería el vector de medias; consecuentemente, el cateto explicado $\widehat{\boldsymbol{y}} - \overline{\boldsymbol{y}}$ "debería" ser nulo.[2]

En la práctica ese cateto no será cero ni siquiera con H_0 cierta: para que lo fuera debería ocurrir que el vector de datos en desviaciones $\boldsymbol{y} - \overline{\boldsymbol{y}}$ fuera ortogonal a todos los regresores en desviaciones, y eso tiene probabilidad cero. Por tanto, la pregunta que el contraste tiene que responder es si el cateto explicado es *más largo de lo que cabe esperar que sea por azar* cuando H_0 es cierta. Es la misma pregunta de la lección 12, con una diferencia: allí el cateto explicado vivía en una recta (la del regresor en desviaciones) y aquí vive en un subespacio de dimensión $k-1$ (el de los $k-1$ regresores en desviaciones, lección 10).

Para responder no basta con mirar los $k-1$ contrastes t de la tabla. La razón está en el *contenido* de la hipótesis: cada t contrasta $H_0 : \beta_j = 0$ *manteniendo a los demás regresores en el modelo*. Es decir, el t de `nox` pregunta si `nox` aporta algo *además de* la constante, `rooms` y `lnox`, y el de `lnox` pregunta si aporta algo además de la constante, `rooms` y `nox`. Ambos pueden responder "no se rechaza $H_0 : \beta_j = 0$" (es decir, los datos sugieren omitir un regresor si el otro se mantiene) y, sin embargo, el contraste conjunto puede rechazar que sobren los dos a la vez (es decir, los datos sugieren que se deben mantener ambos a la vez). "Todos individualmente nulos" y "todos simultáneamente nulos" son afirmaciones distintas, y la segunda constituye la H_0 para el contraste de *significación conjunta*.[3]

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5 ("Testing multiple linear restrictions": el planteamiento de la hipótesis conjunta y por qué los t individuales no la contrastan).

[2] Y la hipotenusa igual al cateto del error: $\boldsymbol{y} - \overline{\boldsymbol{y}} = \widehat{\boldsymbol{e}}$.

[3] Hay una segunda razón, de *probabilidad*. Si se rechazara H_0 conjunta en cuanto alguno de los $k-1$ contrastes t rechace, la probabilidad de rechazar una H_0 cierta no sería menor que el 5 %, y en la práctica es mayor: el suceso "alguno rechaza" contiene al suceso "el primero rechaza", que ya tiene probabilidad 0,05, y lo que añade (que rechace algún otro sin rechazar el primero) tiene probabilidad mayor o igual que cero. Un contraste conjunto es un único contraste sobre la hipótesis que interesa, con un único nivel de significación.

3 El estadístico F

Los dos catetos de la lección 8, cada uno dividido por la dimensión del subespacio donde vive ($k-1$ para el explicado, lección 10; $n-k$ para el residuo, lección 11):

$$\boxed{F = \frac{\text{SEC}/(k-1)}{\text{SRC}/(n-k)}} \qquad \text{(el denominador es } \mathfrak{s}^2\text{)}.$$

Las coordenadas de la perturbación en una base ortonormal son variables aleatorias ortogonales y de la misma longitud σ (homocedasticidad e incorrelación). Bajo H_0, SEC suma $k-1$ de sus cuadrados y SRC las otras $n-k$. Divididas por su número de sumandos, el numerador y el denominador de F estiman los dos σ^2, y $F \approx 1$. Si H_0 es falsa, el efecto de los regresores se suma al cateto explicado y no al residuo: el numerador crece y el denominador no. Un F mucho mayor que 1 es evidencia contra H_0.

Enunciado (demostración en el apéndice): bajo H_0, $F \sim F_{k-1,\,n-k}$. Se rechaza al nivel α si $F > F_c$, con F_c el valor que deja α en la *cola derecha* (una sola cola: F compara longitudes, no tiene signo). Valor p: $\text{P}(F_{k-1,\,n-k} > F)$.

El estadístico F

La lección 12 dejó el estadístico t escrito como $t^2 = \frac{\text{SEC}/1}{\text{SRC}/(n-k)}$, y en su recapitulación hizo notar que ese 1 es $k-1$ con $k=2$. Con $k-1$ en su sitio, la misma fórmula es el estadístico F:

$$F = \frac{\text{SEC}/(k-1)}{\text{SRC}/(n-k)}.$$

El curso ya conoce los dos divisores. El denominador, $\text{SRC}/(n-k)$, es la cuasivarianza de los residuos $\mathfrak{s}^2$ de la lección 11: la suma de cuadrados del residuo dividida por la dimensión $n-k$ del subespacio $\mathcal{L}(\mathbf{1}, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_k)^\perp$ donde el residuo vive. El numerador hace lo mismo con el otro cateto: $\text{SEC} = \|\widehat{\boldsymbol{y}} - \overline{\boldsymbol{y}}\|_e^2$ es la suma de cuadrados del cateto explicado, y $k-1$ es la dimensión del subespacio donde ese cateto vive, el de los regresores en desviaciones (lección 10). Así que F compara los dos catetos *por dimensión*. El motivo de dividir es este. Si en cada subespacio se toma una base de vectores ortogonales de longitud 1, la longitud al cuadrado de un vector es la suma de sus coordenadas al cuadrado (Pitágoras generalizado, lección 10): el cateto explicado suma $k-1$ coordenadas al cuadrado y el residuo, $n-k$. Un cateto puede ser largo por dos motivos: porque sus coordenadas son grandes o porque son muchas. Comparar las dos sumas tal cual mezclaría los dos motivos: con $n = 500$ y $k = 3$, el residuo suma 497 cuadrados y el cateto explicado solo 2, así que el residuo sería más largo aunque todas las coordenadas fuesen del mismo tamaño. Dividir cada suma por su número de coordenadas elimina el segundo motivo y deja solo el primero, el tamaño de las coordenadas: $\text{SEC}/(k-1)$ es la media de las coordenadas al cuadrado del cateto explicado y $\text{SRC}/(n-k)$, la del residuo, y dos medias sí se pueden comparar aunque una tenga 2 sumandos y la otra 497. F es el cociente de esas dos medias, y el párrafo siguiente dice por qué deben parecerse bajo H_0.[4] Recuerde el aviso de la lección 8 sobre las siglas: en su curso de Estadística, SCR era la suma *de regresión*, nuestra SEC, y SCE la suma *del error*, nuestra SRC.

[4] Los dos divisores cuentan dimensiones: $k-1$ las del cateto explicado y $n-k$ las del residuo. Suman $(k-1)+(n-k) = n-1$, la dimensión de $\mathcal{L}(\mathbf{1})^\perp$ (lección 4), donde vive el triángulo entero. La misma lectura, longitud al cuadrado por

¿Por qué sirve ese cociente para contrastar H_0? Supongamos H_0 cierta. Entonces el modelo poblacional es $Y = \beta_1\, 1 + U$ y, como vimos en la lección 12, $Y_i - \overline{Y} = U_i - \overline{U}$ para cada i: la hipotenusa del triángulo es la realización de las perturbaciones centradas. Tomemos una base ortonormal de $\mathcal{L}(\mathbf{1})^\perp$ como la de la lección 12 (vectores de longitud 1 y ortogonales dos a dos), ahora con sus $k-1$ primeros vectores en el subespacio de los regresores en desviaciones (el que el apéndice (html) llama $\mathcal{E}$) y los $n-k$ restantes en el del residuo ($\mathcal{R}$), y las $n-1$ coordenadas de la perturbación: las fórmulas de las coordenadas evaluadas sobre las perturbaciones centradas. Para cada realización, SEC es la suma de los cuadrados de las $k-1$ primeras coordenadas y SRC la de las otras $n-k$ (Pitágoras generalizado, lección 10). Y las coordenadas de la perturbación, evaluadas sobre la muestra aleatoria, son variables aleatorias ortogonales y de la misma longitud σ: cada cuadrado tiene esperanza σ^2. Por tanto, bajo H_0, la longitud al cuadrado del cateto explicado vale en promedio $(k-1)\sigma^2$ y la del residuo, $(n-k)\sigma^2$.[5]

Para estas dos esperanzas bastan la homocedasticidad y la incorrelación de la lección 11; la demostración está en el apéndice (sección 7, Resultados 1 y 2) (html).[6] Dividiendo cada una por su dimensión, *numerador y denominador de F estiman ambos σ^2*, y su cociente debe rondar 1. Si H_0 es falsa, el apéndice (sección 7.2) (html) muestra también qué cambia: las coordenadas en $\mathcal{E}$ llevan sumado el efecto de los regresores no constantes, $\beta_2(X_{i2} - \overline{X}_2) + \cdots + \beta_k(X_{ik} - \overline{X}_k)$, lo que el apéndice llama la *parte sistemática* (sección 6.4 (html)); su suma de cuadrados crece, y el numerador estima σ^2 más algo positivo. El denominador no cambia, porque ese efecto está en el subespacio de los regresores y no tiene coordenadas en $\mathcal{R}$. Un F mucho mayor que 1 es evidencia contra H_0; un F cercano a 1 (o menor) es lo que cabe esperar bajo H_0. La normalidad, como en la lección 12, hará falta para la distribución del cociente.

Para convertir esta idea en un contraste con nivel de significación hace falta saber *cuánto* mayor que 1 es "mucho", y eso exige la distribución de F bajo H_0. Igual que en la lección 12 con la t de Student, la sesión la enuncia y el apéndice la demuestra: bajo H_0 y los supuestos de la lección 12, el estadístico sigue una *distribución F de Fisher–Snedecor con $k-1$ y $n-k$ grados de libertad*, $F_{k-1,\,n-k}$. Es una distribución que solo toma valores positivos, asimétrica, con esperanza próxima a 1 cuando $n-k$ es grande y una cola derecha larga. Su forma depende de los dos números de grados de libertad, las dos dimensiones de los subespacios donde viven los catetos del triángulo.[7] La regla

dirección, explica el divisor n del producto escalar estadístico: $\|\boldsymbol{v}\|_s^2 = \frac{1}{n}\sum_i v_i^2$ es la media de las n coordenadas al cuadrado de $\boldsymbol{v}$ en $\mathbb{R}^n$, y el vector $\mathbf{1}$ mide 1 porque todas sus coordenadas valen 1. La diferencia está en el espacio donde se cuenta: el producto escalar estadístico cuenta siempre las n direcciones de $\mathbb{R}^n$; $\mathfrak{s}^2$ y el F cuentan las del subespacio donde vive cada vector. Por eso la varianza de $\boldsymbol{y}$ divide por n y la cuasivarianza $\mathrm{STC}/(n-1)$ por las $n-1$ direcciones de $\mathcal{L}(\mathbf{1})^\perp$ (nota de la tabla de resultados, lección 12).

[5] Las palabras "en promedio" esconden el mismo abuso de notación de la lección 11: SEC y SRC son aquí las fórmulas de la lección 8 *evaluadas sobre la muestra aleatoria*, variables aleatorias y no los números de una tabla, y lo que se afirma es $\mathrm{E}(\mathrm{SEC}) = (k-1)\sigma^2$ bajo H_0 y $\mathrm{E}(\mathrm{SRC}) = (n-k)\sigma^2$. La segunda igualdad es, dicho de otro modo, la insesgadez de $\mathfrak{s}^2$ que la lección 11 enunció; y vale con o sin H_0, porque el residuo no cambia por que los regresores aporten algo o no.

[6] La versión más elemental de este resultado: la suma de los cuadrados de n variables aleatorias independientes de esperanza cero y varianza σ^2 tiene esperanza $n\sigma^2$, porque cada una aporta σ^2 y la esperanza de una suma es la suma de las esperanzas (regla 1 del apéndice, sección 1.6 (html)). Aquí las $n-1$ coordenadas de la perturbación hacen ese papel: cada cuadrado aporta σ^2, los $k-1$ primeros a SEC y los otros $n-k$ a SRC.

[7] La demostración está en el apéndice (sección 10) (html); aquí basta con la idea, la misma que para la t: numerador y denominador son sumas de cuadrados de dos grupos distintos de coordenadas de la perturbación, $k-1$ y $n-k$, y con normalidad conjunta de las n perturbaciones U_i, esas coordenadas son independientes. De hecho, la t_{n-k} y la $F_{1,\,n-k}$ son la misma distribución mirada de dos maneras: si $T \sim t_{n-k}$, entonces $T^2 \sim F_{1,\,n-k}$. Es la versión distribucional

de decisión tiene una novedad respecto a la lección 12: la región crítica está en *una sola cola*. Se rechaza H_0 al nivel α si $F > F_c$, donde F_c es el valor de la $F_{k-1,\,n-k}$ que deja probabilidad α a su derecha. No hay cola izquierda porque F compara longitudes al cuadrado y no tiene signo: un F pequeño dice que el cateto explicado es corto, que es lo que H_0 predice. El valor p es la probabilidad de un valor al menos tan grande como el observado si H_0 fuese cierta, $\mathrm{P}(F_{k-1,\,n-k} > F)$, y Gretl lo imprime al lado del F al pie de cada tabla.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5 (el estadístico F y su distribución bajo la hipótesis nula); apéndice B (distribuciones χ^2, t y F y la relación $t^2_\nu = F_{1,\nu}$).

4 Lectura geométrica: la misma figura

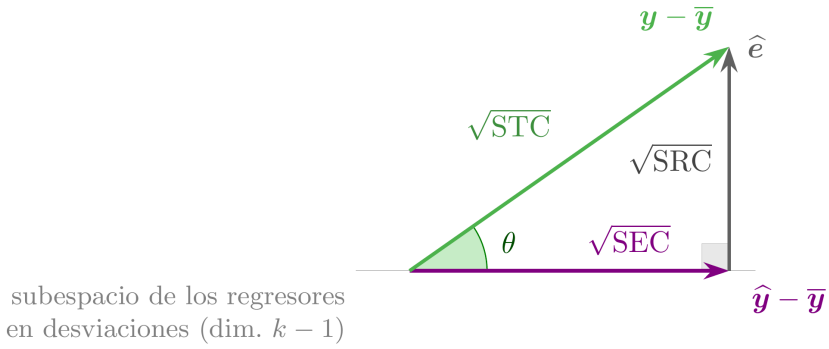


Figura 1: El triángulo de las lecciones 8 y 12, con un solo cambio: ya no hay un regresor medido bajo el eje. En verde, el vector de datos en desviaciones (hipotenusa, longitud $\sqrt{\mathrm{STC}}$); en violeta, el ajuste en desviaciones (cateto explicado, longitud $\sqrt{\mathrm{SEC}}$), que con varios regresores ya no es múltiplo de ninguno de ellos: el eje horizontal es ahora un subespacio de dimensión $k-1$; en gris, el residuo (cateto residual, longitud $\sqrt{\mathrm{SRC}}$), en un subespacio de dimensión $n-k$. El ángulo θ es el de $R^2 = \cos^2\theta$. El estadístico F compara los dos catetos, cada uno dividido por su dimensión.

$$F = \frac{n-k}{k-1}\cdot\frac{\mathrm{SEC}}{\mathrm{SRC}} = \frac{n-k}{k-1}\cdot\frac{R^2}{1-R^2}: \quad \text{función de } \theta \text{ y de dos dimensiones.}$$

Con $k = 2$: $F = (n-2)\,\mathrm{SEC}/\mathrm{SRC} = t^2$, y también $F_c = t^2_c$. El ejemplo de la lección 8 ($n = 5$): $F = \dfrac{90/1}{10/3} = 27 = t^2$; el valor crítico $F_c(1,3) = 10{,}13 = 3{,}18^2$. Bajo H_0, R^2 vale en promedio $(k-1)/(n-1)$ por azar: ahí $F = 1$ y $\bar{R}^2 = 0$.

Lectura geométrica: la misma figura

La figura es similar a la de la lección 12. Con k regresores el esquema del triángulo rectángulo de la bondad de ajuste (lección 8) se mantiene intacto: $\mathrm{STC} = \mathrm{SEC} + \mathrm{SRC}$ y también se mantiene que

de $F = t^2$ que veremos en "Lectura geométrica: la misma figura".

$R^2 = \cos^2\theta$. El motivo es que el residuo MCO siempre es ortogonal al subespacio de los regresores; así que, en particular, $\widehat{\boldsymbol{e}} \perp \widehat{\boldsymbol{y}} - \overline{\boldsymbol{y}}$ puesto que los vectores $\widehat{\boldsymbol{y}}$ y $\overline{\boldsymbol{y}}$ son combinación lineal de los regresores. Lo único que cambia en esta figura respecto a la lección 12 es el eje horizontal: el cateto explicado ya no es un múltiplo del regresor no constante en desviaciones, porque ahora hay $k-1$ regresores y $\widehat{\boldsymbol{y}} - \overline{\boldsymbol{y}}$ es una combinación de todos ellos que, en general, no está alineada con ninguno (lección 10). La recta horizontal representa aquí un subespacio de dimensión $k-1$ (y en la lección 12 correspondía únicamente a los múltiplos del regresor no constante en desviaciones $(\boldsymbol{x} - \overline{\boldsymbol{x}})$).

Escribamos F en términos del triángulo. Sacando los divisores fuera,

$$F = \frac{\mathrm{SEC}/(k-1)}{\mathrm{SRC}/(n-k)} = \frac{n-k}{k-1} \cdot \frac{\mathrm{SEC}}{\mathrm{SRC}},$$

y como $\mathrm{SEC}/\mathrm{SRC} = R^2/(1-R^2)$,[8]

$$F = \frac{n-k}{k-1} \cdot \frac{R^2}{1-R^2}.$$

Es la misma estructura que la identidad de la lección 12 con un factor distinto: allí $t^2 = (n-k)\,R^2/(1-R^2)$; aquí el $n-k$ se divide además por $k-1$. (En el apéndice, sección 5.5 (html), la misma identidad sale de escribir el F con las coordenadas del vector de datos en desviaciones en una base ortonormal.) En los dos casos el estadístico es una función únicamente del ángulo θ (vía $R^2 = \cos^2\theta$) y de las dimensiones de los subespacios donde viven los catetos. Y en los dos casos vale la misma lectura: *el contraste no mide nada que el R^2 no midiera ya*; lo que añade es el factor que cuenta las dimensiones de los dos catetos. Un R^2 dado es tanto más sorprendente cuantas más observaciones haya ($n-k$ grande) y cuantos *menos* regresores se hayan usado para conseguirlo ($k-1$ pequeño).

La explicación está en el R^2 que el azar produce por sí solo. Bajo H_0, si las n perturbaciones U_i son conjuntamente normales, las $n-1$ coordenadas de la perturbación de la sección "El estadístico F" son independientes y todas tienen la distribución $N(0,\sigma^2)$ (apéndice, Resultado 3 (html)); lo que sigue son afirmaciones sobre esperanzas de sumas de sus cuadrados, como en la sección "El estadístico F".[9] Tomemos en $\mathcal{L}(\mathbf{1})^\perp$ la base ortonormal de la sección "El estadístico F", cuyos $k-1$ primeros vectores generan el subespacio de los regresores en desviaciones. Para cada realización, STC es la suma de los cuadrados de las $n-1$ coordenadas del vector de datos en desviaciones; evaluadas sobre la muestra aleatoria, esas $n-1$ coordenadas tienen la misma distribución (isotropía), de modo que cada uno de sus cuadrados vale, en promedio, σ^2, y la suma de los $n-1$, STC, vale en promedio $(n-1)\sigma^2$: a cada cuadrado le corresponde en promedio la fracción $1/(n-1)$ de STC. El cateto explicado, SEC, es la suma de las $k-1$ primeras. Así que, cuando es cierta la H_0 de significación conjunta, $\beta_2 = \cdots = \beta_k = 0$, $R^2 = \mathrm{SEC}/\mathrm{STC}$ vale en promedio $(k-1)/(n-1)$: ese es el R^2 que se obtiene sin que los regresores tengan nada que ver con el regresando. Crece con el número de regresores, porque cada regresor añadido aporta una coordenada más al cateto

[8] Dividiendo numerador y denominador por STC y usando Pitágoras (lección 8).

[9] Ese es aquí el papel de la normalidad: la ortogonalidad de las coordenadas basta para las esperanzas de SEC y SRC por separado, pero no para la esperanza de su cociente; para que R^2 tenga esperanza $(k-1)/(n-1)$ hace falta que las $n-1$ coordenadas sean intercambiables (que su distribución conjunta no cambie al reordenarlas, de modo que el cuadrado de cada una dividido por la suma de los $n-1$ cuadrados tenga la misma esperanza para todas), y eso es lo que da la normalidad (apéndice, sección 8 (html)).

explicado; y decrece con n, porque el mismo número de coordenadas es una fracción menor del total. Un R^2 de 0,30 dice cosas distintas con $n = 11$ y $k = 4$, donde el azar da 0,30 en promedio, que con $n = 101$ y $k = 2$, donde el azar da 0,01.

El estadístico F compara el R^2 observado con esa referencia, el R^2 que el azar produce en promedio bajo H_0, $(k-1)/(n-1)$: sustituyendo $R^2 = (k-1)/(n-1)$ en la fórmula sale $F = 1$. Y es la misma referencia que usa el R^2 ajustado de la actividad 5 (html) de la práctica B de la sesión 14: $\bar{R}^2 = 1 - (1-R^2)\frac{n-1}{n-k}$ vale cero en ese mismo punto. Las dos herramientas descuentan lo mismo, el ajuste que el azar regala por cada regresor; el $\bar{R}^2$ lo hace para comparar modelos y el F para decidir si lo que queda tras el descuento es demasiado para ser casualidad.

Con $k = 2$ la referencia es $1/(n-1)$, y eso explica la propiedad que la lección 12 enunció sin demostrar: que en dimensión alta dos direcciones tomadas al azar son casi ortogonales. Con un solo regresor el subespacio de los regresores en desviaciones es una recta, y $R^2 = \cos^2\theta$ es el cuadrado del coseno del ángulo entre el vector de datos en desviaciones y esa recta. Ese cuadrado vale en promedio $1/(n-1)$ porque la recta es una sola de las $n-1$ direcciones ortonormales, y las $n-1$ coordenadas de la perturbación sobre ellas, evaluadas sobre la muestra aleatoria, tienen la misma distribución y el mismo cuadrado esperado: la longitud al cuadrado de la perturbación centrada se reparte en promedio a partes iguales entre las $n-1$ direcciones, y a la recta del regresor le corresponde $1/(n-1)$ de ella. Cuantas más observaciones, más direcciones se reparten esa longitud y menor es la fracción que cae en la del regresor.

Que el ángulo entre el vector de datos en desviaciones y la recta del regresor sea pequeño exige que casi toda la longitud de ese vector esté sobre esa recta y casi nada en las otras $n-2$ direcciones. Bajo H_0, $Y_i = \beta_1\, 1 + U_i$, así que $Y_i - \overline{Y} = U_i - \overline{U}$: el vector de datos en desviaciones es la realización de las perturbaciones centradas (sección "El estadístico F"), y la distribución de la perturbación no distingue una dirección de otra: concentrarse en la recta del regresor es tan improbable como concentrarse en cualquier otra de las $n-1$ direcciones. Los números: con $n = 5$ el promedio de $\cos^2\theta$ es $1/4$, el de un ángulo de 60°; con $n = 1002$ es $1/1001$, el de un ángulo de 88,2°. Es la figura del cono de la lección 12: con mil observaciones, casi todas las realizaciones de la perturbación centrada forman con la recta del regresor un ángulo próximo a 90°: la franja estrecha alrededor de la vertical. La conclusión: con muchos datos, H_0 se rechaza en cuanto el ángulo se desvía ligeramente de los 90°, porque con H_0 cierta el azar casi nunca produce ni siquiera esa pequeña desviación. Un R^2 minúsculo basta entonces para rechazar.

El caso $k = 2$ es el de la lección 12. Con un único regresor no constante, $k-1 = 1$ y la fórmula se reduce a $F = (n-2)\,\mathrm{SEC}/\mathrm{SRC}$, que es t^2. También coincide el valor crítico, porque la $F_{1,\,n-k}$ es la distribución del cuadrado de una t_{n-k} (apéndice, sección 10 (html): con $q = 1$ el numerador del F es el cuadrado del numerador de la t, y el denominador es el mismo), de modo que $F_c = t_c^2$ y las dos reglas de decisión rechazan en los mismos casos. Es lo que la práctica A de la sesión 18 verificó sobre `hprice2` con `restrict` (actividad 3 (html)), y lo que el ejemplo de juguete de la lección 8 permite comprobar con números redondos: SEC = 90, SRC = 10, $n = 5$, luego $F = (90/1)/(10/3) = 27$, el mismo $t^2 = 27$ de la lección 12; y el valor crítico al 5 % de la $F_{1,3}$ es 10,13, el cuadrado del 3,18 de la t_3. Se rechaza por las dos vías, y con el mismo valor p.

También la región crítica se lee igual que en la lección 12: rechazar cuando $F > F_c$ equivale a rechazar cuando el ángulo θ es menor que un ángulo crítico θ_c (un *cono* alrededor del subespacio de los regresores en desviaciones), y la abertura de ese cono depende de las dos dimensiones. Con

los números de "El F en una tabla de resultados" ($n = 506$, $k = 4$), la abertura al 5 % es de 82,9°: casi todo el espacio, por la misma razón que en la lección 12: en dimensión alta el azar solo produce ángulos próximos a 90°.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5, apartado "The R-squared form of the F statistic".

5 El F en una tabla de resultados

`hprice2`: `price` sobre `rooms`, `nox` y `stratio` (el modelo de la actividad 3 (html) de la práctica sobre `hprice2` que siguió a la lección 10).

Regresor	Coeficiente	Error estándar	Estadístico t
constante	9458,01	4371,41	2,16
`rooms`	7000,63	409,15	17,11
`nox`	-1693,33	236,25	-7,17
`stratio`	-1166,96	128,76	-9,06

$n = 506$, $k = 4$, $R^2 = 0{,}6005$, SRC $= 1{,}711 \cdot 10^{10}$, SEC $= 2{,}572 \cdot 10^{10}$, $\mathfrak{s} = \sqrt{\text{SRC}/(n-k)} = 5837{,}8$ (la "D.T. de la regresión" de Gretl); al pie: $F(3, 502) = 251{,}5$, valor $p = 1{,}3 \cdot 10^{-99}$.

Lectura: $F = 251{,}5$ dice que la longitud al cuadrado por dimensión del cateto explicado es doscientas cincuenta veces mayor que la del residuo; si H_0 fuese cierta esa razón debería rondar 1. Frente a $F_c(3, 502) = 2{,}62$ al 5 %, se rechaza que los tres coeficientes sean cero a la vez. *No dice*: cuáles importan, ni cuánto.

El F en una tabla de resultados

Toda tabla de regresión de Gretl termina con dos líneas de resumen que, hasta hoy, habíamos leído solo en parte: el R^2 y la "D.T. de la regresión", que es la $\mathfrak{s}$ de la lección 11 (la raíz de la cuasivarianza de los residuos), y a su lado un "$F(k-1,\, n-k)$" con su valor p. Ese F es el estadístico de significación conjunta de esta lección: contrasta, automáticamente y para cualquier modelo que se estime, la hipótesis de que todos los coeficientes de los regresores no constantes son cero a la vez. Los dos números entre paréntesis se denominan *grados de libertad* y son las dimensiones de los subespacios donde viven los catetos del triángulo.

Ese F también lo vio en Estadística, al pie de la salida de Excel, en una tabla rotulada "Análisis de varianza" con tres filas, "Regresión", "Residuos" y "Total", y las columnas "Grados de libertad", "Suma de cuadrados", "Promedio de los cuadrados", "F" y "Valor crítico de F". Es el triángulo de esta lección puesto en filas: las sumas de cuadrados son SEC, SRC y STC; los grados de libertad, $k - 1$, $n - k$ y $n - 1$; el "promedio de los cuadrados" es cada suma dividida por su dimensión, SEC$/(k-1)$ y SRC$/(n-k)$; y la "F" es su cociente. La última columna, pese a su rótulo, no es el valor crítico F_c: es el valor p del contraste. Lo que allí era una tabla sin explicación es la fórmula de la transparencia "El estadístico F".

Tomemos el modelo de la actividad 3 (html) de la práctica sobre `hprice2` que siguió a la lección 10, el precio mediano de la vivienda sobre el número de habitaciones, la contaminación y la ratio alumnos/profesor del distrito. Con $n = 506$ y $k = 4$ (tres regresores más la constante), las

dimensiones son $k-1=3$ y $n-k=502$. Todo lo que hace falta para reconstruir el F está en la tabla o sale de ella con la lección 8: SRC lo imprime Gretl; STC se obtiene de $R^2 = 1 - \text{SRC}/\text{STC}$, y $\text{SEC} = \text{STC} - \text{SRC} = 2{,}572 \cdot 10^{10}$. Dividiendo la longitud al cuadrado de cada cateto por su dimensión, el numerador vale $8{,}573 \cdot 10^9$ y el denominador $3{,}408 \cdot 10^7$. El denominador tiene que coincidir con $\mathfrak{s}^2$, la cuasivarianza de los residuos, y coincide: $5837{,}8^2 = 3{,}408 \cdot 10^7$. El cociente es 251,5, el F de la tabla. Por la otra vía, $\frac{502}{3} \cdot \frac{0{,}6005}{0{,}3995} = 251{,}5$, el mismo número.

El valor crítico de la $F_{3,502}$ al 5 % es 2,62, y al 1 %, 3,82; el estadístico observado es cien veces mayor y el valor p es del orden de 10^{-99}. Se rechaza H_0: datos como estos serían muy raros si `rooms`, `nox` y `stratio` tuvieran coeficiente nulo a la vez. La magnitud también se lee: $F = 251{,}5$ dice que la longitud al cuadrado por dimensión del cateto explicado es doscientas cincuenta veces mayor que la del residuo; si H_0 fuese cierta esa razón debería rondar 1.

Y lo que el F *no* dice, que la sección "Qué dice y qué no dice el F" desarrollará. Rechazar $H_0: \beta_2 = \beta_3 = \beta_4 = 0$ es rechazar que *los tres* sean nulos a la vez; no excluye que dos de ellos lo sean. El F conjunto no señala a ningún regresor en particular, ni dice nada de la magnitud de los efectos: para eso están las columnas de la tabla y los intervalos de confianza de la lección 12.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5, apartado "The F statistic for overall significance of a regression"; y sección 4.6 (cómo se presentan los resultados, incluido el F).

6 Restricciones lineales: modelos anidados

Imponer q restricciones lineales sobre los β (excluir, igualar, fijar) obliga al ajuste a vivir en un subespacio *menor* del de los regresores. Proyectar sobre él aleja el ajuste de $\boldsymbol{y}$: ajuste restringido $\widehat{\boldsymbol{y}}_r$, con $\text{SRC}_r \geq \text{SRC}$. Los dos modelos están *anidados*: el restringido es un caso particular del completo.

$$\boxed{F = \frac{(\text{SRC}_r - \text{SRC})/q}{\text{SRC}/(n-k)} \;\sim\; F_{q,\,n-k} \;\text{ bajo } H_0}$$ (significación conjunta: $\widehat{\boldsymbol{y}}_r = \overline{\boldsymbol{y}}$, $q = k-1$).

Restricciones lineales: modelos anidados

Empecemos por la geometría, porque es lo que permite tratar con una única herramienta todas las hipótesis de esta sección. Imponer q restricciones lineales sobre los coeficientes (excluir un regresor, igualar dos coeficientes, fijar un valor) equivale a exigir que el ajuste sea una combinación lineal de los regresores *de un tipo particular*. El conjunto de esas combinaciones es un subespacio *menor* que $\mathcal{L}(\mathbf{1}, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_k)$, contenido en él, con q dimensiones menos.[10] El *ajuste restringido* $\widehat{\boldsymbol{y}}_r$ es la proyección de $\boldsymbol{y}$ sobre ese subespacio menor (lo que Gretl calcula al estimar el modelo sin `nox` ni `stratio`, por ejemplo), y su suma de cuadrados residual, $\text{SRC}_r = \|\boldsymbol{y} - \widehat{\boldsymbol{y}}_r\|_e^2$, es necesariamente mayor o igual que la del modelo completo: proyectar sobre un subespacio más pequeño nunca

[10] Con $\beta_3 = \beta_4 = 0$, el subespacio restringido es $\mathcal{L}(\mathbf{1}, \boldsymbol{x}_2)$: hemos perdido dos generadores. Con $\beta_3 = \beta_4$, es $\mathcal{L}(\mathbf{1}, \boldsymbol{x}_2, \boldsymbol{x}_3 + \boldsymbol{x}_4)$: la combinación $\beta_3\boldsymbol{x}_3 + \beta_4\boldsymbol{x}_4$ con $\beta_3 = \beta_4$ es $\beta_3(\boldsymbol{x}_3 + \boldsymbol{x}_4)$, así que los dos regresores se funden en uno y se pierde una dimensión. Las restricciones que fijan un valor, como $\beta_2 = 1$, dan un conjunto que no pasa por el origen (un subespacio *trasladado* por $\boldsymbol{x}_2$); el argumento que sigue vale igual, porque lo único que usa es que los dos ajustes están en $\mathcal{L}(\mathbf{1}, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_k)$.

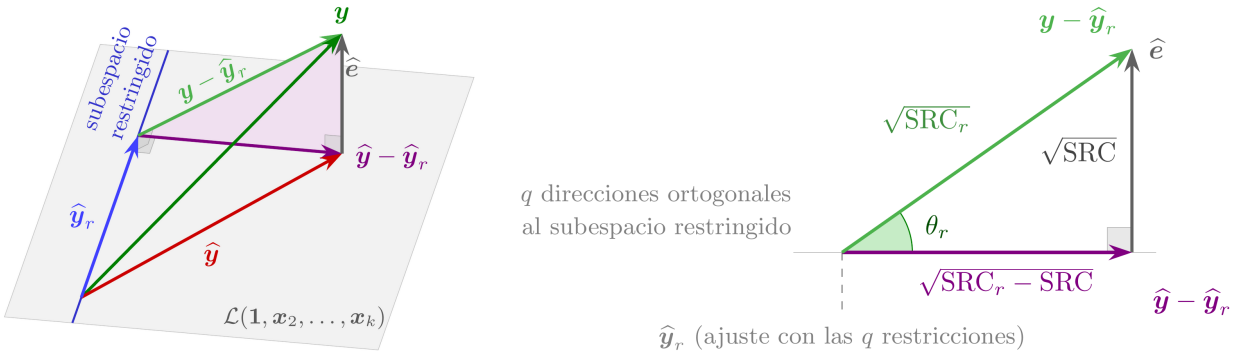


Figura 2: Izquierda: el subespacio de los regresores y, dentro de él, el subespacio restringido; $\widehat{\boldsymbol{y}}$ es la "sombra" de $\boldsymbol{y}$ sobre el plano y $\widehat{\boldsymbol{y}}_r$ su "sombra" sobre el subespacio restringido, más lejos de $\boldsymbol{y}$. Derecha: el triángulo sombreado visto de frente, con el ajuste restringido $\widehat{\boldsymbol{y}}_r$ en el papel del vector de medias $\overline{\boldsymbol{y}}$: hipotenusa $\sqrt{\text{SRC}_r}$, catetos $\sqrt{\text{SRC}_r - \text{SRC}}$ (en las q direcciones del plano de los regresores ortogonales al subespacio restringido) y $\sqrt{\text{SRC}}$. El ángulo recto es $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r \perp \widehat{\boldsymbol{e}}$, de donde $\text{SRC}_r = \text{SRC} + \|\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r\|_e^2$. El ángulo θ_r es el que forman la hipotenusa y el cateto $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r$, y hace el papel del θ de la figura anterior: F es una función de θ_r y de las dos dimensiones q y $n-k$. La significación conjunta es el caso en que el subespacio restringido es la recta de $\mathbf{1}$: entonces $\widehat{\boldsymbol{y}}_r = \overline{\boldsymbol{y}}$, $q = k - 1$, y el triángulo es el de la figura anterior.

queda más cerca de $\boldsymbol{y}$ que proyectar sobre un subespacio que contiene al pequeño. Es la propiedad que la lección 8 anunció como "R^2 nunca empeora al añadir regresores" y que la práctica del R^2 ajustado hizo explícita (actividad 4 (html)): quitar regresores nunca reduce la suma de cuadrados del residuo. La figura de la izquierda en la transparencia, repetida aquí más grande, lo muestra: el plano es el subespacio de los regresores; la recta dentro de él representa el subespacio restringido; $\widehat{\boldsymbol{y}}$ es la "sombra" de $\boldsymbol{y}$ sobre el plano y $\widehat{\boldsymbol{y}}_r$ su "sombra" sobre la recta, más lejos de $\boldsymbol{y}$.

Con esa imagen delante, la definición general. Una *hipótesis lineal* es un sistema de q ecuaciones lineales sobre los coeficientes del modelo poblacional, y el ajuste pierde una dimensión por cada ecuación. El modelo que cumple esas ecuaciones y el modelo completo están *anidados*: el restringido es un caso particular del completo, porque cada combinación lineal de los regresores que el restringido admite la admite también el completo. Geométricamente, el subespacio restringido está contenido en el de los regresores, como la recta dentro del plano de la figura. Tres ejemplos que reaparecerán con números en "Tres restricciones sobre `hprice2`": excluir dos regresores a la vez, $\beta_3 = \beta_4 = 0$ ($q = 2$); excluir uno solo, $\beta_4 = 0$ ($q = 1$, el contraste t de siempre); y una hipótesis que no excluye ningún regresor, sino que relaciona dos coeficientes, $\beta_3 = \beta_4$ ($q = 1$). Otras fijan un valor (una elasticidad unitaria, $\beta_2 = 1$) o una suma (rendimientos constantes a escala, $\beta_2 + \beta_3 = 1$, que veremos al hablar de la función de producción). Las que fijan un valor también tienen su modelo restringido, y se estima como una regresión más: con $\beta_2 = 1$ el término $1 \cdot \boldsymbol{x}_2$ ya no tiene coeficiente que estimar y pasa al lado de $\boldsymbol{y}$, de modo que el modelo restringido regresa $\boldsymbol{y} - \boldsymbol{x}_2$ sobre $\mathbf{1}, \boldsymbol{x}_3, \ldots, \boldsymbol{x}_k$ ($q = 1$); en general, con $\beta_j = c$ se regresa $\boldsymbol{y} - c\,\boldsymbol{x}_j$ sobre los demás regresores. La significación conjunta de "La hipótesis conjunta" es solo una de ellas, y no siempre la más interesante: su subespacio restringido es $\mathcal{L}(\mathbf{1})$.

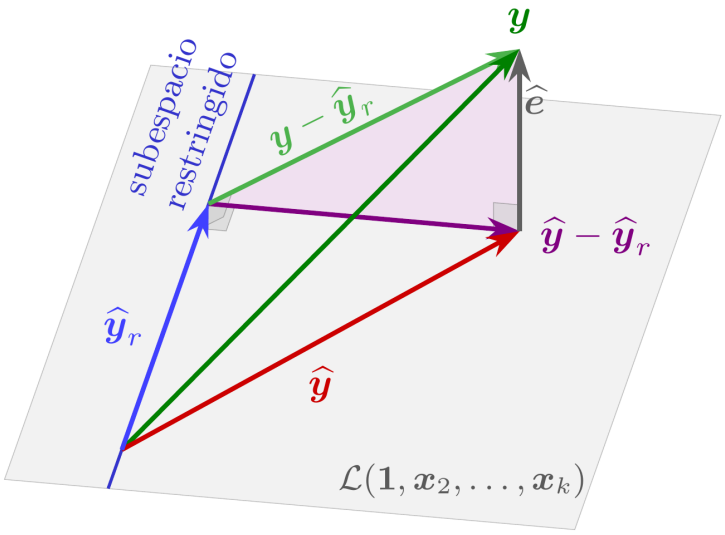


Figura 3: Los dos subespacios. El plano es $\mathcal{L}(\mathbf{1}, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_k)$; la recta, dentro de él, es el subespacio restringido. $\boldsymbol{y}$ está fuera del plano; $\widehat{\boldsymbol{y}}$ es su "sombra" sobre el plano y $\widehat{\boldsymbol{y}}_r$ su "sombra" sobre la recta. El triángulo sombreado es el de la transparencia, visto desde fuera del plano.

En términos de este esquema geométrico, la pregunta del contraste es *cuánto* aumenta la suma de cuadrados del residuo al imponer las restricciones, es decir, cuánto mayor es SRC_r que SRC. Si H_0 es cierta, el modelo restringido es el verdadero y el aumento $\text{SRC}_r - \text{SRC}$ es solo la parte de la perturbación realizada que recogían por azar las q direcciones del plano de los regresores ortogonales al subespacio restringido, las que el modelo completo tiene y el restringido no (apéndice, sección 6.4 (html): bajo H_0, el efecto de los regresores no constantes, la parte sistemática, no tiene coordenadas en esas q direcciones). Si H_0 es falsa, las restricciones suprimen direcciones en las que el ajuste completo sí se acercaba a $\boldsymbol{y}$, y el aumento es grande. Para medirlo hace falta el resultado que hoy demostramos:

Proposición (Pitágoras anidado). Los dos ajustes cumplen $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r \perp \widehat{\boldsymbol{e}}$, y por tanto

$$\text{SRC}_r = \text{SRC} + \|\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r\|_e^2.$$

Demostración. El ajuste restringido $\widehat{\boldsymbol{y}}_r$ es una combinación lineal de los regresores (de un tipo particular), luego pertenece a $\mathcal{L}(\mathbf{1}, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_k)$; y $\widehat{\boldsymbol{y}}$ también. Por tanto, su diferencia está en ese subespacio, y el residuo del modelo completo es ortogonal a todo él (lección 10: $\widehat{\boldsymbol{e}}\mathbf{X} = \mathbf{0}$). Así que $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r \perp \widehat{\boldsymbol{e}}$. Ahora escribimos el residuo restringido como suma de dos vectores ortogonales:

$$\boldsymbol{y} - \widehat{\boldsymbol{y}}_r = (\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r) + (\boldsymbol{y} - \widehat{\boldsymbol{y}}) = (\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r) + \widehat{\boldsymbol{e}}.$$

Aplicando el teorema de Pitágoras de la lección 3, $\|\boldsymbol{y} - \widehat{\boldsymbol{y}}_r\|_e^2 = \|\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r\|_e^2 + \|\widehat{\boldsymbol{e}}\|_e^2$, que es la igualdad anunciada. ■

La figura hace visible un hecho más: $\widehat{\boldsymbol{y}}_r$ es también la proyección de $\widehat{\boldsymbol{y}}$ sobre el subespacio restringido. Llamemos $\boldsymbol{v}_r$ a la "sombra" de $\widehat{\boldsymbol{y}}$ sobre ese subespacio: es el vector del subespacio

restringido tal que $\widehat{\boldsymbol{y}} - \boldsymbol{v}_r$ es ortogonal a dicho subespacio (la condición de ortogonalidad que caracteriza la proyección, lecciones 6 y 10). Ahora bien, $\boldsymbol{y} - \boldsymbol{v}_r = (\boldsymbol{y} - \widehat{\boldsymbol{y}}) + (\widehat{\boldsymbol{y}} - \boldsymbol{v}_r)$, y los dos sumandos son ortogonales al subespacio restringido: el primero porque $\widehat{\boldsymbol{e}}$ es ortogonal a todo el plano y el subespacio restringido es una parte del plano; el segundo por la definición de $\boldsymbol{v}_r$. Luego $\boldsymbol{y} - \boldsymbol{v}_r$ es ortogonal al subespacio restringido, y como $\boldsymbol{v}_r$ está en él, $\boldsymbol{v}_r$ es la "sombra" de $\boldsymbol{y}$: es decir, $\boldsymbol{v}_r = \widehat{\boldsymbol{y}}_r$. Así que $\boldsymbol{y}$ y $\widehat{\boldsymbol{y}}$ tienen la misma "sombra" sobre el subespacio restringido. La proyección puede hacerse en dos pasos, primero sobre el plano y después sobre la recta.

Fíjese que la figura marca tres ángulos rectos, y cada uno tiene su lectura. Uno está en el punto donde termina el vector $\widehat{\boldsymbol{y}}$, que es donde acaba el cateto $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r$ y empieza el cateto $\widehat{\boldsymbol{e}}$: es el ángulo recto del triángulo sombreado, y es recto porque el primer cateto está en el plano y el segundo es ortogonal a todo el plano. Los otros dos están en el punto donde termina el vector $\widehat{\boldsymbol{y}}_r$, y en ambos uno de los catetos está sobre la recta del subespacio restringido. El que forma con $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r$ es la condición de ortogonalidad que define a $\widehat{\boldsymbol{y}}_r$ como "sombra" de $\widehat{\boldsymbol{y}}$; el que forma con $\boldsymbol{y} - \widehat{\boldsymbol{y}}_r$ es lo que acabamos de demostrar, que $\widehat{\boldsymbol{y}}_r$ es también la "sombra" de $\boldsymbol{y}$. El primero de esos dos dice además en qué subespacio está $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r$: en el de los vectores del plano de los regresores ortogonales al subespacio restringido. Ese subespacio tiene dimensión q y es el eje horizontal del triángulo de la derecha de la transparencia.

Volvamos al Pitágoras anidado. La proposición es la de la lección 8 (STC = SEC + SRC) con el vector de medias sustituido por el ajuste restringido, y la figura de la transparencia es la de la lección 8 con esa sustitución: hipotenusa $\boldsymbol{y} - \widehat{\boldsymbol{y}}_r$, catetos $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r$ y $\widehat{\boldsymbol{e}}$. El aumento de la suma de cuadrados residual al imponer las restricciones es la longitud al cuadrado del cateto $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r$: $\mathrm{SRC}_r - \mathrm{SRC} = \|\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r\|_e^2$. Ese cateto es lo que el ajuste completo añade al restringido, porque $\widehat{\boldsymbol{y}} = \widehat{\boldsymbol{y}}_r + (\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r)$, y pertenece al subespacio de dimensión q del párrafo anterior, el de los vectores del plano de los regresores ortogonales al subespacio restringido. Así que ese cateto tiene q dimensiones, igual que el residuo tiene $n - k$. Con esto, el estadístico se construye igual que el de significación conjunta, cada cateto dividido por su dimensión:

$$F = \frac{(\mathrm{SRC}_r - \mathrm{SRC})/q}{\mathrm{SRC}/(n-k)} = \frac{\|\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r\|_e^2/q}{\mathfrak{s}^2}.$$

El mismo reparto por dimensión de la sección "El estadístico F" hace que numerador y denominador estimen ambos σ^2 bajo H_0. Su distribución bajo H_0 es la $F_{q,\,n-k}$ (la demostración está en el apéndice, sección 10 (html)), y la regla es la de siempre: rechazar si $F > F_c$. La significación conjunta es el caso particular en que el subespacio restringido es $\mathcal{L}(\mathbf{1})$: entonces $\widehat{\boldsymbol{y}}_r = \overline{\boldsymbol{y}}$, $\mathrm{SRC}_r = \mathrm{STC}$, el aumento es SEC y $q = k - 1$. Las secciones "La hipótesis conjunta" a "El F en una tabla de resultados" trataban este caso.

Cualquier par de modelos anidados, es decir, cualquier hipótesis lineal, se contrasta con la misma receta: estimar los dos, leer las dos sumas de cuadrados residuales, contar q y $n - k$.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5 ("Testing exclusion restrictions" y "Testing general linear restrictions"); y sección 4.4 (contraste de una única combinación lineal de coeficientes, el caso $q = 1$).

7 Tres restricciones sobre `hprice2`

Modelo completo (actividad 3 (html) de la práctica B de la sesión 14): `price` sobre `rooms`, `nox` y `stratio`, $n = 506$. En Gretl, menú `Contrastes -> Restricciones lineales` (o el comando `restrict`): devuelve el F, sus grados de libertad y el valor p.

H_0	q	F	F_c al 5 %	Lectura
$\beta_{\text{nox}} = \beta_{\text{stratio}} = 0$	2	73,1	3,01	se rechaza: juntas, contaminación y ratio alumnos/profesor acortan el residuo más de lo esperable por azar
$\beta_{\text{stratio}} = 0$	1	82,1	3,86	se rechaza; es el $t = -9{,}06$ de la tabla, al cuadrado
$\beta_{\text{nox}} = \beta_{\text{stratio}}$	1	3,56	3,86	no se rechaza, por poco ($p = 0{,}060$): los datos no separan los dos efectos

La tercera fila *no* excluye ningún regresor: con $\beta_{\text{nox}} = \beta_{\text{stratio}}$, los dos términos se funden en $\beta_{\text{nox}}(\boldsymbol{x}_{\text{nox}} + \boldsymbol{x}_{\text{stratio}})$, y el modelo restringido regresa `price` sobre `rooms` y la *suma* `nox` + `stratio`. La restricción cambia el subespacio del ajuste (una dimensión menos) sin quitar ninguna columna de datos.

Tres restricciones sobre `hprice2`

Los tres contrastes de la tabla se hacen sobre el mismo modelo completo de la sección "El F en una tabla de resultados", de modo que el denominador es siempre el mismo: $\text{SRC}/(n-k) = \mathfrak{s}^2 = 3{,}408 \cdot 10^7$, la cuasivarianza de los residuos de la lección 11, cuya raíz, $\mathfrak{s} = 5837{,}8$, es la "D.T. de la regresión" de Gretl. Lo que cambia de fila a fila es el numerador, es decir, el modelo restringido que se compara.

Primera fila: dos exclusiones a la vez, $H_0 : \beta_{\text{nox}} = \beta_{\text{stratio}} = 0$. El modelo restringido es la regresión simple de `price` sobre `rooms` que arrastramos desde la práctica B de la sesión 11 (actividad 2 (html)), con $\text{SRC}_r = 2{,}209 \cdot 10^{10}$. El aumento al quitar los dos regresores es $4{,}985 \cdot 10^9$, que repartido entre $q = 2$ dimensiones y dividido por $\mathfrak{s}^2$ da $F = 73{,}1$, frente a un valor crítico $F_c(2, 502) = 3{,}01$, con un valor p del orden de 10^{-28}. Se rechaza: la contaminación y la ratio alumnos/profesor acortan el residuo mucho más de lo que lo acortarían si sus dos coeficientes fuesen cero, caso en que solo recogerían por azar la parte de la perturbación que cae en las dos direcciones que añaden al subespacio del ajuste. Es la respuesta a la pregunta "¿sobran estas dos variables?", que ningún t individual formula.

Segunda fila: una exclusión, $H_0 : \beta_{\text{stratio}} = 0$. Ahora el modelo restringido es `price` sobre `rooms` y `nox`, con $\text{SRC}_r = 1{,}991 \cdot 10^{10}$; el aumento es $2{,}799 \cdot 10^9$, $q = 1$, y $F = 82{,}1$. Compárese con la tabla de la sección "El F en una tabla de resultados": el t de `stratio` era $-9{,}06$, y $(-9{,}06)^2 = 82{,}1$. Es la identidad $F = t^2$ con $q = 1$, ahora en un modelo con varios regresores: el contraste t de un coeficiente es el contraste F de una única restricción de exclusión, y el valor crítico $F_c(1, 502) = 3{,}86$ es el cuadrado del $t_c = 1{,}96$ de la lección 12.[11] Gretl lo confirma si se le pide la restricción con

[11] Con $k = 2$ lo demostró la transparencia "Lectura geométrica: la misma figura"; con varios regresores lo comprobamos aquí con números. La demostración general usa la fórmula de $\text{ee}(\hat{\beta}_j)$ que la lección 12 enunció y que la lección 14 leerá con la parte propia del regresor; el apéndice (sección 10) (html) la demuestra con $q = 1$ para cualquier número de regresores, a partir de la fórmula del error estándar de su sección 5.4.

`restrict` o desde el menú: devuelve un $F(1,502)$ idéntico al t^2, con el mismo valor p.

Tercera fila: una igualdad, $H_0 : \beta_{\text{nox}} = \beta_{\text{stratio}}$ ("una unidad más de concentración de óxidos de nitrógeno reduce el precio mediano tanto como un alumno más por profesor"). Esta hipótesis no excluye ningún regresor, así que hay que decir cuál es su modelo restringido. Bajo H_0 los dos coeficientes son el mismo número, β_{nox}, y sacando factor común la combinación $\beta_{\text{nox}}\boldsymbol{x}_{\text{nox}} + \beta_{\text{stratio}}\boldsymbol{x}_{\text{stratio}}$ se convierte en $\beta_{\text{nox}}(\boldsymbol{x}_{\text{nox}} + \boldsymbol{x}_{\text{stratio}})$: los dos regresores se funden en uno, la suma, y el modelo restringido es la regresión de `price` sobre `rooms` y `nox` + `stratio`. Su SRC_r es $1{,}723 \cdot 10^{10}$, apenas por encima del completo: el aumento es $1{,}213 \cdot 10^8$ y $F = 3{,}56$, ligeramente por debajo del valor crítico 3,86. No se rechaza al 5 %, con un valor p de 0,060 que conviene informar tal cual: datos como estos serían algo raros si los dos efectos fuesen iguales, pero no lo bastante para rechazar al 5 %, y la lección 12 ya advirtió que "no rechazar" no es "aceptar". Esta fila muestra que imponer una restricción es cambiar de subespacio, no necesariamente recortar regresores: el subespacio $\mathcal{L}(\mathbf{1}, \boldsymbol{x}_{\text{rooms}}, \boldsymbol{x}_{\text{nox}} + \boldsymbol{x}_{\text{stratio}})$ tiene una dimensión menos que el completo, pero no se obtiene quitando ninguna columna de $\mathbf{X}$.[12]

Esta tercera fila permite enunciar un hecho general sobre el R^2 corregido de la actividad 5 (html) de la práctica B de la sesión 14. Ese coeficiente se puede escribir $\bar{R}^2 = 1 - \frac{\text{SRC}/(n-k)}{\text{STC}/(n-1)}$: a igual STC, es mayor en el modelo cuyo residuo tiene menor longitud al cuadrado por dimensión, $\mathfrak{s}^2 = \text{SRC}/(n-k)$. En el modelo restringido el residuo vive en $n-k+q$ dimensiones y su suma de cuadrados es $\text{SRC} + (\text{SRC}_r - \text{SRC})$ por el Pitágoras anidado. Así que

$$\bar{R}_r^2 > \bar{R}^2 \iff \frac{\text{SRC}_r}{n-k+q} < \frac{\text{SRC}}{n-k} \iff (\text{SRC}_r - \text{SRC})(n-k) < q\,\text{SRC} \iff F = \frac{(\text{SRC}_r - \text{SRC})/q}{\text{SRC}/(n-k)} < 1.$$

Imponer las restricciones mejora el R^2 corregido cuando, y solo cuando, el F que las contrasta es menor que 1. El motivo: el residuo del modelo restringido, $\boldsymbol{y} - \widehat{\boldsymbol{y}}_r$, es la suma de dos vectores ortogonales, el residuo del modelo completo, $\boldsymbol{y} - \widehat{\boldsymbol{y}}$, que tiene $n-k$ dimensiones, y el cateto $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r$, que tiene q. Su suma de cuadrados por dimensión, $\text{SRC}_r/(n-k+q)$, está entre las de los dos sumandos, $\text{SRC}/(n-k)$ y $(\text{SRC}_r - \text{SRC})/q$, y es menor que la del residuo completo cuando la del cateto es la menor de las dos, es decir, cuando $F < 1$. Es la misma referencia que la significación conjunta ($\bar{R}^2 = 0$ donde $F = 1$), ahora para cualquier hipótesis lineal.

En la tabla, la tercera fila tiene $F = 3{,}56$, entre 1 y $F_c = 3{,}86$, y los dos criterios responden a preguntas distintas. El contraste pregunta si datos como estos serían demasiado raros con $\beta_{\text{nox}} = \beta_{\text{stratio}}$; como $3{,}56 < 3{,}86$, no lo son, y H_0 no se rechaza. El R^2 corregido pregunta cuál de los dos modelos tiene menor suma de cuadrados del residuo por dimensión. La del cateto $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r$,

[12] Este contraste puede hacerse también con un estadístico t, como los de la lección 12. El estimador $\hat{\beta}_{\text{nox}} - \hat{\beta}_{\text{stratio}}$ estima $\beta_{\text{nox}} - \beta_{\text{stratio}}$, que bajo H_0 vale cero; su estimación con estos datos es $-1693{,}33 - (-1166{,}96) = -526{,}4$. Para formar el t hay que dividirla por su error estándar, y eso exige la varianza del estimador, que no es la suma de las varianzas de los dos coeficientes (regla 3 del apéndice, sección 1.6 (html), con la esperanza condicional en lugar de la esperanza): $Var[\hat{\beta}_{\text{nox}} - \hat{\beta}_{\text{stratio}} \mid \boldsymbol{X}] = Var[\hat{\beta}_{\text{nox}} \mid \boldsymbol{X}] + Var[\hat{\beta}_{\text{stratio}} \mid \boldsymbol{X}] - 2\,Cov[\hat{\beta}_{\text{nox}}, \hat{\beta}_{\text{stratio}} \mid \boldsymbol{X}]$. Las dos varianzas están en la diagonal de la matriz $Var[\widehat{\boldsymbol{\beta}} \mid \boldsymbol{X}] = \sigma^2(\boldsymbol{X}^\top\boldsymbol{X})^{-1}$ de la lección 11, y la covarianza fuera de la diagonal, $Cov[\hat{\beta}_{\text{nox}}, \hat{\beta}_{\text{stratio}} \mid \boldsymbol{X}] = E[(\hat{\beta}_{\text{nox}} - \beta_{\text{nox}}\,1)(\hat{\beta}_{\text{stratio}} - \beta_{\text{stratio}}\,1) \mid \boldsymbol{X}]$; la tabla de resultados muestra las primeras (los cuadrados de los errores estándar), pero no la segunda. Sustituyendo σ^2 por $\mathfrak{s}^2$, las varianzas estimadas son $236{,}25^2 = 55\,814$ y $128{,}76^2 = 16\,579$, la covarianza estimada es $-2\,719$, y el error estándar de la diferencia es $\sqrt{55\,814 + 16\,579 + 2 \cdot 2\,719} = 279{,}0$. El estadístico es $t = -526{,}4/279{,}0 = -1{,}887$, que bajo H_0 sigue la distribución t con 502 grados de libertad, y su cuadrado, 3,56, es el F de la tabla: $F = t^2$ también aquí, porque la restricción es una sola ($q = 1$). La vía de las sumas de cuadrados da el mismo resultado sin necesitar la covarianza.

$(\text{SRC}_r - \text{SRC})/q = 1{,}213 \cdot 10^8$, es 3,56 veces la del residuo completo, $\mathfrak{s}^2 = 3{,}408 \cdot 10^7$; como el residuo restringido es la suma de los dos, su suma de cuadrados por dimensión es mayor que la del completo, y el R^2 corregido del modelo con la suma `nox` + `stratio` es menor que el del modelo completo. Para que fuese mayor haría falta $F < 1$. Así que "no se rechaza H_0" y "el R^2 corregido prefiere el modelo restringido" son cosas distintas, con umbrales distintos: F_c para la primera y 1 para la segunda. Cuando F cae entre 1 y F_c, como aquí, el contraste no rechaza la restricción, porque solo la rechaza cuando los datos son muy raros bajo ella, y el ajuste corregido no la impone, porque solo compara residuos por dimensión.

En Gretl, las tres filas se obtienen sin construir ni estimar el modelo restringido: en la ventana del modelo completo, el menú `Contrastes -> Restricciones lineales` (o el bloque `restrict` que la práctica A de la sesión 18 usó con `b[2]=0`, actividad 3 (html)) acepta cualquier sistema de ecuaciones lineales sobre los coeficientes y devuelve el F con sus dos grados de libertad y su valor p. Un laboratorio posterior lo aplicará con varias restricciones a la vez y comprobará, estimando los dos modelos, que el F que imprime es el cociente de sumas de cuadrados de esta lección.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.4 (contrastar $\beta_j = \beta_h$ como un t con la covarianza de los estimadores, y por qué la vía del modelo restringido es más cómoda); manual de Gretl, comando `restrict`.

8 Conjunto ≠ individual: el caso de la apertura

Regresores, además de `rooms`	t de `nox`	t de `lnox`	R^2	F de excluir ambos
`nox`	-7,43		0,5352	
`lnox`		-7,51	0,5361	
`nox` y `lnox`	0,18	-1,05	0,5362	28,2 ($F_c = 3{,}01$)

$\rho_{\text{nox,lnox}} = 0{,}994$: los dos regresores en desviaciones apuntan casi en la misma dirección. Cada uno solo es muy significativo; juntos, el ajuste no puede repartir el efecto entre ellos: a cada uno le queda muy poca longitud *propia* (enunciada en la lección 12, definida en la 14), su error estándar se dispara y su t se hunde. Pero el subespacio que generan *juntos* sí acerca $\widehat{\boldsymbol{y}}$ a $\boldsymbol{y}$, y el F lo mide.

Un F conjunto alto con t individuales pequeños es la firma de la *colinealidad* (lección 14). La conclusión correcta no es "sobran los dos", sino "no se puede separar el efecto de uno del efecto del otro".

Conjunto ≠ individual: el caso de la apertura

Volvamos a la tabla con la que abrimos la sesión, ahora con la herramienta para leerla. Las tres filas de la transparencia son tres regresiones del precio mediano de la vivienda: sobre `rooms` y la concentración de óxidos de nitrógeno `nox`; sobre `rooms` y el logaritmo de esa concentración, `lnox`; y sobre `rooms` y las dos medidas a la vez. Las dos primeras dicen lo mismo: el t de la contaminación, $-7{,}4$ o $-7{,}5$, tiene el signo de su coeficiente, así que el coeficiente es negativo, y está muy lejos del valor crítico $\pm 1{,}96$, así que se separa con claridad de cero; el R^2 es 0,535 o 0,536. Medirla en niveles o en logaritmos apenas cambia el resultado, porque la correlación entre `nox` y `lnox` es 0,994; en el lenguaje de la lección 5, sus vectores en desviaciones forman un ángulo de unos 6°, prácticamente la misma dirección.

La tercera fila, leída fila a fila, dice otra cosa. Con las dos medidas en el modelo, el t de `nox` cae a 0,18 y el de `lnox` a $-1{,}05$; los valores p son 0,854 y 0,295, y la lectura fila a fila de la lección 12 podría llevar a asumir que ninguna de las dos interviene. Pero el R^2 apenas ha cambiado (0,5362) y el F de excluir las dos a la vez vale $F(2, 502) = 28{,}2$ frente a un crítico de 3,01: quitar la contaminación del modelo, en cualquiera de sus dos formas, alarga el residuo mucho más de lo que cabe esperar por azar. Los dos coeficientes *juntos* son significativos; *cada uno* no lo es en presencia del otro.

La lección 12 dio la clave en su recapitulación: con varios regresores, el error estándar de $\hat{\beta}_j$ es $\mathfrak{s}/\|\tilde{\boldsymbol{x}}_j\|_e$, donde $\tilde{\boldsymbol{x}}_j$ es lo que le queda de *propio* al regresor j tras descontar lo que comparte con los demás. Cuando `nox` y `lnox` están los dos en el modelo, casi toda la variación de cada uno la comparte con el otro. La parte propia de cada uno es un vector muy corto, el error estándar de cada coeficiente se dispara y el t se hunde: compárense los errores estándar de `nox` y `lnox` en la tabla de la apertura, 2198,85 y 12655,7, con los 236,25 que tenía `nox` en el modelo con `rooms` y `stratio`, sin `lnox`, en la sección "El F en una tabla de resultados". El contraste t de `nox` pregunta si `nox` aporta algo *que* ***`lnox`*** *no aporte ya* (con la constante y `rooms` en el modelo), y los datos no permiten afirmar que aporte; y lo mismo al revés. Pero esa es una pregunta sobre la *dirección propia* de cada regresor, no sobre el subespacio que generan entre los dos. Ese subespacio, un plano dentro de $\mathcal{L}(\mathbf{1})^{\perp}$, sí acerca el ajuste a $\boldsymbol{y}$: la dirección que `nox` y `lnox` comparten recoge una parte grande de la variación del precio, aunque los datos no permitan afirmar que uno añada algo que el otro no aportara ya. El F de excluir ambas mide eso: cuánto se alarga el residuo si se suprime el plano entero. Por eso el F es grande mientras los dos t son pequeños.

Esta situación tiene nombre, *colinealidad*, y le dedicaremos la lección 14. La lectura correcta de la tabla importa porque el error contrario es frecuente en informes y artículos: ante dos regresores con t pequeños, eliminar los dos "porque no son significativos". El contraste conjunto dice que eso es un error: los datos no permiten *separar* el efecto de uno del efecto del otro, pero el F rechaza que sobren los dos a la vez. Qué hacer depende de para qué se quiere el modelo. Si el objetivo es solo predecir el precio, no hay nada que arreglar: el modelo con las dos medidas ajusta al menos tan bien como cualquiera de los otros dos y puede dejarse como está. Si la pregunta económica exige distinguir el efecto de una medida del efecto de la otra, hay que reconocer que estos datos no lo permiten; y quitar una de las dos no lo resuelve, porque el coeficiente de la que queda recoge lo que ambas comparten. La lección 14 vuelve sobre ello. Es la moraleja de la lección 12, que con un solo regresor no constante decía que para medir un efecto hace falta que la variable varíe, trasladada a más regresores: para medir el efecto de cada uno hace falta que cada uno varíe *por su cuenta*.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5, apartado "Relationship between F and t statistics" (el ejemplo en que ningún t es significativo y el F sí lo es); y cap. 3, sección 3.4, apartado sobre multicolinealidad.

9 Qué dice y qué no dice el F

$F = \frac{n-k}{k-1} \cdot \frac{R^2}{1-R^2}$ combina, como el t, *fuerza de la relación* (el ángulo) con *dimensiones* ($n-k$ y $k-1$). Tres casos inventados, calculados con la fórmula para $k = 4$:

n	R^2	θ	F	Veredicto al 5 %
6	0,90	18,4°	6,00	no significativo ($F_c = 19{,}16$)
10	0,90	18,4°	18,00	significativo ($F_c = 4{,}76$)
1003	0,01	84,3°	3,36	significativo ($F_c = 2{,}61$)

El F del pie de cada tabla de Gretl contrasta la significación conjunta de todos los regresores no constantes (*significación global*): una prueba de mínimos, superada casi siempre con muestras grandes. Los F interesantes nacen de preguntas concretas (¿sobran estas dos variables? ¿tienen el mismo efecto?)

Con doce viviendas de `hprice2` elegidas al azar (actividad 5 (html), práctica A de la sesión 18) y el modelo `price` sobre `rooms`, `nox` y `stratio`: $F(3, 8) = 9{,}55 > 4{,}07$, significativo. Pero el t de `stratio` es $-0{,}10$ y los tres intervalos son muy anchos. El F dice que los tres regresores en conjunto acortan el residuo más de lo esperable por azar; no dice cuáles ni de qué tamaño es su efecto: eso lo dicen los coeficientes y sus intervalos. Y nada de esto establece causalidad.

Qué dice y qué no dice el F

Todo lo que la lección 12 dijo sobre la lectura del t vale para el F, y la forma $F = \frac{n-k}{k-1} \cdot \frac{R^2}{1-R^2}$ lo muestra: el estadístico es el producto de un factor que mide la fuerza de la relación en la muestra (el ángulo, el R^2) y otro que solo cuenta dimensiones. La tabla de la transparencia repite el experimento de la lección 12 con $k = 4$: tres casos inventados, no procedentes de datos, con el F calculado con la fórmula a partir de n y R^2. Las dos primeras filas tienen el mismo R^2 de 0,90, el mismo ángulo de 18,4°, y veredictos opuestos: con $n = 6$ hay solo $n - k = 2$ dimensiones para el residuo, el valor crítico de la $F_{3,2}$ es 19,16 y un F de 6 no basta; con $n = 10$ el valor crítico baja a 4,76 y $F = 18$ rechaza la H_0 con holgura. La tercera fila hace el camino inverso: un R^2 del 1 % (un ángulo de 84°, casi ortogonalidad) resulta conjuntamente significativo con mil observaciones. La comparación con la tabla análoga de la lección 12 muestra lo que el F añade al t: el número de regresores también cuenta. Allí, con $k = 2$, bastaban $n = 5$ observaciones para que un $R^2 = 0{,}90$ llevase a rechazar H_0; aquí, con $k = 4$, hacen falta más datos (en la tabla, $n = 10$), porque un mismo valor del R^2 alcanzado con tres regresores no constantes es más fácil de obtener por azar que con uno solo: hay más direcciones sobre las que proyectar, y el azar produce, en promedio, $1/(n-1)$ de R^2 por cada una de ellas, $(k-1)/(n-1)$ en total. Dividir el numerador de F entre $k-1$ compensa ese R^2 producido por azar, porque lo que F compara no son las longitudes de los dos catetos, sino lo que cada uno mide *por dirección*: el cateto explicado repartido entre sus $k-1$ direcciones y el residuo repartido entre sus $n-k$ (sección "El estadístico F"). Bajo H_0 los dos repartos estiman lo mismo, σ^2, sea cual sea k: con más regresores el cateto explicado crece por azar en proporción, y el reparto lo descuenta. Es la misma idea que motivó el R^2 ajustado.

Hay una segunda advertencia, propia del F. El F que Gretl imprime al pie de cada tabla contrasta la significación conjunta de *todos* los regresores no constantes: la hipótesis de que todos sus coeficientes sean cero, es decir, de que lo que el ajuste añade al vector de medias sea solo lo que cabe esperar por azar. Es una prueba de mínimos sobre la validez del modelo: si no se rechaza, no hay nada que interpretar en la tabla. Pero superar ese mínimo dice muy poco del modelo, porque nadie estima un modelo con regresores elegidos al azar; y con muestras grandes se supera casi sin excepción, como muestra la tercera fila de la tabla. En un contraste de significación global, un F grande no dice nada nuevo; uno pequeño en una muestra grande es una señal de alarma.

Los contrastes F que responden a una pregunta del investigador son los de la transparencia "Tres restricciones sobre `hprice2`": ¿sobran estas dos variables?, ¿tienen el mismo efecto?, ¿vale uno la elasticidad?, ¿son constantes los rendimientos a escala?; preguntas cuya respuesta decide cómo se especifica el modelo o qué se concluye de él. El contraste de significación global conviene mirarlo una vez y no volver sobre él.

La tercera advertencia es la que la práctica A de la sesión 18 ilustró con doce viviendas para el t (actividad 5 (html)), y que vale igual para el F. Con las doce viviendas de aquella actividad (sorteadas una sola vez, con semilla fija para poder reproducir el resultado) y el modelo de `rooms`, `nox` y `stratio`, el $F(3,8)$ de significación conjunta fue 9,55 frente a un valor crítico de 4,07: se rechaza H_0: datos como estos serían muy raros ($p = 0{,}005$) si los tres coeficientes fuesen nulos a la vez. Y sin embargo el t de `stratio` es $-0{,}10$, el de `nox`, $-2{,}6$, apenas supera el crítico 2,31, y los intervalos de confianza de los tres coeficientes son muy anchos. El rechazo de H_0 dice que alguna combinación de los regresores acerca el ajuste al precio más de lo que cabe esperar por azar; no dice cuál, ni cuánto, ni con qué precisión. Como en la lección 12, lo que informa es el coeficiente en las unidades del problema y su intervalo, y un F, como un t, solo dice si la desviación respecto a la hipótesis es distinguible del azar. Un F que no rechaza H_0 tampoco prueba que las restricciones sean ciertas: es la ausencia de evidencia en su contra, y con pocas observaciones esa ausencia es frecuente aunque H_0 sea falsa, porque con pocas observaciones el efecto de las restricciones incumplidas alarga poco el cateto $\widehat{\boldsymbol{y}} - \widehat{\boldsymbol{y}}_r$ y el valor crítico es mayor.

Y, como siempre, nada de esto establece causalidad. Un F conjunto significativo dice que la proyección de $\boldsymbol{y}$ sobre el subespacio de los regresores es más larga de lo que el azar produciría; de si alguno de esos regresores *causa* el regresando no dice nada, por las mismas razones de las lecciones 8, 9 y 12. Las correlaciones espurias producen F grandes igual que producen t grandes.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.2f (significación económica frente a estadística, que se aplica sin cambios al F) y sección 4.5, apartado sobre el valor p del contraste F.

10 Recapitulación y guiño a las sesiones siguientes

Pieza	Fórmula	Lectura geométrica
F de significación conjunta	$\frac{\mathrm{SEC}/(k-1)}{\mathrm{SRC}/(n-k)} = \frac{n-k}{k-1}\frac{R^2}{1-R^2}$	razón de longitudes al cuadrado de los catetos, cada una por su dimensión
F de q restricciones	$\frac{(\mathrm{SRC}_r - \mathrm{SRC})/q}{\mathrm{SRC}/(n-k)}$	el mismo triángulo, con $\widehat{\boldsymbol{y}}_r$ en el papel de $\overline{\boldsymbol{y}}$
Caso $q = 1$	$F = t^2$, $F_c = t_c^2$	el contraste t es un F de una restricción
Grados de libertad	$k-1$ (o q) y $n-k$	dimensiones de los dos catetos
Región crítica	$F > F_c$ (una cola)	cono alrededor del subespacio de los regresores

Un único ingrediente nuevo: dividir cada cateto por su dimensión. Demostrado: Pitágoras anidado y $F = t^2$ (con $k = 2$). Enunciado (demostración en el apéndice): la distribución $F_{q,\,n-k}$.

Lección 14: colinealidad. La longitud propia $\|\tilde{\boldsymbol{x}}_j\|_e$ de cada regresor y el *factor de inflación de la varianza* explican con números el caso de `nox` y `lnox`. *En un laboratorio posterior*: `restrict` con varias restricciones a la vez, y la distribución del F bajo H_0 con datos simulados.

Recapitulación y guiño a las sesiones siguientes

La sesión tiene un solo ingrediente nuevo. Todo el aparato (el triángulo, las sumas de cuadrados, el R^2, la cuasivarianza $\mathfrak{s}^2$, la isotropía de las coordenadas de la perturbación bajo normalidad) estaba ya disponible desde las lecciones 8, 11 y 12. Lo único que hoy hemos añadido es una idea: comparar los dos catetos *por dimensión*, dividiendo cada suma de cuadrados por el número de direcciones del subespacio donde vive. Con ella, el contraste t de la lección 12 resulta ser el caso de una sola dirección, y el contraste de cualquier hipótesis lineal sobre los coeficientes (excluir, igualar, fijar) se reduce a una única receta: estimar el modelo con y sin la hipótesis, leer las dos sumas de cuadrados residuales y contar dimensiones.

La tabla resume las piezas. Como en la lección 12, distingamos lo demostrado de lo enunciado. Se ha demostrado con material del propio curso el Pitágoras anidado (el aumento de la suma de cuadrados residual al imponer restricciones es la longitud al cuadrado de un cateto ortogonal al residuo) y las identidades $F = \frac{n-k}{k-1}\frac{R^2}{1-R^2}$ y, con $k = 2$, $F = t^2$. La distribución $F_{q,\,n-k}$ del estadístico bajo H_0 se ha enunciado en la sesión, igual que la t de Student en la lección 12; el apéndice (html) la demuestra (sección 10) a partir de una única propiedad de la normal que queda enunciada. Que numerador y denominador estimen los dos σ^2 bajo H_0 solo usa homocedasticidad e incorrelación, y está demostrado (apéndice, sección 7 (html)). La parte geométrica está demostrada en la sesión; la probabilística, en el apéndice (html).

Quedan dos hilos abiertos. El primero es el caso de `nox` y `lnox`, que hoy hemos sabido *leer* pero no *medir*. La lección 12 enunció que con varios regresores $\mathrm{ee}(\hat{\beta}_j) = \mathfrak{s}/\|\tilde{\boldsymbol{x}}_j\|_e$, con $\tilde{\boldsymbol{x}}_j$ la parte propia del regresor j; hoy hemos visto qué pasa cuando esa parte propia es casi nula: el t individual se hunde mientras el conjunto sigue siendo significativo. La lección 14 pondrá números a $\|\tilde{\boldsymbol{x}}_j\|_e$, mostrará que se calcula con una regresión auxiliar de $\boldsymbol{x}_j$ sobre los demás regresores, y de ahí saldrá el *factor de inflación de la varianza*, la medida habitual de cuánto encarece la colinealidad cada error estándar. El segundo hilo es de laboratorio. En una práctica posterior se aplicará `restrict` con varias restricciones simultáneas sobre datos reales, comprobando estimación a estimación que el F de Gretl es el cociente de sumas de cuadrados de hoy. Y se simulará, con el `loop` de la práctica A de la sesión 16 (actividad 3 (html)), la distribución del F bajo una H_0 cierta: los histogramas mostrarán que ronda 1 y que la cola derecha es la que Gretl tabula.

Para profundizar: Wooldridge, J. M. (2020), cap. 4, sección 4.5 (resumen del contraste F); cap. 3, sección 3.4, apartado "Multicollinearity" (con el que arranca la lección siguiente).