Índice general

1 De dónde venimos: el caso `nox` y `lnox` 2

2 Colinealidad exacta y colinealidad de grado 3

3 La parte propia de un regresor 4

4 Cuánto se acorta: el factor de inflación de la varianza 6

5 El caso `nox` y `lnox` con números 7

6 Por qué oscilan los coeficientes 8

7 Síntomas y diagnóstico 10

8 Qué es y qué no es 11

9 Qué hacer 12

10 Lo que no 15

11 Recapitulación y guiño a las sesiones siguientes 16

Lección 14. Colinealidad: cuando los regresores casi se alinean

Marcos Bujosa

12 de noviembre de 2026

Resumen

La lección 12 dejó enunciado que el error estándar de un coeficiente es $\mathfrak{s}/\|\tilde{\boldsymbol{x}}_j\|_e$, con $\tilde{\boldsymbol{x}}_j$ la parte *propia* del regresor. Hoy definimos esa parte propia, medimos cuánto se acorta cuando un regresor casi cae en el subespacio de los demás y leemos la consecuencia: coeficientes estimados con poca precisión e inestables, con un ajuste que no se mueve.

"El subespacio es estable; las coordenadas, no."

- (slides) — (html) — (pdf)

1 De dónde venimos: el caso `nox` y `lnox`

La lección 13 dejó un caso sin explicar: en `price` sobre `rooms`, `nox` y `lnox`, los dos t de la contaminación eran pequeños y el F de excluirlas juntas, 28,2.

Lo que cambia al añadir `lnox` (`hprice2`, $n = 506$):

Regresores, además de `rooms`	coef. de `nox`	ee($\hat{\beta}_{\text{nox}}$)	$\mathfrak{s}$
`nox`	−1884,7	253,6	6291,0
`nox` y `lnox`	404,2	2198,9	6290,4

El coeficiente pasa de −1884,7 a 404,2 y cambia de signo; el error estándar se multiplica por 8,7; $\mathfrak{s}$ apenas cambia. La lección 12 enunció $\text{ee}(\hat{\beta}_j) = \frac{\mathfrak{s}}{\|\tilde{\boldsymbol{x}}_j\|_e}$: lo que se ha acortado es $\tilde{\boldsymbol{x}}_{\text{nox}}$, la parte *propia* de `nox`.

Hoy: qué es $\tilde{\boldsymbol{x}}_j$, cuánto mide, qué le pasa al coeficiente y qué hacer.

De dónde venimos: el caso `nox` y `lnox`

La lección 13 terminó con un caso que supimos leer pero no medir. Con `rooms` y `nox` en el modelo, la contaminación tiene un t de −7,4; con `rooms`, `nox` y `lnox`, los t de las dos medidas de contaminación caen a 0,18 y −1,05, mientras que el F de excluirlas a la vez vale 28,2. Dijimos que era la firma de la colinealidad y que la lección 14 le pondría números.

Esta obra está bajo una licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional (CC BY-SA 4.0).

La tabla de la transparencia aísla lo que cambia al añadir `lnox`: el coeficiente de `nox` cambia de signo y su error estándar pasa de 253,6 a 2198,9. Lo que casi no cambia es $\mathfrak{s}$, la estimación de σ: 6291,0 frente a 6290,4. El cambio no viene, por tanto, del numerador del error estándar.

La lección 12 dejó enunciado, sin demostrar, que con varios regresores

$$\mathrm{ee}(\hat{\beta}_j) = \frac{\mathfrak{s}}{\|\tilde{\boldsymbol{x}}_j\|_e},$$

donde $\tilde{\boldsymbol{x}}_j$ es lo que le queda de propio al regresor j tras descontar lo que comparte con los demás. Si $\mathfrak{s}$ no ha cambiado y el error estándar se ha multiplicado por 8,7, la parte propia de `nox` se ha dividido por 8,7. Queda por entender qué es $\tilde{\boldsymbol{x}}_j$, por qué se acorta y cuánto.

La sesión tiene tres partes. Las cuatro primeras transparencias definen la parte propia de un regresor y miden su longitud, con el resultado que hoy se demuestra y el error estándar que se lee a partir de él. Las dos siguientes ponen números al caso `nox` y `lnox` y explican por qué los coeficientes oscilan. Las cuatro que siguen son de lectura: síntomas, qué es y qué no es la colinealidad, qué hacer y qué no hacer.

Para profundizar: Wooldridge, J. M. (2020), cap. 3, sección 3.4, apartado "Multicollinearity" (el planteamiento del problema con la fórmula de la varianza de $\hat{\beta}_j$).

2 Colinealidad exacta y colinealidad de grado

Exacta (lección 10): un regresor es combinación lineal de los demás. $\mathbf{X}^\top\mathbf{X}$ no es invertible; infinitos $\widehat{\boldsymbol{\beta}}$ dan el mismo ajuste. Ejemplo: temperatura en Celsius y en Fahrenheit.

De grado (hoy): un regresor en desviaciones forma un ángulo muy pequeño con el subespacio generado por los demás (constante incluida). Solución única, pero estimada con poca precisión e inestable.

Con dos regresores no constantes: $\rho_{\boldsymbol{x}_2\boldsymbol{x}_3}$ próximo a ± 1, es decir, $\cos\theta$ próximo a ± 1 y vectores en desviaciones casi alineados (lección 3). Con más: alguno, en desviaciones, forma un ángulo muy pequeño con el subespacio de los otros, y las correlaciones por parejas no bastan para verlo (lección 10).

Es una escala, no una frontera. La pregunta útil no es "¿hay colinealidad?" sino "¿cuánto aumenta el error estándar de cada coeficiente?".

Colinealidad exacta y colinealidad de grado

El curso ya conoce el caso extremo. En la lección 10, al deducir las ecuaciones normales, dijimos que si los regresores son linealmente dependientes la matriz $\mathbf{X}^\top\mathbf{X}$ no es invertible y el sistema tiene infinitas soluciones: infinitos vectores $\widehat{\boldsymbol{\beta}}$ producen el mismo ajuste $\widehat{\boldsymbol{y}}$. Lo llamamos *colinealidad exacta*, y la práctica que siguió a esa lección lo comprobó (actividad 6 (html)) con la temperatura en grados Celsius y en grados Fahrenheit: Gretl omite una de las dos columnas y avisa. Es una situación que se detecta sola, porque no hay nada que estimar.

La *colinealidad de grado* es el caso próximo a ese: un regresor no es combinación lineal de los demás, pero, tomado en desviaciones, forma un ángulo muy pequeño con el subespacio que

generan (constante incluida). El regresor se toma en desviaciones porque $\mathbf{1}$ está en ese subespacio: sin restar la media, cualquier regresor con una media grande frente a su dispersión formaría un ángulo pequeño con él. En el modelo de `hprice2` con `rooms`, `nox` y `lnox`, el vector de `rooms` sin restar la media forma 6° con el subespacio de los demás, y su error estándar apenas aumenta. La solución existe y es única, pero el coeficiente de ese regresor se estima con poca precisión y cambia mucho ante cambios pequeños de los datos. La palabra "grado" indica que es una escala continua: lo que hay que medir es cuánto aumenta el error estándar de cada coeficiente por este motivo.

Con dos regresores no constantes la escala es la correlación. La lección 5 definió $\rho_{\boldsymbol{x}_2\boldsymbol{x}_3}$ como el coseno del ángulo entre los vectores en desviaciones, y la lección 3 mostró que $\cos\theta = \pm 1$ si y solo si los vectores están alineados. Colinealidad exacta es $\rho = \pm 1$; colinealidad de grado es ρ cerca de ± 1. En adelante diremos que dos regresores *casi se alinean*, o que están *casi alineados*, cuando sus vectores en desviaciones forman un ángulo próximo a 0° (correlación próxima a 1) o a 180° (correlación próxima a -1); y que un regresor casi se alinea con los demás cuando, en desviaciones, forma un ángulo muy pequeño con el subespacio que generan. La lección 3 lo anunció: dos regresores muy correlacionados tienen sus vectores en desviaciones casi alineados.

Con tres o más regresores no constantes la correlación por parejas deja de bastar, por la razón que dio la lección 10: un regresor puede estar cerca del subespacio generado por los demás sin estar cerca de ninguno de ellos en particular. El ejemplo de aquella lección sirve: la renta total de un hogar frente a sus dos componentes, renta del trabajo y renta del capital. Las transparencias "La parte propia de un regresor", "Cuánto se acorta: el factor de inflación de la varianza" y "El caso `nox` y `lnox` con números" construyen la medida que sí sirve en todos los casos: la longitud de la parte propia de cada regresor.

Para profundizar: Wooldridge, J. M. (2020), cap. 3, sección 3.3 (supuesto MLR.3, no colinealidad perfecta) y sección 3.4 (la distinción con la colinealidad "imperfecta").

3 La parte propia de un regresor

Proyectamos $\boldsymbol{x}_j$ sobre el subespacio de *los demás* regresores (constante incluida), como en la lección 10. El residuo de esa *regresión auxiliar* es la parte propia:

$$\boldsymbol{x}_j = \underbrace{(\text{combinación de los demás})}_{\text{lo que comparte}} + \underbrace{\tilde{\boldsymbol{x}}_j}_{\text{lo propio}} \quad , \quad \tilde{\boldsymbol{x}}_j \perp \text{ los demás regresores.}$$

Enunciado en la lección 12 (demostración en el apéndice): $\text{ee}(\hat{\beta}_j) = \mathfrak{s}/\|\tilde{\boldsymbol{x}}_j\|_e$. Con un solo regresor no constante, $\tilde{\boldsymbol{x}}_2 = \boldsymbol{x}_2 - \mu_{\boldsymbol{x}_2}\mathbf{1}$ y se recupera la lección 12.

La parte propia de un regresor

La lección 12 habló de "la parte del regresor j que no se puede reconstruir a partir de los demás". Hoy le damos definición, y la definición es una proyección ortogonal de las de la lección 10, aplicada a un regresor en lugar de al regresando.

Tomemos el regresor $\boldsymbol{x}_j$ y el subespacio generado por todos los demás, constante incluida: $\mathcal{L}(\mathbf{1}, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_{j-1}, \boldsymbol{x}_{j+1}, \ldots, \boldsymbol{x}_k)$. Proyectar $\boldsymbol{x}_j$ sobre ese subespacio es hacer una regresión, la *regresión auxiliar* de $\boldsymbol{x}_j$ sobre los demás regresores. Esa regresión descompone $\boldsymbol{x}_j$ en dos piezas

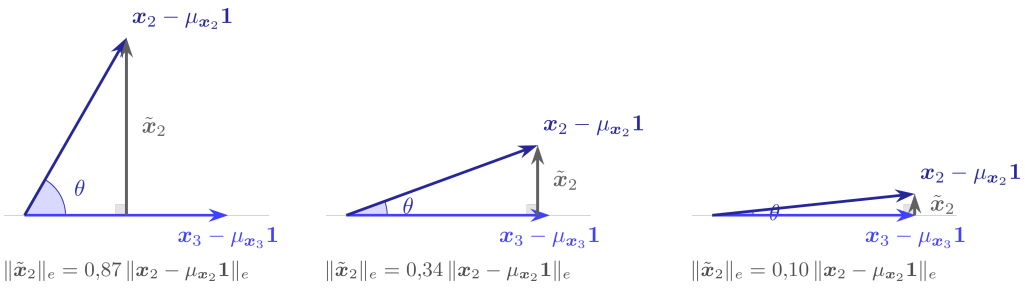


Figura 1: Dos regresores en desviaciones en el plano $\mathcal{L}(\mathbf{1})^\perp$, con ángulo θ de 60°, 20° y 6°. En azul, $\boldsymbol{x}_2 - \mu_{\boldsymbol{x}_2}\mathbf{1}$ y $\boldsymbol{x}_3 - \mu_{\boldsymbol{x}_3}\mathbf{1}$; el vector gris, que va desde la "sombra" del primero sobre la recta del segundo hasta la punta del primero, es $\tilde{\boldsymbol{x}}_2$, la parte propia de $\boldsymbol{x}_2$. Los dos regresores en desviaciones tienen la misma longitud en los tres paneles; la de la parte propia, cateto opuesto al ángulo θ, es $\operatorname{sin}\theta$ veces esa longitud: 0,87, 0,34 y 0,10.

ortogonales: el ajuste, que es la parte de $\boldsymbol{x}_j$ que los demás regresores reproducen, y el residuo, que es la parte que no reproducen. A ese residuo lo llamamos *parte propia* del regresor y lo denotamos $\tilde{\boldsymbol{x}}_j$. Por ser el residuo de una regresión (lección 10), $\tilde{\boldsymbol{x}}_j$ es ortogonal a todos los generadores del subespacio: a $\mathbf{1}$ y a cada uno de los otros regresores. Tiene, en particular, media cero.

La figura lo muestra con dos regresores no constantes, en el plano de las desviaciones. Si solo hay otro regresor, $\boldsymbol{x}_3$, el subespacio de "los demás" en desviaciones es la recta de $\boldsymbol{x}_3 - \mu_{\boldsymbol{x}_3}\mathbf{1}$, y la parte propia de $\boldsymbol{x}_2$ es la componente de $\boldsymbol{x}_2 - \mu_{\boldsymbol{x}_2}\mathbf{1}$ perpendicular a esa recta: el cateto vertical del triángulo. Aquí aparece por primera vez en el curso el seno, y no hace falta nada nuevo para leerlo: en un triángulo rectángulo el cateto opuesto al ángulo θ mide la hipotenusa por $\operatorname{sin}\theta$, igual que el cateto contiguo mide la hipotenusa por $\cos\theta$ (lección 3), y Pitágoras en ese mismo triángulo da $\cos^2\theta + \operatorname{sin}^2\theta = 1$, es decir, $\operatorname{sin}\theta = \sqrt{1-\cos^2\theta}$. En los tres paneles los dos regresores en desviaciones tienen la misma longitud; solo cambia el ángulo θ entre ellos. Con 60° la parte propia es casi todo el regresor; con 6° es una décima parte. La fórmula se establece en "Cuánto se acorta: el factor de inflación de la varianza".

Con esta definición, el enunciado de la lección 12 se lee así: el error estándar de $\hat{\beta}_j$ es la longitud del residuo, $\mathfrak{s}$, por unidad de longitud *de la parte propia* del regresor. Es la misma lectura de la lección 12, "longitud del residuo por unidad de longitud del regresor en desviaciones", con una corrección: con varios regresores no cuenta toda la longitud del regresor, solo la que no comparte con los demás. El enunciado completo tiene dos partes, y las dos son las de la regresión simple con $\tilde{\boldsymbol{x}}_j$ en el lugar del regresor en desviaciones:

$$\hat{\beta}_j = \frac{\langle \tilde{\boldsymbol{x}}_j, \boldsymbol{y}\rangle_e}{\|\tilde{\boldsymbol{x}}_j\|_e^2}, \qquad \operatorname{ee}(\hat{\beta}_j) = \frac{\mathfrak{s}}{\|\tilde{\boldsymbol{x}}_j\|_e}.$$

Cuando solo hay un regresor no constante no hay nada que compartir, la regresión auxiliar es la de $\boldsymbol{x}_2$ sobre $\mathbf{1}$, su residuo es el vector en desviaciones $\boldsymbol{x}_2 - \mu_{\boldsymbol{x}_2}\mathbf{1}$, y la fórmula es la de la lección 12. La demostración está en el apéndice (html) (sección 5.4 para la fórmula de $\hat{\beta}_j$ con la parte propia; 6.5 y 7.1 para la insesgadez y la varianza con k regresores; la insesgadez de $\mathfrak{s}^2$ con k regresores, que

la lección 11 enunció, en 7.2); aquí basta con esa lectura. El resultado, $\hat{\beta}_j$ como coeficiente de la regresión de $\boldsymbol{y}$ sobre la parte propia de $\boldsymbol{x}_j$, se conoce como *teorema de Frisch–Waugh–Lovell*, y es lo que usa la opción "Ortogonalizar" de "Qué hacer".

Para profundizar: Wooldridge, J. M. (2020), cap. 3, sección 3.2, apartado "A partialling out interpretation of multiple regression" (la regresión auxiliar y su residuo).

4 Cuánto se acorta: el factor de inflación de la varianza

Pitágoras en la regresión auxiliar (lección 8), con $\mathrm{STC}_j = \|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e^2$, $\mathrm{SRC}_j = \|\tilde{\boldsymbol{x}}_j\|_e^2$ y $R_j^2 = \cos^2\theta_j$ su coeficiente de determinación, de modo que $1 - R_j^2 = 1 - \cos^2\theta_j = \operatorname{sen}^2\theta_j$:

$$\mathrm{STC}_j = \mathrm{SEC}_j + \mathrm{SRC}_j \implies \boxed{\|\tilde{\boldsymbol{x}}_j\|_e = \|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e \operatorname{sen}\theta_j}$$

Sustituyendo en el error estándar:

$$\mathrm{ee}(\hat{\beta}_j) = \underbrace{\frac{\mathfrak{s}}{\|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e}}_{\text{si no compartiera nada}} \cdot\sqrt{\mathrm{VIF}_j}, \qquad \mathrm{VIF}_j = \frac{1}{1-R_j^2} = \frac{1}{\operatorname{sen}^2\theta_j}.$$

$\rho_{\boldsymbol{x}_2\boldsymbol{x}_3}$ (con $k=3$, $R_2^2 = \rho^2_{\boldsymbol{x}_2\boldsymbol{x}_3}$)	θ	VIF	$\sqrt{\mathrm{VIF}}$
0,5	60°	1,3	1,15
0,9	26°	5,3	2,3
0,99	8°	50	7,1
0,999	2,6°	500	22

Cuánto se acorta: el factor de inflación de la varianza

La igualdad del recuadro, la longitud de la parte propia, se deduce de lo demostrado en la lección 8 sin ningún ingrediente nuevo. La regresión auxiliar de $\boldsymbol{x}_j$ sobre los demás regresores es una regresión como cualquier otra, con $\boldsymbol{x}_j$ en el papel del regresando, así que tiene su triángulo rectángulo y su identidad STC = SEC + SRC. Escribamos las tres sumas con su subíndice j para recordar de qué regresión provienen. La suma total es la longitud al cuadrado del regresor en desviaciones, $\mathrm{STC}_j = \|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e^2$. La suma residual es la longitud al cuadrado de la parte propia, $\mathrm{SRC}_j = \|\tilde{\boldsymbol{x}}_j\|_e^2$, porque $\tilde{\boldsymbol{x}}_j$ es el residuo de esa regresión. Y el coeficiente de determinación de la regresión auxiliar, que llamaremos R_j^2, es $\mathrm{SEC}_j/\mathrm{STC}_j = 1 - \mathrm{SRC}_j/\mathrm{STC}_j$. Despejando,

$$\|\tilde{\boldsymbol{x}}_j\|_e^2 = \mathrm{SRC}_j = \mathrm{STC}_j\,(1 - R_j^2) = \|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e^2\,(1 - R_j^2).$$

Tomando raíces, $\|\tilde{\boldsymbol{x}}_j\|_e = \|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e\sqrt{1-R_j^2}$ (es Pitágoras en la regresión auxiliar, y así lo escribe el apéndice, sección 5.4 (html)). Y la lección 8 otra vez: $R_j^2 = \cos^2\theta_j$, con θ_j el ángulo entre el regresor en desviaciones $(\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1})$ y su ajuste en desviaciones en la regresión auxiliar, así que $1 - R_j^2 = 1 - \cos^2\theta_j = \operatorname{sen}^2\theta_j$ (Pitágoras en el triángulo de la figura, como se explicó al presentarla) y queda la igualdad del recuadro, $\|\tilde{\boldsymbol{x}}_j\|_e = \|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e \operatorname{sen}\theta_j$. Es lo que la figura de "La parte propia de un regresor" muestra: el cateto vertical mide la hipotenusa por el seno del ángulo. ■

Ahora sustituimos la longitud recién obtenida en la fórmula del error estándar, $\mathrm{ee}(\hat{\beta}_j) = \mathfrak{s}/\|\tilde{\boldsymbol{x}}_j\|_e$, que queda escrita como producto de dos factores:

$$\mathrm{ee}(\hat{\beta}_j) = \frac{\mathfrak{s}}{\|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e \sqrt{1-R_j^2}} = \frac{\mathfrak{s}}{\|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e} \cdot \frac{1}{\sqrt{1-R_j^2}}.$$

El primero, $\mathfrak{s}/\|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e$, es el error estándar que tendría $\hat{\beta}_j$ si el regresor no compartiera nada con los demás: la fórmula de la lección 12, con el $\mathfrak{s}$ del modelo completo. El segundo, $1/\sqrt{1-R_j^2}$, es el factor que añade compartir variación con los demás. Su cuadrado tiene nombre propio en los manuales: *factor de inflación de la varianza*, $\mathrm{VIF}_j = 1/(1-R_j^2)$, porque multiplica la varianza del estimador; al error estándar lo multiplica su raíz. En el lenguaje del curso, $\mathrm{VIF}_j = 1/\sin^2\theta_j$: cuanto más se cierra el ángulo entre un regresor en desviaciones y el subespacio de los demás, más se infla.

Con dos regresores no constantes la regresión auxiliar es simple, $\boldsymbol{x}_2$ sobre $\mathbf{1}$ y $\boldsymbol{x}_3$, y la lección 8 demostró que en regresión simple $R^2 = \rho^2$. Por tanto $R_2^2 = \rho^2_{\boldsymbol{x}_2\boldsymbol{x}_3}$ y $\mathrm{VIF}_2 = 1/(1-\rho^2_{\boldsymbol{x}_2\boldsymbol{x}_3})$, y lo mismo para $\boldsymbol{x}_3$: con $k=3$ los dos regresores tienen el mismo VIF. La tabla de la transparencia recorre la escala. Una correlación de 0,5 apenas se nota: el error estándar crece un 15 %. Una de 0,9 lo multiplica por 2,3. Una de 0,99, por 7; y con 0,999 el ángulo es de 2,6° y el error estándar se multiplica por 22. El crecimiento no es lineal en ρ: casi todo el aumento se produce en los últimos grados antes de la alineación exacta. Por eso la colinealidad apenas se nota hasta que la correlación es muy alta.

Con más de dos regresores no constantes no hay atajo: R_j^2 es el R^2 de una regresión múltiple, y hay que estimarla. Gretl lo calcula con un comando, como veremos en "El caso `nox` y `lnox` con números".

Para profundizar: Wooldridge, J. M. (2020), cap. 3, sección 3.4, ecuación de $\mathrm{Var}(\hat{\beta}_j)$ con el factor $1-R_j^2$ y la discusión del VIF que la sigue.

5 El caso `nox` y `lnox` con números

Regresión auxiliar de `nox` sobre `rooms` y `lnox` (`hprice2`): $R_j^2 = 0{,}9879$, es decir, los otros dos regresores reproducen el 98,8 % de la variación de `nox`.

Cantidad	Valor
$\|\boldsymbol{x}_{\mathrm{nox}} - \mu_{\mathrm{nox}}\mathbf{1}\|_e$ (longitud de `nox` en desviaciones de su media)	26,03
$\sqrt{1-R_j^2} = \sin\theta_j$	0,1099
$\|\tilde{\boldsymbol{x}}_{\mathrm{nox}}\|_e$ (parte propia)	2,861
$\mathrm{VIF} = 1/(1-R_j^2)$; $\sqrt{\mathrm{VIF}}$	82,8; 9,10
$\mathfrak{s}/\|\tilde{\boldsymbol{x}}_{\mathrm{nox}}\|_e = 6290{,}37/2{,}861$ (error estándar de `nox`)	$\approx$ 2198,9

El último valor, 2198,9, es el error estándar de `nox` en la tabla de la lección 13 (modelo con `rooms`, `nox` y `lnox`). Sin `lnox`, la parte propia de `nox` medía 24,81; con `lnox`, 2,861 (se ha dividido por 8,7).

En Gretl: comando `vif` tras estimar, o `Análisis -> Colinealidad` en la ventana del modelo. Devuelve 82,8 para `nox`, 82,9 para `lnox` y 1,1 para `rooms`.

El caso `nox` y `lnox` con números

Volvamos al modelo con que abrimos la sesión y hagamos la cuenta completa para `nox`. La regresión auxiliar es la de `nox` sobre la constante, `rooms` y `lnox`, y su coeficiente de determinación es $R_j^2 = 0{,}9879$: los otros regresores reproducen el 98,8 % de la variación de `nox`. Casi todo, como cabía esperar de una variable y su logaritmo, cuya correlación es 0,9939: sus vectores en desviaciones forman un ángulo de 6,3°.

Las longitudes se calculan con la fórmula de "Cuánto se acorta: el factor de inflación de la varianza". El regresor en desviaciones mide 26,03; $\sqrt{1 - R_j^2} = 0{,}1099$; la parte propia mide $26{,}03 \cdot 0{,}1099 = 2{,}861$. Y el error estándar es `s` dividido por esa longitud: $6290{,}37/2{,}861 \approx 2198{,}9$ (con todos los decimales de Gretl, 2198,85), la cifra que Gretl imprime en la tabla de apertura de la lección 13 (html). La fórmula del error estándar se cumple aquí con cuatro cifras.

Conviene leer también el factor por el que se ha multiplicado el error estándar. En el modelo sin `lnox`, la parte propia de `nox` es su residuo sobre **1** y `rooms`, y mide 24,81: casi toda su longitud en desviaciones, porque `rooms` apenas comparte nada con `nox`. Al entrar `lnox`, la parte propia baja a 2,861, un factor 8,7, y el error estándar sube en el mismo factor, de 253,6 a 2198,9. No han cambiado ni `s` ni el número de observaciones; solo la longitud propia de `nox`.

Gretl calcula los factores de inflación con el comando `vif`, que se ejecuta después de estimar el modelo, o desde el menú `Análisis -> Colinealidad` de la ventana del modelo. Para nuestro modelo devuelve 82,8 para `nox`, 82,9 para `lnox` y 1,1 para `rooms`: las dos medidas de contaminación comparten casi toda su variación y ninguna comparte casi nada con `rooms`. Con la salida de Gretl y esta lección, un VIF se lee así: es $1/\operatorname{sin}^2\theta_j$, y su raíz es el factor por el que se ha multiplicado el error estándar del coeficiente respecto al que tendría si el regresor no compartiera variación con los demás regresores. Con 82,8, ese factor es 9,10; y en efecto $241{,}6 \cdot 9{,}10 \approx 2198{,}9$, donde 241,6 es `s` dividido por la longitud completa del regresor en desviaciones.

Para profundizar: manual de Gretl, comando `vif`; Wooldridge, J. M. (2020), cap. 3, sección 3.4 (el VIF como estadístico de diagnóstico y sus límites).

6 Por qué oscilan los coeficientes

$\widehat{\boldsymbol{y}}$ es la proyección de $\boldsymbol{y}$ sobre el subespacio de los regresores y no depende de qué generadores lo describan. Las estimaciones $\hat{\beta}_2$ y $\hat{\beta}_3$ son las *coordenadas* de $\widehat{\boldsymbol{y}}$ respecto de los generadores, y sí dependen de ellos: con generadores casi alineados son inestables.

Un desplazamiento de $\widehat{\boldsymbol{y}}$ perpendicular a $\boldsymbol{x}_2$ cambia $\hat{\beta}_3$ en $1/\operatorname{sin}\theta = \sqrt{\text{VIF}}$ veces ese desplazamiento, y $\hat{\beta}_2$ lo compensa con signo contrario. SRC, R^2 y F dependen de $\widehat{\boldsymbol{y}}$, no de sus coordenadas: la colinealidad no los altera.

Por qué oscilan los coeficientes

El error estándar dice cuánto se dispersa el estimador de un coeficiente de una muestra a otra. La figura dice por qué se dispersa tanto cuando los regresores casi se alinean, y lo dice sin probabilidad: es geometría de coordenadas.

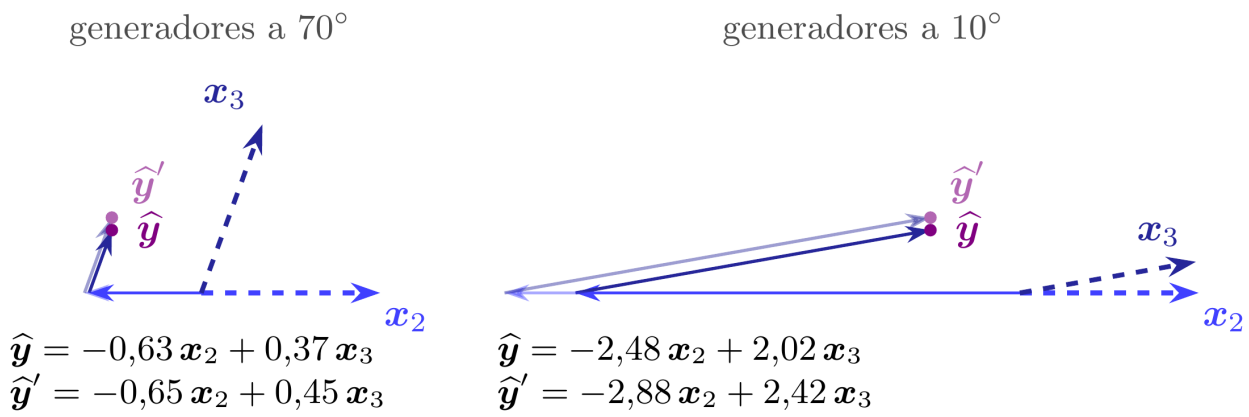


Figura 2: Dos regresores en desviaciones y de longitud 1 (a trazos), que forman 70° a la izquierda y 10° a la derecha, y el mismo ajuste en desviaciones $\widehat{\boldsymbol{y}}$ en los dos paneles. Los tramos continuos son su descomposición $\hat{\beta}_2\boldsymbol{x}_2 + \hat{\beta}_3\boldsymbol{x}_3$: primero $\hat{\beta}_2\boldsymbol{x}_2$, horizontal y hacia la izquierda porque $\hat{\beta}_2 < 0$, y después $\hat{\beta}_3\boldsymbol{x}_3$ hasta $\widehat{\boldsymbol{y}}$. $\widehat{\boldsymbol{y}}'$ es el ajuste que daría otra muestra: dista 0,07 de $\widehat{\boldsymbol{y}}$ en la dirección perpendicular a $\boldsymbol{x}_2$, y su descomposición va en color más claro. A 70° las coordenadas cambian poco, lo mismo que el ajuste; a 10° cambian 0,40 cada una y en sentidos opuestos, casi seis veces el desplazamiento del ajuste: el factor es $1/\operatorname{sin} 10°$.

Recordemos la lección 10: $\widehat{\boldsymbol{y}}$ es la proyección de $\boldsymbol{y}$ sobre el subespacio de los regresores, y $\widehat{\boldsymbol{\beta}}$ son las coordenadas de esa proyección respecto de los generadores, *lo que hay que avanzar en la dirección de cada regresor para llegar a* $\widehat{\boldsymbol{y}}$. La proyección depende del subespacio, no de qué generadores lo describan. Las coordenadas sí dependen de los generadores, y de cómo estén colocados.

La figura toma dos regresores en desviaciones de longitud 1 y un ajuste $\widehat{\boldsymbol{y}}$ en el plano que generan. Si cambia muy ligeramente $\boldsymbol{y}$, cambiará muy ligeramente el ajuste; vamos a representar esa idea con un segundo ajuste $\widehat{\boldsymbol{y}}'$ próximo al primero (a distancia 0,07). Con los generadores a 70°, las coordenadas pasan de (−0,63; 0,37) a (−0,65; 0,45): cambios del mismo orden que el desplazamiento. Con los generadores a 10°, pasan de (−2,48; 2,02) a (−2,88; 2,42): cada coordenada cambia 0,40, casi seis veces el desplazamiento, y una sube lo que la otra baja. La cuenta exacta es sencilla para un desplazamiento perpendicular a $\boldsymbol{x}_2$: la coordenada de $\boldsymbol{x}_3$ cambia $1/\operatorname{sin}\theta$ veces el desplazamiento, y la de $\boldsymbol{x}_2$ lo compensa con signo contrario. Ese factor $1/\operatorname{sin}\theta$ es $\sqrt{\text{VIF}}$, el mismo de "Cuánto se acorta: el factor de inflación de la varianza": el error estándar mide con probabilidad lo que la figura muestra con geometría.

Dos consecuencias. La primera es que los estimadores de los coeficientes de regresores cuyos vectores en desviaciones casi se alinean no solo son imprecisos, sino que lo son *simultáneamente*: con correlación positiva entre los regresores, como en la figura, oscilan en sentidos opuestos (en las muestras en que uno resulta mayor, el otro resulta menor); con correlación negativa, en el mismo sentido. El signo de la covarianza entre los dos estimadores es el contrario al de la correlación entre los regresores. Para verlo basta sustituir $\boldsymbol{x}_3$ por $-\boldsymbol{x}_3$: la correlación entre los regresores cambia de signo, el coeficiente de $\boldsymbol{x}_3$ también, y con él la covarianza entre los dos estimadores. Lo que no depende del signo es que las coordenadas cambian de forma que el ajuste apenas se mueve. La

lección 11 dio, en su fórmula matricial y para $k = 2$, la covarianza entre $\hat{\beta}_1$ y $\hat{\beta}_2$, negativa cuando la media del regresor es positiva; con regresores casi alineados y correlación positiva, la covarianza entre $\hat{\beta}_2$ y $\hat{\beta}_3$ es muy negativa, y así lo comprobaremos con un experimento de Montecarlo en la práctica A de la sesión 22 (actividad 2 (html)). Es lo que se veía en la tabla de la lección 13: con `lnox` en el modelo, el coeficiente de `nox` pasa de $-1884{,}7$ a $404{,}2$ y el de `lnox` es -13262, de signo opuesto. Lo que apenas cambia es lo que los dos términos dan juntos: cuando `nox` pasa de 5 a 6, el precio ajustado baja 1885 dólares en el modelo con `nox` y 2014 en el modelo con `nox` y `lnox`.

La segunda consecuencia es la que hay que retener para leer resultados. Lo que la colinealidad estropea son las coordenadas; no el ajuste. $\widehat{\boldsymbol{y}}$ es el mismo punto se describa como se describa, así que SRC, R^2, $\mathfrak{s}$ y el F de significación conjunta no dependen del ángulo que formen los generadores. Por eso la lección 13 podía decir que las dos variables juntas acortan el residuo más de lo esperable por azar y, a la vez, que no puede determinarse el efecto individual de cada una, porque la muestra no permite separarlos: el subespacio que generan es estable; pero la estimación de cómo se reparte el efecto entre ellas, no.

Para profundizar: Wooldridge, J. M. (2020), cap. 3, sección 3.4 (el ejemplo de gasto por alumno en varias partidas, en el que dos regresores con vectores en desviaciones casi alineados tienen coeficientes estimados con poca precisión mientras el conjunto está bien estimado).

7 Síntomas y diagnóstico

- F conjunto alto con t individuales bajos (lección 13), o R^2 alto con casi nada significativo.
- Errores estándar que se multiplican al añadir un regresor, sin que apenas cambie $\mathfrak{s}$.
- Coeficientes muy sensibles a quitar unas pocas observaciones o a añadir un regresor.
- Correlaciones altas entre regresores (pero con $k > 3$ no bastan; mejor diagnóstico con el VIF_j de cada uno).

Una distinción: que un coeficiente cambie al añadir un regresor es normal, es el efecto parcial de la lección 10. Colinealidad es que su error estándar se multiplique y que el coeficiente cambie mucho al añadir o quitar pocas observaciones.

Qué mirar: $\sqrt{\text{VIF}_j}$, el factor por el que se ha multiplicado el error estándar de $\hat{\beta}_j$. Es una escala, no un veredicto: en los coches de la práctica C de la sesión 22 el VIF es 142 y los dos t son grandes, 10 y $-7{,}5$.

Síntomas y diagnóstico

La colinealidad de grado, a diferencia de la exacta, no es de inmediata detección: Gretl estima el modelo sin ningún aviso. Hay que reconocerla en la tabla, y los síntomas son los que las lecciones anteriores ya han producido.

El primero es el de la lección 13: un F de significación conjunta alto con t individuales bajos, o un R^2 alto en un modelo donde casi ningún coeficiente es significativo. El F y el R^2 miran el subespacio; los t miran las coordenadas. Que discrepen significa que los regresores juntos acortan

el residuo más de lo esperable por azar, pero que la muestra no permite atribuir esa reducción a uno u otro: cada coordenada por separado está mal determinada.

El segundo es el de la tabla de apertura: un error estándar que se multiplica al añadir un regresor mientras `s` no cambia. Conviene contrastar ese síntoma con lo que sí es normal. En la lección 10 y en su laboratorio (actividad 3 (html)) vimos que un coeficiente cambia de valor, y hasta de signo, al añadir un regresor. Es el efecto parcial: el significado del coeficiente cambia porque se mantiene fija otra variable. Eso no es colinealidad. Colinealidad es que, además, el error estándar se multiplique por un factor grande. El tercer síntoma es que el coeficiente se vuelva sensible a cambios pequeños de la muestra: quitar unas pocas observaciones y verlo saltar, como ocurría con las viviendas del laboratorio de regresión múltiple (actividad 6 (html)).

El cuarto es la correlación entre regresores, el síntoma más usado y el menos fiable. Con dos regresores no constantes basta, porque VIF $= 1/(1-\rho^2)$. Con más, la lección 10 explicó por qué no: un regresor en desviaciones puede formar un ángulo muy pequeño con el subespacio generado por otros dos sin estar muy correlado con ninguno. La medida que sirve en todos los casos es el VIF de cada regresor, que Gretl calcula con `vif`, y en particular su raíz, que es el factor por el que se ha multiplicado el error estándar.

Los manuales suelen dar una regla: un VIF mayor que 10 indica un problema. Conviene saberla, porque Gretl la imprime al pie de la salida de `vif`, y conviene saber también que es arbitraria: 10 significa que el error estándar se ha multiplicado por 3,2, y si ese factor es grave o no depende de para qué se quiera el coeficiente. Un VIF de 5 que convierte un intervalo estrecho en uno inservible es un problema; un VIF de 50 en un coeficiente que sigue siendo significativo y con un intervalo aceptable no lo es. Léase la escala, no el umbral. En los coches de la práctica C de la sesión 22 (actividad 4 (html)) el VIF de la edad y el de las millas es 142: cada error estándar se multiplica por 11,9. Aun así los dos t son 10 y $-7{,}5$, y el contraste rechaza que cada coeficiente valga cero.

Para profundizar: Wooldridge, J. M. (2020), cap. 3, sección 3.4 (por qué la regla del VIF mayor que 10 es arbitraria y qué debe mirarse en su lugar).

8 Qué es y qué no es

No es una violación de los supuestos: MCO sigue insesgado y BLUE (lección 11) y los contrastes siguen siendo válidos (lección 12). Los errores estándar grandes son correctos: describen la muestra.

No estropea el ajuste, el R^2 ni la predicción: $\widehat{\boldsymbol{y}}$ es el mismo.

Es una propiedad de la muestra: falta variación *propia*. Es el mismo problema que tener pocos datos.

Para estimar el efecto de una variable hace falta que esa variable varíe *por su cuenta*.

Qué es y qué no es

Los manuales tratan la colinealidad en el capítulo de "problemas" del modelo, y conviene precisar qué clase de problema es, porque no es del tipo de los que vendrán en las lecciones siguientes. En realidad es un problema de la muestra.

No es una violación de los supuestos. Los supuestos del Modelo Clásico hablan de la perturbación y del modelo poblacional; la colinealidad de grado habla de los regresores de la muestra, y ningún supuesto prohíbe que estén correlados. El único que se refiere a la relación de los regresores entre sí, la independencia lineal de la lección 10, prohíbe solo el caso exacto. Con colinealidad de grado, todo lo demostrado sigue siendo válido: el estimador $\hat{\beta}_j$ es insesgado, su varianza es la que dice la fórmula y, aunque aquí sea muy grande, no hay estimador lineal insesgado con una varianza más pequeña (lección 11); los errores estándar de Gretl son correctos y los contrastes t y F valen (lección 12). Los errores estándar grandes informan de que esa muestra no permite estimar ese coeficiente con precisión.

Tampoco estropea el ajuste. Como se vio en "Por qué oscilan los coeficientes", $\widehat{\boldsymbol{y}}$ es la proyección sobre el subespacio, y el subespacio no depende de cómo se le describa. SRC, R^2, $\mathfrak{s}$ y las predicciones son los mismos con generadores casi alineados que con generadores perpendiculares. Si lo que se quiere del modelo es predecir para combinaciones de regresores como las observadas, la colinealidad no es un problema.

Lo que sí es: una propiedad de la muestra, la falta de variación propia. Un regresor con parte propia corta es un regresor que, dentro de esta muestra, casi no varía por su cuenta; y sin variación propia no hay forma de medir su efecto separado. Es la misma situación que tener pocos datos: con las doce viviendas de la práctica A de la sesión 18 (actividad 5 (html)) el intervalo de confianza del coeficiente de `rooms` iba de 1900 a 20000 dólares porque el regresor en desviaciones era corto; con `nox` y `lnox` juntas, la parte propia de cada una es corta. En los dos casos falta longitud, y por eso el remedio "más información" de "Qué hacer" es ese: más datos, o mejores datos.

La falta de variación propia es el punto de llegada de una idea que el curso repite desde la lección 11. Allí, la fórmula de la varianza decía "más dispersión en X, más precisión". La lección 12 la dibujó con el regresor concentrado y el disperso: para estimar bien el efecto de una variable hace falta que esa variable varíe. Hoy, con varios regresores, la idea toma su forma definitiva: hace falta que varíe *por su cuenta*, no a la vez que las demás.

Para profundizar: Wooldridge, J. M. (2020), cap. 3, sección 3.4, la comparación entre colinealidad y tamaño muestral pequeño; Goldberger, A. S. (1991), *A Course in Econometrics*, cap. 23, donde acuñó "micronumerosidad" para subrayar que son el mismo problema.

9 Qué hacer

- *Nada si el objetivo es predecir sin extrapolar*: el ajuste no depende de los generadores.
- *Obtener más información*: más datos, o datos con mayor variación (rentas, tamaños, edades o países más dispares), con regresores que varíen por separado.
- *Reformular*: quedarse con una de las dos variables o con una combinación, o imponer una restricción y contrastarla con el F (lección 13). Puede ganarse precisión, y se pierde lo que aportaba al ajuste la que sale. Mirar qué cambia en las predicciones: `nox` o `lnox` describen la realidad de forma distinta. Con dos magnitudes distintas, como la edad y las millas de un coche, cambia además lo que mide el coeficiente que queda: 28 dólares por semana a igual kilometraje; 7,3 con la edad sola.

- *Ortogonalizar*: sustituir un regresor por su parte propia (el residuo de su regresión auxiliar), que es ortogonal a los demás. El ajuste no cambia; cambia la interpretación de los coeficientes.

Qué hacer

Antes de buscar remedios debemos hacernos una pregunta previa: para qué se quiere el modelo. Si es para predecir, vale lo dicho en "Qué es y qué no es": el ajuste es el mismo con cualquier descripción del subespacio; es decir, no hay nada que hacer dado que la colinealidad no supone un problema para la predicción. La predicción es la misma, con el mismo error estándar; la actividad 6 (html) de la práctica C de la sesión 22 lo comprueba con dos coches, antes y después de sustituir la edad por su parte propia. Lo que sí hay que vigilar es para qué combinación de regresores se predice. Con regresores casi alineados, como la edad y las millas de esos coches, un coche de 300 semanas y 10 mil millas está dentro del rango de cada variable y, sin embargo, lejos de los pares observados en la muestra: predecir ahí es extrapolar, y el error estándar de esa predicción, la dispersión del valor ajustado en ese punto de una muestra a otra, es siete veces el de un coche con una combinación de edad y millas habitual. Los remedios que siguen son para cuando el objetivo es conocer el efecto de cada variable.

Si la colinealidad es falta de variación propia, el remedio de fondo es conseguirla, y solo hay una manera: más información. Las demás opciones no la crean. Reformular el modelo cambia la pregunta por otra que la muestra sí responde; sustituir un regresor por su parte propia cambia la interpretación de los coeficientes. Y, antes que cualquiera de ellas, hay una obligación: decir que la muestra no responde a la pregunta.

El primer remedio, más información, requiere precisar qué información. La fórmula del error estándar usa la longitud euclídea de la parte propia, $\|\tilde{\boldsymbol{x}}_j\|_e$, la de la lección 2 que no divide por n: su cuadrado es una suma de n sumandos, uno por observación, y ninguno es negativo. Al añadir una observación la regresión auxiliar cambia, pero los n sumandos anteriores no pueden sumar menos que antes, porque los coeficientes anteriores hacían mínima esa suma (lección 10), y el sumando nuevo no es negativo. Por eso una observación nueva nunca acorta la parte propia; la alarga tanto más cuanto más se aparte, en el regresor j, de lo que los demás regresores reproducen de ella.[1] Cuánto se alarga depende de qué observaciones se añaden. Si son más observaciones de la misma población, nuevas copias de las mismas variables aleatorias, como las de la matriz de copias del apéndice de geometría (html), secciones 2 y 3, la varianza muestral de cada regresor y la correlación entre regresores apenas cambian, porque aproximan la varianza y la correlación de la población. El VIF se queda donde estaba, la longitud de la parte propia crece con $\sqrt{n}$ y el error estándar baja a ese ritmo: para dividirlo por dos hay que cuadruplicar la muestra. Es el remedio contra tener pocos datos, y es caro.

La otra manera de obtener más información es cambiar la población de la que se muestrea, para que los regresores varíen por separado. En los coches de la práctica C, edad y millas van juntas porque los coches de la muestra tienen un uso parecido, y por eso quedan casi sobre una recta (figura de la actividad 1 (html)). Una muestra que incluyera coches viejos con poco uso y coches jóvenes con mucho (el segundo coche de un hogar, un taxi, una furgoneta de reparto) añadiría

[1] Con la norma estadística de la lección 2, que divide por n, la longitud al cuadrado del regresor en desviaciones es su varianza muestral y no crece con n. Las dos normas se relacionan por $\|\boldsymbol{x}\|_e^2 = n\|\boldsymbol{x}\|_s^2$, y la de la parte propia es $\|\tilde{\boldsymbol{x}}_j\|_e^2 = n\,\|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_s^2\,(1 - R_j^2)$: la varianza muestral del regresor, por lo que no comparte con los demás, por n.

observaciones alejadas de esa recta, y bastan pocas para alargar la parte propia de cada regresor. Es la regla general con datos económicos: para separar el efecto de la renta del de la edad, o el del tamaño de una empresa del de su antigüedad, hace falta una muestra con rentas, edades, tamaños o antigüedades más dispares y, sobre todo, con combinaciones que no vayan siempre juntas: jóvenes con renta alta y mayores con renta baja, empresas grandes y jóvenes. Ampliar el ámbito de la muestra (más países, más sectores, más años) suele ser la manera de conseguirlo. Quien diseña un experimento elige esas combinaciones directamente, y en eso consistía la pregunta 4 (html) de la práctica B de la sesión 16; con datos reales observados en la economía (o en la sociedad), como la población es la que es, se suele perder la posibilidad de diseñar la muestra (ninguna, o casi ninguna, empresa joven es grande desde sus inicios); esa es la razón por la que la colinealidad es más difícil de evitar en economía aplicada.

El segundo remedio es reformular el modelo: quitar un regresor, o fundir dos en uno. Conviene distinguir tres casos, porque lo que se pierde no es lo mismo. Si dos variables son la misma magnitud, una en niveles y otra en logaritmos, como `nox` y `lnox`, la segunda no añade información sobre las viviendas; añade una forma funcional. Quedarse con una no pierde información, pero obliga a elegir entre dos descripciones distintas de la realidad: con `nox` en niveles, cada unidad más de contaminación resta lo mismo al precio; con `lnox`, resta cada vez menos (la interpretación de los regresores en logaritmos se verá en la lección 15). Las dos descripciones ajustan los datos de la muestra casi igual de bien, como mostró la lección 13 con el modelo con `nox` y el modelo con `lnox`: una recta y una curva logarítmica pasan casi por los mismos puntos allí donde hay muchos barrios, en los niveles de contaminación habituales. Se separan en los extremos, donde hay pocos barrios: en el barrio más contaminado de la muestra la recta predice unos 800 dólares menos que la curva, y la diferencia crece fuera del rango observado. Elegir una u otra es elegir qué se predice fuera de lo habitual, y la muestra apenas ayuda a decidirlo.

El segundo caso es el de dos magnitudes distintas que en la muestra se mueven juntas, como la edad y las millas de un coche. Aquí quitar una sí pierde información: el modelo deja de distinguir lo que las dos distinguían. A cambio, el estimador del coeficiente de la que queda gana precisión, y el coeficiente cambia de significado. Con las dos variables, el coeficiente de la edad, 28,02, es el efecto de una semana más de edad *a igual kilometraje*. Con la edad sola, el coeficiente es 7,34, y es el efecto de una semana más de edad *junto con* el de las millas que esa semana trae consigo: en la muestra, por cada semana más de edad un coche tiene, en promedio, 134 millas más (0,134 es la pendiente de la regresión de `miles` sobre `age`). La identidad de la actividad 2 (html) de la práctica C, $7{,}34 \approx 28{,}02 - 154{,}6 \cdot 0{,}134$, lo descompone en el efecto de la edad a igual kilometraje más el efecto de esas 134 millas. Son dos preguntas distintas, y la muestra responde con más precisión a la segunda. Es un intercambio: precisión a cambio de una pregunta menos fina.

El tercer caso es que la teoría diga algo sobre los coeficientes. Una restricción lineal sobre β_2 y β_3 funde los dos regresores en uno. Con $\beta_2 = \beta_3$, el término $\beta_2\boldsymbol{x}_2 + \beta_3\boldsymbol{x}_3$ se escribe $\beta_2(\boldsymbol{x}_2 + \boldsymbol{x}_3)$, y el modelo pasa a tener el regresor $\boldsymbol{x}_2 + \boldsymbol{x}_3$ con un solo coeficiente. La ganancia de precisión depende de la dirección de esa combinación. Con correlación positiva, $\boldsymbol{x}_2 + \boldsymbol{x}_3$ va en la dirección compartida: es un vector largo, y su coeficiente se estima con precisión. No toda restricción da esa ganancia. Con $\beta_2 + \beta_3 = 1$, sustituir $\beta_3 = 1 - \beta_2$ da $\beta_2\boldsymbol{x}_2 + (1 - \beta_2)\boldsymbol{x}_3 = \boldsymbol{x}_3 + \beta_2(\boldsymbol{x}_2 - \boldsymbol{x}_3)$: $\boldsymbol{x}_3$ pasa a restarse del regresando, y el regresor que queda es $\boldsymbol{x}_2 - \boldsymbol{x}_3$. Con correlación positiva es la dirección corta, y el error estándar apenas cambia. La restricción solo gana precisión si la combinación que impone va en la dirección compartida: efectos proporcionales con el mismo signo cuando la correlación es

positiva, con signos opuestos cuando es negativa. La lección 13 enseñó a imponer estas restricciones y a contrastarlas con el estadístico F. Si el F no la rechaza y la combinación va en la dirección compartida, el modelo restringido reduce la colinealidad y permite una interpretación más clara de los resultados.

La cuarta opción de la transparencia, ortogonalizar, tampoco crea variación propia. Deja el subespacio como está y cambia sus generadores: consiste en sustituir un regresor por su componente de variación propia $\tilde{\boldsymbol{x}}_j$, es decir, por el residuo de su regresión auxiliar sobre los demás regresores. El ajuste no depende de qué generadores describan el subespacio ("Por qué oscilan los coeficientes"); esta operación hace que un regresor, o un grupo de ellos, sea ortogonal a los demás. Qué cambia y qué no se deduce de lo demostrado hoy y en la lección 10. No cambia el ajuste: $\widehat{\boldsymbol{y}}$, SRC, R^2, $\mathfrak{s}$ y las predicciones son los mismos. No cambia el coeficiente del regresor sustituido, ni su error estándar: $\hat{\beta}_j$ se calcula con la parte propia de $\boldsymbol{x}_j$, y la parte propia de $\tilde{\boldsymbol{x}}_j$ respecto de los demás es ella misma. Sí cambian los coeficientes de los demás regresores: como $\tilde{\boldsymbol{x}}_j$ es ortogonal a todos ellos, sus coeficientes pasan a ser los del modelo sin $\boldsymbol{x}_j$ (familia ortogonal), con errores estándar menores. Y cambia la interpretación de todos. El coeficiente de $\tilde{\boldsymbol{x}}_j$ es el efecto de la parte de $\boldsymbol{x}_j$ que no acompaña a los demás regresores; el de cada uno de los demás ya no es el efecto "con $\boldsymbol{x}_j$ fijo", sino el efecto de esa variable junto con el de la parte de $\boldsymbol{x}_j$ que, en la muestra, la acompaña. La regresión auxiliar no crea información: asigna toda la variación compartida a los demás regresores, y esa asignación debe justificarla el problema económico, no la estadística. La actividad 6 (html) de la práctica C de la sesión 22 lo ilustra con la edad y las millas de los coches, sustituyendo la edad por su parte propia: allí se ve, con las tablas delante, qué coeficiente conserva su valor, cuál cambia y por qué los dos cambian de interpretación.

El caso en que esa justificación es más clara es el de la práctica D de la sesión 22 (actividad 3 (html)): el precio de ochenta y ocho viviendas sobre la tasación de una inmobiliaria y cuatro características de la vivienda. La inmobiliaria tasa a partir de las características, así que es la tasación la que debe sustituirse por su parte propia. Esa parte propia es la valoración de la inmobiliaria una vez descontado el efecto de las características que están en el modelo: lo que la inmobiliaria valora y no está entre los otros regresores (estado de conservación, situación, calidades). Con ella en el modelo, los coeficientes de las características miden su efecto sin mantener fija la tasación, y el coeficiente de la parte propia de la tasación mide cuánto responde el precio a esa valoración adicional de la inmobiliaria; en la muestra su estadístico t es 8,67 (actividad 4 (html)).

Para profundizar: Kennedy, P. (2008), *A Guide to Econometrics*, cap. 12 (un repaso claro de los remedios y de sus costes).

10 Lo que no

Reconocerlo: si la pregunta exige separar los efectos y la muestra no lo permite, decirlo e informar sobre los intervalos de confianza. Es una obligación, no una opción más.

Lo que no: eliminar regresores uno a uno por su t, sin realizar un contraste conjunto. Con colinealidad de grado, los t bajos son el síntoma, no un veredicto.

Lo correcto: identificar los coeficientes poco significativos y contrastar con el F que valen cero a la vez (lección 13). Si el F no rechaza, quitar esos regresores es una opción, no una obligación.

Lo que no

Reconocerlo no es una opción más: cuando la muestra tiene limitaciones, hay que decirlo. Si la pregunta económica exige separar el efecto de `nox` del de `lnox`, estos datos no lo permiten, y lo correcto es informar de los dos coeficientes con sus intervalos, que serán amplios, y no atribuir a la estimación una precisión que la muestra no da. Un intervalo ancho informa de lo que la muestra no permite precisar. Una vez dicho, es cuando cabe plantearse qué hacer con esas limitaciones, y es ahí donde se barajan las opciones anteriores, en función de los objetivos del estudio.

Lo que no hay que hacer lo dijo la lección 13: eliminar regresores porque sus t son bajos. Con colinealidad de grado, los t bajos son el síntoma, no un veredicto que indique que esos regresores deben eliminarse conjuntamente; de hecho, el F puede rechazar que sus coeficientes valgan cero a la vez. El procedimiento razonable tiene dos pasos: identificar con los t los coeficientes poco significativos y contrastar con el F que esos coeficientes valen cero a la vez. Si el contraste no rechaza, puede ser conveniente eliminar esos regresores, pero no es preceptivo: si la teoría exige mantenerlos, o el modelo sin ellos deja de tener sentido económico, es mejor dejarlos y reconocer que esta muestra no permite estimar bien sus efectos. La eliminación uno a uno, sacando en cada paso el regresor de mayor valor p y reestimando (es lo que hace la opción `--auto` de `omit` en Gretl), llega a un modelo en el que todos los t son grandes; con colinealidad de grado, el primero que sale lo hace por azar y el que queda hereda el efecto de los dos, así que conviene leer el contraste conjunto de todas las variables omitidas, que Gretl imprime al final, y no solo el modelo final. Existen, por último, métodos que renuncian a la insesgadez a cambio de una varianza menor, como la regresión *ridge*, o que sustituyen los regresores por combinaciones ortogonales, como las componentes principales. Quedan fuera de este curso; baste saber que existen y que ninguno crea la información que la muestra no tiene.

Para profundizar: Wooldridge, J. M. (2020), cap. 3, sección 3.4 (qué hacer ante la colinealidad, y por qué eliminar regresores puede ser peor que dejarlos).

11 Recapitulación y guiño a las sesiones siguientes

Pieza	Fórmula	Lectura geométrica
Parte propia del regresor $\boldsymbol{x}_j$	$\tilde{\boldsymbol{x}}_j$: residuo de $\boldsymbol{x}_j$ sobre los demás	lo que $\boldsymbol{x}_j$ no comparte
Longitud de $\tilde{\boldsymbol{x}}_j$	$\|\tilde{\boldsymbol{x}}_j\|_e = \|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e \sin\theta_j$	cateto perpendicular al subespacio de los demás
Error estándar $\mathrm{ee}(\hat{\beta}_j)$	$\mathfrak{s}/\|\tilde{\boldsymbol{x}}_j\|_e$ (demostración en el apéndice)	longitud del residuo por unidad de longitud propia
VIF_j	$1/(1-R_j^2) = 1/\sin^2\theta_j$	inflación de la varianza; su raíz, del error estándar
Coeficientes $\hat{\beta}_j$	coordenadas de $\widehat{\boldsymbol{y}}$	inestables si los generadores casi se alinean

Demostrado: la longitud de la parte propia. Enunciado (demostración en el apéndice, con la familia ortogonal): el error estándar. Ningún supuesto nuevo, ningún supuesto violado.

Laboratorio de colinealidad: la colinealidad creciente en Montecarlo, la regresión auxiliar de `nox`

y el VIF; el laboratorio del F ya anticipó la elipse de confianza de `nox` y `lnox`. *Lección 16*: la trampa de las variables ficticias es colinealidad exacta con $\mathbf{1}$.

Recapitulación y guiño a las sesiones siguientes

La sesión ha añadido una definición y un resultado. La definición es la parte propia de un regresor, el residuo de proyectarlo sobre los demás: una regresión de la lección 10 con un regresor en el papel del regresando. El resultado es su longitud, $\|\boldsymbol{x}_j - \mu_{\boldsymbol{x}_j}\mathbf{1}\|_e \operatorname{sin}\theta_j$, que se deduce de Pitágoras en esa regresión auxiliar. Todo lo demás es lectura: el error estándar de la lección 12, $\mathfrak{s}$ dividido por esa longitud (la fórmula de $\hat{\beta}_j$ sobre la parte propia está demostrada en el apéndice, sección 5.4 (html), con la familia ortogonal de la lección 10, y la varianza $\sigma^2/\|\tilde{\boldsymbol{x}}_j\|_e^2$ en la sección 7.1 (html)), el VIF como inverso del seno al cuadrado, y las coordenadas que oscilan porque los generadores casi se alinean.

Conviene retener también lo que la sesión no ha hecho. No ha añadido ningún supuesto, y ninguno de los anteriores se ha violado: la colinealidad de grado es compatible con todo lo demostrado en las lecciones 11 y 12. Es un problema de la muestra, la falta de variación propia, y su remedio es información, no otro estimador.

Quedan tres hilos, el primero ya recorrido. El laboratorio del contraste F aplicó lo de la lección 13 con datos reales, simuló la distribución del F bajo la hipótesis nula y dejó vista, en la elipse de confianza de `nox` y `lnox` (práctica A de la sesión 20, actividad 6 (html)), la oscilación de los coeficientes que hoy se ha explicado. En el laboratorio de colinealidad de la sesión 22 se verá, con un experimento de Montecarlo, cómo crece la dispersión de los coeficientes al cerrar el ángulo entre dos regresores mientras el ajuste no se mueve (práctica A, actividad 2 (html)); se calculará a mano la parte propia de `nox` con la regresión auxiliar (práctica B, actividad 1 (html)); y se comprobará el VIF de Gretl contra la fórmula de hoy (práctica B, actividad 3 (html)). El tercer hilo es de teoría y llega en la lección 16, al introducir las variables ficticias: si se incluyen una indicadora de hombre y otra de mujer junto con la constante, la suma de las dos es $\mathbf{1}$, y eso es la colinealidad exacta de la lección 10, que hoy hemos repasado: la llamada "trampa de las variables ficticias".

Para profundizar: Wooldridge, J. M. (2020), cap. 3, sección 3.4 (resumen) y cap. 7, sección 7.2 (la trampa de las variables ficticias, con la que enlaza la lección 16).