Índice general

1 De dónde venimos: la indicadora de un suceso como regresor 2

2 Una indicadora desplaza el intercepto: el río Charles 3

3 Con más regresores: la diferencia con lo demás fijo 6

4 En log-nivel: una diferencia porcentual 8

5 La trampa de las variables ficticias 9

6 Varias categorías: una indicadora menos que grupos 11

7 Interacciones: la pendiente cambia de grupo 15

8 El contraste de Chow: ¿la misma ecuación? 17

9 Qué dice y qué no dice el coeficiente de una indicadora 19

10 Recapitulación y guiño a la lección siguiente 21

Lección 16. Variables indicadoras e interacciones: leer las diferencias entre grupos

Marcos Bujosa

20 de octubre de 2026

Resumen

La indicadora de un suceso, $\mathbb{1}_A$ de la lección 12, es hoy un regresor más, que señala una característica de la unidad observada. Su coeficiente es una diferencia entre grupos, en unidades del regresando o porcentual si está en logaritmos. Dos indicadoras complementarias suman la constante, y de ahí la trampa de las variables ficticias. Una interacción permite que una pendiente cambie de grupo, y el contraste de Chow pregunta si los parámetros β del modelo son iguales en dos grupos.

"El coeficiente de una indicadora no es un efecto por unidad: es un salto entre grupos."

- (slides) — (html) — (pdf)

1 De dónde venimos: la indicadora de un suceso como regresor

La lección 12 definió la *indicadora* de un suceso A: $\mathbb{1}_A(\omega) = 1$ si $\omega \in A$ y 0 si no; su esperanza es la probabilidad $\mathrm{P}(A)$, y la variable aleatoria constante es la indicadora del suceso seguro, $\mathit{1} = \mathbb{1}_\Omega$.

Hoy la indicadora señala una característica de la unidad observada. Si A es el suceso formado por los ω en los que la persona observada es mujer, $\mathbb{1}_{\text{mujer}} = \mathbb{1}_A$ vale 1 si es mujer y 0 si es hombre, y entra como un regresor más del modelo de la lección 10:

$$\log(\text{wage}) = \beta_1\, \mathit{1} + \beta_2\, \mathbb{1}_{\text{mujer}} + \beta_3\, \text{educ} + \cdots + U.$$

En la muestra es la columna $\boldsymbol{d}_{\text{mujer}}$, con un 1 en las filas de las mujeres y un 0 en las de los hombres. En los ficheros: `female`, `chas`.

Se llama también variable *dicotómica*, *binaria*, *ficticia* o *dummy*. Lo nuevo de hoy es la interpretación del parámetro que la acompaña, β_2.

Hoy: qué dice el coeficiente de una indicadora, en niveles y en logaritmos; qué ocurre con dos indicadoras complementarias; cómo una interacción cambia una pendiente. Geometría nueva: solo una observación sobre dos indicadoras ortogonales.

Esta obra está bajo una licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional (CC BY-SA 4.0).

De dónde venimos: la indicadora de un suceso como regresor

Muchas variables explicativas de interés no son cantidades sino categorías: el sexo de un trabajador, si está casado, si una vivienda tiene piscina, si un barrio limita con el río, la región, el sector de actividad. Para que una categoría entre en un modelo de regresión hay que convertirla en números, y la forma de hacerlo ya está en el curso. La lección 12, al definir la probabilidad condicional, introdujo la *indicadora* de un suceso A: la variable aleatoria $\mathbb{1}_A$ que vale 1 en los sucesos elementales de A y 0 en los demás, con $\mathrm{E}(\mathbb{1}_A) = \mathrm{P}(A)$. Allí el suceso era $\{U_i \leq u\}$; hoy es el conjunto de los ω en los que la unidad observada tiene una característica. Si A es el suceso de que la persona observada sea mujer, $\mathbb{1}_{\text{mujer}} = \mathbb{1}_A$ vale 1 en los ω en que lo es y 0 en los demás, y su esperanza es la probabilidad de ese suceso, $\mathrm{P}(A)$.

Esa indicadora es una variable aleatoria como cualquier otro regresor, y entra en el modelo poblacional de la lección 10 multiplicada por su coeficiente: $\log(\text{wage}) = \beta_1\, \mathit{1} + \beta_2\, \mathbb{1}_{\text{mujer}} + \beta_3\, \text{educ} + \beta_4\, \text{exper} + \beta_5\, \text{tenure} + U$. En la muestra, la columna correspondiente de la matriz de regresores $\mathbf{X}$ es el vector $\boldsymbol{d}_{\text{mujer}} \in \mathbb{R}^n$ con un 1 en las filas de las mujeres y un 0 en las de los hombres, de la misma manera que $\boldsymbol{x}_j$ es el vector de los n valores observados de X_j. Su media es la proporción de mujeres en la muestra, y estima $\mathrm{P}(A)$. En los ficheros de datos esa columna lleva el nombre de la categoría que vale 1: `female` en `wage1`, `chas` en el Boston original. La constante del modelo, $\mathit{1}$, es también una indicadora, la del suceso seguro Ω: vale 1 para todas las unidades, y en la muestra es el vector $\mathbf{1}$.

Los nombres son varios. Esta lección dice *variable indicadora*, que es el término del curso; en los manuales y en los programas se encuentra también *dicotómica* o *binaria*, por tomar dos valores, *ficticia*, porque no mide una cantidad, que es el término de Gretl en español, y *dummy*, el término inglés. Todos designan lo mismo: una columna de ceros y unos que señala un grupo. Para mínimos cuadrados es una columna más de $\mathbf{X}$: la proyección, los residuos, el R^2, los errores estándar y los contrastes t y F se calculan igual, y todo lo demostrado en las lecciones 8 a 14 sigue en pie. Lo que esta lección añade es la interpretación de su coeficiente, que no es un efecto por unidad, porque una indicadora no tiene unidades, sino una diferencia entre dos grupos. Hay una única pieza de geometría nueva, y es pequeña: dos indicadoras de grupos complementarios son vectores ortogonales que suman $\mathbf{1}$, y eso explica a la vez por qué sus coeficientes son medias de grupo y por qué no pueden entrar las dos en el modelo junto con la constante.

Para profundizar: Wooldridge, J. M. (2020), cap. 7, sección 7.1 ("Describing qualitative information"); lección 12 de este curso, apuntes de "El supuesto nuevo: normalidad", donde se definió $\mathbb{1}_A$.

2 Una indicadora desplaza el intercepto: el río Charles

Boston original (506 barrios; `medv`, precio mediano en miles de dólares; `chas`, 1 en los 35 barrios que limitan con el río Charles):

$$\widehat{\text{medv}} = \underset{(0,42)}{22{,}09} + \underset{(1,59)}{6{,}35}\ \text{chas}, \qquad t = 4{,}00.$$

Los valores ajustados son las medias de cada grupo, y el coeficiente es su diferencia.

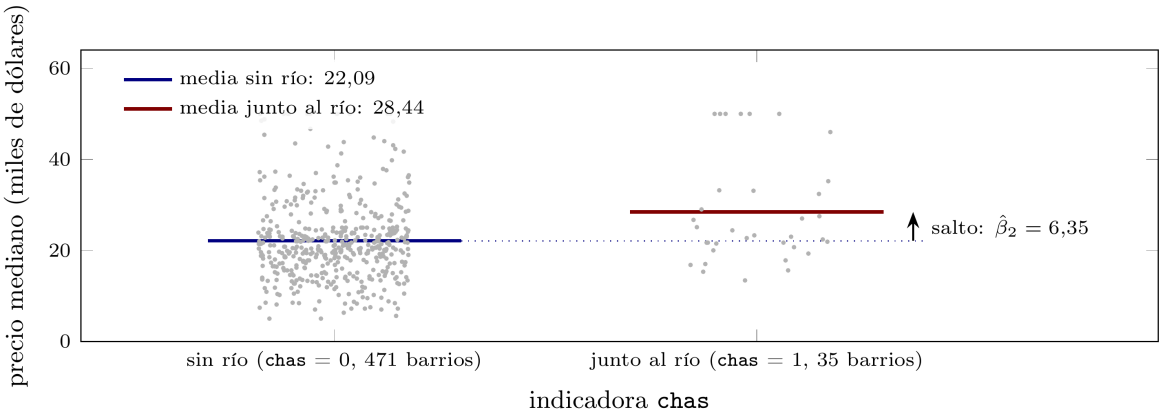


Figura 1: Los 506 barrios del Boston original. En el eje horizontal, la indicadora `chas` (con un desplazamiento horizontal aleatorio para que los puntos no se superpongan); en el vertical, el precio mediano en miles de dólares. El segmento azul es la media de los 471 barrios sin río, 22,09, y el rojo la media de los 35 barrios junto al río, 28,44. Esas dos medias son los dos únicos valores ajustados de `medv` sobre la constante y `chas`, y la flecha es el salto entre ellas: el coeficiente de la indicadora, 6,35. No hay pendiente que dibujar, porque `chas` solo toma los valores 0 y 1: el coeficiente de una indicadora es un salto entre dos grupos, no un efecto por unidad.

La geometría: $\boldsymbol{d}_{\text{no río}} = \mathbf{1} - \boldsymbol{d}_{\text{río}}$, así que $\mathcal{L}(\mathbf{1}, \boldsymbol{d}_{\text{río}}) = \mathcal{L}(\boldsymbol{d}_{\text{río}}, \boldsymbol{d}_{\text{no río}})$: el mismo subespacio con otra base.

Las dos indicadoras son ortogonales, $\langle \boldsymbol{d}_{\text{río}}, \boldsymbol{d}_{\text{no río}} \rangle_s = 0$, porque ningún barrio está en los dos grupos a la vez. Como en la familia ortogonal de la lección 10, cada coeficiente se calcula por separado con la fórmula de la proyección sobre un generador, $\langle \boldsymbol{y}, \boldsymbol{d} \rangle_s / \langle \boldsymbol{d}, \boldsymbol{d} \rangle_s$, que aquí es la media de su grupo:

$$\widehat{\boldsymbol{y}} = 28{,}44\, \boldsymbol{d}_{\text{río}} + 22{,}09\, \boldsymbol{d}_{\text{no río}} = 22{,}09\, \mathbf{1} + 6{,}35\, \boldsymbol{d}_{\text{río}}.$$

Con más regresores, `medv` sobre `rm` y `chas`:

$$\widehat{\text{medv}} = \underset{(2{,}62)}{-34{,}11} + \underset{(0{,}42)}{8{,}97}\ \text{rm} + \underset{(1{,}15)}{4{,}08}\ \text{chas}, \qquad t = 3{,}55.$$

El coeficiente de `chas` ya no es una diferencia de medias, sino la diferencia entre barrios con el mismo número de habitaciones.

Una indicadora desplaza el intercepto: el río Charles

El Boston original es el fichero `boston.csv` que se importó en la actividad 4 (html) de la práctica B de la sesión 4, porque contiene una variable que `hprice2` no tiene: `chas`, la indicadora de los barrios que limitan con el río Charles. Allí se calculó su media, $35/506 = 0{,}069$, y se vio que la media de una indicadora es la proporción de unidades del grupo: es la versión muestral de $\mathrm{E}(\mathbb{1}_A) = \mathrm{P}(A)$.

La regresión más simple con una indicadora es la del precio mediano sobre la constante y `chas`: $\widehat{\texttt{medv}} = 22{,}09 + 6{,}35\,\texttt{chas}$. Como `chas` solo toma los valores 0 y 1, el modelo solo produce dos valores ajustados: 22,09 para los barrios sin río y $22{,}09 + 6{,}35 = 28{,}44$ para los barrios junto al río. Y esos dos valores son las medias de `medv` en cada grupo. Por eso el coeficiente de la indicadora, 6,35 mil dólares, es la diferencia entre las dos medias, y el contraste t de ese coeficiente, con $t = 4{,}00$, es el contraste de igualdad de medias entre los dos grupos. La figura dibuja los 506 barrios con la indicadora en el eje horizontal, las dos medias y el salto entre ellas. Entre 0 y 1 no hay ningún valor posible de `chas`, y hablar de "una unidad más de `chas`" no tiene sentido. El coeficiente de una indicadora es un salto entre grupos, un desplazamiento del intercepto, y no un efecto por unidad.

Que los coeficientes sean medias de grupo tiene una explicación geométrica, la única de esta lección. Sea $\boldsymbol{d}_{\text{río}}$ la columna `chas` y $\boldsymbol{d}_{\text{no río}} = \mathbf{1} - \boldsymbol{d}_{\text{río}}$ la indicadora del grupo complementario. El subespacio generado por la constante y `chas` es el mismo que el generado por las dos indicadoras, porque $\boldsymbol{d}_{\text{no río}} = \mathbf{1} - \boldsymbol{d}_{\text{río}}$ y $\mathbf{1} = \boldsymbol{d}_{\text{río}} + \boldsymbol{d}_{\text{no río}}$: cada vector de un par se obtiene sumando o restando los del otro par, y por tanto $\mathcal{L}(\mathbf{1}, \boldsymbol{d}_{\text{río}}) = \mathcal{L}(\boldsymbol{d}_{\text{río}}, \boldsymbol{d}_{\text{no río}})$. Los dos pares de generadores son dos bases del mismo subespacio, como $\mathbf{1}, \boldsymbol{x}$ y $\mathbf{1}, \boldsymbol{x} - \mu_{\boldsymbol{x}}\mathbf{1}$ en la lección 7. La proyección de $\boldsymbol{y}$ es la misma con cualquiera de las dos bases; lo que cambia son los coeficientes. En la base de las dos indicadoras los coeficientes se calculan sin resolver ningún sistema: $\boldsymbol{d}_{\text{río}}$ y $\boldsymbol{d}_{\text{no río}}$ son ortogonales, $\langle \boldsymbol{d}_{\text{río}}, \boldsymbol{d}_{\text{no río}} \rangle_s = 0$, porque en cada fila una de las dos vale cero. En las ecuaciones normales de la lección 10 el producto escalar de cada regresor con el otro es cero, así que cada ecuación contiene un solo coeficiente, y ese coeficiente es el de la proyección sobre un generador de las lecciones 3 y 4, $\langle \boldsymbol{y}, \boldsymbol{d} \rangle_s / \langle \boldsymbol{d}, \boldsymbol{d} \rangle_s$. Es la misma situación que la familia ortogonal de la lección 10, con dos generadores que no están centrados pero sí son ortogonales entre sí. Para $\boldsymbol{d}_{\text{río}}$, el factor $1/n$ del producto escalar estadístico está en el numerador y en el denominador y se cancela. El cociente es entonces el de dos productos escalares euclídeos:

$$\frac{\langle \boldsymbol{y}, \boldsymbol{d}_{\text{río}} \rangle_s}{\langle \boldsymbol{d}_{\text{río}}, \boldsymbol{d}_{\text{río}} \rangle_s} = \frac{\langle \boldsymbol{y}, \boldsymbol{d}_{\text{río}} \rangle_e}{\langle \boldsymbol{d}_{\text{río}}, \boldsymbol{d}_{\text{río}} \rangle_e} = \frac{\sum_{i=1}^{n} d_i\, y_i}{\sum_{i=1}^{n} d_i^2} = \frac{\sum_{i:\, d_i = 1} y_i}{\sum_{i=1}^{n} d_i},$$

donde d_i es la componente i de $\boldsymbol{d}_{\text{río}}$. En el numerador, los ceros de la indicadora anulan los términos de los barrios sin río, y solo se suman los precios de los barrios junto al río. En el denominador, como $d_i^2 = d_i$, se suman los unos de la indicadora: se cuentan los barrios junto al río, 35. El cociente es la media de ese grupo, 28,44. Con $\boldsymbol{d}_{\text{no río}}$ se obtiene del mismo modo la media de los 471 barrios sin río, 22,09. Cambiar a la base $\{\mathbf{1}, \boldsymbol{d}_{\text{río}}\}$ reescribe el mismo vector ajustado. Basta sustituir $\boldsymbol{d}_{\text{no río}} = \mathbf{1} - \boldsymbol{d}_{\text{río}}$:

$$\widehat{\boldsymbol{y}} = 28{,}44\,\boldsymbol{d}_{\text{río}} + 22{,}09\,(\mathbf{1} - \boldsymbol{d}_{\text{río}}) = 22{,}09\,\mathbf{1} + (28{,}44 - 22{,}09)\,\boldsymbol{d}_{\text{río}} = 22{,}09\,\mathbf{1} + 6{,}35\,\boldsymbol{d}_{\text{río}}.$$

En esta base los barrios sin río no tienen indicadora propia: son la *categoría base*, el grupo en el que $\boldsymbol{d}_{\text{río}}$ vale cero. Por eso el coeficiente de la constante es la media de la categoría base, 22,09, que es el valor ajustado de cualquier barrio sin río. El coeficiente de $\boldsymbol{d}_{\text{río}}$ ya no es una media, sino la diferencia entre la media de su grupo y la de la categoría base. A los barrios junto al río les corresponde, en promedio, un precio 6,35 mil dólares mayor que el de los barrios sin río. Si la base hubiera sido $\{\mathbf{1}, \boldsymbol{d}_{\text{no río}}\}$, la categoría base serían los barrios junto al río. La constante valdría entonces 28,44, y el coeficiente de $\boldsymbol{d}_{\text{no río}}$, $-6{,}35$, sería el menor precio medio de los barrios sin río respecto de los que están junto al río.

Con más regresores el coeficiente de la indicadora deja de ser una diferencia de medias. Si al

modelo se añade el número medio de habitaciones por vivienda del barrio, `rm`, la estimación es la siguiente:

`medv` sobre…	coef.	ee	t
constante	−34,11	2,62	−12,99
`rm`	8,97	0,42	21,55
`chas`	4,08	1,15	3,55

El coeficiente de `chas`, 4,08 mil dólares, es la diferencia de precio mediano entre dos barrios con el mismo número medio de habitaciones por vivienda, uno junto al río y otro no. La comparación es entre barrios, no entre viviendas: el modelo no dice cuánto más vale una vivienda concreta por estar junto al río. Es la lectura *ceteris paribus* de la lección 10, aplicada a un salto entre grupos. La diferencia bruta de medias, 6,35, recoge además que los barrios junto al río tienen viviendas algo mayores: 6,52 habitaciones de media, frente a 6,27 en los demás. Al incluir `rm` como regresor, parte de esa diferencia queda recogida en el término de `rm`: con cuatro decimales en las medias, $8{,}967 \times (6{,}5196 - 6{,}2672) = 2{,}263$ mil dólares. Lo que queda, $6{,}346 - 2{,}263 = 4{,}083$, es el coeficiente de `chas`. La transparencia "Con más regresores: la diferencia con lo demás fijo" vuelve sobre esta distinción con los salarios.

Para profundizar: Wooldridge, J. M. (2020), cap. 7, sección 7.2 ("A single dummy independent variable"); Harrison, D. y Rubinfeld, D. L. (1978), "Hedonic housing prices and the demand for clean air", *Journal of Environmental Economics and Management* 5, 81–102, origen de los datos.

3 Con más regresores: la diferencia con lo demás fijo

`wage1` (526 trabajadores, salario por hora en dólares de 1976; 274 hombres y 252 mujeres). Medias: 7,10 dólares los hombres, 4,59 las mujeres. `wage` sobre la constante y `female`: coeficiente −2,51, la diferencia de medias.

`wage` sobre…	coef.	ee	t
constante	−1,568	0,725	−2,16
`female`	−1,811	0,265	−6,84
`educ`	0,572	0,049	11,58
`exper`	0,025	0,012	2,20
`tenure`	0,141	0,021	6,66

Lectura: entre un hombre y una mujer con la misma educación, experiencia y antigüedad, el salario de la mujer es 1,81 dólares por hora menor, en promedio. De la diferencia bruta de 2,51, los 0,70 restantes corresponden a diferencias en esas tres variables (antigüedad media: 6,5 años los hombres, 3,6 las mujeres).

"Lo demás fijo" solo cubre lo que está en el modelo.

Con más regresores: la diferencia con lo demás fijo

El fichero `wage1` de Wooldridge es el de la transparencia "Log-nivel: salarios y educación" de la lección 15: 526 trabajadores de la encuesta de población de Estados Unidos de 1976, con el salario por hora en dólares, los años de educación (`educ`), de experiencia potencial (`exper`: la edad menos los años de educación menos seis, es decir, los años transcurridos desde el fin de los estudios) y de

antigüedad en la empresa (`tenure`), y la indicadora `female`, que vale 1 para las 252 mujeres y 0 para los 274 hombres.

El salario medio es 7,10 dólares por hora entre los hombres y 4,59 entre las mujeres. La regresión de `wage` sobre la constante y `female` devuelve esas dos cifras:

$$\widehat{\text{wage}} = \underset{(0,21)}{7,10} - \underset{(0,30)}{2,51}\,\text{female}, \qquad t = -8,28,$$

con el error estándar de cada coeficiente entre paréntesis debajo de él, como en la lección 15. La constante es la media de los hombres, la categoría base, y el coeficiente de `female` es la diferencia entre la media de las mujeres y la de los hombres. Es la misma situación que la de los barrios junto al río: con una sola indicadora, el coeficiente es la diferencia de medias entre grupos.

La tabla de la transparencia añade los tres regresores cuantitativos:

$$\begin{aligned}\widehat{\text{wage}} = \underset{(0,725)}{-1,568} - \underset{(0,265)}{1,811}\,\text{female} + \underset{(0,049)}{0,572}\,\text{educ} \\ + \underset{(0,012)}{0,025}\,\text{exper} + \underset{(0,021)}{0,141}\,\text{tenure}.\end{aligned}$$

El coeficiente de `female` pasa a $-1,81$, con error estándar 0,27 y $t = -6,84$. La lectura es la de la lección 10: con lo demás fijo, es decir, entre un hombre y una mujer con los mismos años de educación, de experiencia y de antigüedad, el salario de la mujer es 1,81 dólares por hora menor, en promedio. El intervalo al 95 % va de $-2,33$ a $-1,29$: datos como estos serían muy raros si no hubiera diferencia salarial entre sexos con las tres variables fijas. Los otros coeficientes se leen en las unidades del salario, como en la lección 12: un año más de educación se acompaña de 57 centavos más por hora, y un año más de antigüedad, de 14.

La diferencia entre las dos cifras, $-2,51$ y $-1,81$, dice algo sobre los datos. La diferencia bruta de medias mezcla dos cosas: la diferencia salarial entre hombres y mujeres con la misma educación, experiencia y antigüedad, y el hecho de que los dos grupos no son comparables en las variables del modelo. Las mujeres de la muestra tienen una antigüedad media de 3,6 años frente a 6,5 los hombres, algo menos de experiencia (16,4 frente a 17,6) y casi la misma educación (12,3 frente a 12,8). Como la antigüedad se acompaña de un salario mayor, parte de la diferencia bruta queda recogida en los términos de `educ`, `exper` y `tenure`, y el salto que queda al fijar las tres variables es menor. La descomposición es una identidad: la diferencia bruta es el coeficiente de `female` más, para cada regresor, su coeficiente por la diferencia de medias de ese regresor entre mujeres y hombres,

$$\begin{aligned}-2,512 &= -1,811 + 0,572 \times (-0,471) + 0,0254 \times (-1,130) + 0,141 \times (-2,859) \\ &= -1,811 - 0,269 - 0,029 - 0,403.\end{aligned}$$

De los 0,70 dólares que separan las dos cifras, 0,40 corresponden a la antigüedad. Es la parte propia de la lección 14: el coeficiente de `female` es el de lo que la indicadora no comparte con `educ`, `exper` y `tenure`, y recoge solo la parte de la diferencia salarial que no corresponde a las diferencias de educación, experiencia y antigüedad entre los dos grupos.

Hay que ser preciso con lo que el coeficiente no dice. "Lo demás fijo" se refiere a lo que el modelo incluye: tres variables. Hay muchas otras que difieren entre hombres y mujeres y que el modelo no contiene, como la ocupación, el sector, las horas trabajadas o las interrupciones de la

carrera laboral. El coeficiente −1,81 mide la diferencia salarial entre hombres y mujeres con igual educación, experiencia y antigüedad observadas; no mide la discriminación, que exigiría comparar trabajadores iguales en todo lo relevante, ni dice qué parte de la diferencia se debe a cada causa. La transparencia "Qué dice y qué no dice el coeficiente de una indicadora" recoge esta cautela entre las lecturas incorrectas más frecuentes.

Para profundizar: Wooldridge, J. M. (2020), cap. 7, sección 7.2, ejemplo 7.1 ("Hourly wage equation") y la discusión sobre la interpretación del coeficiente de `female`.

4 En log-nivel: una diferencia porcentual

El mismo modelo con el logaritmo del salario (`lwage`) como regresando:

`lwage` sobre…	coef.	ee	t
constante	0,501	0,102	4,92
`female`	−0,301	0,037	−8,09
`educ`	0,0875	0,0069	12,60
`exper`	0,0046	0,0016	2,85
`tenure`	0,0174	0,0030	5,84

Aproximación (lección 15): con lo demás fijo, el salario de una mujer es menor en la fracción 0,30, un 30 %. **Cálculo exacto**: $e^{-0{,}301} - 1 = -0{,}260$, un 26 % menor; para un cambio grande, la aproximación se queda lejos. Intervalo al 95 % para el coeficiente de `female`: [−0,374, −0,228], del −31 % al −20 % en diferencia exacta.

La lectura depende de la categoría base: el salario de un hombre es un 35 % mayor que el de una mujer con la misma educación, experiencia y antigüedad, porque $e^{0{,}301} - 1 = 0{,}351$. El mismo coeficiente da dos porcentajes, porque cada uno se calcula sobre el salario de un grupo distinto.

En log-nivel: una diferencia porcentual

La lección 15 explicó por qué la ecuación de salarios se estima con el logaritmo del salario como regresando: el rendimiento de la educación se enuncia en porcentaje, y la hipótesis de que cada año multiplica el salario por un factor es más verosímil que la de que le suma una cantidad fija. Lo mismo vale para la diferencia entre sexos: es más natural pensar que las mujeres cobran un cierto porcentaje menos que los hombres que una cantidad fija de dólares, sea el salario de 3 o de 20 dólares por hora. La tabla de la transparencia estima el modelo de la transparencia "Con más regresores: la diferencia con lo demás fijo" con `lwage` en lugar de `wage`.

El coeficiente de `female` es −0,301. La aproximación de la lección 15, $\log(1+p) \approx p$, da la lectura rápida: con la misma educación, experiencia y antigüedad, el salario de una mujer es menor en la fracción 0,30, un 30 %. Pero el coeficiente es grande, y para cambios grandes la aproximación se queda lejos, como se vio con los cuatro años de educación en la lección 15. El cálculo exacto se hace como allí, deshaciendo el logaritmo: el modelo predice para una mujer un salario $e^{-0{,}301} = 0{,}740$ veces el de un hombre con los mismos regresores, es decir, menor en $e^{-0{,}301} - 1 = -0{,}260$, un 26 %. En general, si el coeficiente de una indicadora en un modelo log-nivel es β, el salario del grupo señalado es e^{β} veces el del otro grupo, con lo demás fijo, y la diferencia porcentual exacta es $e^{\beta} - 1$.

La aproximación β sirve cuando el coeficiente es pequeño, por debajo de 0,1 en valor absoluto; para 0,3 la diferencia entre 30 % y 26 % ya importa al informar.

Con la versión exacta aparece una asimetría que con la aproximación pasa inadvertida. La misma estimación dice que una mujer cobra un 26 % menos que un hombre con la misma educación, experiencia y antigüedad, y que ese hombre cobra un 35 % más que ella, porque $e^{0{,}301} - 1 = 0{,}351$. Las dos frases son correctas y describen el mismo cociente de salarios, 0,740 o su inverso 1,351; difieren en el salario sobre el que se calcula el porcentaje. Con la aproximación las dos lecturas darían 30 %, lo que oculta la diferencia. Al informar una diferencia porcentual entre grupos hay que decir respecto de qué grupo se calcula, y la indicadora lo fija: el coeficiente de `female` compara a las mujeres con los hombres, que son el grupo con valor 0, la categoría base.

El intervalo de confianza se construye como en la lección 12 para el coeficiente, de $-0{,}374$ a $-0{,}228$, y después se transforma: los extremos de la diferencia exacta son $e^{-0{,}374} - 1 = -0{,}312$ y $e^{-0{,}228} - 1 = -0{,}204$, así que la diferencia porcentual entre sexos, con las tres variables fijas, está entre el 20 % y el 31 % con una confianza del 95 %. La transformación se aplica a los extremos y no al error estándar, porque la exponencial no es lineal; el intervalo transformado deja de ser simétrico alrededor de la estimación puntual, $-0{,}260$.

Los demás coeficientes se leen como en la lección 15. Un año más de educación se acompaña de un salario mayor en la fracción 0,0875, un 8,75 % aproximado y un 9,1 % exacto; un año más de antigüedad, en un 1,7 %. Son cifras algo distintas de las de la lección 15, donde el modelo tenía `educ` como único regresor; al añadir `female`, `exper` y `tenure`, el coeficiente de `educ` cambia, por el mecanismo de la lección 10.

El modelo impone que la diferencia entre sexos sea la misma para cualquier valor de los demás regresores. La figura lo muestra con un modelo más pequeño, para que quepa en un plano: `lwage` sobre la constante, `female` y `exper`, sin `educ` ni `tenure`,

$$\widehat{\log(\text{wage})} = \underset{(0{,}041)}{1{,}748} - \underset{(0{,}043)}{0{,}393}\,\text{female} + \underset{(0{,}0016)}{0{,}0038}\,\text{exper}.$$

Para los hombres, `female` vale 0 y la recta es $1{,}748 + 0{,}0038\,\text{exper}$; para las mujeres vale 1 y la recta es $(1{,}748 - 0{,}393) + 0{,}0038\,\text{exper} = 1{,}355 + 0{,}0038\,\text{exper}$. La indicadora solo cambia el intercepto; la pendiente de la experiencia es la misma para los dos sexos, y las rectas son paralelas. Por eso la distancia vertical entre ellas, la diferencia entre sexos en logaritmos, es $-0{,}393$ con cualquier experiencia. Que esa distancia no cambie con la experiencia es una restricción del modelo, no un resultado de los datos; la transparencia "Interacciones: la pendiente cambia de grupo" la levanta.

Para profundizar: Wooldridge, J. M. (2020), cap. 7, sección 7.2, apartado "Interpreting coefficients on dummy explanatory variables when the dependent variable is log(y)", con el ejemplo 7.4; Halvorsen, R. y Palmquist, R. (1980), "The interpretation of dummy variables in semilogarithmic equations", *American Economic Review* 70, 474–475, el artículo que fijó la lectura exacta $e^{\beta} - 1$.

5 La trampa de las variables ficticias

La indicadora de ser hombre es $\mathbb{1}_{\text{hombre}} = \mathit{1} - \mathbb{1}_{\text{mujer}}$: las dos suman la indicadora del suceso seguro, $\mathbb{1}_{\text{mujer}} + \mathbb{1}_{\text{hombre}} = \mathbb{1}_{\Omega} = \mathit{1}$. En la muestra, $\boldsymbol{d}_{\text{mujer}} + \boldsymbol{d}_{\text{hombre}} = \mathbf{1}$.

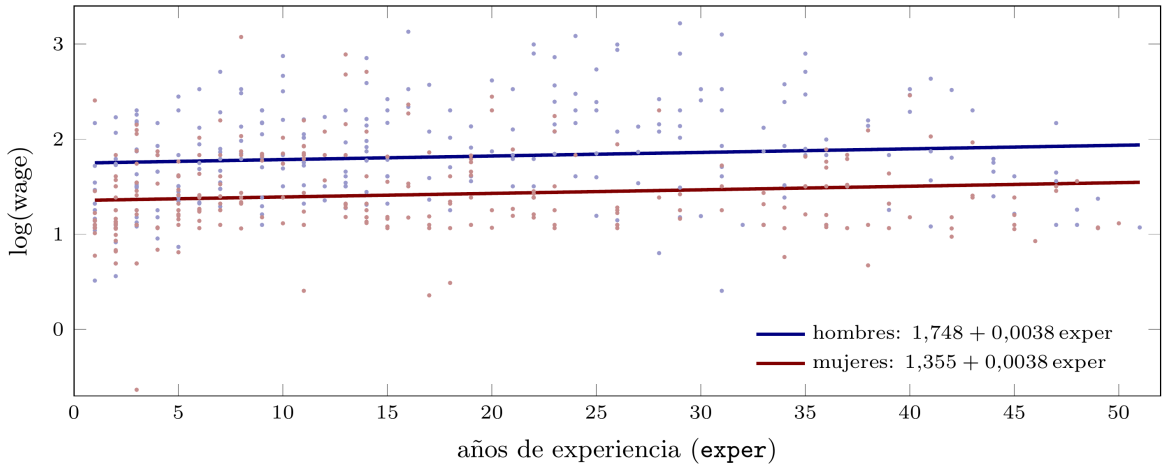


Figura 2: Los 526 trabajadores de `wage1`: logaritmo del salario por hora frente a los años de experiencia, los hombres en azul y las mujeres en rojo. Las dos rectas son el ajuste de `lwage` sobre la constante, `female` y `exper`: la indicadora separa las ordenadas en el origen, 1,748 y 1,355, y las dos rectas tienen la misma pendiente, 0,0038.

Poner las tres columnas en $\mathbf{X}$ es la colinealidad exacta de la lección 10: tres columnas que generan un subespacio de dimensión dos. Gretl avisa: «Omitidas debido a colinealidad exacta: =male=».

Tres escrituras del mismo modelo, `lwage` sobre el sexo (sin otros regresores):

Regresores	Coeficientes	Lectura
constante, `female`	1,814; −0,397	media de los hombres; diferencia mujeres − hombres
constante, `male`	1,416; +0,397	media de las mujeres; diferencia hombres − mujeres
`female`, `male`	1,416; 1,814	media de cada grupo

El mismo subespacio y el mismo ajuste (SRC = 127,6) con otra base: cambia la categoría base de la lectura. En la tercera, $\mathbf{1}$ no es columna, pero está en el subespacio (lección 10).

La trampa de las variables ficticias

La lección 14 dejó anunciada esta transparencia: si se incluyen en el modelo una indicadora de mujer, otra de hombre y la constante, hay colinealidad exacta. La razón está en la definición de la lección 12. La indicadora del suceso "ser hombre" es la del complementario de "ser mujer", $\mathbb{1}_{\text{hombre}} = \mathit{1} - \mathbb{1}_{\text{mujer}}$, de modo que las dos indicadoras suman la indicadora del suceso seguro: $\mathbb{1}_{\text{mujer}} + \mathbb{1}_{\text{hombre}} = \mathbb{1}_{\Omega} = \mathit{1}$, que es la constante del modelo. En la muestra, cada fila tiene un 1 en una de las dos columnas y un 0 en la otra, y $\boldsymbol{d}_{\text{mujer}} + \boldsymbol{d}_{\text{hombre}} = \mathbf{1}$. Si $\mathbf{X}$ contiene las tres columnas, una de ellas es combinación lineal de las otras dos: es la colinealidad exacta de la lección 10, y la actividad 6 (html) de la práctica D de la sesión 14 la construyó a propósito. Las tres columnas generan un subespacio de dimensión dos, la proyección de $\boldsymbol{y}$ sobre él existe y es única, pero hay infinitas maneras de escribirla como combinación lineal de tres vectores que no son linealmente

independientes, y las ecuaciones normales no tienen solución única. Gretl lo detecta al estimar y elimina una de las columnas, con el aviso «Omitidas debido a colinealidad exacta: =male=» en la cabecera de la tabla de resultados. Este error recibe en los manuales el nombre de *trampa de las variables ficticias*.

La solución es omitir una de las tres columnas, y las tres opciones estiman el mismo modelo. La tabla de la transparencia lo muestra con `lwage` sobre el sexo, sin otros regresores, para que los coeficientes sean medias. Con la constante y `female`, la constante es la media del logaritmo del salario de los hombres, 1,814, y el coeficiente de `female` es la diferencia entre la media de las mujeres y la de los hombres, −0,397. Con la constante y `male`, la constante es la media de las mujeres, 1,416, y el coeficiente de `male` la misma diferencia con el signo cambiado. Con las dos indicadoras y sin constante, cada coeficiente es la media de su grupo, por la ortogonalidad de las dos indicadoras que explicó la transparencia "Una indicadora desplaza el intercepto: el río Charles". Los tres ajustes son el mismo vector $\widehat{\boldsymbol{y}}$, con la misma suma de cuadrados de los residuos, 127,6, porque las tres parejas de columnas generan el mismo subespacio de dimensión dos: $\mathcal{L}(\mathbf{1}, \boldsymbol{d}_{\text{mujer}}) = \mathcal{L}(\mathbf{1}, \boldsymbol{d}_{\text{hombre}}) = \mathcal{L}(\boldsymbol{d}_{\text{mujer}}, \boldsymbol{d}_{\text{hombre}})$. Lo que cambia es la base y, con ella, el significado de cada coeficiente.

La tercera escritura cobra una observación que la lección 10 hizo al presentar la matriz de regresores: lo que necesita el ajuste no es que $\mathbf{1}$ sea una de las columnas de $\mathbf{X}$, sino que $\mathbf{1}$ pertenezca al subespacio que generan. En el modelo con `female` y `male` ninguna columna es constante, pero su suma es $\mathbf{1}$, así que $\mathbf{1} \in \mathcal{L}(\boldsymbol{d}_{\text{mujer}}, \boldsymbol{d}_{\text{hombre}})$ y todo lo que depende de ello sigue valiendo: los residuos suman cero, la media de los valores ajustados es la media de $\boldsymbol{y}$ y el R^2 se calcula como en la lección 8. Gretl lo tiene en cuenta: si se estima un modelo sin la constante pero con las dos indicadoras, el R^2 que imprime es el habitual.

En la práctica, la escritura que se usa es la primera, con la constante y una indicadora por cada grupo menos uno. El grupo sin indicadora es la categoría base, y todos los coeficientes de indicadoras se leen como diferencias respecto de ella. Elegir la categoría base es una decisión de presentación, no de modelo: cambiarla no mueve el ajuste ni ningún contraste sobre el modelo completo, solo reordena qué diferencias aparecen directamente como coeficientes, con su error estándar y su t. La transparencia "Varias categorías: una indicadora menos que grupos" usa este recurso para comparar dos grupos que no son la categoría base.

Para profundizar: Wooldridge, J. M. (2020), cap. 7, sección 7.2 ("the dummy variable trap") y cap. 3, sección 3.3 (colinealidad perfecta); lección 10 de este curso, apuntes de "La matriz de regresores y el operador selector".

6 Varias categorías: una indicadora menos que grupos

Con `female` y `married` de `wage1` se construyen cuatro indicadoras, una por grupo: 86 hombres solteros, 188 casados, 120 mujeres solteras y 132 casadas. Suman $\mathbf{1}$: con la constante van tres; categoría base, los hombres solteros.

`lwage` sobre…	coef.	ee	t	$e^{\beta}-1$
hombre casado	0,292	0,055	5,27	+34 %
mujer casada	−0,120	0,058	−2,07	−11 %
mujer soltera	−0,097	0,057	−1,68	−9 %
`educ`, `exper`, `tenure`	0,0835; 0,0032; 0,0157			

Lectura: con la misma educación, experiencia y antigüedad, y respecto de lo que cobra un hombre soltero, un hombre casado cobra un 34 % más, una mujer casada un 11 % menos y una mujer soltera un 9 % menos.

Comparar dos grupos que no son la categoría base: una mujer casada frente a una soltera. La diferencia es la resta de sus coeficientes, $-0{,}120-(-0{,}097)=-0{,}023$: la casada cobra un 2 % menos. Su ee no está en la tabla. Se obtiene estimando de nuevo con las mujeres solteras como categoría base: ee $=0{,}053$ y $t=-0{,}45$. Datos como estos no serían raros si casadas y solteras cobrasen lo mismo.

Varias categorías: una indicadora menos que grupos

Una variable cualitativa puede tener más de dos categorías: la región, el sector o el nivel de estudios por tramos. Se trata igual que el sexo. Cada categoría tiene su indicadora. Si cada unidad pertenece a una y solo a una de las g categorías, en cada fila de la muestra una de las g columnas indicadoras vale 1 y las demás valen 0. Por eso las g columnas suman $\mathbf{1}$, igual que $\boldsymbol{d}_{\text{mujer}}+\boldsymbol{d}_{\text{hombre}}=\mathbf{1}$.

Si el modelo tiene constante, no puede incluir las g indicadoras, sino solo $g-1$. Con las g, la columna $\mathbf{1}$ sería la suma de otras g columnas de $\mathbf{X}$: los regresores serían linealmente dependientes y los coeficientes no estarían determinados (la colinealidad exacta de la transparencia "La trampa de las variables ficticias"). La categoría que se queda sin indicadora es la categoría base. El coeficiente de cada indicadora mide la diferencia entre su categoría y la categoría base cuando se comparan unidades con los mismos valores de los demás regresores (en el ejemplo, la misma educación, experiencia y antigüedad).

El modelo también puede escribirse sin constante y con las g indicadoras. Entonces el coeficiente de cada una es el valor ajustado para esa categoría cuando los demás regresores valen cero. Las dos formulaciones proyectan el regresando sobre el mismo subespacio, porque cada columna de una matriz de regresores es combinación lineal de las columnas de la otra: $\mathbf{1}$ es la suma de las g indicadoras, y la indicadora de la categoría base es $\mathbf{1}$ menos las otras $g-1$. Por tanto dan el mismo ajuste y los mismos residuos; solo cambia lo que mide cada coeficiente.

El ejemplo de la transparencia combina dos variables de dos categorías, el sexo y el estado civil, en una de cuatro: hombres solteros, hombres casados, mujeres solteras y mujeres casadas, con 86, 188, 120 y 132 trabajadores. El fichero `wage1` no trae las cuatro indicadoras; trae dos, `female`, que vale 1 para las mujeres, y `married`, que vale 1 para los casados. Las cuatro se construyen con dos identidades entre indicadoras que se comprueban ω a ω, recogidas en la sección 1.4 del apéndice (pdf) (html). La primera: la indicadora del complementario es *1* menos la indicadora, así que `1-female` señala a los hombres y `1-married` a los solteros. La segunda: el producto de dos indicadoras vale 1 solo cuando las dos valen 1, así que es la indicadora de la intersección de los dos sucesos. Por ejemplo, `married*(1-female)` vale 1 en las filas de los hombres casados y 0 en las demás. Las

cuatro indicadoras son estas:

hombres solteros	`(1-female)*(1-married)`
hombres casados	`(1-female)*married`
mujeres solteras	`female*(1-married)`
mujeres casadas	`female*married`

En Gretl cada una se crea con una orden `series`, por ejemplo `series hcasado = (1-female)*married`, y del mismo modo `mcasada` y `msoltera`. En cada fila vale 1 una y solo una de las cuatro, porque cada trabajador está en uno y solo un grupo, y su suma es **1**. Con los hombres solteros como categoría base, el modelo tiene la constante, tres indicadoras y `educ`, `exper` y `tenure`. La ecuación estimada es

$$\begin{aligned}\widehat{\log(\text{wage})} = &\underset{(0,102)}{0{,}388} + \underset{(0,055)}{0{,}292}\,\text{hcasado} - \underset{(0,058)}{0{,}120}\,\text{mcasada} - \underset{(0,057)}{0{,}097}\,\text{msoltera}\\ &+ \underset{(0,0069)}{0{,}0835}\,\text{educ} + \underset{(0,0017)}{0{,}0032}\,\text{exper} + \underset{(0,0029)}{0{,}0157}\,\text{tenure}.\end{aligned}$$

Cada coeficiente de indicadora mide la diferencia, en logaritmos, entre su grupo y los hombres solteros con la misma educación, experiencia y antigüedad, y la columna $e^{\beta} - 1$ de la tabla de la transparencia la convierte en diferencia porcentual exacta. Respecto de lo que cobra un hombre soltero con la misma educación, experiencia y antigüedad, un hombre casado cobra un 34 % más, una mujer casada un 11 % menos y una mujer soltera un 9 % menos. Para preguntar si cada una de esas diferencias podría ser nula se contrasta que su parámetro vale cero, con el estadístico t, el coeficiente dividido por su error estándar. Para los hombres casados, $t = 5{,}27$: datos como estos serían muy raros si los hombres casados cobrasen lo mismo que los solteros con la misma educación, experiencia y antigüedad, y el contraste al 5 % rechaza. Para las mujeres casadas, $t = -2{,}07$, y el contraste al 5 % también rechaza, porque $|t|$ supera el valor crítico, 1,96. Para las mujeres solteras, $t = -1{,}68$: datos como estos no serían demasiado raros si cobrasen lo mismo que los hombres solteros, y el contraste al 5 % no rechaza.

La ecuación estimada da directamente las tres diferencias con la categoría base, pero no las diferencias entre dos grupos que no son la categoría base. La diferencia entre mujeres casadas y solteras es la resta de los dos coeficientes, $-0{,}120 - (-0{,}097) = -0{,}023$ (un 2 % menos), y su error estándar no se obtiene de los de la ecuación. La varianza de una diferencia de dos estimadores, aquí los coeficientes $\hat{\beta}_3$ de `mcasada` y $\hat{\beta}_4$ de `msoltera`, es $\text{Var}(\hat{\beta}_3 - \hat{\beta}_4) = \text{Var}(\hat{\beta}_3) + \text{Var}(\hat{\beta}_4) - 2\,\text{Cov}(\hat{\beta}_3, \hat{\beta}_4)$, la varianza de una diferencia de variables aleatorias de la asignatura de Estadística, y la tabla de resultados de Gretl no imprime la covarianza. Aquí no es despreciable. Los dos coeficientes son diferencias respecto del mismo grupo, los hombres solteros, y un error al estimar lo que cobra ese grupo desplaza a los dos en el mismo sentido. La covarianza estimada es positiva, 0,0019, y el error estándar de la diferencia es $\sqrt{0{,}058^2 + 0{,}057^2 - 2 \times 0{,}0019} = 0{,}053$; sin la covarianza saldría $\sqrt{0{,}058^2 + 0{,}057^2} = 0{,}081$. Hay una forma de evitar el cálculo: cambiar la categoría base. Si se estima el mismo modelo con las mujeres solteras como categoría base, es decir, con las indicadoras de hombres solteros, hombres casados y mujeres casadas (`hsoltero = (1-female)*(1-married)`, `hcasado` y `mcasada`), la ecuación estimada es

$$\begin{aligned}\widehat{\log(\text{wage})} = &\underset{(0,099)}{0{,}291} + \underset{(0,057)}{0{,}097}\,\text{hsoltero} + \underset{(0,050)}{0{,}389}\,\text{hcasado} - \underset{(0,053)}{0{,}023}\,\text{mcasada}\\ &+ \underset{(0,0069)}{0{,}0835}\,\text{educ} + \underset{(0,0017)}{0{,}0032}\,\text{exper} + \underset{(0,0029)}{0{,}0157}\,\text{tenure}.\end{aligned}$$

El coeficiente de `mcasada` es ahora directamente la diferencia buscada, $-0{,}023$, con su error estándar, 0,053, y su t, $-0{,}45$: datos como estos no serían raros si las mujeres casadas y las solteras cobrasen lo mismo, con lo demás fijo. Los coeficientes de las otras dos indicadoras son también diferencias respecto de las mujeres solteras, y se obtienen de la primera ecuación restándoles el de `msoltera`, $-0{,}097$: $0 - (-0{,}097) = 0{,}097$ para los hombres solteros y $0{,}292 - (-0{,}097) = 0{,}389$ para los casados. La constante, en cambio, le suma ese coeficiente: $0{,}388 + (-0{,}097) = 0{,}291$. El ajuste y los coeficientes de `educ`, `exper` y `tenure` no cambian al cambiar la categoría base; solo cambia qué diferencias se leen directamente.

Hay otra forma de poner el sexo y el estado civil en el modelo: dos indicadoras, `female` y `married`, en lugar de tres. La ecuación estimada es

$$\begin{aligned}\widehat{\log(\text{wage})} = \underset{(0{,}101)}{0{,}490} - \underset{(0{,}037)}{0{,}286}\,\text{female} + \underset{(0{,}040)}{0{,}126}\,\text{married} \\ + \underset{(0{,}0070)}{0{,}0839}\,\text{educ} + \underset{(0{,}0017)}{0{,}0031}\,\text{exper} + \underset{(0{,}0030)}{0{,}0169}\,\text{tenure}.\end{aligned}$$

Ese modelo es más restrictivo. El coeficiente de `married`, 0,126 en logaritmos, es la diferencia entre casados y solteros, y el modelo impone que sea la misma para hombres y para mujeres. En el modelo de los cuatro grupos las dos diferencias estimadas son muy distintas. En la primera ecuación de esta sección, la diferencia entre casados y solteros es 0,292 entre los hombres (el coeficiente de `hcasado`, porque la categoría base son los hombres solteros) y $-0{,}120 - (-0{,}097) = -0{,}023$ entre las mujeres. El modelo de los cuatro grupos es el de las dos indicadoras más su producto, `femmar = female*married`, y ese producto es una *interacción*: permite que la diferencia entre casados y solteros dependa del sexo. Estimado así,

$$\begin{aligned}\widehat{\log(\text{wage})} = \underset{(0{,}102)}{0{,}388} - \underset{(0{,}057)}{0{,}097}\,\text{female} + \underset{(0{,}055)}{0{,}292}\,\text{married} - \underset{(0{,}074)}{0{,}316}\,\text{femmar} \\ + \underset{(0{,}0069)}{0{,}0835}\,\text{educ} + \underset{(0{,}0017)}{0{,}0032}\,\text{exper} + \underset{(0{,}0029)}{0{,}0157}\,\text{tenure},\end{aligned}$$

da el mismo ajuste que el de los cuatro grupos, con la misma constante y la misma suma de cuadrados de los residuos, 85,46, porque los dos generan el mismo subespacio. Cambia lo que mide cada coeficiente, siempre respecto de los hombres solteros. El de `married` mide la diferencia entre casados y solteros entre los hombres, 0,292. El de `female`, la diferencia entre mujeres solteras y hombres solteros, $-0{,}097$. El de la interacción, cuánto cambia la diferencia entre casados y solteros al pasar de los hombres a las mujeres: $-0{,}316$, la resta $-0{,}023 - 0{,}292$ salvo redondeo. Su t es $-4{,}27$: datos como estos serían muy raros si la diferencia entre casados y solteros fuese la misma para hombres y mujeres, que es la restricción del modelo de dos indicadoras. Es la idea de la transparencia "Interacciones: la pendiente cambia de grupo", aplicada a dos indicadoras.

Para profundizar: Wooldridge, J. M. (2020), cap. 7, sección 7.3 ("Using dummy variables for multiple categories"), con el ejemplo 7.6, que es este modelo con dos regresores cuadráticos más; sección 7.4 para la interacción entre dos indicadoras.

7 Interacciones: la pendiente cambia de grupo

Una indicadora desplaza el intercepto; su producto por otro regresor, la *interacción*, desplaza una pendiente:

$$\log(\text{wage}) = \beta_1\, 1 + \beta_2\, \mathbb{1}_{\text{mujer}} + \beta_3\, \text{educ} + \beta_4\, \text{exper} + \beta_5\, \mathbb{1}_{\text{mujer}} \cdot \text{exper} + \beta_6\, \text{tenure} + U.$$

Pendiente de `exper`: β_4 para los hombres, $\beta_4 + \beta_5$ para las mujeres. Diferencia de interceptos: β_2.

`lwage` sobre…	coef.	ee	t
`female`	−0,190	0,059	−3,25
`exper`	0,0084	0,0022	3,76
`female*exper`	−0,0067	0,0027	−2,44
`educ`, `tenure`	0,0896; 0,0158		

Lectura, con la misma educación y antigüedad: un año más de experiencia se acompaña de un salario un 0,84 % mayor para los hombres y un $0{,}84 + (-0{,}67) = 0{,}17$ % para las mujeres. Con la misma experiencia, la diferencia de la mujer respecto del hombre es $-0{,}190 - 0{,}0067\,\text{exper}$ en logaritmos, y $e^{-0{,}190-0{,}0067\,\text{exper}} - 1$ en porcentaje exacto. Con $t = -2{,}44$, datos como estos serían raros si las dos pendientes fuesen iguales.

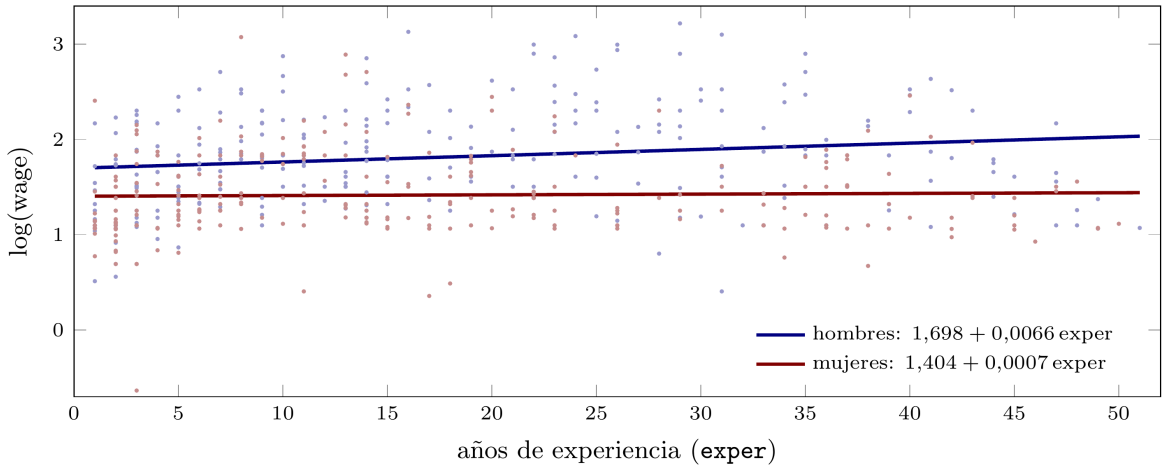


Figura 3: Los 526 trabajadores de `wage1`: logaritmo del salario por hora frente a los años de experiencia, los hombres en azul y las mujeres en rojo. Las dos rectas son el ajuste de `lwage` sobre la constante, `female`, `exper` y su producto, sin `educ` ni `tenure` para que la figura sea plana: la de los hombres tiene ordenada en el origen 1,698 y pendiente 0,0066; la de las mujeres, 1,404 y 0,0007. La indicadora separa las dos ordenadas en el origen y la interacción separa las dos pendientes: la distancia vertical entre las rectas crece con la experiencia. Los coeficientes de la tabla de la transparencia, con `educ` y `tenure`, son algo distintos de los de la figura.

Una indicadora: dos rectas paralelas. Una indicadora y una interacción: dos rectas distintas. Sin ninguna de las dos: una sola recta para todos.

Interacciones: la pendiente cambia de grupo

El modelo de la transparencia "En log-nivel: una diferencia porcentual" impone que la diferencia salarial entre sexos sea la misma a cualquier nivel de experiencia: la indicadora desplaza el intercepto y nada más, así que las dos rectas del salario frente a la experiencia, una para cada sexo, son paralelas. Es una restricción, y los datos pueden no cumplirla. Para permitir que la pendiente de `exper` sea distinta en cada grupo se añade al modelo el producto de la indicadora por el regresor, $\mathbb{1}_{\text{mujer}} \cdot \text{exper}$, que se llama *interacción* entre las dos variables. En la muestra es una columna más de $\mathbf{X}$: vale `exper` en las filas de las mujeres y 0 en las de los hombres; Gretl la construye con `series femexper = female*exper`. Es un regresor en el sentido de la lección 15, una función de dos variables explicativas, y mínimos cuadrados lo trata como a cualquier otro.

La lectura se obtiene escribiendo el modelo por grupos. Para un hombre, $\mathbb{1}_{\text{mujer}} = 0$, y la parte sistemática es $\beta_1 + \beta_3\,\text{educ} + \beta_4\,\text{exper} + \beta_6\,\text{tenure}$: la pendiente de la experiencia es β_4. Para una mujer, $\mathbb{1}_{\text{mujer}} = 1$, y queda $(\beta_1+\beta_2)+\beta_3\,\text{educ}+(\beta_4+\beta_5)\,\text{exper}+\beta_6\,\text{tenure}$: el intercepto se desplaza en β_2 y la pendiente de la experiencia pasa a ser $\beta_4+\beta_5$. El coeficiente de la interacción, β_5, es por tanto la diferencia entre las pendientes de los dos grupos, y la hipótesis de que las dos rectas son paralelas es $H_0\colon \beta_5 = 0$, que se contrasta con el t de la lección 12.

Con los datos, la ecuación estimada es

$$\begin{aligned}\widehat{\log(\text{wage})} = {} & \underset{(0{,}107)}{0{,}417} - \underset{(0{,}059)}{0{,}190}\,\text{female} + \underset{(0{,}0070)}{0{,}0896}\,\text{educ} + \underset{(0{,}0022)}{0{,}0084}\,\text{exper} \\ & - \underset{(0{,}0027)}{0{,}0067}\,\text{femexper} + \underset{(0{,}0030)}{0{,}0158}\,\text{tenure}.\end{aligned}$$

La pendiente de la experiencia es 0,0084 para los hombres: un año más de experiencia se acompaña de un salario mayor en un 0,84 %, con lo demás fijo. Para las mujeres es $\hat\beta_4 + \hat\beta_5 = 0{,}0084 + (-0{,}0067) = 0{,}0017$, un 0,17 % por año. El t de la interacción es $-2{,}44$: datos como estos serían raros si las dos pendientes fuesen iguales, y el contraste al 5 % rechaza que lo sean. El coeficiente de `female`, $-0{,}190$, es ahora la diferencia de interceptos, es decir, la diferencia en logaritmos entre una mujer y un hombre sin experiencia y con la misma educación y antigüedad. Para verlo, se restan las partes sistemáticas de una mujer y de un hombre con la misma educación, la misma experiencia y la misma antigüedad. Los términos β_1, $\beta_3\,\text{educ}$, $\beta_4\,\text{exper}$ y $\beta_6\,\text{tenure}$ son iguales para los dos y se anulan en la resta, y quedan los de la indicadora y la interacción: $\beta_2 + \beta_5\,\text{exper}$. La diferencia no depende, por tanto, de cuánta educación y antigüedad tengan, con tal de que sean las mismas para los dos; sí depende de la experiencia. Con $\text{exper} = 0$ es $\hat\beta_2 = -0{,}190$, y cada año de experiencia le suma $\hat\beta_5 = -0{,}0067$, así que la brecha se amplía. A los diez años es $-0{,}190 + 10 \cdot (-0{,}0067) = -0{,}257$, y a los veinte, $-0{,}324$. En diferencia porcentual exacta, con la fórmula $e^{\beta}-1$ de la transparencia "En log-nivel: una diferencia porcentual", son $e^{-0{,}190}-1 = -0{,}173$, $e^{-0{,}257}-1 = -0{,}227$ y $e^{-0{,}324}-1 = -0{,}277$: con la misma educación y antigüedad, una mujer cobra un 17 % menos que un hombre si ninguno de los dos tiene experiencia, un 23 % menos si los dos tienen diez años y un 28 % menos si tienen veinte. La figura dibuja esta situación con el modelo simple sin `educ` ni `tenure`: la recta de los hombres sube con la experiencia y la de las mujeres apenas, y la distancia entre las dos crece de izquierda a derecha. Sin la interacción, el mismo modelo daba las dos rectas paralelas de la figura de "En log-nivel: una diferencia porcentual".

La misma construcción se aplica a cualquier regresor, y el resultado no siempre es una pendiente distinta. Con la interacción `female*educ` en lugar de `female*exper`, el coeficiente de la interacción

es $-0{,}0072$ con error estándar 0,0136 y $t = -0{,}53$: datos como estos no serían raros si el rendimiento de la educación fuese el mismo para hombres y mujeres, y el contraste no sugiere pendientes distintas en `educ`. Al añadir la interacción `female*educ` cambia también la lectura del coeficiente de `female`. Por el mismo argumento que con la experiencia, la diferencia entre una mujer y un hombre con la misma educación, experiencia y antigüedad es $\beta_2 + \beta_5$ educ, con β_5 ahora el coeficiente de `female*educ`. El coeficiente de `female`, β_2, es esa diferencia con educ $= 0$: entre una mujer y un hombre sin ningún año de educación. En la muestra solo dos trabajadores tienen cero años de educación, así que los datos apenas informan sobre esa diferencia. El coeficiente se obtiene prolongando hasta cero años de educación las rectas de hombres y mujeres, que están estimadas con trabajadores de entre 8 y 18 años de educación en su gran mayoría. Por eso su error estándar es grande: el coeficiente estimado es $-0{,}21$ con error estándar 0,17.

Cuando interesa la diferencia entre sexos en un punto con datos, se elige ese punto como el cero del regresor. Lo habitual es la media. Se construye el regresor centrado `educc = educ - mean(educ)`, que vale cero en la media de la educación, 12,56 años, y su interacción `female*educc`. Centrar solo traslada el origen del regresor: $\boldsymbol{x}_{\text{educc}} = \boldsymbol{x}_{\text{educ}} - 12{,}56\,\mathbf{1}$ y $\boldsymbol{d}_{\text{mujer}} \odot \boldsymbol{x}_{\text{educc}} = \boldsymbol{d}_{\text{mujer}} \odot \boldsymbol{x}_{\text{educ}} - 12{,}56\,\boldsymbol{d}_{\text{mujer}}$, con $\odot$ el producto componente a componente de la lección 7, así que las columnas nuevas son combinaciones lineales de las antiguas y generan el mismo subespacio. El ajuste, la pendiente de la educación y el coeficiente de la interacción, con su t, no cambian. Cambian la constante y el coeficiente de `female`, que pasa a ser $\beta_2 + \beta_5 \cdot 12{,}56$: la diferencia entre una mujer y un hombre con la educación media. Estimado así, vale $-0{,}301$ con error estándar 0,037. Con la educación media, y la misma experiencia y antigüedad, una mujer cobra un 26 % menos que un hombre, porque $e^{-0{,}301} - 1 = -0{,}260$. Con $t = -8{,}09$, datos como estos serían muy raros si no hubiese diferencia. El error estándar es casi cinco veces menor que el de $-0{,}21$, porque ahora la diferencia se mide donde están los datos.

Para profundizar: Wooldridge, J. M. (2020), cap. 7, sección 7.4 ("Interactions involving dummy variables"), apartados "Interactions among dummy variables" y "Allowing for different slopes", con el ejemplo 7.10 (`female*educ`) y la observación sobre centrar el regresor.

8 El contraste de Chow: ¿la misma ecuación?

Para que cada sexo tenga su propio intercepto y sus propias pendientes, se añaden al modelo común (`lwage` sobre `educ`, `exper` y `tenure`) `female` y su producto por cada regresor: `female*educ`, `female*exper` y `female*tenure`. El ajuste es el de dos regresiones separadas, una por sexo. H_0: sus cuatro coeficientes valen cero ($q = 4$). Es el F de la lección 13:

$$F = \frac{(\text{SRC}_r - \text{SRC})/q}{\text{SRC}/(n-k)}, \qquad \text{SRC} = \text{SRC}_{\text{hombres}} + \text{SRC}_{\text{mujeres}}.$$

Modelo común, $\text{SRC}_r = 101{,}46$; hombres ($n = 274$), 49,55; mujeres ($n = 252$), 39,04. Así, $F = \dfrac{(101{,}46 - 88{,}58)/4}{88{,}58/518} = 18{,}8$, frente a $F_c = 2{,}39$ al 5 %.

Lectura: datos como estos serían muy raros si hombres y mujeres compartiesen la ecuación. El contraste dice que algo difiere, no qué: con las ocho columnas ningún t supera 2, porque `female` y `female*educ` tienen correlación 0,96 (lección 14).

El uso original: con datos ordenados en el tiempo, si la relación cambia a partir de una fecha (*cambio estructural*); los grupos son el antes y el después.

El contraste de Chow: ¿la misma ecuación?

Las transparencias "En log-nivel: una diferencia porcentual" e "Interacciones: la pendiente cambia de grupo" han dejado que difieran entre sexos primero el intercepto y después una pendiente. El caso general es dejar que difieran todos los coeficientes: el intercepto y las pendientes de `educ`, `exper` y `tenure`. El modelo que lo permite tiene la constante, los tres regresores, la indicadora `female` y las tres interacciones `female*educ`, `female*exper` y `female*tenure`, ocho columnas. Escrito por grupos, es una ecuación con cuatro coeficientes para los hombres y otra, con otros cuatro, para las mujeres, sin nada en común: las ocho columnas generan el mismo subespacio que las cuatro columnas del modelo común multiplicadas por $\boldsymbol{d}_{\text{hombre}}$ junto con las mismas cuatro multiplicadas por $\boldsymbol{d}_{\text{mujer}}$, y cada vector del primer grupo es ortogonal a cada uno del segundo, porque no tienen ninguna fila distinta de cero en común. La proyección sobre el subespacio se hace, por tanto, grupo a grupo, y el ajuste coincide con el de dos regresiones separadas, una con los 274 hombres y otra con las 252 mujeres: la suma de cuadrados de los residuos del modelo con las interacciones, 88,58, es la suma de las de las dos regresiones separadas, 49,55 y 39,04.

La pregunta de si hombres y mujeres comparten la ecuación es la hipótesis nula de que los coeficientes de la indicadora y de las tres interacciones valen cero, cuatro restricciones lineales. Es el contraste F de la lección 13 sin ningún cambio: el modelo restringido es el modelo común, `lwage` sobre la constante, `educ`, `exper` y `tenure`, con $\text{SRC}_r = 101{,}46$; el modelo completo es el de las ocho columnas, con $\text{SRC} = 88{,}58$ y $n - k = 526 - 8 = 518$ grados de libertad. El estadístico es $F = \frac{(101{,}46 - 88{,}58)/4}{88{,}58/518} = 18{,}8$, frente a un valor crítico al 5 % de 2,39; el valor p es del orden de 10^{-14}. Como F supera con mucho el valor crítico, datos como estos serían muy raros si hombres y mujeres compartiesen la ecuación, y el contraste rechaza que la compartan. Este uso del F, con un modelo restringido común y uno sin restringir que equivale a dos regresiones separadas, se llama *contraste de Chow*, por Chow (1960).

El contraste dice que la ecuación no es la misma, pero no dice en qué difiere. El modelo con las ocho columnas, estimado, es

$$\begin{aligned}\widehat{\log(\text{wage})} = {} & \underset{(0{,}135)}{0{,}322} + \underset{(0{,}199)}{0{,}034}\,\text{female} + \underset{(0{,}0090)}{0{,}0963}\,\text{educ} + \underset{(0{,}0024)}{0{,}0081}\,\text{exper} + \underset{(0{,}0036)}{0{,}0182}\,\text{tenure} \\ & - \underset{(0{,}0142)}{0{,}0162}\,\text{female}\cdot\text{educ} - \underset{(0{,}0033)}{0{,}0059}\,\text{female}\cdot\text{exper} - \underset{(0{,}0065)}{0{,}0079}\,\text{female}\cdot\text{tenure},\end{aligned}$$

y sus t tampoco lo dicen: ninguno supera 2 en valor absoluto (`female`, 0,17; las interacciones con `educ`, `exper` y `tenure`, −1,15, −1,80 y −1,21), y sin embargo el F conjunto es 18,8. Es el caso de la lección 13, un F conjunto alto con t individuales pequeños, y la causa es la de la lección 14: la indicadora y sus tres interacciones están muy correlacionadas. La columna `female*educ` vale `educ` para las mujeres y cero para los hombres, y como `educ` varía poco respecto de su media (12,6 años, con desviación típica 2,8), esa columna es casi proporcional a `female`, con correlación 0,96; el VIF de `female` en ese modelo es 30. Cada una de las cuatro columnas tiene poca variación propia y su t es pequeño, aunque entre las cuatro aporten mucho al ajuste. Para averiguar qué difiere hay que preguntar una cosa cada vez, como hizo la transparencia "Interacciones: la pendiente cambia de grupo" con la pendiente de `exper`, cuya interacción, sola, tiene $t = -2{,}44$. Una variante útil

pregunta solo por las pendientes. Permite que cada sexo tenga su propio intercepto, porque mantiene `female` en el modelo, y contrasta si las pendientes de `educ`, `exper` y `tenure` son las mismas para hombres y mujeres, es decir, si los coeficientes de las tres interacciones valen cero. Para ello se estima el modelo con las ocho columnas y se imponen esas tres restricciones con `restrict`, como en la actividad 2 (html) de la práctica A de la sesión 20. El modelo restringido es entonces el de la transparencia "En log-nivel: una diferencia porcentual": interceptos distintos para cada sexo y pendientes comunes, con rectas paralelas como las de su figura. Con estos datos, $F(3, 518) = 3{,}04$ y valor p 0,028: el contraste rechaza al 5 %, y datos como estos serían raros si las tres pendientes fuesen comunes. Y el caso más simple, $q = 1$, es el de la transparencia "En log-nivel: una diferencia porcentual": si solo puede diferir el intercepto, el F con una restricción es el cuadrado del t de `female`, $8{,}09^2 = 65{,}4$, como se vio en la lección 13.

El uso original del contraste de Chow es con datos ordenados en el tiempo: la pregunta es si la relación cambia a partir de una fecha, un *cambio estructural*, y los dos grupos son las observaciones anteriores y posteriores a esa fecha. La mecánica es la misma, con la indicadora del periodo posterior en lugar de la del sexo.

Para profundizar: Wooldridge, J. M. (2020), cap. 7, sección 7.4, apartado "Testing for differences in regression functions across groups" (el contraste de Chow como F de las interacciones); Chow, G. C. (1960), "Tests of equality between sets of coefficients in two linear regressions", *Econometrica* 28, 591–605; lección 13 de este curso, "El contraste F".

9 Qué dice y qué no dice el coeficiente de una indicadora

Modelo	El coeficiente mide…	Lectura, con los demás regresores fijos
y en niveles	la diferencia entre el grupo señalado y la categoría base	el grupo señalado tiene β unidades de y más que la categoría base
$\log y$	esa diferencia en logaritmos	tiene un $100(e^{\beta} - 1)$ % más, aproximadamente 100β % si β es pequeño
varias categorías	la diferencia de cada grupo con la categoría base	la diferencia entre dos grupos que no son la categoría base es la resta de sus coeficientes
interacción $\mathbb{1} \cdot x$	la diferencia entre las pendientes de x	la pendiente de x es β_x en la categoría base y $\beta_x + \beta$ en el grupo señalado

Lo que no dice. Una indicadora no tiene unidades: su coeficiente no es el efecto de "una unidad más", sino la diferencia entre dos grupos. Qué grupo vale 1 lo decide quien codifica los datos; cambiarlo cambia el signo y la categoría base, no el ajuste. Una indicadora no se transforma logarítmicamente: su logaritmo no existe en 0.

"Con los demás regresores fijos" quiere decir con los del modelo, y nada más. El 26 % entre sexos compara trabajadores con la misma educación, experiencia y antigüedad; no mide la discriminación, porque faltan variables como la ocupación o la jornada.

Qué dice y qué no dice el coeficiente de una indicadora

La tabla de la transparencia reúne las cuatro lecturas de la lección. Las tres primeras son la misma idea en tres formas: el coeficiente de una indicadora es la diferencia entre el grupo señalado y la categoría base, con los demás regresores fijos. En un modelo en niveles, la diferencia está en las unidades del regresando: 1,81 dólares por hora, 4,08 mil dólares. En un modelo con el regresando en logaritmos, la diferencia es relativa: la fracción $e^{\beta} - 1$, que para coeficientes pequeños se aproxima por β, y que se calcula respecto de la categoría base, de modo que el porcentaje cambia al cambiar la categoría base. Con varias categorías, cada coeficiente compara su grupo con la categoría base, y la diferencia entre dos grupos que no son la categoría base es la resta de sus coeficientes; su error estándar se obtiene cambiando la categoría base. La cuarta lectura es distinta: el coeficiente de una interacción es una diferencia de pendientes, y el efecto del regresor en el grupo señalado es la suma de la pendiente común y la interacción.

Las lecturas incorrectas más frecuentes son tres. La primera es tratar la indicadora como una variable con unidades y hablar de "una unidad más de `female`". Una indicadora solo toma dos valores, y su coeficiente compara los dos grupos; no hay nada entre 0 y 1. La segunda es olvidar que la codificación es una decisión. Que las mujeres valgan 1 y los hombres 0, y no al revés, lo decidió quien preparó el fichero; con la codificación contraria el coeficiente sería +0,301, el ajuste sería el mismo y la lectura, la misma diferencia vista desde la otra categoría base. Lo que se compara son grupos, no valores de una variable. Relacionado con esto, una indicadora nunca se transforma: no tiene sentido su logaritmo, que no existe en cero, ni su cuadrado, que es ella misma. La tercera lectura incorrecta es la que la transparencia "Con más regresores: la diferencia con lo demás fijo" ya señaló. "Con lo demás fijo" quiere decir con los regresores del modelo fijos, y nada más. La diferencia del 26 % entre sexos de la transparencia "En log-nivel: una diferencia porcentual" es una diferencia entre hombres y mujeres con la misma educación, experiencia y antigüedad observadas. No es una medida de la discriminación salarial, porque el modelo no contiene la ocupación, el sector, la jornada ni otras variables en las que los dos grupos difieren, y no dice qué parte de la diferencia se debe a cada una. Lo que un modelo con indicadoras puede decir es cuánto cambia la diferencia entre grupos al fijar las variables que incluye: de −2,51 a −1,81 dólares al fijar tres variables. Atribuir lo que queda a una causa concreta exige un argumento que la regresión no proporciona.

Para profundizar: Wooldridge, J. M. (2020), cap. 7, sección 7.2, la discusión del ejemplo 7.1 sobre lo que el coeficiente de `female` mide y lo que no; cap. 3, sección 3.3 ("omitted variable bias") para el papel de las variables que faltan.

10 Recapitulación y guiño a la lección siguiente

Pieza	Fórmula	Lectura
Indicadora como regresor	$\mathbb{1}_A$ en la población, $\boldsymbol{d}$ en la muestra	su coeficiente es un salto entre grupos
Dos grupos complementarios	$\mathbb{1}_A + \mathbb{1}_{A^c} = \mathit{1}$; $\boldsymbol{d}_A + \boldsymbol{d}_{A^c} = \mathbf{1}$	ortogonales: coeficientes = medias; con $\mathbf{1}$, trampa
Log-nivel	$e^{\beta} - 1$	diferencia porcentual exacta respecto de la categoría base
Interacción	pendiente del grupo señalado: $\beta_4 + \beta_5$ en el ejemplo de `exper`	la pendiente común más la diferencia de pendientes
Contraste de Chow	F de la lección 13 con SRC = $\text{SRC}_{\text{grupo 1}} + \text{SRC}_{\text{grupo 2}}$	¿la misma ecuación en los dos grupos?

Geometría nueva: solo la ortogonalidad de dos indicadoras complementarias. Nada enunciado sin demostrar. *Lección 17*: los residuos de `wage` tienen desviación típica 3,42 entre los hombres y 2,32 entre las mujeres; con `lwage`, 0,43 y 0,40. Una varianza que cambia con el grupo es heterocedasticidad.

Recapitulación y guiño a la lección siguiente

La lección ha añadido un tipo de regresor y una tabla de lecturas. El regresor es la indicadora de un grupo, $\mathbb{1}_A$ en la población y el vector $\boldsymbol{d}$ de ceros y unos en la muestra, que la lección 12 ya había definido para otro fin. Para mínimos cuadrados es una columna más; su coeficiente es una diferencia entre el grupo señalado y la categoría base, con los demás regresores fijos: en unidades del regresando si está en niveles, en fracción $e^{\beta} - 1$ si está en logaritmos, y respecto de la categoría base en los dos casos. El producto de una indicadora por otro regresor, la interacción, convierte la diferencia de interceptos en diferencia de pendientes. Y la pregunta de si dos grupos comparten la ecuación entera es un contraste F de la lección 13, el contraste de Chow, cuyo modelo sin restringir equivale a dos regresiones separadas.

La única geometría nueva ha sido pequeña: dos indicadoras de grupos complementarios son ortogonales y suman $\mathbf{1}$. De lo primero sale que sus coeficientes son las medias de grupo; de lo segundo, que no pueden entrar las dos junto con la constante, la trampa de las variables ficticias, y también que la constante no necesita ser una columna de $\mathbf{X}$ para que el ajuste tenga sus propiedades, como la lección 10 había anticipado. Nada se ha enunciado sin demostrar: las lecturas son álgebra sobre el modelo, y el contraste de Chow es el F de la lección 13 con un modelo restringido y otro sin restringir.

Lo que hay que retener para leer resultados es la cautela de la transparencia "Qué dice y qué no dice el coeficiente de una indicadora": el coeficiente compara grupos, no unidades; la categoría base es una decisión; y "lo demás fijo" se limita a lo que el modelo contiene. Un 26 % de diferencia salarial entre sexos con tres variables fijas es un hecho de la muestra; qué lo produce es otra pregunta.

La lección 17 parte de una observación que los datos de hoy ya permiten hacer. En el modelo en niveles de la transparencia "Con más regresores: la diferencia con lo demás fijo", los residuos de los hombres tienen una desviación típica de 3,42 dólares y los de las mujeres de 2,32: la dispersión del salario alrededor de la recta no es la misma en los dos grupos, en contra del supuesto de

homocedasticidad de las lecciones 9 y 11, que pide la misma varianza para todas las observaciones. En el modelo con el logaritmo del salario las dos desviaciones típicas se acercan, 0,43 y 0,40, que es lo que la lección 15 anunció: el logaritmo es el primer remedio. La lección 17 tratará cómo detectar la heterocedasticidad, qué consecuencias tiene para los errores estándar y cómo corregirlos. Y el laboratorio integrador volverá al Boston original con `chas` para estimar, con datos reales y de una vez, un modelo con logaritmos, indicadoras e interacciones, y diagnosticarlo.

Para profundizar: Wooldridge, J. M. (2020), cap. 7, secciones 7.1 a 7.4 (resumen de la lección) y cap. 8, sección 8.1 (anticipo de la heterocedasticidad).