

Sesión 7 (A) — Correlación como coseno: verificación geométrica con hprice2

Marcos Bujosa

Descripción de la práctica

En las lecciones 4 y 5 vimos que la media se obtiene mediante una proyección ortogonal, la desviación típica es una norma, la covarianza es un producto escalar de vectores centrados (es decir, vectores en desviaciones respecto a su media) y, como resultado central de la lección 5, que la correlación ρ_{xy} es el *coseno del ángulo* entre los vectores en desviaciones. Todo eso se demostró con álgebra. Hoy lo *verificamos con datos reales*: calcularemos ρ con el comando de Gretl y, por otro lado, “a mano”, construyendo el producto escalar y las normas con instrucciones de Gretl, para comprobar que ambos procedimientos dan el mismo número.

Retomamos **hprice2** (práctica de la sesión con Gretl anterior) y las mismas tres variables ya etiquetadas: **price**, **rooms**, **nox**.

Los comandos de Gretl que aparecen hoy. En la sesión 4 usamos Gretl casi solo desde los menús. Hoy escribiremos instrucciones en la consola (menú **Herramientas** -> **Consola de Gretl**) o en un guion (**Archivo** -> **Archivos de guion** -> **Nuevo guion**). Conviene fijar antes cuatro ideas del lenguaje:

series crea una variable nueva del conjunto de datos, con un valor por observación. Para nosotros, un vector de $\mathbb{R}^n$. Las operaciones entre series se hacen componente a componente: **price - mean(price)** resta la media a cada uno de los 506 precios.

scalar crea un número (un escalar), por ejemplo el resultado de una suma o de una norma. Los escalares se conservan durante toda la sesión y pueden usarse en instrucciones posteriores.

Funciones **mean(x)**, **sum(x)**, **sqrt(a)**, **cov(x,y)**, **corr(x,y)** o **acos(a)** devuelven un número a partir de una o dos series, o de un escalar. Se escriben con paréntesis, como en matemáticas.

printf imprime un texto con números intercalados. Cada **%4f** es el hueco para un número con cuatro decimales; los valores que rellenan los huecos van después del texto, separados por comas y en el mismo orden; **\n** es un salto de línea.

Todo lo demás son comandos ya vistos (**open**, **setinfo**, **summary**) o que se explican donde aparecen. Para consultar cualquiera de ellos: **help nombre** en la consola (sesión 4).

Objetivo

1. Repasar estadísticos descriptivos de varias variables a la vez.
2. Calcular covarianzas y correlaciones entre pares de variables.
3. Visualizar la relación mediante diagramas de dispersión.
4. Verificar numéricamente que $\rho = \cos \theta$ entre los vectores *centrados* (es decir, en desviaciones).
5. Interpretar el signo y la magnitud de ρ en términos del ángulo entre vectores en desviaciones.

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

Actividad 1 - Recordatorio: datos y estadísticos descriptivos

Abrimos de nuevo `hprice2` y recuperamos las etiquetas de la práctica anterior. `open` carga el fichero de muestra (`--quiet` evita que Gretl liste sus variables) y `setinfo` vuelve a dar a cada variable su descripción (`-d`) y el nombre que se mostrará en los gráficos (`-n`), como en la sesión 4. Hay que repetirlo porque las etiquetas no quedaron guardadas en el fichero de muestra.

en línea de comandos:

```
open hprice2.gdt --quiet
setinfo price -d "Precio mediano de la vivienda ($)" -n "Precio ($)"
setinfo rooms -d "Número medio de habitaciones" -n "Habitaciones"
setinfo nox -d "Concentración de óxidos de nitrógeno" -n "Contaminación (NOx)"
```

- Recuerde los estadísticos descriptivos. `summary` muestra, para cada variable, la media, la mediana, el mínimo, el máximo, la desviación típica y algunas medidas más (sesión 4):

en línea de comandos:

```
summary price rooms nox
```

	Media	Mediana	Mínimo	Máximo
price	22512	21200	5000,0	50001
rooms	6,2841	6,2100	3,5600	8,7800
nox	5,5498	5,3800	3,8500	8,7100

	Desv. Típica.	C.V.	Asimetría	Exc. de curtosis
price	9208,9	0,40907	1,1063	1,4594
rooms	0,70259	0,11181	0,40281	1,8595
nox	1,1584	0,20873	0,72258	-0,080785

	Perc. 5%	Perc. 95%	Rango IQ	Observaciones ausentes
price	10200	43695	8199,0	0
rooms	5,3000	7,6295	0,74250	0
nox	4,0900	7,4000	1,7500	0

Actividad 2 - Covarianzas y correlaciones

- En la ventana principal de Gretl, marque `price`, `rooms` y `nox` (con `Ctrl`), “pinche” con el botón derecho y seleccione **Matriz de correlación**.

El comando `corr` seguido de una lista de variables calcula la correlación de cada par y las presenta en una matriz simétrica, con unos en la diagonal (la correlación de cada variable consigo misma). No lo confunda con la función `corr(x,y)`, con paréntesis y dos variables, que devuelve un solo número y que usaremos en el bloque siguiente.

o bien teclee en línea de comandos:

```
corr price rooms nox
```

Antes de mirar el resultado: pensando en términos económicos, ¿qué signo esperarías en cada uno de los tres pares?

Resultado

Debe obtener una salida como esta:

Coefficientes de correlación, usando las observaciones 1 - 506

Valor crítico al 5% (a dos colas) = 0,0872 para n = 506

price	rooms	nox
1,0000	0,6958	-0,4260
	1,0000	-0,3028
		1,0000

- Calculemos también, por separado, la covarianza y la correlación de cada par de variables (funciones `cov` y `corr` de Gretl)¹. Son tres líneas `printf`, una por par. Cada una tiene dos huecos `%.4f` que se rellenan, por orden, con el valor de `cov(x,y)` y el de `corr(x,y)`; el texto entre comillas se imprime literalmente:

en línea de comandos:

```
printf "Cov(price,rooms) = %.4f    Corr(price,rooms) = %.4f\n", cov(price,rooms), corr(price,rooms)
printf "Cov(price,nox)   = %.4f    Corr(price,nox)   = %.4f\n", cov(price,nox), corr(price,nox)
printf "Cov(rooms,nox)   = %.4f    Corr(rooms,nox)   = %.4f\n", cov(rooms,nox), corr(rooms,nox)
```

```
Cov(price,rooms) = 4501,7557    Corr(price,rooms) = 0,6958
Cov(price,nox)   = -4544,7477   Corr(price,nox)   = -0,4260
Cov(rooms,nox)   = -0,2465     Corr(rooms,nox)   = -0,3028
```

Actividad 3 - Diagramas de dispersión

- Marque dos variables a la vez (p. ej. `price` y `rooms`), “pinche” con el botón derecho y seleccione **Gráfico X-Y**.

El comando `gnuplot` con dos variables dibuja su diagrama de dispersión: la primera en el eje vertical y la segunda en el horizontal. Por defecto superpone una recta ajustada a la nube cuando la relación es apreciable, y en las tres figuras de abajo aparece. En la consola, cada gráfico se abre en una ventana.

o bien teclee en línea de comandos:

```
gnuplot price rooms
gnuplot price nox
gnuplot rooms nox
```




Figura 1: Diagramas de dispersión.

¹Fijese que `corr(x,y)` de Gretl es la implementación numérica del mismo coeficiente de correlación ρ_{xy} definido en la lección 5; aunque `cov(x,y)` no es la implementación exacta de la covarianza σ_{xy} pues Gretl divide internamente por $n - 1$ (en lugar de por n).

Compare la “forma” de cada nube de puntos (más o menos alargada y “alineada” alrededor de la recta mostrada en cada figura²) con el valor numérico de ρ obtenido en la Actividad 2.

Actividad 4 - Verificación geométrica: la correlación como coseno

Vamos a reconstruir, con instrucciones de Gretl, exactamente lo que demostramos con álgebra en la lección 5: centrar los vectores (i.e., restarles su media), comprobar que son ortogonales a **1**, calcular su producto escalar y sus normas, y formar el coseno del ángulo.

Vectores centrados

Tres series nuevas: a cada variable le restamos su media. Gretl resta el mismo número, `mean(price)`, a las 506 componentes, y el resultado es el vector en desviaciones de la lección 4. El sufijo `_c` (de *centrado*) es solo un nombre.

en línea de comandos:

```
series price_c = price - mean(price)
series rooms_c = rooms - mean(rooms)
series nox_c   = nox   - mean(nox)
```

Comprobación de ortogonalidad con 1

La media de cada vector centrado debe ser (esencialmente) cero, es decir, sus valores deben sumar cero (salvo por errores de redondeo). Por tanto, “cada vector centrado debe ser ortogonal a **1**”. Lo comprobamos con `sum(price_c)`, que suma las 506 componentes del vector centrado: es su producto escalar euclídeo con **1**. El formato `%.10f` pide diez decimales, para ver que lo que quede es solo redondeo:

en línea de comandos:

```
printf "Suma price_c = %.10f\n", sum(price_c)
printf "Suma rooms_c = %.10f\n", sum(rooms_c)
printf "Suma nox_c   = %.10f\n", sum(nox_c)
```

```
Suma price_c = 0,0000000152
Suma rooms_c = 0,0000000000
Suma nox_c   = 0,0000000000
```

(Los valores no serán cero por errores de redondeo en coma flotante, pero deben ser insignificantes; del orden de 10^{-8} o menores.)

El coseno del ángulo entre los datos en desviaciones (par price-rooms)

Producto escalar y normas “a mano” (sin dividir por ningún n , es decir, con el producto escalar y la norma *euclídeos*). El bloque traduce línea a línea la fórmula $\cos \theta = \langle \mathbf{x}_c, \mathbf{y}_c \rangle / (\|\mathbf{x}_c\| \|\mathbf{y}_c\|)$:

- `sum(price_c * rooms_c)` multiplica los dos vectores componente a componente y suma los productos: el producto escalar euclídeo.
- `sqrt(sum(price_c^2))` eleva al cuadrado cada componente, suma y extrae la raíz cuadrada: la norma euclídea. El operador `^` actúa componente a componente.
- `coseno_pr` es el cociente de las dos cantidades anteriores.

²que, como veremos en la próxima lección, se llama “recta de regresión”

- `acos` es la función arcocoseno: devuelve el ángulo cuyo coseno es el argumento, en radianes. Multiplicar por `rad2deg`, que vale $180/\pi$, lo pasa a grados.
- Los tres `printf` imprimen el coseno calculado a mano, la correlación que da Gretl y el ángulo.

en línea de comandos:

```
scalar dp_pr      = sum(price_c * rooms_c)
scalar norma_price = sqrt(sum(price_c^2))
scalar norma_rooms = sqrt(sum(rooms_c^2))
scalar coseno_pr   = dp_pr / (norma_price * norma_rooms)

scalar rad2deg    = 180/3.14159265358979
scalar theta_pr   = acos(coseno_pr) * rad2deg

printf "cos(theta) price-rooms (a mano) = %.6f\n", coseno_pr
printf "corr(price,rooms) de Gretl      = %.6f\n", corr(price,rooms)
printf "Ángulo price-rooms = %.2f grados\n", theta_pr
```

Compruebe que `coseno_pr` y `corr(price,rooms)` coinciden.

```
cos(theta) price-rooms (a mano) = 0,695780
corr(price,rooms) de Gretl      = 0,695780
Ángulo price-rooms = 45,91 grados
```

Repetimos para los otros dos pares

Lo mismo para los otros dos pares. Solo falta calcular la norma de `nox_c`: las de `price_c` y `rooms_c` siguen guardadas en los escalares `norma_price` y `norma_rooms`, y el factor `rad2deg` también.

en línea de comandos:

```
scalar norma_nox = sqrt(sum(nox_c^2))

scalar dp_pn = sum(price_c * nox_c)
scalar coseno_pn = dp_pn / (norma_price * norma_nox)
scalar theta_pn = acos(coseno_pn) * rad2deg
printf "cos(theta) price-nox = %.6f (ángulo = %.2f grados)\n", coseno_pn, theta_pn

scalar dp_rn = sum(rooms_c * nox_c)
scalar coseno_rn = dp_rn / (norma_rooms * norma_nox)
scalar theta_rn = acos(coseno_rn) * rad2deg
printf "cos(theta) rooms-nox = %.6f (ángulo = %.2f grados)\n", coseno_rn, theta_rn
```

```
cos(theta) price-nox = -0,426037 (ángulo = 115,22 grados)
cos(theta) rooms-nox = -0,302828 (ángulo = 107,63 grados)
```

Actividad 5 - Síntesis: signo y magnitud como ángulo

Recordando la lección 5: $\rho \approx 1$ corresponde a vectores en desviaciones casi *alineados* (ángulo pequeño); $\rho \approx -1$, a vectores casi alineados pero en *sentidos opuestos* (ángulo cercano a 180°); $\rho \approx 0$, a vectores casi *ortogonales* (ángulo cercano a 90°).

De los tres pares calculados, ¿cuál tiene el ángulo más cercano a 90° ? ¿Qué le dice eso sobre la relación (lineal) entre esas dos variables?

Apéndice - ¿Importa dividir entre n , entre $n - 1$, o no dividir?

En la Actividad 4 no dividimos por ningún n : usamos directamente el producto escalar y la norma *euclídeos* (sin el factor $1/n$ de la lección 4), y aun así el coseno obtenido coincidió con `corr`. Al ser un *cociente*, cualquier factor común que multiplique por igual al numerador y ambas normas se cancela. Comprobémoslo explícitamente, calculando ρ de tres formas distintas. `$nobs` es el número de observaciones del conjunto de datos, 506, y lo guardamos en el escalar `n`. Después calculamos la covarianza y las dos varianzas dos veces, dividiendo por `n` y por `n-1`, y formamos con cada terna el cociente ρ . Los cuatro `printf` imprimen los cuatro resultados uno debajo de otro:

en línea de comandos:

```
scalar n = $nobs

scalar cov_hat_n    = sum(price_c*rooms_c)/n
scalar var_price_n  = sum(price_c^2)/n
scalar var_rooms_n  = sum(rooms_c^2)/n
scalar rho_dividiendo_n = cov_hat_n / sqrt(var_price_n*var_rooms_n)

scalar cov_hat_n1   = sum(price_c*rooms_c)/(n-1)
scalar var_price_n1 = sum(price_c^2)/(n-1)
scalar var_rooms_n1 = sum(rooms_c^2)/(n-1)
scalar rho_dividiendo_n1 = cov_hat_n1 / sqrt(var_price_n1*var_rooms_n1)

printf "rho sin dividir (Actividad 4) = %.6f\n", coseno_pr
printf "rho dividiendo por n         = %.6f\n", rho_dividiendo_n
printf "rho dividiendo por (n-1)     = %.6f\n", rho_dividiendo_n1
printf "rho de Gretl (corr)          = %.6f\n", corr(price,rooms)
```

```
rho sin dividir (Actividad 4) = 0,695780
rho dividiendo por n         = 0,695780
rho dividiendo por (n-1)     = 0,695780
rho de Gretl (corr)          = 0,695780
```

Los cuatro números deben coincidir. Es consecuencia de que ρ es un coseno, y el coseno no cambia si escalamos ambos vectores por la misma constante (homogeneidad de la norma, lección 2; invarianza de la correlación ante reescalados, lección 5). Lo hemos comprobado programándolo.

Preguntas de interpretación para la clase

1. En los tres pares calculados (price-rooms, price-nox, rooms-nox), ¿coincide el signo de la correlación con lo que esperaríamos por argumentos económicos?
2. La covarianza y la correlación entre un mismo par de variables tienen siempre el mismo signo, pero sus magnitudes pueden ser muy distintas de un par a otro. ¿Por qué la correlación es preferible para *comparar* la fuerza de la relación entre distintos pares de variables?
3. ¿Por qué el valor de ρ no depende de si se divide por n , por $n - 1$, o no se divide en absoluto?
4. De los tres pares de variables (en desviaciones), ¿cuál tiene el ángulo más cercano a 90° ? ¿Qué interpretación geométrica tiene ese resultado?
5. Observando los tres diagramas de dispersión, ¿la “forma” de la nube (más o menos alargada/diagonal) se corresponde con la magnitud de ρ calculada?

Para profundizar:

- Wooldridge, J. M. (2020). *Introductory Econometrics: A Modern Approach*. Apéndice B, sección B.4: covarianza y correlación.
- Cottrell, A. y Lucchetti, R. (2023). *Gretl User's Guide*. Sección sobre funciones estadísticas (`corr`, `cov`) y sobre gráficos X-Y.
- Véanse las lecciones 4 y 5 para las demostraciones completas de lo que hoy verificamos numéricamente.

Código completo de la práctica

```
# -----
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# -----

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
↳ directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#   DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
↳ trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

open hprice2.gdt --quiet
setinfo price -d "Precio mediano de la vivienda ($)" -n "Precio ($)"
setinfo rooms -d "Número medio de habitaciones" -n "Habitaciones"
setinfo nox -d "Concentración de óxidos de nitrógeno" -n "Contaminación (NOx)"

outfile --quiet estadisticos.txt
    summary price rooms nox
end outfile

outfile --quiet matrizCorrelaciones.txt
    corr price rooms nox
end outfile

outfile --quiet covarianzasYcorrelaciones.txt
    printf "Cov(price,rooms) = %.4f    Corr(price,rooms) = %.4f\n", cov(price,rooms), corr(price,rooms)
    printf "Cov(price,nox) = %.4f    Corr(price,nox) = %.4f\n", cov(price,nox), corr(price,nox)
    printf "Cov(rooms,nox) = %.4f    Corr(rooms,nox) = %.4f\n", cov(rooms,nox), corr(rooms,nox)
end outfile

gnuplot price rooms --output="price_rooms.png"
gnuplot price nox --output="price_nox.png"
gnuplot rooms nox --output="rooms_nox.png"

series price_c = price - mean(price)
series rooms_c = rooms - mean(rooms)
series nox_c = nox - mean(nox)

outfile --quiet comprobacionOrtogonalidad.txt
    printf "Suma price_c = %.10f\n", sum(price_c)
    printf "Suma rooms_c = %.10f\n", sum(rooms_c)
    printf "Suma nox_c = %.10f\n", sum(nox_c)
end outfile

outfile --quiet coseno-price-rooms.txt
    scalar dp_pr = sum(price_c * rooms_c)
    scalar norma_price = sqrt(sum(price_c^2))
    scalar norma_rooms = sqrt(sum(rooms_c^2))
    scalar coseno_pr = dp_pr / (norma_price * norma_rooms)

    scalar rad2deg = 180/3.14159265358979
    scalar theta_pr = acos(coseno_pr) * rad2deg

    printf "cos(theta) price-rooms (a mano) = %.6f\n", coseno_pr
    printf "corr(price,rooms) de Gretl = %.6f\n", corr(price,rooms)
```

```

    printf "Ángulo price-rooms = %.2f grados\n", theta_pr
end outfile

outfile --quiet cosenosOtrosPares.txt
    scalar norma_nox = sqrt(sum(nox_c^2))

    scalar dp_pn = sum(price_c * nox_c)
    scalar coseno_pn = dp_pn / (norma_price * norma_nox)
    scalar theta_pn = acos(coseno_pn) * rad2deg
    printf "cos(theta) price-nox = %.6f (ángulo = %.2f grados)\n", coseno_pn, theta_pn

    scalar dp_rn = sum(rooms_c * nox_c)
    scalar coseno_rn = dp_rn / (norma_rooms * norma_nox)
    scalar theta_rn = acos(coseno_rn) * rad2deg
    printf "cos(theta) rooms-nox = %.6f (ángulo = %.2f grados)\n", coseno_rn, theta_rn
end outfile

outfile --quiet invarianzarespectodivisor.txt
    scalar n = $nobs

    scalar cov_hat_n = sum(price_c*rooms_c)/n
    scalar var_price_n = sum(price_c^2)/n
    scalar var_rooms_n = sum(rooms_c^2)/n
    scalar rho_dividiendo_n = cov_hat_n / sqrt(var_price_n*var_rooms_n)

    scalar cov_hat_n1 = sum(price_c*rooms_c)/(n-1)
    scalar var_price_n1 = sum(price_c^2)/(n-1)
    scalar var_rooms_n1 = sum(rooms_c^2)/(n-1)
    scalar rho_dividiendo_n1 = cov_hat_n1 / sqrt(var_price_n1*var_rooms_n1)

    printf "rho sin dividir (Actividad 4) = %.6f\n", coseno_pr
    printf "rho dividiendo por n = %.6f\n", rho_dividiendo_n
    printf "rho dividiendo por (n-1) = %.6f\n", rho_dividiendo_n1
    printf "rho de Gretl (corr) = %.6f\n", corr(price,rooms)
end outfile

```

Enlace al guión: [S07-Prct-A-hprice2.inp](#)

Respuestas

1. Signos esperados y observados. Por argumentos económicos cabe esperar $\rho_{\text{price,rooms}} > 0$ (más habitaciones, casas más grandes o mejores, mayor precio) y $\rho_{\text{price,nox}} < 0$ (más contaminación, zona menos deseable, menor precio). El signo de $\rho_{\text{rooms,nox}}$ es menos evidente a priori; con estos datos resulta *negativo*, $\rho_{\text{rooms,nox}} = -0,3028$ (las zonas con más contaminación, más industriales o urbanas, tienden a tener viviendas algo más pequeñas), y de magnitud menor que los otros dos pares (0,6958 y $-0,4260$). Lo importante es formular la expectativa *antes* de mirar el número, y después contrastarla.

2. Covarianza vs. correlación para comparar fuerza de relación. La covarianza depende de las *unidades* de ambas variables (dólares, número de habitaciones, partes por cien millones de NOx), así que su magnitud no es comparable entre pares distintos: una covarianza “grande” puede deberse simplemente a que una variable se mide en una escala con números grandes. La correlación, al ser un coseno, es adimensional y está siempre en $[-1, 1]$; por eso sí permite comparar, de forma homogénea, qué par de variables está “más alineado” en sentido geométrico.

3. Invarianza de ρ al divisor. Porque ρ es un *cociente*: tanto el numerador (covarianza o “producto escalar”) como el denominador (producto de las dos desviaciones típicas o “normas”) llevan el mismo factor de escala (ya sea $1/n$, $1/(n-1)$, o ningún factor en absoluto), y ese factor se cancela exactamente en la división. Es la misma propiedad de homogeneidad de la norma y de invarianza de la correlación ante reescalados demostrada en la lección 5, aplicada aquí a un caso extremo: reescalar por *cualquier* constante positiva común no cambia un coseno.

4. Ángulo más cercano a 90° . Es el par con menor $|\rho|$: **rooms-nox**, cuyo ángulo es de $107,63^\circ$, frente a los $115,22^\circ$ de **price-nox** y los $45,91^\circ$ de **price-rooms**. Un ángulo cercano a 90° significa que los vectores en desviaciones son casi *ortogonales*: la variación de una variable, una vez descontada su media, apenas está alineada con la variación de la otra. Esto no implica que no exista *ninguna* relación entre ambas variables, sino específicamente que no hay relación *lineal* apreciable entre sus componentes centradas.

5. Forma de la nube vs. magnitud de ρ . Sí: cuanto mayor es $|\rho|$, más “alargada” y alineada en torno a una diagonal aparece la nube de puntos (con pendiente positiva si $\rho > 0$, negativa si $\rho < 0$); cuanto más cercano a 0, más “redonda” o dispersa en todas direcciones se ve la nube, sin una dirección diagonal dominante. Esta es la lectura visual exacta del ángulo entre los vectores centrados.