Sesión 7 (C) — Los momentos no bastan: misma media y desviación típica, formas distintas

Marcos Bujosa

Descripción de la práctica

En la práctica A de esta misma sesión comprobamos que $\rho = \cos\theta$. Ahora retrocedemos y planteamos una pregunta más elemental: *¿basta con conocer la media y la desviación típica de una variable para saber cómo se distribuyen sus datos?* La respuesta, como veremos, es *no*: dos conjuntos de datos pueden compartir exactamente esos dos números y, sin embargo, tener distribuciones radicalmente distintas: simétrica, asimétrica, bimodal, con un valor atípico. Esta práctica motiva por qué la estadística descriptiva necesita *más de dos herramientas*: además de media y desviación típica, también conviene analizar los histogramas, diagramas de caja, y estadísticos adicionales como la asimetría y la curtosis.

Narrativa: imaginamos cuatro empresas ficticias (TechNorte, Comercial Sur, Industrias Centro y Consultora Este) cuyo salario mensual (en euros) tiene, en las cuatro, la *misma* media y la *misma* desviación típica. ¿Tienen las cuatro plantillas "el mismo tipo" de estructura salarial?

Objetivo

1. Mostrar que estadísticos idénticos (o casi) no garantizan distribuciones parecidas.
2. Reforzar el uso de histograma y diagrama de caja como herramientas necesarias, no opcionales.
3. Introducir otros estadísticos descriptivos (asimetría, curtosis, mediana) que sí distinguen estas formas.

Nota técnica: en esta práctica los datos no son reales: cada serie se genera con un tipo de distribución propia y luego se *reescala* para forzar una media y una desviación típica comunes. El procedimiento exacto se explica, con el detalle geométrico completo, en el Apéndice final. El tamaño muestral (`n = $nobs`) es un parámetro (cuyo valor `$nobs` queda fijado inicialmente con `nulldata 40`): si al dibujar los histogramas la muestra pareciera escasa, basta con cambiar ese valor a 60 u 80 y volver a ejecutar el guión.

Comandos nuevos de esta práctica. Seguimos usando `nulldata`, `set seed`, `normal`, `uniform`, `series`, `scalar` y `printf` de las prácticas A y B. Lo nuevo:

`setobs 1 1 --cross-section` declara que las observaciones son de sección cruzada (sesión 4).

`D_bruto[1] = 15` cambia solo la primera componente de la serie; los corchetes seleccionan una observación.

`(uniform(0,1) <0.5)` una comparación aplicada a una serie produce otra serie de ceros y unos, con un uno donde se cumple la condición. Sirve para sortear a qué grupo pertenece cada empleado.

`sd(x)` desviación típica de la serie, con divisor $n-1$ (véase el Apéndice). `median`, `skewness` y `kurtosis` se presentan en la Actividad 5.

`summary --simple` versión reducida de `summary`: media, mediana, desviación típica, mínimo y máximo.

`boxplot A B C D` un diagrama de caja por variable, en la misma figura y con la misma escala. `freq` dibuja el histograma de una variable (sesión 4).

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

Actividad 1 - Generación de los datos

Generamos cuatro series de $n = 40$ observaciones con distribuciones muy distintas, pero forzando en las cuatro la misma media (μ_0) y la misma desviación típica (σ_0, medida con la función `sd` de Gretl; véase la nota sobre el divisor en el Apéndice). El truco (reescalado de un vector en desviaciones) usa exactamente las propiedades de invarianza y homogeneidad demostradas en la lección 5; el detalle completo se explica en el Apéndice.

Conjunto vacío de 40 observaciones, declarado de sección cruzada, semilla fija y tres escalares: `n`, el número de observaciones (`$nobs`), y los dos valores objetivo, la media `mu0` y la desviación típica `sigma0`. El texto que sigue a `#` es un comentario que Gretl ignora.

en línea de comandos:

```
nulldata 40
setobs 1 1 --cross-section
set seed 20250213

scalar n     = $nobs
scalar mu0   = 1800  # media común objetivo (euros)
scalar sigma0 = 250  # desviación típica común objetivo (euros)
```

Serie A: forma aproximadamente simétrica (TechNorte)

Tres pasos, que se repetirán en las cuatro series. `A_bruto`: 40 sorteos de una normal estándar, la forma que queremos. `A_z`: la serie estandarizada, restando su media y dividiendo por su desviación típica, con lo que pasa a tener media 0 y `sd` igual a 1. `A`: la serie final, con la media y la desviación típica objetivo, `mu0 + sigma0 * A_z`. Por último, `setinfo` le asigna descripción y nombre para los gráficos, como en la sesión 4.

en línea de comandos:

```
series A_bruto = normal(0,1)
series A_z     = (A_bruto - mean(A_bruto)) / sd(A_bruto)
series A       = mu0 + sigma0 * A_z
setinfo A -d "Salario mensual, TechNorte (forma simétrica)" -n "TechNorte"
```

Serie B: asimetría positiva (Comercial Sur)

Misma receta; cambia solo la forma de partida. `B_bruto` es la suma de los cuadrados de dos normales estándar independientes, una χ^2 con 2 grados de libertad, con cola larga hacia la derecha.

en línea de comandos:

```
series u1 = normal(0,1)
series u2 = normal(0,1)
series B_bruto = u1^2 + u2^2       # suma de cuadrados de normales: fuertemente asimétrica
series B_z     = (B_bruto - mean(B_bruto)) / sd(B_bruto)
series B       = mu0 + sigma0 * B_z
setinfo B -d "Salario mensual, Comercial Sur (asimetría positiva)" -n "Comercial Sur"
```

Serie C: bimodal (Industrias Centro)

La forma de partida es una mezcla de dos grupos. `grupo` vale 1 o 0 para cada empleado según un sorteo uniforme, con probabilidad 1/2 cada valor. `C_bruto` toma en cada fila un valor de una normal centrada en -3 si `grupo` vale 1, y de una normal centrada en 3 si vale 0: la fórmula `grupo*normal(-3,1) + (1-grupo)*normal(3,1)` anula uno de los dos sumandos en cada fila. Después, la misma estandarización y el mismo reescalado.

en línea de comandos:

```
series grupo   = (uniform(0,1) < 0.5)          # dos "categorías" de empleados
series C_bruto = grupo*normal(-3,1) + (1-grupo)*normal(3,1)
series C_z     = (C_bruto - mean(C_bruto)) / sd(C_bruto)
series C       = mu0 + sigma0 * C_z
setinfo C -d "Salario mensual, Industrias Centro (bimodal: dos categorías)" -n "Industrias Centro"
```

Serie D: con un valor atípico (Consultora Este)

Plantilla muy homogénea: normal de media 0 y desviación típica 0,3. La segunda línea sustituye la primera observación por 15, cincuenta desviaciones típicas por encima: el directivo. Después, la misma estandarización y el mismo reescalado, que reparten el efecto de ese valor entre la media y la `sd` comunes.

en línea de comandos:

```
series D_bruto = normal(0,0.3)   # plantilla muy homogénea...
D_bruto[1] = 15                  # ...salvo un directivo con un salario disparado
series D_z = (D_bruto - mean(D_bruto)) / sd(D_bruto)
series D   = mu0 + sigma0 * D_z
setinfo D -d "Salario mensual, Consultora Este (con un valor atípico)" -n "Consultora Este"
```

Actividad 2 - Estadísticos descriptivos clásicos

`summary` de las cuatro series. Con `--simple` muestra solo media, mediana, desviación típica, mínimo y máximo, una fila por serie.

en línea de comandos:

```
summary A B C D --simple
```

	Media	Mediana	D. T.	Mín	Máx
A	1800	1787	250,0	1222	2296
B	1800	1726	250,0	1610	3055
C	1800	1922	250,0	1405	2126
D	1800	1753	250,0	1713	3324

A la vista solo de estos números (media y desviación típica), ¿diría que las cuatro empresas tienen una estructura salarial parecida? Anote su respuesta antes de continuar.

Actividad 3 - Histogramas

- GUI: seleccione cada variable → clic derecho → `Gráficos` → `Distribución de frecuencias`. En la consola, `freq` dibuja el histograma de una variable (sesión 4); hace falta una orden por serie.

  o bien teclee en línea de comandos:

  ```
  freq A
  freq B
  freq C
  freq D
  ```

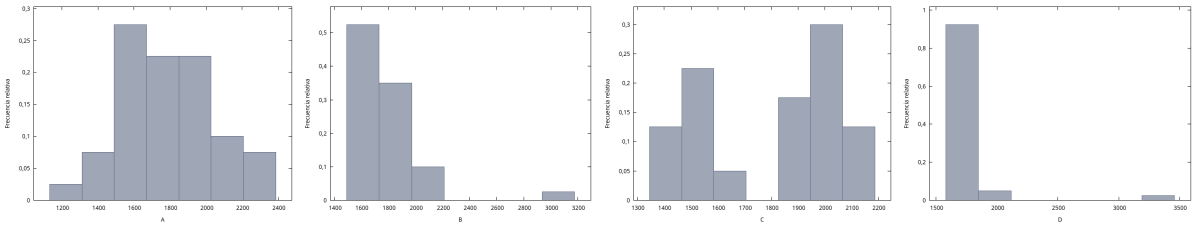


Figura 1: Histogramas.

¿Cambia su respuesta a la pregunta de la Actividad 2 al ver estos cuatro histogramas?

Actividad 4 - Diagramas de caja

`boxplot` con las cuatro series dibuja las cuatro cajas en una misma figura y con la misma escala vertical. En cada caja, la línea horizontal es la mediana, la cruz es la media y los puntos aislados son los valores atípicos.

en línea de comandos:

```
boxplot A B C D
```

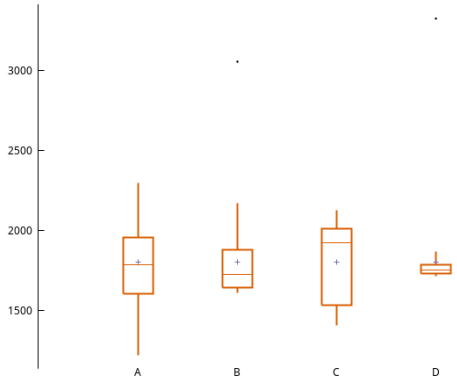


Figura 2: Diagramas de caja.

Compare las cuatro cajas: mediana, rango intercuartílico, longitud de los bigotes y presencia de puntos marcados como atípicos. ¿Qué revela el diagrama de caja que el histograma no mostraba con tanta claridad? ¿Y a la inversa?

Respuesta

El diagrama de caja muestra explícitamente, de forma directamente comparable entre las cuatro empresas y sobre una única escala vertical, varios resúmenes que el histograma deja implícitos: la *mediana*; el *rango intercuartílico*, una medida de dispersión robusta que sí difiere entre empresas, a diferencia de la desviación típica, idéntica por construcción en las cuatro series. Lo que hay que mirar aquí es la caja de Consultora Este: es muy estrecha (el 50 % central de los salarios cabe en unos 56 euros, frente a más de 230 en las otras tres empresas) y la media, marcada con una cruz, queda *fuera* de ella, por encima del tercer cuartil. Eso revela el efecto del directivo con salario extremo: un solo dato desplaza la media lejos de la mayoría de la plantilla, algo que un histograma con pocos intervalos podría ocultar en una barra casi invisible. Y, sobre todo, el *marcado explícito de valores atípicos* como puntos aislados fuera de los bigotes: en Consultora

Este, un único punto extremo se distingue de inmediato, mientras que en un histograma ese mismo dato podría pasar desapercibido como una barra solitaria de altura mínima en el extremo del eje. El boxplot es, en definitiva, el instrumento idóneo para comparar *varias* distribuciones simultáneamente sobre los mismos ejes.

Sin embargo, el diagrama de caja tiene una limitación precisamente donde el histograma es insustituible: la *forma global* de la distribución. El boxplot de Industrias Centro (cuya distribución es bimodal, con dos grupos de empleados bien separados y prácticamente ningún salario "intermedio") puede tener un aspecto ordinario (una caja, una mediana, unos bigotes) sin indicar en absoluto la existencia de dos picos separados; los cinco números que resume un boxplot (mínimo, Q_1, mediana, Q_3, máximo, más atípicos) no pueden codificar cuántas modas tiene una distribución. Solo el histograma, al mostrar la densidad de puntos en cada tramo del rango, revela sin ambigüedad los dos grupos separados por un hueco central. La lección general es que ambas herramientas son complementarias: el boxplot compara resúmenes de posición y dispersión entre grupos; el histograma muestra la forma que esos resúmenes, por sí solos, no pueden capturar.

Actividad 5 - Más allá de la media y la desviación típica

Calculemos, para las cuatro series, algunos estadísticos adicionales: la *mediana* (`median`), la *asimetría* (`skewness`) y la *curtosis* (`kurtosis`, curtosis *excedente* respecto a la normal, que vale 0). Son estadísticos vistos en la asignatura de estadística del cuatrimestre anterior.

Una tabla hecha con `printf`. La primera línea imprime la cabecera: un hueco `%-15s` (texto de quince caracteres, alineado a la izquierda) y cinco huecos `%10s` (diez caracteres, alineados a la derecha). Cada línea siguiente rellena una fila con el nombre de la empresa y cinco funciones aplicadas a su serie: `mean`, `median`, `sd`, `skewness` y `kurtosis`. Los anchos fijos hacen que las columnas queden alineadas.

en línea de comandos:

```
printf "%-15s %10s %10s %10s %10s %10s\n", "Empresa", "Media", "Mediana", "SD", "Asimetria", "Curtosis"
printf "%-15s %10.2f %10.2f %10.2f %10.4f %10.4f\n", "TechNorte",      mean(A), median(A), sd(A), skewness(A), kurtosis(A)
printf "%-15s %10.2f %10.2f %10.2f %10.4f %10.4f\n", "Comercial Sur",  mean(B), median(B), sd(B), skewness(B), kurtosis(B)
printf "%-15s %10.2f %10.2f %10.2f %10.4f %10.4f\n", "Ind. Centro",    mean(C), median(C), sd(C), skewness(C), kurtosis(C)
printf "%-15s %10.2f %10.2f %10.2f %10.4f %10.4f\n", "Consultora Este",mean(D), median(D), sd(D), skewness(D), kurtosis(D)
```

```
Empresa              Media    Mediana         SD  Asimetria   Curtosis
TechNorte          1800,00    1786,56     250,00     0,1190    -0,2722
Comercial Sur      1800,00    1726,48     250,00     3,3545    14,0124
Ind. Centro        1800,00    1922,45     250,00    -0,3539    -1,5767
Consultora Este    1800,00    1753,34     250,00     5,8738    33,3403
```

Observe que la asimetría y la curtosis *sí* distinguen numéricamente lo que media y sd no distinguían. Pero incluso con esta tabla ampliada, ningún número revela con claridad la *bimodalidad* de Industrias Centro: solo el gráfico la muestra sin ambigüedad.

Conviene subrayar la idea general: *asimetría*, *curtosis* y *mediana* mejoran claramente la descripción, pero siguen siendo *resúmenes escalares* de toda la distribución. Cada uno comprime los datos en un único número y, por tanto, inevitablemente pierde información sobre la forma completa. Por eso pueden distinguir bastante bien una cola larga o un atípico, pero no sustituyen a un gráfico cuando lo que queremos detectar es una estructura más global, por ejemplo dos grupos bien separados.

Actividad 6 - Síntesis

La estadística descriptiva es un *conjunto de herramientas complementarias* (medidas numéricas y gráficos) y no un único número: cada una responde a una pregunta distinta sobre los datos. Media y desviación típica resumen *posición* y *dispersión*; asimetría y curtosis dicen algo sobre la *forma*; pero solo el histograma y el diagrama de caja permiten "ver" patrones, como una bimodalidad, que ningún estadístico habitual resume bien en un solo número.

Cuando dispongamos de la recta de ajuste y del R^2 (lección 8), veremos que el mismo fenómeno puede ocurrir con *dos* variables a la vez y su recta de ajuste: es el célebre *cuarteto de Anscombe*, que reservamos para más adelante.

Apéndice - Cómo se han construido estos datos

Esta construcción es una aplicación directa de las propiedades demostradas en la lección 5 para la media y la desviación típica.

Dado cualquier vector $\boldsymbol{x}$ (con la forma que sea) con media $\mu_{\boldsymbol{x}}$ y desviación típica $\sigma_{\boldsymbol{x}} > 0$, definimos su versión *estandarizada*:

$$\boldsymbol{z} = \frac{\boldsymbol{x} - \mu_{\boldsymbol{x}}\mathbf{1}}{\sigma_{\boldsymbol{x}}}.$$

Por construcción, $\boldsymbol{z}$ tiene media 0 y desviación típica 1 (es el vector en desviaciones de $\boldsymbol{x}$, reescalado por su propia norma estadística). Esto es lo que hicimos en cada serie con `A_z`, `B_z`, `C_z`, `D_z`. Nótese que estandarizar *no cambia la forma* de la distribución: solo la traslada y la reescala; la asimetría o la bimodalidad de $\boldsymbol{x}$ se conservan intactas en $\boldsymbol{z}$.

> *Nota técnica sobre Gretl y el divisor.* En esta práctica usamos `sd` tanto para estandarizar como para verificar el resultado final. Por eso, *sea cual sea el convenio interno exacto de Gretl para esa función*,[1] la operación
>
> $$\boldsymbol{z} = \frac{\boldsymbol{x} - \mu_{\boldsymbol{x}}\mathbf{1}}{sd(\boldsymbol{x})}$$
>
> produce una serie con desviación típica 1 *según ese mismo convenio*, y al multiplicar después por `sigma0` obtenemos una serie con desviación típica `sigma0` *según ese mismo convenio*. Es decir: el truco fuerza exactamente la desviación típica objetivo en el *mismo sentido operativo* en que Gretl la mide. Esto no contradice la observación de la práctica B: allí comparábamos *dos convenios distintos* para la varianza (divisor n frente a $n-1$); aquí, en cambio, usamos el *mismo* convenio al normalizar y al reconstruir.

A continuación, reescalamos $\boldsymbol{z}$ a los valores objetivo μ_0 y σ_0:

$$\boldsymbol{y} = \mu_0\mathbf{1} + \sigma_0\,\boldsymbol{z}.$$

Por la *linealidad* de la media (lección 4: sumar una constante desplaza la media exactamente esa constante) y, para la sd, por su *invarianza* ante traslaciones y *homogeneidad* ante escala (lección 5), la media de $\boldsymbol{y}$ es μ_0; por las mismas propiedades aplicadas a la desviación típica, la `sd` de $\boldsymbol{y}$ es σ_0, con independencia de la forma de $\boldsymbol{x}$ de partida. Esto es lo que hace la línea `mu0 + sigma0*A_z` (y análogas): fuerza los dos primeros momentos sin alterar la forma.

Verifiquemos numéricamente que las cuatro series comparten, en efecto, media y sd (salvo el redondeo de coma flotante):

Cuatro `printf`: las medias y las `sd` de las cuatro series, y los dos valores objetivo, para compararlos.

en línea de comandos:

```
printf "\nVerificación: medias y sd deberían coincidir (salvo redondeo)\n"
printf "Media    -> A: %.6f   B: %.6f   C: %.6f   D: %.6f\n", mean(A), mean(B), mean(C), mean(D)
printf "SD       -> A: %.6f   B: %.6f   C: %.6f   D: %.6f\n", sd(A),   sd(B),   sd(C),   sd(D)
printf "(objetivo: mu0 = %.2f ,  sigma0 = %.2f)\n", mu0, sigma0
```

```
Verificación: medias y sd deberían coincidir (salvo redondeo)
Media    -> A: 1800,000000   B: 1800,000000   C: 1800,000000   D: 1800,000000
SD       -> A: 250,000000   B: 250,000000   C: 250,000000   D: 250,000000
(objetivo: mu0 = 1800,00 ,  sigma0 = 250,00)
```

[1] en concreto, `sd` divide por $n-1$, como se comprueba en la práctica B de esta misma sesión; pero el argumento que sigue no depende de ello.

Verifiquemos que la estandarización logra que las cuatro series tengan media cero y `sd` igual a uno (salvo el redondeo de coma flotante):

Lo mismo para las series estandarizadas `A_z`, `B_z`, `C_z` y `D_z`, que deben tener `sd` igual a 1 y media 0.

en línea de comandos:

```
printf "\nChequeo de la estandarización usada en Gretl\n"
printf "sd(A_z) = %.6f   sd(B_z) = %.6f   sd(C_z) = %.6f   sd(D_z) = %.6f\n", sd(A_z), sd(B_z), sd(C_z), sd(D_z)
printf "mean(A_z) = %.6f   mean(B_z) = %.6f   mean(C_z) = %.6f   mean(D_z) = %.6f\n", mean(A_z), mean(B_z), mean(C_z),
↪  mean(D_z)
```

```
Chequeo de la estandarización usada en Gretl
sd(A_z) = 1,000000   sd(B_z) = 1,000000   sd(C_z) = 1,000000   sd(D_z) = 1,000000
mean(A_z) = 0,000000   mean(B_z) = -0,000000   mean(C_z) = 0,000000   mean(D_z) = 0,000000
```

Lo único que *no* controla este procedimiento es la forma: la asimetría de $\boldsymbol{x}$ (o su bimodalidad, o su atípico) pasa intacta a $\boldsymbol{y}$, porque tanto la traslación como el reescalado por una constante positiva son transformaciones que *no alteran* la forma relativa de los datos. Es la misma idea que empleamos en el Apéndice de la práctica A para mostrar la invarianza de ρ ante el divisor, aplicada aquí de forma constructiva en lugar de solo verificatoria.

Preguntas de interpretación para la clase

1. ¿Qué estadístico (de los calculados en la Actividad 5) revela mejor la asimetría de Comercial Sur?
2. ¿Por qué ni la asimetría ni la curtosis bastan para detectar, con claridad, la bimodalidad de Industrias Centro?
3. Si un analista solo mirara la tabla de `summary` (media y sd) y nunca los gráficos, ¿qué conclusión errónea podría sacar sobre las cuatro empresas?
4. En Consultora Este, ¿qué estadístico, media o mediana, describe mejor "el salario típico" de un empleado cualquiera de esa empresa? ¿Por qué difieren tanto entre sí?
5. El procedimiento de generación (estandarizar y reescalar) fuerza la misma media y la misma sd en las cuatro series. ¿Por qué este mismo procedimiento *no puede* forzar, además, la misma asimetría o la misma forma?

Para profundizar:

- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley. (Origen del diagrama de caja y del énfasis en la visualización de datos.)
- Anscombe, F. J. (1973). "Graphs in Statistical Analysis". *The American Statistician*, 27(1), 17-21. (Mención breve: el mismo fenómeno con dos variables y su recta de ajuste, que veremos más adelante.)
- Cottrell, A. y Lucchetti, R. (2023). *Gretl User's Guide*. Funciones `skewness`, `kurtosis`, `median`.
- Véase la lección 5 para las propiedades de invarianza y homogeneidad usadas en el Apéndice.

Código completo de la práctica

```
# ----------------------------------------------------------
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# ----------------------------------------------------------

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
↪  directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#    DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
↪  trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

nulldata 40
setobs 1 1 --cross-section
set seed 20250213

scalar n     = $nobs
scalar mu0   = 1800  # media común objetivo (euros)
scalar sigma0 = 250  # desviación típica común objetivo (euros)

series A_bruto = normal(0,1)
series A_z     = (A_bruto - mean(A_bruto)) / sd(A_bruto)
series A       = mu0 + sigma0 * A_z
setinfo A -d "Salario mensual, TechNorte (forma simétrica)" -n "TechNorte"

series u1 = normal(0,1)
series u2 = normal(0,1)
series B_bruto = u1^2 + u2^2       # suma de cuadrados de normales: fuertemente asimétrica
series B_z     = (B_bruto - mean(B_bruto)) / sd(B_bruto)
series B       = mu0 + sigma0 * B_z
setinfo B -d "Salario mensual, Comercial Sur (asimetría positiva)" -n "Comercial Sur"

series grupo   = (uniform(0,1) < 0.5)          # dos "categorías" de empleados
series C_bruto = grupo*normal(-3,1) + (1-grupo)*normal(3,1)
series C_z     = (C_bruto - mean(C_bruto)) / sd(C_bruto)
series C       = mu0 + sigma0 * C_z
setinfo C -d "Salario mensual, Industrias Centro (bimodal: dos categorías)" -n "Industrias Centro"

series D_bruto = normal(0,0.3)   # plantilla muy homogénea...
D_bruto[1] = 15                  # ...salvo un directivo con un salario disparado
series D_z = (D_bruto - mean(D_bruto)) / sd(D_bruto)
series D   = mu0 + sigma0 * D_z
setinfo D -d "Salario mensual, Consultora Este (con un valor atípico)" -n "Consultora Este"

outfile --quiet estadisticos.txt
    summary A B C D --simple
end outfile

freq A --plot="histA.png"
freq B --plot="histB.png"
freq C --plot="histC.png"
freq D --plot="histD.png"

boxplot A B C D --output="boxplotABCD.png"

outfile --quiet tablaestadisticosadicionales.txt
```

```
    printf "%-15s %10s %10s %10s %10s %10s\n", "Empresa", "Media", "Mediana", "SD", "Asimetria", "Curtosis"
    printf "%-15s %10.2f %10.2f %10.2f %10.4f %10.4f\n", "TechNorte",      mean(A), median(A), sd(A),
    ↪  skewness(A), kurtosis(A)
    printf "%-15s %10.2f %10.2f %10.2f %10.4f %10.4f\n", "Comercial Sur",  mean(B), median(B), sd(B),
    ↪  skewness(B), kurtosis(B)
    printf "%-15s %10.2f %10.2f %10.2f %10.4f %10.4f\n", "Ind. Centro",    mean(C), median(C), sd(C),
    ↪  skewness(C), kurtosis(C)
    printf "%-15s %10.2f %10.2f %10.2f %10.4f %10.4f\n", "Consultora Este",mean(D), median(D), sd(D),
    ↪  skewness(D), kurtosis(D)
end outfile

outfile --quiet verificacionmomentos.txt
    printf "\nVerificación: medias y sd deberían coincidir (salvo redondeo)\n"
    printf "Media    -> A: %.6f   B: %.6f   C: %.6f   D: %.6f\n", mean(A), mean(B), mean(C), mean(D)
    printf "SD       -> A: %.6f   B: %.6f   C: %.6f   D: %.6f\n", sd(A),   sd(B),   sd(C),   sd(D)
    printf "(objetivo: mu0 = %.2f ,  sigma0 = %.2f)\n", mu0, sigma0
end outfile

outfile --quiet estandarizacioninterna.txt
    printf "\nChequeo de la estandarización usada en Gretl\n"
    printf "sd(A_z) = %.6f   sd(B_z) = %.6f   sd(C_z) = %.6f   sd(D_z) = %.6f\n", sd(A_z), sd(B_z),
    ↪  sd(C_z), sd(D_z)
    printf "mean(A_z) = %.6f   mean(B_z) = %.6f   mean(C_z) = %.6f   mean(D_z) = %.6f\n", mean(A_z),
    ↪  mean(B_z), mean(C_z), mean(D_z)
end outfile
```

Enlace al guión: S07-Prct-C-momentos-no-bastan.inp

Respuestas

1. ¿Qué estadístico revela mejor la asimetría de Comercial Sur? La *asimetría* (`skewness`), por definición: es el estadístico diseñado para capturar numéricamente el desequilibrio entre la cola izquierda y la derecha de una distribución. Un valor claramente positivo y alejado de 0 confirma la cola larga hacia la derecha que se ve en el histograma. La curtosis, en cambio, mide el "apuntamiento" o el peso de las colas en general, no la dirección del desequilibrio, así que no es el indicador más directo aquí.

2. ¿Por qué asimetría y curtosis no bastan para detectar la bimodalidad de Industrias Centro? Porque ambos son, igual que la media y la varianza, *momentos* (medidas que resumen toda la distribución en un único número mediante una suma). Un resumen numérico de este tipo puede ser prácticamente idéntico para una distribución con dos picos simétricos y separados y para una distribución con un único pico centrado: si los dos grupos están colocados simétricamente en torno a la media global, la asimetría puede salir cercana a 0 (parece "simétrica"), y la curtosis no fue diseñada para distinguir "un pico ancho" de "dos picos estrechos". La bimodalidad es una característica de la *forma completa* de la distribución, no capturable en un solo escalar: por eso hace falta el histograma, que muestra la densidad en cada zona del rango, no solo un resumen agregado.

3. Si un analista solo mirara `summary` sin gráficos, ¿qué conclusión errónea podría sacar? Podría concluir que las cuatro empresas tienen "el mismo tipo" de plantilla salarial (una estructura homogénea con un salario típico de 1800€ y una dispersión de 250€ alrededor de esa cifra), cuando en realidad una tiene una distribución razonablemente simétrica, otra está sesgada hacia salarios altos poco frecuentes, otra tiene en realidad *dos grupos* de empleados con salarios muy distintos entre sí (y ningún empleado con salario "intermedio"), y la última tiene una plantilla muy homogénea salvo un único directivo con un salario extremo. Decisiones de política salarial basadas solo en la media y la sd (p. ej., "subir un 5 % a todos") tendrían sentido muy distinto según el caso.

4. En Consultora Este, ¿media o mediana describe mejor "el salario típico"? ¿Por qué difieren? La *mediana* describe mucho mejor el salario típico: al ser un estadístico de *orden* (el valor central cuando se ordenan los datos), apenas se ve afectada por un único valor extremo. La media, en cambio, es una *suma* dividida por n, y el salario extremo del directivo la desplaza hacia arriba, de modo que la media puede terminar por encima de lo que gana la mayoría de la plantilla. La diferencia entre ambas (media >mediana, aquí de forma marcada) es en sí misma, sin mirar el histograma, un indicio de que hay al menos un valor atípico influyente hacia arriba.

5. ¿Por qué el procedimiento de generación no puede forzar también la misma asimetría o forma? Porque el procedimiento (estandarizar y reescalar: $\boldsymbol{y} = \mu_0\mathbf{1} + \sigma_0 \frac{\boldsymbol{x} - \mu_{\boldsymbol{x}}\mathbf{1}}{\sigma_{\boldsymbol{x}}}$) solo aplica dos tipos de transformación: una traslación (sumar una constante) y un cambio de escala (multiplicar por una constante positiva). Estas dos operaciones, por construcción, no alteran la forma *relativa* de los datos: si una distribución tiene una cola larga a la derecha, trasladarla o reescalarla no la vuelve simétrica ni le añade un segundo pico. Para cambiar la forma (asimetría, número de modas) haría falta una transformación distinta (no lineal, o que combinara varias fuentes de variación de manera distinta), que es lo que se hizo *antes* de estandarizar, al elegir cada distribución "en bruto" (normal, suma de cuadrados de normales, mezcla de dos normales, etc.).