

Sesión 14 (A) — Regresión múltiple con Gretl: precios de vivienda (Ramanathan)

Marcos Bujosa

Descripción de la práctica

Empezamos el bloque de regresión múltiple (lección 10) con el conjunto de datos reales más pequeño y manejable de todo el curso: 14 viviendas unifamiliares de University City (San Diego, California), tomado de Ramanathan (2002). Es un dataset de sección cruzada tan reducido que, si quisiera, podría casi reproducir a mano alguno de los cálculos; pero lo usaremos únicamente para lo que importa hoy: *aprender a leer* una regresión con más de un regresor, e interpretar sus parámetros.

Objetivo

1. Estimar por primera vez, con Gretl, una regresión con más de un regresor no constante.
2. Comparar el coeficiente de un regresor cuando se estima *solo* frente a cuando se estima *junto* a otro: la esencia del efecto parcial o *ceteris paribus* (lección 10).
3. Ampliar el modelo con un tercer regresor y observar cómo cambia (o no) la lectura de los anteriores.
4. Observar, sin todavía formalizarlo, que el R^2 no baja al añadir regresores (se formalizará, con el R^2 ajustado, en la práctica B de esta sesión).
5. Practicar la lectura de una salida de regresión múltiple sin extraer conclusiones causales injustificadas.
6. Ver cuánto cambia el ajuste al quitar una sola vivienda, y que no todas influyen igual: el primer indicio de que una estimación tiene una *dispersión*, que la lección 11 cuantificará.

Comandos nuevos de esta práctica. Seguimos usando `open`, `setinfo`, `summary`, `corr`, `gnuplot`, `printf` y los escalares (sesiones 4 y 7), y `ols` con la opción `--quiet` y sus accesorios `$coeff`, `$uhat` y `$rsq` (prácticas de la sesión 11). Lo nuevo:

`ols y const x2 x3` la misma orden de la sesión 11 con más regresores tras la constante. Cada nombre añadido es una columna más de la matriz de regresores $\mathbf{X}$ de la lección 10.

`smpl` restringe la muestra a las observaciones que cumplen una condición: `smpl obs ! 1 --restrict=` deja fuera la observación 1 (`obs` es la variable interna con el número de orden de cada observación). `smpl full` restablece la muestra completa.

`resid[12]` la duodécima componente de una serie (sesión 7).

Actividad 1 - Carga y exploración de los datos

- GUI: Archivo -> Abrir archivo de datos -> Archivo de muestra; en la pestaña Ramanathan, el fichero `data4-1` (Prices of single-family homes).

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

open carga el fichero de muestra **data4-1** (**--quiet** evita listar sus variables), como en las sesiones 4 y 11.

o bien teclee en línea de comandos:

```
open data4-1.gdt --quiet
```

Si lo consideramos conveniente podemos castellanizar las etiquetas de las variables para tener gráficos con las leyendas en español. Además, siempre conviene examinar los estadísticos descriptivos principales de las variables.

Cuatro **setinfo**, uno por variable, con la descripción (**-d**) y el nombre para los gráficos (**-n**), y un **summary --simple** con las cuatro variables (media, mediana, desviación típica, mínimo y máximo).

en línea de comandos:

```
setinfo price -d "Precio de la vivienda (miles de dólares)" -n "Precio (miles $)"
setinfo sqft -d "Superficie habitable (pies cuadrados)" -n "Superficie (sqft)"
setinfo bedrms -d "Número de dormitorios" -n "Dormitorios"
setinfo baths -d "Número de cuartos de baño" -n "Baños"

summary price sqft bedrms baths --simple
```

	Media	Mediana	D. T.	Mín	Máx
price	317,5	291,5	88,50	199,9	505,0
sqft	1911	1835	577,8	1065	3000
bedrms	3,643	4,000	0,4972	3,000	4,000
baths	2,357	2,250	0,4463	1,750	3,000

Son solo 14 observaciones: puede inspeccionarlas todas en una sola tabla con **print** y la opción **--byobs**, que muestra varias series en una tabla con una fila por observación (sesión 11):

```
print price sqft bedrms baths --byobs
```

	price	sqft	bedrms	baths
1	199,9	1065	3	1,75
2	228,0	1254	3	2,00
3	235,0	1300	3	2,00
4	285,0	1577	4	2,50
5	239,0	1600	3	2,00
6	293,0	1750	4	2,00
7	285,0	1800	4	2,75
8	365,0	1870	4	2,00
9	295,0	1935	4	2,50
10	290,0	1948	4	2,00
11	385,0	2254	4	3,00
12	505,0	2600	3	2,50
13	425,0	2800	4	3,00
14	415,0	3000	4	3,00

Un conjunto de datos tan pequeño no es representativo de ningún mercado real, pero sirve como primer ejemplo de regresión múltiple.

Actividad 2 - Recordatorio: la regresión simple **price~sqft**

Antes de añadir regresores, recordamos el punto de partida: la regresión simple ya vista en la lección 6.

`ols` estima por mínimos cuadrados el modelo cuyo regresando es la primera variable de la lista y cuyos regresores son las siguientes; `const` es la columna de unos. Es la misma orden de la sesión 11, y su salida se lee igual.

en línea de comandos:

```
ols price const sqft
```

Modelo 1: MCO, usando las observaciones 1-14

Variable dependiente: price

	coeficiente	Desv. típica	Estadístico t	valor p
const	52,3509	37,2855	1,404	0,1857
sqft	0,138750	0,0187329	7,407	8,20e-06 ***

Media de la vble. dep.	317,4929	D.T. de la vble. dep.	88,49816
Suma de cuad. residuos	18273,57	D.T. de la regresión	39,02304
R-cuadrado	0,820522	R-cuadrado corregido	0,805565
F(1, 12)	54,86051	Valor p (de F)	8,20e-06
Log-verosimilitud	-70,08421	Criterio de Akaike	144,1684
Criterio de Schwarz	145,4465	Crit. de Hannan-Quinn	144,0501

De dicha salida, ya podemos reconocer algunos de los resultados obtenidos:

- Los números de la columna bajo el nombre `coeficiente` son los valores estimados para los parámetros β_1 (`const`) y β_2 (`sqft`).
- El número a la derecha del nombre `Media de la vble. dep.` es μ_y donde y es el vector con los datos de los precios de las 14 viviendas unifamiliares.
- El número a la derecha del nombre `Suma de cuad. residuos` es SRC, es decir, $\|\hat{e}\|_e^2$.
- El número a la derecha del nombre `R-cuadrado` es el coeficiente de determinación R^2 del ajuste.

Veamos la recta de regresión correspondiente al ajuste MCO que hemos logrado:

`gnuplot` con el regresando y el regresor dibuja la nube de puntos y la recta ajustada (sesión 7). La opción `--output` guarda el gráfico en un fichero en lugar de abrir una ventana.

en línea de comandos:

```
gnuplot price sqft --output="price_sqft_simple.png"
```




Figura 1: Precio frente a superficie, con la recta ajustada (regresión simple).

Anote el valor de $\hat{\beta}_2$ (coeficiente de **sqft**) y de R^2 : serán su punto de referencia para todo lo que sigue.

Actividad 3 - Más regresiones: con **bedrms**, y con **sqft + bedrms**

Estimamos ahora **price** en función únicamente de **bedrms**, y a continuación en función de **sqft** y **bedrms** a la vez.

Antes de mirar el resultado: ¿qué signo espera para el coeficiente de **bedrms** en el modelo simple? ¿Y en el modelo con **sqft** incluido? ¿Espera que sea *el mismo número* en ambos casos?

Dos **ols** seguidos. El primero es una regresión simple. El segundo lleva dos regresores no constantes tras **const**: es la primera regresión múltiple de la práctica, y Gretl la estima con la misma orden, añadiendo un nombre más a la lista.

en línea de comandos:

```
ols price const bedrms
ols price const sqft bedrms
```

Modelo 2: MCO, usando las observaciones 1-14
Variable dependiente: price

	coeficiente	Desv. típica	Estadístico t	valor p
const	112,853	179,123	0,6300	0,5405
bedrms	56,1756	48,7511	1,152	0,2716
Media de la vble. dep.	317,4929	D.T. de la vble. dep.	88,49816	
Suma de cuad. residuos	91671,71	D.T. de la regresión	87,40314	
R-cuadrado	0,099625	R-cuadrado corregido	0,024594	
F(1, 12)	1,327777	Valor p (de F)	0,271640	
Log-verosimilitud	-81,37352	Criterio de Akaike	166,7470	
Criterio de Schwarz	168,0252	Crit. de Hannan-Quinn	166,6287	

Modelo 3: MCO, usando las observaciones 1-14
Variable dependiente: price

	coeficiente	Desv. típica	Estadístico t	valor p
const	121,179	80,1778	1,511	0,1589

sqft	0,148314	0,0212080	6,993	2,29e-05 ***
bedrms	-23,9106	24,6419	-0,9703	0,3527

Media de la vble. dep.	317,4929	D.T. de la vble. dep.	88,49816
Suma de cuad. residuos	16832,79	D.T. de la regresión	39,11846
R-cuadrado	0,834673	R-cuadrado corregido	0,804613
F(2, 11)	27,76736	Valor p (de F)	0,000050
Log-verosimilitud	-69,50933	Criterio de Akaike	145,0187
Criterio de Schwarz	146,9358	Crit. de Hannan-Quinn	144,8412

Lo que debe observar

Compare el coeficiente de **bedrms** en ambas regresiones: solo, vale +56,2 (mil dólares por dormitorio) con un R^2 de apenas 0,10; junto a **sqft**, pasa a -23,9, y el R^2 sube a 0,83, casi el mismo que tenía **sqft** sola. En la lección 10 vimos que cada $\hat{\beta}_j$, en un modelo con varios regresores, mide un *efecto parcial*: “el efecto promedio en **price** ante un dormitorio más, *manteniendo fija la superficie*”. Eso es una pregunta distinta de “el efecto promedio en **price** ante un dormitorio más, sin ninguna información adicional” (lo que mide el coeficiente del modelo simple). No tienen por qué coincidir, ni siquiera en signo: dos viviendas con la misma superficie pero distinto número de dormitorios reparten ese mismo espacio en habitaciones más pequeñas o más grandes, lo cual puede influir en el precio de forma diferente a como influye “más dormitorios sin más información sobre otras características de la vivienda”. Muchos dormitorios solo caben en viviendas grandes, así que cabe esperar una correlación positiva entre dormitorios y superficie en la muestra. Verifíquelo.

Comprobemos cuán correlacionados están los dos regresores. El comando **corr** imprime la correlación de las variables de la lista (sesión 7).

en línea de comandos:

```
corr sqft bedrms
```

```
corr(sqft, bedrms) = 0,46473046
Bajo la hipótesis nula de no correlación:
t(12) = 1,81814, con valor p a dos colas 0,0941
```

Actividad 4 - Añadimos baths

Ampliamos el modelo con otro regresor adicional: el número de cuartos de baño.

Un regresor más en la lista de **ols**: ahora **X** tiene cuatro columnas.

en línea de comandos:

```
ols price const sqft bedrms baths
```

Modelo 4: MCO, usando las observaciones 1-14
Variable dependiente: price

	coeficiente	Desv. típica	Estadístico t	valor p
-----	-----	-----	-----	-----
const	129,062	88,3033	1,462	0,1746
sqft	0,154800	0,0319404	4,847	0,0007 ***
bedrms	-21,5875	27,0293	-0,7987	0,4430
baths	-12,1928	43,2500	-0,2819	0,7838

Media de la vble. dep.	317,4929	D.T. de la vble. dep.	88,49816
Suma de cuad. residuos	16700,07	D.T. de la regresión	40,86572
R-cuadrado	0,835976	R-cuadrado corregido	0,786769
F(3, 10)	16,98894	Valor p (de F)	0,000299
Log-verosimilitud	-69,45391	Criterio de Akaike	146,9078

Criterio de Schwarz 149,4641 Crit. de Hannan-Quinn 146,6712

Sin considerar la constante, el valor p más alto fue el de la variable 4 (baths)

Compare de nuevo el coeficiente de **bedrms** (y ahora también el de **sqft**) con los obtenidos en la Actividad 3: apenas cambian ($-23,9 \rightarrow -21,6$ y $0,148 \rightarrow 0,155$). ¿Qué signo tiene el coeficiente de **baths**, $-12,2$, y le parece razonable? Si no le parece razonable, ¿cuál podría ser el motivo por el que el resultado obtenido es distinto de lo que usted esperaba?

Observe la matriz de correlaciones entre **sqft**, **bedrms** y **baths**. Con tres variables, **corr** devuelve la matriz simétrica de la sesión 7:

en línea de comandos:

```
corr sqft bedrms baths
```

Coeficientes de correlación, usando las observaciones 1 - 14

Valor crítico al 5% (a dos colas) = 0,5324 para n = 14

sqft	bedrms	baths
1,0000	0,4647	0,7873
	1,0000	0,5323
		1,0000

A la luz de los resultados, ¿qué signo esperaría ver para **baths** en la regresión lineal simple **ols price const baths**? **Verifique su intuición estimando el modelo.**

¿Cree que el valor estimado para **baths** se debe a la valoración de los baños en el mercado inmobiliario? ¿O a que realmente se está midiendo inadvertidamente otra cosa?

Actividad 5 - Síntesis: cuatro modelos, una tabla

Complete la tabla con los resultados de las cuatro regresiones estimadas en esta práctica.

Modelo	$\hat{\beta}_{\text{sqft}}$	$\hat{\beta}_{\text{bedrms}}$	$\hat{\beta}_{\text{baths}}$	R^2
price~sqft		—	—	
price~bedrms	—		—	
price~sqft+bedrms			—	
price~sqft+bedrms+baths				

Cuatro estimaciones seguidas con la opción **--quiet**, que evita imprimir la salida completa de cada una. Tras cada **ols** guardamos en un escalar el accesor **\$rsq**, el R^2 del último modelo estimado (sesión 11). Un accesor se refiere siempre al *último* modelo, por eso hay que guardarlo antes de estimar el siguiente. Los cuatro **printf** finales imprimen los cuatro valores juntos.

en línea de comandos, para obtener los cuatro R^2 en una sola ejecución:

```
ols price const sqft --quiet
scalar r2_1 = $rsq
ols price const bedrms --quiet
scalar r2_2 = $rsq
ols price const sqft bedrms --quiet
scalar r2_3 = $rsq
ols price const sqft bedrms baths --quiet
scalar r2_4 = $rsq

printf "R2 price-sqft          = %.4f\n", r2_1
printf "R2 price-bedrms       = %.4f\n", r2_2
printf "R2 price-sqft+bedrms   = %.4f\n", r2_3
printf "R2 price-sqft+bedrms+baths = %.4f\n", r2_4
```

```

R2 price-sqft          = 0,8205
R2 price-bedrms        = 0,0996
R2 price-sqft+bedrms   = 0,8347
R2 price-sqft+bedrms+baths = 0,8360

```

Observe el R^2 a medida que se añaden regresores: nunca *baja*. Es una propiedad algebraica de MCO, no de estos datos (lección 8), que discutiremos con detalle, junto con su corrección, el R^2 ajustado, en la práctica B de esta sesión.

Actividad 6 - ¿Cuánto depende el ajuste de las viviendas que nos han tocado?

Hasta aquí hemos cambiado el *modelo* y hemos visto cambiar los coeficientes. Ahora vamos a hacer justo lo contrario: mantener fijo el modelo y cambiar los *datos*. Concretamente, vamos a quitar una vivienda de las catorce y reestimar la misma regresión.

La pregunta es sencilla y conviene plantearse antes de ejecutar nada: *si una sola de estas catorce casas hubiera sido distinta, o sencillamente no estuviera en nuestra lista, ¿cambiaría mucho la recta que hemos ajustado?*

Gretl permite restringir la muestra con `smpl`. Desde la interfaz gráfica, lo natural es ir acumulando los ajustes en la *tabla de modelos* (menú Archivo ->Tabla de modelos, o el comando `modeltab add`); en un guion que se ejecuta por lotes, en cambio, resulta más cómodo guardar los coeficientes en escalares e imprimirlos juntos al final. Eso es lo que hace el código siguiente.

Estimamos el mismo modelo quitando, cada vez, una sola vivienda

Quitaremos siempre *una* vivienda, y elegiremos tres que se diferencian en dos rasgos distintos: dónde están dentro del rango de superficies, y a qué distancia quedan de la recta ajustada con las catorce. Anotamos ambas cosas junto a cada resultado, porque la comparación entre las tres filas es todo el contenido de la actividad.

El bloque se lee en cuatro tramos iguales. En el primero, `smpl full` asegura que están las 14 viviendas; se estima la recta y se guardan los dos coeficientes con `$coeff(const)` y `$coeff(sqft)`, los residuos con `$uhat` (la distancia de cada vivienda a la recta) y la media de `sqft`. En cada uno de los tres tramos siguientes, `smpl obs ! 1 --restrict=` deja fuera una observación (la 1, la 12 o la 14), se reestima y se guardan los dos coeficientes con nombres distintos. Antes de cada restricción se vuelve a `smpl full`, porque una restricción nueva se aplica sobre la muestra vigente y se acumularía con la anterior.

- GUI: Muestra ->Restringir, a partir de criterio con la condición `obs ! 1=` (y después `obs ! 12=` y `obs ! 14=`), estimar con Modelo ->Mínimos cuadrados ordinarios y, antes de la siguiente restricción, Muestra ->Recuperar el rango completo.

o bien teclee en línea de comandos:

```

smpl full                # las 14 viviendas
ols price const sqft --quiet
scalar a_todas = $coeff(const)
scalar b_todas = $coeff(sqft)
series resid    = $uhat    # distancia de cada vivienda a la recta
scalar media_sqft = mean(sqft)

smpl full
smpl obs != 1 --restrict --quiet # fuera la vivienda 1: la MAS PEQUEÑA
ols price const sqft --quiet
scalar a_s1 = $coeff(const)
scalar b_s1 = $coeff(sqft)

smpl full
smpl obs != 12 --restrict --quiet # fuera la 12: NO es extrema en tamaño
ols price const sqft --quiet
scalar a_s12 = $coeff(const)
scalar b_s12 = $coeff(sqft)

```

```

smpl full
smpl obs != 14 --restrict --quiet # fuera la 14: la MAS GRANDE
ols price const sqft --quiet
scalar a_s14 = $coeff(const)
scalar b_s14 = $coeff(sqft)

smpl full # recuperamos siempre la muestra completa

```

Una tabla con `printf`, como en la práctica C de la sesión 7 ([actividad 5 \(html\)](#)): una fila por estimación, con el valor de `sqft` y el residuo de la vivienda excluida (`sqft[1]` y `resid[1]` son sus primeras componentes; `[12]` y `[14]`, la duodécima y la decimocuarta) y los dos coeficientes. `%5.0f` es un número sin decimales en cinco caracteres; `%8.2f`, dos decimales en ocho (el residuo); `%10.3f` y `%10.4f`, tres y cuatro decimales en diez (la constante y la pendiente).

y ahora los comparamos:

```

printf "media de sqft en las 14 viviendas = %.1f\n\n", media_sqft
printf "se quita      sqft  residuo  constante  pendiente\n"
printf "-----\n"
printf "nadie (n=14)      -      -      %10.3f %10.4f\n", a_todas, b_todas
printf "obs 1 (n=13)      %5.0f %8.2f %10.3f %10.4f\n", sqft[1], resid[1], a_s1, b_s1
printf "obs 12 (n=13)     %5.0f %8.2f %10.3f %10.4f\n", sqft[12], resid[12], a_s12, b_s12
printf "obs 14 (n=13)     %5.0f %8.2f %10.3f %10.4f\n", sqft[14], resid[14], a_s14, b_s14

```

media de sqft en las 14 viviendas = 1910,9

se quita	sqft	residuo	constante	pendiente

nadie (n=14)	-	-	52,351	0,1388
obs 1 (n=13)	1065	-0,22	52,479	0,1387
obs 12 (n=13)	2600	91,90	78,380	0,1209
obs 14 (n=13)	3000	-53,60	18,962	0,1593

Lo que debe observar

Las tres viviendas que hemos ido quitando afectan al ajuste de tres maneras muy distintas, y esa es la lección:

- *La obs. 1* es la más pequeña de todas (1065 pies cuadrados, el mínimo de la muestra): está en el borde mismo del rango. Y sin embargo quitarla apenas altera el ajuste: la pendiente pasa de 0,1388 a 0,1387. Mire su residuo: -0,22. Esa vivienda está prácticamente *sobre* la recta.
- *La obs. 14* es la más grande (3000 pies cuadrados, el máximo): también está en el borde. Pero su residuo es -53,60, y quitarla cambia la pendiente de 0,1388 a 0,1593 y la constante de 52,351 a 18,962.
- *La obs. 12* (2600 pies cuadrados) *no* está en ningún extremo. Y aun así, con un residuo de +91,90, quitarla cambia la pendiente a 0,1209 y la constante a 78,380.

De donde se siguen tres conclusiones que conviene no confundir:

1. *No hemos cambiado el modelo.* La especificación es idéntica en las cuatro filas; lo único que cambia es qué viviendas entran en el cálculo. Toda la variación que vea procede exclusivamente de la muestra.
2. *No todas las observaciones pesan igual, y la posición no lo explica sola.* Estar en un extremo del rango de superficies no basta para desplazar la recta (la obs. 1 está en el extremo y no la desplaza), y no estar en un extremo no lo impide (la obs. 12 está en el interior y es de las que más alteran el ajuste). Lo que hace falta son *las dos cosas a la vez*: estar lejos del centro en el eje del regresor, y además quedar lejos de la recta. Volveremos sobre esta idea, con nombre propio (*apalancamiento* e *influencia*) y con una medida concreta, en el laboratorio integrador que cierra el curso.

3. Con $n = 14$ esto es muy visible; con $n = 506$ lo sería mucho menos. Esa sensibilidad a los datos es propia de las muestras pequeñas, con cualquier método.

Esta actividad no resuelve nada; deja una pregunta abierta. Hemos comprobado que el ajuste *cambia* cuando cambian los datos, pero no tenemos todavía ninguna forma de decir *cuánto* cambia, ni de anticiparlo antes de estimar. Para eso hace falta hablar de la variabilidad del estimador, y eso exige herramientas que aún no tenemos. Es lo que hará la lección 11: dar una fórmula para la dispersión de β_2 , y mostrar que en ella aparecen el número de observaciones y cuán dispersas están las superficies de las viviendas.

Preguntas de interpretación para la clase

1. ¿Por qué el coeficiente de `bedrms` puede cambiar de signo (o de magnitud) al pasar del modelo simple al modelo con `sqft` incluido, si en ambos casos usamos los mismos 14 datos?
2. ¿Tiene sentido interpretar el coeficiente de `sqft` en el modelo `price~sqft+bedrms+baths` como “el efecto de un pie cuadrado más, manteniendo todo lo demás igual”? ¿Y como “lo que causa” ese cambio de precio?
3. Con solo 14 observaciones, ¿qué cautela adicional debería tener a la hora de generalizar cualquier conclusión de esta práctica a “el mercado de la vivienda” en general?
4. ¿Por qué el R^2 no puede bajar nunca al añadir un regresor, sea cual sea ese regresor (incluso uno completamente irrelevante)?
5. Si tuviera que explicarle a alguien sin formación en econometría la diferencia entre “el efecto de una habitación más” y “el efecto de una habitación más, manteniendo fija la superficie”, ¿cómo lo diría con sus propias palabras?

Para profundizar:

- Véase la lección 10 ([lección 10](#)) para la notación matricial y el enunciado del efecto parcial, cuyo desarrollo con datos reales es el objeto de esta práctica.
- Ramanathan, R. (2002). *Introductory Econometrics with Applications*, 5.^a ed. (fuente original del dataset `data4-1`).
- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 3, sección 3.4 (interpretación *ceteris paribus*).

Código completo de la práctica

```
# -----
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# -----

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
↪ directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#   DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
↪ trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

open data4-1.gdt --quiet

outfile --quiet resumen.txt
    setinfo price -d "Precio de la vivienda (miles de dólares)" -n "Precio (miles $)"
    setinfo sqft -d "Superficie habitable (pies cuadrados)" -n "Superficie (sqft)"
    setinfo bedrms -d "Número de dormitorios" -n "Dormitorios"
    setinfo baths -d "Número de cuartos de baño" -n "Baños"

    summary price sqft bedrms baths --simple
end outfile

outfile --quiet vistazoDatos.txt
    print price sqft bedrms baths --byobs
end outfile

outfile --quiet OLS_Precio_Superficie.txt
    ols price const sqft
end outfile

gnuplot price sqft --output="price_sqft_simple.png"

outfile --quiet olsBedrms.txt
    ols price const bedrms
    ols price const sqft bedrms
end outfile

outfile --quiet corrSqftBedrms.txt
    corr sqft bedrms
end outfile

outfile --quiet olsBaths.txt
    ols price const sqft bedrms baths
end outfile

outfile --quiet corrTres.txt
    corr sqft bedrms baths
end outfile

outfile --quiet sintesisR2.txt
    ols price const sqft --quiet
    scalar r2_1 = $rsq
    ols price const bedrms --quiet
    scalar r2_2 = $rsq
    ols price const sqft bedrms --quiet
```

```

scalar r2_3 = $rsq
ols price const sqft bedrms baths --quiet
scalar r2_4 = $rsq

printf "R2 price~sqft           = %.4f\n", r2_1
printf "R2 price~bedrms        = %.4f\n", r2_2
printf "R2 price~sqft+bedrms   = %.4f\n", r2_3
printf "R2 price~sqft+bedrms+baths = %.4f\n", r2_4
end outfile

smpl full                      # las 14 viviendas
ols price const sqft --quiet
scalar a_todas = $coeff(const)
scalar b_todas = $coeff(sqft)
series resid   = $uhat          # distancia de cada vivienda a la recta
scalar media_sqft = mean(sqft)

smpl full
smpl obs != 1 --restrict --quiet # fuera la vivienda 1: la MAS PEQUEÑA
ols price const sqft --quiet
scalar a_s1 = $coeff(const)
scalar b_s1 = $coeff(sqft)

smpl full
smpl obs != 12 --restrict --quiet # fuera la 12: NO es extrema en tamaño
ols price const sqft --quiet
scalar a_s12 = $coeff(const)
scalar b_s12 = $coeff(sqft)

smpl full
smpl obs != 14 --restrict --quiet # fuera la 14: la MAS GRANDE
ols price const sqft --quiet
scalar a_s14 = $coeff(const)
scalar b_s14 = $coeff(sqft)

smpl full                      # recuperamos siempre la muestra completa
outfile --quiet submuestras.txt
printf "media de sqft en las 14 viviendas = %.1f\n\n", media_sqft
printf "se quita      sqft residuo  constante pendiente\n"
printf "-----\n"
printf "nadie (n=14)      -      -      %10.3f %10.4f\n", a_todas, b_todas
printf "obs 1 (n=13)      %5.0f %8.2f %10.3f %10.4f\n", sqft[1], resid[1], a_s1, b_s1
printf "obs 12 (n=13)     %5.0f %8.2f %10.3f %10.4f\n", sqft[12], resid[12], a_s12, b_s12
printf "obs 14 (n=13)     %5.0f %8.2f %10.3f %10.4f\n", sqft[14], resid[14], a_s14, b_s14
end outfile

```

Enlace al guión: [S14-Prc-A-ramanathan.inp](#)

Respuestas

1. ¿Por qué puede cambiar el coeficiente de `bedrms`? Porque en el modelo simple, el coeficiente de `bedrms` recoge *todo* lo que varía con el número de dormitorios, incluida la superficie (las casas con más dormitorios suelen tener también más superficie): recoge también lo que varía con la superficie, que el modelo simple no separa. En el modelo múltiple, al incluir `sqft` como regresor, el coeficiente de `bedrms` mide únicamente lo que aporta un dormitorio adicional *una vez fijada la superficie*: dos viviendas de igual tamaño, pero con distinto reparto en habitaciones. Ambos números difieren, incluso en signo, porque responden a preguntas distintas, aunque provengan de los mismos datos.
2. Interpretación del coeficiente de `sqft` en el modelo `price~sqft+bedrms+baths`. Sí cabe la lectura *ceteris paribus*: “manteniendo fijos `bedrms` y `baths`, un pie cuadrado adicional se asocia, en promedio, con ese cambio en el precio”. Lo que *no* cabe, sin más, es la lectura causal (“un pie cuadrado más *causa* ese cambio”): como se insistió en la lección 8 y en la lección 9 (“El puente”), la descomposición de

MCO es puramente algebraica y no certifica, por sí sola, ninguna relación de causa a efecto, sea cual sea el número de regresores. Aquí, además, con solo 14 observaciones, cualquier lectura, causal o no, debe tomarse con mucha cautela.

3. Cautela con solo 14 observaciones. Una muestra tan pequeña es extremadamente sensible a la presencia de una única vivienda atípica (un precio inusualmente alto o bajo, una combinación poco común de dormitorios y superficie) y ofrece muy poco margen para distinguir el efecto de `sqft` del de `bedrms` si ambas variables están, en esta muestra concreta, bastante correlacionadas entre sí. Generalizar cualquier coeficiente obtenido aquí a “el mercado de la vivienda” sin más matices sería, cuando menos, precipitado: 14 viviendas de un único barrio y un único año no permiten inferir nada sobre otros mercados o épocas.
4. ¿Por qué el R^2 nunca baja al añadir un regresor? Porque MCO elige siempre los coeficientes que minimizan la suma de residuos al cuadrado (SRC) dentro del subespacio disponible; al añadir un regresor, ese subespacio se amplía (contiene, como caso particular, la solución que ya teníamos antes de incluir el regresor nuevo), así que el mínimo de SRC en el subespacio ampliado nunca puede ser más grande que el mínimo anterior. Como $R^2 = 1 - \text{SRC}/\text{STC}$ y STC no cambia, R^2 no puede bajar. Esto es válido incluso si el regresor añadido no tiene ninguna relación real con la variable dependiente: es una propiedad puramente mecánica, no una señal de que el nuevo regresor “importe”. Si hubiéramos añadido como regresor adicional el número de hermanos del arquitecto que diseñó cada una de las casas, el R^2 probablemente aumentaría; lo que es seguro es que no disminuiría.
5. Explicar la diferencia sin jerga técnica. Una posible formulación: “si comparo, sin más, viviendas con distinto número de habitaciones, estoy comparando peras con manzanas, porque esas viviendas probablemente también difieren en su tamaño; en cambio, si comparo únicamente viviendas del mismo tamaño pero con distinto número de habitaciones, estoy aislando el efecto de repartir ese mismo espacio de una forma u otra”. Esa segunda comparación es lo que mide el coeficiente en el modelo con varios regresores a la vez.