

Sesión 14 (B) — Del R^2 al R^2 ajustado: coeficientes parciales en `hprice2`

Marcos Bujosa

Descripción de la práctica

Retomamos `hprice2`, ya usado en la práctica de regresión simple con datos reales, y damos el paso a la regresión *múltiple*: primero con dos regresores (`rooms` y `nox` a la vez), y después con un tercero (`stratio`, la proporción alumnos/profesor de cada zona). El hilo conductor es doble: por un lado, observar cómo cambia el coeficiente de `rooms` al pasar del modelo simple al múltiple (efecto parcial, lección 10); por otro, comprobar con datos reales una propiedad algebraica de MCO anunciada en la lección 8 —el R^2 nunca disminuye al añadir un regresor— y ver por qué esto exige corregirlo con el R^2 *ajustado* ($\bar{R}^2$), que sí puede bajar.

Objetivo

1. Estimar un modelo con dos regresores no constantes (`rooms`, `nox`) y comparar sus coeficientes con los de las regresiones simples ya conocidas.
2. Ampliar el modelo con un tercer regresor (`stratio`) e interpretar su signo.
3. Verificar con datos reales que R^2 nunca disminuye al añadir regresores, sea cual sea su aporte real.
4. Calcular $\bar{R}^2$ “a mano” y contrastarlo con el que reporta Gretl, entendiendo por qué $\bar{R}^2$ sí puede bajar.
5. Practicar, una vez más, la lectura *ceteris paribus* de los coeficientes sin caer en lenguaje causal.

Actividad 1 - Reapertura de `hprice2` y etiquetas

en línea de comandos:

```
open hprice2.gdt --quiet
setinfo price -d "Precio mediano de la vivienda ($)" -n "Precio ($)"
setinfo rooms -d "Número medio de habitaciones" -n "Habitaciones"
setinfo nox -d "Concentración de óxidos de nitrógeno" -n "Contaminación (NOx)"
setinfo stratio -d "Ratio alumnos/profesor en la zona" -n "Ratio alumnos/profesor"

summary price rooms nox stratio
```

Recuerde de la práctica anterior que `rooms` y `nox` ya se usaron por separado en dos regresiones simples: retomamos aquí esos mismos coeficientes como punto de comparación.

Actividad 2 - De dos regresores a tres: `price~rooms+nox`

Estimamos el modelo con ambos regresores a la vez, y recordamos (reestimándolas aquí mismo, para tener los números a mano) las dos regresiones simples correspondientes.

Antes de mirar el resultado: ¿espera que el coeficiente de `rooms` sea muy distinto en la regresión simple y en la múltiple? ¿Y el de `nox`?

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

en línea de comandos:

```
ols price const rooms
ols price const nox
ols price const rooms nox
```

Lo que debe observar: compare $\hat{\beta}_{\text{rooms}}$ en `price~rooms` frente a `price~rooms+nox`, y $\hat{\beta}_{\text{nox}}$ en `price~nox` frente a `price~rooms+nox`.

Modelo 1: MCO, usando las observaciones 1-506
Variable dependiente: price

	coeficiente	Desv. típica	Estadístico t	valor p
const	-34796,2	2651,53	-13,12	4,74e-34 ***
rooms	9119,55	419,339	21,75	1,87e-74 ***
Media de la vble. dep.	22511,51	D.T. de la vble. dep.	9208,856	
Suma de cuad. residuos	2,21e+10	D.T. de la regresión	6620,865	
R-cuadrado	0,484110	R-cuadrado corregido	0,483086	
F(1, 504)	472,9521	Valor p (de F)	1,87e-74	
Log-verosimilitud	-5168,759	Criterio de Akaike	10341,52	
Criterio de Schwarz	10349,97	Crit. de Hannan-Quinn	10344,83	

Modelo 2: MCO, usando las observaciones 1-506
Variable dependiente: price

	coeficiente	Desv. típica	Estadístico t	valor p
const	41307,8	1816,18	22,74	2,53e-79 ***
nox	-3386,85	320,362	-10,57	9,93e-24 ***
Media de la vble. dep.	22511,51	D.T. de la vble. dep.	9208,856	
Suma de cuad. residuos	3,51e+10	D.T. de la regresión	8339,566	
R-cuadrado	0,181508	R-cuadrado corregido	0,179884	
F(1, 504)	111,7662	Valor p (de F)	9,93e-24	
Log-verosimilitud	-5285,537	Criterio de Akaike	10575,07	
Criterio de Schwarz	10583,53	Crit. de Hannan-Quinn	10578,39	

Modelo 3: MCO, usando las observaciones 1-506
Variable dependiente: price

	coeficiente	Desv. típica	Estadístico t	valor p
const	-18423,4	3346,66	-5,505	5,89e-08 ***
rooms	8178,56	418,076	19,56	8,62e-64 ***
nox	-1884,68	253,573	-7,432	4,62e-13 ***
Media de la vble. dep.	22511,51	D.T. de la vble. dep.	9208,856	
Suma de cuad. residuos	1,99e+10	D.T. de la regresión	6290,987	
R-cuadrado	0,535161	R-cuadrado corregido	0,533312	
F(2, 503)	289,5472	Valor p (de F)	2,12e-84	
Log-verosimilitud	-5142,396	Criterio de Akaike	10290,79	
Criterio de Schwarz	10303,47	Crit. de Hannan-Quinn	10295,77	

En este caso, a diferencia de lo que ocurría con `bedrms` en la práctica de Ramanathan, los coeficientes no cambian de forma tan drástica: esto sugiere (aunque no lo demuestra) que `rooms` y `nox` no están tan fuertemente correlacionadas entre sí como lo estaban `sqft` y `bedrms`. Mire la correlación entre ambas variables.

Actividad 3 - Un tercer regresor: stratio

Añadimos el ratio alumnos/profesor de la zona, una variable que cabe esperar relacionada negativamente con el precio (zonas con colegios más masificados, en principio menos atractivas).

en línea de comandos:

```
ols price const rooms nox stratio
```

Antes de mirar el resultado: ¿qué signo espera para el coeficiente de **stratio**? Contraste su expectativa con lo obtenido, y compare de nuevo los coeficientes de **rooms** y **nox** con los de la Actividad 2: ¿cambian mucho al incorporar **stratio**?

Actividad 4 - R^2 nunca disminuye: los cuatro modelos a la vez

Reunimos los cuatro modelos ya estimados (dos simples, dos múltiples) y comparamos su R^2 .

en línea de comandos:

```
ols price const rooms --quiet
scalar r2_rooms = $rsq

ols price const nox --quiet
scalar r2_nox = $rsq

ols price const rooms nox --quiet
scalar r2_rooms_nox = $rsq

ols price const rooms nox stratio --quiet
scalar r2_todos = $rsq

printf "R2 price-rooms          = %.4f\n", r2_rooms
printf "R2 price-nox           = %.4f\n", r2_nox
printf "R2 price-rooms+nox      = %.4f\n", r2_rooms_nox
printf "R2 price-rooms+nox+stratio = %.4f\n", r2_todos
```

```
R2 price-rooms          = 0,4841
R2 price-nox           = 0,1815
R2 price-rooms+nox      = 0,5352
R2 price-rooms+nox+stratio = 0,6005
```

Observe que R^2 del modelo con tres regresores no constantes es, como mínimo, igual al de cualquiera de los modelos que “contiene” (**price-rooms+nox** y, transitivamente, los dos simples). Esto no es una casualidad de estos datos: es la propiedad puramente mecánica de MCO anunciada en la lección 8 (“un R^2 alto no certifica nada por sí solo”, y en particular, *nunca baja* al añadir un regresor, aporte este lo que aporte).

Actividad 5 - Del R^2 al R^2 ajustado

Si R^2 nunca baja, ¿cómo distinguir un regresor que de verdad mejora el modelo de uno que solo lo “infla” artificialmente? Gretl reporta el R^2 con **\$rsq**, pero no permite recuperar el R^2 *ajustado*, así que lo vamos a recalcular a mano (véase la sección [Apéndice - De dónde sale la fórmula del \$R^2\$ ajustado](#)).

en línea de comandos:

```
ols price const rooms nox --quiet
scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
printf "Modelo price-rooms+nox\n"
printf "  R2          = %.4f\n", $rsq
printf "  R2 ajustado = %.4f\n", Rbarsq

ols price const rooms nox stratio --quiet
scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
printf "Modelo price-rooms+nox+stratio\n"
```

```
printf " R2          = %.4f\n", $rsq
printf " R2 ajustado = %.4f\n", Rbarsq
```

```
Modelo price-rooms+nox
R2          = 0,5352
R2 ajustado = 0,5333
Modelo price-rooms+nox+stratio
R2          = 0,6005
R2 ajustado = 0,5981
```

Compare cuánto sube R^2 y cuánto sube (o no) $\bar{R}^2$ al pasar de dos a tres regresores. Si **stratio** aportara muy poco, $\bar{R}^2$ podría incluso bajar al incluirla, mientras que R^2 jamás lo haría (por ejemplo, compare el ajuste con **rooms** + **proptax** (habitaciones más impuestos) con el ajuste si, además, añade **radial** (acceso a las autopistas)).

El apéndice siguiente explica de dónde sale exactamente la fórmula de $\bar{R}^2$ y por qué tiene esa propiedad.

Apéndice - De dónde sale la fórmula del R^2 ajustado

Recordemos (lección 8) que $R^2 = 1 - \text{SRC}/\text{STC}$, con $\text{STC} = \sum_i (y_i - \mu_{\mathbf{y}})^2$ y $\text{SRC} = \sum_i \hat{e}_i^2$. La idea del R^2 ajustado es sustituir, en ese cociente, cada suma de cuadrados por su *cuasivarianza* correspondiente —es decir, dividir cada una por sus *grados de libertad*, no por el número de observaciones—:

$$\bar{R}^2 = 1 - \frac{\text{SRC}/(n-k)}{\text{STC}/(n-1)},$$

donde k es el número *total* de regresores del modelo (incluida la constante; convención fijada en la lección 10) y $n-k$ son los grados de libertad de los residuos (k parámetros “beta” estimados). El denominador $\text{STC}/(n-1)$ es la cuasivarianza de $\mathbf{y}$: el estimador insesgado de la varianza de la variable Y del modelo teórico.¹ El numerador $\text{SRC}/(n-k)$ es la cuasivarianza de $\hat{\mathbf{e}}$: el estimador insesgado de la varianza de las perturbaciones U del modelo teórico.

Operando algebraicamente sobre esta definición se obtiene una expresión equivalente, más cómoda para el cálculo manual a partir de un R^2 ya conocido:

$$\bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-k}.$$

Por qué R^2 nunca baja pero $\bar{R}^2$ sí puede bajar: pues porque al añadir nuevos regresores, SRC nunca aumenta. El motivo es que SRC es el cuadrado de la distancia entre el vector de datos $\mathbf{y}$ y la combinación lineal de los regresores que está más cerca de $\mathbf{y}$. Al añadir nuevos regresores sin quitar ninguno de los anteriores, usando solo los originales nos podemos acercar tanto como antes (así que la distancia mínima no puede ser mayor). Pero es que, como ahora hay nuevas combinaciones lineales posibles, podría ocurrir que alguna estuviera más cerca de $\mathbf{y}$ de lo que antes nos podíamos acercar. Así que $R^2 = 1 - \text{SRC}/\text{STC}$ nunca baja... pero sí puede subir.

Sin embargo, en el *coeficiente de determinación ajustado* $\bar{R}^2$ hay *dos* efectos en juego: SRC baja (o se mantiene), lo que empuja $\bar{R}^2$ hacia arriba, pero k sube en una unidad, lo que reduce $n-k$ y por tanto agranda el cociente $\text{SRC}/(n-k)$, empujando $\bar{R}^2$ hacia abajo. Si el regresor añadido aporta poco (reduce muy poco SRC), el segundo efecto puede dominar al primero, y $\bar{R}^2$ baja pese a que R^2 no pueda hacerlo.

Verifiquemos que las dos fórmulas arrojan el mismo resultado:

en línea de comandos:

¹las propiedad de *insesgades* que ya conoce del curso de estadística y probabilidad, y que abordaremos en la próxima lección teórica.

```

ols price const rooms nox stratio --quiet
scalar n_obs = $nobs
scalar k_reg = $ncoeff

scalar Rbarsq_orig = 1 - ( $ess/($nobs-$ncoeff) )/( sst(price)/($nobs-1) )
scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)

printf "n = %d, k = %d (incluida la constante)\n", n_obs, k_reg
printf "R2 ajustado (formula original: 1-(SRC/(n-k))/(STC/(n-1)) ) = %.6f\n", Rbarsq_orig
printf "R2 ajustado (formula reducida: 1-(1-R2)(n-1)/(n-k)) = %.6f\n", Rbarsq

```

```

n = 506, k = 4 (incluida la constante)
R2 ajustado (formula original: 1-(SRC/(n-k))/(STC/(n-1)) ) = 0,598133
R2 ajustado (formula reducida: 1-(1-R2)(n-1)/(n-k)) = 0,598133

```

Preguntas de interpretación para la clase

1. ¿Por qué los coeficientes de **rooms** y **nox** cambian relativamente poco entre el modelo simple y el múltiple, a diferencia de lo que ocurría con **bedrms** en la práctica de Ramanathan?
2. ¿Cómo interpreta el signo obtenido para **stratio**? ¿Es coherente con lo que cabría esperar económicamente?
3. Explique, sin usar la fórmula, por qué R^2 no puede bajar nunca al añadir un regresor, mientras que $\bar{R}^2$ sí puede hacerlo.
4. Si al añadir **stratio** el R^2 ajustado hubiera bajado ligeramente, ¿qué le diría eso sobre el aporte de esa variable al modelo?
5. ¿Diría que el R^2 ajustado “certifica” que un modelo es mejor que otro, en el mismo sentido en que la lección 8 advertía que un R^2 alto no certifica una relación causal?

Para profundizar:

- Véanse las lecciones [lecciones 8](#) y [10](#) para la propiedad mecánica de R^2 y la interpretación del efecto parcial.
- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 6, sección 6.3 (R^2 ajustado).

Código completo de la práctica

```
# -----
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# -----

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
↳ directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#   DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
↳ trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

open hprice2.gdt --quiet
setinfo price -d "Precio mediano de la vivienda ($)" -n "Precio ($)"
setinfo rooms -d "Número medio de habitaciones" -n "Habitaciones"
setinfo nox -d "Concentración de óxidos de nitrógeno" -n "Contaminación (NOx)"
setinfo stratio -d "Ratio alumnos/profesor en la zona" -n "Ratio alumnos/profesor"

summary price rooms nox stratio

outfile --quiet Ols_rooms_nox_simple_y_conjunto.txt
    ols price const rooms
    ols price const nox
    ols price const rooms nox
end outfile

ols price const rooms nox stratio

outfile --quiet comparacionR2cuatroModelos.txt
    ols price const rooms --quiet
    scalar r2_rooms = $rsq

    ols price const nox --quiet
    scalar r2_nox = $rsq

    ols price const rooms nox --quiet
    scalar r2_rooms_nox = $rsq

    ols price const rooms nox stratio --quiet
    scalar r2_todos = $rsq

    printf "R2 price~rooms          = %.4f\n", r2_rooms
    printf "R2 price~nox          = %.4f\n", r2_nox
    printf "R2 price~rooms+nox        = %.4f\n", r2_rooms_nox
    printf "R2 price~rooms+nox+stratio = %.4f\n", r2_todos
end outfile

outfile --quiet r2AjustadoCuatroModelos.txt
    ols price const rooms nox --quiet
    scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
    printf "Modelo price~rooms+nox\n"
    printf "  R2          = %.4f\n", $rsq
    printf "  R2 ajustado = %.4f\n", Rbarsq

    ols price const rooms nox stratio --quiet
    scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
```

```

    printf "Modelo price~rooms+nox+stratio\n"
    printf "  R2          = %.4f\n", $rsq
    printf "  R2 ajustado = %.4f\n", Rbarsq
end outfile

outfile --quiet verificacionFormulaR2ajustado.txt
    ols price const rooms nox stratio --quiet
    scalar n_obs = $nobs
    scalar k_reg = $ncoeff

    scalar Rbarsq_orig = 1 - ( $ess/($nobs-$ncoeff) )/( sst(price)/($nobs-1) )
    scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)

    printf "n = %d,  k = %d (incluida la constante)\n", n_obs, k_reg
    printf "R2 ajustado (formula original: 1-(SRC/(n-k))/(STC/(n-1)) ) = %.6f\n", Rbarsq_orig
    printf "R2 ajustado (formula reducida: 1-(1-R2)(n-1)/(n-k)) = %.6f\n", Rbarsq
end outfile

```

Enlace al guión: [S14-Prct-B-hprice2-r2ajustado.inp](#)

Respuestas

1. ¿Por qué **rooms** y **nox** cambian poco, a diferencia de **bedrms**? Porque el cambio de un coeficiente al pasar del modelo simple al múltiple depende de cuánto esté correlacionado el regresor añadido con el que ya estaba presente. En la práctica de Ramanathan, **sqft** y **bedrms** estaban fuertemente relacionadas (las casas con más dormitorios suelen ser grandes), así que incluir una alteraba mucho la lectura de la otra. Si **rooms** y **nox** están menos correlacionadas entre sí en esta muestra, cada coeficiente ya “capta” en el modelo simple gran parte de lo que va a decir en el modelo múltiple, y el cambio es más discreto.
2. Interpretación del signo de **stratio**. Un coeficiente negativo es coherente con la intuición: zonas con una proporción más alta de alumnos por profesor (colegios más masificados, en principio de peor calidad percibida) tienden a tener viviendas más baratas, manteniendo fijas las habitaciones y la contaminación. Como siempre, esta es una lectura *ceteris paribus*, no necesariamente causal: podría haber otros factores (nivel de renta de la zona, inversión pública) que expliquen tanto el ratio alumnos/profesor como el precio.
3. Por qué R^2 no baja nunca y $\bar{R}^2$ sí puede bajar (sin fórmula). Añadir un regresor nunca puede empeorar el mejor ajuste posible: MCO siempre puede, como mínimo, “ignorar” el regresor nuevo (darle coeficiente cero) y quedarse exactamente igual que antes; en la práctica, suele aprovechar algo de esa dirección extra para reducir un poco más los residuos. Por eso R^2 nunca baja. Pero $\bar{R}^2$ además “cobra un precio” por cada regresor añadido —descuenta un grado de libertad (diferencia entre n y k)—, así que si el regresor nuevo casi no reduce los residuos, ese “precio” puede pesar más que la mejora conseguida, y $\bar{R}^2$ se reduce.
4. Si $\bar{R}^2$ hubiera bajado al añadir **stratio**. Eso indicaría que la reducción de residuos lograda por **stratio** es tan pequeña que no compensa el “coste” de estimar un parámetro adicional: una señal de que el aumento de complejidad del modelo, en términos de parsimonia, no compensa la pobre aportación de ese regresor en el ajuste del modelo.
5. ¿Certifica el R^2 ajustado que un modelo es mejor? No, en el mismo sentido en que la lección 8 advertía sobre R^2 : un $\bar{R}^2$ más alto es un indicio a favor de un modelo frente a otro en términos de ajuste penalizado por complejidad, pero no certifica que la especificación sea correcta, que los regresores incluidos sean los relevantes desde un punto de vista teórico, ni que exista ninguna relación causal. Es una herramienta de comparación entre modelos alternativos, no un veredicto definitivo sobre la validez de ninguno de ellos —la elección de qué variables incluir debe seguir estando guiada, en primer lugar, por la teoría económica, no solo por qué estadístico sube o baja.