Sesión 14 (B) — Del R^2 al R^2 ajustado: coeficientes parciales en hprice2

Marcos Bujosa

Descripción de la práctica

Retomamos `hprice2`, ya usado en la práctica B de la sesión 11, y damos el paso a la regresión *múltiple*: primero con dos regresores (`rooms` y `nox` a la vez), y después con un tercero (`stratio`, la proporción alumnos/profesor de cada zona). El hilo conductor es doble: por un lado, observar cómo cambia el coeficiente de `rooms` al pasar del modelo simple al múltiple (efecto parcial, lección 10); por otro, comprobar con datos reales una propiedad algebraica de MCO anunciada en la lección 8 (el R^2 nunca disminuye al añadir un regresor) y ver por qué esto exige corregirlo con el R^2 *ajustado* ($\bar{R}^2$), que sí puede bajar.

Objetivo

1. Estimar un modelo con dos regresores no constantes (`rooms`, `nox`) y comparar sus coeficientes con los de las regresiones simples ya conocidas.
2. Ampliar el modelo con un tercer regresor (`stratio`) e interpretar su signo.
3. Verificar con datos reales que R^2 nunca disminuye al añadir regresores, sea cual sea su aporte real.
4. Calcular $\bar{R}^2$ "a mano" y contrastarlo con el que reporta Gretl, entendiendo por qué $\bar{R}^2$ sí puede bajar.
5. Practicar, una vez más, la lectura *ceteris paribus* de los coeficientes sin caer en lenguaje causal.

Comandos nuevos de esta práctica. Casi todo es conocido: `open`, `setinfo`, `summary` (sesión 4), `printf` y los escalares (sesión 7), `ols` con varios regresores y la opción `--quiet`, `corr` y el accesor `$rsq` (sesión 11 y práctica A de hoy). Lo nuevo son dos accesores del último modelo estimado y una función:

`$ncoeff` el número de coeficientes estimados, es decir, k contando la constante. `$nobs` es el número de observaciones (sesión 7).

`$ess` la suma de los cuadrados de los residuos del último modelo, SRC.

`sst(y)` la suma de los cuadrados de las desviaciones de `y` respecto a su media, STC.

Actividad 1 - Reapertura de hprice2 y etiquetas

`open`, cuatro `setinfo` con la descripción y el nombre para los gráficos, y un `summary` de las cuatro variables, como en la sesión 4. `stratio` es nueva en el curso, por eso la etiquetamos.

en línea de comandos:

```
open hprice2.gdt --quiet
```

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

```
setinfo price   -d "Precio mediano de la vivienda ($)" -n "Precio ($)"
setinfo rooms   -d "Número medio de habitaciones" -n "Habitaciones"
setinfo nox     -d "Concentración de óxidos de nitrógeno" -n "Contaminación (NOx)"
setinfo stratio -d "Ratio alumnos/profesor en la zona" -n "Ratio alumnos/profesor"

summary price rooms nox stratio
```

```
                    Media        Mediana         Mínimo         Máximo
price               22512          21200         5000,0          50001
rooms              6,2841         6,2100         3,5600         8,7800
nox                5,5498         5,3800         3,8500         8,7100
stratio            18,459         19,100         12,600         22,000

            Desv. Típica.           C.V.      AsimetríaExc. de curtosis
price            9208,9        0,40907         1,1063         1,4594
rooms           0,70259        0,11181        0,40281         1,8595
nox              1,1584        0,20873        0,72258      -0,080785
stratio          2,1658        0,11733       -0,80439       -0,29188

                Perc. 5%      Perc. 95%        Rango IQObservaciones ausentes
price              10200          43695         8199,0              0
rooms             5,3000         7,6295        0,74250              0
nox               4,0900         7,4000         1,7500              0
stratio           14,700         21,000         2,8250              0
```

Recuerde de la práctica de regresión simple con datos reales de la sesión 11 (actividad 2 (html) y actividad 3 (html)) *que* `rooms` *y* `nox` *ya se usaron por separado en dos regresiones simples: retomamos aquí esos mismos coeficientes como punto de comparación.*

Actividad 2 - Dos regresores no constantes a la vez: price~rooms+nox

Estimamos el modelo con ambos regresores a la vez, y recordamos (reestimándolas aquí mismo, para tener los números disponibles) las dos regresiones simples correspondientes.

Antes de mirar el resultado: ¿espera que el coeficiente de `rooms` sea muy distinto en la regresión simple y en la múltiple? ¿Y el de `nox`?

Tres `ols` y un `corr`. Los dos primeros son las regresiones simples de la sesión 11; el tercero, con `rooms` y `nox` tras `const`, es el modelo con dos regresores no constantes. `corr rooms nox` imprime la correlación entre ambos, que hará falta en la lectura.

en línea de comandos:

```
ols price const rooms
ols price const nox
ols price const rooms nox
corr rooms nox
```

```
Modelo 1: MCO, usando las observaciones 1-506
Variable dependiente: price

             coeficiente   Desv. típica   Estadístico t   valor p
  ------------------------------------------------------------
  const       -34796,2       2651,53         -13,12       4,74e-34 ***
  rooms         9119,55       419,339         21,75       1,87e-74 ***

Media de la vble. dep.  22511,51   D.T. de la vble. dep.   9208,856
Suma de cuad. residuos  2,21e+10   D.T. de la regresión    6620,865
R-cuadrado              0,484110   R-cuadrado corregido    0,483086
F(1, 504)               472,9521   Valor p (de F)          1,87e-74
Log-verosimilitud      -5168,759   Criterio de Akaike      10341,52
Criterio de Schwarz     10349,97   Crit. de Hannan-Quinn   10344,83
```

```
Modelo 2: MCO, usando las observaciones 1-506
Variable dependiente: price

             coeficiente   Desv. típica   Estadístico t   valor p
  ------------------------------------------------------------------
  const       41307,8        1816,18          22,74       2,53e-79 ***
  nox         -3386,85        320,362        -10,57       9,93e-24 ***

Media de la vble. dep.  22511,51   D.T. de la vble. dep.   9208,856
Suma de cuad. residuos  3,51e+10   D.T. de la regresión    8339,566
R-cuadrado              0,181508   R-cuadrado corregido    0,179884
F(1, 504)               111,7662   Valor p (de F)          9,93e-24
Log-verosimilitud      -5285,537   Criterio de Akaike      10575,07
Criterio de Schwarz     10583,53   Crit. de Hannan-Quinn   10578,39


Modelo 3: MCO, usando las observaciones 1-506
Variable dependiente: price

             coeficiente   Desv. típica   Estadístico t   valor p
  ------------------------------------------------------------------
  const      -18423,4       3346,66         -5,505       5,89e-08 ***
  rooms        8178,56       418,076         19,56        8,62e-64 ***
  nox         -1884,68       253,573         -7,432       4,62e-13 ***

Media de la vble. dep.  22511,51   D.T. de la vble. dep.   9208,856
Suma de cuad. residuos  1,99e+10   D.T. de la regresión    6290,987
R-cuadrado              0,535161   R-cuadrado corregido    0,533312
F(2, 503)               289,5472   Valor p (de F)          2,12e-84
Log-verosimilitud      -5142,396   Criterio de Akaike      10290,79
Criterio de Schwarz     10303,47   Crit. de Hannan-Quinn   10295,77


corr(rooms, nox) = -0,30282803
Bajo la hipótesis nula de no correlación:
 t(504) = -7,13342, con valor p a dos colas 0,0000
```

Lo que debe observar: compare $\hat{\beta}_{\text{rooms}}$ en `price~rooms` frente a `price~rooms+nox`, y $\hat{\beta}_{\text{nox}}$ en `price~nox` frente a `price~rooms+nox`.

Aquí conviene mirar los dos coeficientes por separado, porque no cambian igual:

- `rooms` apenas cambia: pasa de 9119,55 a 8178,56, un descenso de aproximadamente el 10 %.
- `nox`, en cambio, se reduce *casi a la mitad*: de −3386,85 a −1884,68.

Es decir, el mismo par de regresores, estimado conjuntamente, apenas altera un coeficiente y modifica sustancialmente el otro. Conviene no explicarlo únicamente por la correlación entre ambos: la correlación que acaba de imprimir el guion es −0,3028, *menor* en valor absoluto que el +0,4647 entre `sqft` y `bedrms` de la práctica de Ramanathan (actividad 3 (html)), y sin embargo aquí uno de los dos desplazamientos es mucho mayor.

La razón es que el desplazamiento del coeficiente de $\boldsymbol{x}_2$ al añadir $\boldsymbol{x}_3$ no depende solo de cuán correlacionados estén, sino del producto

$$\hat{\beta}_3 \frac{\sigma_{\boldsymbol{x}_2\boldsymbol{x}_3}}{\sigma^2_{\boldsymbol{x}_2}},$$

donde interviene también la *magnitud* del coeficiente del regresor añadido y la escala de cada variable. La correlación indica si habrá desplazamiento; no indica cuánto.

Fíjese que R^2 no es la suma de los dos R^2 simples: $0{,}4841 + 0{,}1815 = 0{,}666$ frente a 0,535, porque sus vectores en desviaciones no son ortogonales (correlación −0,30; lección 10).

El plano de regresión

El modelo `price~rooms+nox` tiene dos regresores no constantes, así que su ajuste es un plano en el espacio de las tres variables, como en la actividad 3 (html) de la práctica A. Dibújelo desde los menús:

1. En la ventana principal de Gretl, `Ver ->Gráficos ->Gráfico en 3D...`
2. Elija `rooms` como variable del eje X, `nox` como variable del eje Y y `price` como variable del eje Z, el vertical. Pulse `Aceptar`.
3. Gire la figura con el ratón. Busque primero la vista en la que el eje de `nox` apunta hacia usted, y luego la vista en la que lo hace el eje de `rooms`.

Qué representa la figura:

- *Cada punto es un barrio* del área de Boston: su número medio de habitaciones por vivienda, su concentración de óxidos de nitrógeno y su precio mediano. Hay 506 puntos, uno por barrio.
- *El plano* es el conjunto de precios ajustados, $-18423 + 8179\,\text{rooms} - 1885\,\text{nox}$. A lo largo del eje de `rooms` sube 8179 dólares por habitación con `nox` fijo; a lo largo del eje de `nox` baja 1885 dólares por unidad con `rooms` fijo. Esas dos pendientes son los efectos parciales de la tabla de la regresión múltiple.
- *Las dos vistas del paso 3* separan los dos efectos. Mirando de frente el eje de `nox`, el plano se ve como una recta que sube con `rooms`; mirando de frente el de `rooms`, como una recta que baja con `nox`. Pero esas rectas no son las de las regresiones simples, que miden los efectos sin fijar el otro regresor: la de `nox` sola tiene pendiente -3387, casi el doble que la del plano.
- *La distancia vertical* de cada punto al plano es su residuo. La nube es ancha alrededor del plano: el R^2 es 0,535, y casi la mitad de la variación del precio queda sin explicar.
- En la esquina de pocas habitaciones y mucha contaminación no hay barrios, y allí el plano llega a dar precios negativos. El plano describe la nube donde hay datos; fuera de ella es una extrapolación.

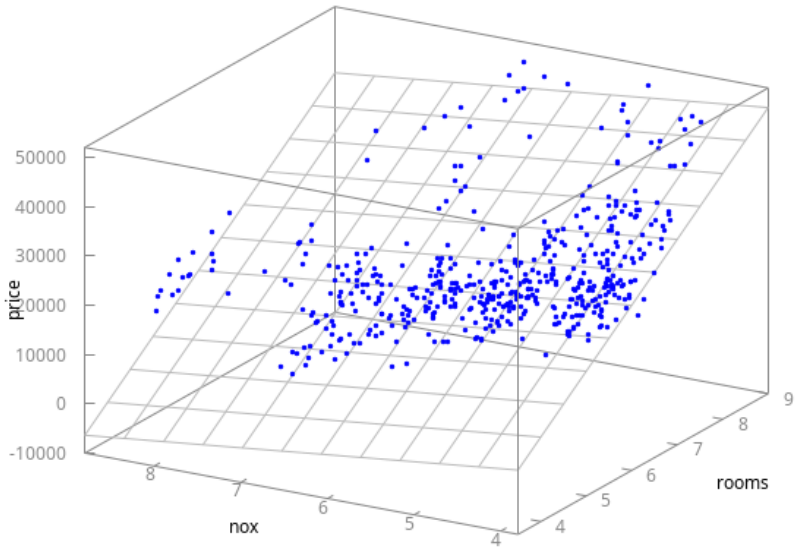


Figura 1: Los 506 barrios (puntos azules) y el plano ajustado de `price` sobre `rooms` y `nox` (en gris).

Actividad 3 - Un tercer regresor: stratio

Añadimos el ratio alumnos/profesor de la zona, una variable que cabe esperar relacionada negativamente con el precio (zonas con colegios más masificados, en principio menos atractivas).

Un regresor más en la lista de `ols`.

Antes de mirar el resultado: ¿qué signo espera para el coeficiente de `stratio`?

en línea de comandos:

```
ols price const rooms nox stratio
```

```
Modelo 4: MCO, usando las observaciones 1-506
Variable dependiente: price

             coeficiente   Desv. típica   Estadístico t   valor p
  ------------------------------------------------------------------
  const        9458,01       4371,41          2,164       0,0310   **
  rooms        7000,63        409,150        17,11        4,83e-52 ***
  nox         -1693,33        236,250        -7,168       2,75e-12 ***
  stratio     -1166,96        128,764        -9,063       2,85e-18 ***

Media de la vble. dep.  22511,51   D.T. de la vble. dep.   9208,856
Suma de cuad. residuos  1,71e+10   D.T. de la regresión    5837,767
R-cuadrado              0,600521   R-cuadrado corregido    0,598133
F(3, 502)               251,5451   Valor p (de F)          1,31e-99
Log-verosimilitud      -5104,059   Criterio de Akaike      10216,12
Criterio de Schwarz     10233,02   Crit. de Hannan-Quinn   10222,75
```

Lo que debe observar

El coeficiente de `stratio` es $-1\,167$: un alumno más por profesor en la zona se asocia, manteniendo fijas habitaciones y contaminación, con unos 1 200 dólares menos de precio mediano. Compare de nuevo los coeficientes de `rooms` y `nox` con los de la Actividad 2: `rooms` baja de 8 179 a 7 001 y `nox` de $-1\,885$ a $-1\,693$. Vuelven a cambiar, porque `stratio` está correlacionada con ambos; cada coeficiente responde a la pregunta "manteniendo fijos *los demás regresores del modelo*", y esa lista acaba de cambiar.

Actividad 4 - R^2 nunca disminuye: los cuatro modelos a la vez

Reunimos los cuatro modelos ya estimados (dos simples, dos múltiples) y comparamos su R^2.

Cuatro `ols` con `--quiet` y, tras cada uno, el accesor `$rsq` guardado en un escalar antes de estimar el siguiente modelo (los accesores se refieren siempre al último modelo estimado). Los `printf` imprimen los cuatro R^2 juntos.

en línea de comandos:

```
ols price const rooms --quiet
scalar r2_rooms = $rsq

ols price const nox --quiet
scalar r2_nox = $rsq

ols price const rooms nox --quiet
scalar r2_rooms_nox = $rsq

ols price const rooms nox stratio --quiet
scalar r2_todos = $rsq

printf "R2 price~rooms               = %.4f\n", r2_rooms
printf "R2 price~nox                 = %.4f\n", r2_nox
printf "R2 price~rooms+nox           = %.4f\n", r2_rooms_nox
printf "R2 price~rooms+nox+stratio   = %.4f\n", r2_todos
```

```
R2 price~rooms                = 0,4841
R2 price~nox                  = 0,1815
R2 price~rooms+nox            = 0,5352
R2 price~rooms+nox+stratio    = 0,6005
```

Observe que R^2 del modelo con tres regresores no constantes es, como mínimo, igual al de cualquiera de los modelos que "contiene" (`price~rooms+nox` y, transitivamente, los dos simples). Es la propiedad mecánica de MCO anunciada en la lección 8 ("un R^2 alto no certifica nada por sí solo", y en particular, *nunca baja* al añadir un regresor, aporte este lo que aporte).

Actividad 5 - Del R^2 al R^2 ajustado

Si R^2 nunca baja, ¿cómo distinguir un regresor que de verdad mejora el modelo de uno que solo lo "infla" artificialmente? Gretl reporta el R^2 con `$rsq`, pero no ofrece ningún *accesor* (`$...`) para el R^2 *ajustado* (aunque sí lo imprime, como "R-cuadrado corregido", en la salida habitual de `ols`), así que lo vamos a recalcular a mano (véase la sección Apéndice - De dónde sale la fórmula del R^2 ajustado).

Tres modelos con el mismo esquema: `ols --quiet`, un escalar `Rbarsq` calculado con la fórmula $1-(1-R^2)(n-1)/(n-k)$ escrita con los accesores `$rsq`, `$nobs` y `$ncoeff`, y tres `printf`. El escalar se sobrescribe en cada modelo, porque se imprime antes de pasar al siguiente. El tercer modelo añade `radial`, una variable de `hprice2` que no habíamos usado hasta ahora.

en línea de comandos:

```
ols price const rooms nox --quiet
scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
printf "Modelo price~rooms+nox\n"
printf "  R2          = %.4f\n", $rsq
printf "  R2 ajustado = %.4f\n", Rbarsq

ols price const rooms nox stratio --quiet
scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
printf "Modelo price~rooms+nox+stratio\n"
printf "  R2          = %.4f\n", $rsq
printf "  R2 ajustado = %.4f\n", Rbarsq

ols price const rooms nox stratio radial --quiet
scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
printf "Modelo price~rooms+nox+stratio+radial\n"
printf "  R2          = %.4f\n", $rsq
printf "  R2 ajustado = %.4f\n", Rbarsq
```

```
Modelo price~rooms+nox
  R2          = 0,5352
  R2 ajustado = 0,5333
Modelo price~rooms+nox+stratio
  R2          = 0,6005
  R2 ajustado = 0,5981
Modelo price~rooms+nox+stratio+radial
  R2          = 0,6008
  R2 ajustado = 0,5976
```

Lea la salida en dos pasos, porque contiene los dos comportamientos posibles.

Primer paso: un regresor que aporta. Al pasar de `price~rooms+nox` a `price~rooms+nox+stratio`, suben los dos índices: R^2 y $\bar{R}^2$. `stratio` aporta lo bastante como para compensar sobradamente el parámetro adicional que hay que estimar.

Segundo paso: un regresor que no aporta. Ahora añadimos `radial` (un índice de accesibilidad a las autopistas radiales) al modelo que acabamos de construir. Mire las dos últimas líneas:

- R^2 *sube*: de 0,6005 a 0,6008. Tenía que subir: nunca baja.
- $\bar{R}^2$ *baja*: de 0,5981 a 0,5976.

Esa es, con datos reales, la diferencia entre los dos índices. `radial` mejora el ajuste (toda variable lo hace, aunque sea por casualidad), pero lo mejora *tan poco* que no compensa el grado de libertad que consume. R^2 no lo refleja; $\bar{R}^2$ sí lo refleja, y baja.

Esto no convierte a $\bar{R}^2$ en un criterio infalible para elegir modelos; la práctica C de esta sesión muestra hasta dónde llega.

El apéndice que cierra esta práctica explica de dónde sale exactamente la fórmula de $\bar{R}^2$ y por qué tiene esa propiedad.

Apéndice - De dónde sale la fórmula del R^2 ajustado

Recordemos (lección 8) que $R^2 = 1 - \text{SRC/STC}$, con $\text{STC} = \sum_i (y_i - \mu_{\boldsymbol{y}})^2$ y $\text{SRC} = \sum_i \hat{e}_i^2$. La idea del R^2 ajustado es sustituir, en ese cociente, cada suma de cuadrados por su *cuasivarianza* correspondiente, es decir, dividir cada una por sus *grados de libertad* y no por el número de observaciones:

$$\bar{R}^2 \;=\; 1 - \frac{\text{SRC}/(n-k)}{\text{STC}/(n-1)},$$

donde k es el número *total* de regresores del modelo (incluida la constante; convención fijada en la lección 10) y $n-k$ son los grados de libertad de los residuos (k parámetros "beta" estimados). El denominador $\text{STC}/(n-1)$ es la cuasivarianza de $\boldsymbol{y}$: el valor, sobre estos datos, del estimador insesgado de la varianza de la variable Y del modelo teórico.[1] El numerador $\text{SRC}/(n-k)$ es la cuasivarianza de $\widehat{\boldsymbol{e}}$: el valor, sobre estos datos, del estimador insesgado de la varianza de las perturbaciones U del modelo teórico.

Conviene no pasar por alto que numerador y denominador estiman *dos cosas distintas*: el numerador, la dispersión de las perturbaciones alrededor de la recta; el denominador, la dispersión total de Y alrededor de su media. $\bar{R}^2$ no es, por tanto, el cociente de dos estimaciones de la misma cantidad, sino, igual que R^2, una comparación entre lo que queda sin explicar y lo que había que explicar, esta vez con cada suma de cuadrados dividida por sus propios grados de libertad.

Operando algebraicamente sobre esta definición se obtiene una expresión equivalente, más cómoda para el cálculo manual a partir de un R^2 ya conocido:

$$\bar{R}^2 \;=\; 1 - (1 - R^2)\,\frac{n-1}{n-k}.$$

Por qué R^2 nunca baja pero $\bar{R}^2$ sí puede bajar: porque al añadir nuevos regresores, SRC nunca aumenta. El motivo es que SRC es el cuadrado de la distancia entre el vector de datos $\boldsymbol{y}$ y la combinación lineal de los regresores que está más cerca de $\boldsymbol{y}$. Al añadir nuevos regresores sin quitar ninguno de los anteriores, usando solo los originales nos podemos acercar tanto como antes (así que la distancia mínima no puede ser mayor). Pero como ahora hay nuevas combinaciones lineales posibles, podría ocurrir que alguna estuviera más cerca de $\boldsymbol{y}$ de lo que antes nos podíamos acercar. Así que $R^2 = 1 - \text{SRC/STC}$ nunca baja, aunque sí puede subir.

Sin embargo, en el *coeficiente de determinación ajustado* $\bar{R}^2$ hay *dos* efectos simultáneos: SRC baja (o se mantiene), lo que aumenta $\bar{R}^2$, pero k sube en una unidad, lo que reduce $n-k$ y por tanto agranda el cociente $\text{SRC}/(n-k)$, lo que reduce $\bar{R}^2$. Si el regresor añadido aporta poco (reduce muy poco SRC), el segundo efecto puede dominar al primero, y $\bar{R}^2$ baja pese a que R^2 no pueda hacerlo.

Verifiquemos que las dos fórmulas arrojan el mismo resultado:

Estimamos el modelo con tres regresores, guardamos n y k con `$nobs` y `$ncoeff`, y calculamos $\bar{R}^2$ de las dos maneras: con la definición, usando `$ess` para SRC y `sst(price)` para STC, y con la fórmula reducida. `%d` es el hueco de `printf` para un número entero.

en línea de comandos:

```
ols price const rooms nox stratio --quiet
scalar n_obs = $nobs
scalar k_reg = $ncoeff

scalar Rbarsq_orig = 1 - ( $ess/($nobs-$ncoeff) )/( sst(price)/($nobs-1) )
scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
```

[1] La propiedad de *insesgadez* que ya conoce del curso de estadística y probabilidad, y que la lección 11 aborda.

```
printf "n = %d,  k = %d (incluida la constante)\n", n_obs, k_reg
printf "R2 ajustado (formula original: 1-(SRC/(n-k))/(STC/(n-1)) ) = %.6f\n", Rbarsq_orig
printf "R2 ajustado (formula reducida: 1-(1-R2)(n-1)/(n-k)) = %.6f\n", Rbarsq
```

```
n = 506,  k = 4 (incluida la constante)
R2 ajustado (formula original: 1-(SRC/(n-k))/(STC/(n-1)) ) = 0,598133
R2 ajustado (formula reducida: 1-(1-R2)(n-1)/(n-k)) = 0,598133
```

Preguntas de interpretación para la clase

1. ¿Por qué los coeficientes de `rooms` y `nox` cambian de forma tan desigual entre el modelo simple y el múltiple (el de `rooms` apenas, el de `nox` casi a la mitad), si su correlación es menor que la de `sqft` y `bedrms` en la práctica de Ramanathan (actividad 3 (html))?

2. ¿Cómo interpreta el signo obtenido para `stratio`? ¿Es coherente con lo que cabría esperar económicamente?

3. Explique, sin usar la fórmula, por qué R^2 no puede bajar nunca al añadir un regresor, mientras que $\bar{R}^2$ sí puede hacerlo.

4. Si al añadir `stratio` el R^2 ajustado hubiera bajado ligeramente, ¿qué le diría eso sobre el aporte de esa variable al modelo?

5. ¿Diría que el R^2 ajustado "certifica" que un modelo es mejor que otro, en el mismo sentido en que la lección 8 advertía que un R^2 alto no certifica una relación causal?

Para profundizar:

- Véanse las lecciones 8 y 10 para la propiedad mecánica de R^2 y la interpretación del efecto parcial.
- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 6, sección 6.3 (R^2 ajustado).

Código completo de la práctica

```
# ------------------------------------------------------------
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# ------------------------------------------------------------

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
↪  directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#    DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
↪  trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

open hprice2.gdt --quiet
outfile --quiet resumen.txt
    setinfo price   -d "Precio mediano de la vivienda ($)" -n "Precio ($)"
    setinfo rooms   -d "Número medio de habitaciones" -n "Habitaciones"
    setinfo nox     -d "Concentración de óxidos de nitrógeno" -n "Contaminación (NOx)"
    setinfo stratio -d "Ratio alumnos/profesor en la zona" -n "Ratio alumnos/profesor"

    summary price rooms nox stratio
end outfile

outfile --quiet Ols_rooms_nox_simple_y_conjunto.txt
    ols price const rooms
    ols price const nox
    ols price const rooms nox
    corr rooms nox
end outfile

outfile --quiet Ols_multiple_con_stratio.txt
    ols price const rooms nox stratio
end outfile

outfile --quiet comparacionR2cuatroModelos.txt
    ols price const rooms --quiet
    scalar r2_rooms = $rsq

    ols price const nox --quiet
    scalar r2_nox = $rsq

    ols price const rooms nox --quiet
    scalar r2_rooms_nox = $rsq

    ols price const rooms nox stratio --quiet
    scalar r2_todos = $rsq

    printf "R2 price~rooms               = %.4f\n", r2_rooms
    printf "R2 price~nox                 = %.4f\n", r2_nox
    printf "R2 price~rooms+nox           = %.4f\n", r2_rooms_nox
    printf "R2 price~rooms+nox+stratio   = %.4f\n", r2_todos
end outfile

outfile --quiet r2AjustadoTresModelos.txt
    ols price const rooms nox --quiet
    scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
    printf "Modelo price~rooms+nox\n"
```

```
    printf "  R2          = %.4f\n", $rsq
    printf "  R2 ajustado = %.4f\n", Rbarsq

    ols price const rooms nox stratio --quiet
    scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
    printf "Modelo price~rooms+nox+stratio\n"
    printf "  R2          = %.4f\n", $rsq
    printf "  R2 ajustado = %.4f\n", Rbarsq

    ols price const rooms nox stratio radial --quiet
    scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)
    printf "Modelo price~rooms+nox+stratio+radial\n"
    printf "  R2          = %.4f\n", $rsq
    printf "  R2 ajustado = %.4f\n", Rbarsq
end outfile

outfile --quiet verificacionFormulaR2ajustado.txt
    ols price const rooms nox stratio --quiet
    scalar n_obs = $nobs
    scalar k_reg = $ncoeff

    scalar Rbarsq_orig = 1 - ( $ess/($nobs-$ncoeff) )/( sst(price)/($nobs-1) )
    scalar Rbarsq = 1 - (1-$rsq)*($nobs-1)/($nobs-$ncoeff)

    printf "n = %d,  k = %d (incluida la constante)\n", n_obs, k_reg
    printf "R2 ajustado (formula original: 1-(SRC/(n-k))/(STC/(n-1)) ) = %.6f\n", Rbarsq_orig
    printf "R2 ajustado (formula reducida: 1-(1-R2)(n-1)/(n-k)) = %.6f\n", Rbarsq
end outfile
```

Enlace al guión: S14-Prct-B-hprice2-r2ajustado.inp

Respuestas

1. ¿Cambian `rooms` y `nox` al pasar del modelo simple al múltiple? De forma muy desigual: `rooms` baja alrededor de un 10 % y `nox` se reduce casi a la mitad. La correlación entre ambos, $-0{,}3028$, no basta para explicarlo: el desplazamiento de $\hat{\beta}_2$ al incorporar $\boldsymbol{x}_3$ vale $\hat{\beta}_3\,\sigma_{\boldsymbol{x}_2\boldsymbol{x}_3}/\sigma^2_{\boldsymbol{x}_2}$, e intervienen también el tamaño del coeficiente del regresor añadido y las escalas de ambas variables. La correlación anticipa *si* habrá desplazamiento, no *cuánto*.

2. Interpretación del signo de `stratio`. Un coeficiente negativo es coherente con la intuición: zonas con una proporción más alta de alumnos por profesor (colegios más masificados, en principio de peor calidad percibida) tienden a tener viviendas más baratas, manteniendo fijas las habitaciones y la contaminación. Como siempre, esta es una lectura *ceteris paribus*, no necesariamente causal: podría haber otros factores (nivel de renta de la zona, inversión pública) que expliquen tanto el ratio alumnos/profesor como el precio.

3. Por qué R^2 no baja nunca y $\bar{R}^2$ sí puede bajar (sin fórmula). Añadir un regresor nunca puede empeorar el mejor ajuste posible: MCO siempre puede, como mínimo, asignar coeficiente cero al regresor nuevo y dar el mismo ajuste que antes; en la práctica, la dirección adicional suele permitir reducir algo más los residuos. Por eso R^2 nunca baja. Pero $\bar{R}^2$ además penaliza cada regresor añadido, pues descuenta un grado de libertad (la diferencia entre n y k), así que si el regresor nuevo casi no reduce los residuos, esa penalización puede superar la mejora conseguida, y $\bar{R}^2$ se reduce.

4. Si $\bar{R}^2$ hubiera bajado al añadir `stratio`. Eso indicaría que la reducción de residuos lograda por `stratio` es tan pequeña que no compensa el grado de libertad perdido al estimar un parámetro adicional: una señal de que el aumento de complejidad del modelo, en términos de parsimonia, no compensa la escasa aportación de ese regresor al ajuste del modelo.

5. ¿Certifica el R^2 ajustado que un modelo es mejor? No, en el mismo sentido en que la lección 8 advertía sobre R^2: un $\bar{R}^2$ más alto es un indicio a favor de un modelo frente a otro en términos de ajuste penalizado por complejidad, pero no certifica que la especificación sea correcta, que los regresores incluidos sean los relevantes desde un punto de vista teórico, ni que exista ninguna relación causal. Es una herramienta de comparación entre modelos alternativos, no un veredicto definitivo sobre la validez de ninguno de ellos. La elección de qué variables incluir debe seguir estando guiada, en primer lugar, por la teoría económica, no solo por qué estadístico sube o baja.