Sesión 16 (B) — Condicionar en $\boldsymbol{X}$: la misma fórmula, dos experimentos

Marcos Bujosa

Descripción de la práctica

Qué es condicionar en $\boldsymbol{X}$ ya está definido con precisión: la lección 9 presentó $E[Z \mid \boldsymbol{X}]$ como la proyección ortogonal de Z sobre las funciones de $\boldsymbol{X}$, y la lección 11 trabajó con esa definición. Esta práctica busca otra cosa: la *consecuencia observable* de condicionar, es decir, qué distingue en los números la varianza condicional evaluada en la muestra observada de la varianza incondicional.

En la práctica A (actividad 3 (html)) mantuvimos el regresor `rooms` fijo a lo largo de las 2000 réplicas, y solo dejamos cambiar la perturbación. Lo justificamos así: $Var[\hat{\beta}_2 \mid \boldsymbol{X}]$ es una función de $\boldsymbol{X}$, y el experimento evalúa esa función en el ω observado, donde $\boldsymbol{X}$ vale `rooms`. Condicionar en $\boldsymbol{X}$ es otra cosa: proyectar sobre las funciones de $\boldsymbol{X}$ (lección 9); de esa proyección sale la función, y el ordenador solo la evalúa. En la imagen de la matriz de copias de la lección 11 (apéndice, sección 3 (html)), fijar el regresor es quedarse con sus n valores en la columna que ocurrió y recorrer, bloque de filas a bloque de filas, solo copias nuevas de la perturbación.

Esta práctica hace lo contrario. Vamos a repetir el mismo experimento de Montecarlo dos veces:

- *Experimento A*: el regresor se fija una vez y no cambia; solo cambia la perturbación.
- *Experimento B*: en cada réplica se sortea *también* un regresor nuevo.

Si la distinción fuera irrelevante, ambos experimentos darían lo mismo. Veremos que no.

Objetivos

1. Comprobar que la fórmula $Var[\hat{\beta}_2 \mid \boldsymbol{X}] = \sigma^2 / \sum_i (X_i - \overline{X})^2$ describe el experimento A, no el B.
2. Ver qué consecuencia numérica tiene condicionar en $\boldsymbol{X}$, operación que las lecciones 9 y 11 ya definieron con precisión.
3. Ver que la insesgadez, en cambio, se cumple en *ambos* experimentos, y entender por qué las dos propiedades se comportan de forma distinta.
4. Apreciar por qué el resultado que reportan los programas estadísticos es siempre el condicional.

Advertencia de diseño. Para que la diferencia se vea con claridad, trabajaremos con una muestra deliberadamente *pequeña*: doce viviendas. Cuanto mayor es la muestra, menos importa la distinción que queremos ilustrar, y con las 506 observaciones de la práctica A costaría apreciarla. En la Actividad 5 repetiremos el experimento con una muestra grande para comprobar eso.

Comandos nuevos de esta práctica. Todo el aparato es el de la práctica A: `open`, `ols --quiet` y sus accesores, `loop --progressive`, `store` y la apertura del fichero de réplicas con `open "@workdir/…"`. Lo nuevo:

`smpl 12 --random` elige al azar doce observaciones del conjunto de datos y restringe la muestra a ellas; a partir de ahí `$nobs` vale 12 y las funciones sobre series actúan solo sobre esas doce. Con `set seed` delante, siempre salen las mismas.

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

`matrix pob_rooms = {rooms}` copia la serie en una matriz columna (práctica D de la sesión 14, actividad 2 (html)); la matriz no se ve afectada por `smpl`, y por eso conserva las 506 viviendas cuando la muestra se restringe a doce.

`muniform(r, c)` matriz de $r \times c$ sorteos uniformes entre 0 y 1.

`ceil(x)` redondeo hacia arriba al entero; `ceil(N * muniform(12,1))` da doce índices enteros entre 1 y N.

`pob_rooms[idx]` extrae de la matriz las filas cuyos índices están en `idx`; si un índice se repite, la misma vivienda sale dos veces (sorteo *con reemplazamiento*).

`min(x), max(x)` mínimo y máximo de una serie.

Bloques que empiezan con `open` cuando la salida de una actividad mezcla escalares teóricos y series de réplicas, los `printf` van en bloques distintos: el que calcula sobre las réplicas va precedido de `open "@workdir/…"`, que abre su fichero, y desde esa línea los escalares anteriores ya no existen. Por eso los valores teóricos se imprimen siempre antes.

Actividad 1 - El mismo mundo, pero con doce viviendas

Reutilizamos el mundo artificial de la práctica A (mismos β_1, β_2 y σ), pero nos quedamos solo con doce viviendas, elegidas al azar. Además, guardamos las 506 viviendas en una matriz antes de restringir la muestra: son la población de la que el experimento B sorteará viviendas nuevas.

Dos bloques. El primero repite el mundo artificial de la práctica A y guarda los 506 valores de `rooms` en la matriz `pob_rooms`, la población del regresor, y calcula su varianza `var_rooms` con el divisor del curso. El segundo imprime la media y la varianza de esa población, restringe la muestra a doce viviendas con `smpl 12 --random` (después de `set seed 160`, para que sean siempre las mismas doce) y calcula sobre ellas `Sxx_obs`, la suma de cuadrados en desviaciones, y `Var_b2_en_X_observada`, la varianza que predice la lección 11. El «Sxx esperado» que también se imprime es $(n-1)$ veces esa varianza: el valor esperado de Sxx para doce viviendas sorteadas de la población.

en línea de comandos:

```
open hprice2.gdt --quiet

ols price const rooms --quiet
scalar beta1_verdadero = $coeff(const)
scalar beta2_verdadero = $coeff(rooms)
scalar sigma   = sqrt($ess/$df)

matrix pob_rooms = {rooms}              # las 506 viviendas: la "poblacion" del regresor
scalar N         = $nobs
scalar var_rooms = sum((rooms-mean(rooms))^2)/N
```

```
printf "Poblacion del regresor (las %d viviendas de hprice2): media = %.4f   varianza = %.4f\n", N, mean(rooms), var_rooms

set seed 160
smpl 12 --random                        # doce viviendas elegidas AL AZAR
scalar Sxx_obs  = sum((rooms-mean(rooms))^2)
scalar Var_b2_en_X_observada = sigma^2 / Sxx_obs

printf "\nSubmuestra observada (n = %d):\n", $nobs
printf "  media(rooms) = %.4f    varianza(rooms) = %.4f\n", mean(rooms), sum((rooms-mean(rooms))^2)/$nobs
printf "  Sxx de estas %d viviendas (suma de cuadrados en desviaciones) = %.4f\n", $nobs, Sxx_obs
printf "  Sxx esperado para %d viviendas sorteadas de la poblacion     = %.4f\n", $nobs, ($nobs-1)*var_rooms
printf "\nVar[b2 | X] en estas %d viviendas (formula de la leccion 11) = %.1f   (error estandar %.1f)\n", $nobs,
↪  Var_b2_en_X_observada, sqrt(Var_b2_en_X_observada)
```

```
Poblacion del regresor (las 506 viviendas de hprice2): media = 6,2841   varianza = 0,4927

Submuestra observada (n = 12):
  media(rooms) = 6,3917    varianza(rooms) = 0,2722
```

```
  Sxx de estas 12 viviendas (suma de cuadrados en desviaciones) = 3,2670
  Sxx esperado para 12 viviendas sorteadas de la poblacion     = 5,4193

Var[b2 | X] en estas 12 viviendas (formula de la leccion 11) = 13417907,5   (error estandar 3663,0)
```

Recuerde que `Sxx` es la abreviatura que introdujimos en la práctica A para $\sum_i (x_i - \mu_{\boldsymbol{x}})^2$: el cuadrado de la norma euclídea del vector en desviaciones del regresor, o equivalentemente $n\,\sigma^2_{\boldsymbol{x}}$ (evaluada sobre la muestra aleatoria, $n\,S^2 = \sum_i (X_i - \overline{X})^2$, lección 11). No es notación del curso, solo una comodidad para los guiones.

Dos detalles del código merecen comentario. El primero es `smpl 12 --random`: elegimos las doce viviendas *al azar*, en lugar de tomar las doce primeras. Es importante, porque `hprice2` viene ordenado por distritos censales y las primeras viviendas se parecen mucho entre sí; tomarlas directamente nos daría una submuestra atípica por un motivo ajeno a lo que queremos estudiar. El segundo es `set seed`, que fija *qué* doce viviendas salen, para que el resultado sea reproducible.

Una cifra de la salida necesita explicación: el «Sxx esperado para 12 viviendas sorteadas de la población», $(n-1)\,\sigma^2_{\boldsymbol{x}}$, con $\sigma^2_{\boldsymbol{x}}$ la varianza de `rooms` en las 506 viviendas (lección 4). Si cada una de las doce viviendas se sortea de las 506 con reemplazamiento, las doce son copias idénticas e independientes de una variable con esa varianza, y el valor esperado de $\sum_i (X_i - \overline{X})^2$ es $(n-1)\,\sigma^2_{\boldsymbol{x}}$, la regla de su curso de Estadística para la cuasivarianza. Es el patrón con el que vamos a comparar el Sxx de las doce viviendas que nos han tocado.

Lo que debe observar

Tres cifras. La primera es el Sxx de estas doce viviendas, 3,27. La segunda es el Sxx esperado para doce viviendas sorteadas de la población, 5,42: el promedio de Sxx sobre todas las muestras posibles de doce. Las doce que han salido tienen valores de `rooms` menos dispersos que la población: varianza 0,272, frente a 0,493 en las 506. La tercera es $Var[\hat{\beta}_2 \mid \boldsymbol{X}]$ evaluada en estas doce viviendas, la fórmula de la lección 11 con el σ del mundo artificial y este Sxx: unos 13,4 millones. Su raíz es el error estándar de $\hat{\beta}_2$, 3663 dólares por habitación, frente a una pendiente verdadera de 9120. Con doce viviendas la estimación es muy imprecisa, y esa imprecisión es lo que hace visible la diferencia que buscamos. Retenga la comparación entre las dos primeras cifras, 3,27 frente a 5,42: es el primero de los dos efectos que explican el signo de lo que sigue.

Actividad 2 - Experimento A: el regresor se queda quieto

Es el experimento de la práctica A sin más cambio que el tamaño muestral: las doce viviendas en lugar de las 506. Cada vuelta sortea la perturbación, construye `y`, estima con `ols --quiet` y guarda el coeficiente `b_fijo` como una fila más de `repFijo.gdt`. Usamos `R = 4000` réplicas, el doble que en la práctica A: la varianza empírica de R réplicas tiene su propio error de Montecarlo, del orden de $\sqrt{2/R}$ en términos relativos (un 3 % con 2000, un 2 % con 4000), y queremos que sea pequeño frente a la diferencia entre los dos experimentos, que resultará ser mucho mayor.

en línea de comandos:

```
scalar R = 4000

set seed 160
loop R --progressive --quiet
    series u = normal(0, sigma)
    series y = beta1_verdadero + beta2_verdadero*rooms + u      # rooms NO cambia
    ols y const rooms --quiet
    scalar b_fijo = $coeff(rooms)
    store "@workdir/repFijo.gdt" b_fijo
endloop
```

```
printf "Hecho: %d replicas con el regresor fijo guardadas en repFijo.gdt\n", R
```

```
Hecho: 4000 replicas con el regresor fijo guardadas en repFijo.gdt
```

Todavía no miramos las estimaciones: las compararemos en la Actividad 4 junto a las del experimento B. Lo que tenemos ahora es un fichero con 4000 estimaciones de β_2, todas obtenidas con las *mismas* doce viviendas y distintas perturbaciones.

Actividad 3 - Experimento B: el regresor también se sortea

Ahora decimos "no solo podría haber sido otra la perturbación; también podrían haber sido otras las doce viviendas". Para eso hace falta una población de la que sortear viviendas nuevas, y la tenemos: las 506 de `hprice2`, guardadas en `pob_rooms`. En cada réplica sorteamos doce de ellas con reemplazamiento: `muniform(12,1)` da doce números entre 0 y 1, `ceil(N * ...)` los convierte en doce índices entre 1 y 506, y `pob_rooms[idx]` extrae esas doce viviendas. Con reemplazamiento, cada sorteo es una copia idéntica e independiente de la distribución de `rooms` en `hprice2`: la muestra aleatoria de la lección 11, con esa distribución como población. Una misma vivienda puede salir dos veces, y eso es lo que hace independientes a los doce sorteos.

Antes de incluir el sorteo en el bucle, hacemos uno solo para ver qué cambia. El bloque sortea un `xnew`, calcula su Sxx y lo imprime junto al de las doce viviendas observadas.

en línea de comandos:

```
set seed 160
matrix idx  = ceil(N * muniform(12,1))      # doce indices entre 1 y 506
series xnew = pob_rooms[idx]                # doce viviendas de hprice2, con reemplazamiento
printf "Sxx de las doce viviendas observadas = %.4f\n", Sxx_obs
printf "Sxx de doce viviendas sorteadas       = %.4f\n", sum((xnew-mean(xnew))^2)
```

```
Sxx de las doce viviendas observadas = 3,2670
Sxx de doce viviendas sorteadas       = 4,5741
```

El Sxx de las doce viviendas sorteadas no coincide con el de las observadas, y en otro sorteo saldría otro. Eso es lo que el experimento B añade: en cada réplica, además de la perturbación, cambia el regresor y con él su Sxx. En el código del bucle las líneas nuevas son las dos primeras; después `y` se construye con `xnew`, la regresión se estima sobre `xnew`, y `store` guarda dos escalares por réplica en `repVar.gdt`: el coeficiente `b_var` y `Sxx_i`, la suma de cuadrados en desviaciones del regresor *de esa réplica*. En el experimento A ese número era una constante, 3,27; aquí es una variable aleatoria más, y en ella está la diferencia entre los dos experimentos.

en línea de comandos:

```
set seed 160
loop R --progressive --quiet
    matrix idx  = ceil(N * muniform(12,1))      # doce indices entre 1 y 506
    series xnew = pob_rooms[idx]                # doce viviendas NUEVAS, de hprice2
    series u    = normal(0, sigma)
    series y    = beta1_verdadero + beta2_verdadero*xnew + u
    ols y const xnew --quiet
    scalar b_var = $coeff(xnew)
    scalar Sxx_i = sum((xnew-mean(xnew))^2)     # el Sxx de ESTA replica
    store "@workdir/repVar.gdt" b_var Sxx_i
endloop
```

```
printf "Hecho: %d replicas con regresor nuevo guardadas en repVar.gdt\n", R
```

```
Hecho: 4000 replicas con regresor nuevo guardadas en repVar.gdt
```

Actividad 4 - Las dos varianzas, comparadas

Ya tenemos los dos ficheros de réplicas. Ahora comparamos tres cosas: lo que predice la lección 11 para nuestras doce viviendas, lo que ha salido con el regresor fijo y lo que ha salido con el regresor sorteado. Tres bloques, cada uno con su salida. El primero imprime la predicción con los escalares que todavía tenemos. El segundo va precedido de `open "@workdir/repFijo.gdt"`, que abre el fichero de réplicas (y borra los escalares, por eso la predicción se imprime antes), y calcula la media y la varianza, con divisor n, de `b_fijo`. El tercero va precedido de `open "@workdir/repVar.gdt"`, hace lo mismo con `b_var` y añade, con `mean`, `min` y `max`, cuánto ha variado `Sxx_i` de una réplica a otra.

en línea de comandos:

```
printf "=== LO QUE PREDICE LA LECCION 11 (condicional en la X observada) ===\n"
printf "beta_2 verdadero  = %.2f\n", beta2_verdadero
printf "Var[b2 | X]       = %.1f\n\n", Var_b2_en_X_observada
```

```
=== LO QUE PREDICE LA LECCION 11 (condicional en la X observada) ===
beta_2 verdadero  = 9119,55
Var[b2 | X]       = 13417907,5
```

```
open "@workdir/repFijo.gdt" --quiet
```

```
printf "=== EXPERIMENTO A: regresor FIJO ===\n"
printf "media de b2hat    = %.2f\n", mean(b_fijo)
printf "varianza de b2hat = %.1f\n\n", sum((b_fijo-mean(b_fijo))^2)/$nobs
```

```
=== EXPERIMENTO A: regresor FIJO ===
media de b2hat    = 9061,70
varianza de b2hat = 13168607,8
```

```
open "@workdir/repVar.gdt" --quiet
```

```
printf "=== EXPERIMENTO B: regresor REMUESTREADO en cada replica ===\n"
printf "media de b2hat    = %.2f\n", mean(b_var)
printf "varianza de b2hat = %.1f\n", sum((b_var-mean(b_var))^2)/$nobs
printf "\nSxx a lo largo de las replicas del experimento B:\n"
printf "  medio = %.4f    minimo = %.4f    maximo = %.4f\n", mean(Sxx_i), min(Sxx_i), max(Sxx_i)
```

```
=== EXPERIMENTO B: regresor REMUESTREADO en cada replica ===
media de b2hat    = 9107,43
varianza de b2hat = 11510016,3

Sxx a lo largo de las replicas del experimento B:
  medio = 5,4394    minimo = 0,4215    maximo = 25,5699
```

Lo que debe observar

Tres hechos, en este orden, con las cifras de las salidas:

1. *El experimento A reproduce la fórmula.* Con el regresor fijo, la varianza empírica de las 4000 estimaciones es 13,17 millones; la lección 11 predecía 13,42 millones con el Sxx de *nuestras doce viviendas*. La diferencia, un 2 %, es el error de Montecarlo. La fórmula de la lección 11 describe este experimento.

2. *El experimento B da otro resultado.* Con el regresor sorteado en cada réplica, la varianza es 11,51 millones, un 13 % menor. No es error de Montecarlo: los dos experimentos responden a preguntas distintas.

3. *Las medias, en cambio, coinciden.* 9062 en A y 9107 en B, frente a un β_2 verdadero de 9120. El promedio de 4000 réplicas de un estimador con error estándar 3663 tiene a su vez un error estándar del orden de $3663/\sqrt{4000} \approx 58$, así que las dos diferencias, 58 y 13, son del orden de ese error. La insesgadez se cumple en los dos diseños; la fórmula de la varianza, no.

De dónde viene la diferencia

Mire la última línea de la salida: a lo largo de las réplicas del experimento B, `Sxx_i` ha ido de 0,42 a 25,57, con un promedio de 5,44, cerca del Sxx esperado de la Actividad 1, 5,42. En el experimento A valía siempre 3,27.

En el experimento A la varianza de $\hat{\beta}_2$ es σ^2 dividido por un número fijo, 3,27. En el experimento B es σ^2 multiplicado por el promedio de $1/\text{Sxx}_i$ a lo largo de las réplicas, y el promedio de un cociente no es el cociente de los promedios: σ^2 dividido por el Sxx medio, 5,44, daría 8,1 millones, lejos de los 11,5 observados; promediar 1/Sxx sobre conjuntos de doce viviendas tan dispares (Sxx entre 0,42 y 25,57) da bastante más que 1/5,44. Dos efectos separan la cifra de B de la de A. El primero es que nuestras doce viviendas tienen un Sxx, 3,27, menor que el esperado, 5,42: la fórmula condicional evaluada en ellas da una varianza mayor que la de un conjunto de doce viviendas con la dispersión de la población. El segundo es ese promedio de 1/Sxx, que empuja la varianza de B hacia arriba. Con nuestras doce viviendas pesa más el primer efecto, y B queda por debajo de A. Con otras doce viviendas, más dispersas que la población, ocurriría lo contrario: lo comprobamos a continuación. La Actividad 5 separa los dos efectos.

Esta es la razón por la que la lección 11 se detuvo en la fórmula condicional y solo mencionó brevemente la incondicional: al intentar calcular $\text{Var}(\hat{\beta}_2)$ aparecía $\text{E}\big(\sigma^2/(nS^2)\big)$, la esperanza de un cociente, que no se simplifica.

Otras doce viviendas, más dispersas que la población

El experimento B no depende de qué doce viviendas hayamos observado: remuestrea las 506 en cada réplica, así que su varianza, 11,51 millones, es la misma sea cual sea la submuestra. El experimento A sí depende de ella. Para ver el signo contrario basta, por tanto, otra submuestra con Sxx mayor que el esperado, y repetir solo el experimento A. Con `set seed 2` salen doce viviendas con Sxx 7,39, frente al esperado 5,42.

Tres bloques. El primero reabre `hprice2`, recupera los escalares, elige esas otras doce viviendas e imprime su Sxx y la varianza que predice la lección 11. El segundo ejecuta sobre ellas el experimento A, con la misma semilla 160 que en la Actividad 2, y guarda el coeficiente `b_fijo2` en `repFijo2.gdt`; después, `open "@workdir/repFijo2.gdt"` abre ese fichero, y el último `printf` imprime la media y la varianza de las estimaciones.

en línea de comandos:

```
open hprice2.gdt --quiet
ols price const rooms --quiet
scalar beta1_verdadero = $coeff(const)
scalar beta2_verdadero = $coeff(rooms)
scalar sigma     = sqrt($ess/$df)
scalar var_rooms = sum((rooms-mean(rooms))^2)/$nobs

set seed 2
smpl 12 --random                        # OTRAS doce viviendas
scalar Sxx_obs2 = sum((rooms-mean(rooms))^2)
scalar Var_b2_en_X_observada2 = sigma^2 / Sxx_obs2
```

```
printf "Sxx de estas otras 12 viviendas = %.4f   (esperado %.4f; las doce de la Actividad 1: 3,2670)\n", Sxx_obs2,
↪  11*var_rooms
printf "Var[b2 | X] en estas 12 viviendas (formula de la leccion 11) = %.1f\n", Var_b2_en_X_observada2
```

```
Sxx de estas otras 12 viviendas = 7,3907   (esperado 5,4193; las doce de la Actividad 1: 3,2670)
Var[b2 | X] en estas 12 viviendas (formula de la leccion 11) = 5931245,3
```

```
set seed 160
loop 4000 --progressive --quiet
    series u = normal(0, sigma)
    series y = beta1_verdadero + beta2_verdadero*rooms + u      # rooms NO cambia
    ols y const rooms --quiet
    scalar b_fijo2 = $coeff(rooms)
    store "@workdir/repFijo2.gdt" b_fijo2
endloop
```

```
open "@workdir/repFijo2.gdt" --quiet
```

```
printf "=== EXPERIMENTO A con las otras doce viviendas: regresor FIJO ===\n"
printf "media de b_fijo2    = %.2f\n", mean(b_fijo2)
printf "varianza de b_fijo2 = %.1f\n", sum((b_fijo2-mean(b_fijo2))^2)/$nobs
```

```
=== EXPERIMENTO A con las otras doce viviendas: regresor FIJO ===
media de b_fijo2    = 9129,66
varianza de b_fijo2 = 5807230,1
```

Lo que debe observar. Con estas doce viviendas la fórmula de la lección 11 da 5,93 millones, y el experimento A lo reproduce: 5,81 millones, con la media de las estimaciones, 9130, cerca de 9120. El experimento B sigue en 11,51 millones, y ahora queda *por encima* de A, al doble. El signo de la diferencia depende de la muestra observada: con doce viviendas poco dispersas la varianza condicional evaluada en ellas es mayor que la incondicional, y con doce viviendas muy dispersas es menor. Entre tanto, la incondicional no se ha movido, porque no usa la muestra observada.

Hay una segunda lectura, y es la que importa para quien analiza datos reales. El error estándar que informa un programa es la raíz de $Var[\hat{\beta}_2 \mid \boldsymbol{X}]$ evaluada en los datos que le tocaron: 3663 dólares por habitación con las primeras doce viviendas y 2435 con las otras doce, en el mismo mundo artificial y con la misma σ. Con muestras pequeñas, la precisión que se atribuye a una estimación depende mucho de la muestra concreta con la que se calcula. Con datos reales la dependencia es aún mayor, porque σ^2 también se sustituye por su estimación $\mathfrak{s}^2$ (lección 11), que cambia de una muestra a otra.

Actividad 5 - ¿Y si la muestra fuera grande?

Repetimos el experimento con cuatrocientas viviendas en lugar de doce, dejando todo lo demás igual. La pregunta es si la diferencia entre los dos experimentos sobrevive cuando la muestra es grande, y en qué sentido: la Actividad 4 ha dicho que el signo de la diferencia depende de si nuestra muestra concreta está más o menos dispersa que lo esperado, y con cuatrocientas viviendas esa comparación puede salir al revés.

Dos cambios respecto a las Actividades 2 y 3 merecen explicación. El primero: los dos experimentos van en *un solo* bucle, que en cada vuelta estima primero con `rooms` fijo (coeficiente `bg_fijo`) y después con un regresor nuevo `xnew` y una perturbación nueva `u2` (coeficiente `bg_var`); así las dos series de réplicas tienen el mismo número de vueltas y la misma semilla, y el cociente entre sus varianzas no depende de eso. El segundo: 40 000 réplicas en lugar de 4 000. Con cuatrocientas viviendas el efecto que buscamos es pequeño, en torno a un 4,7 %, y con 4 000 réplicas el error de Montecarlo de un cociente de varianzas supera el 3 %: repitiendo el experimento con distintas semillas, el cociente oscilaba entre 0,99 y 1,07, y con alguna semilla el efecto desaparecía. Con 40 000 se estabiliza por encima de uno. El coste son unos segundos más. Un experimento simulado tiene su propia precisión, y conviene asegurarse de que su error es menor que el efecto que se quiere ver.

Cuatro bloques. El primero reabre `hprice2` y recupera los escalares (se perdieron al abrir los ficheros de réplicas), toma cuatrocientas viviendas con `smpl 400 --random` y ejecuta el bucle; `store` guarda los dos

coeficientes por réplica en `repGrande.gdt`. El segundo imprime las cifras teóricas, entre ellas el cociente entre el Sxx observado y el esperado, que es lo que cabe esperar del cociente entre las dos varianzas. El tercero, `open "@workdir/repGrande.gdt"`, abre el fichero de réplicas, y el cuarto imprime las dos varianzas empíricas y su cociente.

en línea de comandos:

```
open hprice2.gdt --quiet
ols price const rooms --quiet
scalar beta1_verdadero = $coeff(const)
scalar beta2_verdadero = $coeff(rooms)
scalar sigma   = sqrt($ess/$df)
matrix pob_rooms = {rooms}
scalar N         = $nobs
scalar var_rooms = sum((rooms-mean(rooms))^2)/N

set seed 160
smpl 400 --random
scalar Sxx_obs  = sum((rooms-mean(rooms))^2)
scalar Var_b2_en_X_observada = sigma^2 / Sxx_obs

set seed 160
loop 40000 --progressive --quiet      # diez veces mas replicas que en la Actividad 2: ver el texto
    series u = normal(0, sigma)
    series y = beta1_verdadero + beta2_verdadero*rooms + u
    ols y const rooms --quiet
    scalar bg_fijo = $coeff(rooms)
    matrix idx  = ceil(N * muniform(400,1))
    series xnew = pob_rooms[idx]
    series u2   = normal(0, sigma)
    series y2   = beta1_verdadero + beta2_verdadero*xnew + u2
    ols y2 const xnew --quiet
    scalar bg_var = $coeff(xnew)
    store "@workdir/repGrande.gdt" bg_fijo bg_var
endloop
```

```
printf "Con n = 400:  Sxx observado = %.2f   (esperado: %.2f)\n", Sxx_obs, ($nobs-1)*var_rooms
printf "             Var[b2|X] en las 400 viviendas observadas = %.2f\n", Var_b2_en_X_observada
printf "             cociente Sxx observado/esperado = %.3f  <- lo que cabe esperar de var_B/var_A\n",
↪  Sxx_obs/(($nobs-1)*var_rooms)
```

```
Con n = 400:  Sxx observado = 205,76   (esperado: 196,57)
             Var[b2|X] en las 400 viviendas observadas = 213046,34
             cociente Sxx observado/esperado = 1,047  <- lo que cabe esperar de var_B/var_A
```

```
open "@workdir/repGrande.gdt" --quiet
```

```
printf "  regresor FIJO         : var = %.2f\n", sum((bg_fijo-mean(bg_fijo))^2)/$nobs
printf "  regresor REMUESTREADO : var = %.2f\n", sum((bg_var-mean(bg_var))^2)/$nobs
printf "  cociente observado    : %.3f\n", (sum((bg_var-mean(bg_var))^2))/(sum((bg_fijo-mean(bg_fijo))^2))
```

```
  regresor FIJO         : var = 211595,99
  regresor REMUESTREADO : var = 224930,68
  cociente observado    : 1,063
```

Lo que debe observar

Lo primero que conviene mirar no es el tamaño de la diferencia, sino su *signo*.

Con nuestras doce viviendas, la varianza del experimento B salía **menor** que la del A; con las otras doce de la Actividad 4, más dispersas, **mayor**. Con cuatrocientas sale **mayor**. Es el mecanismo que explicamos en la Actividad 4: el signo depende de si la muestra observada tiene un Sxx más pequeño o más grande que el esperado. Compruébelo en las salidas:

- *Doce viviendas*: Sxx observado = 3,27 frente a un esperado de 5,42. Nuestra muestra estaba **poco dispersa**, la fórmula condicional evaluada en ella daba una varianza mayor que el promedio, y B quedaba por debajo de A.

- *Cuatrocientas viviendas*: Sxx observado = 205,76 frente a un esperado de 196,57. Ahora la muestra está algo **más dispersa** de lo esperado; la fórmula condicional evaluada en ella da una varianza menor que el promedio, y B queda por encima de A. Las varianzas son 211 596 con el regresor fijo (la fórmula de la lección 11 predecía 213 046) y 224 931 con el regresor sorteado.

El cambio de signo es la predicción cumplida. Y descarta una conclusión falsa que sería fácil extraer de la Actividad 4, "la varianza condicional es mayor que la incondicional": evaluada en la muestra observada no es sistemáticamente mayor ni menor, es la varianza *para la muestra que tenemos*, y hacia qué lado caiga depende de cómo sea esa muestra.

En cuanto al tamaño, la diferencia *se reduce* al pasar de doce a cuatrocientas observaciones, de un 13 % a un 6 %, pero no llega a desaparecer. Conviene entender por qué: en esa diferencia se superponen dos efectos:

1. *Nuestra muestra deja de ser excepcional.* Con doce viviendas, el Sxx de la muestra observada podía quedar muy lejos del esperado; con cuatrocientas, cualquier muestra tiene un Sxx bastante parecido al esperado. Este efecto se atenúa al crecer n, pero lentamente.

2. *El promedio de un cociente no es el cociente de los promedios.* Aunque el Sxx medio coincidiera con el observado, promediar σ^2/Sxx sobre las réplicas no daría σ^2 dividido por el Sxx medio. Este segundo efecto también se atenúa con n, y más deprisa que el primero.

Con $n = 400$ el segundo efecto ya es prácticamente inapreciable, y todo lo que queda es el primero. Eso se puede comprobar con las cifras de la salida: el cociente de varianzas que observamos debería parecerse al cociente Sxx observado/esperado: 1,063 frente a 1,047, con un error de Montecarlo del orden del 1 %.

La conclusión práctica es que con muestras grandes la distinción tiene poca consecuencia numérica. La conclusión conceptual, en cambio, no cambia: siguen siendo dos preguntas distintas, y la que responde la fórmula de la lección 11, y también su programa estadístico, es siempre la condicional. Y la condicional, evaluada en la muestra observada, es tan dependiente de esa muestra como lo eran los 3663 y los 2435 dólares de la Actividad 4: el error estándar de una estimación es él mismo una cifra calculada con los datos que tocaron.

Preguntas de interpretación para la clase

1. ¿Qué pregunta responde el experimento A y qué pregunta, distinta, responde el experimento B? Formule ambas con palabras, sin fórmulas.

2. ¿Por qué la insesgadez se cumple en los dos experimentos, mientras que la fórmula de la varianza solo describe el primero? (Pista: ¿en qué paso de la demostración de la lección 11 interviene $\boldsymbol{X}$ de forma esencial?)

3. Cuando Gretl le muestra el error estándar de un coeficiente, ¿está respondiendo a la pregunta del experimento A o a la del B? ¿Por qué cree que es así?

4. Imagine que un investigador *diseña* el experimento y puede elegir los valores del regresor (por ejemplo, las dosis en un ensayo). A la vista de la fórmula de la lección 11, ¿qué le convendría hacer con esas dosis?

5. En la Actividad 5, con $n = 400$, las dos varianzas casi coinciden. ¿Diría entonces que la distinción entre la varianza condicional y la incondicional es irrelevante en la práctica? Argumente a favor y en contra.

Para profundizar:

- Lección 11 (lección 11), sección "Varianza", en particular el párrafo final sobre la varianza incondicional y la descomposición de la varianza (apéndice, sección 1.3).

- Lección 9 (lección 9) para la esperanza condicional como proyección.
- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 2, sección 2.5.

Código completo de la práctica

```
# ------------------------------------------------------------
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# ------------------------------------------------------------

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
↪  directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#    DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
↪  trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

set verbose off

open hprice2.gdt --quiet

ols price const rooms --quiet
scalar beta1_verdadero = $coeff(const)
scalar beta2_verdadero = $coeff(rooms)
scalar sigma   = sqrt($ess/$df)

matrix pob_rooms = {rooms}              # las 506 viviendas: la "poblacion" del regresor
scalar N         = $nobs
scalar var_rooms = sum((rooms-mean(rooms))^2)/N
outfile --quiet preparacion.txt
    printf "Poblacion del regresor (las %d viviendas de hprice2): media = %.4f   varianza = %.4f\n", N,
    ↪  mean(rooms), var_rooms

    set seed 160
    smpl 12 --random                        # doce viviendas elegidas AL AZAR
    scalar Sxx_obs  = sum((rooms-mean(rooms))^2)
    scalar Var_b2_en_X_observada = sigma^2 / Sxx_obs

    printf "\nSubmuestra observada (n = %d):\n", $nobs
    printf "  media(rooms) = %.4f    varianza(rooms) = %.4f\n", mean(rooms),
    ↪  sum((rooms-mean(rooms))^2)/$nobs
    printf "  Sxx de estas %d viviendas (suma de cuadrados en desviaciones) = %.4f\n", $nobs, Sxx_obs
    printf "  Sxx esperado para %d viviendas sorteadas de la poblacion     = %.4f\n", $nobs,
    ↪  ($nobs-1)*var_rooms
    printf "\nVar[b2 | X] en estas %d viviendas (formula de la leccion 11) = %.1f   (error estandar
    ↪  %.1f)\n", $nobs, Var_b2_en_X_observada, sqrt(Var_b2_en_X_observada)
end outfile

scalar R = 4000

set seed 160
loop R --progressive --quiet
    series u = normal(0, sigma)
    series y = beta1_verdadero + beta2_verdadero*rooms + u      # rooms NO cambia
    ols y const rooms --quiet
    scalar b_fijo = $coeff(rooms)
    store "@workdir/repFijo.gdt" b_fijo
endloop
outfile --quiet avisoA.txt
    printf "Hecho: %d replicas con el regresor fijo guardadas en repFijo.gdt\n", R
end outfile
```

```
outfile --quiet unSorteoX.txt
    set seed 160
    matrix idx  = ceil(N * muniform(12,1))      # doce indices entre 1 y 506
    series xnew = pob_rooms[idx]                # doce viviendas de hprice2, con reemplazamiento
    printf "Sxx de las doce viviendas observadas = %.4f\n", Sxx_obs
    printf "Sxx de doce viviendas sorteadas       = %.4f\n", sum((xnew-mean(xnew))^2)
end outfile

set seed 160
loop R --progressive --quiet
    matrix idx  = ceil(N * muniform(12,1))      # doce indices entre 1 y 506
    series xnew = pob_rooms[idx]                # doce viviendas NUEVAS, de hprice2
    series u    = normal(0, sigma)
    series y    = beta1_verdadero + beta2_verdadero*xnew + u
    ols y const xnew --quiet
    scalar b_var = $coeff(xnew)
    scalar Sxx_i = sum((xnew-mean(xnew))^2)     # el Sxx de ESTA replica
    store "@workdir/repVar.gdt" b_var Sxx_i
endloop
outfile --quiet avisoB.txt
    printf "Hecho: %d replicas con regresor nuevo guardadas en repVar.gdt\n", R
end outfile

outfile --quiet comparacion.txt
    printf "=== LO QUE PREDICE LA LECCION 11 (condicional en la X observada) ===\n"
    printf "beta_2 verdadero  = %.2f\n", beta2_verdadero
    printf "Var[b2 | X]       = %.1f\n\n", Var_b2_en_X_observada
end outfile

open "@workdir/repFijo.gdt" --quiet
outfile --quiet comparacionA.txt
    printf "=== EXPERIMENTO A: regresor FIJO ===\n"
    printf "media de b2hat    = %.2f\n", mean(b_fijo)
    printf "varianza de b2hat = %.1f\n\n", sum((b_fijo-mean(b_fijo))^2)/$nobs
end outfile

open "@workdir/repVar.gdt" --quiet
outfile --quiet comparacionB.txt
    printf "=== EXPERIMENTO B: regresor REMUESTREADO en cada replica ===\n"
    printf "media de b2hat    = %.2f\n", mean(b_var)
    printf "varianza de b2hat = %.1f\n", sum((b_var-mean(b_var))^2)/$nobs
    printf "\nSxx a lo largo de las replicas del experimento B:\n"
    printf "  medio = %.4f    minimo = %.4f    maximo = %.4f\n", mean(Sxx_i), min(Sxx_i), max(Sxx_i)
end outfile

open hprice2.gdt --quiet
ols price const rooms --quiet
scalar beta1_verdadero = $coeff(const)
scalar beta2_verdadero = $coeff(rooms)
scalar sigma     = sqrt($ess/$df)
scalar var_rooms = sum((rooms-mean(rooms))^2)/$nobs

set seed 2
smpl 12 --random                        # OTRAS doce viviendas
scalar Sxx_obs2 = sum((rooms-mean(rooms))^2)
scalar Var_b2_en_X_observada2 = sigma^2 / Sxx_obs2
outfile --quiet otrasDoce.txt
    printf "Sxx de estas otras 12 viviendas = %.4f   (esperado %.4f; las doce de la Actividad 1:
    ↪  3,2670)\n", Sxx_obs2, 11*var_rooms
    printf "Var[b2 | X] en estas 12 viviendas (formula de la leccion 11) = %.1f\n", Var_b2_en_X_observada2
end outfile

set seed 160
loop 4000 --progressive --quiet
    series u = normal(0, sigma)
    series y = beta1_verdadero + beta2_verdadero*rooms + u      # rooms NO cambia
```

```
    ols y const rooms --quiet
    scalar b_fijo2 = $coeff(rooms)
    store "@workdir/repFijo2.gdt" b_fijo2
endloop
open "@workdir/repFijo2.gdt" --quiet
outfile --quiet otrasDoceResultado.txt
    printf "=== EXPERIMENTO A con las otras doce viviendas: regresor FIJO ===\n"
    printf "media de b_fijo2    = %.2f\n", mean(b_fijo2)
    printf "varianza de b_fijo2 = %.1f\n", sum((b_fijo2-mean(b_fijo2))^2)/$nobs
end outfile

open hprice2.gdt --quiet
ols price const rooms --quiet
scalar beta1_verdadero = $coeff(const)
scalar beta2_verdadero = $coeff(rooms)
scalar sigma   = sqrt($ess/$df)
matrix pob_rooms = {rooms}
scalar N         = $nobs
scalar var_rooms = sum((rooms-mean(rooms))^2)/N

set seed 160
smpl 400 --random
scalar Sxx_obs  = sum((rooms-mean(rooms))^2)
scalar Var_b2_en_X_observada = sigma^2 / Sxx_obs

set seed 160
loop 40000 --progressive --quiet      # diez veces mas replicas que en la Actividad 2: ver el texto
    series u = normal(0, sigma)
    series y = beta1_verdadero + beta2_verdadero*rooms + u
    ols y const rooms --quiet
    scalar bg_fijo = $coeff(rooms)
    matrix idx  = ceil(N * muniform(400,1))
    series xnew = pob_rooms[idx]
    series u2   = normal(0, sigma)
    series y2   = beta1_verdadero + beta2_verdadero*xnew + u2
    ols y2 const xnew --quiet
    scalar bg_var = $coeff(xnew)
    store "@workdir/repGrande.gdt" bg_fijo bg_var
endloop

outfile --quiet muestraGrande.txt
    printf "Con n = 400:  Sxx observado = %.2f   (esperado: %.2f)\n", Sxx_obs, ($nobs-1)*var_rooms
    printf "             Var[b2|X] en las 400 viviendas observadas = %.2f\n", Var_b2_en_X_observada
    printf "             cociente Sxx observado/esperado = %.3f  <- lo que cabe esperar de var_B/var_A\n",
    ↪  Sxx_obs/(($nobs-1)*var_rooms)
end outfile

open "@workdir/repGrande.gdt" --quiet
outfile --quiet muestraGrandeResultado.txt
    printf "  regresor FIJO         : var = %.2f\n", sum((bg_fijo-mean(bg_fijo))^2)/$nobs
    printf "  regresor REMUESTREADO : var = %.2f\n", sum((bg_var-mean(bg_var))^2)/$nobs
    printf "  cociente observado    : %.3f\n",
    ↪  (sum((bg_var-mean(bg_var))^2))/(sum((bg_fijo-mean(bg_fijo))^2))
end outfile
```

Enlace al guión: S16-Prct-B-condicionar.inp

Respuestas

1. *Las dos preguntas.* El experimento A pregunta: "dadas *estas* doce viviendas, con estos valores concretos de `rooms`, ¿cuánto variaría mi estimación si el azar hubiera repartido otras perturbaciones?". El experimento B pregunta algo más amplio: "¿cuánto variaría mi estimación entre todos los estudios posibles de doce viviendas, considerando que también podrían haber sido otras las viviendas?". La primera toma la muestra de regresores como un dato del problema; la segunda la considera parte de lo que podría haber sido distinto.

2. *Por qué la insesgadez se mantiene.* Porque la demostración de la insesgadez pasa por $E[\hat{\beta}_2 \mid \boldsymbol{X}] = \beta_2$ *1* y después aplica la ley de las esperanzas iteradas: el resultado condicional *no depende de* $\boldsymbol{X}$, es la misma constante sea cual sea la matriz de regresores, y por tanto su promedio sobre todas las $\boldsymbol{X}$ posibles vuelve a ser esa constante. Con la varianza ocurre lo contrario: $Var[\hat{\beta}_2 \mid \boldsymbol{X}] = \sigma^2/\text{Sxx}$ *sí depende* de $\boldsymbol{X}$, así que promediar sobre las $\boldsymbol{X}$ posibles da un número distinto del que corresponde a una $\boldsymbol{X}$ concreta.

3. *Lo que reporta Gretl.* Responde a la pregunta del experimento A: el error estándar se calcula con la matriz de regresores efectivamente observada, sustituyendo σ^2 por su estimación $\mathfrak{s}^2$. Tiene sentido que sea así por dos motivos. Uno práctico: no conocemos la distribución de la que salieron los regresores, así que no podríamos promediar sobre ella aunque quisiéramos. Y otro conceptual: la pregunta que le interesa a quien analiza unos datos es cuánta confianza merece *su* estimación, con *su* muestra, no cuánta merecería en promedio un estudio hipotético que nunca hizo.

4. *Si se pueden elegir los valores del regresor.* La fórmula dice que la varianza es σ^2 dividido por $\sum_i (X_i - \overline{X})^2$. Conviene, por tanto, hacer ese denominador lo más grande posible: elegir dosis muy separadas entre sí, en los extremos del rango admisible, en lugar de concentrarlas en torno a un valor central. Es el mismo principio que hemos visto en sentido contrario en esta práctica: nuestras doce viviendas tenían valores de `rooms` poco dispersos, y eso aumentaba la varianza de la estimación. (Esto supone que el modelo lineal es válido en todo ese rango: separar mucho las dosis mejora la precisión, pero solo si la relación sigue siendo lineal allí.)

5. *¿Es irrelevante con n grande?* A favor de que lo es: numéricamente las dos varianzas se acercan mucho (la diferencia pasa de un 13 % con doce observaciones a un 6 % con cuatrocientas), así que a efectos de calcular un error estándar la distinción cambia poco las cifras. En contra: primero, "n grande" no siempre se tiene, y con muestras pequeñas, que abundan en economía aplicada, la diferencia es la que hemos visto. Segundo, la distinción no es solo numérica, sino conceptual: aclara qué población de muestras estamos imaginando cuando decimos que un estimador "varía". Confundir ambas preguntas lleva a interpretar mal qué significa un error estándar.