Sesión 16 (B) — Condicionar en $\boldsymbol{X}$: la misma fórmula, dos experimentos

Marcos Bujosa

Descripción de la práctica

Qué es condicionar en $\boldsymbol{X}$ ya está definido con precisión: la lección 9 presentó $E[Z \mid \boldsymbol{X}]$ como la proyección ortogonal de Z sobre las funciones de $\boldsymbol{X}$, y la lección 11 trabajó con esa definición. Esta práctica busca otra cosa: la *consecuencia observable* de condicionar, es decir, qué cambia en los números cuando se condiciona y cuando no.

En la práctica A mantuvimos el regresor `rooms` fijo a lo largo de las 2000 réplicas, y solo dejamos cambiar la perturbación. Lo justificamos con una frase: *"eso es lo que significa condicionar en $\boldsymbol{X}$"*. En la imagen de la matriz de copias de la lección 11 (apéndice, sección 3 (html)), condicionar en $\boldsymbol{X}$ no es elegir columnas: es proyectar sobre las funciones de $\boldsymbol{X}$ (lección 9). Mantener el regresor fijo y dejar variar solo la perturbación, bloque de filas a bloque de filas, es la versión experimental de ese condicionamiento.

Esta práctica pone esa frase a prueba haciendo lo contrario. Vamos a repetir el mismo experimento de Montecarlo dos veces:

- *Experimento A*: el regresor se fija una vez y no cambia; solo cambia la perturbación.
- *Experimento B*: en cada réplica se sortea *también* un regresor nuevo.

Si la distinción fuera irrelevante, ambos experimentos darían lo mismo. Veremos que no.
Objetivos

1. Comprobar que la fórmula $Var[\hat{\beta}_2 \mid \boldsymbol{X}] = \sigma^2 / \sum_i (X_i - \overline{X})^2$ describe el experimento A, no el B.
2. Ver qué consecuencia numérica concreta tiene el condicionamiento en $Var[\cdot \mid \boldsymbol{X}]$, que las lecciones 9 y 11 ya definieron con precisión.
3. Ver que la insesgadez, en cambio, se cumple en *ambos* experimentos, y entender por qué las dos propiedades se comportan de forma distinta.
4. Apreciar por qué el resultado que reportan los programas estadísticos es siempre el condicional.

Advertencia de diseño. Para que la diferencia se vea con claridad, trabajaremos con una muestra deliberadamente *pequeña*: doce viviendas. Cuanto mayor es la muestra, menos importa la distinción que queremos ilustrar, y con las 506 observaciones de la práctica A costaría apreciarla. En la última actividad repetiremos el experimento con una muestra grande para comprobar precisamente eso.

Comandos nuevos de esta práctica. Todo el aparato es el de la práctica A: `open`, `ols --quiet` y sus accesores, `loop --progressive`, `store` y la apertura del fichero de réplicas con `open "@workdir/…"`. Lo nuevo:

`smpl 12 --random` elige al azar doce observaciones del conjunto de datos y restringe la muestra a ellas; a partir de ahí `$nobs` vale 12 y las funciones sobre series actúan solo sobre esas doce. Con `set seed` delante, siempre salen las mismas.

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

`sd(x)` desviación típica de una serie, con divisor $n-1$ (sesión 7).

`min(x)`, `max(x)` mínimo y máximo de una serie.

Bloques que empiezan con `open` cuando la salida de una actividad mezcla escalares teóricos y series de réplicas, los `printf` van en bloques distintos: el que calcula sobre las réplicas va precedido de `open "@workdir/…"`, que abre su fichero, y desde esa línea los escalares anteriores ya no existen. Por eso los valores teóricos se imprimen siempre antes.

Actividad 1 - El mismo mundo, pero con doce viviendas

Reutilizamos el mundo artificial de la práctica A (mismos β_1, β_2 y σ), pero nos quedamos solo con doce viviendas, elegidas al azar. Además, anotamos la media y la desviación típica de `rooms` en el conjunto completo: servirán de "población" de la que se sortean regresores nuevos en el experimento B.

Dos bloques. El primero repite el mundo artificial de la práctica A y añade dos escalares, la media y la desviación típica de `rooms` en las 506 viviendas, que servirán de población del regresor. El segundo imprime esa población, restringe la muestra a doce viviendas con `smpl 12 --random` (después de `set seed 160`, para que sean siempre las mismas doce) y calcula sobre ellas `Sxx_obs`, la suma de cuadrados en desviaciones, y `var_cond`, la varianza que predice la lección 11. El «Sxx típico» que también se imprime es $(n-1)$ veces la varianza poblacional del regresor: lo que cabría esperar de doce viviendas cualesquiera.

en línea de comandos:

```
open hprice2.gdt --quiet

ols price const rooms --quiet
scalar b1_true = $coeff(const)
scalar b2_true = $coeff(rooms)
scalar sigma   = sqrt($ess/$df)

scalar mu_r = mean(rooms)              # "poblacion" del regresor
scalar sd_r = sd(rooms)
```

```
printf "Poblacion del regresor: media = %.4f   desv. tipica = %.4f\n", mu_r, sd_r

set seed 160
smpl 12 --random                       # doce viviendas elegidas AL AZAR
scalar Sxx_obs  = sum((rooms-mean(rooms))^2)
scalar var_cond = sigma^2 / Sxx_obs

printf "\nSubmuestra observada (n = %d):\n", $nobs
printf "  media(rooms) = %.4f    desv. tipica(rooms) = %.4f\n", mean(rooms), sd(rooms)
printf "  Sxx = suma de cuadrados en desviaciones = %.4f\n", Sxx_obs
printf "  Sxx tipico de una muestra de este tamano = %.4f\n", ($nobs-1)*sd_r^2
printf "\nVar[b2 | X] que predice la leccion 11 = %.1f   (desv. tipica %.1f)\n", var_cond, sqrt(var_cond)
```

```
Poblacion del regresor: media = 6,2841   desv. tipica = 0,7026

Submuestra observada (n = 12):
  media(rooms) = 6,3917    desv. tipica(rooms) = 0,5450
  Sxx = suma de cuadrados en desviaciones = 3,2670
  Sxx tipico de una muestra de este tamano = 5,4300

Var[b2 | X] que predice la leccion 11 = 13417907,5   (desv. tipica 3663,0)
```

Recuerde que `Sxx` es la abreviatura que introdujimos en la práctica A para $\sum_i (x_i - \mu_{\boldsymbol{x}})^2$: el cuadrado de la norma euclídea del vector en desviaciones del regresor, o equivalentemente $n\,\sigma^2_{\boldsymbol{x}}$ (evaluada sobre la muestra aleatoria, $n\,S^2 = \sum_i (X_i - \overline{X})^2$, lección 11). No es notación del curso, solo una comodidad para los guiones.

Dos detalles del código merecen comentario. El primero es `smpl 12 --random`: elegimos las doce viviendas *al azar*, en lugar de tomar las doce primeras. Es importante, porque `hprice2` viene ordenado por distritos censales y las primeras viviendas se parecen mucho entre sí; tomarlas directamente nos daría una submuestra

atípica por un motivo ajeno a lo que queremos estudiar. El segundo es `set seed`, que fija *qué* doce viviendas salen, para que el resultado sea reproducible.

Una cifra de la salida necesita explicación: el «Sxx típico de una muestra de este tamaño», $(n-1)\,\mathrm{sd}_r^2$. La función `sd` de Gretl divide por $n-1$, así que sd_r^2 es la cuasivarianza de `rooms` en las 506 viviendas, y $(n-1)\,\mathrm{sd}_r^2$ es la suma de cuadrados en desviaciones que tendría, en promedio, una muestra de n viviendas sorteadas de esa población (es la esperanza de $\sum_i (X_i - \overline{X})^2$, con la regla de su curso de Estadística para la cuasivarianza). Es el patrón con el que vamos a comparar el Sxx de las doce viviendas que nos han tocado.

Lo que debe observar

Tres cifras. La primera, el Sxx de nuestras doce viviendas, 3,27, frente al típico de doce viviendas cualesquiera, 5,43: las doce que han salido tienen valores de `rooms` menos dispersos de lo habitual (desviación típica 0,545 frente a 0,703 en las 506). La segunda, la varianza que la lección 11 predice para esta muestra, unos 13,4 millones, es decir, una desviación típica de 3663 dólares por habitación para una pendiente verdadera de 9120: con doce viviendas la estimación es muy imprecisa, y esa imprecisión es lo que hace visible la diferencia que buscamos. Guarde la primera comparación, 3,27 frente a 5,43: explica el signo de todo lo que sigue.

Actividad 2 - Experimento A: el regresor se queda quieto

Es el experimento de la práctica A sin más cambio que el tamaño muestral: las doce viviendas en lugar de las 506. Cada vuelta sortea la perturbación, construye `y`, estima con `ols --quiet` y guarda el coeficiente `b_fijo` como una fila más de `repFijo.gdt`. Usamos `R = 4000` réplicas, el doble que en la práctica A: la varianza empírica de R réplicas tiene su propio error de Montecarlo, del orden de $\sqrt{2/R}$ en términos relativos (un 3 % con 2000, un 2 % con 4000), y queremos que sea pequeño frente a la diferencia entre los dos experimentos, que resultará ser mucho mayor.

en línea de comandos:

```
scalar R = 4000

set seed 160
loop R --progressive --quiet
    series u = normal(0, sigma)
    series y = b1_true + b2_true*rooms + u      # rooms NO cambia
    ols y const rooms --quiet
    scalar b_fijo = $coeff(rooms)
    store "@workdir/repFijo.gdt" b_fijo
endloop
```

```
printf "Hecho: %d replicas con el regresor fijo guardadas en repFijo.gdt\n", R
```

```
Hecho: 4000 replicas con el regresor fijo guardadas en repFijo.gdt
```

Todavía no miramos las estimaciones: las compararemos en la actividad 4 junto a las del experimento B. Lo que tenemos ahora es un fichero con 4000 estimaciones de β_2, todas obtenidas con las *mismas* doce viviendas y distintas perturbaciones.

Actividad 3 - Experimento B: el regresor también se sortea

Ahora decimos "no solo podría haber sido otra la perturbación; también podrían haber sido otras las doce viviendas". Para eso hace falta una población de la que sortear viviendas nuevas, y no tenemos más que las 506 de `hprice2`. La solución más simple es quedarse con su media y su desviación típica, $\mu_r = 6{,}28$ y $\mathrm{sd}_r = 0{,}70$, y sortear de una normal con esos dos números: `mu_r + sd_r*normal(0,1)` son doce sorteos de

una normal estándar reescalados a la media y la dispersión del regresor real. No pretende ser el mecanismo que genera las viviendas de Boston; solo fabrica "otras doce viviendas" con la dispersión típica de las reales.

Antes de meterlo en un bucle, un solo sorteo, para ver qué cambia. El bloque sortea un `xnew`, calcula su Sxx y lo imprime junto al de las doce viviendas observadas.

en línea de comandos:

```
set seed 160
series xnew = mu_r + sd_r*normal(0,1)       # doce viviendas NUEVAS
printf "Sxx de las doce viviendas observadas = %.4f\n", Sxx_obs
printf "Sxx de doce viviendas sorteadas       = %.4f\n", sum((xnew-mean(xnew))^2)
```

```
Sxx de las doce viviendas observadas = 3,2670
Sxx de doce viviendas sorteadas       = 3,1687
```

El Sxx de las doce viviendas sorteadas no coincide con el de las observadas, y en otro sorteo saldría otro. Eso es lo que el experimento B añade: en cada réplica, además de la perturbación, cambia el regresor y con él su Sxx. En el código del bucle la línea nueva es la primera; después `y` se construye con `xnew`, la regresión se estima sobre `xnew`, y `store` guarda dos escalares por réplica en `repVar.gdt`: el coeficiente `b_var` y `Sxx_i`, la suma de cuadrados en desviaciones del regresor *de esa réplica*. En el experimento A ese número era una constante, 3,27; aquí es una variable aleatoria más, y en ella está la diferencia entre los dos experimentos.

en línea de comandos:

```
set seed 160
loop R --progressive --quiet
    series xnew = mu_r + sd_r*normal(0,1)       # doce viviendas NUEVAS
    series u    = normal(0, sigma)
    series y    = b1_true + b2_true*xnew + u
    ols y const xnew --quiet
    scalar b_var = $coeff(xnew)
    scalar Sxx_i = sum((xnew-mean(xnew))^2)     # el Sxx de ESTA replica
    store "@workdir/repVar.gdt" b_var Sxx_i
endloop
```

```
printf "Hecho: %d replicas con regresor nuevo guardadas en repVar.gdt\n", R
```

```
Hecho: 4000 replicas con regresor nuevo guardadas en repVar.gdt
```

Actividad 4 - Las dos varianzas, cara a cara

Ya tenemos los dos ficheros de réplicas. Ahora ponemos cara a cara tres cosas: lo que predice la lección 11 para nuestras doce viviendas, lo que ha salido con el regresor fijo y lo que ha salido con el regresor sorteado. Tres bloques, cada uno con su salida. El primero imprime la predicción con los escalares que todavía tenemos. El segundo va precedido de `AbrirRepFijo`, que abre `repFijo.gdt` (y borra los escalares, por eso la predicción se imprime antes), y calcula la media y la varianza, con divisor n, de `b_fijo`. El tercero va precedido de `AbrirRepVar`, hace lo mismo con `b_var` y añade, con `mean`, `min` y `max`, cuánto ha variado `Sxx_i` de una réplica a otra.

en línea de comandos:

```
printf "=== LO QUE PREDICE LA LECCION 11 (condicional en la X observada) ===\n"
printf "beta_2 verdadero  = %.2f\n", b2_true
printf "Var[b2 | X]       = %.1f\n\n", var_cond
```

```
=== LO QUE PREDICE LA LECCION 11 (condicional en la X observada) ===
beta_2 verdadero  = 9119,55
Var[b2 | X]       = 13417907,5
```

```
open "@workdir/repFijo.gdt" --quiet
```

```
printf "=== EXPERIMENTO A: regresor FIJO ===\n"
printf "media de b2hat    = %.2f\n", mean(b_fijo)
printf "varianza de b2hat = %.1f\n\n", sum((b_fijo-mean(b_fijo))^2)/$nobs
```

```
=== EXPERIMENTO A: regresor FIJO ===
media de b2hat    = 9061,70
varianza de b2hat = 13168607,8
```

```
open "@workdir/repVar.gdt" --quiet
```

```
printf "=== EXPERIMENTO B: regresor REGENERADO en cada replica ===\n"
printf "media de b2hat    = %.2f\n", mean(b_var)
printf "varianza de b2hat = %.1f\n", sum((b_var-mean(b_var))^2)/$nobs
printf "\nSxx a lo largo de las replicas del experimento B:\n"
printf "  medio = %.4f    minimo = %.4f    maximo = %.4f\n", mean(Sxx_i), min(Sxx_i), max(Sxx_i)
```

```
=== EXPERIMENTO B: regresor REGENERADO en cada replica ===
media de b2hat    = 9125,59
varianza de b2hat = 9747173,3

Sxx a lo largo de las replicas del experimento B:
  medio = 5,4482    minimo = 0,7178    maximo = 19,0432
```

Lo que debe observar

Tres hechos, en este orden, con las cifras de las salidas:

1. *El experimento A reproduce la fórmula.* Con el regresor fijo, la varianza empírica de las 4000 estimaciones es 13,17 millones; la lección 11 predecía 13,42 millones con el Sxx de *nuestras doce viviendas*. La diferencia, un 2 %, es el error de Montecarlo. La fórmula de la lección 11 describe este experimento.

2. *El experimento B da otro resultado.* Con el regresor sorteado en cada réplica, la varianza es 9,75 millones, un 27 % menor. No es error de Montecarlo: los dos experimentos responden a preguntas distintas.

3. *Las medias, en cambio, coinciden.* 9062 en A y 9126 en B, frente a un β_2 verdadero de 9120. La media de 4000 réplicas con desviación típica 3600 tiene un error del orden de $3600/\sqrt{4000} \approx 57$, así que las dos están donde deben. La insesgadez se cumple en los dos diseños; la fórmula de la varianza, no.

De dónde viene la diferencia

Mire la última línea de la salida: a lo largo de las réplicas del experimento B, `Sxx_i` ha ido de 0,72 a 19,04, con un promedio de 5,45, que es el Sxx típico de la actividad 1. En el experimento A valía siempre 3,27.

En el experimento A la varianza de $\hat{\beta}_2$ es σ^2 dividido por *un número fijo*. En el experimento B es, en promedio, σ^2 multiplicado por el promedio de 1/Sxx, y el promedio de un cociente no es el cociente de los promedios. Si nuestras doce viviendas concretas resultan tener valores de `rooms` menos dispersos de lo

habitual, su Sxx será menor que el típico y, en consecuencia, condicionar en ellas dará una varianza *mayor* que la que resulta de promediar sobre todos los conjuntos posibles de doce viviendas. Si hubieran salido más dispersas, ocurriría lo contrario.

Esta es la razón por la que la lección 11 se detuvo en la fórmula condicional y solo mencionó brevemente la incondicional: al intentar calcular $\mathrm{Var}(\hat{\beta}_2)$ aparecía $\mathrm{E}\big(\sigma^2/(nS^2)\big)$, la esperanza de un cociente, que no se simplifica.

Actividad 5 - ¿Y si la muestra fuera grande?

Repetimos el experimento con cuatrocientas viviendas en lugar de doce, dejando todo lo demás igual. La pregunta es si la diferencia entre los dos experimentos sobrevive cuando la muestra es grande, y en qué sentido: la actividad 4 ha dicho que el signo de la diferencia depende de si nuestra muestra concreta está más o menos dispersa que lo típico, y con cuatrocientas viviendas esa comparación puede salir al revés.

Dos cambios respecto a la actividad 4 merecen explicación. El primero: los dos experimentos van en *un solo* bucle, que en cada vuelta estima primero con `rooms` fijo (coeficiente `bg_fijo`) y después con un regresor nuevo `xnew` y una perturbación nueva `u2` (coeficiente `bg_var`); así las dos series de réplicas tienen el mismo número de vueltas y la misma semilla, y el cociente entre sus varianzas no depende de eso. El segundo: 40 000 réplicas en lugar de 4 000. Con cuatrocientas viviendas el efecto que buscamos es pequeño, en torno a un 4,5 %, y con 4 000 réplicas el error de Montecarlo de un cociente de varianzas supera el 3 %: repitiendo el experimento con distintas semillas, el cociente oscilaba entre 1,00 y 1,08, y con algunas semillas el efecto parecía desaparecer. Con 40 000 se estabiliza por encima de uno. El coste son unos segundos más. Un experimento simulado tiene su propia precisión, y conviene asegurarse de que es mejor que el efecto que se quiere ver.

Cuatro bloques. El primero reabre `hprice2` y recupera los escalares (se perdieron al abrir los ficheros de réplicas), toma cuatrocientas viviendas con `smpl 400 --random` y ejecuta el bucle; `store` guarda los dos coeficientes por réplica en `repGrande.gdt`. El segundo imprime las cifras teóricas, entre ellas el cociente entre el Sxx observado y el típico, que es lo que cabe esperar del cociente entre las dos varianzas. El tercero, `AbrirRepGrande`, abre `repGrande.gdt`, y el cuarto imprime las dos varianzas empíricas y su cociente.

en línea de comandos:

```
open hprice2.gdt --quiet
ols price const rooms --quiet
scalar b1_true = $coeff(const)
scalar b2_true = $coeff(rooms)
scalar sigma   = sqrt($ess/$df)
scalar mu_r = mean(rooms)
scalar sd_r = sd(rooms)

set seed 160
smpl 400 --random
scalar Sxx_obs  = sum((rooms-mean(rooms))^2)
scalar var_cond = sigma^2 / Sxx_obs

set seed 160
loop 40000 --progressive --quiet      # diez veces mas replicas: ver nota
    series u = normal(0, sigma)
    series y = b1_true + b2_true*rooms + u
    ols y const rooms --quiet
    scalar bg_fijo = $coeff(rooms)
    series xnew = mu_r + sd_r*normal(0,1)
    series u2   = normal(0, sigma)
    series y2   = b1_true + b2_true*xnew + u2
    ols y2 const xnew --quiet
    scalar bg_var = $coeff(xnew)
    store "@workdir/repGrande.gdt" bg_fijo bg_var
endloop
```

```
printf "Con n = 400:  Sxx observado = %.2f   (tipico: %.2f)\n", Sxx_obs, ($nobs-1)*sd_r^2
printf "             Var[b2|X] condicional teorica = %.2f\n", var_cond
printf "             cociente Sxx observado/tipico = %.3f  <- lo que cabe esperar de var_B/var_A\n",
↪  Sxx_obs/(($nobs-1)*sd_r^2)
```

```
Con n = 400:  Sxx observado = 205,76   (tipico: 196,96)
              Var[b2|X] condicional teorica = 213046,34
              cociente Sxx observado/tipico = 1,045  <- lo que cabe esperar de var_B/var_A
```

```
open "@workdir/repGrande.gdt" --quiet
```

```
printf "  regresor FIJO       : var = %.2f\n", sum((bg_fijo-mean(bg_fijo))^2)/$nobs
printf "  regresor REGENERADO : var = %.2f\n", sum((bg_var-mean(bg_var))^2)/$nobs
printf "  cociente observado  : %.3f\n", (sum((bg_var-mean(bg_var))^2))/(sum((bg_fijo-mean(bg_fijo))^2))
```

```
  regresor FIJO       : var = 214203,96
  regresor REGENERADO : var = 224464,19
  cociente observado  : 1,048
```

Lo que debe observar

Lo primero que conviene mirar no es el tamaño de la diferencia, sino su *signo*.

Con doce viviendas, la varianza del experimento B salía **menor** que la del A. Con cuatrocientas sale **mayor**. Es la confirmación del mecanismo que explicamos en la Actividad 4. Allí dijimos que todo dependía de si nuestra muestra concreta tenía un Sxx más pequeño o más grande que el típico, y añadimos: "si hubieran salido más dispersas, ocurriría lo contrario". Compruébelo en las salidas:

- *Doce viviendas*: Sxx observado = 3,27 frente a un típico de 5,43. Nuestra muestra estaba **poco dispersa**, condicionar en ella daba una varianza mayor que el promedio, y por eso B quedaba por debajo de A.
- *Cuatrocientas viviendas*: Sxx observado = 205,76 frente a un típico de 196,96. Ahora la muestra está, ligeramente, **más dispersa** de lo típico; condicionar en ella da una varianza menor que el promedio, y B queda por encima de A.

El cambio de signo es la predicción cumplida. Y descarta una conclusión falsa que sería fácil extraer de la Actividad 4, "condicionar infla la varianza": condicionar no la aumenta ni la reduce sistemáticamente, la *ajusta a la muestra que tenemos*, y hacia qué lado la ajuste depende de cómo sea esa muestra.

En cuanto al tamaño, la diferencia *se reduce mucho* al pasar de doce a cuatrocientas observaciones, pero no llega a desaparecer. Conviene entender por qué, porque en esa distinción hay dos efectos superpuestos:

1. *Nuestra muestra deja de ser excepcional.* Con doce viviendas, el Sxx de la muestra observada podía quedar muy lejos del típico; con cuatrocientas, cualquier muestra tiene un Sxx bastante parecido al típico. Este efecto se atenúa al crecer n, pero lentamente.
2. *El promedio de un cociente no es el cociente de los promedios.* Aunque el Sxx medio coincidiera con el observado, promediar σ^2/Sxx sobre las réplicas no daría σ^2 dividido por el Sxx medio. Este segundo efecto también se atenúa con n, y más deprisa que el primero.

Con $n = 400$ el segundo efecto ya es prácticamente inapreciable, y todo lo que queda es el primero. Eso se puede comprobar con las cifras de la salida: el cociente de varianzas que observamos debería parecerse al cociente Sxx observado/típico, que la salida imprime, y en efecto se le parece.

La conclusión práctica es que con muestras grandes la distinción tiene poca consecuencia numérica. La conclusión conceptual, en cambio, no cambia en absoluto: siguen siendo dos preguntas distintas, y la que responde la fórmula de la lección 11, y también su programa estadístico, es siempre la condicional.

Preguntas de interpretación para la clase

1. ¿Qué pregunta responde el experimento A y qué pregunta, distinta, responde el experimento B? Formule ambas con palabras, sin fórmulas.

2. ¿Por qué la insesgadez se cumple en los dos experimentos, mientras que la fórmula de la varianza solo describe el primero? (Pista: ¿en qué paso de la demostración de la lección 11 interviene $\boldsymbol{X}$ de forma esencial?)

3. Cuando Gretl le muestra el error estándar de un coeficiente, ¿está respondiendo a la pregunta del experimento A o a la del B? ¿Por qué cree que es así?

4. Imagine que un investigador *diseña* el experimento y puede elegir los valores del regresor (por ejemplo, las dosis en un ensayo). A la vista de la fórmula de la lección 11, ¿qué le convendría hacer con esas dosis?

5. En la Actividad 5, con $n = 400$, las dos varianzas casi coinciden. ¿Diría entonces que la distinción entre condicionar y no condicionar es irrelevante en la práctica? Argumente a favor y en contra.

Para profundizar:

- Lección 11 (lección 11), sección "Varianza", en particular el párrafo final sobre la varianza incondicional y la ley de la varianza total.
- Lección 9 (lección 9) para la esperanza condicional como proyección.
- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 2, sección 2.5.

Código completo de la práctica

```
# ------------------------------------------------------------
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# ------------------------------------------------------------

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
↪  directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#    DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
↪  trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

set verbose off

open hprice2.gdt --quiet

ols price const rooms --quiet
scalar b1_true = $coeff(const)
scalar b2_true = $coeff(rooms)
scalar sigma   = sqrt($ess/$df)

scalar mu_r = mean(rooms)               # "poblacion" del regresor
scalar sd_r = sd(rooms)
outfile --quiet preparacion.txt
    printf "Poblacion del regresor: media = %.4f   desv. tipica = %.4f\n", mu_r, sd_r

    set seed 160
    smpl 12 --random                        # doce viviendas elegidas AL AZAR
    scalar Sxx_obs  = sum((rooms-mean(rooms))^2)
    scalar var_cond = sigma^2 / Sxx_obs

    printf "\nSubmuestra observada (n = %d):\n", $nobs
    printf "  media(rooms) = %.4f    desv. tipica(rooms) = %.4f\n", mean(rooms), sd(rooms)
    printf "  Sxx = suma de cuadrados en desviaciones = %.4f\n", Sxx_obs
    printf "  Sxx tipico de una muestra de este tamano = %.4f\n", ($nobs-1)*sd_r^2
    printf "\nVar[b2 | X] que predice la leccion 11 = %.1f   (desv. tipica %.1f)\n", var_cond,
    ↪  sqrt(var_cond)
end outfile

scalar R = 4000

set seed 160
loop R --progressive --quiet
    series u = normal(0, sigma)
    series y = b1_true + b2_true*rooms + u      # rooms NO cambia
    ols y const rooms --quiet
    scalar b_fijo = $coeff(rooms)
    store "@workdir/repFijo.gdt" b_fijo
endloop
outfile --quiet avisoA.txt
    printf "Hecho: %d replicas con el regresor fijo guardadas en repFijo.gdt\n", R
end outfile

outfile --quiet unSorteoX.txt
    set seed 160
    series xnew = mu_r + sd_r*normal(0,1)       # doce viviendas NUEVAS
```

```
    printf "Sxx de las doce viviendas observadas = %.4f\n", Sxx_obs
    printf "Sxx de doce viviendas sorteadas       = %.4f\n", sum((xnew-mean(xnew))^2)
end outfile

set seed 160
loop R --progressive --quiet
    series xnew = mu_r + sd_r*normal(0,1)       # doce viviendas NUEVAS
    series u    = normal(0, sigma)
    series y    = b1_true + b2_true*xnew + u
    ols y const xnew --quiet
    scalar b_var = $coeff(xnew)
    scalar Sxx_i = sum((xnew-mean(xnew))^2)     # el Sxx de ESTA replica
    store "@workdir/repVar.gdt" b_var Sxx_i
endloop
outfile --quiet avisoB.txt
    printf "Hecho: %d replicas con regresor nuevo guardadas en repVar.gdt\n", R
end outfile

outfile --quiet comparacion.txt
    printf "=== LO QUE PREDICE LA LECCION 11 (condicional en la X observada) ===\n"
    printf "beta_2 verdadero  = %.2f\n", b2_true
    printf "Var[b2 | X]       = %.1f\n\n", var_cond
end outfile

open "@workdir/repFijo.gdt" --quiet
outfile --quiet comparacionA.txt
    printf "=== EXPERIMENTO A: regresor FIJO ===\n"
    printf "media de b2hat    = %.2f\n", mean(b_fijo)
    printf "varianza de b2hat = %.1f\n\n", sum((b_fijo-mean(b_fijo))^2)/$nobs
end outfile

open "@workdir/repVar.gdt" --quiet
outfile --quiet comparacionB.txt
    printf "=== EXPERIMENTO B: regresor REGENERADO en cada replica ===\n"
    printf "media de b2hat    = %.2f\n", mean(b_var)
    printf "varianza de b2hat = %.1f\n", sum((b_var-mean(b_var))^2)/$nobs
    printf "\nSxx a lo largo de las replicas del experimento B:\n"
    printf "  medio = %.4f    minimo = %.4f    maximo = %.4f\n", mean(Sxx_i), min(Sxx_i), max(Sxx_i)
end outfile

open hprice2.gdt --quiet
ols price const rooms --quiet
scalar b1_true = $coeff(const)
scalar b2_true = $coeff(rooms)
scalar sigma   = sqrt($ess/$df)
scalar mu_r = mean(rooms)
scalar sd_r = sd(rooms)

set seed 160
smpl 400 --random
scalar Sxx_obs  = sum((rooms-mean(rooms))^2)
scalar var_cond = sigma^2 / Sxx_obs

set seed 160
loop 40000 --progressive --quiet      # diez veces mas replicas: ver nota
    series u = normal(0, sigma)
    series y = b1_true + b2_true*rooms + u
    ols y const rooms --quiet
    scalar bg_fijo = $coeff(rooms)
    series xnew = mu_r + sd_r*normal(0,1)
    series u2   = normal(0, sigma)
    series y2   = b1_true + b2_true*xnew + u2
    ols y2 const xnew --quiet
    scalar bg_var = $coeff(xnew)
    store "@workdir/repGrande.gdt" bg_fijo bg_var
endloop
```

```
outfile --quiet muestraGrande.txt
    printf "Con n = 400:  Sxx observado = %.2f   (tipico: %.2f)\n", Sxx_obs, ($nobs-1)*sd_r^2
    printf "             Var[b2|X] condicional teorica = %.2f\n", var_cond
    printf "             cociente Sxx observado/tipico = %.3f  <- lo que cabe esperar de var_B/var_A\n",
    ↪  Sxx_obs/(($nobs-1)*sd_r^2)
end outfile

open "@workdir/repGrande.gdt" --quiet
outfile --quiet muestraGrandeResultado.txt
    printf "  regresor FIJO       : var = %.2f\n", sum((bg_fijo-mean(bg_fijo))^2)/$nobs
    printf "  regresor REGENERADO : var = %.2f\n", sum((bg_var-mean(bg_var))^2)/$nobs
    printf "  cociente observado  : %.3f\n",
    ↪  (sum((bg_var-mean(bg_var))^2))/(sum((bg_fijo-mean(bg_fijo))^2))
end outfile
```

Enlace al guión: S16-Prct-B-condicionar.inp

Respuestas

1. *Las dos preguntas.* El experimento A pregunta: "dadas *estas* doce viviendas, con estos valores concretos de `rooms`, ¿cuánto variaría mi estimación si el azar hubiera repartido otras perturbaciones?". El experimento B pregunta algo más amplio: "¿cuánto variaría mi estimación entre todos los estudios posibles de doce viviendas, considerando que también podrían haber sido otras las viviendas?". La primera toma la muestra de regresores como un dato del problema; la segunda la considera parte de lo que podría haber sido distinto.

2. *Por qué la insesgadez se mantiene.* Porque la demostración de la insesgadez pasa por $E[\hat{\beta}_2 \mid \boldsymbol{X}] = \beta_2$ *1* y después aplica la ley de las esperanzas iteradas: el resultado condicional *no depende de* $\boldsymbol{X}$, es la misma constante sea cual sea la matriz de regresores, y por tanto su promedio sobre todas las $\boldsymbol{X}$ posibles vuelve a ser esa constante. Con la varianza ocurre lo contrario: $Var[\hat{\beta}_2 \mid \boldsymbol{X}] = \sigma^2/\text{Sxx}$ *sí depende* de $\boldsymbol{X}$, así que promediar sobre las $\boldsymbol{X}$ posibles da un número distinto del que corresponde a una $\boldsymbol{X}$ concreta.

3. *Lo que reporta Gretl.* Responde a la pregunta del experimento A: el error estándar se calcula con la matriz de regresores efectivamente observada, sustituyendo σ^2 por su estimación $\mathfrak{s}^2$. Tiene sentido que sea así por dos motivos. Uno práctico: no conocemos la distribución de la que salieron los regresores, así que no podríamos promediar sobre ella aunque quisiéramos. Y otro conceptual: la pregunta que le interesa a quien analiza unos datos es cuánta confianza merece *su* estimación, con *su* muestra, no cuánta merecería en promedio un estudio hipotético que nunca hizo.

4. *Si se pueden elegir los valores del regresor.* La fórmula dice que la varianza es σ^2 dividido por $\sum_i (X_i - \overline{X})^2$. Conviene, por tanto, hacer ese denominador lo más grande posible: elegir dosis muy separadas entre sí, en los extremos del rango admisible, en lugar de concentrarlas en torno a un valor central. Es el mismo principio que hemos visto en sentido contrario en esta práctica: nuestras doce viviendas tenían valores de `rooms` poco dispersos, y eso aumentaba la varianza de la estimación. (Naturalmente, esto supone que el modelo lineal es válido en todo ese rango: separar mucho las dosis mejora la precisión, pero solo si la relación sigue siendo lineal allí.)

5. *¿Es irrelevante con n grande?* A favor de que lo es: numéricamente las dos varianzas se acercan mucho (la diferencia pasa de ser enorme con doce observaciones a ser modesta con cuatrocientas), así que a efectos de calcular un error estándar la distinción cambia poco las cifras. En contra: primero, "n grande" no siempre se tiene, y con muestras pequeñas, que abundan en economía aplicada, la diferencia es la que hemos visto. Segundo, la distinción no es solo numérica, sino conceptual: aclara qué población de muestras estamos imaginando cuando decimos que un estimador "varía". Confundir ambas preguntas lleva a interpretar mal qué significa exactamente un error estándar.