

Sesión 22 (A) — Dos regresores cada vez más alineados: un experimento de Monte Carlo

Marcos Bujosa

Descripción de la práctica

La lección 14 dijo que el error estándar de $\hat{\beta}_j$ es s dividido por la longitud de la parte propia del regresor, y que esa longitud se encoge con el ángulo entre el regresor y los demás: $\|\tilde{\mathbf{x}}_j\|_e = \|\mathbf{x}_j - \mu_{\mathbf{x}_j} \mathbf{1}\|_e \sin \theta_j$. Con dos regresores no constantes, $\sin^2 \theta = 1 - \rho^2$ y la varianza del estimador se multiplica por $\text{VIF} = 1/(1 - \rho^2)$. Esta práctica lo comprueba repitiendo: construimos dos regresores con una correlación elegida, sorteamos la perturbación dos mil veces y miramos cuánto oscilan las estimaciones.

El mundo artificial tiene $n = 100$, $y = 1 + x_2 + x_3 + u$ con u normal de desviación típica 1, y cuatro versiones del par de regresores: $\rho = 0; 0,9; 0,99$ y $0,999$. Los regresores están fijos dentro de cada experimento; lo único que cambia de una réplica a otra es u . Un detalle de construcción: $\mathbf{x}_3 = \rho \mathbf{z}_1 + \sqrt{1 - \rho^2} \mathbf{z}_2$ con $\mathbf{x}_2 = \mathbf{z}_1$, así que el subespacio generado por $\mathbf{1}$, $\mathbf{x}_2$ y $\mathbf{x}_3$ es *el mismo* para los cuatro valores de ρ . Lo que cambia es el ángulo entre los generadores, no el plano que generan.

Objetivos

1. Comprobar que la varianza empírica de $\hat{\beta}_2$ crece como el VIF, y que coincide con $\sigma^2 / \|\tilde{\mathbf{x}}_2\|_e^2$.
2. Ver que la SRC no cambia con ρ : el ajuste es el mismo punto, y solo cambian sus coordenadas.
3. Ver que $\hat{\beta}_2$ y $\hat{\beta}_3$ oscilan *juntos y al revés*: covarianza negativa, y suma $\hat{\beta}_2 + \hat{\beta}_3$ tan estable como lo era $\hat{\beta}_2$ sin colinealidad.
4. Ver cómo un efecto verdadero deja de ser significativo cuando el regresor pierde parte propia.

Comandos nuevos de esta práctica. Seguimos con `nulldata`, `set seed`, `normal()`, `series` y `scalar` (sesión 7), `ols` con `--quiet` y los accesorios `$ess`, `$coeff` y `$stderr` (sesiones 11 a 18), las matrices y `mcov` (práctica A de la sesión 16) y `critical` (sesión 18). Lo nuevo:

`zeros(R, 2)` crea una matriz de R filas y 2 columnas llena de ceros, para ir guardando en ella un resultado por réplica.

`B[i,] = {a, b}` escribe la fila i de la matriz B ; entre llaves, los dos valores que la rellenan. Al revés, `B0[,1]` es la primera columna entera de $B0$.

`loop i=1..R` repite el bloque hasta `endloop` con el índice i tomando los valores $1, 2, \dots, R$ (en la sesión 11 lo usamos con cuatro vueltas). Aquí hay dos bucles, uno dentro de otro: el exterior recorre las cuatro correlaciones y el interior las réplicas.

`rhos[j]` y `meanc(S[,1])` el elemento j de un vector, y la media de la primera columna de una matriz.

`mcov(B)` matriz de varianzas y covarianzas de las columnas de B , tratando cada columna como una variable y cada fila como una observación (divisor $n - 1$). `V[1,1]` es la varianza de la primera columna y `V[1,2]` la covarianza entre las dos.

`series b = B0[,1]` convierte una columna de una matriz en una serie del conjunto de datos, para poder dibujarla con `freq` y `gnuplot`. El conjunto tiene que tener tantas observaciones como filas la matriz: de ahí el `nulldata R --preserve` previo, con `--preserve` para no perder las matrices.

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

Actividad 1 - Cuatro experimentos, una tabla

Para cada ρ : genere los regresores, mida la parte propia de $\mathbf{x}_2$ con la regresión auxiliar, y repita 2000 veces la estimación guardando $\hat{\beta}_2$, $\hat{\beta}_3$, la SRC y el R^2 . Después resuma: varianza empírica de $\hat{\beta}_2$ frente a la teórica, covarianza, varianza de la suma, y fracción de réplicas en que el t de $\mathbf{x}_2$ supera t_c .

Léalo en tres partes. *Preparación*: un conjunto de 100 observaciones, los coeficientes verdaderos b_1 , b_2 y b_3 (los tres valen 1), la desviación típica del ruido sig , el número de réplicas R , el valor crítico t_c de la t con $n - 3$ grados de libertad (sesión 18) y el vector rhos con las cuatro correlaciones que se van a probar; el primer `printf` imprime la cabecera de la tabla. *Los regresores*: el bucle exterior, `loop j=1..4`, toma en cada vuelta un ρ de rhos ($\text{rhos}[j]$ es su elemento j) y, con la semilla fija, sortea $\mathbf{z}_1$ y $\mathbf{z}_2$, dos normales estándar independientes; $\mathbf{x}_2$ es $\mathbf{z}_1$ y $\mathbf{x}_3$ es la combinación $\rho\mathbf{z}_1 + \sqrt{1 - \rho^2}\mathbf{z}_2$, que tiene correlación ρ con $\mathbf{x}_2$. La regresión auxiliar `ols x2 const x3 --quiet` deja en $\$ess$ la longitud al cuadrado de la parte propia de $\mathbf{x}_2$, y varTeorica es σ^2 dividido por ella. *Las réplicas*: se fija otra semilla para el ruido y el bucle interior, en cada vuelta, sortea $\mathbf{u}$, construye $\mathbf{y}$ con los coeficientes verdaderos, estima por MCO, guarda los dos coeficientes en la fila i de $\mathbf{B}$ y la SRC y el R^2 en la fila i de $\mathbf{S}$, y suma un 1 a `signif` cuando el $|t|$ de $\mathbf{x}_2$ supera t_c (`signif + ...=`). Al salir del bucle interior, `mcov(B)` da la varianza empírica de $\hat{\beta}_2$ y su covarianza con $\hat{\beta}_3$, `meanc` promedia cada columna de $\mathbf{S}$, y el `printf` imprime la fila de la tabla. Los regresores no cambian dentro del bucle interior: solo cambia $\mathbf{u}$. Las últimas líneas guardan en $\mathbf{B}_0$ y $\mathbf{B}_{99}$ las réplicas con $\rho = 0$ y con $\rho = 0,99$ para la Actividad 2 (`if`, `elif` y `endif`: sesión 7).

en línea de comandos:

```

nulldata 100
scalar n      = $nobs
scalar b1     = 1
scalar b2     = 1
scalar b3     = 1
scalar sig    = 1
scalar R      = 2000
scalar tc     = critical(t, n-3, 0.025)
matrix rhos   = {0, 0.9, 0.99, 0.999}
printf "%7s %8s %8s %10s %10s %10s %10s %8s %8s %8s\n", "rho", "corr", "VIF", "var(b2)", "teorica", "cov(b2,b3)",
↪ "var(b2+b3)", "SRC", "R2", "%|t|>tc"
loop j=1..4 --quiet
    scalar rho = rhos[j]
    set seed 2026
    series z1 = normal()
    series z2 = normal()
    series x2 = z1
    series x3 = rho*z1 + sqrt(1-rho^2)*z2
    ols x2 const x3 --quiet
    scalar longPropia2 = sqrt($ess)                # // parte propia de x2 //
    scalar varTeorica  = sig^2/longPropia2^2        # sigma^2 / ||x2 propia||^2
    matrix B = zeros(R, 2)
    matrix S = zeros(R, 2)
    scalar signif = 0
    set seed 20261120
    loop i=1..R --quiet
        series u = normal(0, sig)
        series y = b1 + b2*x2 + b3*x3 + u
        ols y const x2 x3 --quiet
        B[i,] = {$coeff(x2), $coeff(x3)}
        S[i,] = {$ess, $rsq}
        signif += abs($coeff(x2)/$stderr(x2)) > tc
    endloop
    matrix V = mcov(B)
    printf "%7.3f %8.4f %8.1f %10.4f %10.4f %10.4f %10.4f %8.2f %8.4f %8.3f\n", rho, corr(x2, x3), 1/(1-corr(x2,x3)^2),
↪ V[1,1], varTeorica, V[1,2], V[1,1]+V[2,2]+2*V[1,2], meanc(S[,1]), meanc(S[,2]), signif/R
    if j == 1
        matrix B0 = B
    elif j == 3
        matrix B99 = B
    endif
endloop

```

$n = 100$, $\text{beta} = (1, 1, 1)$, $\text{sigma} = 1$, 2000 replicas por cada ρ

ρ	corr	VIF	var(b2)	teorica	cov(b2,b3)	var(b2+b3)	SRC	R2	$\% t >t_c$
--------	------	-----	---------	---------	------------	------------	-----	----	-------------

0,000	-0,0191	1,0	0,0108	0,0104	0,0003	0,0228	96,56	0,6498	1,000
0,900	0,9085	5,7	0,0583	0,0596	-0,0535	0,0115	96,56	0,7895	0,982
0,990	0,9911	56,3	0,5698	0,5855	-0,5668	0,0109	96,56	0,7988	0,261
0,999	0,9991	563,3	5,7069	5,8603	-5,7085	0,0108	96,56	0,7999	0,071

Lo que debe observar

Lea la tabla por columnas. La varianza empírica de $\hat{\beta}_2$ coincide con $\sigma^2/\|\tilde{\mathbf{x}}_2\|_e^2$ en los cuatro casos, con la oscilación propia de dos mil réplicas: el enunciado de la lección 12 y la fórmula de la 14 funcionan. Y crece como el VIF: de 0,011 con $\rho = 0$ a 5,7 con $\rho = 0,999$, un factor 530 que la columna del VIF anuncia.

La SRC es la misma en las cuatro filas, con todos sus decimales. El subespacio es el mismo por construcción y las perturbaciones sorteadas también, así que el residuo es idéntico. El R^2 sí cambia, porque cambia y : con $\beta_2 = \beta_3 = 1$, dos regresores alineados suman sus efectos y la señal es mayor. La colinealidad no cambia el ajuste; dispersa las coordenadas.

La covarianza entre $\hat{\beta}_2$ y $\hat{\beta}_3$ es negativa y casi igual a la varianza en valor absoluto: cuando uno sube, el otro baja lo mismo. Por eso la varianza de la suma se queda en 0,011 para $\rho = 0,9, 0,99$ y $0,999$: la suma se mide con la precisión que $\hat{\beta}_2$ tenía sin colinealidad. Y la última columna dice lo que eso cuesta: un coeficiente que vale 1, con ruido de desviación típica 1 y cien datos, se detecta siempre con $\rho = 0$ y solo el 7% de las veces con $\rho = 0,999$.

Actividad 2 - Los histogramas y la nube

Compare la distribución de $\hat{\beta}_2$ con $\rho = 0$ y con $\rho = 0,99$, y dibuje $\hat{\beta}_3$ frente a $\hat{\beta}_2$ en el segundo caso.

Las matrices B0 y B99 guardan las 2000 réplicas con $\rho = 0$ y con $\rho = 0,99$ (las guardó el bucle de la Actividad 1). Para dibujarlas hay que pasarlas a series: `nulldata R --preserve` abre un conjunto de R observaciones sin borrar las matrices, y cada `series` toma una columna. Después `freq` dibuja el histograma de cada serie y `gnuplot` la nube de $\hat{\beta}_3$ frente a $\hat{\beta}_2$ (la primera variable en el eje vertical, sesión 7). Las opciones `--plot` y `--output` mandan cada gráfico a un fichero de la carpeta de trabajo.

en línea de comandos (con las matrices B0 y B99 de la Actividad 1):

```
nulldata R --preserve
series b2_rho0 = B0[,1]
series b2_rho99 = B99[,1]
series b3_rho99 = B99[,2]
freq b2_rho0
freq b2_rho99
gnuplot b3_rho99 b2_rho99
```

```
rho = 0      : b2 medio = 1,0046   desv. típica = 0,1037   min = 0,661   max = 1,357
rho = 0,99   : b2 medio = 1,0152   desv. típica = 0,7549   min = -1,701  max = 3,318
rho = 0,99   : b2 + b3 medio = 2,0045   desv. típica = 0,1042
correlacion entre b2 y b3 con rho = 0,99: -0,9905
```

Lo que debe observar

Fíjese en los ejes antes que en las barras. Los dos histogramas tienen la misma forma y el mismo centro, 1: el estimador sigue siendo insesgado. Lo que cambia es la escala: con $\rho = 0,99$ la desviación típica es 0,75 en lugar de 0,10, el factor $\sqrt{\text{VIF}} \approx 7$ de la lección 14, y hay réplicas en que $\hat{\beta}_2$ sale negativo, con un verdadero valor de 1.

La nube es la figura de la lección 14 vista dos mil veces: los pares $(\hat{\beta}_2, \hat{\beta}_3)$ no se dispersan en todas direcciones, sino a lo largo de una recta de pendiente -1 , con correlación $-0,99$. Cada muestra reparte el efecto total, 2, entre dos regresores que casi no se distinguen, y el reparto es casi arbitrario; la suma no. Con datos reales solo se dispone de una réplica: un punto de esa nube, sin saber cuál.




Figura 1: $\hat{\beta}_2$ en las 2000 réplicas con $\rho = 0$. El eje horizontal va de 0,66 a 1,36.




Figura 2: $\hat{\beta}_2$ en las 2000 réplicas con $\rho = 0,99$. El eje horizontal va de $-1,7$ a $3,3$: la misma forma, siete veces más ancha.




Figura 3: $\hat{\beta}_3$ frente a $\hat{\beta}_2$ con $\rho = 0,99$. Las 2000 réplicas se alinean sobre la recta $\hat{\beta}_3 = 2 - \hat{\beta}_2$: lo que una coordenada gana lo pierde la otra, y la suma apenas se mueve.

Preguntas de interpretación para la clase

1. ¿Por qué la SRC es exactamente la misma en las cuatro filas de la tabla, y por qué el R^2 no lo es? ¿Habría pasado lo mismo si $\mathbf{x}_3$ se hubiera generado de forma independiente para cada ρ ?
2. Con $\rho = 0$ la varianza de $\hat{\beta}_2 + \hat{\beta}_3$ es 0,023, el doble que con $\rho = 0,99$. ¿Es que la colinealidad *mejora* la estimación de la suma? Razónelo con la parte propia del regresor $\mathbf{x}_2 + \mathbf{x}_3$.
3. En la última columna, el efecto verdadero de $\mathbf{x}_2$ solo se detecta el 26 % de las veces con $\rho = 0,99$. Un investigador con una sola muestra obtiene $t = 0,9$ y concluye que $\mathbf{x}_2$ no influye. ¿Qué diría usted, y qué pediría ver?
4. La nube de la Actividad 2 está centrada en (1,1). Si el investigador de la pregunta anterior obtiene $(\hat{\beta}_2, \hat{\beta}_3) = (-0,5; 2,5)$, ¿son esos valores “incorrectos”? ¿Qué es lo que sí está bien estimado en esa muestra?
5. ¿Qué habría que cambiar en el experimento para que, con $\rho = 0,99$, el t de $\mathbf{x}_2$ volviera a superar t_c en casi todas las réplicas? Diga dos cosas distintas y compare su coste.

Para profundizar

- Lección 14 ([lección 14](#)), en especial “La parte propia de un regresor” y “Por qué oscilan los coeficientes”.
- Lección 11 ([lección 11](#)), la covarianza entre $\hat{\beta}_1$ y $\hat{\beta}_2$ con $k = 2$.
- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 3, sección 3.4, “Multicollinearity”.
- Manual de Gretl: funciones `mcov`, `corr` y `sd`; matrices en bucles.

Código completo de la práctica

```
# -----
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# -----

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
↪ directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#   DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
↪ trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

set verbose off

nulldata 100
scalar n = $nobs
scalar b1 = 1
scalar b2 = 1
scalar b3 = 1
scalar sig = 1
scalar R = 2000
scalar tc = critical(t, n-3, 0.025)
matrix rhos = {0, 0.9, 0.99, 0.999}
outfile --quiet montecarlo.txt
    printf "n = %d, beta = (1, 1, 1), sigma = 1, %d replicas por cada rho\n\n", n, R
    printf "%7s %8s %8s %10s %10s %10s %10s %8s %8s %8s\n", "rho", "corr", "VIF", "var(b2)", "teorica",
    ↪ "cov(b2,b3)", "var(b2+b3)", "SRC", "R2", "%|t|>tc"
    loop j=1..4 --quiet
        scalar rho = rhos[j]
        set seed 2026
        series z1 = normal()
        series z2 = normal()
        series x2 = z1
        series x3 = rho*z1 + sqrt(1-rho^2)*z2
        ols x2 const x3 --quiet
        scalar longPropia2 = sqrt($ess) # // parte propia de x2 //
        scalar varTeorica = sig^2/longPropia2^2 # sigma^2 / ||x2 propia||^2
        matrix B = zeros(R, 2)
        matrix S = zeros(R, 2)
        scalar signif = 0
        set seed 20261120
        loop i=1..R --quiet
            series u = normal(0, sig)
            series y = b1 + b2*x2 + b3*x3 + u
            ols y const x2 x3 --quiet
            B[i,] = {$coeff(x2), $coeff(x3)}
            S[i,] = {$ess, $rsq}
            signif += abs($coeff(x2)/$stderr(x2)) > tc
        endloop
        matrix V = mcov(B)
        printf "%7.3f %8.4f %8.1f %10.4f %10.4f %10.4f %10.4f %8.2f %8.4f %8.3f\n", rho, corr(x2, x3),
        ↪ 1/(1-corr(x2,x3)^2), V[1,1], varTeorica, V[1,2], V[1,1]+V[2,2]+2*V[1,2], meanc(S[,1]),
        ↪ meanc(S[,2]), signif/R
        if j == 1
            matrix B0 = B
        elif j == 3
```

```

        matrix B99 = B
    endif
endloop
end outfile

# Histogramas de b2 con rho = 0 y con rho = 0,99 (mismos ejes)
nulldata R --preserve
series b2_rho0 = B0[,1]
series b2_rho99 = B99[,1]
series b3_rho99 = B99[,2]
series suma_rho99 = b2_rho99 + b3_rho99
outfile --quiet histogramas.txt
    printf "rho = 0      : b2 medio = %.4f  desv. tipica = %.4f  min = %.3f  max = %.3f\n",
    ↪ mean(b2_rho0), sd(b2_rho0), min(b2_rho0), max(b2_rho0)
    printf "rho = 0,99  : b2 medio = %.4f  desv. tipica = %.4f  min = %.3f  max = %.3f\n",
    ↪ mean(b2_rho99), sd(b2_rho99), min(b2_rho99), max(b2_rho99)
    printf "rho = 0,99  : b2 + b3 medio = %.4f  desv. tipica = %.4f\n", mean(suma_rho99), sd(suma_rho99)
    printf "correlacion entre b2 y b3 con rho = 0,99: %.4f\n", corr(b2_rho99, b3_rho99)
end outfile
freq b2_rho0 --plot="@workdir/histRho0.png"
freq b2_rho99 --plot="@workdir/histRho99.png"
gnuplot b3_rho99 b2_rho99 --output="@workdir/nubeRho99.png"

```

Enlace al guión: [S22-Prc2-A-colinealidad-montecarlo.inp](#)

Respuestas

1. *La SRC idéntica.* El residuo es $\mathbf{y}$ menos su proyección sobre el subespacio de los regresores, y ese subespacio es el mismo para los cuatro ρ , porque $\mathbf{x}_3$ es siempre una combinación de $\mathbf{z}_1$ y $\mathbf{z}_2$ y $\mathbf{x}_2 = \mathbf{z}_1$. Como además la perturbación sorteada es la misma (la semilla se fija antes de cada bucle), y $\mathbf{y}$ es $\mathbf{u}$ más un vector del subespacio, el residuo es el residuo de $\mathbf{u}$, idéntico en las cuatro filas. El R^2 cambia porque cambia la longitud de $\hat{\mathbf{y}}$: con los dos efectos positivos, alinear los regresores hace que se sumen. Con un $\mathbf{x}_3$ generado por separado para cada ρ , los subespacios serían distintos y la SRC variaría un poco, sin que eso cambiara la conclusión: el ajuste es casi el mismo; las coordenadas, no.
2. *La suma se estima mejor con colinealidad.* Sí. El coeficiente de la suma es la coordenada del regresor $\mathbf{x}_2 + \mathbf{x}_3$ en la base $\{\mathbf{x}_2 + \mathbf{x}_3, \mathbf{x}_3\}$, y su parte propia es lo que $\mathbf{x}_2 + \mathbf{x}_3$ no comparte con $\mathbf{x}_3$. Cuando $\mathbf{x}_2$ y $\mathbf{x}_3$ están alineados, su suma es casi el doble de largo que cada uno y la varianza de $\hat{\beta}_2 + \hat{\beta}_3$ es la de un solo coeficiente, 0,011; cuando son ortogonales, la suma de dos estimadores independientes tiene el doble de varianza. La colinealidad no destruye información: la concentra en la dirección compartida y la quita de la dirección que separa a los dos regresores.
3. *“ $\mathbf{x}_2$ no influye”.* Que $t = 0,9$ es lo que se obtiene tres de cada cuatro veces con $\rho = 0,99$ aunque el efecto sea 1, así que no rechazar dice muy poco. Pediría ver el intervalo de confianza, que será ancho e incluirá valores tan grandes como 2, y el VIF, que dirá por cuánto se ha multiplicado el error estándar. Y pediría el F de excluir $\mathbf{x}_2$ y $\mathbf{x}_3$ a la vez, que será grande: los datos rechazan que la pareja sobre, aunque no permitan decir cuál de los dos influye.
4. *Valores “incorrectos”.* No: son una réplica posible, un punto de la nube, y el estimador que los produjo es insesgado y de varianza mínima entre los lineales. Lo que está mal es leerlos como el efecto separado de cada regresor, que la muestra no puede dar. Lo que sí está bien estimado es la suma, 2,0, y con ella el ajuste: $\hat{\mathbf{y}}$ es el mismo que el de cualquier otra réplica, con el mismo $\mathbf{s}$ y el mismo R^2 . La predicción de y para una nueva observación en la que x_2 y x_3 vayan juntos, como en la muestra, es tan buena como sin colinealidad.
5. *Qué cambiar.* Más observaciones: la parte propia crece como $\sqrt{n}$, y para recuperar el factor 7 del error estándar haría falta multiplicar n por 50. O más variación propia: sortear $\mathbf{x}_3$ con menos correlación es lo que un diseño experimental puede hacer y los datos observados no; con $\rho = 0,9$ bastaban cien observaciones. La segunda opción es mucho más barata cuando está disponible, y es lo que la lección 14 llamó “muestras en las que los regresores varíen por separado”.