

Sesión 22 (B) — El caso `nox` y `lnox`: la parte propia, el VIF y el error estándar

Marcos Bujosa

Descripción de la práctica

La lección 13 dejó un caso sin explicar y la 14 lo explicó: en `price ~ rooms + nox + lnox` los dos t de la contaminación son pequeños y el F de excluirlas juntas vale 28. La explicación fue una longitud: la parte propia de `nox`, lo que queda de ella después de proyectarla sobre los demás regresores, mide 2,86, cuando el regresor en desviaciones mide 26. Esta práctica hace esa cuenta con Gretl, paso a paso, y comprueba que el error estándar de la tabla es exactamente s dividido por esa longitud.

Es la comprobación numérica del enunciado de la lección 12, $ee(\hat{\beta}_j) = s/\|\tilde{\mathbf{x}}_j\|_e$, que allí no se demostró.

Objetivos

1. Obtener la parte propia de `nox` con la regresión auxiliar sobre `rooms` y `lnox`, y medir su longitud de dos maneras: como raíz de la SRC auxiliar y como $\|\mathbf{x}_j - \mu_{\mathbf{x}_j}\mathbf{1}\|_e \sqrt{1 - R_j^2}$.
2. Comprobar que $s/\|\tilde{\mathbf{x}}_j\|_e$ es el error estándar que imprime Gretl, con todos los decimales.
3. Calcular el VIF a mano y con el comando `vif`, y leer su raíz como el factor por el que se ha multiplicado el error estándar.
4. Repetir la cuenta sin `lnox` para ver de dónde sale el factor 8,7 de la lección 14.
5. Leer los intervalos de confianza de `nox` con y sin `lnox`, y la correlación entre los dos estimadores.

Comandos nuevos de esta práctica. Casi todo se ha visto ya: `open`, `ols` y sus accesores `$sigma`, `$stderr`, `$rsq`, `$ess`, `$coeff` y `$df` (sesiones 11 a 18), `critical` (sesión 18) y `$vcv` ([actividad 3 \(html\)](#) de la práctica B de la sesión 21). Recuerde que los accesores se refieren siempre al *último* modelo estimado: por eso, en esta práctica, se guardan en escalares antes de estimar el siguiente. Lo nuevo:

`vif` se escribe después de estimar un modelo con al menos dos regresores no constantes, y para cada regresor calcula $1/(1 - R_j^2)$, con R_j^2 el de la regresión de ese regresor sobre los demás. En la ventana del modelo es `Análisis -> Colinealidad`.

`$vcv[3,4]` `$vcv` es la matriz de varianzas y covarianzas de los coeficientes, y entre corchetes van la fila y la columna. Los coeficientes siguen el orden de la lista de regresores, así que `[3,4]` es la covarianza entre el tercero (`nox`) y el cuarto (`lnox`), y `[3,3]` la varianza del tercero.

Actividad 1 - El modelo y la regresión auxiliar

Abra `hprice2` y estime `price` sobre `rooms`, `nox` y `lnox`. Anote s y el error estándar de `nox`. Después estime la regresión auxiliar: `nox` sobre la constante, `rooms` y `lnox`. Su SRC es la longitud al cuadrado de la parte propia de `nox`, y su R_j^2 es el R_j^2 de la lección 14.

Dos regresiones seguidas. La primera es el modelo completo: guardamos en `s` la “D.T. de la regresión” de Gretl, `s ($sigma)`, y en `ee_nox` el error estándar de `nox`. La segunda es la *regresión auxiliar*: `nox` como

regresando sobre la constante, `rooms` y `lnox`. De ella guardamos el R^2 y la raíz de su SRC (`$ess`), que es la longitud de la parte propia de `nox`.

o bien teclee en línea de comandos:

```
open hprice2.gdt --quiet
ols price const rooms nox lnox
scalar s = $sigma
scalar ee_nox = $stderr(nox)
ols nox const rooms lnox
scalar R2aux = $rsq
scalar longPropia = sqrt($ess)
```

Modelo 1: MCO, usando las observaciones 1-506

Variable dependiente: price

	coeficiente	Desv. típica	Estadístico t	valor p
const	-8566,88	9983,25	-0,8581	0,3912
rooms	8161,84	418,340	19,51	1,65e-63 ***
nox	404,190	2198,85	0,1838	0,8542
lnox	-13262,2	12655,7	-1,048	0,2952
Media de la vble. dep.	22511,51	D.T. de la vble. dep.	9208,856	
Suma de cuad. residuos	1,99e+10	D.T. de la regresión	6290,373	
R-cuadrado	0,536175	R-cuadrado corregido	0,533404	
F(3, 502)	193,4352	Valor p (de F)	2,36e-83	
Log-verosimilitud	-5141,843	Criterio de Akaike	10291,69	
Criterio de Schwarz	10308,59	Crit. de Hannan-Quinn	10298,32	

Sin considerar la constante, el valor p más alto fue el de la variable 3 (nox)

Modelo 2: MCO, usando las observaciones 1-506

Variable dependiente: nox

	coeficiente	Desv. típica	Estadístico t	valor p
const	-4,13352	0,0837444	-49,36	5,93e-195 ***
rooms	0,000568365	0,00848297	0,06700	0,9466
lnox	5,71719	0,0295918	193,2	0,0000 ***
Media de la vble. dep.	5,549783	D.T. de la vble. dep.	1,158395	
Suma de cuad. residuos	8,183946	D.T. de la regresión	0,127555	
R-cuadrado	0,987923	R-cuadrado corregido	0,987875	
F(2, 503)	20573,26	Valor p (de F)	0,000000	
Log-verosimilitud	325,4808	Criterio de Akaike	-644,9615	
Criterio de Schwarz	-632,2819	Crit. de Hannan-Quinn	-639,9886	

```
R2 de la regresion auxiliar      = 0,9879
||parte propia de nox||         = sqrt(SRC) = 2,8608
||nox en desviaciones||         = 26,0317
sqrt(1 - R2aux)                 = 0,1099   (= seno del angulo)
producto                         = 2,8608
```

Lo que debe observar

La regresión auxiliar tiene un R^2 de 0,9879: `rooms` y `lnox` reproducen el 98,8% de la variación de `nox`, casi todo por cuenta de `lnox` (mire los dos t). La parte propia mide 2,861, y las dos maneras de calcularla coinciden: raíz de la SRC auxiliar, o longitud en desviaciones por $\sqrt{1 - R_j^2} = 0,110$, que es el seno del ángulo entre `nox` y el subespacio de los otros dos regresores, unos 6° .

Actividad 2 - El error estándar, reconstruido

Divida s entre la longitud de la parte propia y compare con la columna “Desv. típica” de la tabla (el error estándar). Calcule también el VIF y descomponga el error estándar en los dos factores de la lección 14.

Tres `printf` con los escalares guardados: s entre la longitud de la parte propia, el error estándar que imprimió Gretl, y el VIF con su raíz, calculados a partir del R^2 auxiliar.

en línea de comandos:

```
printf "s / ||parte propia de nox||      = %.4f\n", s/longPropia
printf "error estandar de nox segun Gretl = %.4f\n", ee_nox
printf "VIF = %.3f   sqrt(VIF) = %.3f\n", 1/(1-R2aux), 1/sqrt(1-R2aux)
```

```
s del modelo completo          = 6290,3733
s / ||parte propia de nox||     = 2198,8472
error estandar de nox segun Gretl = 2198,8472
VIF = 1/(1 - R2aux)             = 82,802      sqrt(VIF) = 9,100
s / ||nox en desviaciones||     = 241,643      x sqrt(VIF) = 2198,847
```

Lo que debe observar

$6290,37/2,8608 = 2198,85$, el error estándar de la tabla con cuatro decimales. El enunciado de la lección 12 se cumple sobre datos reales. Y la descomposición: 241,6 es el error estándar que `nox` tendría si no compartiera nada con los demás regresores, s entre su longitud completa en desviaciones; multiplicado por $\sqrt{\text{VIF}} = 9,10$ da los 2198,85. El VIF es 82,8: la varianza se ha multiplicado por 83, el error estándar por 9.

Actividad 3 - El comando `vif`

Vuelva al modelo completo. En la ventana del modelo, el menú **Análisis -> Colinealidad** calcula los factores de inflación de todos los regresores.

Hay que volver a estimar el modelo completo (con `--quiet`, para no repetir la tabla), porque `vif` actúa sobre el último modelo estimado y el último fue la regresión auxiliar.

o bien teclee en línea de comandos:

```
ols price const rooms nox lnox --quiet
vif
```

```
Factores de inflación de varianza (VIF)
Mínimo valor posible = 1.0
Valores mayores que 10.0 pueden indicar un problema de colinealidad
```

```
rooms    1,103
nox      82,802
lnox     82,922
```

```
VIF(j) = 1/(1 - R(j)^2), donde R(j) es el coeficiente de correlación múltiple
entre la variable j y las demás variables independientes
```

Lo que debe observar

Gretl devuelve el 82,8 de la Actividad 2 para `nox`, 82,9 para `lnox` y 1,1 para `rooms`: las dos medidas de contaminación comparten casi toda su variación y ninguna comparte nada con `rooms`. La nota al pie de la salida define el VIF como $1/(1 - R_j^2)$ con el R_j^2 de la regresión auxiliar, que es lo que usted acaba de calcular, y da la regla del 10. Léala como lo que es, una convención: 10 significa error estándar multiplicado por 3,2.

Actividad 4 - La misma cuenta sin lnox

Estime `price ~ rooms + nox` y repita: parte propia de `nox` sobre `rooms`, `s` dividido por ella, VIF.

La misma secuencia con el modelo sin `lnox`: estimación, `s` guardado en `s_sin`, regresión auxiliar de `nox` sobre `rooms` (ahora un solo regresor), el cociente impreso directamente con los accesorios de esa auxiliar, y `vif` tras volver a estimar el modelo de precios.

en línea de comandos:

```
ols price const rooms nox
scalar s_sin = $sigma
ols nox const rooms --quiet
printf "||parte propia de nox sobre rooms|| = %.3f    s/||.|| = %.2f\n", sqrt($ess), s_sin/sqrt($ess)
ols price const rooms nox --quiet
vif
```

```
price ~ rooms + nox:    coef(nox) = -1884,68    ee(nox) = 253,57    t = -7,43    s = 6290,99
parte propia de nox sobre rooms:    ||.|| = 24,809    R2aux = 0,0917    VIF = 1,101
s / ||parte propia|| = 253,57
```

Factores de inflación de varianza (VIF)

Mínimo valor posible = 1.0

Valores mayores que 10.0 pueden indicar un problema de colinealidad

rooms	1,101
nox	1,101

$VIF(j) = 1/(1 - R(j)^2)$, donde $R(j)$ es el coeficiente de correlación múltiple entre la variable j y las demás variables independientes

Lo que debe observar

Sin `lnox`, la parte propia de `nox` mide 24,81, casi toda su longitud en desviaciones (26,03), porque `rooms` comparte poco con ella: $VIF = 1,1$. El error estándar es 253,57, y $6290,99/24,809 = 253,57$ de nuevo. Entre los dos modelos, `s` casi no cambia (6291,0 frente a 6290,4) y el número de observaciones es el mismo. Lo único que ha cambiado es la longitud propia de `nox`: de 24,81 a 2,86, un factor 8,7, y el error estándar sube en ese factor, de 253,6 a 2198,9.

Actividad 5 - Los intervalos y la correlación entre estimadores

Construya el intervalo al 95 % de `nox` en los dos modelos, el de `lnox` en el completo, y lea en la matriz de varianzas de los estimadores (Análisis -> Matriz de covarianzas de los coeficientes) la correlación entre $\hat{\beta}_{nox}$ y $\hat{\beta}_{lnox}$.

Con el modelo completo estimado, `critical(t, $df, 0.025)` da el valor crítico de la t con los grados de libertad del modelo (sesión 18), y cada intervalo es el coeficiente más y menos `tc` por su error estándar. En el `printf,%%` imprime un signo de tanto por ciento (un % solo abriría un hueco). La correlación entre los dos estimadores es su covarianza dividida por la raíz del producto de sus varianzas, las tres leídas en `$vcv`.

en línea de comandos:

```
ols price const rooms nox lnox --quiet
scalar tc = critical(t, $df, 0.025)
printf "IC 95% de nox: [%.1f ; %.1f]\n", $coeff(nox) - tc*$stderr(nox), $coeff(nox) + tc*$stderr(nox)
printf "correlacion entre los estimadores: %.4f\n", $vcv[3,4]/sqrt($vcv[3,3]*$vcv[4,4])
```

```
IC 95% de nox con lnox en el modelo: [-3915,9 ; 4724,3]
IC 95% de lnox con nox en el modelo: [-38126,8 ; 11602,3]
correlacion entre los dos estimadores: -0,9933
IC 95% de nox sin lnox: [-2382,9 ; -1386,5]
```

Lo que debe observar

Con `lnox` en el modelo, el intervalo de `nox` va de $-3\,900$ a $+4\,700$ dólares por unidad de contaminación: los datos no determinan ni el signo. Sin `lnox`, de $-2\,400$ a $-1\,400$: un coeficiente negativo medido con precisión. Y la correlación entre los dos estimadores es $-0,993$: es la nube de la práctica A ([actividad 2 \(html\)](#)) con datos reales. Los coeficientes 404 y $-13\,262$ de la tabla son un reparto casi arbitrario de un efecto que, tomado en conjunto, es el de siempre; con otra muestra de viviendas, el reparto sería otro y el ajuste casi el mismo.

Preguntas de interpretación para la clase

1. En la Actividad 1, el t de `rooms` en la regresión auxiliar es $0,07$. ¿Qué dice eso sobre la parte propia de `nox`, y por qué el VIF de `rooms` en el modelo de precios es $1,1$ y no 1 ?
2. La descomposición de la Actividad 2 escribe el error estándar como $241,6 \cdot 9,10$. ¿Cuál de los dos factores cambia si se duplican las observaciones manteniendo la misma correlación entre `nox` y `lnox`, y cómo?
3. Un compañero dice: “el VIF de `nox` es 82 , así que hay que quitar `nox` del modelo”. ¿Qué habría que preguntarle antes de aceptar la recomendación?
4. Los intervalos de `nox` con y sin `lnox` no se solapan ni de lejos en su centro: 404 frente a $-1\,885$. ¿Cuál de los dos estima “el efecto de la contaminación”? ¿Miden lo mismo?
5. Con la correlación $-0,993$ entre los dos estimadores, ¿qué combinación de β_{nox} y β_{lnox} estaría bien medida? Diga cómo la contrastaría.

Para profundizar

- Lección 14 ([lección 14](#)), “Cuánto se acorta: el factor de inflación de la varianza” y “El caso `nox` y `lnox` con números”.
- Lección 12 ([lección 12](#)), el enunciado del error estándar con k regresores.
- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 3, sección 3.4, ecuación de $\text{Var}(\hat{\beta}_j)$ y discusión del VIF.
- Manual de Gretl: comando `vif`; accesorios `$sigma`, `$stderr` y `$vcv`.

Código completo de la práctica

```
# -----
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# -----

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
↪ directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#   DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
↪ trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

set verbose off

open hprice2.gdt --quiet
outfile --quiet modelo.txt
    ols price const rooms nox lnox
    scalar s = $sigma
    scalar ee_nox = $stderr(nox)
end outfile
outfile --quiet auxiliar.txt
    ols nox const rooms lnox
    scalar R2aux = $rsq
    scalar longPropia = sqrt($ess)
    printf "\nR2 de la regresion auxiliar      = %.4f\n", R2aux
    printf "||parte propia de nox|| = sqrt(SRC) = %.4f\n", longPropia
    printf "||nox en desviaciones|| = %.4f\n", sqrt(sum((nox - mean(nox))^2))
    printf "sqrt(1 - R2aux)          = %.4f (= seno del angulo)\n", sqrt(1 - R2aux)
    printf "producto                    = %.4f\n", sqrt(sum((nox - mean(nox))^2))*sqrt(1 - R2aux)
end outfile

outfile --quiet errorEstandar.txt
    printf "s del modelo completo          = %.4f\n", s
    printf "s / ||parte propia de nox||      = %.4f\n", s/longPropia
    printf "error estandar de nox segun Gretl = %.4f\n", ee_nox
    printf "VIF = 1/(1 - R2aux)              = %.3f      sqrt(VIF) = %.3f\n", 1/(1-R2aux),
    ↪ 1/sqrt(1-R2aux)
    printf "s / ||nox en desviaciones||      = %.3f      x sqrt(VIF) = %.3f\n", s/sqrt(sum((nox -
    ↪ mean(nox))^2)), s/sqrt(sum((nox - mean(nox))^2))/sqrt(1-R2aux)
end outfile

ols price const rooms nox lnox --quiet
outfile --quiet vif.txt
    vif
end outfile

outfile --quiet sinLnox.txt
    ols price const rooms nox --quiet
    printf "price ~ rooms + nox: coef(nox) = %.2f ee(nox) = %.2f t = %.2f s = %.2f\n", $coeff(nox),
    ↪ $stderr(nox), $coeff(nox)/$stderr(nox), $sigma
    scalar s_sin = $sigma
    ols nox const rooms --quiet
    printf "parte propia de nox sobre rooms: ||.|| = %.3f R2aux = %.4f VIF = %.3f\n", sqrt($ess),
    ↪ $rsq, 1/(1-$rsq)
    printf "s / ||parte propia|| = %.2f\n", s_sin/sqrt($ess)
    ols price const rooms nox --quiet
```

```

    vif
end outfile

outfile --quiet intervalos.txt
    ols price const rooms nox lnox --quiet
    scalar tc = critical(t, $df, 0.025)
    printf "IC 95%% de nox con lnox en el modelo: [%.1f ; %.1f]\n", $coeff(nox) - tc*$stderr(nox),
    ↪ $coeff(nox) + tc*$stderr(nox)
    printf "IC 95%% de lnox con nox en el modelo: [%.1f ; %.1f]\n", $coeff(lnox) - tc*$stderr(lnox),
    ↪ $coeff(lnox) + tc*$stderr(lnox)
    printf "correlacion entre los dos estimadores: %.4f\n", $vcv[3,4]/sqrt($vcv[3,3]*$vcv[4,4])
    ols price const rooms nox --quiet
    printf "IC 95%% de nox sin lnox: [%.1f ; %.1f]\n", $coeff(nox) - tc*$stderr(nox), $coeff(nox) +
    ↪ tc*$stderr(nox)
end outfile

```

Enlace al guión: [S22-Prct-B-hprice2-vif.inp](#)

Respuestas

1. *El t de `rooms` en la auxiliar.* Que `rooms` no aporta nada a la reproducción de `nox` una vez que está `lnox`: la parte propia de `nox` es, en la práctica, lo que `nox` no comparte con `lnox`. El VIF de `rooms` es 1,1 y no 1 porque `rooms` sí comparte algo con la pareja `nox` y `lnox` (barrios más contaminados tienen viviendas algo distintas): su R_j^2 es 0,09. Es un VIF pequeño, y su raíz, 1,05, dice que el error estándar de `rooms` apenas se ha inflado.
2. *Duplicar las observaciones.* El primer factor: `s` apenas cambia y la longitud de `nox` en desviaciones se multiplica por $\sqrt{2}$, así que 241,6 pasa a unos 171. El segundo, $\sqrt{\text{VIF}}$, depende solo del ángulo, y con la misma correlación no se mueve. El error estándar baja a $2198,9/\sqrt{2} \approx 1555$: mejor, pero sigue siendo nueve veces el que `nox` tendría sola. La lección 14 lo dijo: más datos alargan las partes propias sin cambiar el VIF.
3. *“Hay que quitar `nox`”.* Para qué se quiere el coeficiente. Si la pregunta es el efecto de la contaminación sobre el precio, `nox` y `lnox` son la misma contaminación en dos escalas y quedarse con una es razonable: la lección 13 mostró que los dos modelos con una sola medida ajustan igual de bien, y no hay ninguna razón para preferir quitar `nox` a quitar `lnox`. Si la pregunta fuera distinguir un efecto lineal de uno logarítmico, estos datos no lo permiten, y quitar una de las dos no resuelve la pregunta: la esconde. El VIF mide un coste; no dicta el remedio.
4. *Qué mide cada intervalo.* Cosas distintas. Sin `lnox`, β_{nox} es el efecto de la contaminación con `rooms` fijo, y el intervalo lo estima con precisión. Con `lnox`, β_{nox} es el efecto de `nox` *manteniendo fijo su propio logaritmo*, que en la muestra casi no ocurre: la parte propia mide 2,86. El segundo coeficiente responde a una pregunta que los datos apenas contienen, y su intervalo lo refleja. Ninguno de los dos está mal; el segundo está mal *leído* si se toma por el primero.
5. *La combinación bien medida.* La que corresponde a mover `nox` y `lnox` juntas, como van en los datos: en torno a la media de `nox`, $\bar{x} \approx 5,55$, un aumento de una unidad de `nox` aumenta `lnox` en aproximadamente $1/5,55 = 0,18$, así que la combinación $\beta_{\text{nox}} + 0,18\beta_{\text{lnox}}$ es la que la muestra puede estimar; con 404 y $-13\,262$ da unos $-1\,985$, cerca del $-1\,885$ del modelo sin `lnox`. Se contrasta con `restrict` escribiendo `b[nox] + 0.18*b[lnox] = c` para el valor c que se quiera, o pidiendo su intervalo con la matriz de varianzas: la varianza de la combinación es $a^\top Va$ con $a = (0, 0, 1, 0, 18)$.