Sesión 22 (C) — Edad y millas: colinealidad con coeficientes significativos

Marcos Bujosa

Descripción de la práctica

El caso `nox` y `lnox` es la forma más visible de la colinealidad: dos t pequeños y un F grande. Esta práctica muestra otra, menos visible: dos regresores casi alineados cuyos coeficientes son *significativos*, uno de ellos con un signo que nadie esperaría. En esta práctica el VIF no avisa de un t pequeño, sino de un coeficiente que no puede leerse como se lee normalmente.

Los datos son `data3-7` de Ramanathan: cincuenta y siete coches con su coste acumulado de reparaciones (`cost`, en dólares), su edad (`age`, en semanas) y las millas recorridas (`miles`, en miles de millas). Edad y millas crecen juntas: un coche que lleva más tiempo ha recorrido más. La pregunta es qué pasa cuando se pide al modelo que separe el efecto de cada uno.

Objetivos

1. Comparar las dos regresiones simples con la regresión múltiple: los coeficientes cambian de tamaño y uno cambia de signo.
2. Medir la colinealidad: correlación, partes propias y VIF, y comprobar de nuevo $\text{ee}(\hat{\beta}_j) = \mathfrak{s}/\|\tilde{\boldsymbol{x}}_j\|_e$.
3. Ver que un VIF de 142 es compatible con dos t grandes, y qué es lo que ese VIF sí está diciendo.
4. Comprobar la inestabilidad de las coordenadas estimando en dos mitades de la muestra.
5. Sustituir `age` por su parte propia y comprobar qué cambia y qué no.

Comandos nuevos de esta práctica. Casi todo es conocido: `open` y `labels` (sesión 4), `summary --simple` y el comando `corr` (sesión 7), `ols` y sus accesores (sesiones 11 a 18), `vif` (actividad 3 (html) de la práctica B de hoy), `restrict` y `$test` (sesión 20), `$vcv` (actividad 3 (html) de la práctica B de la sesión 20 y actividad 5 (html) de la de hoy), `matrix` y `$coeff` como vector de coeficientes (práctica D de la sesión 14, actividad 2 (html)) y `smpl` (sesiones 14 a 18). Dos novedades y dos recordatorios:

`loop foreach i 1 2` recorre una lista de números; dentro del bucle, `i` vale 1 y después 2. En la práctica B de la sesión 7 (actividad 2 (html)) recorría una lista de series.

`(i = 1) ? 40 : 10`= el operador condicional: vale 40 si se cumple la condición entre paréntesis y 10 si no.

`restrict … end restrict` contrasta sobre el último modelo la restricción escrita dentro; `b[miles] = 0` se refiere al coeficiente de `miles`. Con `--quiet` no imprime las estimaciones restringidas, y `$test` recoge después el estadístico del contraste.

`smpl 1 28` restringe la muestra a las observaciones 1 a 28: todo lo que se estime después usa solo esas filas. `smpl full` devuelve la muestra completa. En los menús, `Muestra ->Establecer rango`.

Licencia: Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0).

Actividad 1 - Los datos y las dos regresiones simples

Abra `data3-7`, mire las variables y su correlación, y estime `cost` sobre `age` y `cost` sobre `miles` por separado.

`open` carga el fichero de muestra de Ramanathan (`--quiet` evita listar las variables) y `labels` muestra la descripción de cada una. `summary --simple` da media, mediana, desviación típica, mínimo y máximo de las tres variables, y el comando `corr` la correlación entre `age` y `miles`. El bloque `Simples` estima las dos regresiones simples con dos `ols`, cada una con su tabla completa, y tras cada una un `printf` resume en una línea el coeficiente, su error estándar, el t, el R^2 y `s`.

o bien teclee en línea de comandos:

```
open data3-7.gdt --quiet
```

```
labels
summary cost age miles --simple
corr age miles
```

```
 cost: cumulative repair cost in actual dollars (11 - 3425)
 age: age of car in weeks of ownership (Range 5 - 538)
 miles: miles driven in thousands (Range 0.8 - 74.4)


                Media    Mediana      D. T.        Mín        Máx
cost             1427       1182       1151      11,00       3425
age             279,5      276,0      148,7      5,000      538,0
miles           41,58      43,40      19,96     0,8000      74,40


corr(age, miles) = 0,99646458
Bajo la hipótesis nula de no correlación:
 t(55) = 87,9614, con valor p a dos colas 0,0000
```

```
ols cost const age
printf "cost ~ age:    coef(age)   = %8.3f   ee = %7.3f   t = %6.2f   R2 = %.4f   s = %.1f\n", $coeff(age), $stderr(age),
↪  $coeff(age)/$stderr(age), $rsq, $sigma
ols cost const miles
printf "cost ~ miles:  coef(miles) = %8.3f   ee = %7.3f   t = %6.2f   R2 = %.4f   s = %.1f\n", $coeff(miles),
↪  $stderr(miles), $coeff(miles)/$stderr(miles), $rsq, $sigma
```

```
Modelo 1: MCO, usando las observaciones 1-57
Variable dependiente: cost

             coeficiente   Desv. típica   Estadístico t   valor p
  ------------------------------------------------------------------
  const      -625,935       104,150          -6,010       1,55e-07 ***
  age           7,34348       0,329580       22,28        3,31e-29 ***

Media de la vble. dep.  1426,632   D.T. de la vble. dep.   1151,186
Suma de cuad. residuos   7401653   D.T. de la regresión    366,8453
R-cuadrado              0,900265   R-cuadrado corregido    0,898451
F(1, 55)                496,4588   Valor p (de F)          3,31e-29
Log-verosimilitud      -416,4431   Criterio de Akaike      836,8863
Criterio de Schwarz     840,9724   Crit. de Hannan-Quinn   838,4743

cost ~ age:    coef(age)   =    7,343   ee =   0,330   t =  22,28   R2 = 0,9003   s = 366,8

Modelo 2: MCO, usando las observaciones 1-57
Variable dependiente: cost
```

```
            coeficiente   Desv. típica   Estadístico t   valor p
  ------------------------------------------------------------
  const       -796,075      134,745          -5,908       2,26e-07 ***
  miles         53,4507       2,92614        18,27        5,11e-25 ***

Media de la vble. dep.  1426,632   D.T. de la vble. dep.   1151,186
Suma de cuad. residuos  10501755   D.T. de la regresión    436,9680
R-cuadrado              0,858491   R-cuadrado corregido    0,855919
F(1, 55)                333,6690   Valor p (de F)          5,11e-25
Log-verosimilitud      -426,4135   Criterio de Akaike      856,8271
Criterio de Schwarz     860,9132   Crit. de Hannan-Quinn   858,4151

cost ~ miles:  coef(miles) =   53,451   ee =   2,926   t =  18,27   R2 = 0,8585   s = 437,0
```

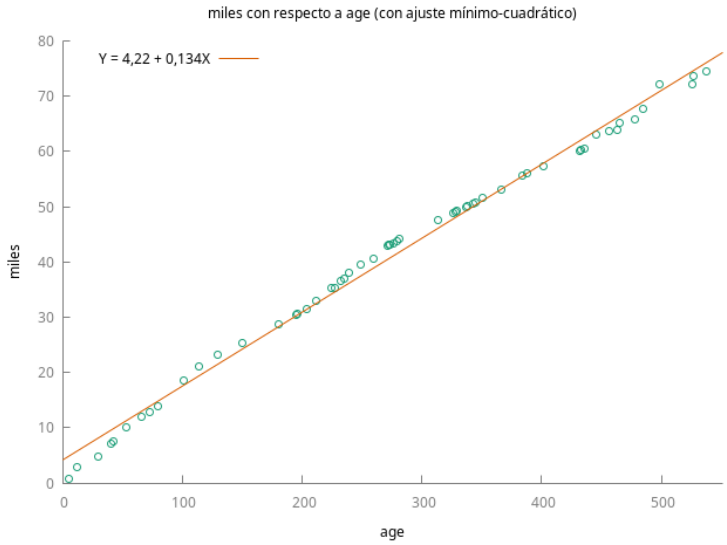


Figura 1: `miles` frente a `age`: los cincuenta y siete coches están casi sobre una recta. La correlación es 0,9965.

Lo que debe observar

Las dos regresiones simples dicen lo esperable: en el ajuste, a cada semana de edad le acompañan unos 7 dólares más de reparaciones; cada mil millas, con unos 53. Los dos coeficientes son positivos, con t de 22 y de 18. Pero la figura muestra que las dos variables son casi la misma: la correlación es 0,9965, un ángulo de 4,8°, y en esta muestra "más viejo" y "más rodado" son casi indistinguibles.

Actividad 2 - Las dos juntas

Estime `cost` sobre `age` y `miles`, y pida los factores de inflación (`Análisis ->Colinealidad`).

La regresión con los dos regresores y, a continuación, `vif` sobre ese modelo (actividad 3 (html) de la práctica B).

o bien teclee en línea de comandos:

```
ols cost const age miles
vif
```

```
Modelo 3: MCO, usando las observaciones 1-57
```

```
Variable dependiente: cost

             coeficiente   Desv. típica   Estadístico t   valor p
  ------------------------------------------------------------
  const         26,1888     114,201          0,2293      0,8195
  age           28,0163       2,77558       10,09        4,91e-14 ***
  miles       -154,635       20,6882        -7,475       6,99e-10 ***

Media de la vble. dep.  1426,632   D.T. de la vble. dep.   1151,186
Suma de cuad. residuos   3637878   D.T. de la regresión    259,5537
R-cuadrado              0,950980   R-cuadrado corregido    0,949165
F(2, 54)                523,8010   Valor p (de F)          4,36e-36
Log-verosimilitud      -396,1995   Criterio de Akaike      798,3990
Criterio de Schwarz     804,5282   Crit. de Hannan-Quinn   800,7810


Factores de inflación de varianza (VIF)
Mínimo valor posible = 1.0
Valores mayores que 10.0 pueden indicar un problema de colinealidad

         age  141,676
       miles  141,676

VIF(j) = 1/(1 - R(j)^2), donde R(j) es el coeficiente de correlación múltiple
entre la variable j y las demás variables independientes
```

Lo que debe observar

El coeficiente de `age` se ha multiplicado casi por cuatro, de 7,3 a 28,0, y el de `miles` ha cambiado de signo: de +53 a −155. Los dos son significativos, con t de 10 y de −7,5. El ajuste es mejor que el de cualquiera de las simples: $R^2 = 0{,}951$ y $\mathfrak{s} = 260$ frente a 367 y 437. Y el VIF es 142 para los dos regresores (con $k = 3$ es el mismo para ambos, $1/(1-\rho^2)$): el error estándar de cada coeficiente es $\sqrt{142} = 11{,}9$ veces el que tendría si el regresor estuviera solo.

Léase el signo con cuidado. −155 no dice que rodar abarate las reparaciones. Dice que, *a igual edad*, en el ajuste, un coche con más millas de las que corresponden a su edad tiene menos gasto acumulado; o, con la misma cuenta, que a igual kilometraje, un coche más viejo gasta mucho más. Los dos coeficientes describen el efecto de mover un regresor mientras el otro se queda quieto, y en esta muestra eso casi nunca ocurre. Compruébelo: $7{,}34 \approx 28{,}02 - 154{,}6 \cdot 0{,}134$, donde 0,134 es la pendiente de `miles` sobre `age` de la figura. Es la identidad que la práctica B de la sesión 14 (actividad 2 (html)) enunció para `rooms` y `nox`: la regresión simple mezcla los dos efectos en la proporción en que la muestra los mezcla.

Actividad 3 - Las partes propias y el error estándar

Mida la parte propia de cada regresor con la regresión auxiliar y compruebe la fórmula del error estándar con `miles`.

Dos regresiones auxiliares con `--quiet`, porque solo queremos sus accesores: la de `age` sobre `miles` y la de `miles` sobre `age`. En cada una, la raíz de `$ess` es la longitud de la parte propia, que el `printf` imprime junto a la longitud del regresor en desviaciones y al R^2 auxiliar. Después se vuelve a estimar el modelo completo y se imprime $\mathfrak{s}$ entre la longitud de la parte propia de `miles` junto al error estándar de `miles` que da Gretl; `$sigma` y `$stderr` se refieren al modelo que acaba de estimarse.

en línea de comandos:

```
ols age const miles --quiet
printf "parte propia de age   sobre miles: ||.|| = %8.3f    ||age en desviaciones||   = %8.3f    R2aux = %.4f\n",
↪  sqrt($ess), sqrt(sum((age-mean(age))^2)), $rsq
ols miles const age --quiet
scalar longPropiaMiles = sqrt($ess)
printf "parte propia de miles sobre age:   ||.|| = %8.3f    ||miles en desviaciones|| = %8.3f    R2aux = %.4f\n",
↪  longPropiaMiles, sqrt(sum((miles-mean(miles))^2)), $rsq
```

```
ols cost const age miles --quiet
printf "s = %.3f ;  s/||parte propia de miles|| = %.3f ;  ee(miles) de Gretl = %.3f\n", $sigma, $sigma/longPropiaMiles,
↪  $stderr(miles)
```

```
parte propia de age   sobre miles: ||.|| =   93,513    ||age en desviaciones||   = 1113,071    R2aux = 0,9929
parte propia de miles sobre age:   ||.|| =   12,546    ||miles en desviaciones|| =  149,332    R2aux = 0,9929
s = 259,554 ;  s/||parte propia de miles|| = 20,688 ;  ee(miles) de Gretl = 20,688
```

Lo que debe observar

La parte propia de `miles` mide 12,5 cuando el regresor en desviaciones mide 149: queda el 8,4 % de su longitud, que es $\sqrt{1-0{,}9929} = \operatorname{sin} 4{,}8°$. Y 259,55/12,546 = 20,69, el error estándar de la tabla. La parte propia de `age` mide 93,5 cuando el regresor en desviaciones mide 1113. Los dos regresores son largos, tienen mucha variación; lo que no tienen es variación *por separado*.

Actividad 4 - Contrastes: t grandes con un VIF de 142

Compare los t individuales, el F conjunto y el F de omitir cada regresor, y lea la correlación entre los dos estimadores.

Sobre el modelo completo, dos bloques `restrict` contrastan, uno tras otro, que el coeficiente de `age` sea cero y que el de `miles` sea cero; cada F queda en `$test` y se guarda en un escalar. El bloque `ContrastesResultados` imprime los resultados: los dos t con el valor crítico, los intervalos al 95 %, el F global del pie de la tabla (`$Fstat`) con su valor crítico, los dos F de omisión con sus valores p (`pvalue`, sesión 18) y la correlación entre los dos estimadores, leída en `$vcv`: la fila 2 y la columna 3 corresponden a `age` y `miles`, segundo y tercer coeficiente de la lista (el primero es la constante).

en línea de comandos:

```
ols cost const age miles --quiet
scalar df = $df
restrict --quiet
    b[age] = 0
end restrict
scalar F_age = $test
restrict --quiet
    b[miles] = 0
end restrict
scalar F_miles = $test
```

```
scalar tc = critical(t, df, 0.025)
printf "Modelo completo: t(age) = %.2f   t(miles) = %.2f   t_c = %.3f\n", $coeff(age)/$stderr(age),
↪  $coeff(miles)/$stderr(miles), tc
printf "IC 95%% de age:   [%.2f ; %.2f]\n", $coeff(age) - tc*$stderr(age), $coeff(age) + tc*$stderr(age)
printf "IC 95%% de miles: [%.1f ; %.1f]\n", $coeff(miles) - tc*$stderr(miles), $coeff(miles) + tc*$stderr(miles)
printf "F de significacion conjunta (pie de tabla) = %.1f   F_c(2,%d) = %.3f\n", $Fstat, df, critical(F, 2, df, 0.05)
printf "Omitir age:   F(1,%d) = %.2f = t^2   valor p = %.2e\n", df, F_age, pvalue(F, 1, df, F_age)
printf "Omitir miles: F(1,%d) = %.2f = t^2   valor p = %.2e\n", df, F_miles, pvalue(F, 1, df, F_miles)
printf "correlacion entre los estimadores de age y miles: %.4f\n", $vcv[2,3]/sqrt($vcv[2,2]*$vcv[3,3])
```

```
Modelo completo: t(age) = 10,09   t(miles) = -7,47   t_c = 2,005
IC 95% de age:   [22,45 ; 33,58]
IC 95% de miles: [-196,1 ; -113,2]
F de significacion conjunta (pie de tabla) = 523,8   F_c(2,54) = 3,168
Omitir age:   F(1,54) = 101,89 = t^2   valor p = 4,91e-14
Omitir miles: F(1,54) = 55,87 = t^2   valor p = 6,99e-10
correlacion entre los estimadores de age y miles: -0,9965
```

Lo que debe observar

Con un VIF de 142, los dos coeficientes son significativos y el contraste rechaza omitir cualquiera de los dos: las partes propias son cortas, pero los coeficientes son tan grandes que sus t superan de sobra el umbral. El VIF no es un veredicto sobre la significación; es la escala del error estándar. Aquí dice que el intervalo de `miles`, de −196 a −113, sería doce veces más estrecho si `miles` no compartiera casi todo con `age`. Y la correlación entre los dos estimadores, −0,9965, dice que si en otra muestra el coeficiente de `age` saliera menor, el de `miles` saldría menos negativo en proporción: la pareja está bien determinada; el reparto, no.

Actividad 5 - La misma regresión en dos mitades

Estime el modelo con los coches 1 a 28 y con los coches 29 a 57.

`smpl 1 28` deja activas las 28 primeras observaciones y la regresión que sigue se estima solo con ellas. `smpl 29 57` hace lo mismo con la segunda mitad, y `smpl full` restablece los 57 coches antes de seguir.

en línea de comandos (o `Muestra ->Establecer rango`):

```
printf "La misma regresion en dos mitades de la muestra:\n"
smpl 1 28
ols cost const age miles
printf "obs 1-28 : coef(age) = %8.3f (ee %6.3f)   coef(miles) = %9.3f (ee %7.3f)   s = %.1f\n", $coeff(age), $stderr(age),
↪  $coeff(miles), $stderr(miles), $sigma
smpl 29 57
ols cost const age miles
printf "obs 29-57: coef(age) = %8.3f (ee %6.3f)   coef(miles) = %9.3f (ee %7.3f)   s = %.1f\n", $coeff(age), $stderr(age),
↪  $coeff(miles), $stderr(miles), $sigma
smpl full
```

```
La misma regresion en dos mitades de la muestra:

Modelo 4: MCO, usando las observaciones 1-28
Variable dependiente: cost

            coeficiente   Desv. típica   Estadístico t   valor p
  ------------------------------------------------------------
  const      -149,704        72,6969         -2,059       0,0500  *
  age           5,14157       4,62351         1,112       0,2767
  miles        -5,36813      30,4128         -0,1765      0,8613

Media de la vble. dep.  516,1429   D.T. de la vble. dep.   414,5243
Suma de cuad. residuos  507960,8   D.T. de la regresión    142,5427
R-cuadrado              0,890512   R-cuadrado corregido    0,881753
F(2, 25)                101,6678   Valor p (de F)          9,82e-13
Log-verosimilitud      -177,0137   Criterio de Akaike      360,0273
Criterio de Schwarz     364,0239   Crit. de Hannan-Quinn   361,2491

obs 1-28 : coef(age) =    5,142 (ee  4,624)   coef(miles) =    -5,368 (ee  30,413)   s = 142,5

Modelo 5: MCO, usando las observaciones 29-57 (n = 29)
Variable dependiente: cost

            coeficiente   Desv. típica   Estadístico t   valor p
  ------------------------------------------------------------
  const       -975,847      774,808          -1,259       0,2191
  age           23,7238       8,23016         2,883       0,0078  ***
  miles       -107,742       69,5516         -1,549       0,1334

Media de la vble. dep.  2305,724   D.T. de la vble. dep.   924,8631
Suma de cuad. residuos   2285691   D.T. de la regresión    296,4982
R-cuadrado              0,904566   R-cuadrado corregido    0,897225
F(2, 26)                123,2194   Valor p (de F)          5,45e-14
Log-verosimilitud      -204,6350   Criterio de Akaike      415,2700
Criterio de Schwarz     419,3719   Crit. de Hannan-Quinn   416,5547

obs 29-57: coef(age) =   23,724 (ee  8,230)   coef(miles) =  -107,742 (ee  69,552)   s = 296,5
```

Lo que debe observar

En una mitad el coeficiente de `miles` es −5 y en la otra −108; el de `age`, 5 y 24. Con la mitad de los datos las partes propias son más cortas todavía, los errores estándar se disparan y las coordenadas cambian con el azar de cada mitad. El fichero está ordenado por edad, así que las dos mitades son además coches jóvenes y coches viejos, y `s` cambia de una a otra; eso añade una diferencia real a la oscilación. Pero la lección es la de la nube de la práctica A (actividad 2 (html)): con regresores alineados, los coeficientes individuales son lo primero que cambia de una muestra a otra.

Actividad 6 - Sustituir `age` por su parte propia

Guarde la parte propia de `age` (el residuo de su regresión auxiliar sobre `miles`) y úsela como regresor en lugar de `age`. Después prediga el coste de dos coches con los dos modelos.

La primera línea estima la regresión auxiliar de `age` sobre `miles` con `--quiet`; las dos siguientes guardan sus coeficientes en los escalares `a0` y `a1` (harán falta para la predicción), y la cuarta guarda sus residuos, `$uhat`, en una serie nueva, `uhatAge` (como en la actividad 4 (html) de la práctica D de la sesión 14). En los menús, en la ventana de la regresión auxiliar, `Guardar ->Residuos`. `corr` comprueba que el residuo no está correlado con `miles`. Después se estima `cost` sobre `miles` y `uhatAge`, y `vif` calcula los factores de inflación de ese modelo.

o bien teclee en línea de comandos:

```
ols age const miles --quiet
scalar a0 = $coeff(const)
scalar a1 = $coeff(miles)
series uhatAge = $uhat
corr uhatAge miles
ols cost const miles uhatAge
vif
```

```
corr(uhatAge, miles) = 0,00000000
Bajo la hipótesis nula de no correlación:
 t(55) = 2,41383e-13, con valor p a dos colas 1,0000


Modelo 6: MCO, usando las observaciones 1-57
Variable dependiente: cost

             coeficiente   Desv. típica   Estadístico t   valor p
  ------------------------------------------------------------------
  const       -796,075       80,0369         -9,946       8,27e-14 ***
  miles         53,4507       1,73809        30,75        6,66e-36 ***
  uhatAge       28,0163       2,77558        10,09        4,91e-14 ***

Media de la vble. dep.  1426,632   D.T. de la vble. dep.   1151,186
Suma de cuad. residuos   3637878   D.T. de la regresión    259,5537
R-cuadrado              0,950980   R-cuadrado corregido    0,949165
F(2, 54)                523,8010   Valor p (de F)          4,36e-36
Log-verosimilitud      -396,1995   Criterio de Akaike      798,3990
Criterio de Schwarz     804,5282   Crit. de Hannan-Quinn   800,7810


Factores de inflación de varianza (VIF)
Mínimo valor posible = 1.0
Valores mayores que 10.0 pueden indicar un problema de colinealidad

       miles    1,000
     uhatAge    1,000

VIF(j) = 1/(1 - R(j)^2), donde R(j) es el coeficiente de correlación múltiple
entre la variable j y las demás variables independientes
```

Lo que debe observar

`uhatAge` es la parte de la edad que no acompaña al kilometraje: cuántas semanas más (o menos) tiene un coche de las que corresponden a sus millas. Su correlación con `miles` es cero, por las ecuaciones normales de la regresión auxiliar, y el VIF de los dos regresores es 1.

Compare la tabla con la de la Actividad 2. SRC, R^2 y `s` = 259,55 son los mismos: `miles` y `uhatAge` generan con la constante el mismo subespacio que `age` y `miles`, y la proyección no depende de cómo se describa el subespacio. El coeficiente de `uhatAge` es el de `age` en la Actividad 2, 28,02, con el mismo error estándar, 2,78: los dos se calculan con la misma parte propia de la edad. Lo que ha cambiado es el coeficiente de `miles`: ahora es 53,45, el de la regresión simple de la Actividad 1. Ya no mide el efecto de las millas a edad fija (−155), sino el de las millas sin descontar nada: la identidad de la Actividad 2, leída al revés, da $53{,}45 \approx -154{,}6 + 28{,}02 \cdot 7{,}43$, donde 7,43 son las semanas de edad que, en la muestra, acompañan a cada mil millas (la pendiente de `age` sobre `miles`). Lo descontado es la edad, no las millas.

Los dos coeficientes tienen ahora el signo esperado y t grandes, pero la regresión auxiliar no ha añadido información. Ha asignado toda la variación que comparten `age` y `miles` al regresor `miles`, y a `uhatAge` solo lo que la edad tiene de propio. Con la asignación contraria (sustituir `miles` por su residuo sobre `age`), el coeficiente de `age` sería el de la regresión simple, 7,3, y el del residuo de `miles` seguiría siendo −155. Qué asignación es razonable lo decide el problema económico, no la estadística.

La predicción con los dos modelos

Para la predicción, los valores del coche se ponen en un vector fila `x0` con un 1 delante, por la constante. La predicción es `x0*$coeff`, el producto de ese vector por el vector de coeficientes del último modelo, y su error estándar es la raíz de `x0*$vcv*x0'`, la forma cuadrática con la matriz de covarianzas de los coeficientes (`x0'` es el vector traspuesto). En el modelo con `uhatAge` el coche no se describe por su edad, sino por su parte propia: la edad menos lo que las millas predicen de ella, `300 - (a0 + a1*mi)`. El bucle `loop foreach i 1 2` repite el cálculo para dos coches de 300 semanas: `mi` vale 40 mil millas en la primera vuelta y 10 en la segunda (la expresión `(i = 1) ? 40 : 10`= elige el primer valor si la condición se cumple y el segundo si no).

en línea de comandos:

```
loop foreach i 1 2
    scalar mi = (i == 1) ? 40 : 10
    printf "Coche de 300 semanas y %d mil millas\n", mi
    ols cost const age miles --quiet
    matrix x0 = {1, 300, mi}
    printf "   modelo con age:     prediccion = %8.1f   ee = %6.1f\n", x0*$coeff, sqrt(x0*$vcv*x0')
    ols cost const miles uhatAge --quiet
    matrix x0 = {1, mi, 300 - (a0 + a1*mi)}
    printf "   modelo con uhatAge: prediccion = %8.1f   ee = %6.1f   (uhatAge del coche = %.1f)\n", x0*$coeff,
    ↪  sqrt(x0*$vcv*x0'), 300 - (a0 + a1*mi)
endloop
```

```
Coche de 300 semanas y 40 mil millas
   modelo con age:     prediccion =   2245,7   ee =   95,9
   modelo con uhatAge: prediccion =   2245,7   ee =   95,9   (uhatAge del coche = 32,3)
Coche de 300 semanas y 10 mil millas
   modelo con age:     prediccion =   6884,7   ee =  710,9
   modelo con uhatAge: prediccion =   6884,7   ee =  710,9   (uhatAge del coche = 255,1)
```

Lo que debe observar

Las predicciones son las mismas con los dos modelos, y con el mismo error estándar: el coche típico, de 300 semanas y 40 mil millas, cuesta 2 246 dólares con un error estándar de 96; el de 300 semanas y 10 mil millas, 6 885 con un error estándar de 711. Sustituir `age` por su parte propia no cambia nada de la predicción, porque el ajuste es el mismo. Lo que sí cambia de un coche a otro es la precisión: el segundo coche está dentro del rango de cada variable, pero su parte propia de edad es 255 semanas cuando las de la muestra no pasan de unas pocas decenas; está lejos de la recta de la Actividad 1, y predecir ahí es extrapolar.

Preguntas de interpretación para la clase

1. En la Actividad 2, el coeficiente de `miles` pasa de $+53$ a -155 al añadir `age`. Explique con la parte propia por qué el coeficiente de la regresión múltiple no tiene por qué parecerse al de la simple.

2. Compruebe la identidad $7{,}34 \approx 28{,}02 - 154{,}6 \cdot 0{,}134$ y diga qué representa cada uno de los tres números de la derecha.

3. Con un VIF de 142, ¿por qué los dos coeficientes son significativos? ¿Qué tendría que valer el coeficiente de `miles` para no serlo?

4. Un taller quiere predecir el coste de reparaciones de un coche de 300 semanas y 40 mil millas, valores típicos de la muestra. ¿Le preocupa la colinealidad para esa predicción? ¿Y para un coche de 300 semanas y 10 mil millas?

5. Si tuviera que informar del efecto de la edad sobre el coste, ¿qué modelo usaría y qué diría del coeficiente de `miles`?

6. En la Actividad 6, ¿por qué el coeficiente de `uhatAge` coincide con el de `age` de la Actividad 2, y el de `miles` con el de su regresión simple? ¿Ha resuelto la regresión auxiliar la colinealidad?

Para profundizar

- Lección 14 (lección 14), "Síntomas y diagnóstico" y "Qué es y qué no es".
- Lección 10 (lección 10), el coeficiente de regresión múltiple como coordenada, y la familia ortogonal como único caso en que coincide con el simple.
- Ramanathan, R. (2002). *Introductory Econometrics with Applications*, 5.ª ed., ejemplo 5.2 y sección 5.4 sobre multicolinealidad.
- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 3, sección 3.4.

Código completo de la práctica

```
# ------------------------------------------------------------
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# ------------------------------------------------------------

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
↪  directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#    DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
↪  trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

set verbose off

open data3-7.gdt --quiet
outfile --quiet descripcion.txt
    labels
    summary cost age miles --simple
    corr age miles
end outfile

outfile --quiet simples.txt
    ols cost const age
    printf "cost ~ age:    coef(age)   = %8.3f   ee = %7.3f   t = %6.2f   R2 = %.4f   s = %.1f\n",
    ↪  $coeff(age), $stderr(age), $coeff(age)/$stderr(age), $rsq, $sigma
    ols cost const miles
    printf "cost ~ miles:  coef(miles) = %8.3f   ee = %7.3f   t = %6.2f   R2 = %.4f   s = %.1f\n",
    ↪  $coeff(miles), $stderr(miles), $coeff(miles)/$stderr(miles), $rsq, $sigma
end outfile
gnuplot miles age --output="@workdir/milesAge.png"

outfile --quiet conjunto.txt
    ols cost const age miles
    vif
end outfile

outfile --quiet partesPropias.txt
    ols age const miles --quiet
    printf "parte propia de age   sobre miles: ||.|| = %8.3f    ||age en desviaciones||   = %8.3f    R2aux
    ↪  = %.4f\n", sqrt($ess), sqrt(sum((age-mean(age))^2)), $rsq
    ols miles const age --quiet
    scalar longPropiaMiles = sqrt($ess)
    printf "parte propia de miles sobre age:   ||.|| = %8.3f    ||miles en desviaciones|| = %8.3f    R2aux
    ↪  = %.4f\n", longPropiaMiles, sqrt(sum((miles-mean(miles))^2)), $rsq
    ols cost const age miles --quiet
    printf "s = %.3f ;  s/||parte propia de miles|| = %.3f ;  ee(miles) de Gretl = %.3f\n", $sigma,
    ↪  $sigma/longPropiaMiles, $stderr(miles)
end outfile

ols cost const age miles --quiet
scalar df = $df
restrict --quiet
    b[age] = 0
end restrict
scalar F_age = $test
restrict --quiet
```

```
    b[miles] = 0
end restrict
scalar F_miles = $test
outfile --quiet contrastes.txt
    scalar tc = critical(t, df, 0.025)
    printf "Modelo completo: t(age) = %.2f   t(miles) = %.2f   t_c = %.3f\n", $coeff(age)/$stderr(age),
    ↪  $coeff(miles)/$stderr(miles), tc
    printf "IC 95%% de age:   [%.2f ; %.2f]\n", $coeff(age) - tc*$stderr(age), $coeff(age) +
    ↪  tc*$stderr(age)
    printf "IC 95%% de miles: [%.1f ; %.1f]\n", $coeff(miles) - tc*$stderr(miles), $coeff(miles) +
    ↪  tc*$stderr(miles)
    printf "F de significacion conjunta (pie de tabla) = %.1f   F_c(2,%d) = %.3f\n", $Fstat, df,
    ↪  critical(F, 2, df, 0.05)
    printf "Omitir age:   F(1,%d) = %.2f = t^2   valor p = %.2e\n", df, F_age, pvalue(F, 1, df, F_age)
    printf "Omitir miles: F(1,%d) = %.2f = t^2   valor p = %.2e\n", df, F_miles, pvalue(F, 1, df, F_miles)
    printf "correlacion entre los estimadores de age y miles: %.4f\n", $vcv[2,3]/sqrt($vcv[2,2]*$vcv[3,3])
end outfile

outfile --quiet submuestras.txt
    printf "La misma regresion en dos mitades de la muestra:\n"
    smpl 1 28
    ols cost const age miles
    printf "obs 1-28 : coef(age) = %8.3f (ee %6.3f)   coef(miles) = %9.3f (ee %7.3f)   s = %.1f\n",
    ↪  $coeff(age), $stderr(age), $coeff(miles), $stderr(miles), $sigma
    smpl 29 57
    ols cost const age miles
    printf "obs 29-57: coef(age) = %8.3f (ee %6.3f)   coef(miles) = %9.3f (ee %7.3f)   s = %.1f\n",
    ↪  $coeff(age), $stderr(age), $coeff(miles), $stderr(miles), $sigma
    smpl full
end outfile

outfile --quiet ortogonal.txt
    ols age const miles --quiet
    scalar a0 = $coeff(const)
    scalar a1 = $coeff(miles)
    series uhatAge = $uhat
    corr uhatAge miles
    ols cost const miles uhatAge
    vif
end outfile

outfile --quiet prediccion.txt
    loop foreach i 1 2
        scalar mi = (i == 1) ? 40 : 10
        printf "Coche de 300 semanas y %d mil millas\n", mi
        ols cost const age miles --quiet
        matrix x0 = {1, 300, mi}
        printf "   modelo con age:     prediccion = %8.1f   ee = %6.1f\n", x0*$coeff, sqrt(x0*$vcv*x0')
        ols cost const miles uhatAge --quiet
        matrix x0 = {1, mi, 300 - (a0 + a1*mi)}
        printf "   modelo con uhatAge: prediccion = %8.1f   ee = %6.1f   (uhatAge del coche = %.1f)\n",
        ↪  x0*$coeff, sqrt(x0*$vcv*x0'), 300 - (a0 + a1*mi)
    endloop
end outfile
```

Enlace al guión: S22-Prct-C-ramanathan-coches.inp

Respuestas

1. *Por qué cambia tanto el coeficiente.* El coeficiente de `miles` en la regresión simple es la coordenada de $\widehat{\boldsymbol{y}}$ sobre `miles` en desviaciones, un vector de longitud 149. En la múltiple es la coordenada de $\widehat{\boldsymbol{y}}$ en la base $\{\mathbf{1}, \text{age}, \text{miles}\}$, y una coordenada depende de toda la base: con generadores casi alineados, la lección 14 mostró que el mismo ajuste admite descomposiciones muy distintas. Además, la lección 14 enunció que ese coeficiente se mide con la *parte propia* de `miles`, un vector de longitud 12,5 casi ortogonal a `miles` en desviaciones. Los dos coeficientes responden a preguntas distintas y no hay razón para que se parezcan, ni en tamaño ni en signo. Coinciden solo cuando los regresores son ortogonales (lección 10, familia ortogonal).

2. *La identidad.* 28,02 es el coeficiente de `age` en la múltiple; $-154{,}6$ el de `miles`; 0,134 es cuántas mil millas más tiene, en esta muestra, un coche una semana más viejo. La regresión simple de `cost` sobre `age` recoge el efecto directo de la edad más el efecto de las millas que la edad arrastra: $28{,}02 + (-154{,}6)(0{,}134) = 7{,}30$. La identidad es exacta salvo redondeo, y dice que el coeficiente de la simple no es "el efecto de la edad", sino el efecto de la edad *junto con todo lo que en la muestra se mueve con ella.*

3. *Significativos con VIF* 142. Porque el t es el coeficiente entre su error estándar, y el VIF solo infla el denominador: 20,7 en lugar de 1,74. Con un coeficiente de -155 el cociente sigue siendo $-7{,}5$. Para no ser significativo, el coeficiente de `miles` tendría que ser menor que $2{,}005 \cdot 20{,}7 \approx 41$ en valor absoluto; sin la colinealidad, bastaría con que fuera menor que 3,5. El VIF dice cuánta precisión se ha perdido, no si queda suficiente.

4. *Predicción.* Para el coche típico, no: 300 semanas y 40 mil millas está sobre la recta de la figura, y allí el ajuste es el mismo cualquiera que sea el reparto entre los dos coeficientes; la predicción usa $\widehat{\boldsymbol{y}}$, que la colinealidad no toca. Para el coche de 300 semanas y 10 mil millas, sí: está lejos de la recta, en una región donde no hay datos, y la predicción depende de la coordenada de `miles` por separado, $-155 \cdot (10 - 40) = +4\,640$ dólares sobre el coche típico. Ese número descansa en la parte propia de `miles`, que mide 12,5: es una extrapolación con un error estándar enorme.

5. *Qué informar.* Depende de la pregunta, y hay que decir cuál se responde. Si se quiere el efecto de la edad sin separar lo que la edad arrastra, la regresión simple, 7,3 dólares por semana, con su intervalo estrecho, y advertir que incluye el efecto del kilometraje. Si se quiere el efecto de la edad a kilometraje fijo, la múltiple, 28 con intervalo de 22 a 34, y advertir que en la muestra casi no hay coches con la misma edad y distinto kilometraje, que el coeficiente de `miles` es negativo y difícil de interpretar por separado, y que el VIF es 142. Lo que no se puede hacer es informar de -155 como "el efecto de rodar mil millas".

6. *Sustituir un regresor por su parte propia.* El coeficiente de un regresor en la regresión múltiple se calcula con su parte propia respecto a los demás. La parte propia de `uhatAge` respecto a `miles` es el propio `uhatAge`, que ya es ortogonal a `miles`; y es la misma que la de `age` respecto a `miles` en la Actividad 2. Por eso el coeficiente y el error estándar coinciden (28,02 y 2,78). `miles`, en cambio, es ortogonal a `uhatAge`, y con un regresor ortogonal su coeficiente es el de la regresión simple (lección 10, familia ortogonal): 53,45. La colinealidad no se ha resuelto, porque el subespacio, el ajuste y la parte propia de la edad son los mismos. Lo que ha cambiado es la pregunta que responde el coeficiente de `miles`: el efecto de las millas junto con la edad que las acompaña, en lugar del efecto de las millas a edad fija. Su error estándar es menor porque responde a una pregunta que la muestra sí permite responder con precisión.