

Sesión 22 (C) — Edad y kilómetros: colinealidad con coeficientes significativos

Marcos Bujosa

Descripción de la práctica

El caso `nox` y `lnox` es la forma más visible de la colinealidad: dos t pequeños y un F grande. Esta práctica muestra otra, menos visible: dos regresores casi alineados cuyos coeficientes son *significativos*, uno de ellos con un signo que nadie esperaría. Aquí el VIF no avisa de un t pequeño, sino de un coeficiente que no puede leerse como se lee normalmente.

Los datos son `data3-7` de Ramanathan: cincuenta y siete coches con su coste acumulado de reparaciones (`cost`, en dólares), su edad (`age`, en semanas) y los kilómetros recorridos (`miles`, en miles de millas). Edad y kilómetros crecen juntos: un coche que lleva más tiempo ha recorrido más. La pregunta es qué pasa cuando se pide al modelo que separe el efecto de cada uno.

Objetivos

1. Comparar las dos regresiones simples con la regresión múltiple: los coeficientes cambian de tamaño y uno cambia de signo.
2. Medir la colinealidad: correlación, partes propias y VIF, y comprobar de nuevo $ee(\hat{\beta}_j) = \mathfrak{s}/\|\tilde{\mathbf{x}}_j\|_e$.
3. Ver que un VIF de 142 es compatible con dos t grandes, y qué es lo que ese VIF sí está diciendo.
4. Comprobar la inestabilidad de las coordenadas estimando en dos mitades de la muestra.

Comandos nuevos de esta práctica. No hay ninguno: `open` y `labels` (sesión 4), `summary --simple` y el comando `corr` (sesión 7), `ols` y sus accesorios (sesiones 11 a 18), `vif` ([actividad 3 \(html\)](#) de la práctica B de hoy), `restrict` y `$test` (sesión 21), `$vcv` ([actividad 3 \(html\)](#) de la práctica B de la sesión 21 y [actividad 5 \(html\)](#) de la de hoy) y `smpl` (sesiones 14 a 18). Dos recordatorios:

`restrict ... end restrict` contrasta sobre el último modelo la restricción escrita dentro; `b[miles] = 0` se refiere al coeficiente de `miles`. Con `--quiet` no imprime las estimaciones restringidas, y `$test` recoge después el estadístico del contraste.

`smpl 1 28` restringe la muestra a las observaciones 1 a 28: todo lo que se estime después usa solo esas filas. `smpl full` devuelve la muestra completa. En los menús, `Muestra ->Establecer rango`.

Actividad 1 - Los datos y las dos regresiones simples

Abra `data3-7`, mire las variables y su correlación, y estime `cost` sobre `age` y `cost` sobre `miles` por separado.

`open` carga el fichero de muestra de Ramanathan (`--quiet` evita listar las variables) y `labels` muestra la descripción de cada una. `summary --simple` da media, mediana, desviación típica, mínimo y máximo de las tres variables, y el comando `corr` la correlación entre `age` y `miles`. Las dos últimas líneas estiman las dos regresiones simples, cada una con su tabla completa.

o bien teclee en línea de comandos:

```
open data3-7.gdt --quiet
labels
summary cost age miles --simple
corr age miles
ols cost const age
ols cost const miles
```

cost: cumulative repair cost in actual dollars (11 - 3425)
age: age of car in weeks of ownership (Range 5 - 538)
miles: miles driven in thousands (Range 0.8 - 74.4)

	Media	Mediana	D. T.	Min	Máx
cost	1427	1182	1151	11,00	3425
age	279,5	276,0	148,7	5,000	538,0
miles	41,58	43,40	19,96	0,8000	74,40

corr(age, miles) = 0,99646458
Bajo la hipótesis nula de no correlación:
t(55) = 87,9614, con valor p a dos colas 0,0000

cost ~ age:	coef(age) =	7,343	ee =	0,330	t =	22,28	R2 =	0,9003	s =	366,8
cost ~ miles:	coef(miles) =	53,451	ee =	2,926	t =	18,27	R2 =	0,8585	s =	437,0




Figura 1: miles frente a age: los cincuenta y siete coches están casi sobre una recta. La correlación es 0,9965.

Lo que debe observar

Las dos regresiones simples dicen lo esperable: en el ajuste, cada semana de edad va con unos 7 dólares más de reparaciones; cada mil millas, con unos 53. Los dos coeficientes son positivos, con t de 22 y de 18. Pero la figura muestra que las dos variables son casi la misma: la correlación es 0,9965, un ángulo de $4,8^\circ$, y en esta muestra “más viejo” y “más rodado” son casi indistinguibles.

Actividad 2 - Las dos juntas

Estime cost sobre age y miles, y pida los factores de inflación (Análisis ->Colinealidad).

La regresión con los dos regresores y, a continuación, `vif` sobre ese modelo ([actividad 3 \(html\)](#) de la práctica B).

o bien teclee en línea de comandos:

```
ols cost const age miles
vif
```

Modelo 1: MCO, usando las observaciones 1-57

Variable dependiente: cost

	coeficiente	Desv. típica	Estadístico t	valor p
const	26,1888	114,201	0,2293	0,8195
age	28,0163	2,77558	10,09	4,91e-14 ***
miles	-154,635	20,6882	-7,475	6,99e-10 ***

Media de la vble. dep.	1426,632	D.T. de la vble. dep.	1151,186
Suma de cuad. residuos	3637878	D.T. de la regresión	259,5537
R-cuadrado	0,950980	R-cuadrado corregido	0,949165
F(2, 54)	523,8010	Valor p (de F)	4,36e-36
Log-verosimilitud	-396,1995	Criterio de Akaike	798,3990
Criterio de Schwarz	804,5282	Crit. de Hannan-Quinn	800,7810

Factores de inflación de varianza (VIF)

Mínimo valor posible = 1.0

Valores mayores que 10.0 pueden indicar un problema de colinealidad

```
age 141,676
miles 141,676
```

$VIF(j) = 1/(1 - R(j)^2)$, donde $R(j)$ es el coeficiente de correlación múltiple entre la variable j y las demás variables independientes

Lo que debe observar

El coeficiente de `age` se ha multiplicado casi por cuatro, de 7,3 a 28,0, y el de `miles` ha cambiado de signo: de +53 a -155. Los dos son significativos, con t de 10 y de -7,5. El ajuste es mejor que el de cualquiera de las simples: $R^2 = 0,951$ y $s = 260$ frente a 367 y 437. Y el VIF es 142 para los dos regresores (con $k = 3$ es el mismo para ambos, $1/(1 - \rho^2)$): el error estándar de cada coeficiente es $\sqrt{142} = 11,9$ veces el que tendría si el regresor estuviera solo.

Léase el signo con cuidado. -155 no dice que rodar abarate las reparaciones. Dice que, *a igual edad*, en el ajuste, un coche con más millas de las que corresponden a su edad tiene menos gasto acumulado; o, con la misma cuenta, que a igual kilometraje, un coche más viejo gasta mucho más. Los dos coeficientes describen el efecto de mover un regresor mientras el otro se queda quieto, y en esta muestra eso casi nunca ocurre. Compruébelo: $7,34 \approx 28,02 - 154,6 \cdot 0,134$, donde 0,134 es la pendiente de `miles` sobre `age` de la figura. Es la identidad que la práctica B de la sesión 14 ([actividad 2 \(html\)](#)) enunció para `rooms` y `nox`: la regresión simple mezcla los dos efectos en la proporción en que la muestra los mezcla.

Actividad 3 - Las partes propias y el error estándar

Mida la parte propia de cada regresor con la regresión auxiliar y compruebe la fórmula del error estándar con `miles`.

Regresión auxiliar de `miles` sobre `age` (con `--quiet`, porque solo queremos su `$ess`): la raíz es la longitud de la parte propia de `miles`. Después se vuelve a estimar el modelo completo y se imprime `s` entre esa longitud junto al error estándar de `miles` que da Gretl; `$sigma` y `$stderr` se refieren al modelo que acaba de estimarse.

en línea de comandos:

```

ols miles const age --quiet
scalar longPropiaMiles = sqrt($ess)
ols cost const age miles --quiet
printf "s/||parte propia de miles|| = %.3f    ee(miles) = %.3f\n", $sigma/longPropiaMiles, $stderr(miles)

```

```

parte propia de age    sobre miles: ||.|| =    93,513    ||age en desviaciones||    = 1113,071    R2aux = 0,9929
parte propia de miles sobre age:    ||.|| =    12,546    ||miles en desviaciones|| = 149,332    R2aux = 0,9929
s = 259,554 ;    s/||parte propia de miles|| = 20,688 ;    ee(miles) de Gretl = 20,688

```

Lo que debe observar

La parte propia de `miles` mide 12,5 cuando el regresor en desviaciones mide 149: queda el 8,4% de su longitud, que es $\sqrt{1 - 0,9929} = \sin 4,8^\circ$. Y $259,55/12,546 = 20,69$, el error estándar de la tabla. Lo mismo para `age`: 93,5 de 1113. Los dos regresores son largos, tienen mucha variación; lo que no tienen es variación *por separado*.

Actividad 4 - Contrastes: t grandes con un VIF de 142

Compare los t individuales, el F conjunto y el F de omitir cada regresor, y lea la correlación entre los dos estimadores.

Sobre el modelo completo, el bloque `restrict` contrasta que el coeficiente de `miles` sea cero, y el F resultante queda en `$test`. La correlación entre los dos estimadores se lee en `$vcv`: la fila 2 y la columna 3 corresponden a `age` y `miles`, segundo y tercer coeficiente de la lista (el primero es la constante). El guion completo añade los intervalos, el F global del pie de la tabla (`$Fstat`) y los valores p con `pvalue` (sesión 18).

en línea de comandos:

```

ols cost const age miles --quiet
restrict --quiet
    b[miles] = 0
end restrict
printf "Omitir miles: F = %.2f\n", $test
printf "correlacion entre los estimadores: %.4f\n", $vcv[2,3]/sqrt($vcv[2,2]*$vcv[3,3])

```

```

Modelo completo: t(age) = 10,09    t(miles) = -7,47    t_c = 2,005
IC 95% de age:    [22,45 ; 33,58]
IC 95% de miles: [-196,1 ; -113,2]
F de significacion conjunta (pie de tabla) = 523,8    F_c(2,54) = 3,168
Omitir age:    F(1,54) = 101,89 = t^2    valor p = 4,91e-14
Omitir miles: F(1,54) = 55,87 = t^2    valor p = 6,99e-10
correlacion entre los estimadores de age y miles: -0,9965

```

Lo que debe observar

Con un VIF de 142, los dos coeficientes son significativos y el contraste rechaza omitir cualquiera de los dos: las partes propias son cortas, pero los coeficientes son tan grandes que sus t superan de sobra el umbral. El VIF no es un veredicto sobre la significación; es la escala del error estándar. Aquí dice que el intervalo de `miles`, de -196 a -113 , sería doce veces más estrecho si `miles` no compartiera casi todo con `age`. Y la correlación entre los dos estimadores, $-0,9965$, dice que si en otra muestra el coeficiente de `age` saliera menor, el de `miles` saldría menos negativo en la misma medida: la pareja está bien determinada; el reparto, no.

Actividad 5 - La misma regresión en dos mitades

Estime el modelo con los coches 1 a 28 y con los coches 29 a 57.

`smpl 1 28` deja activas las 28 primeras observaciones y la regresión que sigue se estima solo con ellas. `smpl 29 57` hace lo mismo con la segunda mitad, y `smpl full` restablece los 57 coches antes de seguir.
en línea de comandos (o Muestra ->Establecer rango):

```
smpl 1 28
ols cost const age miles
smpl 29 57
ols cost const age miles
smpl full
```

La misma regresión en dos mitades de la muestra:

```
obs 1-28 : coef(age) =    5,142 (ee  4,624)   coef(miles) =   -5,368 (ee 30,413)   s = 142,5
obs 29-57: coef(age) =   23,724 (ee  8,230)   coef(miles) =  -107,742 (ee 69,552)   s = 296,5
```

Lo que debe observar

En una mitad el coeficiente de `miles` es -5 y en la otra -108 ; el de `age`, 5 y 24 . Con la mitad de los datos las partes propias son más cortas todavía, los errores estándar se disparan y las coordenadas cambian con el azar de cada mitad. El fichero está ordenado por edad, así que las dos mitades son además coches jóvenes y coches viejos, y s cambia de una a otra; eso añade una diferencia real a la oscilación. Pero la lección es la de la nube de la práctica A ([actividad 2 \(html\)](#)): con regresores alineados, los coeficientes individuales son lo primero que cambia de una muestra a otra.

Preguntas de interpretación para la clase

1. En la Actividad 2, el coeficiente de `miles` pasa de $+53$ a -155 al añadir `age`. Explique con la parte propia por qué el coeficiente de la regresión múltiple no tiene por qué parecerse al de la simple.
2. Compruebe la identidad $7,34 \approx 28,02 - 154,6 \cdot 0,134$ y diga qué representa cada uno de los tres números de la derecha.
3. Con un VIF de 142, ¿por qué los dos coeficientes son significativos? ¿Qué tendría que valer el coeficiente de `miles` para no serlo?
4. Un taller quiere predecir el coste de reparaciones de un coche de 300 semanas y 40 mil millas, valores típicos de la muestra. ¿Le preocupa la colinealidad para esa predicción? ¿Y para un coche de 300 semanas y 10 mil millas?
5. Si tuviera que informar del efecto de la edad sobre el coste, ¿qué modelo usaría y qué diría del coeficiente de `miles`?

Para profundizar

- Lección 14 ([lección 14](#)), “Síntomas y diagnóstico” y “Qué es y qué no es”.
- Lección 10 ([lección 10](#)), el coeficiente de regresión múltiple como coordenada, y la familia ortogonal como único caso en que coincide con el simple.
- Ramanathan, R. (2002). *Introductory Econometrics with Applications*, 5.^a ed., ejemplo 5.2 y sección 5.4 sobre multicolinealidad.
- Wooldridge, J. M. (2020). *Introductory Econometrics*, cap. 3, sección 3.4.

Código completo de la práctica

```
# -----
# Copyright (C) 2026 Marcos Bujosa
# Licencia: GNU General Public License v3.0 o posterior
# Este código es software libre y puede ser redistribuido y/o modificado bajo los términos de la GPL.
# Ver el archivo LICENSE del repositorio para más detalles.
# -----

# Los dos primeros comandos son necesarios para que Gretl guarde los resultados de la práctica en el
# ↪ directorio de trabajo
# al ejecutar lo siguiente desde un terminal (use los nombres y ruta que correspondan)
#
#   DIRECTORIO="Nombre_Directorio_trabajo" gretlcli -b ruta/nombre_fichero_de_la_practica.inp
#
# Si esto no le funciona en su sistema, comente las siguientes dos líneas y sitúese en el directorio de
# ↪ trabajo de gretl
# que corresponda (configure dicho directorio de trabajo desde la ventana principal de Gretl).

string directory = getenv("DIRECTORIO")
set workdir "@directory"

set verbose off

open data3-7.gdt --quiet
outfile --quiet descripcion.txt
    labels
    summary cost age miles --simple
    corr age miles
end outfile
outfile --quiet simples.txt
    ols cost const age --quiet
    printf "cost ~ age:      coef(age)      = %8.3f    ee = %7.3f    t = %6.2f    R2 = %.4f    s = %.1f\n",
    ↪ $coeff(age), $stderr(age), $coeff(age)/$stderr(age), $rsq, $sigma
    ols cost const miles --quiet
    printf "cost ~ miles:    coef(miles) = %8.3f    ee = %7.3f    t = %6.2f    R2 = %.4f    s = %.1f\n",
    ↪ $coeff(miles), $stderr(miles), $coeff(miles)/$stderr(miles), $rsq, $sigma
end outfile
gnuplot cost age --output="@workdir/costAge.png"
gnuplot miles age --output="@workdir/milesAge.png"

outfile --quiet conjunto.txt
    ols cost const age miles
    vif
end outfile

outfile --quiet partesPropias.txt
    ols age const miles --quiet
    printf "parte propia de age    sobre miles: ||.|| = %8.3f    ||age en desviaciones|| = %8.3f    R2aux
    ↪ = %.4f\n", sqrt($ess), sqrt(sum((age-mean(age))^2)), $rsq
    ols miles const age --quiet
    scalar longPropiaMiles = sqrt($ess)
    printf "parte propia de miles sobre age: ||.|| = %8.3f    ||miles en desviaciones|| = %8.3f    R2aux
    ↪ = %.4f\n", longPropiaMiles, sqrt(sum((miles-mean(miles))^2)), $rsq
    ols cost const age miles --quiet
    printf "s = %.3f ; s/||parte propia de miles|| = %.3f ; ee(miles) de Gretl = %.3f\n", $sigma,
    ↪ $sigma/longPropiaMiles, $stderr(miles)
end outfile

ols cost const age miles --quiet
scalar df = $df
restrict --quiet
    b[age] = 0
end restrict
scalar F_age = $test
restrict --quiet
```

```

    b[miles] = 0
end restrict
scalar F_miles = $test
outfile --quiet contrastes.txt
    scalar tc = critical(t, df, 0.025)
    printf "Modelo completo: t(age) = %.2f   t(miles) = %.2f   t_c = %.3f\n", $coeff(age)/$stderr(age),
    ↪ $coeff(miles)/$stderr(miles), tc
    printf "IC 95% de age:   [%.2f ; %.2f]\n", $coeff(age) - tc*$stderr(age), $coeff(age) +
    ↪ tc*$stderr(age)
    printf "IC 95% de miles: [%.1f ; %.1f]\n", $coeff(miles) - tc*$stderr(miles), $coeff(miles) +
    ↪ tc*$stderr(miles)
    printf "F de significacion conjunta (pie de tabla) = %.1f   F_c(2,%d) = %.3f\n", $Fstat, df,
    ↪ critical(F, 2, df, 0.05)
    printf "Omitir age:   F(1,%d) = %.2f = t^2   valor p = %.2e\n", df, F_age, pvalue(F, 1, df, F_age)
    printf "Omitir miles: F(1,%d) = %.2f = t^2   valor p = %.2e\n", df, F_miles, pvalue(F, 1, df, F_miles)
    printf "correlacion entre los estimadores de age y miles: %.4f\n", $vcv[2,3]/sqrt($vcv[2,2]*$vcv[3,3])
end outfile

outfile --quiet submuestras.txt
    printf "La misma regresion en dos mitades de la muestra:\n"
    smpl 1 28
    ols cost const age miles --quiet
    printf "obs 1-28 : coef(age) = %.3f (ee %.6.3f)   coef(miles) = %.9.3f (ee %.7.3f)   s = %.1f\n",
    ↪ $coeff(age), $stderr(age), $coeff(miles), $stderr(miles), $sigma
    smpl 29 57
    ols cost const age miles --quiet
    printf "obs 29-57: coef(age) = %.3f (ee %.6.3f)   coef(miles) = %.9.3f (ee %.7.3f)   s = %.1f\n",
    ↪ $coeff(age), $stderr(age), $coeff(miles), $stderr(miles), $sigma
    smpl full
end outfile

```

Enlace al guión: [S22-Prct-C-ramanathan-coches.inp](#)

Respuestas

1. *Por qué cambia tanto el coeficiente.* El coeficiente de **miles** en la regresión simple es la coordenada de $\hat{y}$ sobre **miles** en desviaciones, un vector de longitud 149. En la múltiple es la coordenada de $\hat{y}$ en la base $\{1, \text{age}, \text{miles}\}$, y una coordenada depende de toda la base: con generadores casi alineados, la lección 14 mostró que el mismo ajuste admite descomposiciones muy distintas. Además, la lección 14 enunció que ese coeficiente se mide con la *parte propia* de **miles**, un vector de longitud 12,5 casi ortogonal a **miles** en desviaciones. Los dos coeficientes responden a preguntas distintas y no hay razón para que se parezcan, ni en tamaño ni en signo. Coinciden solo cuando los regresores son ortogonales (lección 10, familia ortogonal).
2. *La identidad.* 28,02 es el coeficiente de **age** en la múltiple; $-154,6$ el de **miles**; 0,134 es cuántas mil millas más tiene, en esta muestra, un coche una semana más viejo. La regresión simple de **cost** sobre **age** recoge el efecto directo de la edad más el efecto de las millas que la edad arrastra: $28,02 + (-154,6)(0,134) = 7,30$. La identidad es exacta salvo redondeo, y dice que el coeficiente de la simple no es “el efecto de la edad”, sino el efecto de la edad *junto con todo lo que en la muestra se mueve con ella*.
3. *Significativos con VIF 142.* Porque el t es el coeficiente entre su error estándar, y el VIF solo infla el denominador: 20,7 en lugar de 1,74. Con un coeficiente de -155 el cociente sigue siendo $-7,5$. Para no ser significativo, el coeficiente de **miles** tendría que ser menor que $2,005 \cdot 20,7 \approx 41$ en valor absoluto; sin la colinealidad, bastaría con que fuera menor que 3,5. El VIF dice cuánta precisión se ha perdido, no si queda suficiente.
4. *Predicción.* Para el coche típico, no: 300 semanas y 40 mil millas está sobre la recta de la figura, y allí el ajuste es el mismo cualquiera que sea el reparto entre los dos coeficientes; la predicción usa $\hat{y}$, que la colinealidad no toca. Para el coche de 300 semanas y 10 mil millas, sí: está lejos de la recta, en una región donde no hay datos, y la predicción depende de la coordenada de **miles** por separado, $-155 \cdot (10 - 40) = +4640$ dólares sobre el coche típico. Ese número descansa en la parte propia de **miles**, que mide 12,5: es una extrapolación con un error estándar enorme.
5. *Qué informar.* Depende de la pregunta, y hay que decir cuál se responde. Si se quiere el efecto de la edad sin separar lo que la edad arrastra, la regresión simple, 7,3 dólares por semana, con su intervalo estrecho, y advertir que incluye el efecto del kilometraje. Si se quiere el efecto de la edad a kilometraje fijo, la múltiple, 28 con intervalo de 22 a 34, y advertir que en la muestra casi no hay coches con la misma edad y distinto kilometraje, que el coeficiente de **miles** es negativo y difícil de interpretar por separado, y que el VIF es 142. Lo que no se puede hacer es informar de -155 como “el efecto de rodar mil millas”.